PREDIKSI HARGA KOMODITAS PANGAN DI JAWA TENGAH MENGGUNAKAN METODE LONG SHORT-TERM MEMORY

SKRIPSI

Oleh :
SANIA NABILA SALSABILA
NIM. 220605110047

PROGRAM STUDI TEKNIK INFORMATIKA
FAKULTAS SAINS DAN TEKNOLOGI
UNIVERSITAS ISLAM NEGERI MAULANA MALIK IBRAHIM
MALANG
2025

PREDIKSI HARGA KOMODITAS PANGAN DI JAWA TENGAH MENGGUNAKAN METODE LONG SHORT-TERM MEMORY

SKRIPSI

Diajukan kepada:
Universitas Islam Negeri Maulana Malik Ibrahim Malang
Untuk memenuhi Salah Satu Persyaratan dalam
Memperoleh Gelar Sarjana Komputer (S.Kom)

Oleh :
SANIA NABILA SALSABILA
NIM. 220605110047

PROGRAM STUDI TEKNIK INFORMATIKA
FAKULTAS SAINS DAN TEKNOLOGI
UNIVERSITAS ISLAM NEGERI MAULANA MALIK IBRAHIM MALANG
2025

HALAMAN PERSETUJUAN

PREDIKSI HARGA KOMODITAS PANGAN DI JAWA TENGAH MENGGUNAKAN METODE LONG SHORT-TERM MEMORY

SKRIPSI

Oleh :
SANIA NABILA SALSABILA
NIM. 220605110047

Telah Diperiksa dan Disetujui untuk Diuji:
Tanggal: 09 Desember 2025

Pembimbing I,	Pembimbing II,
Prof. Dr. Suhartono S.Si M.Kom	Dr. M. Imamudin Lc, MA
NIP. 19680519 200312 1 001	NIP. 19740602 200901 1 010

Mengetahui,
Ketua Program Studi Teknik Informatika
Fakultas Sains dan Teknologi
Universitas Islam Negeri Maulana Malik Ibrahim Malang

Supriyono, M. Kom
NIP. 19841010 201903 1 012

HALAMAN PENGESAHAN

PREDIKSI HARGA KOMODITAS PANGAN DI JAWA TENGAH MENGGUNAKAN METODE LONG SHORT-TERM MEMORY

SKRIPSI

Oleh :
SANIA NABILA SALSABILA
NIM. 220605110047

Telah Dipertahankan di Depan Dewan Penguji Skripsi
dan Dinyatakan Diterima Sebagai Salah Satu Persyaratan
Untuk Memperoleh Gelar Sarjana Komputer (S.Kom)
Tanggal: 22 Desember 2025

Susunan Dewan Penguji

Ketua Penguji	: Supriyono, M. Kom NIP. 19841010 201903 1 012	( )
Anggota Penguji I	: Tri Mukti Lestari, M.Kom NIP. 19911108 202012 2 005	( )
Anggota Penguji II	: Prof. Dr. Suhartono S.Si M.Kom NIP. 19680519 200312 1 001	( )
Anggota Penguji III	: Dr. M. Imamudin Lc, MA NIP. 19740602 200901 1 010	( )

Mengetahui dan Mengesahkan,
Ketua Program Studi Teknik Informatika
Fakultas Sains dan Teknologi
Universitas Islam Negeri Maulana Malik Ibrahim Malang

Supriyono, M. Kom
NIP. 19841010 201903 1 012

PERNYATAAN KEASLIAN TULISAN

Saya yang bertanda tangan di bawah ini:

Nama	: Sania Nabila Salsabila
NIM	: 220605110047
Fakultas / Program Studi	: Sains dan Teknologi / Teknik Informatika
Judul Skripsi	: Prediksi Harga Komoditas Pangan Di Jawa Tengah Menggunakan Metode Long Short-Term Memory.

Menyatakan dengan sebenarnya bahwa Skripsi yang saya tulis ini benar-benar merupakan hasil karya saya sendiri, bukan merupakan pengambil alihan data, tulisan, atau pikiran orang lain yang saya akui sebagai hasil tulisan atau pikiran saya sendiri, kecuali dengan mencantumkan sumber cuplikan pada daftar pustaka.

Apabila dikemudian hari terbukti atau dapat dibuktikan skripsi ini merupakan hasil jiplakan, maka saya bersedia menerima sanksi atas perbuatan tersebut.

Malang, 26 Desember 2025
Yang membuat pernyataan,



Sania Nabila Salsabila
NIM.220605110047

MOTTO

"Life is always going to be hard, so we need to push for what we want"

HALAMAN PERSEMBAHAN

Dengan penuh rasa syukur kepada Allah SWT, skripsi ini penulis persembahkan untuk ayah saya, Nur Slamet, dan ibu saya, Yuda Erwiyanti, atas doa, kasih sayang, serta dukungan yang tidak pernah berhenti mengiringi setiap langkah saya. Untuk para dosen yang telah membimbing, mengarahkan, dan berbagi ilmu selama masa studi. Untuk sahabat dan teman-teman seperjuangan yang telah menemani dalam berbagai proses, baik suka maupun duka. Dan, untuk diri saya sendiri yang telah berusaha menyelesaikan setiap proses dan memilih untuk terus melangkah hingga akhirnya skripsi ini dapat diselesaikan.

KATA PENGANTAR

Puji syukur penulis panjatkan ke hadirat Allah SWT atas limpahan rahmat, karunia, dan kemudahan-Nya sehingga penulis dapat menyelesaikan skripsi yang berjudul "Prediksi Harga Komoditas Pangan di Jawa Tengah Menggunakan Metode Long Short-Term Memory (LSTM)" sebagai salah satu syarat untuk memperoleh gelar Sarjana Komputer pada Program Studi Teknik Informatika, Fakultas Sains dan Teknologi, Universitas Islam Negeri Maulana Malik Ibrahim Malang.

Dalam proses penyusunan skripsi ini, penulis menyadari bahwa banyak pihak yang telah memberikan dukungan, bimbingan, dan doa. Oleh karena itu, dengan segala kerendahan hati, penulis menyampaikan ucapan terima kasih dan penghargaan yang sebesar-besarnya kepada:.

1. Prof. Ilfi Nur Diana, selaku Rektor Universitas Islam Negeri Maulana Malik Ibrahim Malang.
2. Dr. Agus Mulyono, M.Kes, selaku Dekan Fakultas Sains dan Teknologi Universitas Islam Negeri Maulana Malik Ibrahim Malang.
3. Bapak Supriyono, M.Kom, selaku Ketua Program Studi Teknik Informatika sekaligus Ketua Penguji, atas arahan, perhatian, serta masukan yang berharga bagi penyempurnaan skripsi ini.
4. Prof. Dr. Suhartono, S.Si., M.Kom., selaku Dosen Pembimbing I yang telah meluangkan waktu, memberikan bimbingan, arahan, serta masukan konstruktif dalam proses penelitian ini.
5. Dr. M. Imamudin, Lc., M.A., selaku Dosen Pembimbing II yang juga telah memberikan bimbingan, motivasi, dan panduan ilmiah selama penyusunan skripsi.
6. Ibu Tri Mukti Lestari, M.Kom., selaku Anggota Penguji I, atas saran dan evaluasi yang membangun dalam proses ujian skripsi.
7. Bapak Okta Qomaruddin Aziz, M.Kom., selaku dosen yang telah bersedia membimbing dan menjawab berbagai pertanyaan penulis selama proses penyusunan skripsi ini.
8. Diri sendiri, yang telah berusaha, bertahan, dan terus belajar hingga skripsi ini dapat terselesaikan.
9. Ayah Nur Slamet dan ibu Yuda Erwiyanti, atas segala doa, kasih sayang, dukungan moral, finansial, dan material, serta kesabaran yang tidak pernah berhenti dalam mendampingi penulis selama proses perkuliahan.
10. Kakak, adik, dan seluruh keluarga besar, yang memberikan semangat, doa, dan dorongan dalam setiap langkah penulis
11. Izza Syahri Ramadhan, teman dekat yang telah menemani penulis selama masa perkuliahan, mendengarkan keluh kesah, dan memberikan dukungan yang berarti.
12. Teman dekat penulis lainnya, yang menemani penulis dan mendengarkan keluh kesah penulis selama masa penulisan dan penyusuan skripsi.
13. Seluruh teman seangkatan dan rekan mahasiswa di Program Studi Teknik Informatika, atas kebersamaan, kerja sama, serta bantuan-bantuan kecil yang berarti selama masa studi.

14. Taeyong NCT, yang menjadi salah satu penyemangat penulis dalam menjalani proses perkuliahan dan penyusunan skripsi.
15. CW Coffee, Kopi Kenangan, Tomoro Coffee, dan Cafe 24 Jam Malang lainnya yang menjadi tempat penulis belajar dan menyelesaikan tugas-tugas perkuliahan, serta para driver Gojek dan Grab yang membantu mobilitas penulis selama masa studi.

Malang, 26 Desember 2025



Penulis

DAFTAR ISI

HALAMAN PERSETUJUAN ..... **iii**
HALAMAN PENGESAHAN ..... **iv**
PERNYATAAN KEASLIAN TULISAN ..... **v**
MOTTO ..... **vi**
HALAMAN PERSEMBAHAN ..... **vii**
KATA PENGANTAR ..... **viii**
DAFTAR ISI ..... **x**
DAFTAR GAMBAR ..... **xiii**
DAFTAR TABEL ..... **xvi**
ABSTRAK ..... **xviii**
ABSTRACT ..... **xix**
الملخص ..... **xx**
BAB I PENDAHULUAN **1**
1.1 Latar Belakang 1
1.2 Rumusan Masalah 5
1.3 Batasan Masalah 5
1.4 Tujuan Penelitian 5
1.5 Manfaat Penelitian 5
BAB II STUDI PUSTAKA **7**
2.1 Penelitian Terdahulu 7
2.2 Harga Komoditas Pangan 11
2.3 Prediksi 11
2.4 Time Series 13
2.5 Pre-Processing 15
2.5.1 Transformasi Data 15
2.5.2 Data Cleaning 15
2.5.3 Exploratory Data Analysis (EDA) 16
2.5.4 Missing Value 16
2.5.5 Normalisasi Data 17
2.5.6 Split Data 18
2.5.7 Sliding Window 18
2.6 *Long Short-Term Memory* (LSTM) 19
2.7 *Mean Absolute Percentage Error* (MAPE) 24
BAB III DESAIN DAN IMPLEMENTASI **26**
3.1 Desain Sistem 26
3.2 Pengumpulan Data 27
3.3 Pre-processing 28
3.3.1 Transformasi Data 29
3.3.2 Cleaning data 30
3.3.3 Exploratory Data Analysis (EDA) 31
3.3.4 Imputasi Missing Value 32
3.3.5 Normaliasi Data 34
3.3.6 Pembagian Data (Splitting Data) 35

3.3.7 Pembentukan Sliding Window 36
3.4 Implementasi Model Long Short-Term Memory (LSTM)..... 38
3.4.1 Arsitektur Model..... 39
3.4.2 Input Layer..... 41
3.4.3 Hidden Layer (Long Short-Term Memory)..... 42
3.4.6 Output Layer (Dense) 45
3.5 Training Model..... 46
3.6 Testing Model 48
3.7 Skenario Percobaan 49
3.8 Evaluasi Model 51
BAB IV HASIL DAN PEMBAHASAN 54
4.1 Skenario Uji Coba..... 54
4.2 Hasil Uji Coba 57
4.2.1 Hasil Uji Coba Skenario Univariate Komoditas Beras..... 58
4.2.2 Hasil Uji Coba Skenario Univariate Komoditas Daging Ayam 62
4.2.3 Hasil Uji Coba Skenario Univariate Komoditas Daging Sapi..... 67
4.2.4 Hasil Uji Coba Skenario Univariate Komoditas Telur Ayam 71
4.2.5 Hasil Uji Coba Skenario Univariate Komoditas Bawang Merah 75
4.2.6 Hasil Uji Coba Skenario Univariate Komoditas Cabai Merah..... 79
4.2.7 Hasil Uji Coba Skenario Univariate Komoditas Cabai Rawit..... 83
4.2.8 Hasil Uji Coba Skenario Univariate Komoditas Minyak Goreng 88
4.2.9 Hasil Uji Coba Skenario Univariate Komoditas Gula Pasir..... 92
4.2.10 Hasil Uji Coba Skenario Multivariate Komoditas Beras..... 96
4.2.11 Hasil Uji Coba Skenario Multivariate Komoditas Daging Ayam 100
4.2.12 Hasil Uji Coba Skenario Multivariate Komoditas Daging Sapi..... 104
4.2.13 Hasil Uji Coba Skenario Multivariate Komoditas Telur Ayam 109
4.2.14 Hasil Uji Coba Skenario Multivariate Komoditas Bawang Merah .. 113
4.2.15 Hasil Uji Coba Skenario Multivariate Komoditas Cabai Merah 117
4.2.16 Hasil Uji Coba Skenario Multivariate Komoditas Cabai Rawit..... 121
4.2.17 Hasil Uji Coba Skenario Multivariate Komoditas Minyak Goreng . 125
4.2.18 Hasil Uji Coba Skenario Multivariate Komoditas Gula Pasir..... 129
4.3 Pembahasan..... 133
4.3.1 Analisis Hasil Skenario Univariate..... 133
4.3.2 Analisis Hasil Skenario Multivariate..... 136
4.3.3 Perbandingan Hasil Terbaik Skenario Univariate dan Multivariate... 138
4.3.4 Pengaruh Variasi Window Size dan Jumlah Unit LSTM terhadap Akurasi Model 139
4.3.5 Analisis Pola Harga dan Volatilitas Komoditas 141
4.3.6 Analisis Arsitektur Model LSTM terhadap Performa Prediksi 143
4.4 Integrasi Islam..... 146
4.4.1 *Muamalah Ma'a Allah*..... 147
4.4.2 *Muamalah Ma'a al-Alam*..... 148
4.4.3 *Muamalah Ma'a an-Nas*..... 150
BAB V KESIMPULAN DAN SARAN 152
5.1 Kesimpulan..... 152
5.2 Saran 152

DAFTAR PUSTAKA 154

DAFTAR GAMBAR

Gambar 2.1 Arsitektur Model LSTM (Cahyani et al., 2023).....20
Gambar 3.1 Alur Desain Sistem.....27
Gambar 3.2 Pergerakan Harga Komoditas Pangan di Jawa Tengah Tahun 2020–2025.....32
Gambar 3.3 Arsitektur Model LSTM Penelitian 40
Gambar 4.1 Nilai MAPE Skenario Univariate Komoditas Beras 59
Gambar 4.2 Grafik Actual vs Predicted Komoditas Beras Skenario Univarate Terbaik 60
Gambar 4.3 Grafik Forecast Oktober 2025 Komoditas Beras Skenario Univarate Terbaik.....60
Gambar 4.4 Nilai MAPE Skenario Univariate Komoditas Daging Ayam.....63
Gambar 4.5 Grafik Actual vs Predicted Komoditas Daging Ayam Skenario Univariate Terbaik.....64
Gambar 4.6 Grafik Forecast Oktober 2025 Komoditas Daging Ayam Skenario Univarate Terbaik.....65
Gambar 4.7 Nilai MAPE Skenario Univariate Komoditas Daging Sapi 68
Gambar 4.8 Grafik Actual vs Predicted Komoditas Daging Sapi Skenario Univarate Terbaik.....68
Gambar 4.9 Grafik Forecast Oktober 2025 Komoditas Daging Sapi Skenario Univarate Terbaik.....69
Gambar 4.10 Nilai MAPE Skenario Univariate Komoditas Telur Ayam.....72
Gambar 4.11 Grafik Actual vs Predicted Komoditas Telur Ayam Skenario Univarate Terbaik.....73
Gambar 4.12 Grafik Forecast Oktober 2025 Komoditas Telur Ayam Skenario Univarate Terbaik.....73
Gambar 4.13 Nilai MAPE Skenario Univariate Komoditas Bawang Merah.....76
Gambar 4.14 Grafik Actual vs Predicted Komoditas Bawang Merah Skenario Univarate Terbaik.....77
Gambar 4.15 Grafik Forecast Oktober 2025 Komoditas Bawang Merah Skenario Univarate Terbaik.....78
Gambar 4.16 Nilai MAPE Skenario Univariate Komoditas Cabai Merah 80
Gambar 4.17 Grafik Actual vs Predicted Komoditas Cabai Merah Skenario Univarate Terbaik.....81
Gambar 4.18 Grafik Forecast Oktober 2025 Komoditas Cabai Merah Skenario Univarate Terbaik.....82
Gambar 4.19 Nilai MAPE Skenario Univariate Komoditas Cabai Rawit 85
Gambar 4.20 Grafik Actual vs Predicted Komoditas Cabai Rawit Skenario Univarate Terbaik.....85
Gambar 4.21 Grafik Forecast Oktober 2025 Komoditas Cabai Rawit Skenario Univarate Terbaik.....86
Gambar 4.22 Nilai MAPE Skenario Univariate Komoditas Minyak Goreng.....89
Gambar 4.23 Grafik Actual vs Predicted Komoditas Minyak Goreng Skenario Univarate Terbaik.....89

Gambar 4.24 Grafik Forecast Oktober 2025 Komoditas Minyak Goreng Skenario Univarate Terbaik....90
Gambar 4.25 Nilai MAPE Skenario Univariate Komoditas Gula Pasir 93
Gambar 4.26 Grafik Actual vs Predicted Komoditas Gula Pasir Skenario Univarate Terbaik....93
Gambar 4.27 Grafik Forecast Oktober 2025 Komoditas Gula Pasir Skenario Univarate Terbaik....94
Gambar 4.28 Nilai MAPE Skenario Multivariate Komoditas Beras 97
Gambar 4.29 Grafik Actual vs Predicted Komoditas Beras Skenario Multivariate Terbaik 98
Gambar 4.30 Grafik Forecast Oktober 2025 Komoditas Beras Skenario Multivariate Terbaik....98
Gambar 4.31 Nilai MAPE Skenario Multivariate Komoditas Daging Ayam....101
Gambar 4.32 Grafik Actual vs Predicted Komoditas Daging Ayam Skenario Multivariate Terbaik....102
Gambar 4.33 Grafik Forecast Oktober 2025 Komoditas Daging Ayam Skenario Multivariate Terbaik....102
Gambar 4.34 Nilai MAPE Skenario Multivariate Komoditas Daging Sapi 105
Gambar 4.35 Grafik Actual vs Predicted Komoditas Daging Sapi Skenario Multivariate Terbaik....106
Gambar 4.36 Grafik Forecast Oktober 2025 Komoditas Daging Sapi Skenario Multivariate Terbaik....107
Gambar 4.37 Nilai MAPE Skenario Multivariate Komoditas Telur Ayam....110
Gambar 4.38 Grafik Actual vs Predicted Komoditas Telur Ayam Skenario Multivariate Terbaik....110
Gambar 4.39 Grafik Forecast Oktober 2025 Komoditas Telur Ayam Skenario Multivariate Terbaik....111
Gambar 4.40 Nilai MAPE Skenario Multivariate Komoditas Bawang Merah....114
Gambar 4.41 Grafik Actual vs Predicted Komoditas Bawang Merah Skenario Multivariate Terbaik....115
Gambar 4.42 Grafik Forecast Oktober 2025 Komoditas Bawang Merah Skenario Multivariate Terbaik....115
Gambar 4.43 Nilai MAPE Skenario Multivariate Komoditas Cabai Merah 118
Gambar 4.44 Grafik Actual vs Predicted Komoditas Cabai Merah Skenario Multivariate Terbaik....119
Gambar 4.45 Grafik Forecast Oktober 2025 Komoditas Cabai Merah Skenario Multivariate Terbaik....120
Gambar 4.46 Nilai MAPE Skenario Multivariate Komoditas Cabai Rawit 122
Gambar 4.47 Grafik Actual vs Predicted Komoditas Cabai Rawit Skenario Multivariate Terbaik....123
Gambar 4.48 Grafik Forecast Oktober 2025 Komoditas Cabai Rawit Skenario Multivariate Terbaik....124
Gambar 4.49 Nilai MAPE Skenario Multivariate Komoditas Minyak Goreng...126
Gambar 4.50 Grafik Actual vs Predicted Komoditas Minyak Goreng Skenario Multivariate Terbaik 127

Gambar 4.51 Grafik Forecast Oktober 2025 Komoditas Minyak Goreng Skenario Multivariate Terbaik 128
Gambar 4.52 Nilai MAPE Skenario Multivariate Komoditas Gula Pasir 130
Gambar 4.53 Grafik Actual vs Predicted Komoditas Gula Pasir Skenario Multivariate Terbaik.....131
Gambar 4.54 Grafik Forecast Oktober 2025 Komoditas Gula Pasir Skenario Multivariate Terbaik.....132
Gambar 4.54 Nilai MAPE Terbaik Tiap Komoditas Skenario Univariate 135
Gambar 4.55 Nilai MAPE Terbaik Tiap Komoditas Skenario Multivariate 137
Gambar 4.56 Perbandingan MAPE Terbaik Skenario Univariate dan Multivariate 139
Gambar 4.58 Pola Harga Komoditas Daging Sapi.....141
Gambar 4.59 Pola Harga Komoditas Minyak Goreng 141
Gambar 4.60 Pola Harga Komoditas Cabai Merah.....142
Gambar 4.61 Pola Harga Komoditas Cabai Rawit.....142

DAFTAR TABEL

Tabel 2.1 Penelitian Terdahulu 9
Tabel 3.1 Contoh Dataset Harga Harian Komoditas Pangan 28
Tabel 3.2 Contoh Data Setelah Proses Transformasi ke Wide Format 30
Tabel 3.3.Contoh Data Setelah Proses Cleaning Data 31
Tabel 3.4 Contoh Data Harga Komoditas Minyak Goreng Sebelum Penerapan Imputasi Missing Value LOCF 33
Tabel 3.5 Contoh Data Harga Komoditas Minyak Goreng Setelah Penerapan Imputasi Missing Value LOCF 33
Tabel 3.6 Contoh Data Harga Beras Setelah Normalisasi 35
Tabel 3.7 Contoh Pembentukan Data Sliding Window (W = 3) 37
Tabel 3.8 Variasi Panjang Sliding Window yang Diterapkan 37
Tabel 3.9 Skenario Percobaan 50
Tabel 3.10 Contoh Data untuk Penerapan Evaluasi Model 52
Tabel 4.1 Pembagian Dataset Berdasarkan Rentang Waktu 55
Tabel 4.2 Konfigurasi Hyperparameter Model LSTM 56
Tabel 4.3 Hasil Pengujian Skenario Univariate Komoditas Beras 58
Tabel 4.4 Perbandingan Harga Aktual dan Hasil Forecast Komoditas Beras Oktober 2025 Skenario Univarate Terbaik 61
Tabel 4.5 Hasil Pengujian Skenario Univariate Komoditas Daging Ayam 62
Tabel 4.6 Perbandingan Harga Aktual dan Forecast Daging Ayam Skenario Univariate Terbaik 65
Tabel 4.7 Hasil Pengujian Skenario Univariate Komoditas Daging Sapi 67
Tabel 4.8 Perbandingan Harga Aktual dan Forecast Daging Sapi Skenario Univariate Terbaik 70
Tabel 4.9 Hasil Pengujian Skenario Univariate Komoditas Telur Ayam 71
Tabel 4.10 Perbandingan Harga Aktual dan Forecast Telur Ayam Skenario Univariate Terbaik 74
Tabel 4.11 Hasil Pengujian Skenario Univariate Komoditas Bawang Merah 75
Tabel 4.12 Perbandingan Harga Aktual dan Forecast Bawang Merah Skenario Univariate Terbaik 78
Tabel 4.13 Hasil Pengujian Skenario Univariate Komoditas Cabai Merah 79
Tabel 4.14 Perbandingan Harga Aktual dan Forecast Cabai Merah Skenario Univariate Terbaik 82
Tabel 4.15 Hasil Pengujian Skenario Univariate Komoditas Cabai Rawit 84
Tabel 4.16 Perbandingan Harga Aktual dan Forecast Cabai Rawit Skenario Univariate Terbaik 87
Tabel 4.17 Hasil Pengujian Skenario Univariate Komoditas Minyak Goreng 88
Tabel 4.18 Perbandingan Harga Aktual dan Forecast Minyak Goreng Skenario Univariate Terbaik 90
Tabel 4.19 Hasil Pengujian Skenario Univariate Komoditas Gula Pasir 92
Tabel 4.20 Perbandingan Harga Aktual dan Forecast Gula Pasir Skenario Univariate Terbaik 95
Tabel 4.21 Hasil Pengujian Skenario Multivariate Komoditas Beras 96

Tabel 4.22 Perbandingan Harga Aktual dan Hasil Forecast Komoditas Beras Oktober 2025 Skenario Multivariate Terbaik.....99
Tabel 4.23 Hasil Pengujian Skenario Multivariate Komoditas Daging Ayam 100
Tabel 4.24 Perbandingan Harga Aktual dan Forecast Daging Ayam Skenario Multivariate Terbaik.....103
Tabel 4.25 Hasil Pengujian Skenario Multivariate Komoditas Daging Sapi.....104
Tabel 4.26 Perbandingan Harga Aktual dan Forecast Daging Sapi Skenario Multivariate Terbaik.....107
Tabel 4.27 Hasil Pengujian Skenario Multivariate Komoditas Telur Ayam 109
Tabel 4.28 Perbandingan Harga Aktual dan Forecast Telur Ayam Skenario Multivariate Terbaik.....112
Tabel 4.29 Hasil Pengujian Skenario Multivariate Komoditas Bawang Merah ..113
Tabel 4.30 Perbandingan Harga Aktual dan Forecast Bawang Merah Skenario Multivariate Terbaik.....116
Tabel 4.31 Hasil Pengujian Skenario Multivariate Komoditas Cabai Merah.....117
Tabel 4.32 Perbandingan Harga Aktual dan Forecast Cabai Merah Skenario Multivariate Terbaik.....120
Tabel 4.33 Hasil Pengujian Skenario Multivariate Komoditas Cabai Rawit.....121
Tabel 4.34 Perbandingan Harga Aktual dan Forecast Cabai Rawit Skenario Multivariate Terbaik.....124
Tabel 4.35 Hasil Pengujian Skenario Multivariate Komoditas Minyak Goreng .126
Tabel 4.36 Perbandingan Harga Aktual dan Forecast Minyak Goreng Skenario Multivariate Terbaik.....128
Tabel 4.37 Hasil Pengujian Skenario Multivariate Komoditas Gula Pasir.....129
Tabel 4.38 Perbandingan Harga Aktual dan Forecast Gula Pasir Skenario Multivariate Terbaik.....132
Tabel 4.39 Hasil Skenario Univariate Seluruh Komoditas 134
Tabel 4.40 Hasil Skenario Multivariate Seluruh Komoditas 136
Tabel 4.41 Perbandingan Nilai MAPE Terbaik Skenario Univariate dan Multivariate 138

ABSTRAK

Salsabila, Sania Nabila. 2025**. Prediksi Harga Komoditas Pangan di Provinsi Jawa Tengah Menggunakan Metode Long Short-Term Memory**. Skripsi. Program Studi Teknik Informatika Fakultas Sains dan Teknologi Universitas Islam Negeri Maulana Malik Ibrahim Malang. Pembimbing: (I) Prof. Dr. Suhartono S.Si M.Kom (II) Dr. M. Imamudin Lc, MA.

.

Kata kunci: Prediksi Harga Pangan, LSTM, Deret Waktu, Sliding Window, MAPE.

Fluktuasi harga pangan di Provinsi Jawa Tengah menuntut ketersediaan sistem prediksi yang akurat sebagai dasar pengambilan keputusan berbasis data. Penelitian ini bertujuan untuk memprediksi harga harian sembilan komoditas pangan menggunakan metode Long Short-Term Memory (LSTM) serta mengevaluasi tingkat akurasinya menggunakan Mean Absolute Percentage Error (MAPE). Data harga harian periode 2020–2025 diproses melalui tahapan imputasi *Last Observation Carried Forward* (LOCF), normalisasi Min–Max, dan pembentukan *sliding window* dengan ukuran 7, 14, dan 30 hari. Pengujian dilakukan menggunakan dua skenario input, yaitu *univariate* dan *multivariate*, dengan variasi jumlah unit LSTM sebesar 32 dan 64 unit. Hasil penelitian menunjukkan bahwa seluruh nilai MAPE berada di bawah 10%, yang menandakan tingkat akurasi prediksi yang sangat baik. Skenario *univariate* memberikan performa terbaik pada 8 dari 9 komoditas, dengan nilai MAPE terendah diperoleh pada Daging Sapi sebesar 0,10%, Minyak Goreng sebesar 0,14%, dan Beras sebesar 0,14%. Pada skenario *multivariate*, hasil terbaik dicapai pada konfigurasi *window size* 7–14 hari dengan 64 unit LSTM, dengan nilai MAPE terendah pada Gula Pasir sebesar 0,25% dan Minyak Goreng sebesar 0,32%. Secara keseluruhan, hasil penelitian menunjukkan bahwa *input layer* dengan jendela historis panjang lebih efektif untuk komoditas dengan fluktuasi harga tinggi, sedangkan *input layer* yang lebih pendek lebih sesuai untuk komoditas dengan pola harga stabil atau pada skenario *multivariate*. Temuan ini menegaskan bahwa metode LSTM, khususnya pada skenario *univariate*, merupakan pendekatan yang efektif untuk prediksi harga pangan harian dan dapat digunakan sebagai dasar pengembangan sistem prediksi harga pangan yang lebih akurat dan adaptif.

ABSTRACT

Salsabila, Sania Nabila. 2025. **Commodity Price Prediction in Central Java Province Using the Long Short-Term Memory Method. Thesis. Study Program of Informatics Engineering**, Faculty of Science and Technology, Maulana Malik Ibrahim State Islamic University, Malang. Advisors: (I) Prof. Dr. Suhartono S.Si M.Kom (II) Dr. M. Imamudin Lc, MA.

.

Keywords: Food Price Prediction, LSTM, Time Series, Sliding Window, MAPE.

Fluctuations in food prices in Central Java Province require an accurate prediction system as a basis for data-driven decision making. This study aims to predict the daily prices of nine food commodities using the Long Short-Term Memory (LSTM) method and evaluate its accuracy using Mean Absolute Percentage Error (MAPE). Daily price data for the 2020–2025 period was processed through the Last Observation Carried Forward (LOCF) imputation stage, Min–Max normalization, and the formation of a sliding window with sizes of 7, 14, and 30 days. Testing was carried out using two input scenarios, namely univariate and multivariate, with variations in the number of LSTM units of 32 and 64 units. The results show that all MAPE values are below 10%, indicating a very good level of prediction accuracy. The univariate scenario provides the best performance for 8 out of 9 commodities, with the lowest MAPE values obtained for Beef at 0.10%, Cooking Oil at 0.14%, and Rice at 0.14%. In the multivariate scenario, the best results were achieved in the window size configuration of 7–14 days with 64 LSTM units, with the lowest MAPE values for Granulated Sugar at 0.25% and Cooking Oil at 0.32%. Overall, the results of the study show that input layers with long historical windows are more effective for commodities with high price fluctuations, while shorter input layers are more suitable for commodities with stable price patterns or in multivariate scenarios. These findings confirm that the LSTM method, particularly in univariate scenarios, is an effective approach for daily food price prediction and can be used as a basis for developing more accurate and adaptive food price prediction systems.

الملخص

سالسابيلا، سانيا نابيلة. ٢٠٢٥ .**تنبؤ أسعار السلع الغذائية في إقليم جاوا الوسطى باستخدام شبكة الذاكرة طويلة وقصيرة المدى** .رسالة جامعية. قسم تقنية المعلومات، كلية العلوم والتكنولوجيا، جامعة مولانا مالك إبراهيم الإسلامية الحكومية مالانج. بإشراف:(١) الأستاذ الدكتور سهرتونو، س.س.ي، م.كوم(٢)الدكتور محمد إمام الدين، ماجستير.

المفتاحية الكلمات : توقعات أسعار المواد الغذائية، LSTM، السلاسل الزمنية، النافذة المنزلقة، MAPE

تتطلب تقلبات أسعار المواد الغذائية في مقاطعة جاوة الوسطى نظامًا دقيقًا للتنبؤ كأساس لاتخاذ القرارات المستندة إلى البيانات. تهدف هذه الدراسة إلى التنبؤ بالأسعار اليومية لتسع سلع غذائية باستخدام طريقة الذاكرة الطويلة القصيرة المدى (LSTM) وتقييم دقتها باستخدام متوسط الخطأ المطلق المئوي (MAPE). تمت معالجة بيانات الأسعار اليومية للفترة ٢٠٢٠–٢٠٢٥ من خلال مرحلة الاستكمال بالقيمة الأخيرة الملاحظة (LOCF)، والتطبيع Min–Max، وتشكيل نافذة منزلقة بأحجام ٧ و١٤ و٣٠ يومًا. تم إجراء الاختبار باستخدام سيناريوهين للإدخال، وهما سيناريو أحادي المتغير وسيناريو متعدد المتغيرات، مع اختلافات في عدد وحدات LSTM من ٣٢ إلى ٦٤ وحدة. أظهرت النتائج أن جميع قيم MAPE كانت أقل من ١٠٪، مما يشير إلى مستوى جيد جدًا من دقة التنبؤ. كان السيناريو أحادي المتغير هو الأفضل بالنسبة لـ ٨ من أصل ٩ سلع، حيث تم الحصول على أقل قيم MAPE للحوم البقر بنسبة ٠,١٠٪، وزيت الطهي بنسبة ٠,١٤٪، والأرز بنسبة ٠,١٤٪. في السيناريو متعدد المتغيرات، تم تحقيق أفضل النتائج مع تكوين حجم نافذة من ٧ إلى ١٤ يومًا و٦٤ وحدة LSTM، مع أقل قيم MAPE للسكر المحبب عند ٠,٢٥٪ وزيت الطهي عند ٠,٣٢٪. بشكل عام، تشير نتائج الدراسة إلى أن طبقات الإدخال ذات النوافذ التاريخية الأطول تكون أكثر فعالية بالنسبة للسلع التي تتعرض لتقلبات سعرية عالية، في حين أن طبقات الإدخال الأقصر تكون أكثر ملاءمة للسلع ذات الأنماط السعرية المستقرة أو في السيناريوهات متعددة المتغيرات. وتؤكد هذه النتائج أن طريقة LSTM، لا سيما في السيناريوهات أحادية المتغيرات، هي نهج فعال للتنبؤ اليومي بأسعار المواد الغذائية ويمكن استخدامها كأساس لتطوير أنظمة تنبؤ بأسعار المواد الغذائية أكثر دقة وتكيفًا..

.

BAB I

PENDAHULUAN

1.1 Latar Belakang

Indonesia merupakan negara agraris yang sebagian besar penduduknya bergantung pada sektor pertanian, terutama di wilayah pedesaan. Berdasarkan data Badan Pusat Statistik (BPS, 2023), jumlah petani pengguna lahan mencapai 27,8 juta orang, sedangkan petani gurem sebanyak 17,2 juta orang. Sektor ini memiliki peran penting dalam perekonomian nasional karena menjadi sumber penghidupan utama dan penyedia bahan pangan. Dari lima subsektor pertanian, subsektor tanaman pangan berkontribusi besar terhadap pemenuhan kebutuhan pokok dan kestabilan ekonomi masyarakat pedesaan (Wijaya et al., 2025). *Menurut Food and Agriculture Organization* (FAO), salah satu dimensi penting dalam ketahanan pangan adalah stabilitas, yaitu kemampuan sistem pangan untuk menjaga pasokan dan harga agar tetap seimbang meskipun terjadi perubahan iklim atau gangguan distribusi (Ghalibaf et al., 2022). Ketika harga di tingkat produsen berfluktuasi, pendapatan petani menjadi tidak menentu dan produksi sulit dipertahankan, yang pada akhirnya berdampak pada harga di tingkat konsumen. Oleh sebab itu, kestabilan harga di tingkat produsen menjadi faktor penting dalam menjaga kesejahteraan petani dan keberlanjutan sistem pangan nasional.

Provinsi Jawa Tengah merupakan salah satu lumbung pangan nasional dengan kontribusi besar terhadap ketahanan pangan Indonesia. Berdasarkan Indeks Ketahanan Pangan (IKP) tahun 2023, provinsi ini menempati peringkat kedua nasional dengan skor 84,80 dan produksi padi sebesar 8,83 juta ton gabah kering

giling (Badan Pusat Statistik, 2024) (Permatasari & Purnomo, 2025). Namun, meskipun ketersediaan pangan tinggi, harga di tingkat produsen masih mengalami fluktuasi yang cukup tajam. Data dari Pusat Informasi Harga Pangan Strategis Nasional (PIHPS) periode 2020–2025 menunjukkan bahwa komoditas seperti cabai rawit, bawang merah, dan telur ayam ras sering mengalami perubahan harga akibat ketidakseimbangan pasokan, kondisi cuaca, serta hambatan distribusi (Azwina & Syahbudi, 2022). Fluktuasi tersebut menyebabkan ketidakpastian pendapatan bagi petani dan menyulitkan pemerintah dalam menetapkan kebijakan harga yang efektif. Oleh karena itu, diperlukan sistem prediksi harga yang mampu menganalisis data historis untuk memperkirakan perubahan harga di masa depan. Hasil prediksi dapat membantu petani menentukan strategi produksi dan mendukung pemerintah daerah dalam menjaga stabilitas harga pangan di tingkat produsen agar ketahanan pangan di Jawa Tengah tetap terjaga.

Dalam Al-Qur'an, Surah Yusuf ayat 47–49 menceritakan kisah Nabi Yusuf *'alaihissalam* yang memberikan petunjuk kepada masyarakat Mesir untuk bercocok tanam selama tujuh tahun masa kelimpahan dan menyimpan sebagian hasil panen sebagai persiapan menghadapi tujuh tahun masa kesulitan. Kisah tersebut menggambarkan pentingnya perencanaan pangan yang matang, berkelanjutan, dan antisipatif terhadap ketidakpastian ekonomi (Rahmi et al., 2021).

قَالَ تَزْرَعُوْنَ سَبْعَ سِنِيْنَ دَاَبًاۚ فَمَا حَصَدْتُّمْ فَذَرُوْهُ فِيْ سُنْۢبُلِهٖٓ اِلَّا قَلِيْلًا مِّمَّا تَاْكُلُوْنَ ٤٧ ثُمَّ يَاْتِيْ مِنْۢ بَعْدِ ذٰلِكَ سَبْعٌ شِدَادٌ يَّاْكُلْنَ مَا قَدَّمْتُمْ لَهُنَّ اِلَّا قَلِيْلًا مِّمَّا تُحْصِنُوْنَ ٤٨ ثُمَّ يَاْتِيْ مِنْۢ بَعْدِ ذٰلِكَ عَامٌ فِيْهِ يُغَاثُ النَّاسُ وَفِيْهِ يَعْصِرُوْنَ ٤٩

"Dia (Yusuf) berkata, "Hendaknya kamu bercocok tanam tujuh tahun (berturut-turut) sebagaimana biasa; kemudian apa yang kamu tuai hendaklah kamu biarkan ditangkainya kecuali sedikit untuk kamu makan""Kemudian setelah itu akan

datang tujuh (tahun) yang sangat sulit, yang menghabiskan apa yang kamu simpan untuk menghadapinya (tahun sulit), kecuali sedikit dari apa (bibit gandum) yang kamu simpan" "Setelah itu akan datang tahun, di mana manusia diberi hujan (dengan cukup) dan pada masa itu mereka memeras (anggur)" (*QS. Yusuf: 47- 49).*

Menurut penafsiran Imam Al-Qurṭubī, perintah Nabi Yusuf *'alaihissalam* untuk menyimpan hasil panen dalam bulirnya menunjukkan pentingnya menjaga kualitas bahan pangan dan mengelola cadangan secara efisien agar dapat dimanfaatkan pada masa sulit. Nilai tersebut sejalan dengan prinsip pengelolaan data dan perencanaan modern yang menggunakan informasi untuk menghadapi ketidakpastian ekonomi (Rahmi et al., 2021). Prinsip kehati-hatian dan perencanaan jangka panjang yang diajarkan Nabi Yusuf menjadi dasar moral dalam penerapan metode *Long Short-Term Memory* (LSTM) untuk memprediksi harga pangan berbasis data deret waktu.

Metode *Long Short-Term Memory* (LSTM) merupakan pengembangan dari *Recurrent Neural Network (RNN)* yang mampu mengenali pola data berurutan dan menyimpan informasi penting dari waktu sebelumnya. Model ini memiliki tiga gerbang utama, yaitu *input gate*, *forget gate*, dan *output gate*, yang berfungsi mengatur informasi yang disimpan maupun dilupakan. Dengan mekanisme tersebut, LSTM dapat mempelajari tren harga jangka pendek dan panjang secara efektif tanpa kehilangan konteks waktu (Febriyanti et al., 2025).

Kinerja hasil prediksi pada penelitian ini diukur menggunakan *Mean Absolute Percentage Error* (MAPE), yaitu rata-rata persentase kesalahan antara hasil prediksi dan nilai aktual. Semakin kecil nilai MAPE, semakin baik tingkat

akurasi model. Metrik ini dipilih karena mudah dipahami, terukur, dan banyak digunakan dalam penelitian prediksi harga komoditas (Priyatno et al., 2024).

Beberapa penelitian terdahulu telah membuktikan bahwa metode LSTM mampu memberikan hasil prediksi yang akurat untuk berbagai jenis komoditas. Cahyani et al. (2023) menggunakan LSTM untuk memprediksi harga bahan pokok nasional dan memperoleh nilai akurasi yang tinggi dengan R^2 sebesar 0,8852. Penelitian lain oleh Rahmad et al. (2023) menerapkan LSTM untuk memprediksi indeks harga produsen pertanian karet dan menghasilkan nilai MAPE sebesar 1,09%, yang tergolong sangat baik. Selanjutnya, Dwika & Avianto (2023) menerapkan metode yang sama untuk memprediksi harga cabai merah keriting di Yogyakarta dan memperoleh nilai MAPE sebesar 3,69% dengan tingkat akurasi 96,30%. Meskipun hasilnya menunjukkan kinerja yang baik, sebagian besar penelitian tersebut masih terbatas pada satu jenis komoditas dan wilayah tertentu.

Penelitian ini dilakukan untuk menerapkan metode *Long Short-Term Memory* (LSTM) dalam memprediksi harga harian produsen berbagai komoditas pangan utama di Provinsi Jawa Tengah pada periode 2020–2025. Melalui penerapan metode LSTM dan evaluasi menggunakan *Mean Absolute Percentage Error* (MAPE), penelitian ini diharapkan dapat menghasilkan model prediksi harga yang akurat dan mudah diimplementasikan. Hasil penelitian ini diharapkan mampu memberikan informasi yang bermanfaat bagi pemerintah daerah, petano, dan pelaku usaha dalam menjaga kestabilan harga di tingkat produsen serta mendukung ketahanan pangan daerah yang berbasis data dan teknologi.

1.2 Rumusan Masalah

Bagaimana kinerja metode *Long Short-Term Memory* (LSTM) dalam melakukan prediksi harga harian komoditas pangan di Provinsi Jawa Tengah yang dievaluasi berdasarkan nilai *Mean Absolute Percentage Error* (MAPE)?

1.3 Batasan Masalah

Penelitian ini dibatasi pada penggunaan data harga harian komoditas pangan wilayah Provinsi Jawa Tengah dengan periode waktu Januari 2020 hingga September 2025. Komoditas pangan yang dianalisis meliputi sembilan jenis komoditas, yaitu beras, daging ayam, daging sapi, telur ayam, bawang merah, cabai merah, cabai rawit, minyak goreng, dan gula pasir.

1.4 Tujuan Penelitian

Penelitian ini bertujuan untuk menerapkan metode Long Short-Term Memory (LSTM) dalam memprediksi harga harian komoditas pangan di Provinsi Jawa Tengah dan mengevaluasi tingkat akurasinya menggunakan Mean Absolute Percentage Error (MAPE).

1.5 Manfaat Penelitian

Penelitian ini diharapkan dapat memperkaya kajian akademis mengenai penerapan metode Long Short-Term Memory (LSTM) dalam prediksi harga komoditas pangan. Secara praktis, hasil penelitian ini diharapkan dapat menjadi

acuan bagi pemerintah daerah, petani, dan pelaku usaha dalam perencanaan produksi dan kebijakan stabilisasi harga pangan di Provinsi Jawa Tengah

BAB II

STUDI PUSTAKA

2.1 Penelitian Terdahulu

Berbagai penelitian telah menerapkan metode Long Short-Term Memory (LSTM) untuk memodelkan data deret waktu. Murugesan et al. (2021) mengembangkan beberapa arsitektur deep learning, yaitu Basic LSTM, Bi-LSTM, Stacked LSTM, CNN-LSTM, dan Conv-LSTM untuk memprediksi harga grosir lima komoditas pertanian di India (beras, gandum, kacang gram, pisang, dan kacang tanah). Data harian diperoleh dari Reserve Bank of India dengan periode Januari 2000–Juli 2020. Model Basic LSTM menggunakan satu lapisan tersembunyi dengan 50 neuron, aktivasi ReLU, optimizer Adam, dan fungsi kerugian MSE. Hasil menunjukkan nilai MAE antara 0,23–0,36 dan RMSE antara 0,151–0,487. Meskipun akurasinya lebih rendah dibandingkan model Stacked LSTM dan CNN-LSTM, Basic LSTM dianggap efisien karena struktur yang sederhana dan waktu pelatihan yang lebih cepat. Penelitian ini menegaskan bahwa LSTM efektif untuk mengenali pola jangka panjang, namun kurang akurat untuk menangkap fluktuasi jangka pendek yang dipengaruhi faktor musiman.

Nafi'iyah & Wulandari (2022) membangun model LSTM untuk memprediksi harga beras berdasarkan tiga kategori kualitas (premium, medium, dan luar kulit). Model terdiri dari empat neuron input, tiga hidden layer berisi 50 neuron, serta satu output layer tunggal. Model dilatih menggunakan Adam optimizer, 100 epoch, fungsi aktivasi ReLU, dan loss MAE. Hasil menunjukkan MAE rata-rata 83,49 (premium), 89,60 (medium), dan 96,99 (luar kulit), dengan

kesalahan terendah 71,06 pada beras premium. Keterbatasan penelitian terletak pada ukuran dataset yang kecil dan interval waktu bulanan, sehingga pola harian dan musiman tidak terekam secara optimal. Dwika & Avianto (2023) mengembangkan sistem prediksi harga cabai merah keriting di DIY menggunakan data harian PIHPS periode 2017–2023 dengan total 1.580 data. Pra-pemrosesan mencakup cleaning, Min–Max scaling, serta pembentukan sliding window berisi 10 lag. Model terbaik diperoleh pada rasio 70:30 dengan konfigurasi 30 neuron, epoch 150, batch size 48, learning rate 0,001, aktivasi ReLU, dan Adam optimizer. Nilai MAPE 3,6995% menunjukkan kesalahan prediksi yang rendah. Keterbatasan penelitian terletak pada penggunaan satu komoditas dan konteks univariat sehingga pola jangka panjang belum sepenuhnya ditangkap.

Cahyani et al. (2023) menerapkan LSTM untuk memprediksi empat komoditas pangan nasional, yaitu daging ayam ras segar, beras kualitas bawah II, minyak goreng, dan minyak goreng curah. Data PIHPS periode 2018–2021 sebanyak 903 observasi digunakan dalam penelitian. Pre-processing meliputi uji normalitas, Min–Max scaling, dan sliding window (7, 10, 15). Hasil terbaik untuk beras kualitas bawah II dan daging ayam ras dicapai dengan optimizer Adam (RMSE 0,0492 dan 0,0937), sedangkan minyak goreng terbaik dengan RMSProp (RMSE 0,0313). Penelitian ini memperlihatkan kemampuan LSTM dalam mengenali pola jangka pendek, namun ruang lingkup waktu yang pendek dan penggunaan variabel tunggal menjadi batasan. Zhang et al. (2024) memprediksi harga enam jenis sayuran di pasar grosir Beijing menggunakan data harian periode 2009–2023. Arsitektur LSTM terdiri dari dua hidden layer berisi 32 neuron dengan

dropout 0,2, learning rate 0,0027, dan 200 epoch. Model menghasilkan nilai R^2 hingga 0,982 dan MAPE terendah 0,024 pada komoditas kentang. LSTM terbukti lebih unggul dibandingkan CNN, XGBoost, dan SVR. Keterbatasan penelitian ini adalah fokus data yang hanya mencakup pasar Beijing.

Berdasarkan penelitian terdahulu, LSTM terbukti mampu mengenali pola temporal jangka panjang pada data harga komoditas yang bersifat nonlinier, tetapi sebagian besar studi masih terbatas pada satu komoditas, satu wilayah, data bulanan, serta belum menguji variasi window size dan jumlah unit LSTM secara sistematis. Penelitian penulis mengatasi keterbatasan tersebut dengan menggunakan data harian sembilan komoditas pangan di Provinsi Jawa Tengah periode 2020–2025, serta menerapkan variasi window size (7, 14, dan 30) dan jumlah neuron LSTM (16 dan 32) untuk menilai pengaruh panjang jendela historis dan kapasitas memori model. Ringkasan perbandingan penelitian terdahulu dan penelitian penulis ditampilkan pada Tabel 2.1.

Tabel 2.1 Penelitian Terdahulu

No	Nama Peneliti dan Judul Penelitian	Hasil Penelitian	Perbedaan Penelitian
1.	(Murugesan et al., 2021) Deep learning based models: Basic LSTM, Bi LSTM, Stacked LSTM, CNN LSTM and Conv LSTM to forecast Agricultural commodities prices	Model *Basic LSTM* menghasilkan MAE 0,23–0,36 dan RMSE 0,151–0,487, model dinilai efektif untuk pola jangka panjang namun kurang optimal pada fluktuasi harga jangka pendek.	Penelitian penulis menggunakan data sembilan komoditas pangan di Jawa Tengah dengan periode 2020–2025, serta menerapkan variasi *window size* dan jumlah unit LSTM untuk menganalisis pengaruh panjang data historis terhadap akurasi model.
2.	(Nafi'iyah & Wulandari, 2022)	Model menghasilkan MAE rata-rata 83,49 (premium), 89,60	Menggunakan data harian sembilan komoditas dengan

No	Nama Peneliti dan Judul Penelitian	Hasil Penelitian	Perbedaan Penelitian
	Prediksi Harga Beras Berdasarkan Kualitas Beras dengan Metode Long Short-Term Memory (LSTM)	(medium), dan 96,99 (luar kulit); menunjukkan performa yang cukup baik meskipun data masih bersifat bulanan dan terbatas.	cakupan lima tahun serta menerapkan variasi window size dan unit LSTM untuk hasil prediksi yang lebih stabil.
3.	(Dwika & Avianto, 2023) Prediksi Harga Pangan di Pasar Tradisional Kota Surabaya dengan Metode LSTM	Model menghasilkan MAPE 3,6995% dan akurasi 96,3005%, menunjukkan performa sangat baik dalam memprediksi harga harian cabai merah keriting di Yogyakarta.	Menggunakan data harian sembilan komoditas pangan di wilayah Jawa Tengah serta menerapkan variasi *window size* dan jumlah unit LSTM untuk meningkatkan akurasi hasil prediksi.
4.	(Cahyani et al., 2023) Implementasi Metode Long Short-Term Memory (LSTM) untuk Memprediksi Harga Bahan Pokok Nasional	Model LSTM terbaik menggunakan *Adam* pada beras kualitas bawah II (RMSE 0,0492 dan R^2 0,8852) dan daging ayam (RMSE 0,0937 dan R^2 0,5949); *RMSProp* optimal untuk minyak goreng (RMSE 0,0313 dan R^2 0,7492). Model efektif dalam prediksi jangka pendek namun cenderung *overfitting* pada data tertentu.	Menggunakan data harian sembilan komoditas pangan di tingkat provinsi dengan cakupan waktu lima tahun, serta menerapkan variasi *window size* dan jumlah unit LSTM sebagai upaya peningkatan generalisasi model.
5.	(Zhang et al., 2024) Short-Term Forecasting of Vegetable Prices Based on LSTM Model—Evidence from Beijing's Vegetable Data	Model LSTM mencapai R^2 tertinggi 0,982 dan MAPE terendah 0,024, dengan akurasi rata-rata di atas 85%. Model unggul 5% dibanding CNN, XGBoost, dan SVR dalam prediksi harga enam komoditas sayuran di Beijing.	Berfokus pada wilayah Indonesia, khususnya Provinsi Jawa Tengah, serta menerapkan variasi *window size* dan jumlah unit LSTM untuk menganalisis pengaruh struktur model terhadap akurasi prediksi harga pangan.

2.2 Harga Komoditas Pangan

Komoditas pangan merupakan kebutuhan dasar manusia yang berasal dari sumber daya hayati, baik dalam bentuk segar maupun hasil pengolahan. Undang-Undang Nomor 18 Tahun 2012 mendefinisikan pangan sebagai segala sesuatu yang berasal dari hasil pertanian, perkebunan, perikanan, peternakan, kehutanan, dan air yang digunakan sebagai makanan atau minuman, termasuk bahan tambahan dan bahan baku pangan (Chintia & Destiningsih, 2022). Komoditas pangan utama di Indonesia meliputi beras, daging ayam, daging sapi, telur ayam, cabai merah, cabai rawit, bawang merah, minyak goreng, dan gula pasir (Helbawanti et al., 2021).

Harga komoditas pangan merupakan nilai tukar suatu barang yang terbentuk melalui mekanisme pasar, terutama dipengaruhi oleh interaksi antara permintaan dan penawaran. Pada komoditas pangan pokok, volatilitas atau fluktuasi harga kebutuhan pangan cenderung lebih banyak ditentukan oleh faktor penawaran, mengingat tingkat konsumsi masyarakat yang relatif stabil dari waktu ke waktu. Faktor musim, kondisi cuaca, kelancaran distribusi, serta ketersediaan stok menjadi penyebab utama terjadinya perubahan harga, yang pada akhirnya dapat berdampak langsung terhadap daya beli masyarakat, khususnya kelompok berpenghasilan rendah (Chintia & Destiningsih, 2022).

2.3 Prediksi

Prediksi merupakan bagian dari kajian statistik dan ilmu data yang digunakan untuk memperkirakan suatu nilai atau keadaan di masa mendatang berdasarkan data yang tersedia. Secara umum, prediksi dilakukan dengan

memanfaatkan pola atau hubungan yang terbentuk dari data masa lalu untuk menghasilkan estimasi terhadap kondisi yang belum diketahui. Pendekatan ini digunakan dalam berbagai bidang untuk membantu penyusunan rencana atau kebijakan ketika data aktual belum tersedia (E. Hasibuan, 2022).

Dalam ruang lingkup teknologi informasi dan sistem cerdas, prediksi diterapkan untuk membaca pola dari data historis yang kemudian digunakan untuk memperkirakan kejadian berikutnya. Metode ini digunakan dalam berbagai aplikasi, seperti sistem rekomendasi, peramalan penjualan, dan pengolahan data pasar. Tujuan utamanya adalah untuk memberikan estimasi nilai berdasarkan informasi sebelumnya, bukan untuk menggambarkan kondisi saat ini (Satrani Azral et al., 2023).

Konsep prediksi juga sejalan dengan nilai-nilai yang diajarkan dalam Al-Qur'an. Dalam QS. Al-Hasyr ayat 18, Allah Swt. berfirman:

يٰٓاَيُّهَا الَّذِيْنَ اٰمَنُوا اتَّقُوا اللّٰهَ وَلْتَنْظُرْ نَفْسٌ مَّا قَدَّمَتْ لِغَدٍۚ وَاتَّقُوا اللّٰهَۗ اِنَّ اللّٰهَ خَبِيْرٌۢ ۢبِمَا تَعْمَلُوْنَ ١٨

"Wahai orang-orang yang beriman, bertakwalah kepada Allah dan hendaklah setiap orang memperhatikan apa yang telah diperbuatnya untuk hari esok (akhirat). Bertakwalah kepada Allah. Sesungguhnya Allah Mahateliti terhadap apa yang kamu kerjakan" (QS. Al-Hasyr:18)

Ayat tersebut mengandung pesan agar manusia selalu memperhatikan tindakan yang dilakukan pada masa kini sebagai bentuk persiapan untuk masa yang akan datang. Menurut penjelasan Imam Al-Ghazali, ayat ini menegaskan bahwa setiap umat diperintahkan untuk berusaha memperbaiki diri dan meningkatkan ketakwaan kepada Allah Swt., karena kehidupan manusia seharusnya tidak stagnan, melainkan terus mengalami peningkatan dan perbaikan. Sementara itu, Imam Al-

Shazali menafsirkan kata “perhatikanlah” sebagai perintah untuk senantiasa mengevaluasi perbuatan dan merencanakan langkah yang lebih baik demi masa depan (Alhaq & Mahmud, 2024). Dengan demikian, makna ayat tersebut dapat dikaitkan dengan konsep prediksi, di mana manusia dituntut untuk menggunakan pengetahuan dan data masa lalu sebagai dasar dalam mempersiapkan dan memperkirakan keadaan di masa mendatang, sehingga setiap keputusan yang diambil menjadi lebih terarah dan bermanfaat.

2.4 Time Series

Data deret waktu atau *time series* adalah sekumpulan data yang dicatat secara berurutan dalam rentang waktu tertentu dan memiliki jarak waktu yang tetap, seperti harian, mingguan, atau bulanan. Data jenis ini sering digunakan dalam berbagai bidang, terutama pada kasus yang membutuhkan pencatatan nilai dari waktu ke waktu, seperti suhu harian, volume penjualan, permintaan energi, dan harga komoditas pangan (Fungki Wahyu & Billy Hendrik, 2023).

Data deret waktu memiliki karakteristik unik berupa pola-pola yang dapat dikenali selama periode pengamatan. Pola tersebut secara umum terbagi menjadi tiga, yaitu tren (*trend*), musiman (*seasonality*), dan siklus (*cycle*). Tren mencerminkan arah umum data dalam jangka panjang, seperti kenaikan atau penurunan harga dari waktu ke waktu. Pola musiman menggambarkan perubahan yang terjadi secara teratur dalam periode waktu tertentu, misalnya naiknya harga bahan pokok menjelang hari besar. Sementara itu, pola siklus mencerminkan

fluktuasi yang terjadi dalam periode yang lebih panjang dan tidak selalu berulang secara tetap (Nur Cahyo & Susanti, 2023).

Pengenalan terhadap pola-pola tersebut menjadi dasar dalam analisis deret waktu. Analisis ini bertujuan untuk memahami hubungan antar nilai data dalam rangka menghasilkan peramalan (*forecasting*) terhadap kondisi di masa depan. Salah satu sifat penting dalam data deret waktu adalah adanya autokorelasi, yaitu ketergantungan antara nilai saat ini dengan nilai-nilai sebelumnya. Karakteristik ini memungkinkan model prediksi memanfaatkan data historis untuk memperkirakan nilai pada periode selanjutnya (Nur Cahyo & Susanti, 2023).

Untuk menganalisis data deret waktu, digunakan dua pendekatan utama, yaitu pendekatan domain waktu (*time domain*) dan domain frekuensi (*frequency domain*). Analisis dalam domain waktu melibatkan pengujian terhadap kestasioneran data, pemeriksaan autokorelasi, serta estimasi parameter model yang sesuai. Sementara itu, pendekatan domain frekuensi digunakan untuk mengidentifikasi pola-pola berdasarkan komponen frekuensi dalam data, dengan teknik seperti *spectral analysis* untuk menguraikan variasi periodik yang tersembunyi dalam data (Fungki Wahyu & Billy Hendrik, 2023).

Berdasarkan jumlah variabel yang dicatat, data deret waktu diklasifikasikan menjadi dua jenis, yaitu univariat dan multivariat. Data univariat hanya mencakup satu variabel dalam setiap titik waktu, seperti data harga cabai harian. Jenis ini digunakan ketika fokus analisis hanya pada satu parameter yang berubah terhadap waktu. Sebaliknya, data multivariat mencakup lebih dari satu variabel yang diamati secara bersamaan, seperti harga beras, telur, dan cabai yang dicatat setiap hari.

Pendekatan ini bermanfaat untuk melihat hubungan antar variabel dalam satu kerangka waktu yang sama (Nur Cahyo & Susanti, 2023)

2.5 Pre-Processing

Pre-Processing atau pra-pemrosesan data adalah tahap awal dalam proses analisis yang bertujuan untuk mempersiapkan data agar dapat digunakan dalam pemodelan. Tahap ini mencakup serangkaian proses seperti pembersihan, transformasi, penskalaan, serta pembentukan struktur input dan pemisahan data (Zafira et al., 2024). Tujuan utamanya adalah untuk meningkatkan kesesuaian dan kualitas data sehingga hasil prediksi menjadi lebih akurat (Haq et al., 2024).

2.5.1 Transformasi Data

Transformasi data dilakukan untuk menyesuaikan struktur atau bentuk data sesuai kebutuhan metode analisis yang digunakan. Proses ini dapat mencakup perubahan format tabel, penyatuan atau pemisahan atribut, serta penyesuaian nilai agar sesuai dengan standar input model (Giga Razki Ardiansyah et al., 2023). Selain itu, beberapa atribut dalam dataset dapat mengalami perubahan skala atau distribusi untuk memenuhi persyaratan algoritma tertentu pemodelan (Agung et al., 2023).

2.5.2 Data Cleaning

Data cleaning merupakan proses untuk mengidentifikasi dan memperbaiki data yang tidak lengkap, tidak valid, atau tidak konsisten (Raharja et al., 2024). Langkah ini dapat dilakukan dengan menghapus duplikat, mengoreksi format yang

salah, serta menghilangkan nilai-nilai yang tidak diperlukan. Tujuannya adalah agar hanya data yang relevan dan bersih yang digunakan dalam pelatihan model (Sawitri & Medan, 2025). Pembersihan juga dapat melibatkan penghapusan atribut yang tidak memiliki pengaruh signifikan terhadap keluaran model (Gori et al., 2024).

2.5.3 Exploratory Data Analysis (EDA)

Exploratory Data Analysis (EDA) merupakan tahap awal untuk memahami kondisi dan karakteristik data sebelum masuk ke proses pemodelan. Pada tahap ini dilakukan pembuatan visualisasi, seperti grafik garis deret waktu, untuk melihat pola pergerakan harga, tren kenaikan atau penurunan, serta fluktuasi yang terjadi dari waktu ke waktu. EDA juga mencakup analisis statistik deskriptif yang membantu mengidentifikasi sebaran data, nilai ekstrem, dan kemungkinan anomali. Hasil analisis ini menjadi dasar dalam menentukan kebutuhan pre-processing serta memastikan data berada dalam kondisi yang tepat untuk proses pemodelan selanjutnya (Pratama & Sanjaya, 2025).

2.5.4 Missing Value

Missing value adalah kondisi ketika nilai suatu atribut tidak tersedia untuk satu atau beberapa entri data. Hal ini bisa terjadi karena data tidak dikumpulkan, tidak ditemukan, atau memang tidak ada (Miraati Laia, 2023). Nilai kosong dapat mengurangi jumlah data yang tersedia untuk pelatihan, dan jika dibiarkan, dapat menurunkan akurasi prediksi model (Widianti & Pratama, 2024). Salah satu metode yang dapat digunakan untuk menangani nilai hilang (missing value) adalah *Last*

Observation Carried Forward (LOCF). Metode ini mengisi data yang tidak lengkap dengan menggunakan nilai terakhir yang tercatat sebelum data tersebut hilang. Dengan demikian, nilai pada periode yang tidak tercatat dianggap sama dengan nilai sebelumnya yang masih tersedia. Jika data yang hilang terdapat pada awal deret, maka pengisian dilakukan menggunakan nilai pertama dari data yang lengkap. Pendekatan ini dinilai sesuai untuk data harga pangan karena perubahan harga umumnya tidak bersifat ekstrem dalam jangka waktu pendek (L. S. Hasibuan & Novialdi, 2022).

2.5.5 Normalisasi Data

Normalisasi diperlukan ketika fitur dalam dataset memiliki rentang nilai yang berbeda, sehingga fitur dengan skala besar tidak mendominasi model. Normalisasi data dapat dilakukan menggunakan metode Min–Max Scaling, yaitu teknik yang mengubah skala data ke dalam rentang nilai antara 0 dan 1. Proses ini dilakukan untuk mengatasi perbedaan skala antar variabel, karena model *Long Short-Term Memory* (LSTM) sangat sensitif terhadap variasi skala input. Dengan melakukan normalisasi, proses pelatihan model menjadi lebih stabil, efisien, dan menghasilkan akurasi prediksi yang lebih baik. Persamaan normalisasi Min–Max dituliskan pada persamaan 2.2.

$$X_{norm} = \frac{X - X_{min}}{X_{max} - X_{min}} \quad (2.2)$$

Keterangan:
X_{norm} : Nilai hasil normalisasi.
X : Nilai data asli sebelum dinormalisasi.
X_{max} : Nilai maksimum dari keseluruhan data.
X_{min} : Nilai minimum dari keseluruhan data.

2.5.6 Split Data

Split data adalah proses pembagian data menjadi dua atau lebih bagian untuk keperluan pelatihan dan pengujian model. Dalam prediksi deret waktu, pembagian ini dilakukan secara berurutan berdasarkan waktu (chronological split), bukan secara acak (Oktafiani et al., 2023). Hal ini dilakukan untuk menjaga alur waktu dalam dataset dan mencegah kebocoran informasi dari masa depan ke masa lalu yang dapat menyebabkan hasil evaluasi menjadi tidak valid (Alhafiz & R, 2025).

Dalam penelitian ini digunakan rasio pembagian data 70% untuk *training set*, 15% untuk *validation set*, dan 15% untuk *test set* dengan metode *time-based split* untuk menjaga urutan temporal data. Pemilihan rasio tersebut didukung oleh temuan Akbar et al (2025), yang menunjukkan bahwa skenario pembagian dataset 70:15:15 memberikan performa yang lebih baik dibandingkan skenario lain. Dalam studi tersebut, proporsi data validasi yang lebih besar memungkinkan evaluasi model dilakukan secara lebih optimal sehingga potensi *overfitting* atau *underfitting* dapat terdeteksi lebih awal. Hasil evaluasi memperlihatkan bahwa rasio 70:15:15 menghasilkan nilai MAE, RMSE, dan MAPE yang lebih rendah, menandakan kemampuan generalisasi model yang lebih baik.

2.5.7 Sliding Window

Sliding window merupakan teknik yang digunakan untuk mengubah data deret waktu menjadi kumpulan potongan data berurutan dengan panjang jendela tertentu. Setiap potongan atau *window* terdiri atas sejumlah nilai historis yang digunakan sebagai masukan (*input*), dan satu nilai berikutnya yang digunakan

sebagai target (*output*) untuk proses prediksi (Arsi et al., 2022). Teknik ini memungkinkan model, khususnya model berbasis urutan seperti LSTM, untuk memahami hubungan temporal antar data secara lebih efektif dan menghasilkan prediksi yang lebih akurat terhadap nilai di masa depan (Radho et al., 2022). Verianto (2024) menjelaskan penerapan *sliding window* menjaga kontinuitas waktu dalam data sehingga model dapat mempelajari pola perubahan harga secara konsisten tanpa kehilangan konteks historis. Dengan cara ini, model dapat mengenali tren jangka pendek maupun jangka panjang dari data historis harga. Secara matematis, *sliding window* dapat dinyatakan dengan persamaan 2.3.

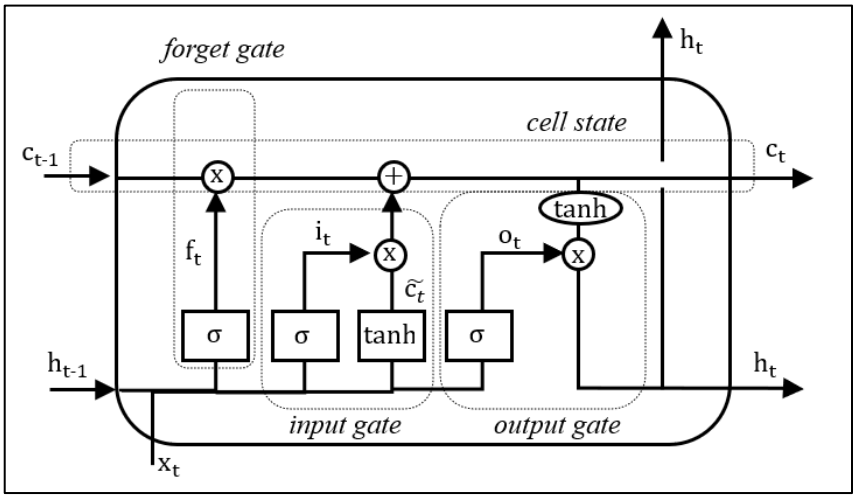
$$[\mathrm{X}_t = [X_{t-n}, X_{t-n+1}, \dots, X_{t-1}], \quad y_t = X_t] \tag{2.3}$$

Keterangan:
$\mathrm{X_t}$: nilai data pada waktu ke-t.
$\mathrm{X_t}$: vektor input yang berisi data sepanjang nnn hari sebelum waktu ke- t.
$\mathrm{y_t}$: nilai target yang akan diprediksi pada waktu ke- t.
N : ukuran jendela (window size), yaitu jumlah data historis yang digunakan sebagai input.

2.6 *Long Short-Term Memory* (LSTM)

Long Short-Term Memory (LSTM) merupakan salah satu arsitektur jaringan saraf tiruan yang dikembangkan dari model Recurrent Neural Network (RNN). LSTM dirancang untuk mengatasi kelemahan utama pada RNN konvensional, yaitu hilangnya nilai gradien (*vanishing gradient problem*), yang menyebabkan jaringan sulit mengingat informasi dalam jangka waktu yang panjang. Untuk mengatasi hal tersebut, LSTM mengadopsi mekanisme *gating system* yang memungkinkan jaringan untuk menyimpan, memperbarui, dan melupakan informasi secara selektif sesuai kebutuhan (Febriyanti et al., 2025).

Arsitektur LSTM terdiri dari empat komponen utama, yaitu input gate, forget gate, output gate, dan cell state. Pertama, *input gate* yang menentukan seberapa banyak informasi baru dari input akan disimpan dalam *cell state*. Kedua, *forget gate* berfungsi untuk memilih informasi dari memori sebelumnya yang perlu dihapus. Ketiga, *output gate* mengatur informasi yang akan dikirim sebagai keluaran pada waktu tertentu. Sementara itu, *cell state* berperan sebagai memori jangka panjang yang membawa informasi dari waktu ke waktu dalam urutan data (Febriyanti et al., 2025). Arsitektur model LSTM terhubung secara berurutan dan mengatur arus data berdasarkan masukan baru serta kondisi memori sebelumnya Gambar 2.1.



Gambar 2.1 Arsitektur Model LSTM (Cahyani et al., 2023)

Metode *Long Short-Term Memory* (LSTM) memiliki arsitektur yang serupa dengan *Recurrent Neural Network* (RNN), namun memiliki mekanisme internal yang lebih kompleks dalam mengatur proses penyimpanan informasi jangka panjang melalui komponen yang disebut *gate*. LSTM terdiri atas empat gerbang utama, yaitu *forget gate*, *input gate*, *cell state*, dan *output gate*. Setiap gerbang

berfungsi mengatur aliran informasi berdasarkan masukan pada waktu ke-ttt serta *hidden state* dari waktu sebelumnya (Cahyani et al., 2023).

Gerbang pertama adalah forget gate, yang berfungsi menentukan informasi mana dari *cell state* sebelumnya yang perlu dipertahankan atau dihapus. Nilai *forget gate* dihitung menggunakan fungsi aktivasi sigmoid sebagaimana ditunjukkan pada persamaan 2.4 (Cahyani et al., 2023).

$$f_t = \sigma\left(W_f[h_{t-1}, x_t] + b_f\right) \tag{2.4}$$

Keterangan:
f_t : nilai forget gate pada waktu ke-t.
σ : fungsi aktivasi sigmoid.
W_f : bobot pada forget gate.
h_{t-1} : hidden state pada waktu sebelumnya.
x_t : nilai masukan pada waktu ke-t
b_f : nilai bias pada forget gate.

Melalui gerbang forget gate, LSTM dapat menghapus informasi yang tidak relevan dari memori dan hanya mempertahankan informasi penting yang akan digunakan untuk pembaruan berikutnya. Selanjutnya adalah input gate, yang berfungsi mengatur informasi baru yang akan disimpan ke dalam *cell state*. Sama seperti *forget gate*, gerbang ini juga menggunakan fungsi aktivasi sigmoid untuk menentukan proporsi informasi baru yang perlu ditambahkan. Persamaan input gate dapat ditulis pada persamaan 2.5 (Cahyani et al., 2023).

$$i_t = \sigma(W_i[h_{t-1}, x_t] + b_i) \tag{2.5}$$

Keterangan:
i_t : nilai input gate pada waktu ke-t.
W_i : bobot pada input gate.
b_i : bias pada input gate.
h_{t-1} : hidden state sebelumnya.
x_t : masukan pada waktu ke-t.

Setelah itu, LSTM menghitung kandidat *cell state* baru ($\widetilde{C_t}$) yang merepresentasikan informasi baru yang dapat ditambahkan ke memori. Proses ini menggunakan fungsi aktivasi *tanh* sebagaimana dirumuskan pada persamaan 2.6 (Cahyani et al., 2023).

$$\widetilde{C_t} = \tanh(W_c[h_{t-1}, x_t] + b_c) \quad (2.6)$$

Keterengan:
$\widetilde{C_t}$: kandidat nilai cell state baru
W_c : bobot pada cell state
b_c : bias pada cell state
h_{t-1} : hidden state sebelumnya
x_t : nilai masukan pada waktu ke-t.

Setelah nilai *forget gate*, *input gate*, dan kandidat *cell state* baru diperoleh, maka nilai cell state diperbarui dengan menggabungkan informasi lama yang dipertahankan dan informasi baru yang ditambahkan. Pembaruan *cell state* ditunjukkan oleh persamaan 2.7 (Cahyani et al., 2023).

$$C_t = f_t * C_{t-1} + i_t * \widetilde{C_t} \quad (2.7)$$

Keterangan:
C_t : nilai cell state pada waktu ke-t.
C_{t-1} : cell state pada waktu sebelumnya.
f_t : forget gate.
i_t : input gate.
$\widetilde{C_t}$: kandidat cell state baru.

Nilai *cell state* ini berperan sebagai memori jangka panjang yang membawa informasi penting dari satu waktu ke waktu berikutnya. Tahap berikutnya adalah output gate, yang menentukan bagian dari *cell state* yang akan digunakan untuk menghasilkan *hidden state* baru. Nilai *output gate* dihitung menggunakan fungsi aktivasi sigmoid pada persamaan 2.8 (Cahyani et al., 2023).

$$o_t = \sigma(W_o[h_{t-1}, x_t] + b_o) \quad (2.8)$$

Keterangan:

o_t : nilai output gate pada waktu ke-t
W_o : bobot pada output gate.
b_o : bias pada output gate.
h_{t-1} : hidden state sebelumnya.
x_t : nilai masukan pada waktu ke-t.

Proses terakhir adalah keluaran akhir (hidden state), dihitung dengan mengalikan aktivasi dari *cell state* saat ini dengan nilai output gate. Proses ini memastikan bahwa hanya informasi penting dari memori yang digunakan untuk menghasilkan keluaran. Rumus hidden state ditulis pada persamaan 2.9 (Cahyani et al., 2023).

$$h_t = o_t * \tanh(C_t) \tag{2.9}$$

Keterangan:
h_t : hidden state pada waktu ke-t.
o_t : output gate,
C_t : cell state saat ini.

Nilai *hidden state* ini menjadi keluaran utama dari unit LSTM pada waktu ke-t, sekaligus menjadi masukan bagi proses pada waktu berikutnya. Melalui mekanisme empat gerbang tersebut, LSTM mampu menyimpan, memperbarui, dan menghapus informasi secara adaptif sehingga lebih efektif dalam mempelajari pola temporal jangka panjang maupun jangka pendek pada data deret waktu (Cahyani et al., 2023).

Melalui rangkaian proses tersebut, LSTM mampu menyaring dan menyimpan informasi yang relevan dari waktu ke waktu, sekaligus menghindari hilangnya gradien selama pelatihan. Kemampuan ini menjadikan LSTM efektif dalam menangkap hubungan jangka panjang, pola musiman, serta fluktuasi non-linear yang sering muncul pada data deret waktu (Nugroho et al., 2025).

2.7 *Mean Absolute Percentage Error* (MAPE)

Evaluasi terhadap performa model prediksi sangat penting dilakukan untuk mengetahui sejauh mana hasil prediksi mendekati nilai aktual. Dalam analisis data deret waktu, salah satu metrik yang umum digunakan untuk mengevaluasi akurasi model adalah *Mean Absolute Percentage Error* (MAPE). MAPE merupakan metrik evaluasi yang menyatakan rata-rata kesalahan absolut dalam bentuk persentase terhadap nilai aktual. Penggunaan persentase dalam MAPE memudahkan interpretasi, karena satuan kesalahan tidak bergantung pada skala data (Meriani & Rahmatulloh, 2024).

MAPE dihitung dengan cara mengambil rata-rata dari nilai absolut selisih antara nilai aktual dan nilai prediksi, kemudian dibagi dengan nilai aktual, dan hasilnya dikalikan 100%. Proses ini menghasilkan ukuran kesalahan dalam bentuk persentase yang relatif terhadap nilai sebenarnya. Dengan demikian, MAPE sangat berguna dalam konteks perbandingan performa antar model, terutama ketika digunakan pada data yang memiliki satuan atau skala yang berbeda-beda (Sulastri et al., 2023). Secara matematis, rumus MAPE dinyatakan pada persamaan 2.10.

$$MAPE = \frac{1}{n}\sum_{i=1}^{n}\left|\frac{X_i - F_i}{X_i}\right| \times 100\% \qquad (2.10)$$

Keterangan:
MAPE : Mean Absolute Percentage Error (kesalahan persentase absolut rata-rata)
X_i : nilai aktual pada observasi ke-i
F_i : nilai hasil prediksi model pada observasi ke-i
n : jumlah total observasi.

Persamaan tersebut menggambarkan bahwa MAPE dihitung dengan menjumlahkan seluruh nilai kesalahan relatif absolut antara nilai aktual dan nilai prediksi, kemudian dibagi dengan jumlah total data, dan dikonversi ke dalam

bentuk persentase. Semakin kecil nilai MAPE, maka semakin baik kemampuan model dalam melakukan prediksi. Secara umum, nilai MAPE di bawah 10% dikategorikan sangat baik, antara 10%–20% baik, 20%–50% cukup, dan di atas 50% menunjukkan akurasi yang rendah (Sulastri et al., 2023).

BAB III

DESAIN DAN IMPLEMENTASI

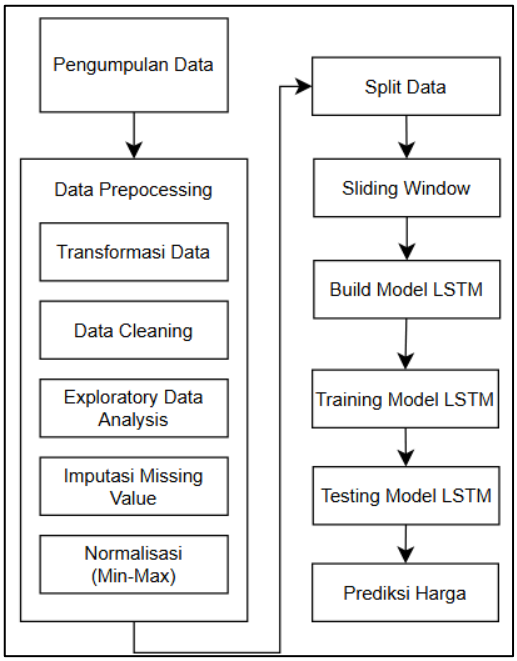
3.1 Desain Sistem

Tahapan desain sistem dalam penelitian ini dimulai dari proses pengumpulan data harga harian sembilan komoditas pangan strategis di Jawa Tengah yang diperoleh dari Pusat Informasi Harga Pangan Strategis Nasional (PIHPS) untuk periode tahun 2020–2025. Data mentah yang telah terkumpul kemudian memasuki tahap pra-pemrosesan (data preprocessing). Tahap pra-pemrosesan meliputi transformasi data, pembersihan data, exploratory data analysis (EDA) untuk memahami pola, tren, imputasi nilai hilang untuk memperbaiki missing value, serta normalisasi Min–Max agar seluruh variabel berada pada rentang nilai yang seragam sehingga proses pelatihan model menjadi lebih stabil.

Setelah proses pra-pemrosesan selesai, data kemudian melalui tahap split data, yaitu pembagian data menjadi tiga subset, data latih (training), data validasi (validation), dan data uji (testing). Pembagian dilakukan secara kronologis berdasarkan urutan waktu guna mempertahankan struktur temporal dari data deret waktu. Selanjutnya dilakukan sliding window, yaitu pembentukan jendela data dengan panjang tertentu (window size) untuk menghasilkan urutan histori harga yang akan menjadi input bagi model dalam melakukan prediksi harga satu langkah ke depan (one-step ahead forecasting).

Pada tahap berikutnya, data hasil sliding window digunakan untuk membangun model Long Short-Term Memory (LSTM). Proses ini mencakup penyusunan arsitektur model yang terdiri dari lapisan input, lapisan tersembunyi

(hidden layer) LSTM, dan lapisan output. Setelah model berhasil dibangun, dilakukan pelatihan model (training) menggunakan data latih dan pemantauan performa melalui data validasi untuk mencegah overfitting serta memastikan model mampu mempelajari pola historis dengan optimal. Setelah training selesai, model memasuki tahap pengujian (testing) menggunakan data uji untuk menghasilkan prediksi harga komoditas pada periode yang belum pernah dilihat model sebelumnya. Alur desain sistem yang digunakan dalam penelitian Gambar 3.1.



Gambar 3.1 Alur Desain Sistem

3.2 Pengumpulan Data

Data yang digunakan dalam penelitian ini diperoleh dari Pusat Informasi Harga Pangan Strategis Nasional (PIHPS Nasional) melalui laman resmi https://hargapangan.id. Pengumpulan data difokuskan pada wilayah Provinsi Jawa Tengah dan mencakup sembilan komoditas pangan, yaitu beras, daging ayam,

daging sapi, telur ayam, bawang merah, cabai merah, cabai rawit, minyak goreng, dan gula pasir.

Rentang waktu data yang digunakan adalah 1 Januari 2020 hingga 30 September 2025, dengan frekuensi pencatatan harian. Dataset disediakan dalam format wide format, di mana setiap baris merepresentasikan satu komoditas dan kolom selanjutnya menunjukkan tanggal, bulan, dan tahun harga sarian dengan satuan rupiah. Komoditas pangan yang digunakan terdiri dari 9 komoditas Tabel 3.1.

Tabel 3.1 Contoh Dataset Harga Harian Komoditas Pangan

No	**Komoditas (Rp)**	**1/1/2020**	**02/ 01/ 2020**	**03/ 01/ 2020**	**06/ 01/ 2020**	**07/ 01/ 2020**	**08/ 01/ 2020**
I	Beras	9,350	9,350	9,350	9,350	9,350	9,350
II	Daging Ayam	26,000	26,000	26,000	26,000	26,000	26,000
III	Daging Sapi	101,800	101,800	101,800	101,800	101,800	101,800
IV	Telur Ayam	21,950	21,950	21,950	21,950	21,950	21,950
V	Bawang Merah	24,400	24,400	24,400	24,400	24,400	24,400
VI	Cabai Merah	20,500	20,500	20,500	20,500	20,500	20,500
VII	Cabai Rawit	20,250	20,250	20,250	20,250	20,250	20,250
VIII	Minyak Goreng	9,000	9,000	9,000	9,000	9,000	9,000
IX	Gula Pasir	11,150	11,150	11,150	11,150	11,150	11,150

3.3 Pre-processing

Pra-pemrosesan data merupakan tahap awal dalam pengembangan model prediksi harga komoditas pangan berbasis data deret waktu. Tujuan utama dari tahap ini adalah menyiapkan data agar sesuai dengan kebutuhan struktur input model LSTM. Pada penelitian ini, tahapan pra-pemrosesan mencakup proses

pembersihan nilai tidak valid, transformasi data, imputasi missing value, deteksi dan penanganan outlier, normalisasi, pembentukan sliding window, serta pembagian data menjadi subset pelatihan, validasi, dan pengujian.

3.3.1 Transformasi Data

Tahap transformasi data dilakukan untuk menyesuaikan struktur dataset agar sesuai dengan kebutuhan model deret waktu berbasis LSTM. Dataset awal yang diperoleh dari PIHPS Nasional disajikan dalam format *long*, di mana setiap baris berisi satu entri data yang terdiri atas atribut tanggal, nama komoditas, dan harga harian. Format tersebut belum dapat langsung digunakan dalam pelatihan model karena setiap komoditas masih terpisah berdasarkan nama, sedangkan model LSTM memerlukan struktur data yang terorganisasi berdasarkan urutan waktu.

Langkah pertama dalam proses transformasi adalah menggabungkan seluruh file data harga komoditas dari tahun 2020 hingga 2025 menjadi satu dataset terpadu. Setelah itu, data yang semula dalam format *long* diubah ke format *wide* menggunakan proses *pivoting*, dengan menjadikan tanggal sebagai indeks utama dan setiap komoditas pangan sebagai kolom. Dengan demikian, setiap baris pada dataset *wide* merepresentasikan tanggal, bulan dan tahun data, sedangkan setiap kolom menunjukkan harga harian dari masing-masing komoditas pangan.

Transformasi ini bertujuan untuk memudahkan proses analisis dan pembentukan jendela waktu (*sliding window*) pada tahap berikutnya. Selain itu, penyusunan data ke dalam format *wide* memungkinkan model membaca seluruh harga komoditas pada tanggal yang sama secara paralel, baik untuk pendekatan

univariat maupun multivariat. Sebelum transformasi, dataset disajikan dalam bentuk long pada Tabel 3.1. Hasil transformasi data dari format long ke wide Tabel 3.2.

Tabel 3.2 Contoh Data Setelah Proses Transformasi ke Wide Format

No.	Date	Beras	Daging Ayam	Daging Sapi	…	Cabai Rawit	Minyak Goreng	Gula Pasir
1.	1/2/2020	9,350	26,000	101,800	…	20,250	9,000	11,150
2.	1/3/2020	9,350	26,000	101,800	…	20,250	9,000	11,150
3.	1/6/2020	9,350	26,000	101,800	…	20,250	9,000	11,150
4.	1/7/2020	9,350	26,000	101,800	…	20,250	9,000	11,150
5.	1/8/2020	9,350	26,000	101,800	…	20,250	9,000	11,150
6.	1/9/2020	9,350	26,000	101,800	…	20,250	9,000	11,150

3.3.2 Cleaning data

Tahap data cleaning dilakukan untuk memastikan bahwa data harga yang diperoleh dari Pusat Informasi Harga Pangan Strategis Nasional (PIHPS) memiliki format yang seragam dan dapat diolah dalam analisis numerik. Pada dataset awal, sebagian nilai harga dituliskan menggunakan tanda koma (,) sebagai pemisah ribuan, misalnya “9,350”. Penulisan tersebut menyebabkan kolom harga terbaca sebagai tipe string, sehingga tidak dapat digunakan langsung dalam perhitungan matematis maupun pada proses pemodelan.

Untuk mengatasi hal ini, dilakukan pembersihan data dengan menghapus seluruh tanda koma (,) sehingga nilai harga dapat dikonversi ke tipe numerik (float). Setelah proses ini, seluruh kolom harga memiliki format yang konsisten dan siap digunakan pada tahap pra-pemrosesan berikutnya seperti interpolasi, normalisasi, dan pembentukan sliding window. Contoh data sebelum pembersihan pada Tabel 3.2, kemudian hasil data setelah proses cleaning data Tabel 3.3.

Tabel 3.3.Contoh Data Setelah Proses Cleaning Data

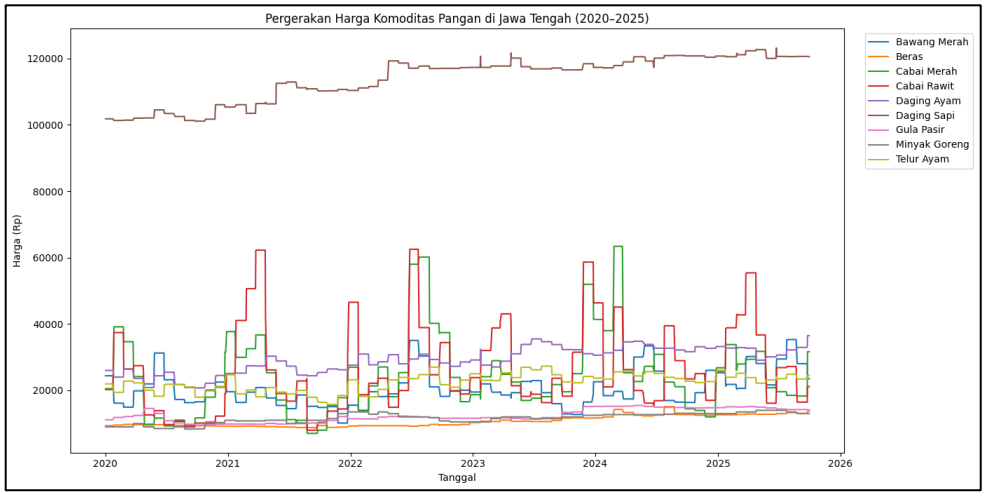
No.	Date	Beras	Daging Ayam	Daging Sapi	…	Minyak Goreng	Gula Pasir
1.	1/2/2020	9350	26000	101800	…	9000	11150
2.	1/3/2020	9350	26000	101800	…	9000	11150
3.	1/6/2020	9350	26000	101800	…	9000	11150
4.	1/7/2020	9350	26000	101800	…	9000	11150
5.	1/8/2020	9350	26000	101800	…	9000	11150
6.	1/9/2020	9350	26000	101800	…	9000	11150

3.3.3 Exploratory Data Analysis (EDA)

Exploratory Data Analysis (EDA) dilakukan untuk memperoleh pemahaman awal mengenai pola, tren, serta karakteristik fluktuasi harga komoditas pangan di Jawa Tengah selama periode 2020–2025. Pada tahap ini, seluruh data komoditas divisualisasikan dalam bentuk grafik deret waktu untuk mengamati pergerakan harga dari hari ke hari. Visualisasi tersebut memudahkan identifikasi komoditas dengan volatilitas tinggi, tren jangka panjang, serta periode lonjakan harga yang berulang.

Visualisasi EDA data harga komoditas pangan di jawa tengah periode tahun 2020 – 2025 menunjukkan bahwa komoditas memiliki pola pergerakan harga yang berbeda. Komoditas seperti cabai merah, cabai rawit, dan bawang merah menunjukkan fluktuasi yang sangat tajam, ditandai dengan puncak harga yang berulang setiap tahun. Hal ini mengindikasikan sifat musiman (seasonality) yang kuat serta sensitivitas komoditas hortikultura terhadap kondisi cuaca dan distribusi. Sebaliknya, komoditas beras, minyak goreng, gula pasir, serta telur ayam menunjukkan pola yang relatif stabil dengan perubahan harga yang tidak terlalu ekstrem. Sementara itu, daging sapi terlihat berada pada kisaran harga yang jauh lebih tinggi dibandingkan komoditas lain dan cenderung memiliki tren stabil

dengan peningkatan bertahap sepanjang periode pengamatan. Visualisasi pergerakan harga komoditas pangan di Jawa Tengah Tahun 2020 – 2025 Gambar 3.2.



Gambar 3.2 Pergerakan Harga Komoditas Pangan di Jawa Tengah Tahun 2020–2025

3.3.4 Imputasi Missing Value

Dalam data deret waktu harga komoditas, sering dijumpai adanya tanggal-tanggal yang tidak memiliki catatan harga akibat keterlambatan pelaporan atau gangguan pencatatan di lapangan. Nilai yang hilang tersebut disebut *missing value* dan perlu diimputasi agar data tetap kontinu serta dapat digunakan pada tahap pelatihan model.

Untuk menangani nilai yang hilang, penelitian ini menggunakan metode Last Observation Carried Forward (LOCF). Metode ini mengisi nilai yang tidak tercatat dengan menggunakan harga terakhir yang tersedia sebelum terjadi kekosongan data. Apabila terdapat satu atau beberapa tanggal berturut-turut tanpa catatan harga, maka nilai pada tanggal-tanggal tersebut digantikan dengan harga terakhir yang tercatat sebelumnya. Pendekatan ini dinilai sesuai untuk data harga

pangan karena perubahan harga biasanya bersifat gradual dan tidak mengalami fluktuasi ekstrem dari hari ke hari, sehingga nilai sebelumnya masih representatif terhadap kondisi aktual.

Tabel 3.4 Contoh Data Harga Komoditas Minyak Goreng Sebelum Penerapan Imputasi Missing Value LOCF

No.	Tanggal	Harga (Rp)
1.	23 Januari 2023	10.500
2.	24 Januari 2023	–
3.	25 Januari 2023	10.500

Contoh data sebelum imputasi ditunjukkan pada Tabel 3.4, di mana harga komoditas Minyak Goreng pada tanggal 23 Januari 2023 tercatat sebesar Rp 10.500, sedangkan pada tanggal 24 Januari 2023 tidak tersedia nilai harga (*missing value*). Untuk mengatasi kekosongan tersebut, digunakan metode imputasi Last Observation Carried Forward (LOCF), yaitu mengisi nilai yang hilang dengan harga terakhir yang tercatat. Dengan demikian, nilai pada tanggal 24 Januari 2023 diisi menggunakan harga tanggal sebelumnya, yaitu Rp 10.500. Hasil setelah penerapan imputasi LOCF Tabel 3.5.

Tabel 3.5 Contoh Data Harga Komoditas Minyak Goreng Setelah Penerapan Imputasi Missing Value LOCF

No.	Tanggal	Harga (Rp)
1.	23 Januari 2023	10.500
2.	24 Januari 2023	10.500
3.	25 Januari 2023	10.500

Nilai hasil imputasi yang diperoleh melalui metode LOCF selanjutnya digunakan sebagai bagian dari dataset bersih yang siap diproses lebih lanjut pada tahap pra-pemrosesan berikutnya.

3.3.5 Normaliasi Data

Setelah data dibersihkan dari *outlier*, tahap selanjutnya adalah melakukan normalisasi data. Tahap ini bertujuan untuk menyamakan skala antar komoditas agar model tidak bias terhadap harga dengan rentang nilai yang besar. Proses normalisasi juga membantu mempercepat konvergensi model dan meningkatkan stabilitas selama proses pelatihan pada metode LSTM.

Penelitian ini menggunakan metode *Min–Max Scaling*, sebagaimana dijelaskan pada rumus (2.2) pada Bab II, yang berfungsi untuk memetakan nilai ke dalam rentang $[0,1]$. Nilai minimum $x_{\min}$ dan maksimum $x_{\max}$ diperoleh dari data latih, dan parameter tersebut juga digunakan untuk menormalkan data validasi serta data uji agar skala seluruh subset data tetap konsisten dan tidak terjadi *data leakage*.

Sebagai contoh, jika harga beras pada tanggal 1 Januari 2020 sebesar Rp 9.350, dengan nilai minimum dari data latih $x_{\min} = 9.300$ dan nilai maksimum $x_{\max} = 9.500$, maka hasil normalisasi dihitung sebagai berikut:

$$x_{\text{norm}} = \frac{9.350 - 9.300}{9.500 - 9.300} = \frac{50}{200} = 0.25$$

Nilai hasil normalisasi sebesar 0,25 menunjukkan bahwa harga beras pada tanggal tersebut berada pada posisi 25% dari rentang nilai antara harga minimum dan maksimum dalam data pelatihan. Nilai-nilai hasil normalisasi seperti ini kemudian digunakan sebagai *input feature* dalam model LSTM. Setelah proses pelatihan dan prediksi selesai, dilakukan denormalisasi untuk mengembalikan nilai hasil prediksi ke dalam satuan rupiah agar dapat dibandingkan langsung dengan data aktual. Sebagai ilustrasi, contoh hasil normalisasi data harga beras Tabel 3.6.

Tabel 3.6 Contoh Data Harga Beras Setelah Normalisasi

No.	Tanggal	Harga Asli (Rp)	Nilai Normalisasi
1.	01 Januari 2020	9.350	0.25
2.	02 Januari 2020	9.400	0.50
3.	03 Januari 2020	9.450	0.75
4.	06 Januari 2020	9.500	1.00
5.	07 Januari 2020	9.400	0.50
6.	08 Januari 2020	9.350	0.25
7.	09 Januari 2020	9.300	0.00

Pada contoh di atas, nilai harga beras bervariasi dari Rp 9.300 hingga Rp 9.500, sehingga hasil normalisasi mencerminkan perubahan skala yang proporsional antar tanggal. Data hasil normalisasi ini selanjutnya digunakan sebagai masukan pada model LSTM untuk mengenali pola perubahan harga dan melakukan prediksi harga pada periode berikutnya.

3.3.6 Pembagian Data (Splitting Data)

Setelah data dinormalisasi, tahap selanjutnya adalah pembagian data (splitting data) menjadi tiga subset, yaitu data latih, data validasi, dan data uji. Pembagian dilakukan secara kronologis berdasarkan urutan waktu agar dependensi temporal antar data tetap terjaga dan tidak terjadi data leakage atau kebocoran informasi dari periode masa depan ke dalam data pelatihan.

Proporsi pembagian yang digunakan dalam penelitian ini adalah 70% untuk data latih, 15% untuk data validasi, dan 15% untuk data uji. Data latih digunakan dalam proses pembelajaran model untuk mengenali pola historis harga, sedangkan data validasi berfungsi untuk memantau kinerja model selama pelatihan dan

membantu dalam penentuan parameter yang optimal. Sementara itu, data uji digunakan untuk mengukur kemampuan generalisasi model terhadap data baru yang belum pernah digunakan dalam proses pelatihan.

Tahap pembagian data ini dilakukan sebelum proses sliding window, sehingga pembentukan jendela waktu dilakukan secara terpisah pada masing-masing subset. Dengan demikian, setiap subset tetap merepresentasikan urutan waktu yang berkesinambungan dan dapat digunakan secara konsisten dalam proses pelatihan, validasi, serta pengujian model LSTM.

3.3.7 Pembentukan Sliding Window

Tahap berikutnya adalah pembentukan *sliding window*, yang berfungsi untuk mengubah data deret waktu menjadi kumpulan pasangan data input dan target (*X*, *y*) yang akan digunakan dalam proses pelatihan model LSTM. Setiap *window* terdiri atas sejumlah data harga harian pada periode sebelumnya yang digunakan untuk memprediksi harga pada hari berikutnya. Teknik ini membantu model dalam mengenali hubungan berurutan antar waktu dan mempelajari pola perubahan harga secara konsisten dari data historis.Jika panjang window dilambangkan dengan W, Proses pembentukan *sliding window* pada penelitian ini mengikuti rumus (2.3) pada Bab II, di mana sejumlah nilai historis sepanjang *n* hari dijadikan sebagai input (X_t), sedangkan nilai pada hari ke-t dijadikan sebagai target (y_t). Dengan pendekatan ini, model LSTM dapat mempelajari hubungan temporal antar data untuk menghasilkan prediksi harga yang lebih akurat pada periode berikutnya.

Sebagai contoh penerapan, digunakan data harga beras yang telah dinormalisasi pada Tabel 3.6. Digunakan panjang jendela (*window size*) tiga hari (W = 3), di mana tiga nilai harga sebelumnya dijadikan sebagai *input* dan satu nilai berikutnya digunakan sebagai *target* keluaran model Tabel 3.7.

Tabel 3.7 Contoh Pembentukan Data Sliding Window (W = 3)

No.	Window ke-	Input (X)	Target (y)
1.	1	[0.25, 0.50, 0.75]	1.00
2.	2	[0.50, 0.75, 1.00]	0.50
3.	3	[0.75, 1.00, 0.50]	0.25
4.	4	[1.00, 0.50, 0.25]	0.00

Pada pembentukan data sliding window dengan W=3 Tabel 3.7. Jadi setiap baris merepresentasikan satu *window* yang berisi tiga hari data historis sebagai masukan untuk memprediksi harga pada hari berikutnya. Teknik ini menjaga keterurutan waktu pada data sehingga model dapat mempelajari dinamika fluktuasi harga secara berkelanjutan.

Dalam penelitian ini, digunakan beberapa variasi panjang *window* untuk menguji pengaruh konteks historis terhadap kinerja model prediksi. Konfigurasi panjang *window* yang akan digunakan pada penelitian Tabel 3.8.

Tabel 3.8 Variasi Panjang Sliding Window yang Diterapkan

No.	Panjang Window (hari)	Keterangan
1.	7	Digunakan untuk mengamati pola perubahan harga jangka pendek
2.	14	Digunakan untuk mengamati pola perubahan harga jangka menengah
3.	30	Digunakan untuk mengamati pola perubahan harga jangka panjang

3.4 Implementasi Model Long Short-Term Memory (LSTM)

Implementasi model *Long Short-Term Memory* (LSTM) dilakukan untuk membangun sistem prediksi harga harian komoditas pangan di Provinsi Jawa Tengah berdasarkan data deret waktu periode 2020–2025. Model LSTM dipilih karena mampu mempelajari pola ketergantungan jangka panjang (*long-term dependencies*) melalui mekanisme *cell state* dan *gating function*. Kemampuan ini membuat LSTM efektif dalam menangkap dinamika perubahan harga yang bersifat musiman dan fluktuatif dari waktu ke waktu.

Data yang digunakan berasal dari hasil tahap *pre-processing* yang telah melalui proses *sliding window*. Data tersebut kemudian dijadikan masukan (*input*) ke dalam model LSTM dalam bentuk urutan harga beberapa hari sebelumnya untuk memprediksi harga pada hari berikutnya (*one-step ahead prediction*).

Model LSTM dirancang dengan tiga lapisan utama, yaitu *input layer*, *hidden layer* (LSTM), dan *output layer* (Dense). *Input layer* menerima data dalam format jendela waktu (*window size*) tertentu, *hidden layer* berfungsi mengenali hubungan temporal antar waktu dengan jumlah unit neuron yang divariasikan, sedangkan *output layer* menghasilkan satu nilai prediksi dalam skala hasil normalisasi. Nilai keluaran model kemudian dikembalikan ke skala asli (rupiah) melalui proses *denormalisasi* agar dapat dibandingkan secara langsung dengan harga aktual.

Pelatihan model dilakukan secara kronologis tanpa pengacakan urutan data untuk menjaga konsistensi waktu. Optimisasi parameter dilakukan menggunakan algoritma Adam dengan fungsi kehilangan *Mean Squared Error* (MSE), sedangkan performa model dievaluasi menggunakan metrik *Mean Absolute Percentage Error*

(MAPE) untuk mengukur tingkat kesalahan prediksi. Setelah model mencapai konfigurasi terbaik, sistem prediksi berbasis LSTM ini digunakan untuk menghasilkan perkiraan harga komoditas pangan selama satu bulan ke depan berdasarkan pola historis harga harian sebelumnya.

3.4.1 Arsitektur Model

Arsitektur model *Long Short-Term Memory* (LSTM) pada penelitian ini dirancang untuk mempelajari pola perubahan harga komoditas pangan berdasarkan urutan data historis. Model ini terdiri atas tiga lapisan utama, yaitu *input layer*, *hidden layer* (LSTM), dan *output layer* (Dense). Setiap lapisan memiliki peran yang saling berkaitan dalam proses pembelajaran pola data dan menghasilkan prediksi harga yang akurat.

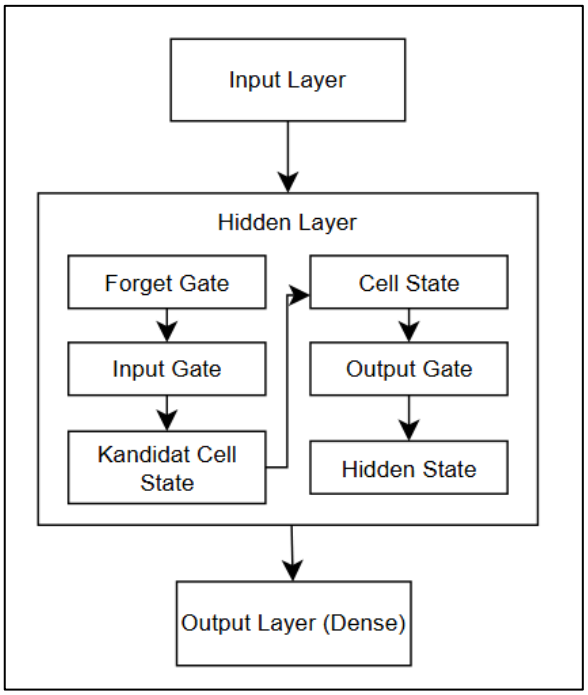
Lapisan *input* berfungsi menerima data hasil *sliding window* dalam bentuk urutan nilai harga harian sepanjang periode waktu tertentu (*window size*). Data yang masuk berbentuk tensor berdimensi tiga, yaitu $(B \times W \times F_{in})$, di mana B merupakan ukuran batch, W adalah panjang jendela waktu (window size), dan F_{in} jumlah fitur masukan. Nilai-nilai ini kemudian diteruskan ke lapisan tersembunyi untuk dianalisis lebih lanjut.

Lapisan *hidden* merupakan inti dari model LSTM yang berfungsi mengenali pola temporal dan hubungan antar waktu. Pada lapisan ini terdapat mekanisme memori internal berupa *forget gate, input gate*, *cell state, output gate*, dan *hideen state* yang secara adaptif mengatur informasi mana yang perlu disimpan atau dilupakan. Proses ini memungkinkan model untuk mempertahankan informasi

penting dari data masa lalu dan memanfaatkannya dalam memprediksi nilai di masa mendatang.

Lapisan *output* atau *Dense layer* berfungsi mengubah hasil representasi dari lapisan LSTM menjadi satu nilai prediksi tunggal, yaitu harga pada hari berikutnya. Hasil keluaran ini masih berada dalam skala normalisasi, sehingga perlu dikembalikan ke satuan rupiah melalui proses *denormalisasi* agar dapat dibandingkan dengan nilai harga aktual.

Arsitektur model LSTM dirancang untuk menangkap pola historis harga pangan yang bersifat berurutan dan dinamis, sehingga mampu menghasilkan prediksi yang stabil dan akurat berdasarkan data historis harian komoditas pangan di Provinsi Jawa Tengah. Arsitektur model LSTM yang digunakan pada penelitian Gambar 3.3.



Gambar 3.3 Arsitektur Model LSTM Penelitian

3.4.2 Input Layer

Lapisan *input* merupakan tahap awal dalam arsitektur model LSTM yang berfungsi menerima data berurutan hasil proses *sliding window* untuk selanjutnya dipelajari oleh jaringan. Data masukan disusun dalam format tiga dimensi berbentuk tensor $(B \times W \times F_{in})$, dimana B menyatakan jumlah *batch* data yang diproses dalam satu iterasi pelatihan, W merupakan panjang jendela waktu (*window size*) yang menunjukkan banyaknya data historis yang digunakan untuk memprediksi nilai berikutnya, dan F_{in} adalah jumlah fitur input yang dimasukkan ke dalam model pada setiap langkah waktu.

Dalam penelitian ini, *window size* digunakan untuk menentukan seberapa panjang data historis yang dijadikan acuan prediksi. Semakin besar nilai W, maka semakin panjang pula konteks temporal yang dapat ditangkap oleh model, meskipun hal tersebut juga meningkatkan kompleksitas komputasi selama proses pelatihan.

Model LSTM yang digunakan dalam penelitian ini dapat diimplementasikan dengan dua pendekatan, yaitu *univariat* dan *multivariat*. Pada pendekatan *univariat*, hanya satu variabel harga dari satu komoditas yang digunakan sebagai input, sehingga jumlah fitur input bernilai $F_{in} = 1$. Sementara itu, pada pendekatan *multivariat*, digunakan beberapa variabel masukan secara bersamaan.

Sebagai contoh, digunakan data hasil *sliding window* dengan panjang jendela $W = 3$ sebagaimana ditunjukkan pada Tabel 3.5 Contoh Pembentukan Data Sliding Window (W = 3). Salah satu sampel input–target dari data tersebut adalah:

$$X_t = [0.25,0.50,0.75]\,, \quad y_{t+1} = 1.00$$

Pada pendekatan univariat, data ini dimasukkan ke dalam model LSTM dalam bentuk tensor berdimensi $(1 \times 3 \times 1)$, yaitu satu *batch* data, tiga langkah waktu, dan satu fitur input.

Bentuk input layer menunjukkan bahwa model mempelajari hubungan antar waktu sekaligus antar fitur dalam satu rentang jendela. *Input layer* berperan penting dalam menyusun data berurutan agar memiliki struktur yang sesuai dengan arsitektur LSTM, sehingga model dapat secara efektif mempelajari pola temporal harga komoditas pangan dan menghasilkan prediksi yang akurat.

3.4.3 Hidden Layer (Long Short-Term Memory)

Lapisan tersembunyi (hidden layer) pada arsitektur model LSTM berfungsi untuk mempelajari hubungan temporal dalam data deret waktu dengan mempertahankan informasi penting dari periode sebelumnya melalui mekanisme memori internal. Berbeda dengan jaringan RNN konvensional, LSTM memiliki tiga gerbang utama, yaitu *forget gate*, *input gate*, dan *output gate*, serta satu *cell state* yang berfungsi sebagai memori jangka panjang. Setiap gerbang bekerja secara adaptif untuk menentukan informasi mana yang perlu disimpan, diperbarui, atau dilupakan pada setiap langkah waktu.

Pada penelitian ini, proses pembelajaran dilakukan menggunakan pendekatan univariat, di mana data masukan berbentuk tensor berdimensi $(1 \times 3 \times 1)$, Sebagai contoh, digunakan data hasil *sliding window* dengan input $X_t = [0.25,0.50,0.75]$ dan target $y_{t+1} = 1.0$. Data ini merepresentasikan tiga nilai harga historis yang digunakan untuk memprediksi harga pada hari berikutnya.

1. Forget Gate

Tahapan pertama dalam unit LSTM adalah menghitung forget gate menggunakan rumus (2.4). Gerbang ini menentukan proporsi informasi dari memori sebelumnya C_{t-1} yang akan dipertahankan. Misalkan bobot dan bias yang digunakan adalah $W_f = [0.5,0.3,0.2]$ dan $b_f = 0.1$. Maka nilai forget gate dihitung sebagai berikut:

$$f_t = \sigma\left(W_f \cdot X_t + b_f\right)$$

$$f_t = \sigma\left((0.5 \times 0.25) + (0.3 \times 0.50) + (0.2 \times 0.75) + 0.1\right)$$

$$f_t = \sigma(0.125 + 0.150 + 0.150 + 0.1) = \sigma(0.525)$$

$$f_t = 0.628$$

Hasil $f_t = 0.628$ menunjukkan bahwa sekitar 62.8% informasi dari memori sebelumnya akan dipertahankan untuk langkah berikutnya.

2. Input Gate

Tahapan berikutnya adalah input gate, yang berfungsi mengatur seberapa besar informasi baru dari input akan disimpan ke dalam memori. Berdasarkan rumus (2.5), nilai input gate dihitung dengan fungsi aktivasi sigmoid. Misalkan $W_{\mathrm{i}} = [0.4,0.3,0.2]$ dan $b_{\mathrm{i}} = 0.05$, maka:

$$i_t = \sigma(W_i \cdot X_t + b_i)$$

$$i_t = \sigma\left((0.4 \times 0.25) + (0.3 \times 0.50) + (0.2 \times 0.75) + 0.05\right)$$

$$i_t = \sigma(0.10 + 0.15 + 0.15 + 0.05) = \sigma(0.45)$$

$$i_t = 0.611$$

Nilai $i_t = 0.611$ berarti sekitar 61.1% informasi baru dari input akan dimasukkan ke dalam memori jangka panjang.

3. Kandidat Cell State

Selanjutnya dihitung kandidat memori baru ($\widetilde{C_t}$) menggunakan rumus (2.6) dengan fungsi aktivasi tanh. Misalkan bobot dan bias untuk cell state adalah $W_c = [0.3,0.4,0.3]$ dan $b_c = 0.0$:

$$\widetilde{C_t} = \tanh(W_c \cdot X_t + b_c)$$

$$\widetilde{C_t} = \tanh\big((0.3 \times 0.25) + (0.4 \times 0.50) + (0.3 \times 0.75) + 0.0\big)$$

$$\widetilde{C_t} = \tanh(0.075 + 0.200 + 0.225) = \tanh(0.500)$$

$$\widetilde{C_t} = 0.462$$

Nilai ini menunjukkan informasi baru yang berpotensi disimpan dalam memori berdasarkan input saat ini.

4. Pembaruan Cell State

Cell state (C_t) diperbarui dengan menggabungkan hasil dari forget gate dan input gate sebagaimana pada rumus (2.7). Misalkan cell state sebelumnya $C_t = 0.3$, maka:

$$C_t = f_t \cdot C_{t-1} + i_t \cdot \widetilde{C_t}$$

$$C_t = (0.628 \times 0.3) + (0.611 \times 0.462)$$

$$C_t = 0.188 + 0.282 = 0.470$$

Hasil $C_t = 0.470$ menunjukkan nilai memori terkini setelah memperhitungkan informasi lama dan baru.

5. Output Gate dan Hidden State

Tahap terakhir adalah menghitung output gate dan hidden state menggunakan rumus (2.8) dan (2.9). Misalkan $W_o = [0.5,0.4,0.3]$ dan $b_o = 0.1$:

$$o_t = \sigma(W_o \cdot X_t + b_o)$$

$$o_t = \sigma\big((0.5 \times 0.25) + (0.4 \times 0.50) + (0.3 \times 0.75) + 0.1\big)$$

$$o_t = \sigma(0.125 + 0.200 + 0.225 + 0.1) = \sigma(0.65)$$

Kemudian, nilai hidden state dihitung dengan mengalikan hasil output gate dengan aktivasi dari cell state saat ini:

$$o_t = 0.657$$

$$h_t = o_t \cdot \tanh(C_t)$$

$$h_t = 0.657 \times \tanh(0.470)$$

$$h_t = 0.657 \times 0.438 = 0.288$$

Dengan demikian, nilai $h_t = 0.288$ menjadi keluaran utama dari lapisan tersembunyi pada waktu ke-t. Nilai ini akan diteruskan ke lapisan berikutnya, yaitu lapisan keluaran (Dense Layer), untuk menghasilkan prediksi harga komoditas pangan pada hari selanjutnya.

Lapisan tersembunyi LSTM berperan penting dalam menangkap pola fluktuasi harga yang tidak linier serta menjaga konteks historis dari data deret waktu, sehingga hasil prediksi menjadi lebih akurat dan stabil.

3.4.6 Output Layer (Dense)

Lapisan keluaran atau *Dense layer* merupakan tahap akhir pada arsitektur model LSTM yang berfungsi mengubah representasi hasil pembelajaran dari *hidden state* menjadi satu nilai prediksi harga pada waktu berikutnya. Setiap neuron pada lapisan ini terhubung penuh (*fully connected*) dengan seluruh unit pada lapisan sebelumnya, sehingga memungkinkan jaringan untuk melakukan kombinasi linier dari seluruh informasi yang telah dipelajari. Fungsi utama lapisan *Dense* adalah

melakukan transformasi linier terhadap *hidden state* terakhir dan menghasilkan nilai prediksi akhir dalam skala normalisasi.Secara matematis, operasi pada lapisan *Dense* dituliskan dengan rumus linear 3.1.

$$\hat{y} = h_t W + b \tag{3.1}$$

Keterangan:
$\hat{y}$: nilai hasil prediksi pada skala normalisasi
h_t : hidden state terakhir yang dihasilkan oleh lapisan LSTM pada waktu ke-T
W : bobot pada lapisan Dense
b : nilai bias pada lapisan Dense.

Sebagai contoh, jika dari hasil lapisan tersembunyi diperoleh $h_t = 0.288$, dengan bobot $W = 0.75$ dan bias $b = 0.10$, maka perhitungan pada lapisan *Dense* dilakukan sebagai berikut:

$$\hat{y} = (0.288 \times 0.75) + 0.10 = 0.316$$

Nilai $\hat{y} = 0.316$ ini masih berada pada skala hasil normalisasi Min–Max dengan rentang [0,1]. Oleh karena itu, hasil prediksi perlu dikembalikan ke skala asli (rupiah) melalui proses denormalisasi agar dapat dibandingkan dengan harga aktual.

3.5 Training Model

Proses training model dilakukan untuk melatih jaringan LSTM agar mampu mengenali pola pergerakan harga komoditas pangan berdasarkan data historis. Data hasil sliding window dimasukkan ke dalam model secara berurutan melalui proses forward pass, sehingga model menghasilkan prediksi berdasarkan perhitungan pada lapisan LSTM dan lapisan Dense. Berdasarkan contoh perhitungan pada tahap implementasi model, nilai hidden state terakhir yang diperoleh adalah:

$$h_t = 0.288$$

Nilai tersebut diproses oleh lapisan Dense melalui transformasi linier sesuai persamaan 3.1. Misalnya dengan bobot $W = 0.75$ dan b = 0.10, diperoleh prediksi pada skala normalisasi sebagai berikut:

$$\hat{y} = (0.288)(0.75) + 0.10 = 0.316$$

Nilai prediksi ini kemudian dibandingkan dengan nilai aktual pada skala normalisasi dengan persamaan 3.2.

$$\text{error} = y - \hat{y} \tag{3.2}$$

Keterangan:
y : nilai aktual pada skala normalisasi
$\hat{y}$: nilai prediksi pada skala normalisasi

Misalnya nilai actual adalah sebagai berikut:

$$y = 1.00$$

Maka, nilai error adalah:

$$\text{error} = 1.00 - 0.316 = 0.684$$

Error ini dihitung menggunakan fungsi kehilangan *Mean Squared Error* (MSE) dengan persamaan 3.3.

$$\text{MSE} = (y - \hat{y})^2 \tag{3.3}$$

Keterangan:
y : nilai aktual pada skala normalisasi
$\hat{y}$: nilai prediksi pada skala normalisasi
MSE : fungsi kehilangan Mean Squared Error

$$\text{MSE} = (0.684)^2 = 0.467856$$

Nilai MSE selanjutnya digunakan dalam proses *backpropagation* untuk memperbarui bobot dan bias pada seluruh lapisan jaringan. Algoritma Adam dengan laju pembelajaran 0.001 digunakan untuk mempercepat proses konvergensi bobot. Secara umum, pembaruan bobot dilakukan menggunakan persamaan 3.4.

$$W_{\text{baru}} = W_{\text{lama}} - \alpha \cdot \frac{\partial \text{MSE}}{\partial W} \tag{3.4}$$

Keterangan:
$W, W_{\text{lama}}, W_{\text{baru}}$: bobot lapisan Dense sebelum dan sesudah pembaruan
α : learning rate
$\frac{\partial \text{MSE}}{\partial W}$: gradien fungsi kehilangan terhadap bobot

Sebagai ilustrasi sederhana, misalkan bobot awal $W_{\text{lama}} = 0.75$, *learning rate* $\alpha = 0.001$, dan gradien:

$$W_{\text{lama}} = 0.75, \quad \alpha = 0.001, \quad \frac{\partial \text{MSE}}{\partial W} = 0.020$$

maka bobot baru dihitung menjadi:

$$W_{\text{baru}} = 0.75 - (0.001)(0.020) = 0.74998$$

Pada proses selanjutnya, nilai W_{baru} akan menggantikan bobot lama dalam model, sehingga bobot ini digunakan pada *forward pass* epoch berikutnya. Dengan demikian, setiap siklus pelatihan membuat model semakin menyesuaikan bobotnya berdasarkan error yang dihasilkan. Seluruh proses ini berlangsung berulang selama beberapa epoch yang mencakup *forward pass*, perhitungan error menggunakan MSE, *backpropagation*, dan pembaruan bobot hingga nilai loss menunjukkan pola yang stabil.

3.6 Testing Model

Tahap testing model dilakukan untuk mengukur kemampuan model LSTM dalam memprediksi harga komoditas pangan menggunakan data yang tidak termasuk dalam proses pelatihan. Pada tahap ini, model yang telah dilatih digunakan untuk menghasilkan prediksi berdasarkan input dari data uji, kemudian hasil prediksi tersebut dibandingkan dengan nilai aktual pada waktu yang sama.

Proses prediksi dimulai dari keluaran lapisan Dense berupa nilai $\hat{y}$ dalam skala normalisasi. Nilai tersebut kemudian dikembalikan ke satuan rupiah melalui proses denormalisasi menggunakan parameter minimum dan maksimum dari data latih.

Misalkan nilai prediksi pada skala normalisasi adalah:

$$\hat{y} = 0.316$$

dengan nilai minimum dan maksimum data latih masing-masing misalnya:

$$x_{min} = 12\,000, \qquad x_{max} = 13\,000$$

Proses denormalisasi dihitung dengan persamaan:

$$\hat{x} = \hat{y} \times (x_{\max} - x_{\min}) + x_{\min} \tag{3.6}$$

diperoleh nilai prediksi dalam satuan rupiah:

$$\hat{x} = 0.316 \times (13.000 - 12.000) + 12.000 = 12.316$$

Nilai prediksi tersebut kemudian dibandingkan dengan harga aktual, misalnya:

$$x = 12.500$$

sehingga error absolutnya adalah:

$$|x - \hat{x}| = |12\,500 - 12\,316| = 184$$

Nilai error ini menggambarkan selisih antara prediksi dan data aktual pada titik waktu tertentu. Perhitungan kesalahan dasar pada tahap testing ini menjadi dasar untuk proses evaluasi performa model.

3.7 Skenario Percobaan

Skenario percobaan pada penelitian ini dirancang untuk mengevaluasi kinerja dan konsistensi model Long Short-Term Memory (LSTM) dalam

memprediksi harga harian komoditas pangan di Provinsi Jawa Tengah. Tujuan utama dari rancangan percobaan ini adalah untuk menganalisis pengaruh variasi parameter masukan dan konfigurasi jaringan terhadap tingkat akurasi hasil prediksi yang dihasilkan oleh model.

Pada penelitian ini dilakukan dua skenario percobaan utama yang dibedakan berdasarkan struktur masukan (*input structure*), yaitu pendekatan univariat dan pendekatan multivariat. Kedua skenario tersebut dijalankan dengan variasi panjang jendela waktu (*window size*) sebesar 7, 14, dan 30 hari, serta jumlah unit tersembunyi (*hidden units*) pada lapisan LSTM sebanyak 32 dan 64 neuron. Rancangan scenario konfigurasi percobaan penelitian Tabel 3.9.

Tabel 3.9 Skenario Percobaan

No	**Parameter yang Divariasi**	**Komoditas Target**	**Window Size (hari)**	**Tipe Input**	**Jumlah Unit LSTM**
1.	Window Size, Unit LSTM, Struktur Input	Tiap Jenis Komoditas Pangan	7, 14, 30	Univariat	32, 64
2,	Window Size, Unit LSTM, Struktur Input	Tiap Jenis Komoditas Pangan	7, 14, 30	Multivariat	32, 64

Pada Skenario 1 (Univariat), model LSTM dilatih menggunakan satu variabel masukan yang berasal dari data historis harga masing-masing komoditas pangan secara terpisah. Tujuan dari skenario ini adalah untuk mengukur kemampuan model dalam mengenali pola fluktuasi harga berdasarkan data tunggal tanpa mempertimbangkan keterkaitan dengan komoditas lain. Pengujian dilakukan terhadap sembilan jenis komoditas pangan utama, yaitu beras, daging ayam, daging

sapi, telur ayam, bawang merah, cabai merah, cabai rawit, minyak goreng, dan gula pasir.

Selanjutnya, pada Skenario 2 (Multivariat), model dilatih menggunakan sembilan komoditas pangan utama secara bersamaan sebagai variabel masukan. Dalam skenario ini, setiap komoditas secara bergantian dijadikan target prediksi (target variable), sedangkan delapan komoditas lainnya berfungsi sebagai variabel pendukung (predictor variables). Pendekatan ini digunakan untuk mengetahui sejauh mana hubungan antar harga komoditas pangan dapat meningkatkan kemampuan model dalam menghasilkan prediksi yang lebih akurat dan stabil.

Seluruh percobaan dilakukan dengan menggunakan metrik evaluasi Mean Absolute Percentage Error (MAPE) sebagai ukuran kinerja model. Penggunaan metrik yang sama pada kedua skenario memungkinkan proses perbandingan hasil dilakukan secara objektif, konsisten, dan terukur. Melalui kedua skenario ini, penelitian diharapkan dapat memperoleh konfigurasi model LSTM yang paling optimal dalam memprediksi harga komoditas pangan, baik berdasarkan data tunggal maupun kombinasi antar komoditas, sehingga mampu menghasilkan prediksi dengan tingkat akurasi tinggi dan performa yang stabil terhadap dinamika fluktuasi harga di Provinsi Jawa Tengah.

3.8 Evaluasi Model

Evaluasi kinerja model prediksi dilakukan menggunakan metrik *Mean Absolute Percentage Error* (MAPE), sebagaimana dijelaskan pada rumus (2.10) di Bab II. Metrik ini digunakan untuk mengukur rata-rata kesalahan absolut antara

nilai aktual dan nilai hasil prediksi dalam bentuk persentase terhadap nilai aktual. Semakin kecil nilai MAPE, semakin baik tingkat akurasi model yang dihasilkan.

Sebagai contoh penerapan, digunakan contoh data harga aktual hasil denormalisasi untuk komoditas beras di Provinsi Jawa Tengah Tabel 3.10. Nilai harga prediksi diperoleh dari hasil keluaran model LSTM setelah proses pelatihan selesai.

Tabel 3.10 Contoh Data untuk Penerapan Evaluasi Model

No.	Tanggal	Harga Aktual (Rp/kg)	Harga Prediksi (Rp/kg)
1.	01 Januari 2020	9.350	9.360
2.	02 Januari 2020	9.400	9.410
3.	03 Januari 2020	9.450	9.470
4.	06 Januari 2020	9.500	9.490
5.	07 Januari 2020	9.400	9.380
6.	08 Januari 2020	9.350	9.340
7.	09 Januari 2020	9.300	9.310

Perhitungan MAPE dilakukan menggunakan rumus (2.10) dengan langkah-langkah sebagai berikut:

$$\text{MAPE} = \frac{100}{7} \times \left|\frac{9350 - 9360}{9350}\right| + \left|\frac{9400 - 9410}{9400}\right| + \left|\frac{9450 - 9470}{9450}\right| +$$

$$\left|\frac{9500 - 9490}{9500}\right| + \left|\frac{9400 - 9380}{9400}\right| + \left|\frac{9350 - 9340}{9350}\right| + \left|\frac{9300 - 9310}{9300}\right|$$

Kemudian dihitung setiap komponennya dengan perhitungan sebagai berikut:

$$\text{MAPE} = \frac{100}{7} \times \left[\begin{matrix} 0.00107 + 0.00106 + 0.00212 + \\ 0.00105 + 0.00213 + 0.00107 + 0.00108 \end{matrix}\right]$$

$$\text{MAPE} = 14.2857 \times 0.00858 = 0.1226\%$$

Dengan demikian, diperoleh nilai MAPE sebesar 0.12%, yang menunjukkan bahwa rata-rata kesalahan prediksi model terhadap harga aktual hanya sekitar 0.12 persen dari nilai sebenarnya.

BAB IV

HASIL DAN PEMBAHASAN

4.1 Skenario Uji Coba

Skenario uji coba pada penelitian ini dilakukan untuk mengevaluasi kinerja model Long Short-Term Memory (LSTM) dalam memprediksi harga harian sembilan komoditas pangan di Provinsi Jawa Tengah. Skenario uji coba dilakukan dengan dua skenario, yaitu univariate (satu komoditas sebagai input dan target) dan multivariate (sembilan komoditas sebagai input dengan satu komoditas sebagai target). Evaluasi model dilakukan menggunakan metrik Mean Absolute Percentage Error (MAPE). Tahapan uji coba yang dilakukan meliputi beberapa langkah berikut.

a. Transformasi dan Penggabungan Data (*Data Transformation*)

   Data harga harian komoditas pangan periode 2020–2025 yang terdiri dari beberapa file Excel digabungkan menjadi satu dataset. Dataset tersebut yang sebelumnya dalam format *long*, kemudian ditransformasikan ke dalam format *wide time series*, dengan tanggal sebagai baris dan harga sembilan komoditas pangan sebagai kolom.

b. Data Cleaning

   Tahap *data cleaning* dilakukan untuk memastikan seluruh nilai harga berada dalam format numerik dan bebas dari inkonsistensi. Pada tahap ini, tanda koma (,) pada nilai harga dihapus agar data dapat dikonversi menjadi tipe *float*, sehingga dapat diproses dalam analisis numerik.

c. Exploratory Data Analysis (EDA)

Tahap EDA dilakukan secara sederhana untuk memahami kondisi awal data dengan menampilkan jumlah nilai hilang, statistik deskriptif, serta grafik perkembangan harga setiap komoditas selama periode 2020–2025. Visualisasi ini memberikan gambaran umum pola fluktuasi dan tren harga sebelum pra-pemrosesan dilakukan.

d. Imputasi Missing Value

Nilai hilang ditangani menggunakan metode Last Observation Carried Forward (LOCF) melalui proses forward-fill dan backward-fill. Tahap ini memastikan bahwa seluruh kolom komoditas memiliki nilai lengkap untuk diproses lebih lanjut.

e. Pembagian Dataset (*Data Splitting*)

Dataset dibagi secara kronologis menjadi data training, validation, dan testing berdasarkan urutan waktu. Pembagian dilakukan dengan menggunakan sebanyak 70% data awal sebagai data training, diikuti oleh 15% data berikutnya sebagai data validation, dan 15% data terakhir sebagai data testing. Pembagian ini dilakukan tanpa pengacakan untuk menjaga karakteristik deret waktu. Pembagian rentang waktu dataset Tabel 4.1.

Tabel 4.1 Pembagian Dataset Berdasarkan Rentang Waktu

No.	Jenis Data	Jumlah Hari	Persentase
1.	Training	1048 hari	70%
2.	Validation	225 hari	15%
3.	Testing	225 hari	15%

f. Normalisasi Data

Seluruh komoditas dinormalisasi menggunakan Min-Max Scaling (0–1). Untuk skenario multivariate, satu scaler digunakan untuk semua fitur. Sedangkan pada skenario univariate, setiap komoditas memiliki scaler terpisah. Normalisasi hanya di-fit pada data training untuk mencegah kebocoran data.

g. Pembentukan Sliding Window

Data yang telah dinormalisasi diubah menjadi bentuk sekuensial menggunakan teknik sliding window agar sesuai dengan format input LSTM. Penelitian ini menggunakan tiga variasi window size yaitu 7 hari, 14 hari, dan 30 hari, baik untuk skenario univariate maupun multivariate.

h. Implementasi Model LSTM

Model LSTM dibangun menggunakan satu lapisan LSTM dan satu lapisan Dense dengan output satu nilai prediksi. Variasi jumlah unit LSTM yang diuji adalah 32 dan 64 unit, dengan Dropout 0.2, fungsi loss MSE, dan optimizer Adam (learning rate 0.001). Pelatihan dilakukan hingga 150 epoch dengan batch size 32. Konfigurasi model LSTM Tabel 4.2.

Tabel 4.2 Konfigurasi Hyperparameter Model LSTM

Parameter	**Nilai**
Arsitektur	1 LSTM layer + 1 Dense
Unit LSTM	{32, 64}
Dropout	0.2
Optimizer	Adam
Learning rate	0.001
Loss function	MSE
Batch size	32
Epoch	150
Window size	{7, 14, 30}
Horizon prediksi	1

i. Eksperimen Univariat dan Multivariat

Pada skenario univariate, model dilatih secara terpisah untuk setiap komoditas menggunakan satu variabel input. Pada skenario multivariate, sembilan komoditas dijadikan variabel input untuk memprediksi salah satu komoditas target, sehingga hubungan antar harga dapat dipelajari secara bersamaan.

j. Evaluasi Model

Model yang telah dilatih diuji menggunakan data testing. Hasil prediksi dikonversi kembali ke satuan rupiah melalui inverse transform, kemudian dibandingkan dengan data aktual. Evaluasi dilakukan dengan menghitung nilai MAPE (Mean Absolute Percentage Error).

k. Forecasting

Tahap forecasting dilakukan untuk memberikan gambaran prediksi harga komoditas pangan setelah periode pengujian berakhir. Pada proses ini model digunakan untuk menghasilkan prediksi harga selama 22 hari kerja (satu bulan kerja) menggunakan metode roll-forward, di mana prediksi hari sebelumnya dijadikan bagian dari input untuk memprediksi hari berikutnya.

4.2 Hasil Uji Coba

Hasil evaluasi sistem yang menggunakan metode Long Short-Term Memory (LSTM) dibahas pada subbab ini. Perbandingan antara nilai aktual dan nilai hasil prediksi digunakan sebagai dasar untuk menilai kinerja model yang telah dikembangkan. Tujuan dari evaluasi ini adalah untuk mengetahui sejauh mana efektivitas metode LSTM dalam memprediksi harga harian komoditas pangan di

Provinsi Jawa Tengah. Penilaian difokuskan pada model dengan performa terbaik yang ditentukan berdasarkan nilai Mean Absolute Percentage Error (MAPE) terendah.

4.2.1 Hasil Uji Coba Skenario Univariate Komoditas Beras

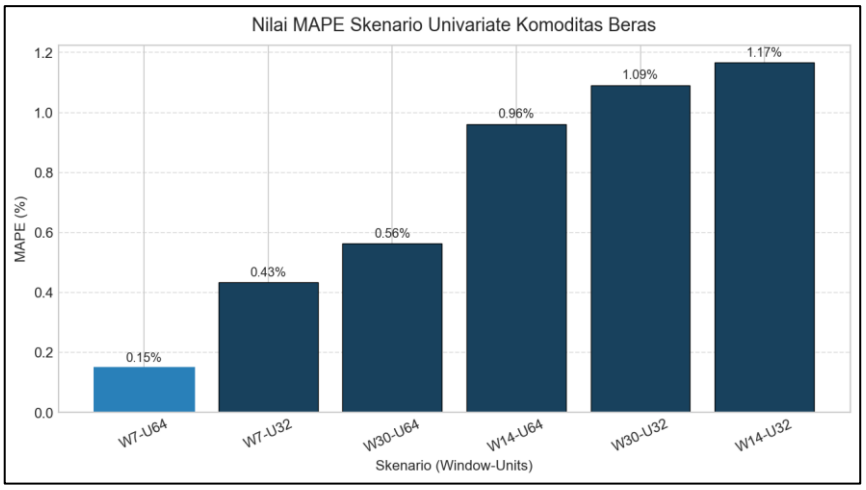
Hasil pengujian pada komoditas beras dilakukan menggunakan beberapa kombinasi parameter sliding window dan jumlah unit LSTM. Pengujian ini bertujuan untuk mengidentifikasi konfigurasi yang mampu mempelajari pola historis harga beras secara stabil dan menghasilkan tingkat error paling rendah baik pada data testing maupun pada proses forecasting. Analisis dilakukan dengan meninjau nilai MAPE pada seluruh skenario serta mengevaluasi akurasi model terbaik melalui grafik *actual vs predicted* dan proyeksi harga satu bulan ke depan.

Tabel 4.3 Hasil Pengujian Skenario Univariate Komoditas Beras

No.	Window	Units	MAPE Testing	MAPE Forecasting
1.	7	32	0.43%	2.74%
2.	7	64	0.14%	0.67%
3.	14	32	1.16%	8.63%
4.	14	64	0.96%	8.00%
5.	30	32	1.09%	8.04%
6.	30	64	0.56%	5.13%

Tabel 4.3 menyajikan hasil pengujian seluruh skenario univariate komoditas beras. Terlihat bahwa kombinasi window 7 dengan 64 unit LSTM merupakan konfigurasi yang menghasilkan performa terbaik, ditandai dengan nilai MAPE testing paling rendah sebesar 0,149% dan MAPE forecasting sebesar 0,671%. Hasil ini menunjukkan bahwa model lebih efektif ketika diberi jendela observasi pendek (7 hari), sehingga pola lokal perubahan harga dapat ditangkap secara lebih presisi

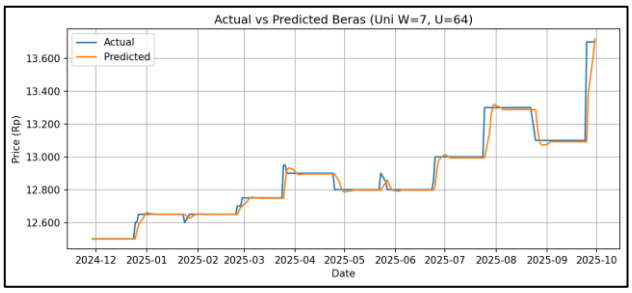
tanpa menimbulkan overfitting seperti pada skenario dengan unit terlalu besar atau window lebih panjang. Sebaliknya, skenario dengan window 14 dan 30 cenderung menghasilkan MAPE forecasting jauh lebih tinggi, terutama konfigurasi W14-U32 dan W14-U64 yang mencapai di atas 8%. Hal ini mengindikasikan bahwa penambahan panjang window justru menambah noise pada komoditas dengan pola fluktuasi yang relatif stabil seperti beras.



Gambar 4.1 Nilai MAPE Skenario Univariate Komoditas Beras

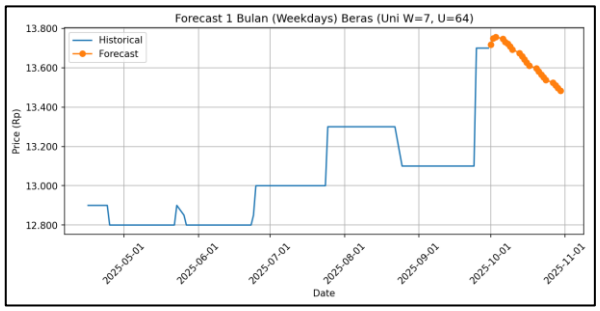
Gambar 4.1 memperlihatkan distribusi nilai MAPE dari seluruh skenario secara visual. Pola pada grafik menunjukkan perbedaan performa antar-skenario yang cukup konsisten: dua skenario dengan window 7 (W7-U32 dan W7-U64) berada pada posisi terendah, diikuti oleh kombinasi window 30, kemudian window 14 yang memiliki error tertinggi. Nilai MAPE terendah sebesar 0,15% pada skenario W7-U64 menegaskan bahwa model lebih responsif ketika diberi konteks historis yang lebih pendek namun dipadukan dengan kapasitas representasi yang memadai melalui 64 unit LSTM. Trend peningkatan error pada window 14 dan 30 juga secara teknis memperlihatkan bahwa model kesulitan mempertahankan

stabilitas prediksi ketika diberi informasi masa lalu yang terlalu jauh dan kurang relevan terhadap dinamika harga beras harian.



Gambar 4.2 Grafik Actual vs Predicted Komoditas Beras Skenario Univarate Terbaik

Gambar 4.2 menampilkan grafik actual vs predicted untuk skenario terbaik, yaitu window 7 dengan 64 unit LSTM. Grafik menunjukkan bahwa kurva prediksi model mengikuti garis aktual dengan sangat baik, termasuk pada titik-titik perubahan harga yang bersifat stepwise seperti kenaikan harga pada Agustus 2025. Kesesuaian pola ini menunjukkan bahwa model mampu mengestimasi level harga dengan error minimal serta mempertahankan kemampuan mengikuti tren lokal tanpa menghasilkan deviasi yang signifikan. Akurasi prediksi yang tinggi pada skenario ini juga memperkuat hasil evaluasi MAPE sebelumnya, bahwa kombinasi W7-U64 paling optimal dalam menangkap karakteristik pola harga beras.



Gambar 4.3 Grafik Forecast Oktober 2025 Komoditas Beras Skenario Univarate Terbaik

Gambar 4.3 menyajikan hasil forecasting untuk periode Oktober 2025 menggunakan skenario terbaik. Pola forecast memperlihatkan kecenderungan penurunan harga secara bertahap setelah mencapai puncaknya pada awal Oktober. Secara teknis, tren menurun yang muncul merupakan respons model terhadap pola historis sebelum periode prediksi, di mana harga beras menunjukkan kenaikan bertahap pada September dan kemudian kembali stabil. Penurunan yang terjadi pada prediksi dapat dipahami sebagai bentuk penyesuaian model terhadap kecenderungan koreksi harga setelah periode kenaikan kuat suatu pola yang juga tercermin pada data historis beberapa bulan sebelumnya.

Tabel 4.4 Perbandingan Harga Aktual dan Hasil Forecast Komoditas Beras Oktober 2025 Skenario Univarate Terbaik

No.	Tanggal	Harga Aktual (Rp)	Harga Prediksi (Rp)
1.	10/1/2025	13700	13718.38
2.	10/2/2025	13700	13749.56
…	…	…	…
11.	10/15/2025	13700	13643.68
12.	10/16/2025	13700	13627.82
…	…	…	…
21.	10/29/2025	13700	13496.78
22.	10/30/2025	13700	13483.70

Tabel 4.4 menyajikan perbandingan antara harga aktual dan hasil prediksi harga komoditas beras selama Oktober 2025 pada skenario univariate terbaik dengan window size 7 dan 64 unit LSTM. Berdasarkan data yang ditampilkan, pada awal periode pengujian model mampu menghasilkan nilai prediksi yang sangat mendekati harga aktual, khususnya pada tanggal 1–2 Oktober 2025, dengan selisih prediksi berada pada kisaran puluhan rupiah dari harga aktual sebesar Rp13.700. Kondisi ini menunjukkan bahwa model berhasil menangkap pola harga jangka

pendek yang relatif stabil pada awal bulan. Namun, pada data yang ditampilkan untuk pertengahan hingga akhir periode, terlihat adanya kecenderungan nilai prediksi yang lebih rendah dibandingkan harga aktual yang tetap berada pada kisaran yang sama. Perbedaan ini mengindikasikan bahwa model merespons pola historis sebelumnya yang mengarah pada penyesuaian harga, meskipun pada kenyataannya harga aktual tidak mengalami perubahan signifikan. Meskipun demikian, selisih antara harga prediksi dan harga aktual masih berada dalam batas yang wajar dan tidak menunjukkan deviasi ekstrem, sehingga hasil forecasting pada komoditas beras tetap dapat dikategorikan memiliki tingkat akurasi yang baik untuk data dengan karakteristik harga yang relatif stabil.

4.2.2 Hasil Uji Coba Skenario Univariate Komoditas Daging Ayam

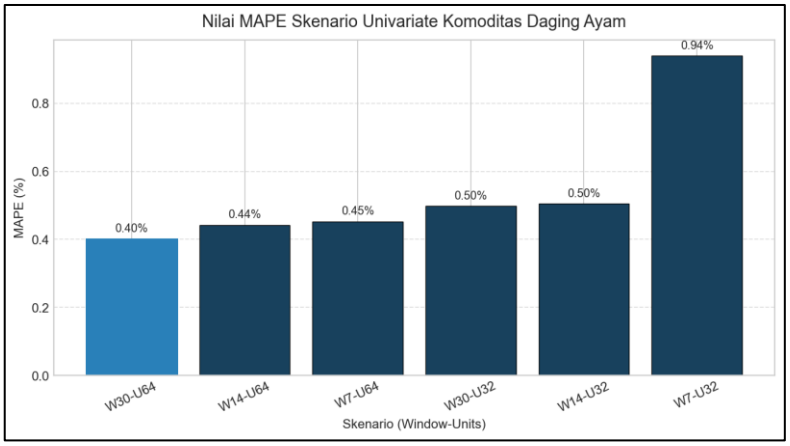
Pengujian pada komoditas daging ayam dilakukan untuk mengevaluasi performa model LSTM dalam mempelajari pola harga historis dan menghasilkan prediksi yang akurat. Skenario diuji menggunakan kombinasi sliding window 7, 14, dan 30 hari serta jumlah unit LSTM 32 dan 64.

Tabel 4.5 Hasil Pengujian Skenario Univariate Komoditas Daging Ayam

No.	Window	Units	MAPE Testing	MAPE Forecasting
1.	7	32	0.93%	5.37%
2.	7	64	0.45%	2.70%
3.	14	32	0.50%	3.87v
4.	14	64	0.44%	3.81%
5.	30	32	0.49%	1.17%
6.	30	64	0.40%	1.28%

Tabel 4.5 menunjukkan hasil pengujian seluruh skenario univariate untuk komoditas daging ayam. Berdasarkan nilai MAPE testing dan forecasting, skenario

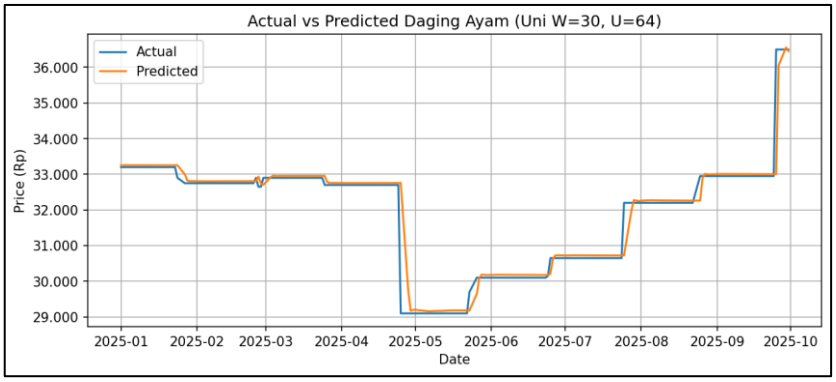
terbaik diperoleh pada kombinasi window 30 dan 64 unit (W30-U64). Skenario ini menghasilkan MAPE testing 0,400%, yang merupakan nilai terendah dibandingkan kombinasi lainnya. Pada tahap forecasting, MAPE sebesar 1,286% juga termasuk kategori rendah, menunjukkan kestabilan model dalam memprediksi data di luar rentang pelatihan. Secara teknis, performa terbaik pada window 30 hari mengindikasikan bahwa harga daging ayam memiliki pola pergerakan yang lebih dipengaruhi oleh konteks historis jangka menengah. Dengan demikian, penggunaan window lebih panjang memberi model informasi yang cukup untuk mempelajari perubahan harga yang bersifat bertahap maupun fluktuasi mendadak.



Gambar 4.4 Nilai MAPE Skenario Univariate Komoditas Daging Ayam

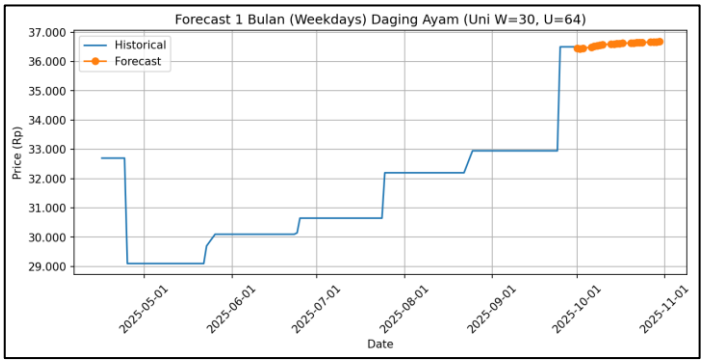
Gambar 4.4 memperlihatkan distribusi nilai MAPE pada seluruh skenario. Grafik menunjukkan bahwa dua skenario dengan window 30 (W30-U32 dan W30-U64) berada pada rentang error terendah, masing-masing sekitar 0,50% dan 0,40%. Hal ini menegaskan bahwa model lebih stabil saat diberi rangkaian data historis yang lebih panjang, sementara window 7 menghasilkan error tertinggi terutama pada konfigurasi W7-U32 yang mencapai 0,94%. Secara teknis, hal ini

menunjukkan bahwa konteks 7 hari terlalu pendek untuk komoditas yang memiliki perubahan harga lebih kompleks seperti daging ayam, sehingga model tidak memperoleh cukup informasi untuk mempelajari pola tren dan siklus harga mingguannya.



Gambar 4.5 Grafik Actual vs Predicted Komoditas Daging Ayam Skenario Univariate Terbaik

Gambar 4.5 menampilkan grafik actual vs predicted dari skenario terbaik (W30-U64). Pada grafik terlihat bahwa garis prediksi mengikuti pergerakan harga aktual dengan sangat baik, termasuk pada fase penurunan tajam harga pada bulan Mei 2025 dan kenaikan bertahap pada Juli hingga September 2025. Kedekatan pola kedua garis menunjukkan bahwa model mampu mengestimasi perubahan harga secara halus maupun perubahan mendadak tanpa menghasilkan deviasi yang signifikan. Hal ini mengonfirmasi bahwa kombinasi window 30 dan 64 unit memungkinkan model menangkap dinamika harga yang tidak hanya bersifat lokal, tetapi juga perubahan dalam periode yang lebih panjang.



Gambar 4.6 Grafik Forecast Oktober 2025 Komoditas Daging Ayam Skenario Univarate Terbaik

Gambar 4.6 menyajikan hasil forecasting untuk bulan Oktober 2025. Grafik menunjukkan bahwa model memprediksi kenaikan harga yang stabil dari kisaran Rp36.500 menuju sekitar Rp36.800 sepanjang bulan tersebut. Pola naik yang relatif konsisten merupakan respons model terhadap tren kuat kenaikan harga pada akhir September. Dari sudut pandang teknis, hasil ini menunjukkan bahwa model cukup sensitif terhadap pola momentum harga dan memperpanjang kecenderungan tersebut ke periode forecasting, sesuatu yang umum dijumpai pada model deret waktu yang mengandalkan pola historis sebagai dasar proyeksi.

Tabel 4.6 Perbandingan Harga Aktual dan Forecast Daging Ayam Skenario Univariate Terbaik

No.	Tanggal	Harga Aktual (Rp)	Harga Prediksi (Rp)
1.	10/1/2025	36500	36453.74
2.	10/2/2025	36500	36434.69
…	…	…	…
11.	10/15/2025	36500	36610.86
12.	10/16/2025	36500	36618.1
…	…	…	…
21.	10/29/2025	34750	36673.89
22.	10/30/2025	34750	36679.95

Tabel 4.6 menyajikan perbandingan antara harga aktual dan hasil prediksi harga komoditas daging ayam selama Oktober 2025 pada skenario univariate terbaik dengan window size 30 dan 64 unit LSTM. Berdasarkan data yang ditampilkan, pada awal periode pengujian model menghasilkan nilai prediksi yang sangat mendekati harga aktual, khususnya pada tanggal 1–2 Oktober 2025, dengan selisih prediksi yang relatif kecil dari harga aktual sebesar Rp36.500. Kondisi ini menunjukkan bahwa model mampu mengikuti pola harga daging ayam yang masih stabil pada awal bulan. Namun, pada data yang ditampilkan untuk pertengahan hingga akhir periode, terlihat adanya perbedaan yang semakin besar antara harga aktual dan harga prediksi. Harga aktual pada akhir periode mengalami penurunan hingga berada pada kisaran Rp34.750, sementara model justru menghasilkan nilai prediksi yang lebih tinggi dan relatif stabil di atas Rp36.000. Perbedaan ini mengindikasikan bahwa model univariate merespons pola historis sebelumnya yang tidak merepresentasikan adanya penurunan harga secara tiba-tiba. Secara teknis, kondisi tersebut menunjukkan keterbatasan model dalam mengantisipasi perubahan harga yang bersifat abrupt ketika informasi penurunan tersebut tidak tercermin pada data masa lalu. Meskipun demikian, deviasi prediksi yang terjadi masih mencerminkan karakteristik komoditas daging ayam yang memiliki volatilitas relatif tinggi, sehingga hasil forecasting tetap memberikan gambaran tren harga secara umum meskipun kurang responsif terhadap perubahan ekstrem.

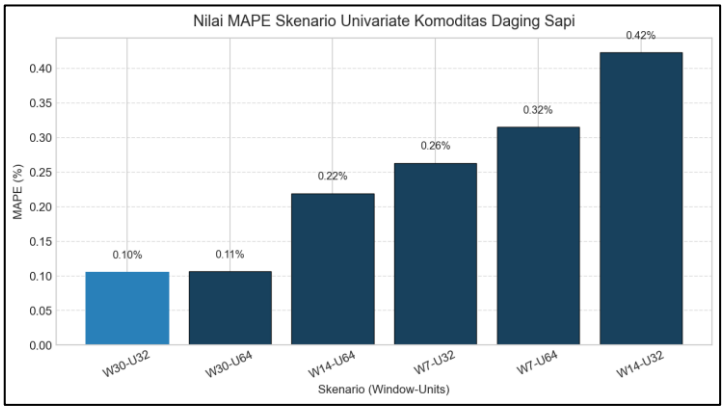
4.2.3 Hasil Uji Coba Skenario Univariate Komoditas Daging Sapi

Pengujian skenario univariate pada komoditas daging sapi dilakukan untuk mengevaluasi kemampuan model LSTM dalam mempelajari pola harga yang cenderung stabil namun memiliki beberapa perubahan tiba-tiba pada periode tertentu. Skenario diuji menggunakan variasi window 7, 14, dan 30 serta unit LSTM 32 dan 64.

Tabel 4.7 Hasil Pengujian Skenario Univariate Komoditas Daging Sapi

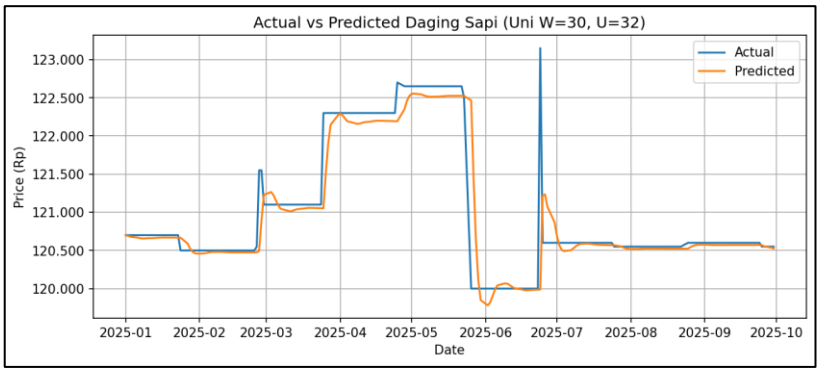
No.	Window	Units	MAPE Testing	MAPE Forecasting
1.	7	32	0.26%	1.13%
2.	7	64	0.31%	1.67%
3.	14	32	0.42%	2.10%
4.	14	64	0.21%	1.03%
5.	30	32	0.10%	0.12%
6.	30	64	0.10%	0.24%

Tabel 4.7 menyajikan hasil pengujian untuk seluruh kombinasi parameter. Dari tabel terlihat bahwa performa terbaik dicapai oleh kombinasi window 30 dan 32 unit (W30-U32), dengan nilai MAPE testing 0,104% dan MAPE forecasting hanya 0,124%. Nilai ini merupakan yang terendah dibandingkan skenario lain. Secara teknis, performa optimal pada window 30 menunjukkan bahwa harga daging sapi membutuhkan konteks historis lebih panjang agar model dapat memahami perubahan tren jangka menengah. Model tampak lebih stabil pada window besar, sedangkan window 7 dan 14 menghasilkan error yang lebih tinggi, misalnya W14-U32 dengan MAPE testing 0,422% dan forecasting 2,103%. Perbedaan ini mencerminkan bahwa pola harga daging sapi tidak cukup terwakili oleh informasi jangka pendek, sehingga window panjang memberikan struktur temporal yang lebih kaya untuk dipelajari oleh model.



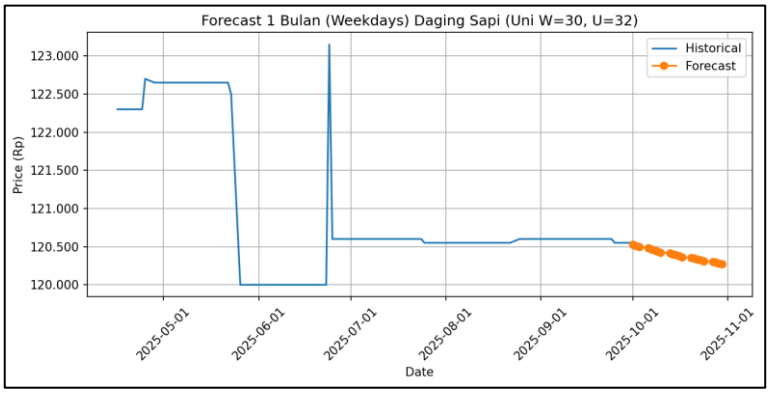
Gambar 4.7 Nilai MAPE Skenario Univariate Komoditas Daging Sapi

Gambar 4.7 menunjukkan distribusi nilai MAPE pada seluruh skenario. Grafik menegaskan bahwa dua skenario window 30 (W30-U32 dan W30-U64) berada pada posisi dengan error paling rendah, masing-masing 0,10% dan 0,11%. Sementara itu, skenario dengan window 14 menghasilkan error tertinggi, terutama W14-U32 yang mencapai sekitar 0,42%. Dari sisi teknis, hasil ini konsisten dengan karakteristik harga daging sapi yang relatif lambat berubah sehingga model membutuhkan urutan historis panjang untuk memprediksi arah perubahan dengan akurat. Window pendek cenderung memberikan sinyal temporal yang kurang lengkap dan membuat model lebih rentan terhadap deviasi prediksi.



Gambar 4.8 Grafik Actual vs Predicted Komoditas Daging Sapi Skenario Univarate Terbaik

Gambar 4.8 menampilkan grafik actual vs predicted untuk skenario terbaik (W30-U32). Grafik memperlihatkan bahwa garis prediksi sangat mendekati garis aktual, termasuk pada bagian pola harga yang mengalami kenaikan bertahap dari Maret hingga Mei 2025, serta penurunan tajam pada pertengahan Juni. Meski terjadi perbedaan kecil pada puncak kenaikan harga sebelum penurunan, model tetap mampu mengikuti bentuk tren secara keseluruhan. Kinerja ini menunjukkan bahwa model LSTM berhasil menangkap kecenderungan struktur harga yang cenderung trend-following dengan beberapa anomali, serta mampu mereplikasi dinamika harga yang stabil pada periode Juli hingga September dengan deviasi minimal.



Gambar 4.9 Grafik Forecast Oktober 2025 Komoditas Daging Sapi Skenario Univarate Terbaik

Gambar 4.9 menyajikan hasil forecasting harga daging sapi untuk Oktober 2025. Grafik menunjukkan tren penurunan harga secara bertahap dari sekitar Rp120.500 menuju kisaran Rp120.200 pada akhir bulan. Secara teknis, model memperpanjang kecenderungan penurunan harga pada akhir data historis, sehingga menghasilkan prediksi yang terus bergerak sedikit lebih rendah setiap harinya. Pola ini mencerminkan mekanisme dasar LSTM yang memanfaatkan kecenderungan

tren terakhir sebagai sinyal utama ketika pola musiman atau kejadian eksternal tidak tersedia dalam data historis. Dengan demikian, hasil forecasting tetap relevan untuk komoditas yang memiliki volatilitas rendah seperti daging sapi.

Tabel 4.8 Perbandingan Harga Aktual dan Forecast Daging Sapi Skenario Univariate Terbaik

No.	Tanggal	Harga Aktual (Rp)	Harga Prediksi (Rp)
1.	10/1/2025	120550	120525.34
2.	10/2/2025	120550	120510.61
…	…	…	…
11.	10/15/2025	120550	120388.86
12.	10/16/2025	120550	120377.16
…	…	…	…
21.	10/29/2025	120450	120282.37
22.	10/30/2025	120450	120272.92

Tabel 4.8 menyajikan perbandingan antara harga aktual dan hasil prediksi harga komoditas daging sapi selama Oktober 2025 pada skenario univariate terbaik dengan window size 30 dan 32 unit LSTM. Berdasarkan data yang ditampilkan, pada awal periode pengujian model menghasilkan nilai prediksi yang sangat mendekati harga aktual, khususnya pada tanggal 1–2 Oktober 2025, dengan selisih prediksi yang relatif kecil dari harga aktual sebesar Rp120.550. Pada data yang ditampilkan untuk pertengahan hingga akhir periode, nilai prediksi menunjukkan kecenderungan menurun secara bertahap, sementara harga aktual terlihat relatif stabil dengan perubahan yang sangat kecil. Perbedaan antara harga prediksi dan harga aktual tersebut mengindikasikan bahwa model merespons pola historis sebelumnya yang mengarah pada penyesuaian harga secara gradual. Secara teknis, deviasi yang terjadi masih tergolong rendah dan konsisten sepanjang periode yang ditampilkan, sehingga menunjukkan bahwa model LSTM univariate mampu

memberikan prediksi yang sangat akurat pada komoditas daging sapi yang memiliki pola harga relatif stabil dan tidak menunjukkan fluktuasi ekstrem.

4.2.4 Hasil Uji Coba Skenario Univariate Komoditas Telur Ayam

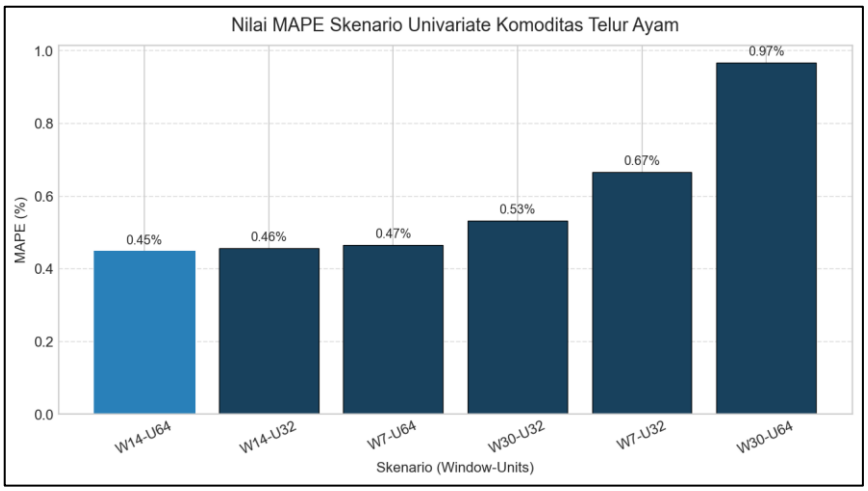
Pengujian skenario univariate untuk komoditas telur ayam dilakukan untuk mengevaluasi kemampuan model LSTM dalam mempelajari pola harga yang lebih fluktuatif dibandingkan komoditas sebelumnya. Kombinasi parameter yang diuji meliputi variasi window 7, 14, dan 30 hari serta unit LSTM 32 dan 64.

Tabel 4.9 Hasil Pengujian Skenario Univariate Komoditas Telur Ayam

No.	Window	Units	MAPE Testing	MAPE Forecasting
1.	7	32	0.66%	5.24%
2.	7	64	0.46%	3.29%
3.	14	32	0.45%	2.49%
4.	14	64	0.44%	2.34%
5.	30	32	0.53%	4.02%
6.	30	64	0.96%	8.46%

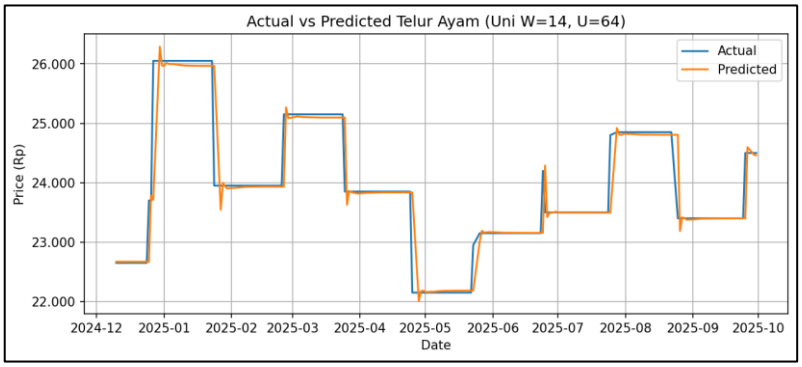
Tabel 4.9 menunjukkan bahwa performa terbaik diperoleh pada kombinasi window 14 dengan 64 unit LSTM (W14-U64). Skenario ini menghasilkan MAPE testing 0,447% dan MAPE forecasting 2,348%, yang merupakan nilai terendah di antara semua variasi. Performa baik pada window 14 menunjukkan bahwa pola harga telur ayam membutuhkan cakupan informasi historis yang tidak terlalu pendek maupun terlalu panjang. Window 7 terlalu singkat sehingga model kurang menangkap siklus harga yang terbentuk secara bertahap, sedangkan window 30 justru memperburuk performa karena memasukkan terlalu banyak pola lama yang tidak lagi relevan. Hal ini terlihat pada skenario W30-U64 yang menghasilkan

MAPE forecasting tertinggi sebesar 8,467%, mengindikasikan terjadinya overfitting atau hilangnya sensitivitas model terhadap pola harga terkini.



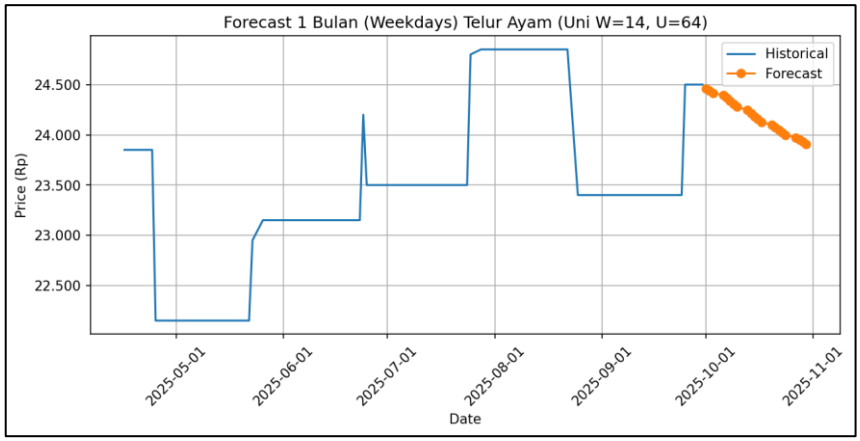
Gambar 4.10 Nilai MAPE Skenario Univariate Komoditas Telur Ayam

Gambar 4.10 memperlihatkan sebaran nilai MAPE pada seluruh skenario. Terlihat bahwa tiga skenario terbaik berada pada window 14 dan window 7 dengan unit 64 (W14-U64, W14-U32, dan W7-U64), masing-masing berada pada kisaran error 0,45–0,47%. Sementara itu, dua skenario window 30 menunjukkan performa terburuk terutama W30-U64 dengan error mendekati 1%. Secara teknis, grafik ini menegaskan bahwa pola harga telur ayam memiliki struktur temporal menengah yang tidak dapat ditangkap secara optimal menggunakan window pendek maupun panjang. Hal ini konsisten dengan karakteristik telur ayam yang memiliki siklus fluktuasi mingguan dan bulanan, sehingga model memerlukan konteks yang tepat untuk mengekstraksi informasi tersebut.



Gambar 4.11 Grafik Actual vs Predicted Komoditas Telur Ayam Skenario Univarate Terbaik

Gambar 4.11 menampilkan grafik actual vs predicted untuk skenario terbaik (W14-U64). Grafik menunjukkan bahwa model berhasil mengikuti perubahan harga yang terjadi secara bertahap, termasuk kenaikan tajam pada Desember–Januari, penurunan signifikan pada Mei 2025, serta kenaikan kembali menuju Agustus dan September. Meskipun terdapat sedikit deviasi pada titik perubahan ekstrem, prediksi model tetap berada sangat dekat dengan nilai aktual. Secara teknis, performa ini menunjukkan bahwa model mampu mempelajari pola fluktuasi non-linear dan stepwise, yang umum terjadi pada komoditas pangan dengan dinamika permintaan dan pasokan harian.



Gambar 4.12 Grafik Forecast Oktober 2025 Komoditas Telur Ayam Skenario Univarate Terbaik

Gambar 4.12 menunjukkan hasil forecasting untuk Oktober 2025 menggunakan model terbaik. Grafik menunjukkan pola penurunan harga dari sekitar Rp24.500 menuju kisaran Rp24.000 dalam beberapa minggu. Tren turun yang terbentuk merupakan respons model terhadap pola historis pada akhir September yang menunjukkan penurunan bertahap. Secara teknis, konfigurasi W14-U64 menghasilkan prediksi yang stabil dan tidak menunjukkan fluktuasi ekstrem, menandakan bahwa model belajar dari kecenderungan tren terakhir dan meneruskannya ke masa depan secara konservatif.

Tabel 4.10 Perbandingan Harga Aktual dan Forecast Telur Ayam Skenario Univariate Terbaik

No.	Tanggal	Harga Aktual (Rp)	Harga Prediksi (Rp)
1.	10/1/2025	24500	24461.21
2.	10/2/2025	24500	24438.59
…	…	…	…
11.	10/15/2025	24500	24185.87
12.	10/16/2025	24500	24156.11
…	…	…	…
21.	10/29/2025	25750	23929.66
22.	10/30/2025	25750	23908.79

Tabel 4.10 menyajikan perbandingan antara harga aktual dan hasil prediksi harga komoditas telur ayam selama Oktober 2025 pada skenario univariate terbaik dengan window size 14 dan 64 unit LSTM. Berdasarkan data yang ditampilkan, pada awal periode pengujian model menghasilkan nilai prediksi yang relatif dekat dengan harga aktual, khususnya pada tanggal 1–2 Oktober 2025, dengan selisih yang masih berada dalam kisaran puluhan rupiah dari harga aktual sebesar Rp24.500. Namun, pada data yang ditampilkan untuk pertengahan hingga akhir periode, nilai prediksi menunjukkan kecenderungan penurunan secara bertahap,

sementara harga aktual pada akhir periode justru berada pada tingkat yang lebih tinggi dibandingkan awal bulan. Perbedaan antara arah pergerakan harga prediksi dan harga aktual tersebut menunjukkan bahwa model univariate merespons pola historis sebelumnya yang mengarah pada penurunan harga, tanpa mampu mengantisipasi adanya perubahan harga yang bersifat abrupt. Secara teknis, kondisi ini mencerminkan keterbatasan model LSTM univariate dalam menangkap dinamika perubahan harga yang tidak tercermin pada data masa lalu. Meskipun demikian, deviasi yang terjadi masih mencerminkan karakteristik komoditas telur ayam yang memiliki volatilitas relatif lebih tinggi dibandingkan komoditas dengan harga stabil, sehingga hasil forecasting tetap memberikan gambaran tren harga secara umum.

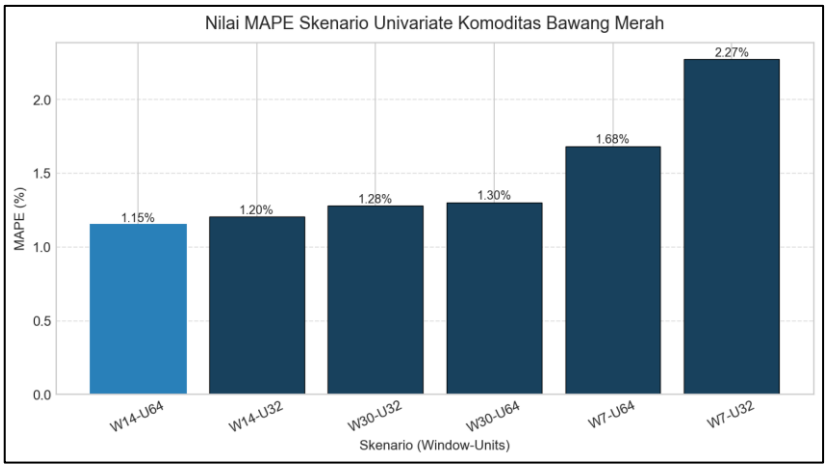
4.2.5 Hasil Uji Coba Skenario Univariate Komoditas Bawang Merah

Pengujian skenario univariate pada komoditas bawang merah dilakukan untuk memahami kemampuan model LSTM dalam mempelajari pola harga yang sangat fluktuatif dan memiliki perubahan ekstrem pada beberapa periode. Variasi parameter yang digunakan meliputi window 7, 14, dan 30 hari serta unit LSTM 32 dan 64.

Tabel 4.11 Hasil Pengujian Skenario Univariate Komoditas Bawang Merah

No.	Window	Units	MAPE Testing	MAPE Forecasting
1.	7	32	2.27%	14.28%
2.	7	64	1.68%	7.46%
3.	14	32	1.20%	3.14%
4.	14	64	1.15%	2.76%
5.	30	32	1.27%	2.99%
6.	30	64	1.30%	6.05%

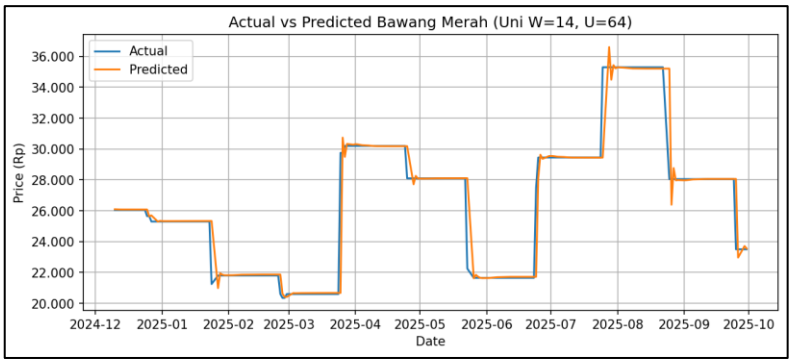
Tabel 4.11 menunjukkan hasil pengujian seluruh skenario univariate bawang merah. Berdasarkan nilai MAPE testing dan forecasting, skenario terbaik diperoleh pada kombinasi window 14 dengan 64 unit LSTM (W14-U64), dengan nilai MAPE testing 1,150% dan MAPE forecasting 2,764%. Nilai ini merupakan yang terendah dibandingkan skenario lainnya, menandakan bahwa model bekerja paling stabil ketika diberi konteks historis menengah (14 hari). Sebaliknya, skenario dengan window 7 menunjukkan performa terburuk, khususnya W7-U32 yang menghasilkan MAPE forecasting 14,285%, mencerminkan bahwa konteks jangka pendek tidak cukup untuk menangkap pola harga bawang merah yang sangat volatil. Window 30 juga tidak memberikan hasil optimal karena model cenderung terlalu "melebar" mengikuti pola lama yang kurang relevan terhadap fluktuasi terbaru, seperti terlihat pada W30-U64 dengan MAPE forecasting 6,052%.



Gambar 4.13 Nilai MAPE Skenario Univariate Komoditas Bawang Merah

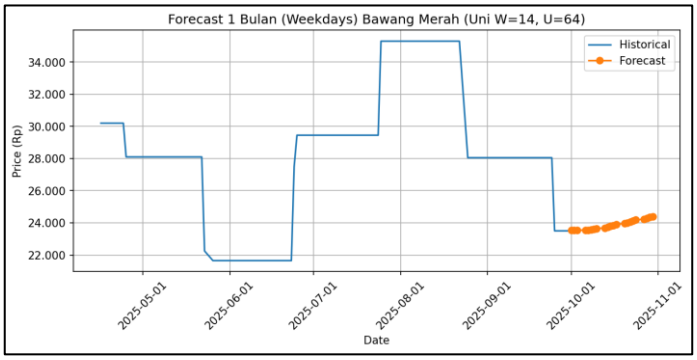
Gambar 4.13 memperlihatkan distribusi nilai MAPE seluruh skenario. Grafik menunjukkan bahwa pola error cenderung meningkat pada window 7, lalu menurun pada window 14, dan kembali meningkat pada window 30. Secara teknis,

hal ini menunjukkan bahwa struktur harga bawang merah memiliki pola siklik yang tidak dapat ditangkap secara efektif dengan window terlalu pendek ataupun terlalu panjang. Window 14 memberikan keseimbilan yang optimal antara panjang konteks temporal dan relevansi informasi historis. Skenario dengan unit 64 secara umum memberikan performa lebih stabil dibandingkan unit 32, khususnya dalam skenario dengan volatilitas tinggi seperti bawang merah.



Gambar 4.14 Grafik Actual vs Predicted Komoditas Bawang Merah Skenario Univarate Terbaik

Gambar 4.14 menampilkan grafik actual vs predicted untuk skenario terbaik (W14-U64). Grafik memperlihatkan bahwa model mampu mengikuti pola harga dengan cukup baik meskipun terdapat beberapa deviasi pada titik perubahan ekstrem, seperti lonjakan harga tajam pada Februari dan August 2025. Model berhasil meniru bentuk pergerakan harga yang bersifat stepwise, namun tetap mengalami kesulitan pada kenaikan atau penurunan yang sangat drastis dalam waktu singkat. Secara teknis, hal ini disebabkan oleh karakteristik LSTM yang belajar dari pola berulang, sehingga perubahan harga yang tidak memiliki kemiripan dengan pola masa lalu cenderung sulit diprediksi secara akurat.



Gambar 4.15 Grafik Forecast Oktober 2025 Komoditas Bawang Merah Skenario Univarate Terbaik

Gambar 4.15 menunjukkan hasil forecasting selama Oktober 2025 menggunakan skenario terbaik. Model memprediksi tren kenaikan bertahap dari kisaran Rp23.500 menuju Rp24.300. Pola naik ini merupakan respons model terhadap tren historis akhir September yang menunjukkan pergerakan stabil dengan kecenderungan sedikit meningkat. Model melanjutkan pola tersebut secara konservatif tanpa menampilkan fluktuasi ekstrem. Secara teknis, prediksi ini mencerminkan sifat model LSTM yang cenderung memperpanjang tren terakhir ketika volatilitas tinggi tidak terdeteksi secara kuat dalam jendela historis yang digunakan.

Tabel 4.12 Perbandingan Harga Aktual dan Forecast Bawang Merah Skenario Univariate Terbaik

No.	**Tanggal**	**Harga Aktual (Rp)**	**Harga Prediksi (Rp)**
1.	10/1/2025	23500	23547.8
2.	10/2/2025	23500	23551.85
…	…	…	…
11.	10/15/2025	23500	23792.56
12.	10/16/2025	23500	23848.04
…	…	…	…
21.	10/29/2025	26650	24344.31
22.	10/30/2025	26650	24397.83

Tabel 4.12 menyajikan perbandingan antara harga aktual dan hasil prediksi harga komoditas bawang merah selama Oktober 2025 pada skenario univariate terbaik dengan window size 14 dan 64 unit LSTM. Berdasarkan data yang ditampilkan, pada awal periode pengujian model menghasilkan nilai prediksi yang relatif dekat dengan harga aktual, dengan selisih yang masih berada pada kisaran puluhan rupiah dari harga aktual sebesar Rp23.500. Pada data yang ditampilkan untuk pertengahan periode, nilai prediksi menunjukkan kecenderungan meningkat secara bertahap, sementara harga aktual masih berada pada tingkat yang relatif sama. Namun, pada data yang ditampilkan menjelang akhir periode, harga aktual mengalami kenaikan yang lebih tinggi dibandingkan nilai prediksi model. Perbedaan antara harga aktual dan harga prediksi tersebut menunjukkan bahwa model univariate tidak mampu mengikuti perubahan harga yang meningkat secara tajam dalam waktu singkat. Secara teknis, kondisi ini mencerminkan keterbatasan model LSTM univariate yang sangat bergantung pada pola historis sebelumnya, sehingga kurang responsif terhadap perubahan harga yang bersifat abrupt dan tidak tercermin dalam data masa lalu.

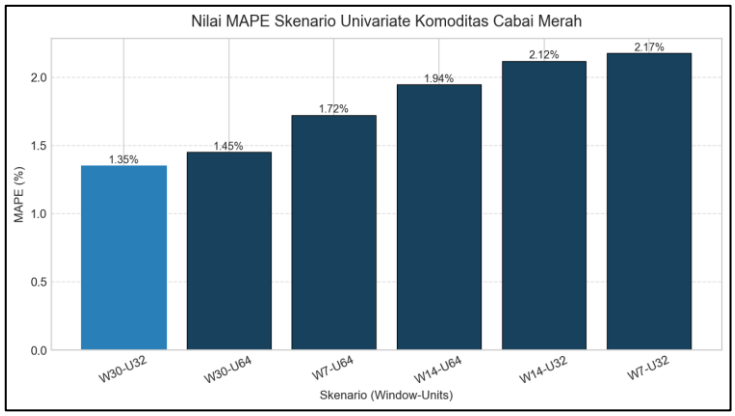
4.2.6 Hasil Uji Coba Skenario Univariate Komoditas Cabai Merah

Pengujian skenario univariate pada komoditas cabai merah dilakukan untuk mengevaluasi performa model LSTM dalam mempelajari pola harga yang memiliki volatilitas tinggi dan perubahan ekstrem pada periode tertentu. Variasi parameter yang digunakan meliputi window 7, 14, dan 30 hari serta unit LSTM 32 dan 64.

Tabel 4.13 Hasil Pengujian Skenario Univariate Komoditas Cabai Merah

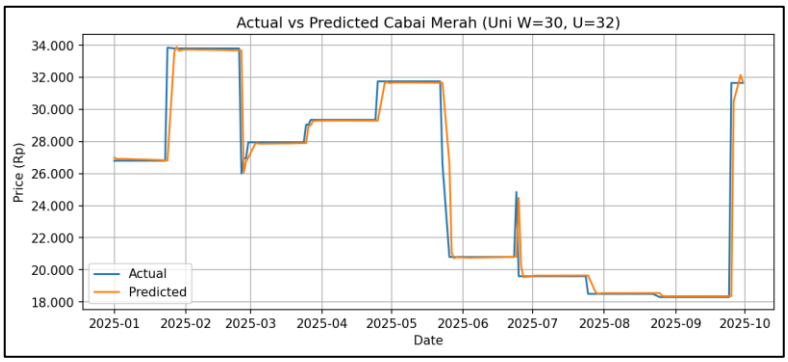
No.	Window	Units	MAPE Testing	MAPE Forecasting
1.	7	32	2.17%	12.93%
2.	7	64	1.72%	2.49%
3.	14	32	2.11%	10.11%
4.	14	64	1.94%	9.62%
5.	30	32	1.34%	0.92%
6.	30	64	1.44%	4.16%

Tabel 4.13 menunjukkan hasil pengujian seluruh kombinasi parameter untuk komoditas cabai merah. Berdasarkan nilai MAPE, skenario terbaik diperoleh pada kombinasi window 30 dan 32 unit LSTM (W30-U32), dengan MAPE testing 1,348% dan MAPE forecasting 0,922%, yang merupakan nilai terendah dari seluruh skenario. Hasil ini menunjukkan bahwa model memerlukan konteks historis yang panjang untuk memahami pola harga cabai merah yang sering mengalami kenaikan dan penurunan ekstrem. Sebaliknya, window pendek (7 hari) menghasilkan performa yang sangat buruk, khususnya skenario W7-U32 yang mencapai MAPE forecasting 12,934%, menandakan bahwa model tidak mampu menangkap volatilitas komoditas ini jika hanya diberikan informasi jangka pendek. Window 14 juga tidak memberikan hasil optimal karena fluktuasi harga yang tajam memerlukan rangkaian data lebih panjang untuk dapat dipelajari oleh LSTM.



Gambar 4.16 Nilai MAPE Skenario Univariate Komoditas Cabai Merah

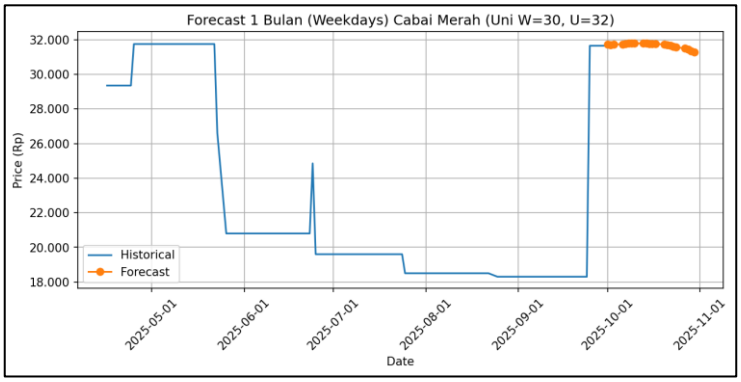
Gambar 4.16 memperlihatkan visualisasi nilai MAPE untuk seluruh skenario univariate. Terlihat bahwa model memberikan performa terbaik pada window 30, diikuti window 7 dan 14 dengan nilai error yang jauh lebih tinggi. Kecenderungan menurunnya error pada window 30 secara teknis menunjukkan bahwa model membutuhkan informasi historis yang panjang untuk menstabilkan prediksi terhadap volatilitas ekstrem. Hal ini sesuai dengan karakteristik cabai merah yang mengalami perubahan harga tajam akibat faktor musiman, cuaca, dan pasokan, sehingga pola jangka panjang lebih informatif bagi model dibandingkan sinyal jangka pendek.



Gambar 4.17 Grafik Actual vs Predicted Komoditas Cabai Merah Skenario Univarate Terbaik

Gambar 4.17 menampilkan grafik actual vs predicted untuk skenario terbaik (W30-U32). Grafik menunjukkan bahwa model mampu mengikuti pola umum pergerakan harga, termasuk lonjakan harga pada Februari dan penurunan tajam pada Juni 2025. Meskipun terdapat deviasi pada titik perubahan ekstrem, prediksi model tetap berada cukup dekat dengan nilai aktual. Secara teknis, ini menunjukkan bahwa window 30 memberi model kapasitas cukup untuk mempelajari struktur volatilitas yang berulang, sehingga prediksi lebih stabil walaupun tidak selalu tepat

pada titik ekstrem. LSTM dalam konfigurasi ini dapat mengantisipasi arah pergerakan harga, meskipun tidak sepenuhnya akurat dalam memetakan besarnya perubahan.



Gambar 4.18 Grafik Forecast Oktober 2025 Komoditas Cabai Merah Skenario Univarate Terbaik

Gambar 4.18 menunjukkan hasil forecasting untuk Oktober 2025. Model memprediksi harga cabai merah berada pada kisaran relatif stabil antara Rp31.900–Rp31.400 sepanjang bulan tersebut. Pola prediksi yang cenderung datar ini merupakan respons model terhadap tren stabil pada akhir September, di mana harga meningkat tajam dan kemudian cenderung stagnan. Secara teknis, model mengekstrapolasi pola tersebut dan mempertahankannya tanpa mengikuti volatilitas ekstrem karena tidak ditemukan pola shock serupa pada jendela historis yang digunakan dalam pelatihan.

Tabel 4.14 Perbandingan Harga Aktual dan Forecast Cabai Merah Skenario Univariate Terbaik

No.	Tanggal	Harga Aktual (Rp)	Harga Prediksi (Rp)
1.	10/1/2025	31650	31728.36
2.	10/2/2025	31650	31699.35
…	…	…	…
11.	10/15/2025	31650	31779.55
12.	10/16/2025	31650	31770.48
…	…	…	…

No.	Tanggal	Harga Aktual (Rp)	Harga Prediksi (Rp)
21.	10/29/2025	31900	31356.95
22.	10/30/2025	31900	31278.75

Tabel 4.14 menyajikan perbandingan antara harga aktual dan hasil prediksi harga komoditas cabai merah selama Oktober 2025 pada skenario univariate terbaik dengan window size 30 dan 32 unit LSTM. Berdasarkan data yang ditampilkan, pada awal periode pengujian nilai prediksi model relatif dekat dengan harga aktual, dengan selisih yang masih berada dalam kisaran puluhan hingga ratusan rupiah dari harga aktual sebesar Rp31.650. Pada data yang ditampilkan untuk pertengahan periode, harga aktual terlihat relatif stabil, sementara nilai prediksi mulai menunjukkan kecenderungan menurun secara bertahap. Pada data yang ditampilkan menjelang akhir periode, harga aktual berada pada tingkat yang lebih tinggi dibandingkan nilai prediksi model. Perbedaan arah pergerakan ini menunjukkan bahwa model univariate LSTM merespons pola historis sebelumnya yang mengarah pada koreksi harga, sehingga tidak mampu mengikuti perubahan harga yang meningkat secara cepat. Secara teknis, kondisi ini mencerminkan keterbatasan model yang sangat bergantung pada informasi masa lalu, khususnya pada komoditas cabai merah yang memiliki volatilitas tinggi dan fluktuasi harga yang dinamis.

4.2.7 Hasil Uji Coba Skenario Univariate Komoditas Cabai Rawit

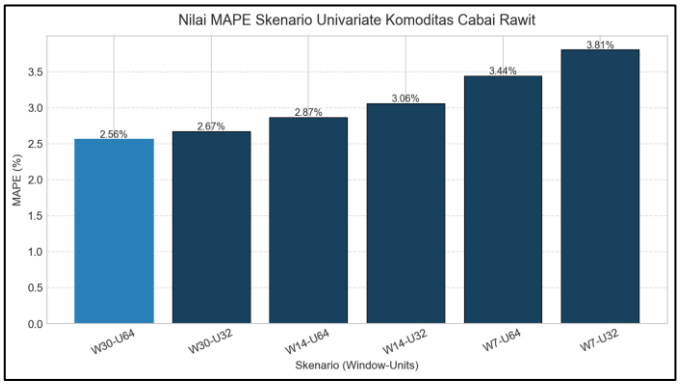
Pengujian skenario univariate untuk komoditas cabai rawit dilakukan untuk mengevaluasi kemampuan model LSTM dalam mempelajari pola harga yang

sangat volatil dan mengalami perubahan ekstrem dalam rentang waktu yang pendek. Variasi parameter yang digunakan terdiri dari window 7, 14, dan 30 hari serta unit LSTM 32 dan 64.

Tabel 4.15 Hasil Pengujian Skenario Univariate Komoditas Cabai Rawit

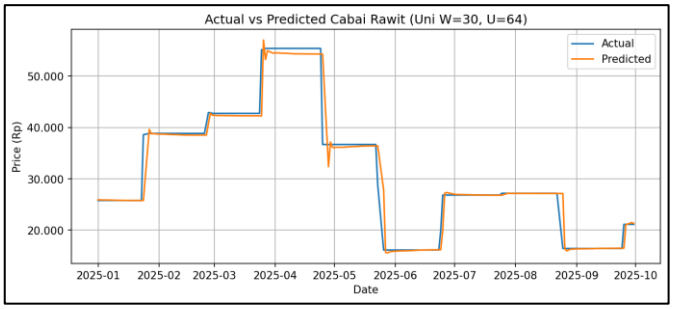
No.	Window	Units	MAPE Testing	MAPE Forecasting
1.	7	32	3.80%	48.01%
2.	7	64	3.44%	44.33%
3.	14	32	3.06%	21.25%
4.	14	64	2.86%	24.58%
5.	30	32	2.67%	14.76%
6.	30	64	2.56%	14.23%

Tabel 4.15 menunjukkan bahwa performa terbaik dicapai oleh kombinasi window 30 dan 64 unit LSTM (W30-U64), dengan nilai MAPE testing 2,562% dan MAPE forecasting 14,230%, yang merupakan nilai terendah dibandingkan skenario lainnya. Walaupun nilai error ini tetap jauh lebih tinggi dibandingkan komoditas lain, skenario W30-U64 memberikan stabilitas yang lebih baik pada komoditas dengan tingkat volatilitas ekstrem seperti cabai rawit. Window 7 menghasilkan performa terburuk dengan MAPE forecasting mencapai 48,014% pada skenario W7-U32, menunjukkan bahwa konteks historis jangka pendek tidak cukup untuk mempelajari dinamika harga cabai rawit yang sangat tidak stabil. Window 14 memberikan performa menengah, namun masih menghasilkan error yang besar karena model tidak dapat menangkap lonjakan harga yang terjadi secara mendadak.



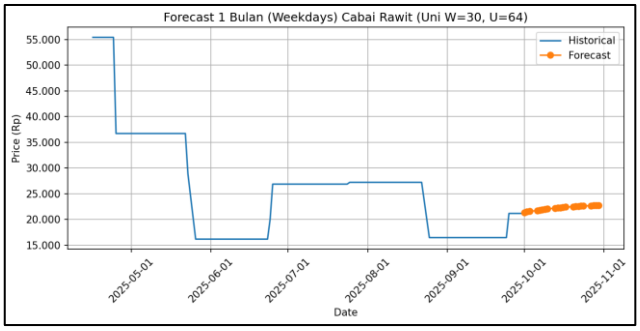
Gambar 4.19 Nilai MAPE Skenario Univariate Komoditas Cabai Rawit

Gambar 4.19 memperlihatkan distribusi nilai MAPE dari seluruh skenario. Terlihat bahwa nilai error meningkat seiring dengan berkurangnya panjang window, menunjukkan bahwa model memerlukan konteks historis yang panjang untuk dapat membuat prediksi yang lebih stabil. Secara teknis, pola ini konsisten dengan karakteristik cabai rawit yang dipengaruhi oleh faktor musiman, cuaca ekstrem, dan gangguan pasokan, sehingga sinyal harga jangka pendek tidak mampu mewakili pola fluktuasi yang kompleks. Dengan demikian, window 30 menjadi pilihan yang paling tepat karena memungkinkan model mengamati pola berulang yang lebih panjang sehingga mengurangi noise yang muncul pada window pendek.



Gambar 4.20 Grafik Actual vs Predicted Komoditas Cabai Rawit Skenario Univarate Terbaik

Gambar 4.20 menampilkan grafik actual vs predicted untuk skenario terbaik (W30-U64). Hasil grafik menunjukkan bahwa model mampu mengikuti pola umum harga, namun terjadi deviasi cukup besar pada titik-titik perubahan ekstrem, seperti lonjakan harga pada April 2025 dan penurunan tajam pada Mei 2025. Pada bagian harga stabil, model mengikuti garis aktual dengan baik, tetapi kesulitan memprediksi selisih yang ekstrem pada fluktuasi harga tinggi. Secara teknis, ini merupakan keterbatasan wajar pada model univariate LSTM karena model hanya bergantung pada pola historis dan memiliki kesulitan menangkap price shocks yang tidak konsisten dengan pola masa lalu.



Gambar 4.21 Grafik Forecast Oktober 2025 Komoditas Cabai Rawit Skenario Univarate Terbaik

Gambar 4.21 menunjukkan hasil forecasting model untuk Oktober 2025. Model memprediksi kenaikan harga secara bertahap dari kisaran Rp21.000 menuju sekitar Rp22.500 sepanjang bulan tersebut. Kenaikan yang terprediksi relatif halus ini terjadi karena model memperpanjang pola tren stabil pada akhir September. Tidak adanya indikasi shock besar dalam data historis menyebabkan model menghasilkan prediksi yang konservatif dan bertahap. Secara teknis, hal ini mencerminkan sifat LSTM yang cenderung merespons pola jangka panjang dan mengurangi sensitivitas terhadap noise ekstrem.

Tabel 4.16 Perbandingan Harga Aktual dan Forecast Cabai Rawit Skenario Univariate Terbaik

No.	Tanggal	Harga Aktual (Rp)	Harga Prediksi (Rp)
1.	10/1/2025	21150	21352.24
2.	10/2/2025	21150	21476.83
…	…	…	…
11.	10/15/2025	21150	22289.22
12.	10/16/2025	21150	22349.53
…	…	…	…
21.	10/29/2025	14850	22718.71
22.	10/30/2025	14850	22749.62

Tabel 4.16 menyajikan perbandingan antara harga aktual dan hasil prediksi harga komoditas cabai rawit selama Oktober 2025 pada skenario univariate terbaik dengan window size 30 dan 64 unit LSTM. Berdasarkan data yang ditampilkan, nilai prediksi model menunjukkan kecenderungan meningkat secara bertahap sepanjang periode pengujian, sementara harga aktual pada awal periode berada pada tingkat yang relatif stabil. Namun, pada data yang ditampilkan menjelang akhir periode, harga aktual mengalami penurunan yang cukup besar, sedangkan nilai prediksi model tetap berada pada tingkat yang jauh lebih tinggi. Perbedaan arah pergerakan yang sangat kontras ini menunjukkan bahwa model univariate LSTM mempertahankan pola historis kenaikan harga yang dipelajarinya, tanpa mampu menyesuaikan diri terhadap perubahan harga yang menurun secara tajam dalam waktu singkat. Secara teknis, kondisi tersebut mencerminkan keterbatasan model yang sangat bergantung pada informasi masa lalu, sehingga kurang responsif terhadap dinamika harga ekstrem pada komoditas cabai rawit yang memiliki volatilitas sangat tinggi.

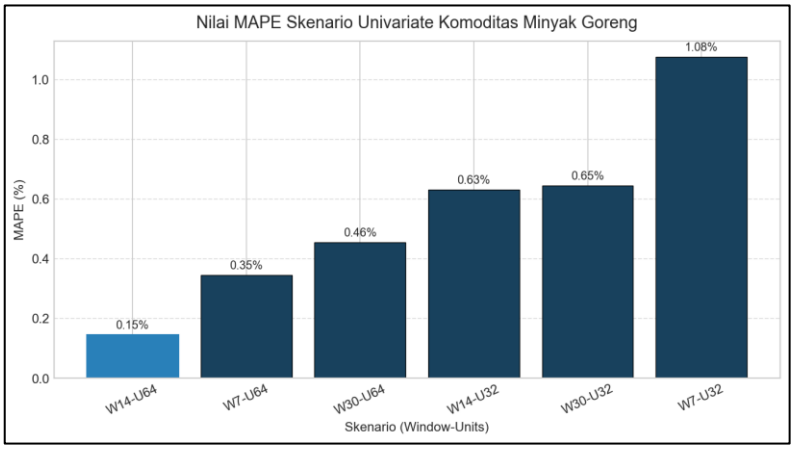
4.2.8 Hasil Uji Coba Skenario Univariate Komoditas Minyak Goreng

Pengujian skenario univariate pada komoditas minyak goreng dilakukan untuk mengevaluasi performa model LSTM dalam mempelajari pola harga yang relatif stabil dibandingkan komoditas pangan lainnya. Variasi parameter yang diuji meliputi window 7, 14, dan 30 hari serta jumlah unit LSTM 32 dan 64.

Tabel 4.17 Hasil Pengujian Skenario Univariate Komoditas Minyak Goreng

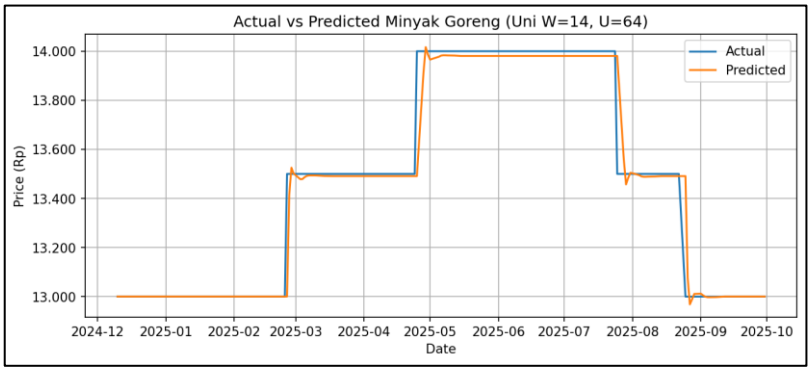
No.	Window	Units	MAPE Testing	MAPE Forecasting
1.	7	32	1.07%	7.36%
2.	7	64	0.34%	1.99%
3.	14	32	0.63%	3.02%
4.	14	64	0.14%	0.02%
5.	30	32	0.64%	3.90%
6.	30	64	0.45%	2.95%

Tabel 4.17 menunjukkan bahwa performa terbaik dicapai pada kombinasi window 14 dan 64 unit LSTM (W14-U64), dengan nilai MAPE testing 0,146% dan MAPE forecasting 0,020%, yang merupakan nilai terendah pada seluruh skenario. Hasil ini menunjukkan bahwa model bekerja sangat baik ketika diberikan konteks historis sepanjang 14 hari, yang cukup untuk menangkap pola perubahan harga minyak goreng yang cenderung gradual. Sebaliknya, window 7 menghasilkan performa lebih buruk, terutama kombinasi W7-U32 dengan MAPE forecasting 7,362%, menunjukkan bahwa konteks jangka pendek tidak memadai untuk memprediksi variasi kecil pada harga minyak goreng. Window 30 juga tidak menghasilkan performa lebih baik karena memasukkan data historis terlalu panjang sehingga menambah noise pada komoditas dengan dinamika harga yang relatif lambat berubah.



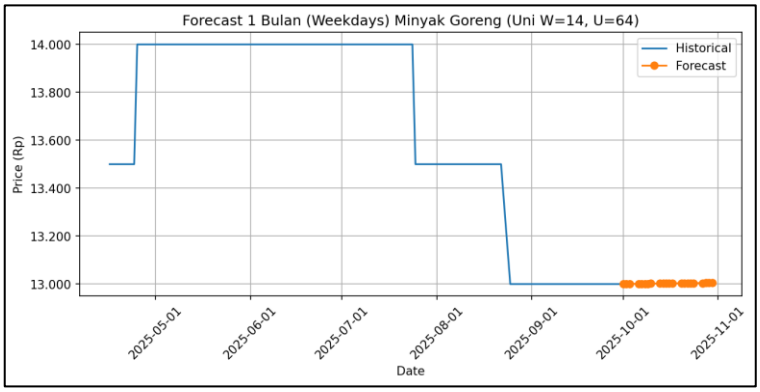
Gambar 4.22 Nilai MAPE Skenario Univariate Komoditas Minyak Goreng

Gambar 4.22 memperlihatkan distribusi nilai MAPE dari seluruh skenario. Terlihat bahwa W14-U64 berada jauh di bawah skenario lainnya, menandakan stabilitas model yang sangat baik pada konfigurasi tersebut. Sementara itu, nilai MAPE meningkat pada window 30 dan paling tinggi pada window 7. Secara teknis, pola ini menunjukkan bahwa minyak goreng memiliki pola historis jangka menengah yang ideal untuk dipelajari model, sehingga window 14 memberikan keseimbangan paling optimal—tidak terlalu pendek hingga kehilangan informasi tren, dan tidak terlalu panjang hingga menghasilkan pola yang tidak lagi relevan.



Gambar 4.23 Grafik Actual vs Predicted Komoditas Minyak Goreng Skenario Univarate Terbaik

Gambar 4.23 menampilkan grafik actual vs predicted untuk skenario terbaik (W14-U64). Grafik menunjukkan bahwa model mampu mengikuti perubahan harga dengan sangat mendekati nilai aktual pada seluruh periode pengujian. Baik kenaikan bertahap menuju bulan Maret maupun penurunan harga pada akhir Agustus berhasil direplikasi model dengan deviasi yang sangat kecil. Secara teknis, hal ini menunjukkan bahwa struktur harga minyak goreng yang stabil dan minim volatilitas memungkinkan LSTM belajar pola dengan presisi tinggi tanpa mengalami overfitting maupun underfitting.



Gambar 4.24 Grafik Forecast Oktober 2025 Komoditas Minyak Goreng Skenario Univarate Terbaik

Gambar 4.24 menyajikan hasil forecasting selama Oktober 2025. Model memprediksi harga minyak goreng akan berada pada kisaran stabil sekitar Rp13.000 sepanjang bulan tersebut tanpa perubahan signifikan. Prediksi ini merupakan kelanjutan dari pola historis akhir September yang juga stabil. Secara teknis, ini menunjukkan bahwa model menggunakan tren jangka menengah yang konsisten untuk menghasilkan prediksi konservatif, cocok untuk komoditas yang tidak menunjukkan indikasi volatilitas tinggi.

Tabel 4.18 Perbandingan Harga Aktual dan Forecast Minyak Goreng Skenario Univariate Terbaik

No.	Tanggal	Harga Aktual (Rp)	Harga Prediksi (Rp)
1.	10/1/2025	13000	13000.28
2.	10/2/2025	13000	13000.51
…	…	…	…
11.	10/15/2025	13000	13002.58
12.	10/16/2025	13000	13002.79
…	…	…	…
21.	10/29/2025	13000	13004.57
22.	10/30/2025	13000	13004.75

Tabel 4.18 menyajikan perbandingan antara harga aktual dan hasil prediksi harga komoditas minyak goreng selama Oktober 2025 pada skenario univariate terbaik dengan window size 14 dan 64 unit LSTM. Berdasarkan data yang ditampilkan, nilai prediksi model menunjukkan kedekatan yang sangat tinggi terhadap harga aktual, dengan selisih yang sangat kecil pada setiap titik waktu yang ditampilkan. Pada awal hingga akhir periode pengujian yang terlihat pada tabel, harga aktual berada pada tingkat yang sama, sementara nilai prediksi hanya mengalami peningkatan yang sangat kecil. Kondisi ini menunjukkan bahwa model mampu merepresentasikan pola harga minyak goreng yang relatif stabil secara konsisten. Secara teknis, deviasi prediksi yang sangat rendah mencerminkan bahwa model LSTM univariate bekerja sangat efektif pada komoditas dengan fluktuasi harga minimal, sehingga hasil forecasting yang dihasilkan memiliki tingkat akurasi yang sangat tinggi.

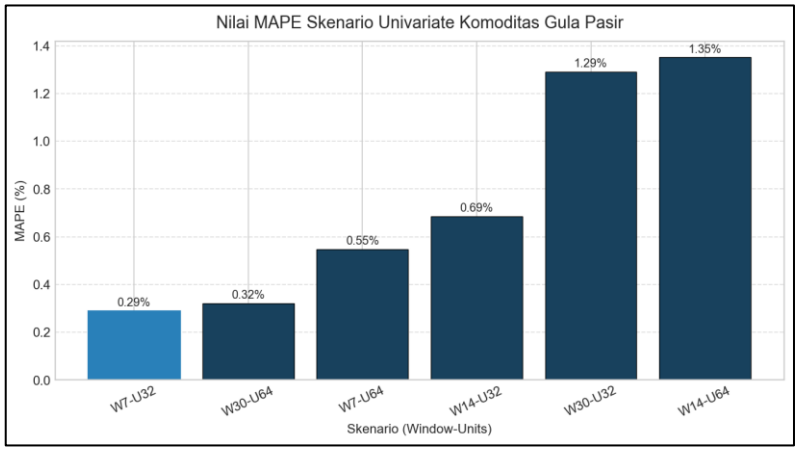
4.2.9 Hasil Uji Coba Skenario Univariate Komoditas Gula Pasir

Pengujian skenario univariate pada komoditas gula pasir dilakukan untuk mengevaluasi kemampuan model LSTM dalam mempelajari pola harga yang relatif stabil namun tetap memiliki perubahan bertahap pada periode tertentu. Pengujian dilakukan menggunakan variasi window 7, 14, dan 30 hari serta unit LSTM 32 dan 64.

Tabel 4.19 Hasil Pengujian Skenario Univariate Komoditas Gula Pasir

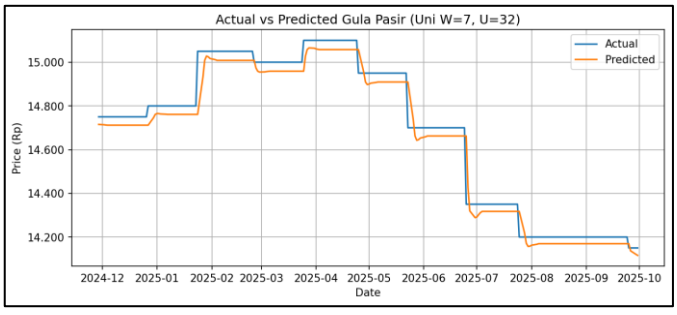
No.	Window	Units	MAPE Testing	MAPE Forecasting
1.	7	32	0.28%	2.10%
2.	7	64	0.54%	4.61%
3.	14	32	0.68%	5.08%
4.	14	64	1.35%	10.24%
5.	30	32	1.29%	9.63%
6.	30	64	0.32%	2.23%

Tabel 4.19 menunjukkan bahwa skenario terbaik diperoleh pada kombinasi window 7 dan 32 unit LSTM (W7-U32), dengan nilai MAPE testing 0,288% dan MAPE forecasting 2,100%. Nilai ini merupakan yang terendah di antara seluruh varian yang diuji, menunjukkan bahwa model bekerja optimal ketika menggunakan jendela historis yang lebih pendek. Hal ini mengindikasikan bahwa pola harga gula pasir bersifat lebih responsif terhadap tren jangka pendek dan tidak membutuhkan rentang historis panjang. Sebaliknya, skenario dengan window 14 menghasilkan nilai error tertinggi, terutama W14-U64 dengan MAPE forecasting mencapai 10,244%, yang menunjukkan adanya ketidaksesuaian antara panjang window dan karakteristik pola harga gula pasir. Window 30 menghasilkan performa menengah, namun tetap kurang stabil dibandingkan window 7, khususnya pada konfigurasi dengan 32 unit.



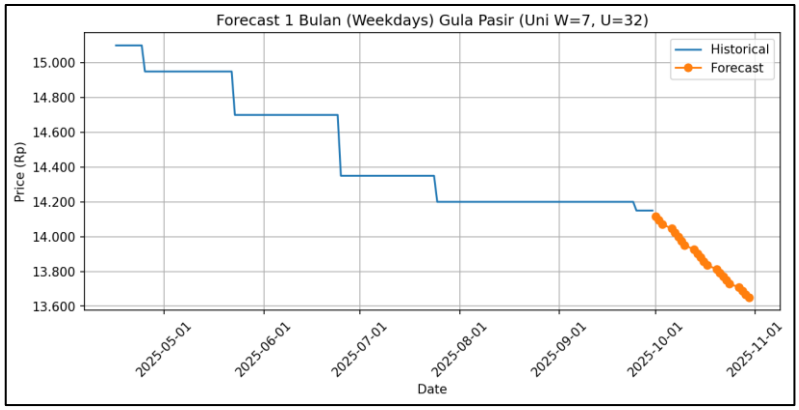
Gambar 4.25 Nilai MAPE Skenario Univariate Komoditas Gula Pasir

Gambar 4.25 memperlihatkan distribusi nilai MAPE seluruh skenario. Pola pada grafik menunjukkan bahwa dua skenario terbaik berada pada window 7 (W7-U32 dan W7-U64), masing-masing dengan error 0,29% dan 0,55%, sedangkan skenario dengan window 14 dan 30 memiliki nilai error lebih tinggi. Secara teknis, hal ini menunjukkan bahwa gula pasir memiliki struktur harga yang bergerak secara bertahap dan tidak bergantung pada pola jangka panjang, sehingga window pendek lebih efektif dalam memberikan sinyal yang relevan untuk model. Selain itu, penggunaan unit LSTM lebih besar (64 unit) tidak selalu meningkatkan performa dan bahkan memperburuk hasil pada beberapa skenario karena menambah kompleksitas yang tidak diperlukan.



Gambar 4.26 Grafik Actual vs Predicted Komoditas Gula Pasir Skenario Univarate Terbaik

Gambar 4.26 menampilkan grafik actual vs predicted untuk skenario terbaik (W7-U32). Model mampu mengikuti bentuk tren harga dengan cukup baik, termasuk kenaikan bertahap pada Januari hingga April 2025 dan penurunan konsisten mulai Mei hingga September 2025. Perbedaan kecil terlihat terutama pada puncak harga di bulan Februari dan April, yang menunjukkan bahwa model masih mengalami sedikit kesulitan dalam memprediksi perubahan harga yang sifatnya transisi cepat. Meskipun demikian, secara keseluruhan, model mempertahankan pola prediksi yang mendekati harga aktual sehingga memastikan akurasi yang memadai.



Gambar 4.27 Grafik Forecast Oktober 2025 Komoditas Gula Pasir Skenario Univarate Terbaik

Gambar 4.27 menunjukkan hasil forecasting untuk Oktober 2025. Model memprediksi tren penurunan harga gula pasir yang berlanjut dari pola historis bulan September, dengan nilai prediksi turun secara bertahap dari sekitar Rp14.150 menuju kisaran Rp13.700. Pola menurun yang dihasilkan menunjukkan bahwa model memanfaatkan tren jangka pendek yang konsisten dan memperpanjangnya ke periode forecasting. Secara teknis, ini menunjukkan bahwa LSTM univariate

merespons kuat terhadap pola peluruhan harga yang stabil sehingga menghasilkan prediksi yang cenderung smooth dan teratur.

Tabel 4.20 Perbandingan Harga Aktual dan Forecast Gula Pasir Skenario Univariate Terbaik

No.	Tanggal	Harga Aktual (Rp)	Harga Prediksi (Rp)
1.	10/1/2025	14150	14116.1
2.	10/2/2025	14150	14094.29
…	…	…	…
11.	10/15/2025	14150	13880.19
12.	10/16/2025	14150	13857.51
…	…	…	…
21.	10/29/2025	14250	13668.19
22.	10/30/2025	14250	13648.75

Tabel 4.20 menyajikan perbandingan antara harga aktual dan hasil prediksi harga komoditas gula pasir selama Oktober 2025 pada skenario univariate terbaik dengan window size 7 dan 32 unit LSTM. Berdasarkan data yang ditampilkan, nilai prediksi model secara konsisten berada di bawah harga aktual pada setiap titik waktu yang terlihat dalam tabel. Pada awal periode pengujian, selisih antara harga prediksi dan harga aktual masih relatif kecil, namun pada data yang ditampilkan untuk pertengahan hingga akhir periode, perbedaan tersebut tampak semakin besar. Sementara harga aktual pada akhir periode berada pada tingkat yang lebih tinggi dibandingkan awal bulan, nilai prediksi model justru menunjukkan kecenderungan menurun secara bertahap. Perbedaan arah pergerakan ini mengindikasikan bahwa model univariate merespons pola historis sebelumnya yang mengarah pada penurunan harga, sehingga prediksi yang dihasilkan cenderung lebih rendah dibandingkan kondisi aktual. Secara teknis, deviasi ini mencerminkan sensitivitas model LSTM univariate terhadap pola jangka pendek yang dipelajari dari data masa

lalu, meskipun perbedaannya masih mencerminkan karakteristik harga gula pasir yang bergerak secara gradual tanpa fluktuasi ekstrem..

4.2.10 Hasil Uji Coba Skenario Multivariate Komoditas Beras

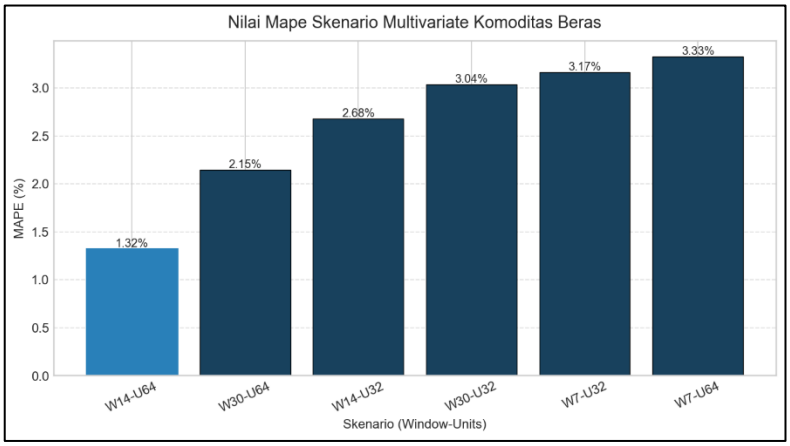
Pengujian pada skenario multivariate untuk komoditas beras dilakukan dengan melibatkan seluruh variabel harga delapan komoditas lain sebagai fitur input tambahan. Pendekatan ini bertujuan untuk melihat sejauh mana dinamika antar-komoditas dapat memberikan kontribusi terhadap peningkatan kemampuan model dalam mempelajari pola harga beras, terutama pada perubahan jangka pendek. Seluruh skenario diuji menggunakan kombinasi sliding window 7, 14, dan 30 hari serta unit LSTM 32 dan 64.

Tabel 4.21 Hasil Pengujian Skenario Multivariate Komoditas Beras

No.	Window	Units	MAPE Testing	MAPE Forecasting
1.	7	32	3.16%	12.24%
2.	7	64	3.32%	14.47%
3.	14	32	2.67%	12.46%
4.	14	64	1.32%	8.44%
5.	30	32	3.03%	13.94%
6.	30	64	2.14%	11.39%

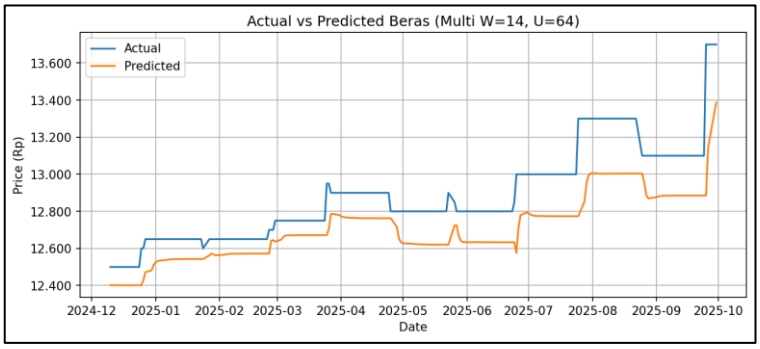
Tabel 4.21 menunjukkan bahwa performa terbaik diperoleh pada skenario window 14 dan units 64 dengan nilai MAPE testing sebesar 1,325% dan MAPE forecasting 8,440%. Hasil ini mengindikasikan bahwa pada konfigurasi tersebut model mampu menangkap hubungan antar-komoditas secara lebih stabil dibandingkan window 7 atau 30 hari. Window 14 memberikan keseimbangan konteks historis yang tidak terlalu pendek, sehingga informasi volatilitas jangka menengah dapat dimanfaatkan tanpa menimbulkan overfitting. Selain itu, unit 64

memungkinkan model mempelajari interaksi multivariat yang lebih kompleks, namun tetap terkontrol sebagaimana terlihat dari nilai error yang lebih rendah. Sebaliknya, skenario window 7 menghasilkan error lebih tinggi karena konteks yang terbatas, sementara window 30 cenderung menyebabkan model kehilangan sensitivitas terhadap perubahan lokal sehingga prediksi menjadi tidak adaptif.



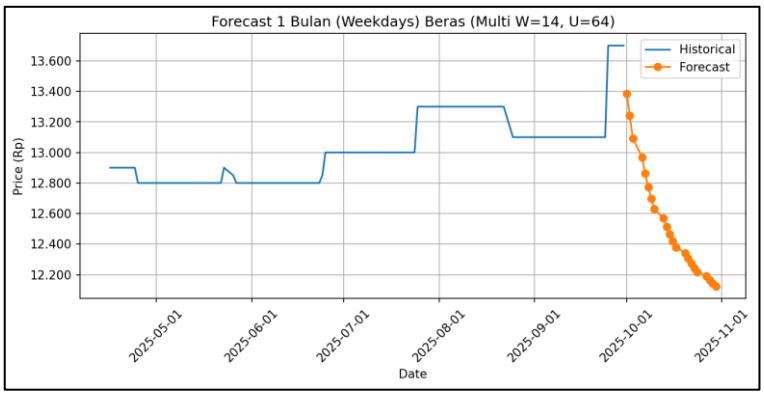
Gambar 4.28 Nilai MAPE Skenario Multivariate Komoditas Beras

Gambar 4.28 memperlihatkan secara visual bahwa skenario W14-U64 memberikan nilai MAPE paling rendah dibandingkan skenario lainnya. Pola tersebut konsisten dengan kecenderungan bahwa model multivariate membutuhkan konteks historis yang lebih panjang untuk dapat memahami hubungan silang antar-komoditas yang tidak bersifat linier. Nilai MAPE yang meningkat pada skenario W30-U32 dan W30-U64 mengindikasikan bahwa konteks terlalu panjang membuat model cenderung menggeneralisasi secara berlebihan (over-smoothing), sehingga pola perubahan harga beras yang sifatnya gradual tidak terrepresentasi secara presisi pada proses prediksi.



Gambar 4.29 Grafik Actual vs Predicted Komoditas Beras Skenario Multivariate Terbaik

Gambar 4.29 menunjukkan perbandingan antara harga aktual dan prediksi pada skenario terbaik (W14, U64). Grafik memperlihatkan bahwa model mampu mengikuti arah pergerakan harga namun cenderung menghasilkan estimasi yang lebih rendah (*underprediction*) pada sebagian besar periode. Fenomena ini mencerminkan bahwa meskipun fitur multivariat memberikan tambahan informasi, pengaruh antar-komoditas terhadap harga beras tidak cukup kuat untuk meningkatkan akurasi secara signifikan. Secara teknis, hal ini menunjukkan bahwa dinamika harga beras lebih didominasi oleh pola internal komoditas itu sendiri, sementara variabel eksternal hanya berperan minor sehingga model lebih sulit mengekstraksi sinyal yang benar-benar relevan.



Gambar 4.30 Grafik Forecast Oktober 2025 Komoditas Beras Skenario Multivariate Terbaik

Gambar 4.30 memperlihatkan hasil forecasting selama Oktober 2025, di mana model menunjukkan tren penurunan harga beras secara bertahap. Secara teknis, hal ini terjadi karena model multivariate lebih sensitif terhadap penurunan pola fluktuasi antar-komoditas yang terjadi pada akhir September, sehingga sinyal penurunan terbawa ke prediksi bulan berikutnya. Namun, pola penurunan yang terlalu tajam dibandingkan data aktual mengindikasikan bahwa model multivariate masih memiliki tendency bias downward, menunjukkan bahwa beban informasi multivariat justru mendorong output ke arah smoothing yang lebih kuat. Hal ini mengonfirmasi bahwa untuk komoditas beras, pendekatan multivariate tidak memberikan keunggulan dibandingkan univariate.

Tabel 4.22 Perbandingan Harga Aktual dan Hasil Forecast Komoditas Beras Oktober 2025 Skenario Multivariate Terbaik

No.	Tanggal	Harga Aktual (Rp)	Harga Prediksi (Rp)
1.	10/1/2025	13700	13386.37
2.	10/2/2025	13700	13240.9
…	…	…	…
11.	10/15/2025	13700	12465.85
12.	10/16/2025	13700	12421.07
…	…	…	…
21.	10/29/2025	13700	12142.69
22.	10/30/2025	13700	12121.89

Tabel 4.22 menyajikan perbandingan antara harga aktual dan hasil prediksi harga komoditas beras selama Oktober 2025 pada skenario multivariate terbaik dengan window size 14 dan 64 unit LSTM. Berdasarkan data yang ditampilkan, nilai prediksi model secara konsisten berada di bawah harga aktual pada seluruh titik waktu yang terlihat dalam tabel. Pada awal periode pengujian, selisih antara harga prediksi dan harga aktual sudah cukup besar, dan pada data yang ditampilkan

untuk pertengahan hingga akhir periode, perbedaan tersebut tampak semakin melebar. Sementara harga aktual terlihat relatif stabil pada tingkat yang sama, nilai prediksi model justru menunjukkan kecenderungan menurun secara bertahap. Kondisi ini mengindikasikan bahwa penggunaan input multivariate belum mampu membantu model dalam mempertahankan level harga beras yang stabil. Secara teknis, hasil ini menunjukkan bahwa penambahan variabel input lain tidak selalu meningkatkan performa prediksi, khususnya pada komoditas dengan pola harga yang relatif datar, karena informasi utama dari variabel target dapat menjadi kurang dominan dalam proses pembelajaran model.

4.2.11 Hasil Uji Coba Skenario Multivariate Komoditas Daging Ayam

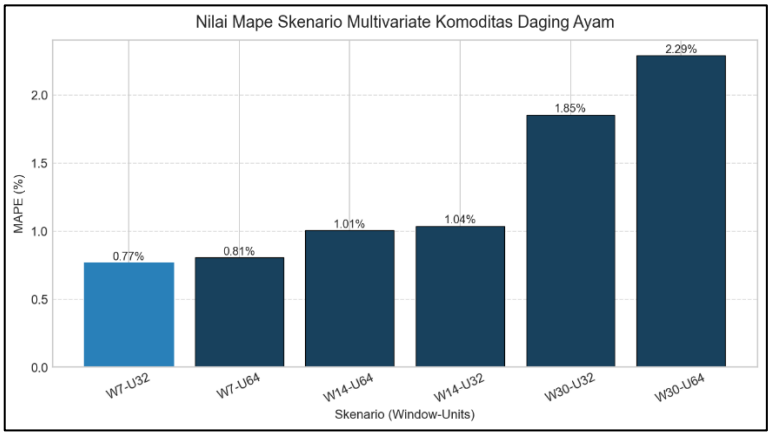
Pengujian skenario multivariate pada komoditas daging ayam dilakukan untuk melihat sejauh mana penambahan variabel harga komoditas lain dapat meningkatkan kemampuan model dalam mengenali pola pergerakan harga. Evaluasi dilakukan menggunakan kombinasi sliding window 7, 14, dan 30 hari serta jumlah unit LSTM sebanyak 32 dan 64.

Tabel 4.23 Hasil Pengujian Skenario Multivariate Komoditas Daging Ayam

No.	Window	Units	MAPE Testing	MAPE Forecasting
1.	7	32	0.76%	1.40%
2.	7	64	0.80%	5.38%
3.	14	32	1.03%	4.47%
4.	14	64	1.00%	1.38%
5.	30	32	1.85%	4.86%
6.	30	64	2.29%	5.47%

Tabel 4.23 menunjukkan hasil pengujian seluruh kombinasi skenario multivariate. Terlihat bahwa konfigurasi window 7 dan 32 unit LSTM

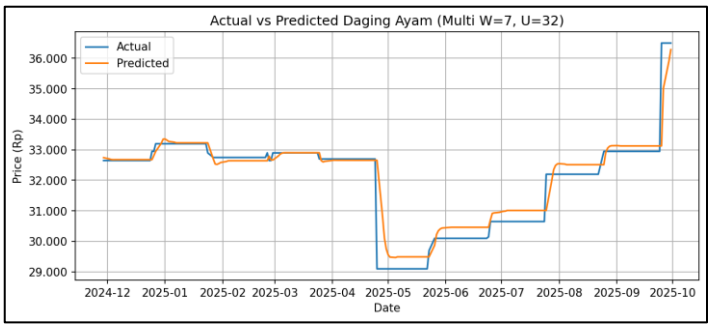
menghasilkan performa terbaik dengan MAPE testing sebesar 0,767% dan MAPE forecasting sebesar 1,406%. Nilai error yang rendah pada skenario ini menunjukkan bahwa penambahan variabel multikomoditas memberikan konteks yang cukup membantu model dalam mempelajari dinamika harga daging ayam, khususnya pada perubahan jangka pendek. Sebaliknya, penggunaan window yang lebih panjang seperti 30 hari menyebabkan nilai MAPE meningkat signifikan, mengindikasikan bahwa model mengalami kesulitan mempertahankan stabilitas error ketika konteks historis yang diberikan terlalu panjang.



Gambar 4.31 Nilai MAPE Skenario Multivariate Komoditas Daging Ayam

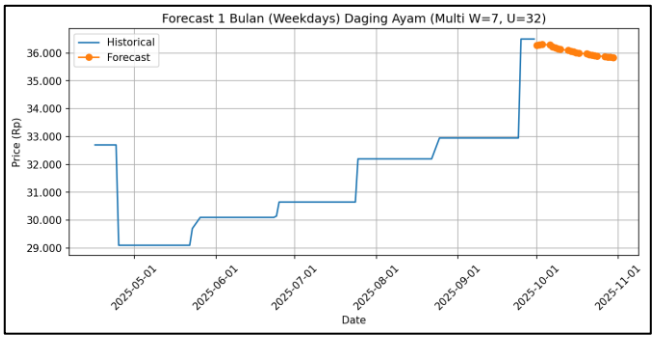
Gambar 4.31 memperlihatkan distribusi nilai MAPE pada setiap kombinasi window–unit. Pola yang terlihat menegaskan bahwa window pendek (7 hari) memberikan kinerja paling stabil pada pendekatan multivariate. Hal ini terjadi karena window pendek lebih sensitif untuk menangkap pola lokal, khususnya ketika harga daging ayam memiliki perubahan gradual dan tidak terlalu fluktuatif. Sebaliknya, window 30 hari menghasilkan error tertinggi, yang menunjukkan bahwa penambahan terlalu banyak informasi historis membuat model sulit

mempertahankan fokus pada perubahan harga terkini sehingga learning menjadi kurang efisien.



Gambar 4.32 Grafik Actual vs Predicted Komoditas Daging Ayam Skenario Multivariate Terbaik

Gambar 4.32 menunjukkan perbandingan antara nilai aktual dan prediksi pada skenario terbaik (W7–U32). Secara umum, model mampu mengikuti pola tren harga dengan cukup baik, termasuk fase penurunan tajam pada awal Mei 2025 dan kenaikan harga pada September hingga Oktober 2025. Namun terdapat beberapa bagian di mana prediksi model sedikit tertinggal (lagging) dari perubahan aktual, terutama saat terjadi transisi harga yang relatif cepat. Fenomena lag ini wajar pada model multivariate, karena model harus menyeimbangkan pengaruh variabel lain yang bisa memiliki ritme perubahan berbeda dari komoditas target.



Gambar 4.33 Grafik Forecast Oktober 2025 Komoditas Daging Ayam Skenario Multivariate Terbaik

Gambar 4.33 menampilkan hasil forecasting untuk satu bulan ke depan pada skenario terbaik. Model menghasilkan pola prediksi yang cenderung menurun secara perlahan dari titik awal Oktober 2025. Pergerakan prediksi yang relatif halus menunjukkan bahwa model lebih mengutamakan pola jangka menengah dibanding merespons fluktuasi kecil. Hal ini konsisten dengan karakter multivariate yang sering kali meredam noise akibat adanya variabel tambahan. Meskipun demikian, pola forecast tetap berada dalam rentang yang masuk akal dan tidak menunjukkan prediksi ekstrem yang tidak realistis.

Tabel 4.24 Perbandingan Harga Aktual dan Forecast Daging Ayam Skenario Multivariate Terbaik

No.	Tanggal	Harga Aktual (Rp)	Harga Prediksi (Rp)
1.	10/1/2025	36500	36284.57
2.	10/2/2025	36500	36302.52
…	…	…	…
11.	10/15/2025	36500	36040.03
12.	10/16/2025	36500	36014.84
…	…	…	…
21.	10/29/2025	34750	35847.2
22.	10/30/2025	34750	35833.77

Tabel 4.24 menyajikan perbandingan antara harga aktual dan hasil prediksi harga komoditas daging ayam selama Oktober 2025 pada skenario multivariate terbaik dengan window size 7 dan 32 unit LSTM. Berdasarkan data yang ditampilkan, nilai prediksi model pada awal periode berada sedikit di bawah harga aktual. Pada data yang ditampilkan untuk pertengahan hingga akhir periode, terlihat bahwa harga aktual mengalami penurunan, sementara nilai prediksi model tetap berada pada tingkat yang lebih tinggi dibandingkan harga aktual pada akhir periode. Perbedaan arah pergerakan ini menunjukkan bahwa model multivariate belum

sepenuhnya mampu menyesuaikan prediksi terhadap perubahan harga yang terjadi dalam periode pengujian. Secara teknis, kondisi tersebut mengindikasikan bahwa penambahan variabel input lain belum secara optimal membantu model dalam menangkap dinamika penurunan harga daging ayam, sehingga prediksi yang dihasilkan cenderung lebih stabil dibandingkan pergerakan harga aktual yang ditampilkan.

4.2.12 Hasil Uji Coba Skenario Multivariate Komoditas Daging Sapi

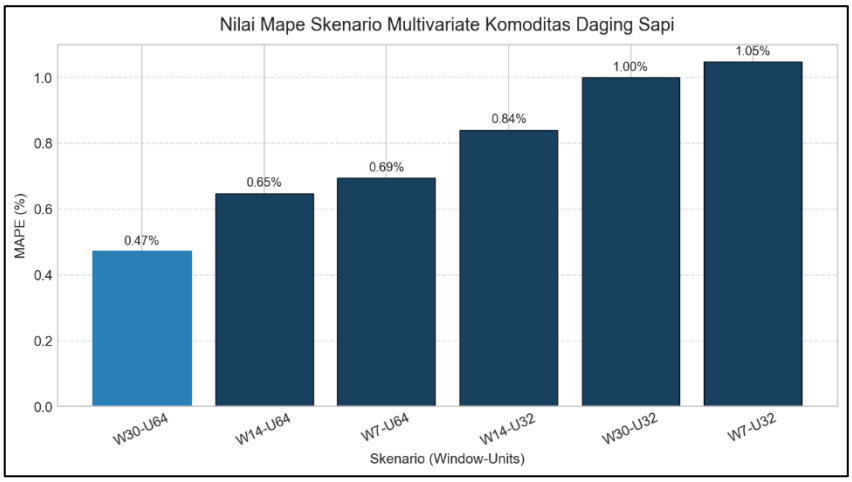
Skenario multivariate untuk komoditas daging sapi dilakukan dengan mengombinasikan variabel harga dari seluruh komoditas lain sebagai fitur tambahan dalam model. Tujuan skenario ini adalah mengevaluasi apakah dinamika antar-komoditas mampu meningkatkan kemampuan model dalam mempelajari pola jangka pendek dan jangka panjang harga daging sapi. Seluruh pengujian menggunakan tiga variasi sliding window (7, 14, dan 30 hari) dan dua konfigurasi jumlah unit LSTM (32 dan 64 unit). Pemilihan skenario terbaik ditentukan berdasarkan nilai MAPE paling rendah pada data testing.

Tabel 4.25 Hasil Pengujian Skenario Multivariate Komoditas Daging Sapi

No.	Window	Units	MAPE Testing	MAPE Forecasting
1.	7	32	1.04%	4.14%
2.	7	64	0.69%	4.13%
3.	14	32	0.84%	3.38%
4.	14	64	0.64%	3.31%
5.	30	32	1.00%	4.51%
6.	30	64	0.47%	3.01%

Tabel 4.25 menampilkan hasil pengujian skenario multivariate komoditas daging sapi, yang menunjukkan bahwa konfigurasi window 30 dengan 64 unit

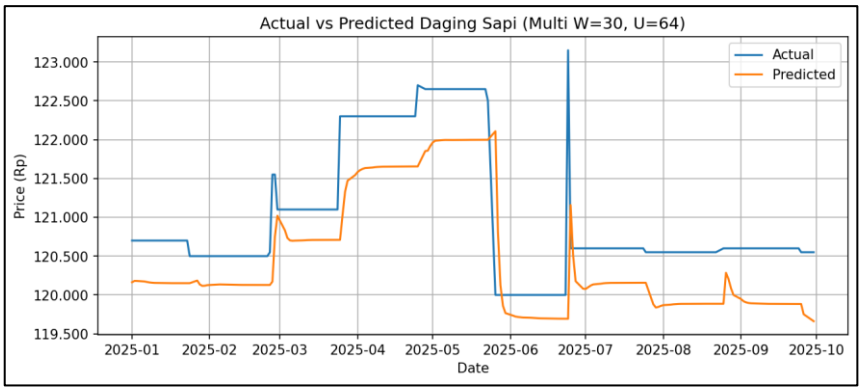
LSTM (W30-U64) menghasilkan kinerja paling baik pada data testing, yaitu MAPE 0.472% dan forecasting MAPE 3.019%. Nilai ini merupakan yang terendah di antara seluruh konfigurasi, menandakan bahwa model lebih stabil ketika diberikan konteks historis lebih panjang (long-range temporal dependency) dan kapasitas model yang lebih besar. Sebaliknya, konfigurasi W30-U32 dan W7-U32 memiliki MAPE testing lebih tinggi (1.001% dan 1.047%), yang menunjukkan bahwa model kurang optimal ketika kapasitas memorinya tidak cukup untuk menangkap interaksi multivariate yang kompleks antar-komoditas. Secara teknis, ini memperlihatkan bahwa jumlah unit LSTM yang lebih besar lebih efektif pada skenario multivariate, karena fitur tambahan membuat struktur data menjadi lebih kompleks dibanding skenario univariate.



Gambar 4.34 Nilai MAPE Skenario Multivariate Komoditas Daging Sapi

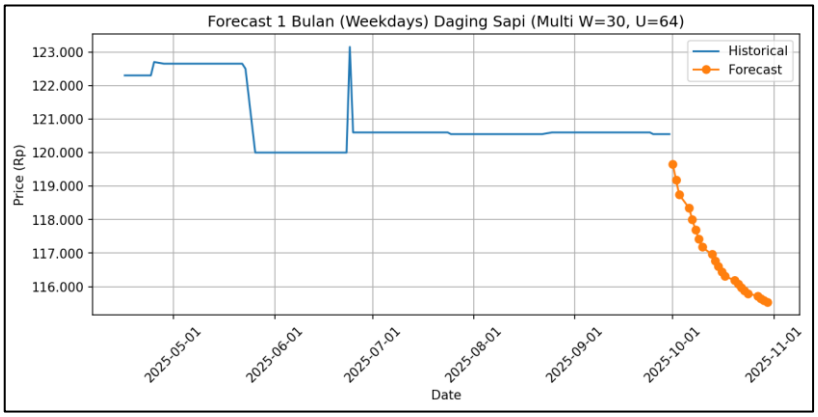
Gambar 4.34 menunjukkan perbandingan nilai MAPE seluruh skenario multivariate komoditas daging sapi. Pola pada grafik mempertegas temuan dari tabel, yaitu bahwa skenario W30-U64 muncul sebagai konfigurasi paling optimal. Selain memiliki MAPE terendah, perbedaan performanya terhadap konfigurasi

lainnya cukup signifikan—misalnya dibandingkan W7-U32 (1.047%) atau W14-U32 (0.841%).Secara teknis, grafik ini menunjukkan bahwa semakin panjang jendela waktu, semakin baik model mempelajari pola musiman dan perubahan harga yang tidak langsung, khususnya pada komoditas yang cenderung stabil seperti daging sapi. Namun, keunggulan ini hanya muncul ketika unit LSTM cukup besar; jika tidak, model justru mengalami underfitting.



Gambar 4.35 Grafik Actual vs Predicted Komoditas Daging Sapi Skenario Multivariate Terbaik

Gambar 4.35 menggambarkan hasil prediksi model skenario terbaik (W30-U64) dibanding nilai aktual. Secara visual, prediksi mengikuti tren umum harga daging sapi, namun terdapat beberapa deviasi pada titik perubahan harga yang bersifat tajam atau mendadak, misalnya pada lonjakan di awal Juli 2025 dan penurunan signifikan pada awal Mei 2025. Keterlambatan respon model terhadap perubahan ekstrem ini merupakan karakteristik umum LSTM, terutama pada skenario multivariate di mana model harus memproses banyak variabel sekaligus. Meskipun demikian, overall trend berhasil direplikasi dengan baik, yang terlihat dari bentuk kurva prediksi yang konsisten mengikuti arah pergerakan harga aktual.



Gambar 4.36 Grafik Forecast Oktober 2025 Komoditas Daging Sapi Skenario Multivariate Terbaik

Gambar 4.36 menampilkan hasil peramalan harga daging sapi selama satu bulan ke depan. Model memproyeksikan bahwa harga daging sapi akan mengalami tren penurunan bertahap dari kisaran 120.550 menjadi sekitar 115.500 rupiah pada akhir Oktober 2025. Pola ini menunjukkan bahwa model mendeteksi adanya fase stabilitas harga setelah periode volatil sebelumnya, kemudian memproyeksikan koreksi harga jangka pendek. Secara teknis, bentuk kurva forecast menggambarkan bahwa model lebih sensitif terhadap tren jangka panjang daripada fluktuasi harian. Hal ini konsisten dengan sifat skenario W30-U64 yang memanfaatkan jendela historis panjang, sehingga prediksi cenderung lebih smooth.

Tabel 4.26 Perbandingan Harga Aktual dan Forecast Daging Sapi Skenario Multivariate Terbaik

No.	Tanggal	Harga Aktual (Rp)	Harga Prediksi (Rp)
1.	10/1/2025	120550	119661.98
2.	10/2/2025	120550	119190.25
…	…	…	…
11.	10/15/2025	120550	116605.31
12.	10/16/2025	120550	116452.02
…	…	…	…
21.	10/29/2025	120450	115591.64

No.	Tanggal	Harga Aktual (Rp)	Harga Prediksi (Rp)
22.	10/30/2025	120450	115534.35

Tabel 4.26 menyajikan perbandingan antara harga aktual dan hasil prediksi harga komoditas daging sapi selama Oktober 2025 pada skenario multivariate terbaik dengan window size 30 dan 64 unit LSTM. Berdasarkan data yang ditampilkan, nilai prediksi model pada seluruh titik waktu yang terlihat dalam tabel berada di bawah harga aktual. Pada awal periode pengujian, selisih antara harga prediksi dan harga aktual sudah terlihat cukup jelas, dan pada data yang ditampilkan untuk pertengahan hingga akhir periode, perbedaan tersebut tetap konsisten. Sementara harga aktual relatif stabil dengan perubahan yang sangat kecil, nilai prediksi model menunjukkan kecenderungan menurun secara bertahap. Kondisi ini mengindikasikan bahwa model multivariate menghasilkan estimasi harga yang lebih rendah dibandingkan kondisi aktual. Secara teknis, hasil ini menunjukkan bahwa penggunaan input multivariate belum mampu membantu model dalam mempertahankan level harga daging sapi yang relatif stabil, sehingga prediksi cenderung mengikuti arah penyesuaian ke bawah. Meskipun demikian, pola prediksi yang konsisten dan tidak menunjukkan fluktuasi ekstrem tetap mencerminkan bahwa model mampu menghasilkan estimasi harga yang stabil pada komoditas dengan karakteristik harga yang relatif konstan.

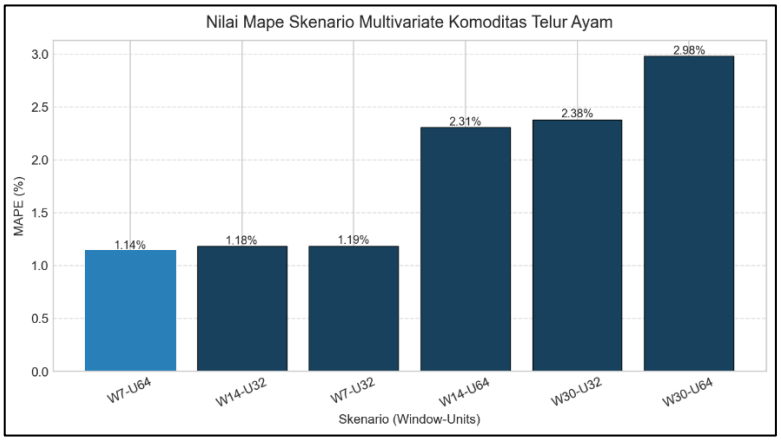
4.2.13 Hasil Uji Coba Skenario Multivariate Komoditas Telur Ayam

Skenario multivariate untuk komoditas telur ayam dilakukan dengan mengombinasikan tiga konfigurasi sliding window (7, 14, dan 30 hari) serta dua jumlah unit LSTM (32 dan 64). Pendekatan multivariate memungkinkan model memanfaatkan pola pergerakan antar-komoditas lain yang berpotensi berkorelasi terhadap dinamika harga telur ayam.

Tabel 4.27 Hasil Pengujian Skenario Multivariate Komoditas Telur Ayam

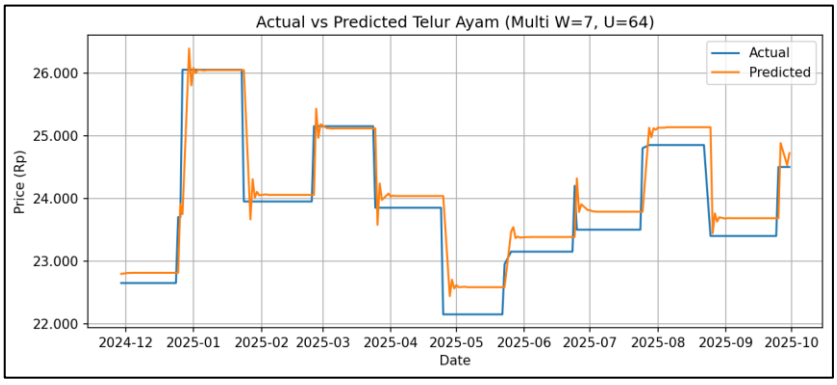
No.	Window	Units	MAPE Testing	MAPE Forecasting
1.	7	32	1.18%	8.00%
2.	7	64	1.14%	5.74%
3.	14	32	1.18%	1.77%
4.	14	64	2.30%	14.02%
5.	30	32	2.38%	12.34%
6.	30	64	2.98%	23.12%

Tabel 4.27 menyajikan hasil pengujian seluruh kombinasi skenario multivariate. Dari tabel terlihat bahwa konfigurasi window 7 dan unit 64 memberikan MAPE testing terendah yaitu 1,142%, sedangkan forecasting terbaik justru dicapai oleh kombinasi window 14 dan unit 32 dengan MAPE 1,778%. Pola ini menunjukkan bahwa meskipun model dengan unit lebih besar mampu menurunkan error pada data uji, performa pada data forecasting tidak selalu meningkat. Hal ini mengindikasikan bahwa untuk komoditas dengan fluktuasi tajam seperti telur ayam, model cenderung sensitif terhadap kapasitas memorinya: window lebih pendek menangkap dinamika lokal dengan baik pada testing, sedangkan window menengah (14 hari) menghasilkan prediksi ke depan yang lebih stabil karena tidak terlalu responsif terhadap noise perubahan harga jangka pendek.



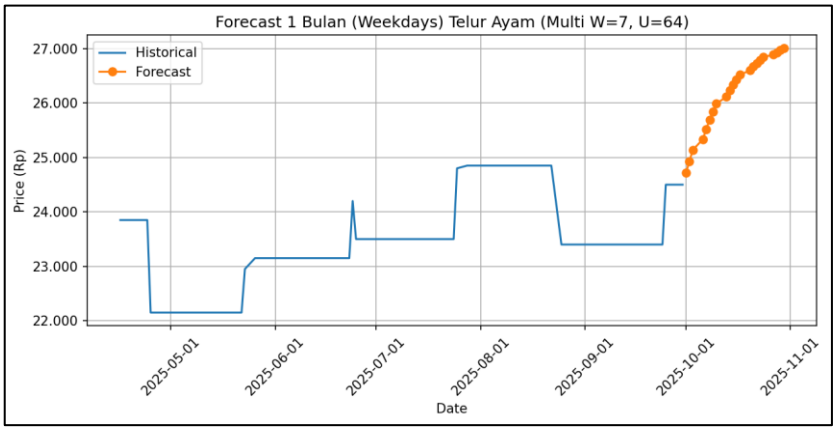
Gambar 4.37 Nilai MAPE Skenario Multivariate Komoditas Telur Ayam

Gambar 4.37 menampilkan visualisasi nilai MAPE untuk seluruh skenario. Terlihat jelas bahwa konfigurasi W7-U64 dan W14-U32 merupakan dua kandidat terbaik untuk testing dan forecasting. Skema lain seperti W30-U64 dan W30-U32 menunjukkan peningkatan error yang signifikan, mencerminkan bahwa window terlalu panjang tidak sesuai untuk komoditas dengan pola volatil yang berubah dalam rentang waktu pendek. Hal ini menunjukkan bahwa ketepatan model sangat dipengaruhi oleh sejauh mana panjang memori (lookback) sesuai dengan karakteristik musiman dan frekuensi perubahan harga telur ayam.



Gambar 4.38 Grafik Actual vs Predicted Komoditas Telur Ayam Skenario Multivariate Terbaik

Gambar 4.38 merupakan grafik Actual vs Predicted untuk skenario terbaik, yaitu W7–U64 berdasarkan akurasi testing. Grafik menunjukkan bahwa model mampu mengikuti arah tren harga secara konsisten, termasuk pola kenaikan tajam pada awal tahun dan penurunan signifikan pada pertengahan tahun. Namun, terdapat perbedaan amplitudo pada beberapa segmen, terutama ketika harga mengalami transisi cepat. Hal ini disebabkan oleh sifat harga telur ayam yang berubah dalam level diskrit (stepwise), sehingga model LSTM yang bekerja secara kontinu cenderung menghaluskan perubahan tersebut. Meskipun demikian, bentuk kurva dipertahankan dengan baik, menunjukkan bahwa dependensi temporal telah berhasil dipelajari model.



Gambar 4.39 Grafik Forecast Oktober 2025 Komoditas Telur Ayam Skenario Multivariate Terbaik

Gambar 4.39 memperlihatkan hasil forecasting satu bulan ke depan (Oktober 2025) menggunakan skenario terbaik berdasarkan performa forecasting, yaitu W14–U32. Model memproyeksikan adanya tren kenaikan harga yang stabil sepanjang periode tersebut. Kenaikan yang mulus ini merupakan konsekuensi dari kemampuan model dalam menangkap kecenderungan historis tanpa terpengaruh fluktuasi minor. Secara teknis, window 14 hari menyediakan konteks yang cukup

untuk mengenali pola musiman, sementara unit 32 mencegah model melakukan overfitting terhadap pola jangka pendek yang tidak konsisten.

Tabel 4.28 Perbandingan Harga Aktual dan Forecast Telur Ayam Skenario Multivariate Terbaik

No.	Tanggal	Harga Aktual (Rp)	Harga Prediksi (Rp)
1.	10/1/2025	24500	24720.64
2.	10/2/2025	24500	24925.74
…	…	…	…
11.	10/15/2025	24500	26336.99
12.	10/16/2025	24500	26432.87
…	…	…	…
21.	10/29/2025	25750	26970.5
22.	10/30/2025	25750	27004.71

Tabel 4.28 memuat perbandingan harga aktual dan hasil prediksi harga telur ayam selama Oktober 2025 dengan scenario multivariat model window 7 dan 64 unit LSTM. Berdasarkan prediksi harga pada Tabel 4.22 Model terlihat menghasilkan prediksi yang meningkat secara gradual, dimulai dari sekitar 24.720–25.520 pada minggu pertama dan meningkat hingga sekitar 27.004–27.070 pada akhir bulan. Perbedaan antara harga aktual dan prediksi menunjukkan bahwa model cenderung memperkirakan kenaikan harga yang lebih agresif dibandingkan realisasi pasar. Hal ini merupakan konsekuensi dari pola historis di bulan sebelumnya yang menunjukkan tren naik. Secara teknikal, bias naik ini umum terjadi pada komoditas musiman ketika model menangkap pola tren sebelumnya dan mengekstrapolasikannya secara linier. Walaupun demikian, struktur prediksi yang konsisten dan tidak menghasilkan pola ekstrem menunjukkan bahwa model multivariate cukup stabil dan tidak mengalami divergensi prediksi.

4.2.14 Hasil Uji Coba Skenario Multivariate Komoditas Bawang Merah

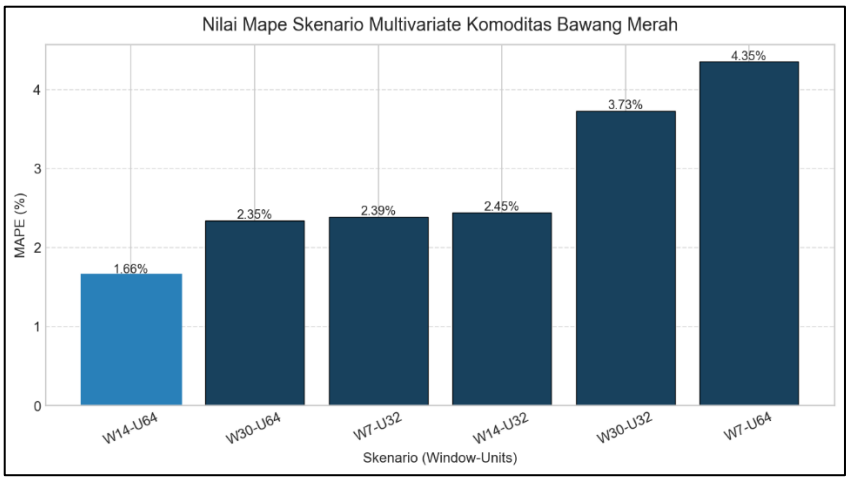
Pengujian skenario multivariate untuk komoditas bawang merah dilakukan untuk melihat sejauh mana model LSTM mampu mempelajari keterkaitan harga bawang merah dengan dinamika delapan komoditas pangan lainnya Variasi skenario diuji melalui kombinasi panjang window (7, 14, dan 30 hari) serta jumlah unit LSTM (32 dan 64).

Tabel 4.29 Hasil Pengujian Skenario Multivariate Komoditas Bawang Merah

No.	Window	Units	MAPE Testing	MAPE Forecasting
1.	7	32	2.39%	26.83%
2.	7	64	4.35%	39.88%
3.	14	32	2.44%	24.01%
4.	14	64	1.65%	15.20%
5.	30	32	3.73%	9.68%
6.	30	64	2.34%	17.73%

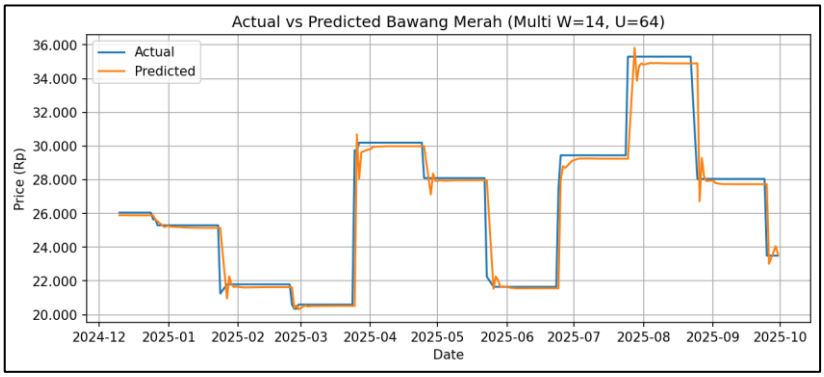
Tabel 4.29 menunjukkan hasil pengujian pada enam konfigurasi yang diuji. Nilai MAPE testing terendah diperoleh pada konfigurasi W14-U64 dengan MAPE sebesar 1,656%, yang menunjukkan bahwa window 14 hari memberikan konteks historis yang cukup untuk menangkap dinamika harga jangka pendek bawang merah. Model dengan window terlalu pendek (7 hari) cenderung kehilangan informasi pergerakan harga sebelum periode fluktuasi besar, menghasilkan MAPE testing yang lebih tinggi, misalnya 2,393% pada W7-U32 dan 4,352% pada W7-U64. Sebaliknya, pada window panjang (30 hari), kinerja model tidak konsisten; meskipun W30-U32 menghasilkan MAPE forecasting lebih rendah (9,687%), nilai MAPE testing masih relatif tinggi (3,734%) sehingga kurang stabil. Performa terbaik secara keseluruhan ditentukan berdasarkan kombinasi akurasi testing dan

forecasting, sehingga W14-U64 dipilih sebagai konfigurasi optimum untuk skenario multivariate.



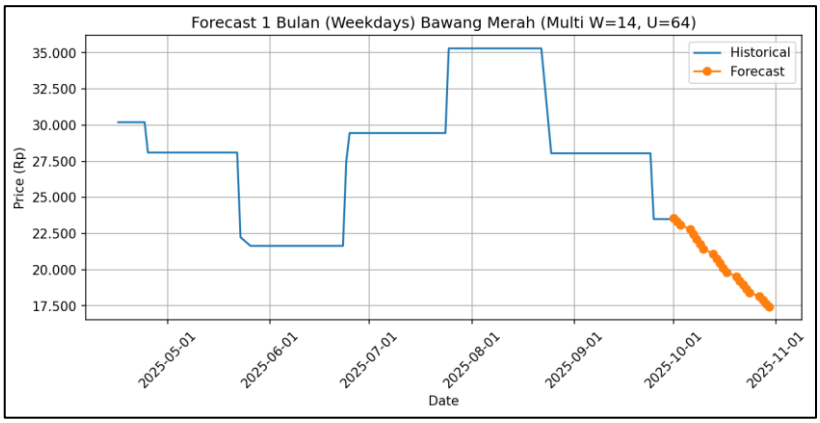
Gambar 4.40 Nilai MAPE Skenario Multivariate Komoditas Bawang Merah

Gambar 4.40 mengilustrasikan perbandingan MAPE pada seluruh skenario multivariate. Grafik menunjukkan bahwa model dengan window 14 hari dan 64 unit memberikan performa paling konsisten, dengan gap antara skenario lain cukup signifikan. Terlihat bahwa jumlah unit tidak selalu berbanding lurus dengan akurasi; misalnya, W7-U64 justru menghasilkan MAPE tertinggi. Hal ini menunjukkan bahwa peningkatan kompleksitas model tanpa didukung konteks historis yang memadai dapat menyebabkan overfitting terhadap noise, terutama pada komoditas dengan fluktuasi tajam seperti bawang merah.



Gambar 4.41 Grafik Actual vs Predicted Komoditas Bawang Merah Skenario Multivariate Terbaik

Gambar 4.41 menunjukkan hasil prediksi model pada konfigurasi terbaik (W14-U64). Secara teknis, model dapat mengikuti pola naik–turun harga bawang merah dengan cukup baik, termasuk lonjakan signifikan pada periode April–Agustus 2025. Namun, terlihat bahwa model masih mengalami smoothing pada titik-titik perubahan harga yang ekstrem. Hal ini merupakan karakter umum LSTM, yang cenderung menstabilkan prediksi ketika menghadapi pola volatil. Meski demikian, bentuk kurva prediksi tetap berada pada jalur tren aktual, yang menandakan bahwa model berhasil mempelajari struktur deret waktu meskipun intensitas fluktuasinya sulit ditangkap secara presisi.



Gambar 4.42 Grafik Forecast Oktober 2025 Komoditas Bawang Merah Skenario Multivariate Terbaik

Gambar 4.42 menggambarkan hasil forecasting untuk bulan Oktober 2025. Model menghasilkan proyeksi penurunan harga secara bertahap sepanjang bulan. Pola menurun ini sejalan dengan kecenderungan akhir data historis sebelum proses forecasting, menunjukkan bahwa model memanfaatkan tren jangka pendek sebagai basis proyeksi. Namun, penurunan yang cukup tajam pada nilai forecast mengindikasikan bahwa model lebih responsif terhadap perubahan sebelum Oktober, yang dapat menjadi konsekuensi smoothing dan sensitivitas LSTM terhadap pola dominan dalam window historis.

Tabel 4.30 Perbandingan Harga Aktual dan Forecast Bawang Merah Skenario Multivariate Terbaik

No.	Tanggal	Harga Aktual (Rp)	Harga Prediksi (Rp)
1.	10/1/2025	23500	23568.07
2.	10/2/2025	23500	23371.14
…	…	…	…
11.	10/15/2025	23500	20450.02
12.	10/16/2025	23500	20133.55
…	…	…	…
21.	10/29/2025	26650	17659.92
22.	10/30/2025	26650	17423.09

Tabel 4.30 menyajikan perbandingan antara harga aktual dan hasil prediksi harga komoditas bawang merah selama Oktober 2025 pada skenario multivariate terbaik dengan window size 14 dan 64 unit LSTM. Berdasarkan data yang ditampilkan, nilai prediksi model menunjukkan variasi yang cukup besar dibandingkan harga aktual. Pada awal periode pengujian, nilai prediksi masih berada relatif dekat dengan harga aktual. Namun, pada data yang ditampilkan untuk pertengahan hingga akhir periode, selisih antara harga prediksi dan harga aktual terlihat semakin melebar, dengan nilai prediksi berada jauh di bawah harga aktual. Sementara harga aktual pada akhir periode berada pada tingkat yang lebih tinggi

dibandingkan awal bulan, nilai prediksi model justru menunjukkan kecenderungan menurun secara signifikan. Kondisi ini mengindikasikan bahwa model multivariate belum mampu mengikuti perubahan harga bawang merah yang meningkat secara tajam dalam periode pengujian. Secara teknis, hasil tersebut mencerminkan keterbatasan model dalam menangkap dinamika harga yang sangat fluktuatif, terutama ketika perubahan harga tidak tercermin secara kuat pada pola historis yang digunakan sebagai input model.

4.2.15 Hasil Uji Coba Skenario Multivariate Komoditas Cabai Merah

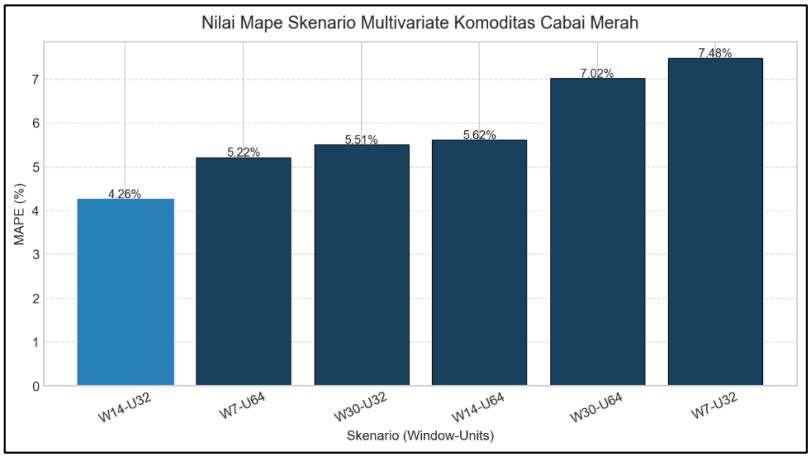
Pengujian model multivariate untuk komoditas cabai merah dilakukan dengan memvariasikan panjang window (7, 14, dan 30 hari) serta jumlah unit LSTM (32 dan 64 unit). Seluruh konfigurasi diuji untuk menilai kemampuan model dalam mempelajari dinamika harga cabai merah yang memiliki karakteristik sangat volatile.

Tabel 4.31 Hasil Pengujian Skenario Multivariate Komoditas Cabai Merah

No.	Window	Units	MAPE Testing	MAPE Forecasting
1.	7	32	7.48%	14.09%
2.	7	64	5.21%	0.61%
3.	14	32	4.26%	14.61%
4.	14	64	5.61%	6.50%
5.	30	32	5.51%	13.83%
6.	30	64	7.02%	3.19%

Tabel 4.31 menampilkan hasil pengujian seluruh skenario multivariate cabai merah. Secara teknis, performa terbaik dicapai oleh konfigurasi window 14 dan 32 unit LSTM dengan MAPE testing sebesar 4,264%, yang merupakan nilai terendah dibandingkan skenario lain. Hasil ini menunjukkan bahwa konteks historis selama

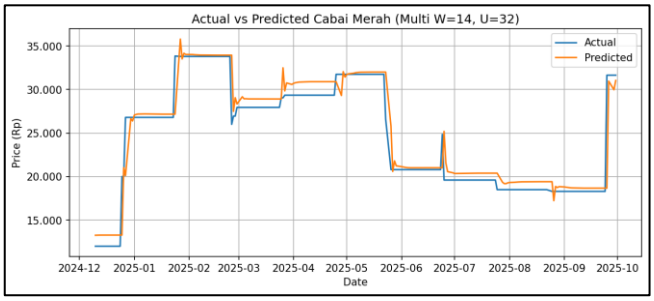
14 hari memberikan informasi temporal yang lebih stabil untuk komoditas volatil ini dibandingkan window 7 hari (yang terlalu pendek) atau window 30 hari (yang cenderung mengandung noise fluktuasi jangka panjang). Selain itu, unit 32 menghasilkan generalisasi lebih baik dibandingkan 64 unit, yang pada komoditas sangat fluktuatif seperti cabai merah cenderung mendorong overfitting. Sementara itu, MAPE forecasting menunjukkan variasi yang jauh lebih besar (0,613–14,619%), menandakan bahwa perbedaan struktur volatilitas pada data Oktober 2025 memberikan tantangan lebih besar bagi model.



Gambar 4.43 Nilai MAPE Skenario Multivariate Komoditas Cabai Merah

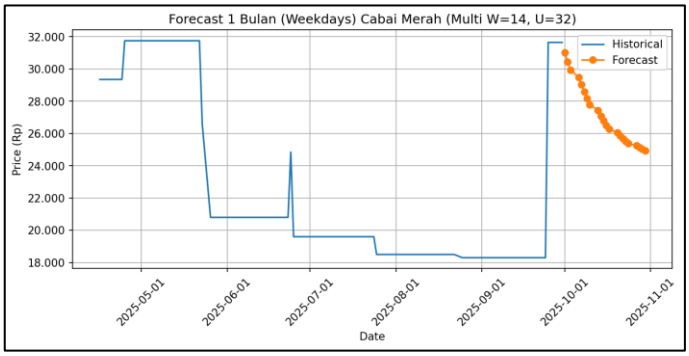
Gambar 4.43 memperlihatkan perbandingan nilai MAPE antar skenario multivariate. Dari grafik tersebut terlihat jelas bahwa skenario W14–U32 berada pada posisi terendah, sedangkan skenario W7–U32 dan W30–U64 memberikan error tertinggi. Secara teknikal, pola ini menunjukkan bahwa model membutuhkan konteks temporal menengah untuk menstabilkan pembelajaran, sedangkan window pendek gagal menangkap transisi harga, dan window panjang menyulitkan model memfilter lonjakan-lonjakan harga musiman. Kinerja yang menurun pada unit 64

juga menunjukkan bahwa kapasitas model yang terlalu besar tidak selalu relevan bagi komoditas yang sangat fluktuatif karena meningkatkan sensitivitas terhadap noise.



Gambar 4.44 Grafik Actual vs Predicted Komoditas Cabai Merah Skenario Multivariate Terbaik

Gambar 4.44 menampilkan grafik actual vs predicted menggunakan skenario terbaik (W14, U=32). Secara umum, model berhasil mengikuti arah perubahan harga, terutama pada periode Maret–Mei dan Agustus–September yang memiliki pola naik turun tajam. Namun demikian, terlihat adanya bias underestimation ketika terjadi lonjakan harga mendadak, yang merupakan konsekuensi dari sifat deret waktu cabai merah yang sangat abrupt. Secara teknis, LSTM memprediksi secara smooth karena proses backpropagation melalui time-steps menghaluskan sinyal ekstrem sehingga prediksi mendekati rata-rata lokal. Meski demikian, model tetap mampu mempertahankan akurasi yang baik sesuai nilai MAPE.



Gambar 4.45 Grafik Forecast Oktober 2025 Komoditas Cabai Merah Skenario Multivariate Terbaik

Gambar 4.45 menunjukkan hasil forecasting harga cabai merah selama Oktober 2025 dengan menggunakan skenario terbaik. Hasil prediksi memperlihatkan tren penurunan bertahap dari kisaran Rp31.000-an menuju kisaran Rp24.000-an pada akhir bulan. Secara teknis, pola ini merupakan respons model terhadap trend historis sebelum Oktober yang didominasi penurunan setelah puncak harga September. LSTM memproyeksikan kelanjutan pola tersebut karena fitur multivariate turut menangkap variabel komoditas lain yang ikut menurun pada periode yang sama. Meskipun demikian, forecasting tetap lebih halus dibandingkan harga aktual, menegaskan kembali kecenderungan smoothing yang menjadi karakter bawaan model LSTM.

Tabel 4.32 Perbandingan Harga Aktual dan Forecast Cabai Merah Skenario Multivariate Terbaik

No.	Tanggal	Harga Aktual (Rp)	Harga Prediksi (Rp)
1.	10/1/2025	31650	31036.82
2.	10/2/2025	31650	30434.92
…	…	…	…
11.	10/15/2025	31650	26794.7
12.	10/16/2025	31650	26519.61
…	…	…	…
21.	10/29/2025	31900	25030.69
22.	10/30/2025	31900	24937.232

Tabel 4.32 menyajikan perbandingan antara harga aktual dan hasil prediksi harga komoditas cabai merah selama Oktober 2025 pada skenario multivariate terbaik dengan window size 14 dan 32 unit LSTM. Berdasarkan data yang ditampilkan, nilai prediksi model secara konsisten berada di bawah harga aktual pada seluruh titik waktu yang terlihat dalam tabel. Pada awal periode pengujian, selisih antara harga prediksi dan harga aktual sudah terlihat, dan pada data yang ditampilkan untuk pertengahan hingga akhir periode, perbedaan tersebut tampak semakin besar. Sementara harga aktual relatif stabil pada level yang lebih tinggi, nilai prediksi model menunjukkan kecenderungan menurun secara bertahap. Kondisi ini mengindikasikan bahwa model multivariate belum mampu menyesuaikan prediksi terhadap perubahan level harga cabai merah yang meningkat. Secara teknis, hasil ini mencerminkan keterbatasan model dalam menangkap dinamika harga yang sangat fluktuatif, sehingga prediksi yang dihasilkan cenderung lebih rendah dibandingkan nilai aktual.

4.2.16 Hasil Uji Coba Skenario Multivariate Komoditas Cabai Rawit

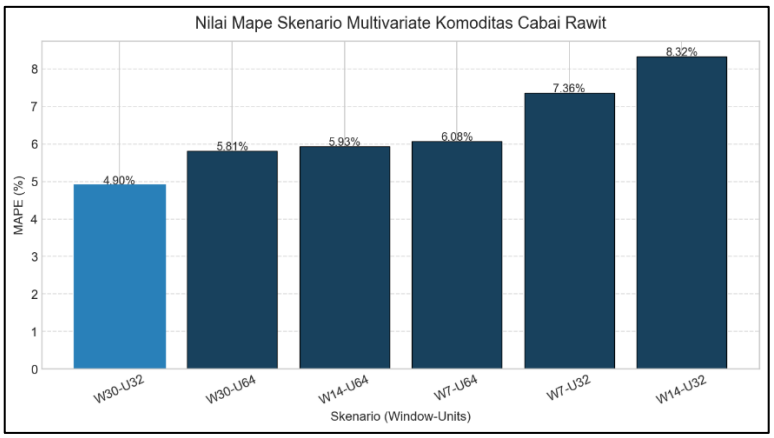
Pengujian pada komoditas cabai rawit dengan skenario multivariate dilakukan untuk menilai kemampuan model dalam mempelajari pola harga harian ketika informasi seluruh komoditas lain turut digunakan sebagai fitur tambahan. Variasi pengujian mencakup kombinasi sliding window 7, 14, dan 30 hari serta jumlah unit LSTM 32 dan 64.

Tabel 4.33 Hasil Pengujian Skenario Multivariate Komoditas Cabai Rawit

No.	Window	Units	MAPE Testing	MAPE Forecasting
1.	7	32	7.35%	103.10%
2.	7	64	6.07%	75.07%

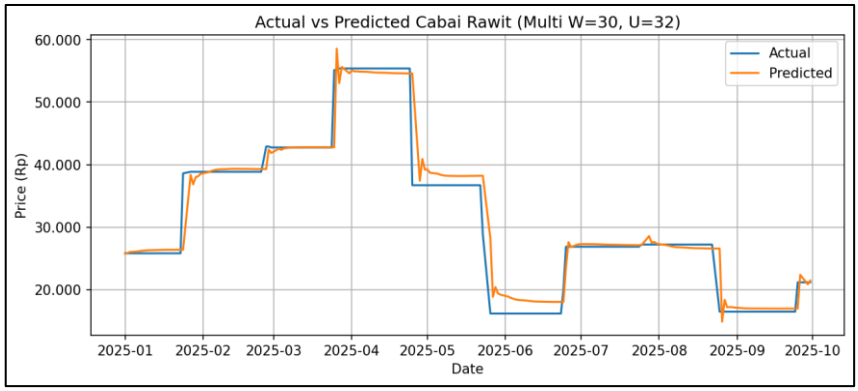
No.	Window	Units	MAPE Testing	MAPE Forecasting
3.	14	32	8.32%	101.19%
4.	14	64	5.93%	53.35%
5.	30	32	4.90%	25.38%
6.	30	64	5.81%	36.78%

Tabel 4.33 Hasil Pengujian Skenario Multivariate Komoditas Cabai Rawit menunjukkan bahwa nilai MAPE testing terendah dicapai oleh konfigurasi W30-U32 dengan MAPE sebesar 4.904%, sehingga konfigurasi ini dipilih sebagai skenario terbaik. Dari sisi forecasting, variasi window 30 hari juga memberikan nilai kesalahan yang lebih rendah dibandingkan window lebih pendek, yakni 25.384% pada W30-U32. Secara teknis, hal ini mengindikasikan bahwa model membutuhkan rentang historis lebih panjang untuk memahami pola volatil cabai rawit ketika fitur multivariate digunakan. Window pendek (7 dan 14 hari) cenderung tidak mampu menangkap dinamika fluktuasi besar, sehingga menghasilkan MAPE forecasting yang sangat tinggi, khususnya pada konfigurasi W7-U32 dan W14-U32 yang mencapai lebih dari 100%.



Gambar 4.46 Nilai MAPE Skenario Multivariate Komoditas Cabai Rawit

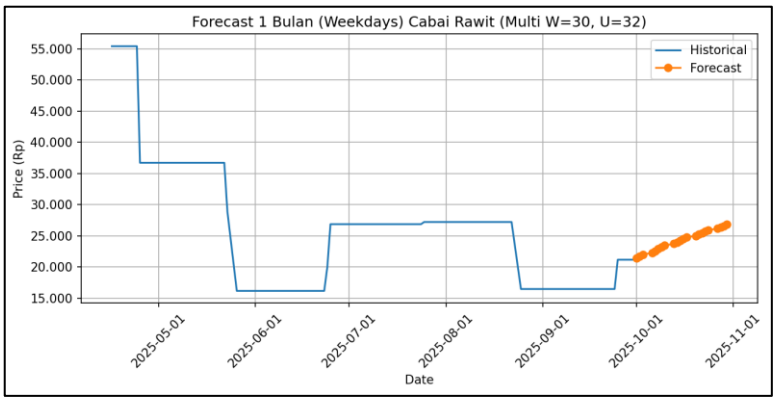
Gambar 4.46 Nilai MAPE Skenario Multivariate Komoditas Cabai Rawit memperlihatkan jarak performa yang cukup kontras antar skenario. Grafik menunjukkan bahwa model dengan window 30 hari menghasilkan kesalahan paling rendah, sedangkan window 7 dan 14 hari mengalami degradasi performa signifikan. Pola ini menegaskan pentingnya kedalaman informasi historis bagi model, terutama ketika cabai rawit mengalami perubahan harga yang ekstrem pada rentang waktu pendek. Unit LSTM 32 juga terlihat lebih stabil dibandingkan 64 unit, yang mengindikasikan bahwa model lebih mudah mengalami overfitting ketika kapasitas memorinya terlalu besar untuk dataset dengan tingkat volatilitas tinggi.



Gambar 4.47 Grafik Actual vs Predicted Komoditas Cabai Rawit Skenario Multivariate Terbaik

Gambar 4.47 Grafik Actual vs Predicted Komoditas Cabai Rawit Skenario Multivariate Terbaik menampilkan hasil prediksi menggunakan konfigurasi terbaik W30-U32. Secara umum, model mampu mengikuti pola besar perubahan harga, termasuk kenaikan drastis menjelang Maret–April dan penurunan tajam pada Mei–Juni. Namun, terdapat beberapa deviasi prediksi di titik-titik ekstrem akibat sensitivitas harga cabai rawit yang sangat tinggi. Secara teknis, deviasi ini berasal dari pergeseran tren harga yang tidak sepenuhnya tercermin pada data komoditas

lain sebagai fitur pendukung, sehingga model multivariate tidak selalu memperbaiki performa seperti yang diharapkan.



Gambar 4.48 Grafik Forecast Oktober 2025 Komoditas Cabai Rawit Skenario Multivariate Terbaik

Gambar 4.48 Grafik Forecast Oktober 2025 Komoditas Cabai Rawit Skenario Multivariate Terbaik menunjukkan bahwa model memprediksi tren kenaikan harga sepanjang periode Oktober 2025. Pola prediksi bergerak naik secara konsisten dari harga sekitar 22.000 menjadi lebih dari 27.000. Secara teknis, model mengasumsikan bahwa tren penurunan harga pada bulan sebelumnya mulai berbalik menuju pemulihan. Namun demikian, akurasi prediksi ini tetap dipengaruhi oleh tingginya volatilitas cabai rawit sehingga hasil forecasting cenderung lebih "lancar" (smooth) dibandingkan pola aktual yang fluktuatif. Hal ini merupakan karakter umum pada model multivariate ketika menghadapi komoditas dengan perubahan harga ekstrem.

Tabel 4.34 Perbandingan Harga Aktual dan Forecast Cabai Rawit Skenario Multivariate Terbaik

No.	Tanggal	Harga Aktual (Rp)	Harga Prediksi (Rp)
1.	10/1/2025	21150	22233.62
2.	10/2/2025	21150	23242.30
…	…	…	…
11.	10/15/2025	21150	29079.70
12.	10/16/2025	21150	24489.23

No.	Tanggal	Harga Aktual (Rp)	Harga Prediksi (Rp)
…	…	…	…
21.	10/29/2025	14850	32437.37
22.	10/30/2025	14850	32670.98

Tabel 4.34 menyajikan perbandingan antara harga aktual dan hasil prediksi harga komoditas cabai rawit selama Oktober 2025 pada skenario multivariate terbaik dengan window size 30 dan 32 unit LSTM. Berdasarkan data yang ditampilkan, nilai prediksi model pada seluruh titik waktu yang terlihat dalam tabel berada di atas harga aktual. Pada awal periode pengujian, selisih antara harga prediksi dan harga aktual sudah cukup besar, dan pada data yang ditampilkan untuk pertengahan hingga akhir periode, perbedaan tersebut semakin meningkat. Sementara harga aktual menunjukkan penurunan pada akhir periode, nilai prediksi model justru terus meningkat. Perbedaan arah pergerakan ini menunjukkan bahwa model multivariate menghasilkan estimasi harga yang jauh lebih tinggi dibandingkan kondisi aktual. Secara teknis, hasil ini mengindikasikan bahwa penggunaan input multivariate belum mampu membantu model dalam menyesuaikan prediksi terhadap dinamika harga cabai rawit yang sangat fluktuatif, sehingga prediksi cenderung menyimpang jauh dari nilai aktual pada periode pengujian.

4.2.17 Hasil Uji Coba Skenario Multivariate Komoditas Minyak Goreng

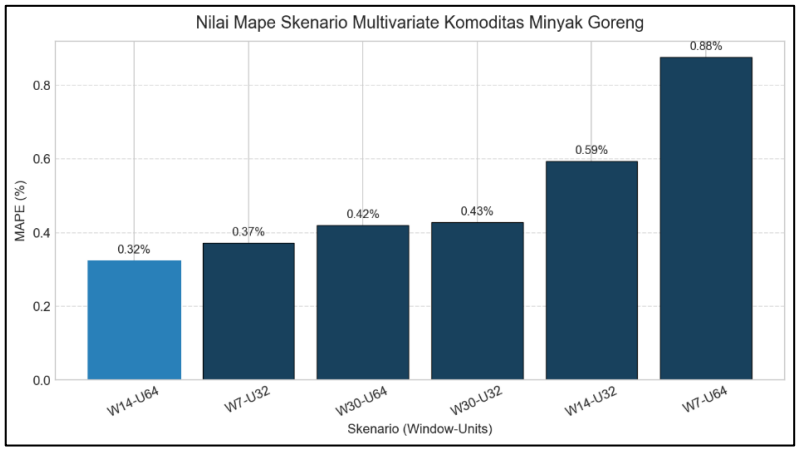
Pengujian pada komoditas minyak goreng dengan pendekatan multivariate dilakukan menggunakan kombinasi sliding window 7, 14, dan 30 hari dengan jumlah unit LSTM 32 dan 64. Tujuan pengujian ini adalah menilai apakah

penambahan variabel fitur dari komoditas lain dapat meningkatkan stabilitas prediksi pada komoditas yang relatif tidak volatil ini.

Tabel 4.35 Hasil Pengujian Skenario Multivariate Komoditas Minyak Goreng

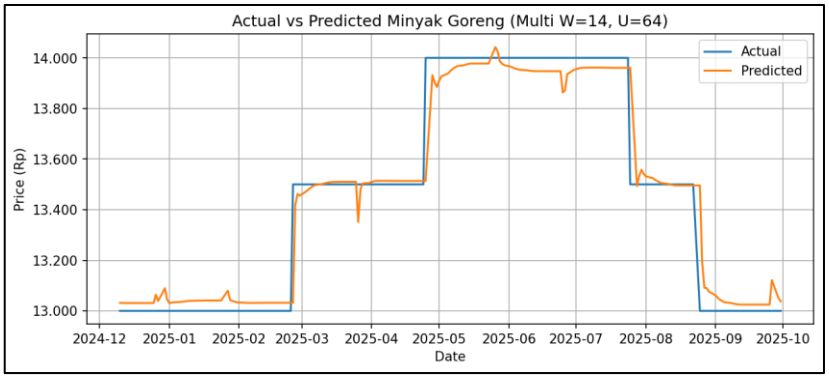
No.	Window	Units	MAPE Testing	MAPE Forecasting
1.	7	32	0.37%	0.24%
2.	7	64	0.87%	5.96%
3.	14	32	0.59%	1.68%
4.	14	64	0.32%	1.08%
5.	30	32	0.42%	0.25%
6.	30	64	0.4%	0.26%

Tabel 4.35 menunjukkan hasil pengujian untuk seluruh skenario multivariate pada komoditas minyak goreng. Dari seluruh kombinasi, konfigurasi window 14 dan 64 unit memberikan nilai error terendah, baik pada fase testing (MAPE 0.323%) maupun forecasting (MAPE 1.089%). Kinerja ini menunjukkan bahwa model mampu mempelajari pergerakan harga minyak goreng yang cenderung statis apabila diberikan konteks historis yang cukup panjang. Selain itu, perbedaan kinerja antarskenario tidak terlalu jauh, yang mengindikasikan bahwa komoditas dengan variabilitas rendah cenderung tidak memerlukan kompleksitas model yang besar.



Gambar 4.49 Nilai MAPE Skenario Multivariate Komoditas Minyak Goreng

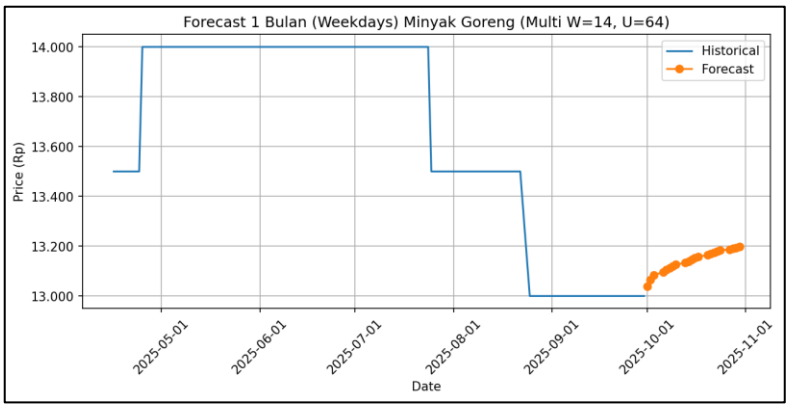
Gambar 4.49 memperlihatkan nilai MAPE dari seluruh skenario. Tampak bahwa konfigurasi W14–U64 berada pada posisi terendah dibanding skenario lain. Secara teknis, hasil ini mengindikasikan bahwa model cenderung bekerja lebih stabil ketika diberi jendela input yang tidak terlalu pendek agar fluktuasi kecil pada data dapat tersaring, sekaligus tidak terlalu panjang sehingga tidak memunculkan noise. Selain itu, unit 64 memberi kapasitas representasi yang cukup untuk mengekstraksi pola halus tanpa menyebabkan overfitting, yang terlihat dari konsistensi nilai MAPE testing dan forecasting.



Gambar 4.50 Grafik Actual vs Predicted Komoditas Minyak Goreng Skenario Multivariate Terbaik

Gambar 4.50 menunjukkan grafik perbandingan antara data aktual dan hasil prediksi untuk skenario terbaik. Model terlihat mampu mengikuti pola perubahan harga secara ketat, terutama pada segmen awal dan pertengahan tahun ketika harga relatif stabil. Penyimpangan kecil yang muncul pada periode mendekati bulan Oktober 2025 menunjukkan bahwa model masih sensitif terhadap perubahan mendadak, tetapi secara umum deviasi tetap rendah karena rentang perubahan harga

minyak goreng memang kecil. Hal ini memperkuat kesimpulan bahwa karakter data yang datar sangat menguntungkan bagi model LSTM multivariate.



Gambar 4.51 Grafik Forecast Oktober 2025 Komoditas Minyak Goreng Skenario Multivariate Terbaik

Gambar 4.51 menyajikan hasil forecasting satu bulan ke depan (Oktober 2025). Pola hasil ramalan menunjukkan tren meningkat yang sangat lembut dari Rp13.000 menuju sekitar Rp13.198. Model tampak menghasilkan prediksi yang smooth dengan gradien kecil, suatu perilaku yang lazim ketika data input historis tidak menunjukkan perubahan tajam. Secara teknis, kecenderungan ini menggambarkan bahwa model lebih mengedepankan mean reversion karena keterbatasan sinyal tren pada data historis minyak goreng.

Tabel 4.36 Perbandingan Harga Aktual dan Forecast Minyak Goreng Skenario Multivariate Terbaik

No.	Tanggal	Harga Aktual (Rp)	Harga Prediksi (Rp)
1.	10/1/2025	13000	13037.9
2.	10/2/2025	13000	13065.57
…	…	…	…
11.	10/15/2025	13000	13146.23
12.	10/16/2025	13000	13152.45
…	…	…	…
21.	10/29/2025	13000	13194.66
22.	10/30/2025	13000	13198.02

Tabel 4.36 menyajikan perbandingan antara harga aktual dan hasil prediksi harga komoditas minyak goreng selama Oktober 2025 pada skenario multivariate terbaik dengan window size 14 dan 64 unit LSTM. Berdasarkan data yang ditampilkan, nilai prediksi model berada relatif dekat dengan harga aktual pada seluruh titik waktu yang terlihat dalam tabel. Pada awal hingga akhir periode pengujian yang ditampilkan, harga aktual berada pada tingkat yang sama, sementara nilai prediksi menunjukkan peningkatan yang kecil dan bertahap. Perbedaan antara harga prediksi dan harga aktual tersebut bersifat konsisten tanpa menunjukkan deviasi yang ekstrem. Kondisi ini mengindikasikan bahwa model multivariate mampu menghasilkan prediksi yang stabil pada komoditas minyak goreng yang memiliki pola harga relatif konstan, sehingga pergerakan harga yang dihasilkan model tetap berada di sekitar nilai aktual.

4.2.18 Hasil Uji Coba Skenario Multivariate Komoditas Gula Pasir

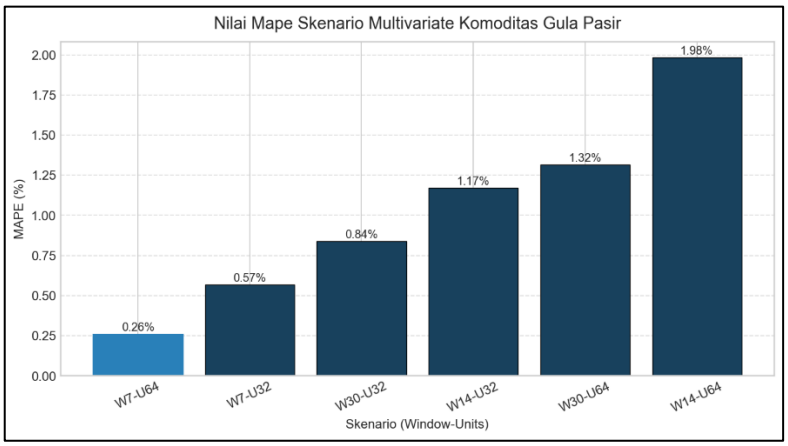
Skenario multivariate pada komoditas gula pasir dilakukan untuk mengevaluasi sejauh mana model LSTM mampu mempelajari pola harga dengan mempertimbangkan keterkaitan antar komoditas lain dalam sistem pasar pangan. Pengujian dilakukan dengan memvariasikan panjang sliding window (7, 14, dan 30 hari) serta jumlah unit LSTM (32 dan 64), sehingga dapat dianalisis pengaruh kombinasi parameter terhadap akurasi model pada data pengujian maupun performa forecasting.

Tabel 4.37 Hasil Pengujian Skenario Multivariate Komoditas Gula Pasir

No.	Window	Units	MAPE Testing	MAPE Forecasting
1.	7	32	0.56%	7.59%
2.	7	64	0.25%	1.83%

No.	Window	Units	MAPE Testing	MAPE Forecasting
3.	14	32	1.17%	3.69%
4.	14	64	1.98%	9.13%
5.	30	32	0.83%	1.04%
6.	30	64	1.31%	4.67%

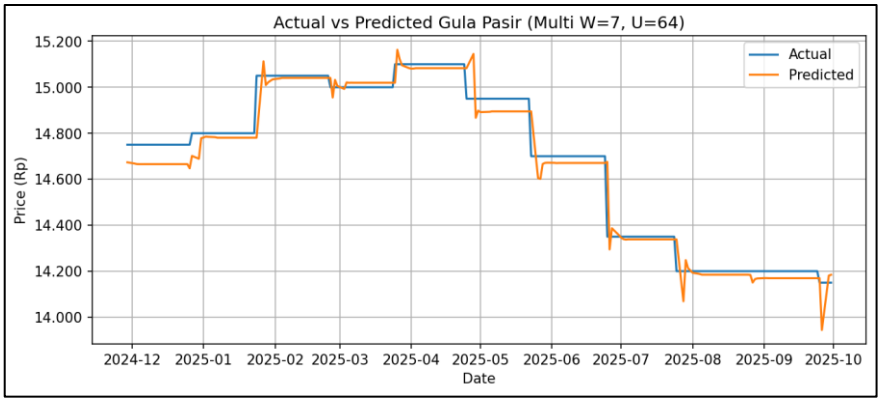
Tabel 4.37 menampilkan hasil pengujian seluruh skenario multivariate untuk komoditas gula pasir. Berdasarkan tabel tersebut, terlihat bahwa kombinasi window 7 dan 64 unit LSTM menghasilkan MAPE Testing terendah sebesar 0,258%, menunjukkan bahwa model mampu menangkap pola jangka pendek dengan stabil. Pada sisi forecasting, nilai MAPE terbaik diperoleh pada window 30 dan 32 unit, yakni 1,049%, yang mengindikasikan bahwa konteks historis yang lebih panjang memberikan stabilitas prediksi jangka depan. Perbedaan ini menunjukkan bahwa performa pada data testing tidak selalu berbanding lurus dengan performa forecasting, sehingga pemilihan skenario terbaik harus mempertimbangkan kedua aspek.



Gambar 4.52 Nilai MAPE Skenario Multivariate Komoditas Gula Pasir

Gambar 4.52 menunjukkan distribusi nilai MAPE untuk masing-masing skenario. Terlihat bahwa skenario W7-U64 menjadi yang paling unggul pada tahap

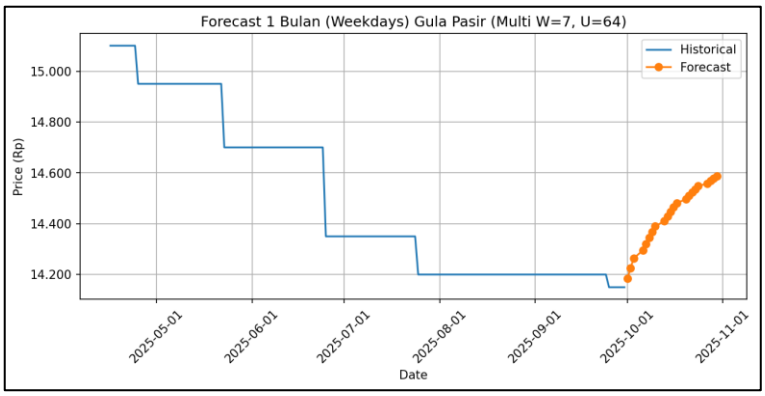
testing, sedangkan W30-U32 menjadi kombinasi yang paling kompetitif pada tahap forecasting. Pola ini mengindikasikan bahwa gula pasir sebagai komoditas dengan fluktuasi rendah lebih mudah direpresentasikan oleh window pendek saat mempelajari data historis, namun tetap membutuhkan konteks yang lebih panjang untuk memberikan prediksi ke depan yang lebih stabil. Sementara itu, skenario dengan error besar seperti W14-U64 (MAPE 1,982%) menunjukkan bahwa peningkatan kompleksitas model tidak selalu menghasilkan generalisasi yang baik, terutama pada data multivariate yang memiliki korelasi antar variabel yang tidak seragam.



Gambar 4.53 Grafik Actual vs Predicted Komoditas Gula Pasir Skenario Multivariate Terbaik

Gambar 4.53 memperlihatkan grafik perbandingan antara harga aktual dan prediksi untuk skenario terbaik. Model mampu mengikuti pola perubahan harga harian secara konsisten, terutama pada area transisi harga yang cenderung bertahap. Pergerakan prediksi tampak lebih halus dibandingkan data aktual, yang mengindikasikan bahwa LSTM melakukan smoothing terhadap noise jangka pendek. Meskipun demikian, akurasi tetap tinggi karena karakteristik harga gula

pasir memang tidak memiliki lonjakan ekstrem sehingga model multivariate dapat memanfaatkan kestabilan pola tersebut.



Gambar 4.54 Grafik Forecast Oktober 2025 Komoditas Gula Pasir Skenario Multivariate Terbaik

Gambar 4.54 menunjukkan hasil forecast satu bulan ke depan (Oktober 2025) menggunakan skenario terbaik. Prediksi model memperlihatkan kecenderungan kenaikan harga secara bertahap dari sekitar Rp14.150 menuju kisaran Rp14.580. Pergerakan prediksi yang meningkat secara konsisten menunjukkan bahwa model menangkap pola musiman dan tren jangka pendek yang terlihat pada data historis. Selain itu, tidak terdapat prediksi outlier atau deviasi tajam, yang menandakan bahwa model memiliki kestabilan yang baik dalam memproyeksikan harga komoditas yang cenderung statis.

Tabel 4.38 Perbandingan Harga Aktual dan Forecast Gula Pasir Skenario Multivariate Terbaik

No.	Tanggal	Harga Aktual (Rp)	Harga Prediksi (Rp)
1.	10/1/2025	14150	14184.37
2.	10/2/2025	14150	14225.61
…	…	…	…
11.	10/15/2025	14150	14447.91
12.	10/16/2025	14150	14465.05
…	…	…	…
21.	10/29/2025	14250	14578.48
22.	10/30/2025	14250	14587.43

Tabel 4.38 menyajikan perbandingan antara harga aktual dan hasil prediksi harga komoditas gula pasir selama Oktober 2025 pada skenario multivariate terbaik dengan window size 7 dan 64 unit LSTM. Berdasarkan data yang ditampilkan, nilai prediksi model berada di sekitar harga aktual pada seluruh titik waktu yang terlihat dalam tabel. Pada awal periode pengujian, perbedaan antara harga prediksi dan harga aktual masih relatif kecil, dan pada data yang ditampilkan untuk pertengahan hingga akhir periode, nilai prediksi menunjukkan kecenderungan meningkat secara bertahap seiring dengan kenaikan level harga aktual. Perbedaan antara harga prediksi dan harga aktual tersebut bersifat konsisten tanpa menunjukkan deviasi yang ekstrem. Kondisi ini mengindikasikan bahwa model multivariate mampu mengikuti perubahan level harga gula pasir yang relatif stabil, sehingga prediksi yang dihasilkan tetap berada di sekitar nilai aktual sepanjang periode yang ditampilkan.

4.3 Pembahasan

Berdasarkan hasil uji coba dengan variasi struktur input (univariate dan multivariate), window size (7, 14, dan 30 hari), serta jumlah unit LSTM (32 dan 64), diperoleh gambaran menyeluruh mengenai bagaimana konfigurasi model memengaruhi performa prediksi harga komoditas pangan di Provinsi Jawa Tengah.

4.3.1 Analisis Hasil Skenario Univariate

Hasil uji coba skenario univariate untuk sembilan komoditas pangan dengan variasi window size 7, 14, dan 30 hari, serta unit LSTM 32 dan 64 Tabel 4.39. Setiap

baris pada tabel merepresentasikan performa model untuk satu konfigurasi dan terlihat bahwa setiap komoditas memiliki konfigurasi terbaik yang berbeda berdasarkan nilai MAPE terendah.

Tabel 4.39 Hasil Skenario Univariate Seluruh Komoditas

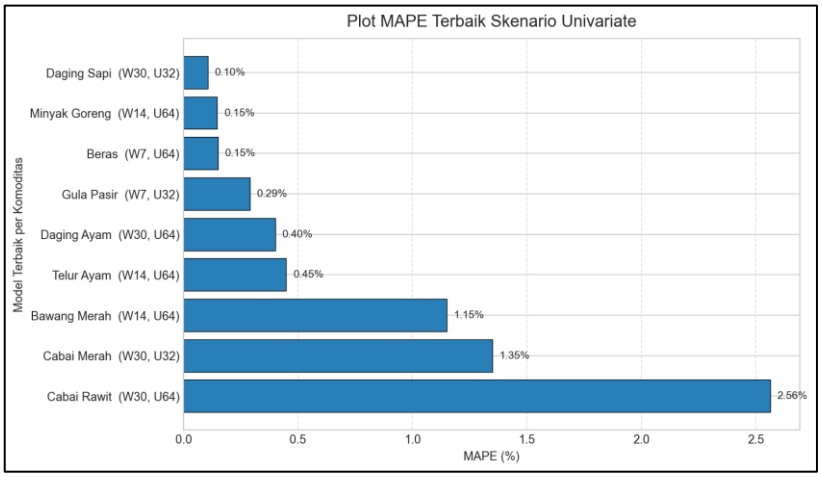
No.	Komoditas	Window Size – Units LSTM					
		W7-U32	W7-U64	W14-U32	W14-U64	W30-U32	W30-U64
1.	Beras	0.43%	0.14%	1.16%	0.96%	1.09%	0.56%
2,	Daging Ayam	0.93%	0.45%	0.50%	0.44%	0.49%	0.40%
3.	Daging Sapi	0.26%	0.31%	0.42%	0.21%	0.10%	0.10%
4.	Telur Ayam	0.66%	0.46%	0.45%	0.44%	0.53%	0.96%
5.	Bawang Merah	2.27%	1.68%	1.20%	1.15%	1.27%	1.30%
6.	Cabai Merah	2.17%	1.72%	2.11%	1.94%	1.34%	1.44%
7.	Cabai Rawit	3.80%	3.44%	3.06%	2.86%	2.67%	2.56%
8.	Minyak Goreng	1.07%	0.34%	0.63%	0.14%	0.64%	0.45%
9.	Gula Pasir	0.28%	0.54%	0.68%	1.35%	1.29%	0.32%

Pada komoditas Beras, nilai MAPE terbaik adalah 0,149% yang diperoleh pada konfigurasi W7, U64. Pola harga beras yang relatif stabil membuat window pendek sudah cukup memberikan representasi pola historis. Daging Ayam menunjukkan nilai MAPE terbaik 0,400% pada konfigurasi W30, U64, menandakan bahwa model membutuhkan informasi historis lebih panjang untuk mengenali perubahan musiman yang terjadi secara bertahap.

Komoditas Daging Sapi menghasilkan nilai MAPE terbaik 0,105% pada konfigurasi W30, U32, yang merupakan nilai MAPE paling rendah di seluruh percobaan. Hal ini disebabkan oleh pola harga daging sapi yang stabil sehingga

model dapat mengenali polanya dengan baik. Telur Ayam menunjukkan nilai MAPE terendah 0,448% pada konfigurasi W14, U64, sedangkan Bawang Merah terbaik pada W14, U64 dengan MAPE 1,151%.

Komoditas dengan volatilitas tinggi seperti Cabai Merah dan Cabai Rawit masih menunjukkan nilai MAPE yang relatif besar. Cabai Merah terbaik pada W30, U32 dengan MAPE 1,348%, sedangkan Cabai Rawit terbaik pada W30, U64 dengan MAPE 2,562%. Hal ini menunjukkan bahwa model membutuhkan konteks historis yang panjang untuk menangkap pola musiman pada komoditas hortikultura. Minyak Goreng memperoleh nilai MAPE terbaik 0,146% pada W14, U64, sedangkan Gula Pasir terbaik pada W7, U32 dengan nilai 0,289%.



Gambar 4.54 Nilai MAPE Terbaik Tiap Komoditas Skenario Univariate

Gambar 4.54 menampilkan perbandingan nilai MAPE terbaik untuk tiap komoditas pada skenario univariate. Berdasarkan gambar tersebut, komoditas dengan MAPE paling rendah adalah Daging Sapi (0,10%; W30, U32), diikuti Minyak Goreng (0,15%; W14, U64), dan Beras (0,15%; W7, U64). MAPE tertinggi pada gambar ini terlihat pada Cabai Rawit sebesar 2,56% dengan konfigurasi W30,

U64. Gambar ini mempertegas bahwa stabilitas harga suatu komoditas sangat berpengaruh terhadap tingkat error model, di mana komoditas stabil cenderung menghasilkan error lebih kecil.

4.3.2 Analisis Hasil Skenario Multivariate

Hasil performa model LSTM pada skenario multivariate Tabel 4.40. Tidak seperti pada skenario univariate, penambahan fitur dari komoditas lain tidak selalu membantu meningkatkan akurasi model.

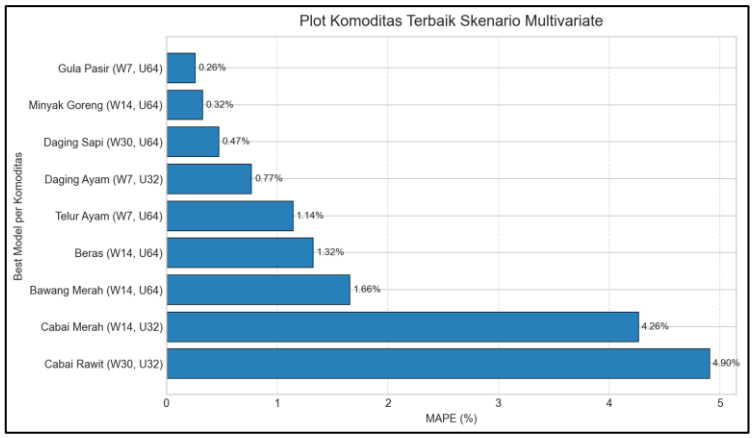
Tabel 4.40 Hasil Skenario Multivariate Seluruh Komoditas

No.	Komoditas	Window Size – Units LSTM					
		W7-U32	W7-U64	W14-U32	W14-U64	W30-U32	W30-U64
1.	Beras	3.16%	3.32%	2.67%	1.32%	3.03%	2.14%
2.	Daging Ayam	0.76%	0.80%	1.03%	1.00%	1.85%	2.29%
3.	Daging Sapi	1.04%	0.69%	0.84%	0.64%	1.00%	0.47%
4.	Telur Ayam	1.18%	1.14%	1.18%	2.30%	2.38%	2.98%
5.	Bawang Merah	2.39%	4.35%	2.44%	1.65%	3.73%	2.34%
6.	Cabai Merah	7.48%	5.21%	4.26%	5.61%	5.51%	7.02%
7.	Cabai Rawit	7.35%	6.07%	8.32%	5.93%	4.90%	5.81%
8.	Minyak Goreng	0.37%	0.87%	0.59%	0.32%	0.42%	0.42%
9.	Gula Pasir	0.56%	0.25%	1.17%	1.98%	0.83%	1.31%

Pada komoditas Beras, nilai MAPE terbaik adalah 1,325% pada konfigurasi W14, U64, jauh lebih tinggi dibanding univariate. Daging Ayam memiliki MAPE terbaik 0,767% pada W7, U32, sedangkan Daging Sapi memperoleh nilai terbaik

0,471% pada W30, U64. Telur Ayam menunjukkan MAPE 1,142% pada W7, U64, sedangkan Bawang Merah menghasilkan MAPE terbaik 1,656% pada W14, U64.

Komoditas Cabai Merah dan Cabai Rawit kembali menunjukkan MAPE tinggi bahkan pada model terbaik, masing-masing 4,264% (W14, U32) dan 4,904% (W30, U32). Sementara itu, komoditas stabil seperti Minyak Goreng dan Gula Pasir memperoleh MAPE rendah, yaitu 0,323% (W14, U64) dan 0,258% (W7, U64).



Gambar 4.55 Nilai MAPE Terbaik Tiap Komoditas Skenario Multivariate

Gambar 4.55 memperlihatkan nilai MAPE terbaik tiap komoditas pada skenario multivariate. Nilai MAPE terendah pada gambar ini adalah Gula Pasir (0,26%; W7, U64), diikuti Minyak Goreng (0,32%; W14, U64) dan Daging Sapi (0,47%; W30, U64). Sebaliknya, nilai MAPE tertinggi muncul pada Cabai Rawit (4,90%; W30, U32). Gambar ini menegaskan bahwa multivariate hanya efektif pada komoditas yang memiliki korelasi kuat dengan komoditas lain dan memiliki pola harga yang stabil.

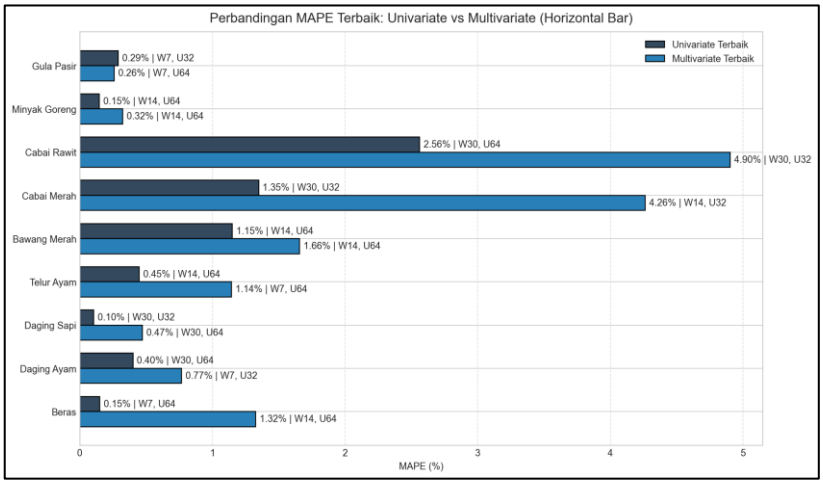
4.3.3 Perbandingan Hasil Terbaik Skenario Univariate dan Multivariate

Perbandingan langsung kedua skenario dapat dilihat pada Gambar 4.56 dan Tabel 4.41. Gambar 4.56 menampilkan dua bar untuk setiap komoditas: satu mewakili nilai univariate terbaik, dan satu lagi multivariate terbaik. Secara visual, bar univariate hampir selalu lebih pendek, menandakan error yang lebih kecil.

Tabel 4.41 Perbandingan Nilai MAPE Terbaik Skenario Univariate dan Multivariate

No.	Komoditas	Nilai MAPE Terbaik Skenario Univariate	Nilai MAPE Terbaik Skenario Multivariate
1.	Beras	0.149%	1.32%
2.	Daging Ayam	0.40%	0.76%
3.	Daging Sapi	0.10%	0.47%
4.	Telur Ayam	0.44%	1.14%
5.	Bawang Merah	1.15%	1.65%
6.	Cabai Merah	1.34%	4.26%
7.	Cabai Rawit	2.56%	4.90%
8.	Minyak Goreng	0.14%	0.32%
9.	Gula Pasir	0.28%	0.25%

Nilai MAPE univariate terbaik jauh lebih rendah dibanding multivariate pada delapan komoditas. Misalnya, Beras univariate 0,149% (W7, U64) vs multivariate 1,325% (W14, U64). Daging Ayam univariate 0,400% vs multivariate 0,767%. Cabai Rawit bahkan mengalami peningkatan error signifikan: 2,562% (univariate; W30, U64) menjadi 4,904% (multivariate; W30, U32).



Gambar 4.56 Perbandingan MAPE Terbaik Skenario Univariate dan Multivariate

Satu-satunya komoditas dengan performa multivariate lebih baik adalah Gula Pasir, yaitu univariate 0,289% vs multivariate 0,258%. Hal ini menunjukkan bahwa hubungan Gula Pasir dengan komoditas lain cukup kuat dan stabil untuk meningkatkan akurasi model.

Berdasarkan Gambar 4.56, menggambarkan bahwa pendekatan univariate lebih sesuai untuk sebagian besar komoditas pangan di Jawa Tengah, terutama ketika pola harga komoditas tidak memiliki korelasi berarti dengan komoditas lain.

4.3.4 Pengaruh Variasi Window Size dan Jumlah Unit LSTM terhadap Akurasi Model

Berdasarkan hasil dari skenario univariate dan multivariate pada Tabel 4.39 dan Tabel 4.40, terlihat adanya pola kecenderungan tertentu pada kombinasi window size dan jumlah unit LSTM yang memengaruhi performa model. Pada skenario univariate, window size panjang yaitu 30 hari (W30) lebih sering menghasilkan nilai MAPE terendah, terutama pada komoditas yang memiliki

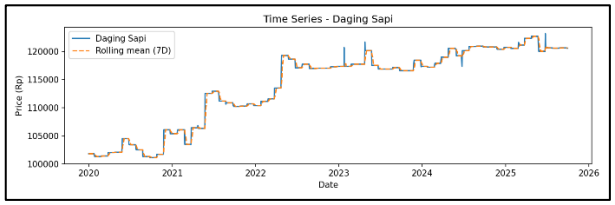
volatilitas tinggi seperti Cabai Merah, Cabai Rawit, dan Daging Ayam. Kondisi ini menunjukkan bahwa pola musiman jangka menengah lebih mampu ditangkap ketika model menerima konteks historis yang lebih panjang sehingga dinamika kenaikan dan penurunan harga yang berulang dapat dipelajari secara lebih efektif.

Selain pengaruh window, jumlah unit LSTM juga menunjukkan pola tertentu. Unit sebesar 64 lebih sering menghasilkan performa terbaik dibandingkan 32 unit, khususnya pada komoditas dengan pola harga yang kompleks dan tidak stabil. Hal ini dapat diinterpretasikan bahwa kapasitas model yang lebih besar memberikan ruang yang lebih fleksibel bagi jaringan untuk mempelajari hubungan non-linear dalam data deret waktu. Namun, kondisi ini tidak berlaku pada semua komoditas. Daging Sapi, misalnya, yang memiliki pola harga stabil, justru memperoleh performa terbaik pada konfigurasi U32. Temuan ini mengindikasikan bahwa model dengan kapasitas besar tidak selalu diperlukan dan bahkan dapat menyebabkan overfitting pada komoditas dengan fluktuasi rendah.

Berbeda dengan univariate, pada skenario multivariate kecenderungan parameter sedikit bergeser. Window size pendek hingga menengah, yaitu antara W7 dan W14, lebih sering menjadi konfigurasi terbaik. Hal ini dapat dijelaskan oleh adanya tambahan fitur harga dari komoditas lain yang turut menjadi masukan model sehingga konteks informasi tidak perlu berasal dari jendela waktu historis yang panjang. Meski demikian, unit LSTM 64 tetap lebih dominan menghasilkan nilai MAPE terbaik pada skenario multivariate, menandakan bahwa jumlah fitur lebih banyak membutuhkan kapasitas representasi yang lebih besar untuk menangkap pola keterkaitan antar-komoditas.

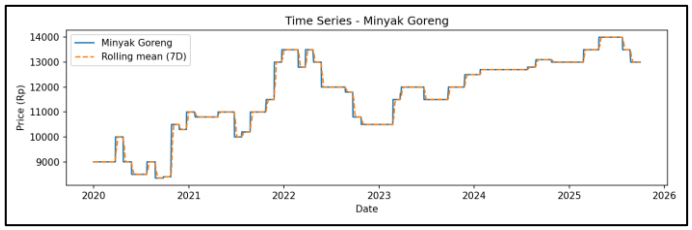
4.3.5 Analisis Pola Harga dan Volatilitas Komoditas

Untuk memahami penyebab perbedaan performa, dianalisiss berdasarkan pola harga masing-masing komoditas pada Gambar 4.58 hingga Gambar 4.61.



Gambar 4.58 Pola Harga Komoditas Daging Sapi

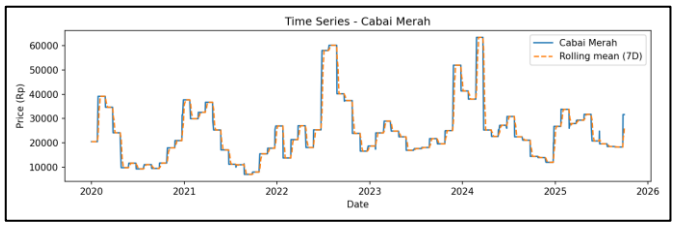
Gambar 4.58 yang menampilkan pola harga Daging Sapi menunjukkan fluktuasi yang relatif stabil dan tren naik yang bertahap sepanjang periode pengamatan. Kestabilan pola ini menjelaskan mengapa model univariate mampu menghasilkan nilai MAPE yang rendah yaitu 0,100% pada konfigurasi W30, U32. Model tidak perlu mengantisipasi puncak harga ekstrem, sehingga pola jangka menengah yang terekam pada window panjang sudah cukup untuk meningkatkan akurasi.



Gambar 4.59 Pola Harga Komoditas Minyak Goreng

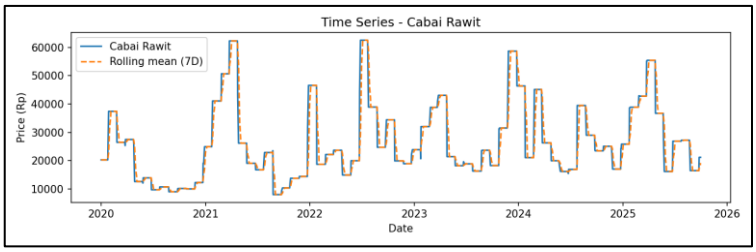
Gambar 4.59 menampilkan harga Minyak Goreng yang bergerak naik secara perlahan dengan sedikit noise. Ketika pola harga bersifat halus seperti ini, model memperoleh akurasi yang sangat tinggi baik pada univariate maupun multivariate. Hal tersebut tercermin dari nilai MAPE univariate sebesar 0,146% pada W14, U64

serta nilai MAPE multivariate 0,323% pada konfigurasi W14, U64. Pola harga yang smooth mempermudah model dalam melakukan generalisasi.



Gambar 4.60 Pola Harga Komoditas Cabai Merah

Gambar 4.60 yang menggambarkan harga Cabai Merah menunjukkan adanya puncak harga yang sangat tinggi dan berulang setiap tahunnya. Puncak ekstrem ini menyebabkan model kesulitan melakukan prediksi akurat karena pola kenaikan dan penurunan harga tidak hanya bergantung pada informasi historis tetapi juga pada faktor eksternal seperti musim panen dan kondisi cuaca. Kondisi ini tercermin pada nilai MAPE yang lebih tinggi, yaitu 1,348% pada univariate (W30, U32) dan 4,264% pada multivariate (W14, U32).



Gambar 4.61 Pola Harga Komoditas Cabai Rawit

Gambar 4.61 menunjukkan volatilitas yang bahkan lebih tinggi pada komoditas Cabai Rawit. Pola harga memperlihatkan lonjakan tajam yang muncul berulang dalam rentang waktu yang tidak teratur. Tingkat volatilitas ekstrem ini menjelaskan mengapa nilai MAPE komoditas ini berada pada tingkat yang paling

tinggi di antara seluruh komoditas, yaitu 2,562% pada univariate (W30, U64) dan 4,904% pada multivariate (W30, U32). Model LSTM mengalami kesulitan dalam memprediksi perubahan harga yang sangat tiba-tiba karena pola tersebut tidak selalu tercermin pada window historis.

Dari keempat gambar pola harga komoditas terlihat bahwa semakin tinggi tingkat volatilitas suatu komoditas, semakin besar pula nilai MAPE yang diperoleh, bahkan ketika model menggunakan konfigurasi terbaiknya. Hal ini menjadi alasan utama mengapa nilai MAPE terbaik masing-masing komoditas berbeda-beda, karena kemampuan model untuk mempelajari pola harga sangat dipengaruhi oleh kestabilan harga komoditas yang bersangkutan.

4.3.6 Analisis Arsitektur Model LSTM terhadap Performa Prediksi

Arsitektur model Long Short-Term Memory (LSTM) pada penelitian ini terdiri atas tiga komponen utama, yaitu *input layer* yang menerima urutan data historis dengan variasi *sliding window* selama 7, 14, dan 30 hari, *hidden layer* berupa sel LSTM dengan jumlah unit 32 atau 64, serta *dense layer* tunggal yang menghasilkan satu nilai prediksi harga untuk setiap komoditas. Variasi ukuran *sliding window* dan jumlah unit pada *hidden layer* memengaruhi kualitas keluaran *dense layer*, yang tercermin pada nilai Mean Absolute Percentage Error (MAPE) masing-masing komoditas.

Pada skenario univariate, model LSTM dievaluasi menggunakan satu variabel harga sebagai input dan target prediksi untuk setiap komoditas, yaitu Beras, Daging Ayam, Daging Sapi, Cabai Merah, Cabai Rawit, Minyak Goreng, dan Gula

Pasir. Hasil pengujian menunjukkan bahwa performa optimal dicapai ketika panjang input historis selaras dengan karakteristik volatilitas harga komoditas. Beras, yang memiliki pola harga relatif stabil, mencapai nilai MAPE terendah sebesar 0,149% pada *input layer* tujuh hari dengan *hidden layer* 64 unit, mengindikasikan bahwa konteks historis pendek sudah memadai. Sebaliknya, Daging Ayam memerlukan *input layer* lebih panjang, yaitu 30 hari dengan *hidden layer* 64 unit, untuk mencapai MAPE sebesar 0,400%, yang menunjukkan adanya pengaruh pola musiman.

Komoditas Daging Sapi menunjukkan bahwa stabilitas harga memungkinkan penggunaan kapasitas *hidden layer* yang lebih kecil, dengan MAPE terendah sebesar 0,10% pada kombinasi *input layer* 30 hari dan *hidden layer* 32 unit. Pada komoditas dengan volatilitas tinggi, seperti Cabai Merah dan Cabai Rawit, kinerja terbaik diperoleh melalui *input layer* yang lebih panjang dan kapasitas *hidden layer* yang lebih besar. Cabai Merah mencapai MAPE terendah sebesar 1,34% pada konfigurasi W30–U32, sedangkan Cabai Rawit mencapai MAPE sebesar 2,56% pada konfigurasi W30–U64. Hal ini menunjukkan bahwa konteks historis yang luas dan kapasitas representasi yang lebih besar diperlukan untuk mempelajari pola fluktuasi ekstrem. Pada Minyak Goreng, konfigurasi *input layer* 14 hari dan *hidden layer* 64 unit menghasilkan MAPE terendah sebesar 0,14%, sedangkan Gula Pasir mencapai nilai terbaik sebesar 0,289% pada *input layer* tujuh hari dengan *hidden layer* 32 unit. Temuan ini menegaskan bahwa arsitektur optimal pada skenario univariate sangat bergantung pada karakteristik fluktuasi masing-masing komoditas.

Pada skenario multivariate, *input layer* menerima urutan historis dari sembilan komoditas secara simultan, sehingga *hidden layer* dapat mempelajari keterkaitan antar-komoditas. Pada komoditas Beras, konfigurasi *input layer* 14 hari dan *hidden layer* 64 unit menghasilkan nilai MAPE sebesar 1,325%. Daging Ayam mencapai performa terbaik pada *input layer* tujuh hari dan *hidden layer* 32 unit dengan MAPE sebesar 0,76%, menunjukkan bahwa pengayaan fitur dapat mengurangi kebutuhan konteks historis panjang. Daging Sapi kembali menunjukkan performa baik dengan MAPE sebesar 0,47% pada *input layer* 30 hari dan *hidden layer* 64 unit.

Sebaliknya, pada komoditas dengan volatilitas tinggi, performa prediksi pada skenario multivariate cenderung menurun. Cabai Merah dan Cabai Rawit masing-masing menghasilkan MAPE terendah sebesar 4,26% dan 4,90%, yang menunjukkan bahwa keterkaitan antar-komoditas belum cukup kuat untuk mengompensasi volatilitas ekstrem. Pada komoditas yang lebih stabil, seperti Minyak Goreng, model menghasilkan MAPE rendah sebesar 0,32% pada *input layer* 14 hari dan *hidden layer* 64 unit. Gula Pasir menjadi satu-satunya komoditas yang menunjukkan peningkatan akurasi pada skenario multivariate, dengan MAPE sebesar 0,25% pada *input layer* tujuh hari dan *hidden layer* 64 unit.

Secara keseluruhan, analisis arsitektur model LSTM menunjukkan bahwa performa dense layer sangat bergantung pada kesesuaian kombinasi input layer dan hidden layer dengan karakteristik volatilitas masing-masing komoditas. Input layer panjang lebih efektif untuk komoditas volatil, sedangkan input pendek lebih sesuai untuk komoditas stabil atau ketika model memiliki fitur tambahan pada skenario

multivariate. Hidden layer dengan 64 unit cenderung menghasilkan performa lebih baik pada komoditas kompleks, sementara hidden layer 32 unit cukup untuk komoditas dengan pola harga sederhana. Temuan ini menjelaskan secara teknis bagaimana struktur jaringan LSTM berkontribusi pada akurasi prediksi harga pangan dan mengapa parameter terbaik berbeda-beda untuk setiap komoditas serta setiap skenario pengujian.

4.4 Integrasi Islam

Integrasi Islam dalam penelitian ini diwujudkan melalui tiga bentuk *muamalah* yang menggambarkan hubungan manusia dengan Allah, alam, dan sesama manusia. Ketiga dimensi ini menjadi landasan moral dan spiritual dalam penerapan ilmu pengetahuan, khususnya pada pengembangan model *Long Short-Term Memory* (LSTM) untuk prediksi harga komoditas pangan. *Muamalah ma'a Allah* mencerminkan tanggung jawab manusia dalam menggunakan ilmu sebagai amanah dari Allah, *muamalah ma'a al-'alam* menekankan pentingnya menjaga keseimbangan dan kelestarian alam dalam setiap kemajuan teknologi, sedangkan *muamalah ma'a an-nas* mengajarkan nilai keadilan, kejujuran, dan tanggung jawab sosial dalam penerapan hasil penelitian agar bermanfaat bagi masyarakat. Ketiga aspek tersebut membentuk dasar etika Islam yang menyatukan antara ilmu, iman, dan kemaslahatan.

4.4.1 *Muamalah Ma'a Allah*

Hubungan manusia dengan Allah (*mu'amalah ma'a Allah*) menegaskan bahwa setiap aktivitas manusia, termasuk kegiatan ilmiah, merupakan bagian dari ibadah dan bentuk pengabdian kepada-Nya. Allah berfirman dalam QS. Al-An'am:165.

وَهُوَ الَّذِيْ جَعَلَكُمْ خَلٰۤىِٕفَ الْاَرْضِ وَرَفَعَ بَعْضَكُمْ فَوْقَ بَعْضٍ دَرَجٰتٍ لِّيَبْلُوَكُمْ فِيْ مَآ اٰتٰىكُمْۗ اِنَّ رَبَّكَ سَرِيْعُ الْعِقَابِۖ وَاِنَّهٗ لَغَفُوْرٌ رَّحِيْمٌ ١٦٥

"Dan Dia-lah yang menjadikan kalian khalifah-khalifah di bumi dan mengangkat sebagian kalian atas sebagian yang lain dalam derajat, untuk menguji kalian terhadap apa yang telah diberikan kepada kalian" (QS. Al-An'am:165).

Ayat tersebut mengingatkan bahwa ilmu dan kemampuan yang dimiliki manusia adalah amanah serta ujian dari Allah. Manusia dituntut untuk menggunakan ilmu tersebut dengan tanggung jawab dan tidak menyalahgunakannya untuk kepentingan yang merugikan orang lain (Omor et al., 2025).

Penelitian ini mencerminkan bentuk tanggung jawab tersebut. Penggunaan teknologi *Long Short-Term Memory* (LSTM) untuk memprediksi harga komoditas pangan dilakukan sebagai upaya untuk memberikan manfaat bagi masyarakat, terutama dalam menjaga kestabilan harga dan membantu pengambilan kebijakan yang lebih tepat. Dengan adanya prediksi yang akurat, potensi kerugian akibat fluktuasi harga dapat dikurangi, sehingga kesejahteraan petani, pedagang, dan konsumen dapat lebih terlindungi. Langkah ini merupakan wujud nyata penerapan ilmu pengetahuan yang berorientasi pada kemaslahatan, sesuai dengan nilai-nilai Islam yang mengajarkan agar setiap amal manusia membawa manfaat bagi sesama.

Selain berfungsi sebagai kontribusi ilmiah, penelitian ini juga menjadi bentuk pengamalan spiritual dalam menjalankan peran sebagai khalifah di bumi. Setiap peneliti tidak hanya bertanggung jawab terhadap hasil yang dicapai, tetapi juga terhadap dampak yang ditimbulkan dari penerapan ilmunya. Oleh karena itu, keberhasilan penelitian tidak hanya diukur dari ketepatan model dan nilai kesalahan yang kecil, tetapi juga dari sejauh mana hasilnya membawa kebaikan bagi masyarakat.

4.4.2 *Muamalah Ma'a al-Alam*

Manusia sebagai khalifah di bumi memiliki tanggung jawab untuk menjaga, mengelola, dan memanfaatkan alam secara bijak agar membawa kemaslahatan bagi seluruh makhluk hidup. Allah Swt. berfirman dalam QS. As-Sajdah: 27:

اَوَلَمْ يَرَوْا اَنَّا نَسُوْقُ الْمَاۤءَ اِلَى الْاَرْضِ الْجُرُزِ فَنُخْرِجُ بِهٖ زَرْعًا تَأْكُلُ مِنْهُ اَنْعَامُهُمْ وَاَنْفُسُهُمْۗ اَفَلَا يُبْصِرُوْنَ ٢٧

"Tidakkah mereka memperhatikan bahwa Kami mengarahkan (awan yang mengandung) air ke bumi yang tandus, lalu Kami menumbuhkan dengannya (air hujan) tanam-tanaman, sehingga hewan-hewan ternak mereka dan mereka sendiri dapat makan darinya. Maka, mengapa mereka tidak memperhatikan?" (QS. As-Sajdah: 27).

Ayat tersebut menggambarkan bagaimana Allah menegaskan pentingnya memperhatikan dan memanfaatkan sumber daya alam yang telah disediakan dengan sebaik-baiknya. Ayat tersebut menunjukkan bahwa Islam mendorong manusia untuk mengelola dan menghidupkan tanah yang tidak termanfaatkan agar dapat memberi manfaat ekonomi dan sosial bagi masyarakat. Tanah yang dibiarkan kosong tanpa pengelolaan sama artinya dengan menyia-nyiakan potensi rezeki yang Allah sediakan di bumi (Suprihatin, 2016).

Pada penelitian ini, nilai *muamalah ma'a al-'alam* tercermin dari upaya penggunaan teknologi prediktif untuk mendukung optimalisasi sektor pertanian. Model *Long Short-Term Memory* (LSTM) yang digunakan dalam penelitian ini membantu memprediksi fluktuasi harga komoditas pangan di Jawa Tengah, sehingga dapat menjadi dasar dalam perencanaan distribusi dan pengelolaan lahan pertanian secara lebih efektif. Dengan mengetahui tren harga yang akan datang, pemerintah dan petani dapat mengatur pola tanam serta pemanfaatan lahan agar hasil pertanian lebih seimbang dengan kebutuhan pasar. Upaya ini tidak hanya mencegah pemborosan sumber daya, tetapi juga mendukung pemanfaatan lahan secara maksimal agar tidak ada tanah yang terbengkalai atau tidak produktif.

Penelitian ini menegaskan bahwa teknologi dapat menjadi sarana untuk mewujudkan prinsip Islam dalam menjaga alam dan memanfaatkan sumber daya dengan tanggung jawab. Prediksi harga pangan yang akurat dapat membantu petani menentukan waktu tanam dan jenis komoditas yang sesuai, sehingga produktivitas pertanian meningkat dan kesejahteraan masyarakat dapat terjaga. Dengan demikian, penerapan teknologi dalam penelitian ini sejalan dengan pesan QS. As-Sajdah: 27 yang mendorong manusia untuk memperhatikan, mengelola, dan menghidupkan bumi agar menjadi sumber kehidupan yang bermanfaat bagi semua makhluk serta menghindarkan lahan dari keadaan kosong yang sia-sia.

4.4.3 *Muamalah Ma'a an-Nas*

Hubungan manusia dengan sesama (*mu'amalah ma'a an-nas*) menekankan pentingnya keadilan, kejujuran, dan tanggung jawab dalam segala bentuk interaksi sosial dan ekonomi. Allah Swt. berfirman dalam QS. Al-An'am: 152.

وَلَا تَقْرَبُوْا مَالَ الْيَتِيْمِ اِلَّا بِالَّتِيْ هِيَ اَحْسَنُ حَتّٰى يَبْلُغَ اَشُدَّهٗۚ وَاَوْفُوا الْكَيْلَ وَالْمِيْزَانَ بِالْقِسْطِۚ لَا نُكَلِّفُ نَفْسًا اِلَّا وُسْعَهَاۚ وَاِذَا قُلْتُمْ فَاعْدِلُوْا وَلَوْ كَانَ ذَا قُرْبٰىۚ وَبِعَهْدِ اللّٰهِ اَوْفُوْاۗ ذٰلِكُمْ وَصّٰىكُمْ بِهٖ لَعَلَّكُمْ تَذَكَّرُوْنَۙ ١٥٢

"Dan janganlah mendekati harta anak yatim kecuali dengan cara yang lebih bermanfaat, sampai ia dewasa, dan sempurnakanlah takaran dan timbangan dengan adil. Tidak ada beban yang lebih besar daripada kemampuan seseorang" (QS. Al-An'am: 152).

Ayat ini menunjukkan bahwa manusia diperintahkan untuk berlaku adil dan amanah dalam mengelola harta, menunaikan janji, serta menjaga hak orang lain. Ayat tersebut menegaskan tanggung jawab moral manusia dalam menjaga amanah ekonomi dan sosial, terutama terhadap pihak yang lemah seperti anak yatim, dengan prinsip keadilan dan kehati-hatian (Anior et al., 2024).

Dalam penelitian ini, nilai-nilai tersebut dapat diterapkan dalam praktik pengelolaan informasi dan kebijakan ekonomi yang adil. Sistem prediksi harga komoditas pangan yang dikembangkan dengan metode *Long Short-Term Memory* (LSTM) bertujuan memberikan informasi yang transparan dan akurat bagi semua pihak, baik pemerintah, pelaku pasar, maupun masyarakat. Ketepatan informasi harga dapat mengurangi risiko manipulasi dan ketimpangan dalam transaksi ekonomi. Dengan adanya hasil prediksi yang dapat dipercaya, para pemangku kepentingan dapat mengambil keputusan yang lebih adil, sehingga kesejahteraan masyarakat dapat meningkat secara merata. Prinsip ini sejalan dengan pesan Al-

Qur’an agar manusia menegakkan kejujuran dan keadilan dalam setiap aktivitas sosial dan ekonomi.

BAB V

KESIMPULAN DAN SARAN

5.1 Kesimpulan

Berdasarkan hasil percobaan metode Long Short-Term Memory (LSTM) mampu memprediksi harga harian komoditas pangan di Provinsi Jawa Tengah dengan akurasi sangat baik yang ditunjukkan oleh seluruh nilai MAPE di bawah 10%. Pada skenario univariate, model memberikan performa terbaik pada 8 dari 9 komoditas, dengan nilai MAPE terendah diperoleh pada Daging Sapi sebesar 0,10%, Minyak Goreng sebesar 0,15%, dan Beras sebesar 0,14%. Secara umum, konfigurasi terbaik pada skenario ini diperoleh pada variasi window size 7–30 hari dengan 32–64 unit LSTM, bergantung pada karakteristik masing-masing komoditas. Pada skenario multivariate, performa prediksi terbaik diperoleh pada konfigurasi window size 7–14 hari dengan 64 unit LSTM, dengan nilai MAPE terendah dicapai oleh Gula Pasir sebesar 0,25% dan Minyak Goreng sebesar 0,32%. Secara keseluruhan, hasil penelitian menunjukkan bahwa input layer panjang lebih efektif untuk komoditas volatil, sedangkan input layer pendek lebih sesuai untuk komoditas stabil atau ketika model memiliki fitur tambahan pada skenario multivariate. Temuan ini menunjukkan bahwa konfigurasi optimal model LSTM ditentukan oleh karakteristik data harga tiap komoditas.

5.2 Saran

Berdasarkan hasil penelitian ini, penelitian selanjutnya disarankan untuk mengembangkan variasi arsitektur model di luar LSTM dasar, seperti Bidirectional

LSTM, Stacked LSTM, atau Gated Recurrent Unit (GRU*)*, guna membandingkan kinerja model dan memperoleh konfigurasi yang lebih optimal dalam memprediksi harga komoditas pangan. Selain itu, penambahan variabel eksternal yang berpengaruh terhadap perubahan harga, seperti curah hujan, inflasi, biaya distribusi, dan volume produksi, juga disarankan agar model mampu menangkap faktor-faktor penyebab fluktuasi harga secara lebih komprehensif dan menghasilkan prediksi yang lebih realistis untuk mendukung pengambilan keputusan kebijakan pangan.

DAFTAR PUSTAKA

Agung, A., Daniswara, A., Kadek, I., & Nuryana, D. (2023). Data Preprocessing Patterns in the Assessment of Teacher Education Program Students. *Journal of Informatics and Computer Science*, *05*, 97–100.

Akbar, B. M., Anggraeny, F. T., & Mandyartha, E. P. (2025). Peramalan Harga Minyak Mentah Brent Berbasis Model Prophet dengan Optimasi Tree-Structured Parzen Estimator (TPE). *JIIP - Jurnal Ilmiah Ilmu Pendidikan, 8(11), 12777-12782*, *8*(November).

Alhafiz, A., & R, R. K. (2025). *Implementation of the K-Nearest Neighbor Algorithm for Birth Rate Prediction*. *9*(4), 1441–1450.

Alhaq, D. L., & Mahmud, H. (2024). Tafsir Ayat-Ayat Perencanaan Perspektif Al-Quran dan Al-Hadist. *Mushaf Journal: Jurnal Ilmu Al Quran Dan Hadis*, *4*(3), 506–516. https://mushafjournal.com/index.php/mj/article/view/287

Anior, I. A., Kholillah, N., & Rahmawati, A. (2024). Konsep Kejujuran dan Keadilan dalam Al-Qur ' an (Studi Tafsir Tematik). *L-Qadim: JournalTafsir Dan Ilmu Tafsir(JTIT)*, *1*(2), 1–10.

Arsi, P., Astuti, T., Rahmawati, D., & Subarkah, P. (2022). Implementasi Sliding Window Algotihm pada Prediksi Kurs berbasis Neural Network. *DoubleClick: Journal of Computer and Information Technology*, *6*(1), 51.

Azwina, R., & Syahbudi, M. (2022). Pengaruh Fluktuasi Harga Komoditas Pangan Terhadap Inflasi di Provinsi Sumatera Utara tahun (2019-2021). *El-Mal: Jurnal Kajian Ekonomi & Bisnis Islam*, *4*(1), 238–249.

Bank Indonesia. (2025). Tabel harga produsen daerah. Bank Indonesia. https://www.bi.go.id/hargapangan/TabelHarga/ProdusenDaerah (diakses pada 1 November 2025)

Cahyani, J., Mujahidin, S., & Fiqar, T. P. (2023). Implementasi Metode Long Short Term Memory (LSTM) untuk Memprediksi Harga Bahan Pokok Nasional. *Jurnal Sistem Dan Teknologi Informasi (JustIN)*, *11*(2), 346.

Chintia, R. A., & Destiningsih, R. (2022). Pengaruh Harga Komoditas Pangan Terhadap Inflasi Di Kota Semarang. *Jurnal Ilmiah Ekonomi Bisnis*, *27*(2), 244–258.

Dwika, A. R. H., & Avianto, D. (2023). Implementasi Algoritma LSTM untuk Prediksi Harga Cabai Merah Keriting di Yogyakarta. *Jurnal Indonesia : Manajemen Informatika Dan Komunikasi*, *5*(1), 635–648.

Febriyanti, A. Y., Prasetya, D. A., & Trimono, T. (2025). Stock Price Prediction and Risk Estimation Using Hybrid CNN-LSTM and VaR-ECF. *Jurnal Teknik Informatika (Jutif)*, *6*(3), 1539–1554.

Fungki Wahyu, & Billy Hendrik. (2023). Perbandingan Algoritma Time Series Dan Fuzzy Inference System Dalam Analisis Data Deret Waktu. *Jurnal Penelitian Teknologi Informasi Dan Sains*, *1*(3), 16–24.

Ghalibaf, M. B., Gholami, M., & Mohammadian, N. (2022). Stability of Food Security in Iran; Challenges and Ways Forward: A Narrative Review. *Iranian Journal of Public Health*, *51*(12), 2654–2663.

Giga Razki Ardiansyah, Musayyanah, M., Wega Aqvirandy, M. Difa Farady, Mia

Nilam Cahya, & Tri Hadiono. (2023). Deteksi kanker payudara menggunakan artificial neurol network pada deep learning. *INFOTECH : Jurnal Informatika & Teknologi*, *4*(2), 259–269.

Gori, T., Sunyoto, A., & Al Fatta, H. (2024). Preprocessing Data dan Klasifikasi untuk Prediksi Kinerja Akademik Siswa. *Jurnal Teknologi Informasi Dan Ilmu Komputer*, *11*(1), 215–224. https://doi.org/10.25126/jtiik.20241118074

Haq, M. Z., Octiva, C. S., Ayuliana, A., Nuryanto, U. W., & Suryadi, D. (2024). Algoritma Naïve Bayes untuk Mengidentifikasi Hoaks di Media Sosial. *Jurnal Minfo Polgan*, *13*(1), 1079–1084. https://doi.org/10.33395/jmp.v13i1.13937

Hasibuan, E. (2022). Implementasi Machine Learning untuk Prediksi Harga Mobil Bekas dengan Algoritma Regresi Linear berbasis Web. *Jurnal Ilmiah Komputasi*, *21*(4), 595–602. https://doi.org/10.32409/jikstik.21.4.3327

Hasibuan, L. S., & Novialdi, Y. (2022). Prediksi Harga Minyak Goreng Curah dan Kemasan Menggunakan Algoritme Long Short-Term Memory (LSTM). *Jurnal Ilmu Komputer Dan Agri-Informatika*, *9*(2), 149–157.

Helbawanti, O., Saputro, W. A., & Ulfa, A. N. (2021). Pengaruh Harga Bahan Pangan Terhadap Inflasi di Indonesia. *Agrisaintifika Jurnal Ilmu-Ilmu Pertanian Vol.5, No. 2, 2021*, *5*(2), 107–116.

Meriani, A. P., & Rahmatulloh, A. (2024). Perbandingan Gated Recurrent Unit (Gru) Dan Algoritma Long Short Term Memory (Lstm) Linear Refression Dalam Prediksi Harga Emas Menggunakan Model Time Series. *Jurnal Informatika Dan Teknik Elektro Terapan*, *12*(1).

Miraati Laia. (2023). Analisis Kinerja Algoritma K-Nearest Neighbor Imputation (KNNI) Untuk Missing Value Pada Klasifikasi Data Mining. *Journal of Informatics, Electrical and Electronics Engineering*, *2*(3), 92–98.

Murugesan, R., Mishra, E., & Krishnan, A. H. (2021). Deep Learning Based Models: Basic LSTM, Bi LSTM, Stacked LSTM, CNN LSTM and Conv LSTM to Forecast Agricultural Commodities Prices. *Research Square*, *01*, 0–32.

Nafi'iyah, N., & Wulandari, P. A. (2022). Prediksi Harga Beras Berdasarkan Kualitas Beras dengan Metode Long Short Term Memory. *INOVTEK Polbeng - Seri Informatika*, *7*(2), 278. https://doi.org/10.35314/isi.v7i2.2599

Nugroho, S., Agung, H., Benyamin, H. R., & Soekirno, S. (2025). Performance Comparison of 1D-CNN and LSTM Deep Learning Models for Time Series-Based Electric Power Prediction. *ELKOMIKA: Jurnal Teknik Energi Elektrik, Teknik Telekomunikasi, & Teknik Elektronika*, *13*(1), 44.

Nur Cahyo, E., & Susanti, E. (2023). Analisis Time Series Untuk Deep Learning Dan Prediksi Data Spasial Seismik: Studi Literatur. *Jurnal Teknologi*, *15*(2), 124–136. https://doi.org/10.34151/jurtek.v15i2.3581

Oktafiani, R., Hermawan, A., & Avianto, D. (2023). *Pengaruh Komposisi Split Data Terhadap Performa Klasifikasi Penyakit Kanker Payudara Menggunakan Algoritma Machine Learning*. *9*(April), 19–28.

Omor, N., Tafsir, P., Surah, I., & Ayat, A. (2025). Meritokrasi Ilahiah dan Ujian Sosial: Perpektif Tafsir Interdisiplin Surah Al-An'ām Ayat 165. *YAHDIFA: Jurnal Akademik Humaniora Diskursus Interdisiplin Fundamental Agama*, *Vol 1 No 1*, 56–74.

Permatasari, Y. A., & Purnomo, D. (2025). Fenomena Pangan Di Jawa Tengah Dari Sisi Ketersediaan Komoditi Pangan Beras. *Equilibrium : Jurnal Ilmiah Ekonomi, Manajemen Dan Akuntansi*, *14*(1), 54.

Pratama, M. B., & Sanjaya, F. I. (2025). Prediksi omset penjualan toko mbak ning pasar cinderamata menggunakan long short term memory. *Jurnal Sistem Informasi Dan Sistem Komputer*, *10*(1), 160–167.

Priyatno, A. M., Sudirman, W. F. R., & Musridho, R. J. (2024). Feature selection using non-parametric correlations and important features on recursive feature elimination for stock price prediction. *International Journal of Electrical and Computer Engineering*, *14*(2), 1906–1915.

Radho, A. E., Sugiartawan, P., & Santiago, G. A. (2022). Prediksi Jumlah Kasus COVID-19 Menggunakan Teknik Sliding Wondows dengan Metode BPNN. *Jurnal Sistem Informasi Dan Komputer Terapan Indonesia (JSIKTI)*, *4*(1), 12–23. https://doi.org/10.33173/jsikti.123

Raharja, A. R., Jayadi, Pramudianto, A., & Muchsam, Y. (2024). Penerapan Algoritma Decision Tree dalam Klasifikasi Data "Framingham" Untuk Menunjukkan Risiko Seseorang Terkena Penyakit Jantung dalam 10 Tahun Mendatang. *Technologia Journal*, *1*(1). https://doi.org/10.62872/cwgzp962

Rahmad, F., Mukhtar, H., & Awaluddin. (2023). Prediksi Indeks Harga Produsen Pertanian Karet Di Indonesia Menggunakan Metode LSTM. *Jurnal Fasilkom*, *13*(01), 1–6. https://doi.org/10.37859/jf.v13i01.4851

Rahmi, A., Sukardi, T., & Wijaya, A. S. (2021). Mitigasi Krisis Pangan Dalam Al-Qur'an (Perspektif Kitab Tafsir Al-Qurtubi). *Ikhtisar: Jurnal Pengetahuan Islam*, *1*(1), 25–38.

Satrani Azral, Bambang, K., & Khasnur, H. (2023). Hybrid Deep Learning Untuk Prediksi Kunjungan Tamu Hotel. *Jurnal Sistem Informasi Dan Teknologi(S I N T E K)*, *V*(2), 100–107.

Sawitri, D., & Medan, U. H. (2025). *Peran Deep Learning Dan Big Data Dalam Mendekteksi Masalah Peran Deep Learning Dan Big Data Dalam Mendekteksi Masalah Keuangan*. *April*. https://doi.org/10.46576/djtechno

Sulastri, H., Anwar, G. S., & Dewi, E. N. F. (2023). Peramalan Stok Barang Percetakan dan ATK Menggunakan Single Moving Average. *Jurnal Rekayasa Teknologi Informasi (JURTI)*, *7*(1), 59.

Suprihatin, T. (2016). Pemanfaatan lahan kosong perspektif ekonomi islam. *Hukum Islam*, *XVI*(2), 161–169.

Verianto, E. (2024). Penerapan LSTM Dengan Regularisasi Untuk Mencegah Overfitting Pada Model Prediksi Tingkat Inflasi Di Indonesia. *Jurnal Sistem Informasi Dan Sistem Komputer*, *9*(2), 195–204.

Widianti, A., & Pratama, I. (2024). *Penanganan Missing Values Dan Prediksi Data Timbunan*. *9*(2), 242–251.

Wijaya, M. F., Phalepi, M. Y., Afriyanti, G., Mariya, A., Natalia, C., & Nispuana, S. (2025). The Role of The Agricultural Sector on Economic Growth in Indonesia. *Food, Culture and Society*, *28*(2), 335.

Zafira, F., Irawan, B., & Bahtiar, A. (2024). Penerapan Data Mining Untuk Estimasi Stok Barang Dengan Metode K-Means Clustering. *JATI (Jurnal Mahasiswa Teknik Informatika)*, *8*(1), 156–161. https://doi.org/10.36040/jati.v8i1.8319

Zhang, Q., Yang, W., Zhao, A., Wang, X., Wang, Z., & Zhang, L. (2024). Short-term forecasting of vegetable prices based on LSTM model—Evidence from Beijing's vegetable data. In *PLoS ONE* (Vol. 19, Issue 7 July).