SISTEM CERDAS MULTI-OUTPUT MODEL DEEP LEARNING PADA IDENTIFIKASI ALAT PELINDUNG DIRI DI LINGKUNGAN INDUSTRI

Disusun oleh:

Muhammad Bagus Adi Prayoga

4.33.20.0.17

PROGRAM STUDI S.Tr TEKNOLOGI REKAYASA KOMPUTER

JURUSAN TEKNIK ELEKTRO

POLITEKNIK NEGERI SEMARANG

2024

SISTEM CERDAS MULTI-OUTPUT MODEL DEEP LEARNING PADA IDENTIFIKASI ALAT PELINDUNG DIRI DI LINGKUNGAN INDUSTRI

Skripsi ini disusun untuk melengkapi sebagian persyaratan menjadi Sarjana Terapan

Disusun oleh:

Muhammad Bagus Adi Prayoga

4.33.20.0.17

PROGRAM STUDI S.Tr TEKNOLOGI REKAYASA KOMPUTER

JURUSAN TEKNIK ELEKTRO

POLITEKNIK NEGERI SEMARANG

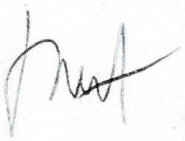
2024

PERNYATAAN KEASLIAN SKRIPSI

Saya menyatakan dengan sesungguhnya bahwa skripsi dengan judul **"*Sistem Cerdas Multi-output Model Deep Learning pada Identifikasi Alat Pelindung Diri di Lingkungan Industri*"** yang dibuat untuk melengkapi sebagian persyaratan menjadi Sarjana Terapan pada Program Studi Teknologi Rekayasa Komputer Jurusan Teknik Elektro Politeknik Negeri Semarang sejauh yang saya ketahui bukan merupakan tiruan atau duplikasi dari skripsi yang sudah dipublikasikan dan atau pernah dipakai untuk mendapatkan gelar Sarjana Terapan di lingkungan Politeknik Negeri Semarang maupun di perguruan tinggi atau instansi manapun, kecuali bagian yang sumber informasinya dicantumkan sebagaimana mestinya.

Semarang, 4 Juli 2024

Pelaksana,



Muhammad Bagus Adi Prayoga

NIM 4.33.20.0.17

HALAMAN PERSETUJUAN

Skripsi dengan judul **"*Sistem Cerdas Multi-output Model Deep Learning pada Identifikasi Alat Pelindung Diri di Lingkungan Industri*"** dibuat untuk melengkapi sebagian persyaratan menjadi Sarjana Terapan pada Program Studi Teknologi Rekayasa Komputer Jurusan Teknik Elektro Politeknik Negeri Semarang dan disetujui untuk diajukan dalam sidang ujian skripsi.

Semarang, 5 Juli 2024

Pembimbing I,	Pembimbing II,
Prayitno, S.ST., M.T., Ph.D.	Nurseno Bayu Aji, S.Kom., M.Kom.
NIP 198504102014041002	NIP 199107302019031010

Mengetahui,
Ketua Program Studi S.Tr Teknologi Rekayasa Komputer

Kuwat Santoso, S.Kom., M.Kom.
NIP 198407192019031008

HALAMAN PENGESAHAN

Skripsi dengan judul **"*Sistem Cerdas Multi-output Model Deep Learning pada Identifikasi Alat Pelindung Diri di Lingkungan Industri*"** telah dipertahankan dalam ujian wawancara dan diterima sebagai syarat untuk menjadi Sarjana Terapan pada Program Studi Teknologi Rekayasa Komputer Jurusan Teknik Elektro Politeknik Negeri Semarang pada tanggal 5 Juli 2024.

Tim Penguji

Penguji I,	Penguji II,	Penguji III,
Idhawati Hestiningsih, S. Kom., M. Kom.	Afandi Nur Aziz Thohari, S.T., M.Cs.	Wiktasari, S.T., M.Kom.
NIP. 197711192008012013	NIP. 199004112019031014	NIP. 198703272019032012

Ketua,	Sekretaris,
Prayitno, S.ST., M.T., Ph.D.	Suko Tyas Pernanda, M.Cs.
NIP. 198504102014041002	NIP. 199109172022031007

Mengesahkan,
Ketua Jurusan Teknik Elektro

Yusnan Bahruzzaman, S.T., M.Eng.
NIP. 197503132006041001

ABSTRAK

Muhammad Bagus Adi Prayoga, "Sistem Cerdas Multi-output Model Deep Learning pada Identifikasi Alat Pelindung Diri di Lingkungan Industri", Skripsi DIV Jurusan Teknik Elektro Politeknik Negeri Semarang, di bawah bimbingan Prayitno, S.ST., M.T., Ph.D. dan Nurseno Bayu Aji, S.Kom., M.Kom., Juli 2024.

Keselamatan pekerja di lingkungan industri bergantung pada penggunaan Alat Pelindung Diri (APD) yang benar. Penelitian ini mengusulkan sistem pembelajaran mendalam yang baru untuk mengatasi tantangan ini, dengan fokus pada industri konstruksi. Sistem yang dibangun menggunakan dua tahap pendekatan, pertama menggunakan model deteksi objek YOLOv8x untuk menemukan lokasi pekerja secara akurat di dalam gambar. Selanjutnya, model klasifikasi *multi-output* berbasis VGG16 menilai penggunaan helm, rompi, dan sepatu bot yang tepat untuk setiap pekerja yang terdeteksi. Evaluasi yang ketat pada kumpulan data yang beragam dari gambar beranotasi menunjukkan keefektifan sistem, mencapai *mean average precision* (mAP) sebesar 90,96% untuk deteksi pekerja dan rata-rata *F1-score* sebesar 89,42% untuk klasifikasi APD. Penggunaan model YOLOv8x menunjukkan peningkatan kinerja sekitar 1-2% dibandingkan model deteksi objek lainnya, sementara model VGG16 mengungguli model klasifikasi lain dengan peningkatan sekitar 1-16%. Integrasi kedua model ini menawarkan solusi efektif untuk meningkatkan pemantauan keselamatan di tempat kerja, sehingga menciptakan lingkungan yang lebih aman bagi pekerja konstruksi.

Kata Kunci: *Deep Learning,* Deteksi Objek, Klasifikasi *Multi-output,* Alat Pelindung Diri (APD), Keselamatan Konstruksi

ABSTRACT

Muhammad Bagus Adi Prayoga, "Deep Learning Model-Based Multi-output Intelligent System on Identification of Personal Protective Equipment in Industrial Environment", DIV Thesis, Department of Electrical Engineering, Politeknik Negeri Semarang, under the guidance of Prayitno, S.ST., M.T., Ph.D. and Nurseno Bayu Aji, S.Kom., M.Kom., July 2024.

Worker safety in industrial environments depends on the correct use of Personal Protective Equipment (PPE). This research proposes a novel deep learning system to address this challenge, focusing on the construction industry. The system utilizes a two-stage approach: first, the YOLOv8x object detection model accurately locates workers within images. Next, a VGG16-based multi-output classification model assesses the correct usage of helmets, vests, and boots for each detected worker. Rigorous evaluation on a diverse dataset of annotated images demonstrates the system's effectiveness, achieving a mean average precision (mAP) of 90.96% for worker detection and an average F1-score of 89.42% for PPE classification. The YOLOv8x model outperforms other object detection models by approximately 1-2%, while the VGG16 model surpasses other classification models with an improvement of about 1-16%. The integration of these two models offers an effective solution to enhance workplace safety monitoring, creating a safer environment for construction workers.

Keywords: Deep Learning, Object Detection, Multi-output Classification, Personal Protective Equipment (PPE), Construction Safety

KATA PENGANTAR

Puji dan syukur penulis panjatkan ke hadirat Allah SWT, atas limpahan rahmat dan karunia-Nya sehingga penulis dapat menyelesaikan skripsi ini dengan judul ***"Sistem Cerdas Multi-output Model Deep Learning pada Identifikasi Alat Pelindung Diri di Lingkungan Industri"*** yang disusun untuk memenuhi salah satu syarat menyelesaikan pendidikan Program Studi Sarjana Terapan Teknologi Rekayasa Komputer Jurusan Teknik Elektro Politeknik Negeri Semarang.

Dalam penyusunan skripsi, penulis banyak mendapatkan bantuan dan dukungan dari berbagai pihak sehingga segala prosesnya berjalan dengan baik. Oleh karena itu penulis ingin mengucapkan terimakasih kepada:

1. Allah SWT, atas rahmat dan karunia-Nya, serta limpahan nikmat yang diberikan.
2. Kedua orang tua dan keluarga tercinta yang telah memberikan doa, motivasi, dan segala bentuk dukungan.
3. Bapak Yusnan Badruzzaman, S.T., M.Eng. selaku Ketua Jurusan Teknik Elektro.
4. Bapak Kuwat Santoso, S.T., M.Kom. selaku Ketua Program Studi Sarjana Terapan Teknologi Rekayasa Komputer.
5. Bapak Prayitno, S.ST, M.T., Ph.D., dan Bapak Nurseno Bayu Aji, S.Kom., M.Kom., selaku Dosen Pembimbing yang memberikan arahan dan masukan kepada penulis mengenai proses penelitian dan penyusunan laporan.
6. Teman-teman Kelas TI-4A yang telah mendukung dan membantu penulis.
7. Seluruh pihak yang terlibat baik secara langsung maupun tidak langsung yang tidak bisa penulis sebutkan satu per satu dalam membantu penulis menyelesaikan laporan ini.

Penulis menyadari bahwa penyusunan skripsi ini masih banyak kekurangan. Oleh karena itu, penulis mengharapkan kritik dan saran dari semua pihak yang ingin memberikan masukan demi perkembangan positif bagi penulis. Demikian laporan

skripsi yang penulis susun, semoga dapat bermanfaat bagi semua pihak dan penulis sendiri. Akhir kata penulis ucapkan terimakasih.

Semarang, 4 Juli 2024



Muhammad Bagus Adi Prayoga

DAFTAR ISI

PERNYATAAN KEASLIAN SKRIPSI i
HALAMAN PERSETUJUAN ii
HALAMAN PENGESAHAN iii
ABSTRAK iv
ABSTRACT v
KATA PENGANTAR vi
DAFTAR ISI viii
DAFTAR GAMBAR x
DAFTAR TABEL xi
DAFTAR LAMPIRAN xii
BAB I PENDAHULUAN 1
1.1 Latar Belakang 1
1.1.1 Rumusan Masalah 2
1.1.2 Manfaat 2
1.1.3 Tujuan 3
1.2 Batasan Masalah 3
1.3 Sistematika Penulisan 4
BAB II TINJAUAN PUSTAKA 6
2.1 Landasan Teori 6
2.1.1 Kesehatan dan Keselamatan Kerja (K3) 6
2.1.2 Alat Pelindung Diri 7
2.1.3 Klasifikasi *Multi-output* 8
2.1.4 Deteksi Objek 9
2.1.5 *Convolutional Neural Network* (CNN) 10
2.1.6 *Cross-Industry Standard Process for Data Mining* (CRISP-DM) 12
2.2 Tinjauan Pustaka 12
BAB III KEGIATAN PELAKSANAAN 19
3.1 Pemahaman Bisnis 20
3.1.1 Latar Belakang 20

3.1.2 Tujuan 20
3.1.3 Ketersediaan Sumber Daya 20
3.1.4 Kebutuhan, Asumsi, dan Batasan 24
3.1.5 Risiko dan Rencana Mitigasi 25
3.1.6 Tolok Ukur Keberhasilan 25
3.2 Pemahaman Data 26
3.3 Persiapan Data 28
3.4 Pemodelan 29
3.4.1 Arsitektur Model 29
3.4.2 Pelatihan Model 36
3.5 Evaluasi 36
3.6 Deployment 39
BAB IV ANALISIS DAN PEMBAHASAN 40
4.1 Analisis Data 40
4.2 Analisis Pemodelan dan Evaluasi 41
4.2.1 *Hyperparameter* Model 42
4.2.2 Evaluasi Model Deteksi Objek 43
4.2.3 Evaluasi Model Klasifikasi *Multi-output* 46
4.3 Analisis *Deployment* 51
4.3.1 Pengujian Unggahan Pengguna 52
4.3.2 Pengujian Tangkapan *Webcam* 52
4.3.3 Pengujian Video *Real-time* 53
BAB V KESIMPULAN 55
5.1 Kesimpulan 55
5.2 Saran 55
DAFTAR PUSTAKA 57
LAMPIRAN 62

DAFTAR GAMBAR

Gambar 2.1 Hubungan antara PDCA dan kerangka kerja SNI ISO 45001:2018 ... 6
Gambar 2.2 Hierarki pengendalian risiko 7
Gambar 2.3 Diagram metodologi CRISP-DM..... 12
Gambar 3.1 Diagram metodologi CRISP-DM..... 19
Gambar 3.2 Sampel gambar pada dataset gabungan..... 27
Gambar 3.3 Format anotasi COCO..... 27
Gambar 3.4 Flowchart pelabelan data..... 28
Gambar 3.5 Contoh pelabelan gambar dengan format COCO 28
Gambar 3.6 Flowchart cara kerja gabungan kedua model..... 29
Gambar 3.7 Arsitektur model klasifikasi multi-output 30
Gambar 3.8 Tabel confusion matrix..... 38
Gambar 4.1 Confusion matrix deteksi pekerja YOLOv8x..... 44
Gambar 4.2 Sampel hasil prediksi model deteksi pekerja YOLOv8x 45
Gambar 4.3 Confusion matrix atribut APD helm model VGG16..... 48
Gambar 4.4 Confusion matrix atribut APD rompi model VGG16 49
Gambar 4.5 Confusion matrix atribut APD sepatu model VGG16 50
Gambar 4.6 Halaman beranda prototipe web..... 51
Gambar 4.7 Pengujian fitur unggahan pengguna..... 52
Gambar 4.8 Pengujian fitur tangkapan webcam 53
Gambar 4.9 Pengujian fitur video real-time..... 54

DAFTAR TABEL

Tabel 2.1 Perbandingan penelitian terdahulu 15
Tabel 3.1 Kebutuhan sumber daya perangkat lunak 23
Tabel 3.2 Persebaran data gambar dari berbagai sumber 26
Tabel 3.3 Arsitektur backbone AlexNet 31
Tabel 3.4 Arsitektur backbone VGG16 32
Tabel 3.5 Arsitektur backbone ResNet18 33
Tabel 3.6 Arsitektur backbone EfficientNetV2 34
Tabel 3.7 Arsitektur backbone MobilNetV3 35
Tabel 4.1 Distribusi label pada masing-masing atribut APD 40
Tabel 4.2 Distribusi pembagian dataset untuk model deteksi objek 41
Tabel 4.3 Distribusi pembagian dataset untuk model klasifikasi multi-output 41
Tabel 4.4 Hyperparameter model deteksi objek dan klasifikasi multi-output 42
Tabel 4.5 Perbandingan model deteksi objek 43
Tabel 4.6 Perbandingan performa model klasifikasi multi-output 47
Tabel 4.7 Perbandingan metadata model model klasifikasi multi-output 47

DAFTAR LAMPIRAN

Lampiran 1 Kode Program Model Klasifikasi APD Multi-output 62
Lampiran 2 Kode Program Model Deteksi Pekerja 64
Lampiran 3 Kode Program Deployment Prototipe Web 65
Lampiran 4 Lembar Kontrol Bimbingan 68
Lampiran 5 Surat Tugas 72
Lampiran 6 Form Revisi Skripsi 73
Lampiran 7 Surat Keterangan Selesai Revisi Skripsi 76

BAB I
PENDAHULUAN

1.1 Latar Belakang

Keselamatan dan Kesehatan Kerja (K3) merupakan pilar fundamental dalam mewujudkan lingkungan kerja yang aman, sehat, dan produktif bagi para pekerja [1]. Berdasarkan data Organisasi Perburuhan Internasional (ILO) di tahun 2018, angka kematian pekerja akibat faktor pekerjaan mencapai 2,6 juta jiwa, dengan 330.000 di antaranya dikarenakan kecelakaan kerja [2]. Di Indonesia sendiri, data BPJS Ketenagakerjaan menunjukkan tren kenaikan kasus kecelakaan kerja dalam lima tahun terakhir, dengan total 239,000 kasus hingga Agustus 2023 [3]. Peningkatan ini menunjukkan bahwa lebih banyak upaya diperlukan untuk mengurangi risiko dan meningkatkan keamanan tempat kerja.

Beberapa penelitian menunjukkan bahwa kelalaian dalam penggunaan Alat Pelindung Diri (APD) telah merenggut nyawa ribuan pekerja. Kematian tragis ini dapat dicegah dengan penggunaan APD yang sesuai, seperti topi pelindung, rompi pengaman, dan sepatu keamanan [4]. Peraturan Menteri Tenaga Kerja dan Transmigrasi Republik Indonesia Nomor 8 tahun 2010 mewajibkan penggunaan APD bagi seluruh pekerja yang memasuki tempat kerja. Namun, realita menunjukkan rendahnya kepatuhan terhadap regulasi ini. Survei menunjukkan bahwa 94% pekerja manufaktur dan 56,5% pekerja konstruksi tidak menggunakan APD saat bekerja, menjadi alarm bagi perlunya penegakan regulasi dan edukasi yang lebih gencar [5].

Hubungan erat antara pengawasan dan kepatuhan penggunaan APD ditegaskan oleh berbagai penelitian [6]. Fakta ini memperkuat peran krusial pengawasan dalam mendorong kepatuhan, di mana pekerja termotivasi untuk menggunakan APD demi menghindari konsekuensi seperti teguran atau pemberhentian [7]. Upaya pengawasan yang dilakukan oleh tim *Human Safety Environment* (HSE) sering kali bersifat manual dan rentan terhadap keterbatasan manusia yang efisiensinya menurun dalam durasi yang lama, sehingga tidak dapat memastikan tingkat kepatuhan yang memadai [8]. Sebagai upaya meningkatkan pengawasan

keselamatan proyek, sistem pengawasan cerdas mulai menggeser metode inspeksi manual tradisional [9]. Penelitian sebelumnya telah mengembangkan sistem deteksi objek APD tunggal, seperti helm dan rompi, namun sistem tersebut hanya berfokus pada identifikasi keberadaan APD tersebut tanpa mengaitkannya dengan pekerja yang seharusnya menggunakannya [3], [10], [11], [12]. Hal ini menyulitkan dalam membedakan pekerja yang menggunakan APD dengan yang tidak.

Oleh karena itu, penelitian ini mengusulkan pengembangan sistem yang tidak hanya mampu mendeteksi pekerja, tetapi juga mengidentifikasi jenis APD yang dikenakan oleh masing-masing pekerja. Solusi yang diusulkan adalah pengembangan "*Sistem Cerdas Multi-output Model Deep Learning Pada Identifikasi Alat Pelindung Diri Di Lingkungan Industri*". Sistem ini diharapkan dapat memberikan kontribusi signifikan dalam meningkatkan keamanan dan kepatuhan penggunaan APD di tempat kerja.

1.1.1 Rumusan Masalah

Berdasarkan latar belakang yang telah disajikan, rumusan masalah pada skripsi ini adalah sebagai berikut:

1. Bagaimana mengimplementasi model deteksi objek berbasis *deep learning* untuk mendeteksi pekerja di lokasi industri konstruksi secara efektif?
2. Bagaimana mengimplementasi model klasifikasi *multi-output* berbasis *deep learning* untuk mengklasifikasikan dengan akurat alat pelindung diri yang dikenakan oleh pekerja di lokasi industri konstruksi?

1.1.2 Manfaat

Manfaat pengembangan dan penerapan dari skripsi ini adalah sebagai berikut:

1.1.2.1 Secara Teoritis

Hasil pembuatan penelitian ini secara teoritis diharapkan dapat memberikan sumbangan pemikiran tentang implementasi deteksi dan klasifikasi *multi-output* pada alat pelindung diri di lingkungan industri konstruksi.

1.1.2.2 Secara Praktis

Hasil pembuatan penelitian ini secara praktis diharapkan dapat memudahkan suatu pihak untuk mengembangkan sistem pengawasan penggunaan alat pelindung diri pada lingkungan industri konstruksi dengan mengimplementasikan algoritma deteksi dan klasifikasi *multi-output* sesuai pada skripsi ini.

1.1.2.3 Secara Akademis

Hasil pembuatan penelitian ini dapat dijadikan sebagai acuan untuk penelitian sejenis terhadap penggunaan algoritma deteksi objek dan klasifikasi *multi-output* berbasis *deep learning*.

1.1.3 Tujuan

Tujuan dari penyusunan skripsi ini adalah sebagai berikut:

1. Mengimplementasi model deteksi objek berbasis *deep learning* untuk mendeteksi pekerja di lingkungan industri konstruksi secara efektif.
2. Mengimplementasi model klasifikasi *multi-output* berbasis *deep learning* untuk mengklasifikasikan dengan akurat alat pelindung diri yang dikenakan oleh pekerja di lingkungan industri konstruksi.
3. Mengetahui hasil evaluasi dari model deteksi objek dan klasifikasi *multi-output* berbasis *deep learning* pada citra lingkungan industri konstruksi, dengan fokus pada kinerja dan keakuratannya.

1.2 Batasan Masalah

Dalam pengembangan dan penerapan dari skripsi, masalah yang dibahas terbatas pada beberapa faktor, antara lain:

1. Penelitian ini menggunakan *dataset* citra publik yang terbatas pada konteks penggunaan alat pelindung diri di lingkungan industri konstruksi.
2. Model deteksi objek hanya mendeteksi pekerja dalam citra.
3. Model klasifikasi *multi-output* hanya mengklasifikasikan status penggunaan helm, rompi, dan sepatu pada pekerja yang terdeteksi.
4. Penelitian ini berfokus pada penggunaan algoritma deteksi objek dan klasifikasi *multi-output* berbasis *deep learning*.

5. Arsitektur model deteksi objek yang digunakan terbatas pada Faster R-CNN, RetinaNet, YOLOv5, dan YOLOv8.
6. Arsitektur model klasifikasi *multi-output* yang digunakan terbatas pada AlexNet, VGG16, ResNet18, EfficientNetV2, dan MobileNetV3.
7. Penelitian ini hanya menghasilkan prototipe web untuk mencoba model yang telah dilatih.

1.3 Sistematika Penulisan

Sistematika penulisan skripsi ini terdiri dari beberapa bab dan sub bab sebagai berikut:

BAB I PENDAHULUAN

Bab pendahuluan terdiri dari beberapa sub bab, yang berisi latar belakang yang juga meliputi rumusan masalah, manfaat pengembangan dan penerapan skripsi, dan tujuan pembuatan skripsi, batasan masalah skripsi, serta sistematika penulisan laporan skripsi.

BAB II TINJAUAN PUSTAKA

Bab tinjauan pustaka berisi landasan teori yang digunakan pada skripsi dan tinjauan pustaka mengenai penelitian-penelitian sebelumnya yang berkaitan dengan skripsi beserta perbandingannya.

BAB III KEGIATAN PELAKSANAAN

Bab kegiatan pelaksanaan berisi kegiatan pelaksanaan penelitian skripsi dengan menggunakan metodologi *Cross-Industry Standard Process for Data Mining* (CRISP-DM).

BAB IV ANALISIS DAN PEMBAHASAN

Bab analisis dan pembahasan berisi hasil dari analisis dan perbandingan pada masing-masing model yang telah dilatih.

BAB V KESIMPULAN

Berisi kesimpulan yang dijabarkan dari hasil analisis dan pembahasan skripsi.

DAFTAR PUSTAKA

Daftar pustaka berisi sumber pustaka yang dijadikan panduan dalam pengembangan dan pengerjaan laporan skripsi.

LAMPIRAN

Lampiran berisi dokumen tambahan yang dilampirkan ke dalam laporan skripsi.

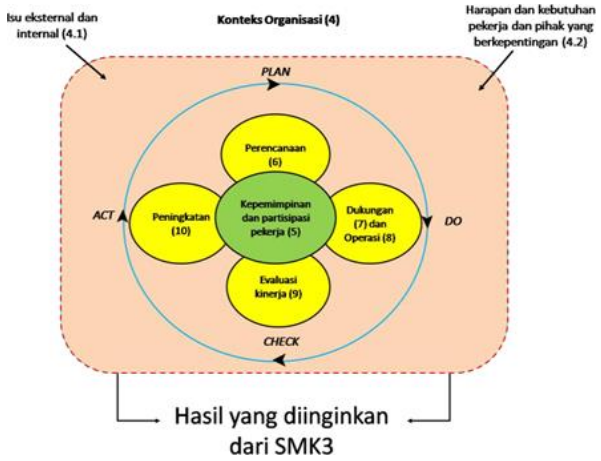
BAB II
TINJAUAN PUSTAKA

Bab ini membahas teori yang digunakan dalam penelitian ini dan penelitian sebelumnya tentang konsep skripsi "*Sistem Cerdas Multi-output Model Deep Learning Pada Identifikasi Alat Pelindung Diri Di Lingkungan Industri*", serta perbandingan antara masing-masing penelitian tersebut.

2.1 Landasan Teori

2.1.1 Kesehatan dan Keselamatan Kerja (K3)

K3 (Keselamatan dan Kesehatan Kerja) adalah sistem manajemen holistik yang mencakup penilaian risiko, pengendalian bahaya, pengawasan, pelatihan, dan promosi keselamatan kerja. Tujuan K3 adalah menciptakan lingkungan kerja yang aman dan sehat bagi karyawan, melindungi mereka dari cedera atau bahaya di tempat kerja. Manfaat utama K3 adalah mencegah, mengurangi, dan memadamkan risiko kecelakaan, kebakaran, dan ledakan. Selain itu, K3 memberikan panduan dan kesempatan untuk menyelamatkan diri saat keadaan darurat, sekaligus menyediakan pertolongan dan perlindungan jika terjadi kecelakaan atau keadaan darurat lainnya [13].



Gambar 2.1 Hubungan antara PDCA dan kerangka kerja SNI ISO 45001:2018

Penerapan K3 yang efektif melibatkan pendekatan sistematis yang dikenal sebagai siklus PDCA (*Plan, Do, Check, Act*). Tahap "*Plan*" (Perencanaan) berfokus pada identifikasi bahaya, penilaian risiko, dan pengembangan rencana pengendalian yang komprehensif. Selanjutnya, tahap "*Do*" (Pelaksanaan) melibatkan implementasi rencana pengendalian tersebut, termasuk penggunaan Alat Pelindung Diri (APD), pelatihan karyawan, dan pengawasan yang ketat. Tahap "*Check*" (Pemeriksaan) dilakukan untuk memantau dan mengevaluasi efektivitas pengendalian yang telah diterapkan, melalui inspeksi, audit, dan analisis data kecelakaan. Terakhir, tahap "*Act*" (Tindakan) melibatkan perbaikan berkelanjutan berdasarkan temuan dari tahap pemeriksaan, memastikan sistem K3 selalu ditingkatkan.

Hierarki Pengendalian juga merupakan prinsip penting dalam penerapan K3. Prinsip ini mengutamakan pengendalian risiko pada sumbernya, yaitu dengan eliminasi atau substitusi bahaya jika memungkinkan. Jika tidak memungkinkan, pengendalian teknis seperti isolasi dan ventilasi dapat diterapkan. Selanjutnya, pengendalian administratif seperti rotasi kerja dan pelatihan dapat digunakan untuk mengurangi risiko. Penggunaan Alat Pelindung Diri (APD) menjadi pilihan terakhir sebagai perlindungan tambahan bagi pekerja.



Gambar 2.2 Hierarki pengendalian risiko

2.1.2 Alat Pelindung Diri

Alat pelindung diri (APD) adalah alat penting yang digunakan untuk melindungi pekerja dari berbagai bahaya di tempat kerja, termasuk bahaya fisik, kimia, dan

biologis. Tujuan utama APD adalah meningkatkan keselamatan kerja dengan melindungi pekerja dari bahaya seperti jatuh dari benda, sengatan listrik, dan panas. Penggunaan APD yang tepat dan sesuai dengan jenis bahaya yang dihadapi di tempat kerja sangat penting untuk mencegah kecelakaan [14].

APD menjadi krusial ketika upaya pengendalian risiko pada tingkat yang lebih tinggi tidak memungkinkan atau tidak efektif. Pengawasan ketat terhadap penggunaan APD, meliputi kesesuaiannya dengan jenis bahaya, kondisi baik, dan penggunaan yang benar oleh pekerja, sangat penting untuk menjamin keselamatan dan kesehatan mereka. Selain itu, pelatihan dan edukasi komprehensif tentang penggunaan APD yang tepat harus diberikan kepada pekerja untuk meningkatkan kesadaran dan pemahaman mereka akan pentingnya APD dalam mencegah kecelakaan dan penyakit akibat kerja.

2.1.3 Klasifikasi *Multi-output*

Menurut Kamus Besar Bahasa Indonesia (KBBI), klasifikasi adalah pengelompokan sesuatu secara sistematis berdasarkan kaidah atau standar tertentu. Dalam konteks pembelajaran mesin, klasifikasi adalah tugas untuk memprediksi label atau kategori suatu objek berdasarkan fitur-fitur yang diberikan. Model klasifikasi dilatih menggunakan data yang telah diberi label sebelumnya, kemudian digunakan untuk memprediksi label data baru yang belum diketahui labelnya.

Klasifikasi *multi-output* adalah pendekatan pembelajaran mesin di mana satu model dapat menghasilkan beberapa prediksi secara bersamaan untuk satu input. Tidak seperti klasifikasi biner atau multi-kelas tradisional yang hanya menghasilkan satu prediksi, klasifikasi *multi-output* dapat menghasilkan banyak prediksi untuk setiap sampel data. Penggunaan satu model terpadu untuk tugas ganda adalah keunggulan utama metode ini. Ini memungkinkan pembelajaran yang lebih luas dan efektif dari fitur-fitur yang relevan untuk semua target prediksi [15].

Dalam konteks pengolahan citra menggunakan *Convolutional Neural Networks* (CNNs), klasifikasi *multi-output* melibatkan penggunaan satu jaringan CNN untuk menghasilkan beberapa prediksi secara bersamaan. Arsitektur CNN untuk klasifikasi *multi-output* terdiri dari lapisan input yang menerima gambar sebagai input, lapisan konvolusi yang mengekstraksi fitur-fitur penting dari gambar, dan

beberapa lapisan output yang masing-masing sesuai dengan target prediksi yang berbeda. Setelah melewati lapisan konvolusi, lapisan pemisah akan membagi fitur menjadi beberapa cabang, yang masing-masing terhubung dengan lapisan klasifikasi yang berbeda untuk tugas prediksi yang berbeda. Lapisan klasifikasi ini bertanggung jawab untuk memproses fitur-fitur yang relevan dengan tugasnya dan menghasilkan prediksi untuk target output tertentu.

Keunggulan utama dari pendekatan ini adalah bahwa proses ekstraksi fitur hanya terjadi sekali pada lapisan konvolusi dan digunakan bersama oleh semua lapisan klasifikasi [15]. Fitur-fitur yang diekstraksi ini dianggap sebagai lapisan bersama (*shared layer)*, yang berarti informasi yang dipelajari dari gambar input dapat dimanfaatkan secara efisien oleh semua tugas klasifikasi. Hal ini mempercepat proses pelatihan model karena tidak perlu melatih beberapa model terpisah untuk setiap tugas. Selain itu, penggunaan lapisan bersama juga dapat meningkatkan kinerja model karena memungkinkan transfer pengetahuan antar tugas [16].

2.1.4 Deteksi Objek

Deteksi objek adalah proses identifikasi dan lokalisasi objek dalam gambar atau video. Saat ini, kemajuan dalam *deep learning* dan *Convolutional Neural Networks* (CNNs) telah mengubah algoritma deteksi objek secara signifikan. Metode berbasis *deep learning* ini telah menggantikan pendekatan tradisional yang lebih sederhana dalam metode deteksi objek modern. CNN telah meningkatkan akurasi dan efisiensi deteksi objek secara signifikan karena kemampuannya untuk mempelajari fitur-fitur kompleks secara langsung dari data gambar [17]. Proses deteksi objek melibatkan dua langkah utama yaitu deteksi kotak pembatas (*bounding box*) untuk mengidentifikasi area potensial di mana objek berada, dan klasifikasi objek untuk menentukan jenis objek tersebut.

Model deteksi objek berbasis *deep learning* secara umum dapat dikategorikan menjadi dua jenis, yaitu *two-stage detector* dan *one-stage detector* [18]. *Two-stage detector* beroperasi dalam dua langkah yaitu pertama, menghasilkan beberapa *Region of Interest* (ROI) potensial yang mungkin mengandung objek, kemudian menyaring dan menyempurnakan ROI ini untuk mengklasifikasikan objek dan melokalisasi kotak pembatasnya dengan lebih akurat. Di sisi lain, *one-stage*

detector melakukan klasifikasi dan lokalisasi objek secara langsung dari peta fitur gambar tanpa melalui tahap ROI yang eksplisit. Perbedaan utama ini menghasilkan karakteristik kinerja yang berbeda, di mana *one-stage detector* umumnya lebih cepat namun cenderung kurang akurat, sementara *two-stage detector* menawarkan akurasi yang lebih tinggi namun dengan kecepatan yang lebih lambat [19].

Perkembangan deteksi objek berbasis *deep learning* dimulai dengan *two-stage detector* seperti R-CNN yang menggunakan algoritma pencarian selektif dan CNN untuk mengidentifikasi objek dalam gambar secara akurat namun relatif lambat [20]. Model ini kemudian disempurnakan menjadi Fast R-CNN dan Faster R-CNN untuk meningkatkan kecepatan pembelajaran. Di sisi lain, *one-stage detector* seperti YOLO muncul pada tahun 2016 dengan kemampuan untuk memprediksi kotak pembatas dan probabilitas kelas objek secara langsung dalam satu lintasan, sehingga lebih cepat dan cocok untuk aplikasi waktu nyata [21]. YOLO terus berkembang dengan pesat, ditandai dengan peluncuran versi-versi terbaru seperti YOLOv4 hingga YOLOv8, yang terus meningkatkan akurasi dan efisiensi model.

2.1.5 *Convolutional Neural Network* (CNN)

Convolutional Neural Networks (CNN) adalah jenis jaringan saraf tiruan yang menggunakan operasi konvolusi untuk memproses dan menganalisis gambar. Operasi konvolusi memungkinkan CNN untuk mempelajari atribut lokal gambar, seperti tepi, sudut, dan tekstur [22]. Kemudian informasi ini digabungkan untuk memahami gambar secara keseluruhan. Lapisan input, output, dan lapisan tersembunyi di antaranya adalah beberapa lapisan CNN.

Lapisan tersembunyi ini terdiri dari lapisan pooling, yang mempertahankan informasi penting sambil mengurangi dimensi data, dan lapisan konvolusi, yang menggunakan filter untuk mengekstraksi elemen penting dari gambar. Untuk memperkenalkan non-linearitas dan meningkatkan representasi model, CNN juga menggunakan fungsi aktivasi seperti ReLU. Kinerja dan stabilitas pelatihan ditingkatkan dengan teknik normalisasi *batch* dan lapisan. Lapisan terhubung penuh (*fully connected*) digunakan untuk mengklasifikasikan dan mengenali objek dalam gambar setelah melalui berbagai lapisan konvolusi dan *pooling*.

Perkembangan arsitektur CNN telah menghasilkan berbagai model yang sangat berpengaruh dalam tugas klasifikasi gambar, terutama pada *dataset* besar seperti ImageNet. Model-model ini tidak hanya meningkatkan akurasi klasifikasi gambar, tetapi juga menjadi dasar bagi banyak pengembangan deteksi objek berbasis CNN. Berdasarkan survei [23], beberapa arsitektur CNN yang umum digunakan yaitu:

1. AlexNet

   Model pelopor yang menggunakan fungsi aktivasi ReLU dan lapisan konvolusi untuk mencapai terobosan dalam klasifikasi gambar, memenangkan tantangan ImageNet 2012 [24].
2. VGG

   Arsitektur yang lebih dalam dengan beberapa lapisan konvolusi dan *max-pooling*, mencapai akurasi tinggi pada ImageNet 2014 [25].
3. ResNet

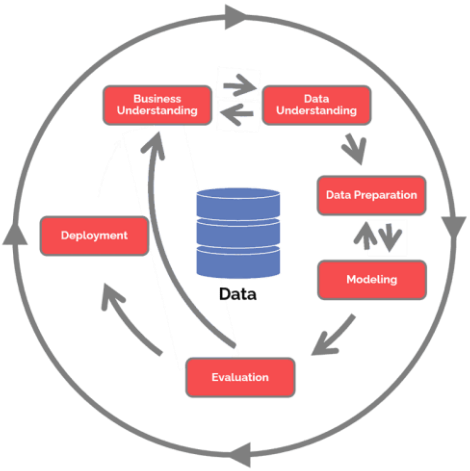
   Mengatasi masalah gradien menghilang (*vanishing gradient*) dengan koneksi pintas (*skip connection*), memungkinkan pelatihan model yang sangat dalam dan memenangkan tantangan ILSVRC 2015 [26].
4. MobileNet

   Dirancang untuk perangkat dengan sumber daya terbatas, menggunakan konvolusi *depthwise separable* untuk mengurangi ukuran model dan meningkatkan kecepatan komputasi [27].
5. EfficientNet

   Berfokus pada penskalaan model yang efisien dengan menyeimbangkan kedalaman, lebar, dan resolusi jaringan untuk mencapai akurasi tinggi dengan sumber daya komputasi yang lebih sedikit [28].

Kelima model *pre-trained* ini dipilih karena mewakili berbagai pendekatan dan kemajuan dalam arsitektur CNN. AlexNet merupakan model pelopor yang memberikan dasar pemahaman tentang bagaimana CNN dapat berhasil diterapkan dalam klasifikasi gambar. VGG menunjukkan pentingnya kedalaman jaringan untuk mencapai akurasi tinggi, sementara ResNet mengatasi masalah gradien hilang yang sering muncul pada jaringan yang sangat dalam. MobileNet dan EfficientNet dipilih karena fokusnya pada efisiensi, yang sangat relevan dalam konteks klasifikasi gambar pada perangkat dengan sumber daya terbatas.

2.1.6 *Cross-Industry Standard Process for Data Mining* (CRISP-DM)



Gambar 2.3 Diagram metodologi CRISP-DM

Cross-Industry Standard Process for Data Mining (CRISP-DM) adalah kerangka kerja terstruktur yang membimbing proses penambangan data [29]. Terdiri dari enam tahap utama yaitu pemahaman bisnis, pemahaman data, persiapan data, pemodelan, evaluasi, dan penyebaran. Tahap awal berfokus pada pemahaman mendalam tentang tujuan bisnis dan data yang tersedia, diikuti dengan persiapan data untuk analisis.

Tahap selanjutnya melibatkan pengembangan model penambangan data, evaluasi kinerja model, dan akhirnya, penerapan model ke dalam lingkungan bisnis. CRISP-DM menekankan sifat iteratif dari proses ini, memungkinkan penyesuaian dan perbaikan di setiap tahap. Pendekatan ini memastikan bahwa proyek penambangan data selaras dengan tujuan bisnis dan menghasilkan wawasan yang berharga untuk pengambilan keputusan.

2.2 Tinjauan Pustaka

Bagian tinjauan pustaka ini menyajikan hasil kajian mendalam terhadap beberapa jurnal ilmiah terkemuka yang menjadi fondasi dalam pengembangan penelitian ini. Informasi yang disajikan bertujuan untuk memberikan landasan teoretis yang kuat serta memperkaya pemahaman mengenai metode dan pendekatan yang digunakan dalam penelitian ini.

Penelitian yang dilakukan oleh Hatami et al., mengembangkan sistem deteksi helm dan rompi keselamatan secara *real-time* menggunakan YOLOv2. Sistem ini menunjukkan mAP sebesar 76,68% dan akurasi akhir sebesar 81,60%. Selain itu, menurut penelitian ini hasil deteksi dipengaruhi oleh pencahayaan, posisi objek kamera, dan tinggi objek [10].

Penelitian yang dilakukan oleh Nurfirmansyah dan Dijaya, mengembangkan sistem deteksi kelalaian 10 kelas APD pada pekerja konstruksi bangunan menggunakan YOLOv4. Sistem ini diuji dengan *webcam* dan CCTV, dan mencapai akurasi rata-rata 80%. Akurasi yang lebih tinggi dapat dicapai dengan menggunakan GPU berkualitas tinggi serta resolusi kamera yang baik [11].

Penelitian yang dilakukan oleh Nugroho et al., mengembangkan sistem klasifikasi helm keselamatan menggunakan CNN, yang mencapai akurasi rata-rata 81%. Sistem ini dapat ditingkatkan dengan menggunakan gambar yang lebih jelas dan arsitektur CNN yang lebih efektif [12].

Penelitian yang dilakukan oleh Adiwibowo et al., menggunakan metode deteksi kepala pekerja YOLOv3 dan deteksi APD Faster R-CNN untuk mendeteksi alat pelindung diri pada kepala pekerja. Hasil pengujian menunjukkan akurasi 73,83% untuk YOLOv3 dalam deteksi objek kepala dan 93,61% untuk Faster R-CNN dalam deteksi APD. Selain itu, penelitian ini juga membandingkan penggunaan *dataset* latih yang heterogen dan homogen, dan menemukan bahwa *dataset* heterogen memberikan hasil yang lebih baik [30].

Penelitian yang dilakukan oleh Mailoa dan Santoso, menggunakan metode deteksi kepala dan badan YOLOv3 diikuti dengan klasifikasi APD helm dan rompi menggunakan CNN ResNet50. Hasil pengujian menunjukkan akurasi deteksi kepala dan badan sebesar 64,09% dan 63,03%, serta akurasi klasifikasi APD sebesar 96%. Akan tetapi, proses deteksi pada banyak objek (kepala dan badan) hanya mampu berhasil mendeteksi 2 atau 3 objek saja [31].

Penelitian yang dilakukan oleh Nugraha dan Rifai, menggunakan CNN berbasis YOLOv4 dan YOLOv5 untuk mendeteksi penggunaan berbagai jenis APD di

laboratorium. Hasil pengujian menunjukkan mAP tertinggi pada YOLOv5 *Transfer Learning*, yakni 88,6% [3].

Penelitian yang dilakukan oleh Shi et al, mengusulkan Improved YOLOv5 dengan penambahan BoT dan *self-attention mechanism* untuk meningkatkan performa dan mengurangi jumlah parameter dalam mendeteksi APD pada lokasi kerja listrik. Hasil eksperimen menunjukkan peningkatan mAP sebesar 2% dari YOLOv5 biasa [9].

Penelitian yang dilakukan oleh Delhi et al., menggunakan YOLOv3 untuk mendeteksi kepatuhan penggunaan APD pada lokasi konstruksi. Hasil pengujian pada set validasi mencapai F1-score 96% dan tingkat *precision* serta *recall* rata-rata 96%. Terdapat beberapa keterbatasan, seperti kecepatan inferensi hanya 2 *frame per second* dan potensi kesalahan klasifikasi pada helm akibat ketidakcocokan warna [32].

Penelitian yang dilakukan oleh Gallo et al., membandingkan beberapa arsitektur model deteksi objek untuk mendeteksi APD di lingkungan industri. Hasil pengujian menunjukkan bahwa YOLOv4 mencapai mAP@50 sebesar 95,3%, sementara YOLOv4-Tiny memiliki performa FPS terbaik dengan 6,8. Hasil eksperimen menunjukkan adanya pertukaran (*trade-off*) antara akurasi dan kemampuan model dalam bekerja secara *real-time* [33].

Penelitian yang dilakukan oleh Pradana et al., menggabungkan CNN untuk deteksi APD pada area kepala dan sensor *Inductive Proximity* untuk deteksi sepatu keamanan. Hasil pengujian menunjukkan akurasi 85,83% untuk APD pada area kepala. Namun, terdapat kendala dalam membedakan antara kacamata keamanan ketika diimplementasikan secara *real-time* [34].

Penelitian yang dilakukan oleh Lee et al., mengembangkan YOLO-EfficientNet yang telah berhasil mengatasi keterbatasan *multi-class object-detection* dalam kasus deteksi helm keamanan. Pendekatan ini membagi proses deteksi menjadi dua tahap yaitu mendeteksi kepala pekerja dan mengklasifikasikan setiap kepala, menghasilkan akurasi yang lebih tinggi, mengurangi komputasi, dan mengurangi kebutuhan *dataset* yang heterogen [35].

Penelitian yang dilakukan oleh Stephen et al., mengembangkan CNN *dual-output* untuk klasifikasi *fashion* dengan akurasi 98% untuk jenis *fashion* dan 95% untuk warnanya. Pendekatan *multiple-loss multi-output* CNN memungkinkan jaringan belajar dan melakukan klasifikasi pada dua tugas secara bersamaan, yang dapat meningkatkan kinerja pada kedua tugas tersebut [16].

Penelitian yang dilakukan oleh Yao et al., mengembangkan *Generalised Stacking Multi-output* CNN (GSMo-CNN) untuk klasifikasi tanaman dan penyakit dengan akurasi dan *F1-score* yang lebih tinggi dibandingkan dengan model lainnya. GSMo-CNN menggunakan *transfer learning* dan pendekatan *multi-output* untuk meningkatkan kinerjanya dan proses pelatihan yang lebih cepat [15].

Penelitian yang dilakukan oleh Zhou et al., mengembangkan model DM-LSTM untuk prakiraan kualitas udara multi-langkah ke depan dengan akurasi yang lebih tinggi dibandingkan dengan model lain. DM-LSTM menggunakan pendekatan *multi-output* untuk meramalkan PM2.5, PM10, dan NOx secara bersamaan [36].

Penelitian yang dilakukan oleh Jo et al., mengembangkan model *deep learning* untuk klasifikasi *sleep stage* dan *apnea* secara bersamaan menggunakan pendekatan *multi-output*. Model yang diusulkan dapat secara efektif mengklasifikasikan kedua tugas tersebut dengan satu model yang memiliki akurasi dan *F1-score* yang tinggi [37].

Berdasarkan tinjauan pustaka sebelumnya, Tabel 2.1 menyajikan perbandingan antara *dataset* yang digunakan, pendekatan dan metode, serta hasil yang dicapai dalam penelitian terkait.

Tabel 2.1 Perbandingan penelitian terdahulu

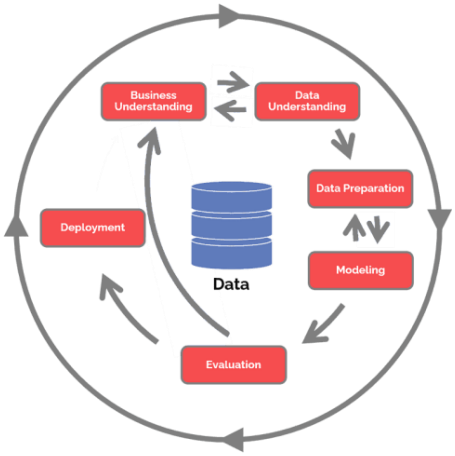
No	Penelitian	*Dataset*	Pendekatan dan Metode	Hasil
1	[10]	VOC2008 (1500 citra) dan INRIA (1500 citra)	*Object detection*; CNN YOLO (*Pre-trained* YOLOv2)	Pengujian dengan 90 citra pada 9 skenario yang berbeda menghasilkan 82% *precision*, 82% *recall*, dan 79% *F1-score*

No	Penelitian	*Dataset*	Pendekatan dan Metode	Hasil
2	[11]	*Dataset* privat (1142 citra)	*Object detection*; YOLOv2	Hasil pelatihan yaitu 76,68% mAP dan 87,93% Avg IoU. Pengujian dengan 5 citra menghasilkan akurasi sebesar 81,60%
3	[12]	*Dataset* privat (500 citra)	*Object detection*; YOLOv4	Hasil pelatihan yaitu 99,99% mAP dan 86,94% Avg IoU. Pengujian dengan 4 citra menghasilkan akurasi sebesar 80%
4	[30]	Tidak ada informasi	I*mage classification*; CNN	Pengujian pada *test* set menghasilkan 81% *accuracy*, 75% *precision*, 94% *recall*, dan 83% *F1-score*
5	[31]	Open Images Dataset, YOLO, dan Google; Tidak ada informasi mengenai jumlahnya	*Object detection*; YOLOv3 (deteksi kepala) dan Faster R-CNN (deteksi APD)	Hasil pengujian pada YOLOv3 menghasilkan akurasi sebesar 73,83% dan Faster R-CNN menghasilkan akurasi sebesar 93,61%
6	[3]	*Dataset* publik dari Roboflow (2738 citra)	*Object detection* dan *image classification*; YOLOv3 (deteksi kepala dan badan) dan CNN ResNet50 (klasifikasi APD)	Hasil pengujian pada YOLOv3 menghasilkan akurasi deteksi kepala sebesar 64,09% dan akurasi deteksi badan sebesar 63,03%. Sedangkan pengujian pada Faster R-CNN menghasilkan akurasi sebesar 96%.
7	[9]	*Dataset* privat (1235 citra) dan	*Object detection*; YOLOv4,	Hasil pengujian terbaik pada model YOLOv5 *Transfer*

No	Penelitian	*Dataset*	Pendekatan dan Metode	Hasil
		dataset sintesis dengan *data augmentation*	YOLOv5 *from scratch*, dan YOLOv5 Transfer Learning	*Learning* dengan mAP sebesar 88,6%.
8	[32]	*Dataset* public dari *web crawling* (5015 citra)	*Object detection*; Improved YOLOv5 dengan penambahan BoT dan *self attention mechanism*	Hasil pelatihan pada metode yang diusulkan yaitu mAP sebesar 87,1%, dimana ada peningkatan 2% dari YOLOv5 biasa
9	[33]	Campuran *dataset* privat dan publik dari *web crawling* (2509 citra)	*Object detection*; YOLOv3	Hasil pengujian pada *validation set* yaitu *F1-score* sebesar 96% dan *precision* serta *recall* sebesar 96%.
10	[34]	Campuran *dataset* privat dan publik (7486 citra)	*Object detection*; YOLOv4, YOLOv4-Tiny, SSD MobileNet, CenterNet, dan EfficientDet D0	Hasil pengujian menunjukkan bahwa YOLOv4 mencapai mAP@50 terbaik yaitu sebesar 95,3%, sementara YOLOv4-Tiny memiliki performa FPS terbaik dengan 6,8.
11	[35]	*Dataset* publik dari Roboflow, *Crawling*, dan Kaggle (21568 citra)	Dual model yang terdiri dari model *object detection* (YOLOv5x) dan *image classification* (EfficientNetB7)	Hasil pengujian menghasilkan performa mAP@50 sebesar 91,4% dan F1-score sebesar 93,7%.
12	[16]	DeepFashion (2167 citra)	*Multi-output image*	Hasil pengujian menghasilkan akurasi 98% pada *fashion*

No	Penelitian	*Dataset*	Pendekatan dan Metode	Hasil
			classification; CNN dengan VGG16 sebagai *backbone*-nya	*block* dan 95% pada *color block.*
13	[15]	*Benchmark dataset* diantaranya yaitu Plant Village, Plant Leaves, PlantDoc-0.2, dan PlantDoc-0.1	*Multi-output image classification*; Generalised Stacking Multi-output CNN (GSMo-CNN)	Model GSMo-CNN dengan Bal*anced Weights Transfer Learning* (*Backbone* InceptionV3) mencapai kinerja yang baik pada semua *dataset benchmark*. Model ini secara signifikan meningkatkan *akurasi* dan skor F1 di semua dataset dibandingkan dengan model lainnya.
14	[36]	*Dataset* privat dari stasiun pemantauan udara di kota Taipei, Taiwan	*Multi-output forecasting*; Deep learning based multi-output LSTM (DM-LSTM)	Model DM-LSTM yang diusulkan secara signifikan meningkatkan stabilitas *spatio-temporal* dan akurasi prakiraan kualitas udara dibandingkan dengan model Shallow Multi-output LSTM (SM-LSTM).
15	[37]	*Dataset* ISRUC-Sleep	*Multi-output classification*; SleepExpertNet	Hasil pengujian pada *test set* menunjukkan akurasi dan skor F1 rata-rata mikro sebesar 99% untuk klasifikasi *apnea*, serta akurasi dan *F1-score* rata-rata mikro sebesar 69% untuk klasifikasi tahap tidur.

BAB III
KEGIATAN PELAKSANAAN



Gambar 3.1 Diagram metodologi CRISP-DM

Kegiatan pelaksanaan penelitian ini menggunakan metodologi *Cross-Industry Standard Process for Data Mining* (CRISP-DM). Dimana metodologi ini merupakan pendekatan yang paling banyak digunakan untuk melaksanakan proyek-proyek penambangan data.

Metodologi ini mencakup enam langkah, yang masing-masing digambarkan pada Gambar 3.1, yaitu:

1. Pemahaman Bisnis: memahami tujuan proyek dan masalah yang akan dipecahkan dengan penambangan data..
2. Pemahaman Data: mengumpulkan dan menganalisis data untuk mengetahui kualitas dan relevansinya.
3. Persiapan Data: melakukan pembersihan, transformasi, dan integrasi data untuk memastikan data siap digunakan dalam proses pemodelan.
4. Pemodelan: membangun model yang sesuai dengan tujuan proyek dan karakteristik data.
5. Evaluasi: uji model untuk memastikan keakuratan dan kemampuannya mencapai tujuan.
6. *Deployment*: mengimplementasikan model yang telah dilatih dalam lingkungan produksi dan didokumentasikan dengan baik.

3.1 Pemahaman Bisnis

3.1.1 Latar Belakang

Keselamatan dan Kesehatan Kerja (K3) menjadi perhatian utama dalam menciptakan lingkungan kerja yang aman dan produktif. Namun, data dari Organisasi Perburuhan Internasional (ILO) dan BPJS Ketenagakerjaan menunjukkan tingginya angka kecelakaan kerja, baik secara global maupun di Indonesia. Salah satu faktor penyebab utama kecelakaan kerja adalah kelalaian dalam penggunaan Alat Pelindung Diri (APD). Meskipun regulasi mewajibkan penggunaan APD, tingkat kepatuhan masih rendah di berbagai sektor industri.

Pengawasan penggunaan APD menjadi kunci dalam meningkatkan kepatuhan, tetapi metode manual yang ada memiliki keterbatasan. Oleh karena itu, diperlukan solusi inovatif untuk mengotomatiskan dan meningkatkan efisiensi pengawasan APD. Salah satu solusi yang menjanjikan adalah penggunaan teknologi *computer vision* dengan pendekatan klasifikasi *multi-output*. Pendekatan ini memungkinkan pengembangan sistem yang dapat secara otomatis mendeteksi dan mengklasifikasikan penggunaan APD secara *real-time* dari gambar atau video. Dengan demikian, diharapkan tingkat kepatuhan penggunaan APD dapat ditingkatkan, sehingga risiko kecelakaan kerja dapat diminimalkan.

3.1.2 Tujuan

Tujuan dari pembuatan penelitian ini adalah sebagai berikut:

1. Mengimplementasikan model deteksi objek berbasis *deep learning* untuk mendeteksi pekerja di lingkungan industri konstruksi secara efektif.
2. Mengimplementasikan model klasifikasi *multi-output* berbasis *deep learning* untuk mengklasifikasikan dengan akurat alat pelindung diri yang dikenakan oleh pekerja di lingkungan industri konstruksi.

3.1.3 Ketersediaan Sumber Daya

Ketersediaan sumber daya merupakan faktor penting dalam keberhasilan penelitian ini, mencakup sumber data, perangkat keras, dan perangkat lunak. Berikut adalah beberapa sumber data yang akan digunakan selama penelitian:

3.1.3.1 Sumber Daya Data

1. *Color Helmet and Vest Dataset* (CHV) [38]

   CHV adalah *dataset* publik yang terdiri dari 1330 gambar berkualitas tinggi dari lokasi konstruksi nyata, yang dipilih dari lebih dari 10.000 gambar berdasarkan kriteria ketat, termasuk latar belakang konstruksi yang relevan, berbagai pose orang, sudut objek dan jarak, serta jumlah kelas. *Dataset* ini berisi 6 kelas objek yaitu orang, rompi, dan 4 warna helm (kuning, putih, merah, dan biru), dengan total 9209 objek. Setiap objek diberi anotasi dengan label kelas dan kotak pembatas (*bounding box*). 80% dari gambar digunakan untuk pelatihan, 10% untuk validasi, dan 10% untuk pengujian model deteksi objek. Sebagian besar objek berukuran kecil (area $\leq$ 322 px2), yang menambah tantangan dalam proses deteksi. Dataset CHV tersedia secara publik di repositori GitHub dari penulis (https://github.com/ZijianWang-ZW/PPE_detection).

2. *Construction Personal Protective Equipment Dataset* (CPPE) [39]

   CPPE adalah *dataset* baru yang terdiri dari 932 gambar berkualitas tinggi yang dikumpulkan dari *dataset* publik dan gambar dari internet. *Dataset* ini mencakup berbagai aktivitas konstruksi, kondisi pencahayaan, oklusi, dan resolusi, dengan total 2747 objek helm, 1339 objek rompi keselamatan, dan 3428 objek pekerja. *Dataset* ini dibagi menjadi 627 gambar pelatihan dan 305 gambar pengujian, dengan anotasi yang mencakup penggunaan helm dan rompi yang benar dan tidak benar. CPPE dikembangkan untuk mengatasi keterbatasan *dataset* yang ada dan memberikan sumber daya yang komprehensif untuk melatih dan mengevaluasi model deteksi APD. *Dataset* CPPE dapat diakses pada repositori Github dari penulis (https://github.com/ruoxinx/PPE-Detection-Pose/).

3. *Site Object Detection Dataset* (SODA) [40]

   SODA adalah *dataset* gambar berskala besar yang dibuat khusus untuk konstruksi. *Dataset* ini terdiri dari 19.846 gambar dari berbagai lokasi konstruksi, kondisi cuaca, dan fase konstruksi, mencakup berbagai sudut dan perspektif. SODA mencakup 15 kelas objek yang dikategorikan menjadi pekerja, material, mesin, dan tata letak, dengan total 286.201 objek.

Dataset ini telah dianotasi secara manual dengan label sesuai kategori yang telah ditentukan, dan analisis statistik menunjukkan bahwa *dataset* ini beragam dan besar. *Dataset* SODA tersedia secara publik pada web resmi dari penulis (https://linjiarui.net/en/portfolio/2022-02-22-SODA-site-object-detection-dataset-for-deep-learning-in-construction).

4. Microsoft *Common Objects in Context Dataset* (MS COCO) [41]

   MS COCO adalah *dataset* besar yang dirancang untuk memajukan penelitian dalam pengenalan objek dan segmentasi. *Dataset* ini mencakup berbagai macam kategori objek sehari-hari dalam konteks alami mereka, termasuk orang dalam berbagai pose dan situasi. MS COCO memiliki lebih dari 2,5 juta objek berlabel, dengan hampir 270.000 objek tersegmentasi dari kategori objek orang dalam data pelatihan dan validasi tahun 2014 saja. *Dataset* ini secara khusus ditujukan untuk tugas-tugas seperti mendeteksi orang dalam berbagai pandangan non-ikonik (misalnya, sebagian tersembunyi, di tengah keramaian) dan melokalisasi orang secara tepat dalam gambar menggunakan segmentasi per objek. Fokus pada objek orang dalam konteks sehari-hari menjadikannya sumber daya yang berharga untuk melatih dan mengevaluasi model yang bertujuan memahami adegan yang kompleks secara visual. Bagian dari *dataset* COCO yang hanya berisi objek manusia dapat diakses melalui Roboflow (https://universe.roboflow.com/shreks-swamp/coco-dataset-limited--person-only/browse).

5. *Safety Boots Dataset* [42]

   Safety Boots Dataset merupakan kumpulan data gambar publik yang terdiri dari 396 gambar yang menampilkan pekerja dalam berbagai situasi di lingkungan kerja. *Dataset* ini secara khusus difokuskan pada deteksi sepatu keamanan (*safety boots*) yang dikenakan oleh pekerja. Dengan total 755 objek sepatu, dataset ini menyediakan sumber daya berharga untuk melatih model pembelajaran mesin dalam mendeteksi penggunaan sepatu keamanan. *Dataset* ini diharapkan dapat meningkatkan keselamatan kerja dengan memastikan penggunaan perlengkapan pelindung yang tepat. *Dataset* ini tersedia secara umum pada situs Roboflow (https://universe.roboflow.com/ppe-datacustom/safety-boots-rmxcj).

3.1.3.2 Sumber Daya Perangkat Lunak dan Keras

Sumber daya perangkat lunak yang digunakan dalam penelitian ini beserta dengan fungsinya masing-masing dapat dilihat pada Tabel 3.1.

Tabel 3.1 Kebutuhan sumber daya perangkat lunak

No	Nama Perangkat Lunak	Fungsi
1	Kaggle	Menyediakan lingkungan komputasi, dan akses GPU untuk melatih model
2	Visual Studio Code	Editor kode untuk menulis dan mengedit kode sumber
3	CVAT (*Computer Vision Annotation Tool)*	Menganotasi data gambar untuk proyek deteksi objek, klasifikasi, dan segmentasi
4	CometML	Melacak eksperimen, visualisasi metrik, dan mengelola model yang telah dilatih
5	Python	Bahasa pemrograman utama yang digunakan untuk mengembangkan penelitian ini
6	OpenCV	Pustaka untuk pemrosesan citra dan visi komputer
7	Numpy	Pustaka untuk komputasi numerik dengan *array* dan matriks
8	PyTorch	Pustaka *deep learning* untuk membangun dan melatih model
9	Lightning	Menyederhanakan pelatihan PyTorch dan meningkatkan produktivitas
10	Ultralytics	*Framework* untuk melatih model deteksi objek YOLO
11	Detectron2	*Framework* untuk deteksi dan segmentasi objek
12	ONNX	Format model yang *open-source* dan portabel untuk *framework* yang berbeda
13	Streamlit	Membuat aplikasi web untuk menampilkan hasil penelitian

Sumber daya perangkat keras utama yang digunakan dalam penelitian ini adalah laptop Acer E5-475G. Laptop ini memiliki spesifikasi sebagai berikut:

- Sistem Operasi: Windows 10
- Prosesor: Intel® Core™ i3-7100U
- Memori (RAM): 4GB
- Layar: 14 inci dengan resolusi HD (1366 x 768)
- Penyimpanan: 1TB HDD
- Kartu Grafis: NVIDIA® GeForce® 940MX dengan 2GB GDDR5 VRAM

Dalam melatih model *deep learning* baik untuk tugas deteksi objek pekerja maupun klasifikasi *multi-output* APD, akan menggunakan sumber daya dari Kaggle dengan GPU P100. Berikut adalah spesifikasi lengkapnya:

- Sistem Operasi: Linux
- Prosesor: Intel® Xeon® CPU @ 2.20GHz
- Memori (RAM): 16GB
- Penyimpanan: 155GB
- Kartu Grafis: NVIDIA® Tesla® dengan 16GB GDDR5 VRAM dan 3584 CUDA core

3.1.4 Kebutuhan, Asumsi, dan Batasan

1. Kebutuhan

   Penelitian ini membutuhkan data gambar dari lokasi konstruksi yang representatif dan mencakup berbagai skenario penggunaan APD. Data ini idealnya berasal dari *dataset* publik yang sudah ada dan mencakup variasi sudut pengambilan gambar dan jenis APD yang digunakan.

2. Asumsi

   Kualitas *dataset* publik yang digunakan dalam penelitian ini diasumsikan sudah cukup baik dan representatif untuk melatih model *deep learning* untuk mendeteksi tiga jenis APD utama yaitu helm, rompi, dan sepatu.

3. Batasan

   Sistem ini dibatasi untuk mendeteksi kepatuhan APD dengan mendeteksi pekerja terlebih dahulu, kemudian mengklasifikasikan APD berdasarkan

hasil deteksi pekerja menggunakan model *multi-output*. Meskipun model telah dilatih dengan *dataset* publik yang luas, kesalahan prediksi di dunia nyata masih mungkin terjadi karena kondisi lapangan yang beragam dan berubah-ubah mungkin tidak sepenuhnya diwakili dalam *dataset* tersebut.

3.1.5 Risiko dan Rencana Mitigasi

1. Risiko

   Terdapat risiko bahwa data yang diperoleh dari berbagai sumber *dataset* publik mungkin tidak sepenuhnya relevan dengan kebutuhan penelitian, mengandung *noise* atau data yang tidak perlu, dan memiliki format anotasi yang tidak sesuai untuk pelatihan model klasifikasi *multi-output*.

2. Rencana Mitigasi

   Proses pembersihan dan penyaringan data secara menyeluruh akan dilakukan untuk memastikan kualitas dan relevansi data. Data dari semua sumber *dataset* akan dipilih secara sampel dengan fokus pada gambar yang relevan dengan penelitian, yaitu gambar yang mengandung objek manusia dan pekerja yang menggunakan APD. Selanjutnya, data yang terpilih akan dianotasi ulang menggunakan format COCO (*Common Objects in Context*). Format COCO dipilih karena memiliki atribut untuk setiap objek, termasuk *bounding box* dan label kelas, yang sesuai untuk melatih model klasifikasi *multi-output*. Dengan demikian, data yang digunakan akan lebih bersih, relevan, dan sesuai dengan kebutuhan penelitian.

3.1.6 Tolok Ukur Keberhasilan

Tolok ukur keberhasilan dari penelitian ini adalah sebagai berikut:

1. Metrik *mean Average Precision* (mAP) pada ambang batas *Intersection over Union* (IoU) sebesar 50% (mAP@50) harus melebihi 75% untuk menilai efektivitas model identifikasi objek pekerja.
2. Nilai *F1-score* rata-rata untuk masing-masing dari tiga kelas APD (helm, rompi, dan sepatu) harus lebih besar dari 85% untuk menentukan seberapa baik kinerja model klasifikasi *multi-output* untuk fitur APD.

3.2 Pemahaman Data

Proses pengumpulan data gambar untuk penelitian ini dilakukan dengan mengambil sampel dari beberapa sumber data publik, antara lain *Color Helmet and Vest Dataset* (CHV), *Construction Personal Protective Equipment Dataset* (CPPE), *Site Object Detection Dataset* (SODA), Microsoft *Common Objects in Context Dataset* (MS COCO), dan *Safety Boots Dataset*. Pemilihan sampel bertujuan untuk mendapatkan representasi data yang beragam dan mencakup berbagai kondisi di lokasi konstruksi, namun tetap mempertimbangkan keterbatasan waktu dan sumber daya dalam pelabelan ulang data.

Tabel 3.2 Persebaran data gambar dari berbagai sumber

Dataset	**Jumlah Gambar**
CHV	1321
CPPE	229
SODA	251
MS COCO	180
Safety Boots	118
Total	2099

Proses pengambilan sampel data gambar dari berbagai sumber *dataset* publik digambarkan dalam Tabel 3.2. Seluruh 1321 gambar dari *dataset* CHV dimasukkan dalam kumpulan *dataset* ini. Hal tersebut dikarenakan *dataset* CHV menawarkan cakupan luas terhadap kondisi di lokasi konstruksi, termasuk latar belakang yang sesuai, pose pekerja yang beragam, serta variasi sudut dan jarak objek. Sebanyak 229 gambar dipilih dari *dataset* CPPE untuk menghindari duplikasi data dengan CHV. Pemilihan ini dilakukan karena CPPE merupakan hasil penggabungan CHV dengan *dataset* lainnya.

Untuk menambah variasi sudut pandang, 251 gambar pekerja dari jarak jauh diambil dari *dataset* SODA, yang secara khusus menonjolkan pengambilan gambar pekerja dari kejauhan. Selanjutnya, 180 gambar manusia (person) dari dataset MS COCO ditambahkan untuk melengkapi data pekerja tanpa APD, mengingat tiga *dataset* sebelumnya lebih berfokus pada pekerja yang menggunakan APD. Terakhir, *dataset Safety Boots* yang terdiri dari 118 gambar pekerja yang

menggunakan sepatu keamanan ditambahkan. Hal ini bertujuan untuk memperkaya sampel pekerja yang menggunakan atribut APD ini, karena pada *dataset* sebelumnya banyak pekerja yang tidak terlihat bagian bawah badannya. Kombinasi keempat *dataset* ini menghasilkan total 2099 gambar dengan variasi yang beragam, sebagaimana ditunjukkan pada Gambar 3.2.

Dataset yang telah disusun ini memerlukan proses anotasi dengan format Microsoft COCO sebelum dapat digunakan untuk melatih model deteksi objek dan klasifikasi *multi-output*. Pemilihan format ini didasarkan pada struktur datanya yang konsisten, kompatibilitasnya dengan berbagai model *deep learning*, serta atribut pada setiap objek yang akan berfungsi sebagai label dalam pelatihan model klasifikasi *multi-output*. Struktur *dataset* yang telah diformat menggunakan Microsoft COCO diilustrasikan pada Gambar 3.3.



Gambar 3.2 Sampel gambar pada dataset gabungan

```
{
  "info": info,
  "images": [image],
  "annotations": [annotation],
  "licenses": [license]
}

image {
  "id": int,
  "width": int,
  "height": int,
  "file_name": str,
  "license": int,
  "flickr_url": str,
  "coco_url": str,
  "date_captured": datetime
}

annotation {
  "id": int,
  "image_id": int,
  "category_id": int,
  "segmentation": RLE or
[polygon],
  "area": float,
  "bbox": [x,y,width,height],
  "iscrowd": 0 or 1
}

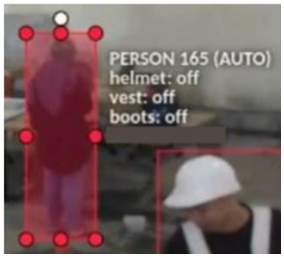
categories [{
  "id": int,
  "name": str,
  "supercategory": str,
}]
```

Gambar 3.3 Format anotasi COCO

3.3 Persiapan Data



Gambar 3.4 Flowchart pelabelan data



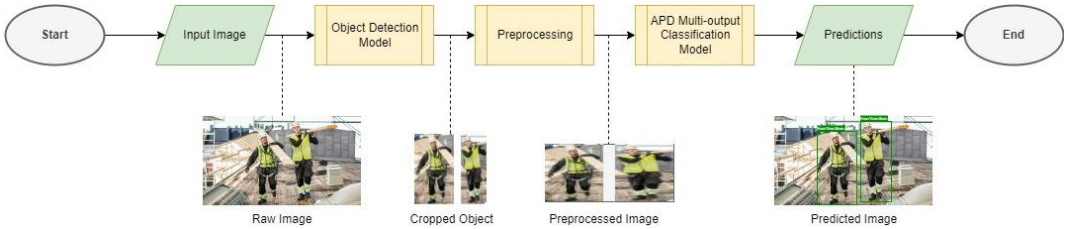
Gambar 3.5 Contoh pelabelan gambar dengan format COCO

Tahap persiapan data melibatkan dua langkah krusial. Pertama, seluruh gambar dalam *dataset* mengalami proses pelabelan ulang menggunakan format anotasi Microsoft COCO (*Common Objects in Context*). Keunggulan format ini terletak pada kemampuannya untuk menambahkan atribut pada setiap objek yang dianotasi, termasuk informasi vital mengenai status penggunaan Alat Pelindung Diri (APD) pada pekerja konstruksi. Kedua, *dataset* akan dibagi menjadi tiga bagian yaitu data latih, data validasi, dan data tes. Pembagian ini bertujuan untuk memastikan model dapat dilatih dengan baik, dievaluasi secara objektif, dan diuji kinerjanya pada data yang belum pernah dilihat sebelumnya.

Proses pelabelan ulang digambarkan pada diagram alir Gambar 3.4. Pertama, gambar yang belum berlabel dibuka di aplikasi CVAT (*Computer Vision Annotation Tool*). Kemudian, setiap pekerja dalam gambar diberi *bounding box*. Selanjutnya, atribut *bounding box* tersebut diberi label sesuai status penggunaan APD (helm, rompi, sepatu). Setelah semua gambar diberi label, hasilnya disimpan dalam format MS COCO. Contoh pelabelan ulang dalam format ini dapat dilihat pada Gambar 3.5.

3.4 Pemodelan

3.4.1 Arsitektur Model

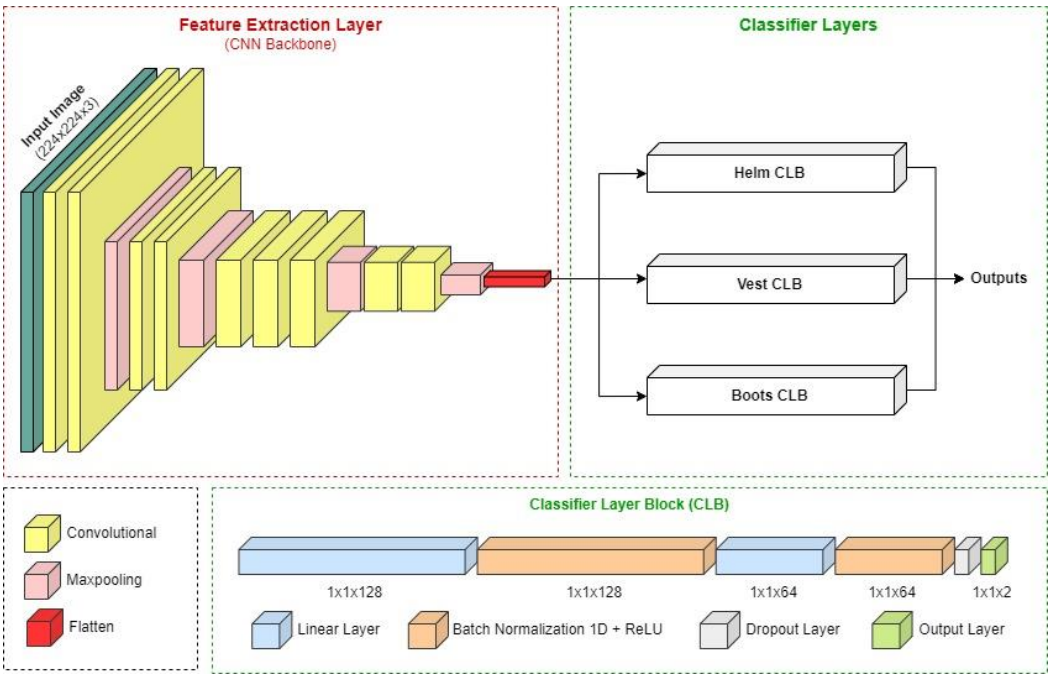


Gambar 3.6 Flowchart cara kerja gabungan kedua model

Sistem ini menggunakan dua model *deep learning* yang saling melengkapi untuk mendeteksi dan mengklasifikasikan penggunaan APD. Model deteksi objek pertama-tama mengidentifikasi lokasi dan bentuk pekerja dalam gambar. Kemudian, model klasifikasi *multi-output* menganalisis apakah pekerja tersebut menggunakan APD dengan benar. Pendekatan dua tahap ini diharapkan dapat meningkatkan akurasi dan memungkinkan pelatihan model dengan data yang lebih sedikit dibandingkan dengan model tunggal [35]. Cara kerja sistem ini diilustrasikan pada diagram alir Gambar 3.6.

Model deteksi objek pekerja pada penelitian ini memanfaatkan model pretrained Faster RCNN, RetinaNet, YOLOv5, dan YOLOv8 dalam berbagai variasi ukuran. Untuk mengadaptasi model-model ini dengan *dataset* yang digunakan, metode *fine-tuning* diterapkan. Metode ini menggunakan pemuatan parameter dari model yang telah dilatih sebelumnya (*pre-trained model*) sebelum melakukan pelatihan ulang dengan *dataset* ini.

Tahap kedua sistem melibatkan pemrosesan hasil prediksi *bounding box* dari model deteksi objek. Setiap objek pekerja yang terdeteksi akan dipangkas secara individual dan digunakan sebagai input untuk model klasifikasi *multi-output*. Model klasifikasi *multi-output* dibangun menggunakan metode *transfer learning*, yang mengombinasikan lapisan ekstraksi fitur (*CNN backbone*) yang telah dilatih sebelumnya dengan lapisan pengklasifikasi baru. Arsitektur lengkap model ini dapat dilihat pada Gambar 3.7.



Gambar 3.7 Arsitektur model klasifikasi multi-output

Dalam upaya mengoptimalkan kinerja model dan mempercepat proses pelatihan, lapisan ekstraksi fitur memanfaatkan model-model *pre-trained* seperti AlexNet, VGG16, ResNet18, EfficientNetV2, dan MobileNetV3. Bobot pada lapisan ini dibekukan selama pelatihan agar tetap tidak berubah, karena bobot ini telah dilatih pada *dataset* besar dan mengandung pengetahuan umum tentang fitur-fitur visual. Dengan membekukan lapisan ekstraksi fitur, model dapat fokus pada pembelajaran fitur-fitur spesifik yang relevan dengan tugas klasifikasi APD. Lapisan ekstraksi fitur ini membantu menangkap fitur global dari data input. Fitur global ini termasuk representasi abstrak dari bentuk dan tekstur umum objek, yang membedakannya dari fitur lokal yang lebih detail seperti tepi dan sudut.

Tabel 3.3 menunjukkan arsitektur lapisan ekstraksi fitur yang berbasis pada model AlexNet. AlexNet terdiri dari lima lapisan konvolusi yang masing-masing diikuti oleh fungsi aktivasi ReLU (*Rectified Linear Unit*). Penggunaan ReLU setelah setiap lapisan konvolusi bertujuan untuk memperkenalkan non-linearitas, sehingga meningkatkan kemampuan jaringan dalam memodelkan hubungan kompleks dalam data. Selain itu, terdapat lapisan *max pooling* yang berfungsi untuk mengurangi dimensi spasial peta fitur, sehingga membantu mengurangi kompleksitas komputasi dan mempercepat pelatihan. Salah satu inovasi utama AlexNet adalah penggunaan ReLU sebagai fungsi aktivasi, yang terbukti mempercepat pelatihan secara signifikan dibandingkan dengan fungsi aktivasi tradisional seperti Tanh atau Sigmoid.

Tabel 3.3 Arsitektur backbone AlexNet

Layer	***Output Shape***	***Parameters***
Conv2d + ReLU	[-1, 64, 55, 55]	23,296
MaxPool2d	[-1, 64, 27, 27]	-
Conv2d + ReLU	[-1, 192, 27, 27]	307,392
MaxPool2d	[-1, 192, 13, 13]	-
Conv2d + ReLU	[-1, 384, 13, 13]	663,936
Conv2d + ReLU	[-1, 256, 13, 13]	884,992
Conv2d + ReLU	[-1, 256, 13, 13]	590,080
MaxPool2d	[-1, 256, 6, 6]	-
Total params: 2,469,696 *Trainable params: 2,469,696* *Non-trainable params: 0* *Total mult-adds (M): 656.05*		
Input size (MB): 0.60 *Forward/backward pass size (MB): 3.88* *Params size (MB): 9.88* *Estimated Total Size (MB): 14.36*		

Tabel 3.4 menunjukkan arsitektur lapisan ekstraksi fitur yang berbasis pada model VGG16. VGG16 merupakan arsitektur *Convolutional Neural Network (*CNN) yang lebih dalam dan kompleks dibandingkan dengan AlexNet. Arsitektur ini terdiri dari 13 lapisan konvolusi yang dikelompokkan menjadi 5 blok, dengan setiap blok diikuti oleh lapisan *max pooling*. VGG16 membuktikan bahwa kedalaman jaringan (jumlah lapisan) memiliki dampak signifikan terhadap performa, yang kemudian menjadi landasan bagi pengembangan arsitektur CNN yang lebih dalam di masa depan.

Tabel 3.4 Arsitektur backbone VGG16

Layer	***Output Shape***	***Parameters***
(Conv2d + ReLU) x 2	[-1, 64, 224, 224]	[1.792, 36.928]
MaxPool2d	[-1, 64, 112, 112]	-
(Conv2d + ReLU) x 2	[-1, 128, 112, 112]	[73.856, 147.584]
MaxPool2d	[-1, 128, 56, 56]	-
(Conv2d + ReLU) x 3	[-1, 256, 112, 112]	[295.168, 590.080, 590.080]
MaxPool2d	[-1, 256, 28,28]	-
(Conv2d + ReLU) x3	[-1, 512, 28, 28]	[1.180.160, 2.359.808, 2.359.808]
MaxPool2d	[-1, 512, 14,14]	-
(Conv2d + ReLU) x3	[-1, 512, 14, 14]	[2.359.808, 2.359.808, 2.359.808]
MaxPool2d	[-1, 512, 7, 7]	-
Total params: 14,714,688 *Trainable params: 14,714,688* *Non-trainable params: 0* *Total mult-adds (G): 15.36*		
Input size (MB): 0.60 *Forward/backward pass size (MB): 108.38* *Params size (MB): 58.86* *Estimated Total Size (MB): 167.84*		

Tabel 3.5 menunjukkan arsitektur lapisan ekstraksi fitur yang berbasis pada model ResNet18. ResNet18 adalah arsitektur *Convolutional Neural Network* (CNN) yang secara efektif mengatasi masalah gradien hilang pada jaringan yang sangat dalam melalui penggunaan koneksi pintas (*skip connection*). Koneksi pintas ini memungkinkan informasi dari lapisan sebelumnya untuk melewati beberapa lapisan dan langsung ditambahkan ke output lapisan selanjutnya, sehingga mempercepat proses pelatihan dan meningkatkan performa model secara keseluruhan. Setiap blok Conv_x dalam ResNet18 terdiri dari dua lapisan konvolusi 3x3, yang masing-masing diikuti oleh lapisan *batch normalization* dan aktivasi ReLU. Selain itu, setiap blok Conv_x juga dilengkapi dengan koneksi pintas.

Tabel 3.5 Arsitektur backbone ResNet18

Layer	***Output Shape***	***Parameters***
Conv1	[-1, 64, 112, 112]	[9.408, 128]
Conv2_x	[-1, 64, 56, 56]	[73.984, 73.984]
Conv3_x	[-1, 128, 28, 28]	[230.144, 295.424]
Conv4_x	[-1, 256, 14, 14]	[919.040, 1.180.672]
Conv5_x	[-1, 512, 7, 7]	[3.673.088, 4.720,640]
Total params: 11,176,512 *Trainable params: 11,176,512* *Non-trainable params: 0* *Total mult-adds (G): 1.81*		
Input size (MB): 0.60 *Forward/backward pass size (MB): 39.74* *Params size (MB): 44.71* *Estimated Total Size (MB): 85.05*		

Tabel 3.6 menunjukkan arsitektur EfficientNetV2, sebuah model *Convolutional Neural Network* (CNN) yang dirancang untuk mencapai kinerja tinggi dengan efisiensi komputasi yang lebih baik. Model ini dimulai dengan lapisan *Conv2dNormActivation*, yang menggabungkan konvolusi, *batch normalization*, dan fungsi aktivasi SiLU (*Sigmoid Linear Unit*). Selanjutnya, terdapat serangkaian blok *Fused-MBConv* dan *MBConv*, yang merupakan varian dari *Inverted Bottleneck Convolution* (*MBCon*v) dengan perbedaan pada penggabungan operasi tertentu. *Fused-MBConv* menggabungkan beberapa operasi seperti konvolusi *depthwise*,

konvolusi *pointwise*, dan *Squeeze-and-Excitation* (SE) untuk meningkatkan efisiensi komputasi, sedangkan *MBConv* tidak menggabungkan operasi tersebut. Dengan perbedaan ini, EfficientNetV2 dapat mengimbangi akurasi dan kecepatan komputasi, membuatnya menarik untuk berbagai aplikasi penglihatan komputer.

Tabel 3.6 Arsitektur backbone EfficientNetV2

Layer	***Output Shape***	***Parameters***
Conv2dNormActivation	[-1, 24, 112, 112]	696
FusedMBConv x 2	[-1, 24, 112, 112]	10.464
FusedMBConv x 4	[-1, 48, 56, 56]	303.552
FusedMBConv x 4	[-1, 64, 28, 28]	589.184
MBConv x 6	[-1, 128, 14, 14]	917.680
MBConv x 9	[-1, 160, 14, 14]	3.463.840
MBConv x 15	[-1, 256, 7, 7]	14.561.832
Conv2dNormActivation	[-1, 1280, 7, 7]	330.240
Total params: 20,177,488 *Trainable params: 20,177,488* *Non-trainable params: 0* *Total mult-adds (G): 2.85*		
Input size (MB): 0.60 *Forward/backward pass size (MB): 194.81* *Params size (MB): 80.71* *Estimated Total Size (MB): 276.13*		

Tabel 3.7 menunjukkan arsitektur MobileNetV3, sebuah *Convolutional Neural Network* (CNN) yang dioptimalkan untuk perangkat seluler. Arsitektur ini terdiri dari lapisan *Conv2dNormActivation* awal (konvolusi, *batch normalization*, dan fungsi aktivasi *Hardswish*), beberapa blok *InvertedResidual* yang ditumpuk (jumlahnya bervariasi tergantung varian MobileNetV3), dan lapisan *Conv2dNormActivation* akhir. Blok *InvertedResidual* merupakan inti dari MobileNetV3 dan varian dari blok *residual* yang membalik urutan konvolusi dengan melakukan konvolusi 1x1, konvolusi *depthwise* 3x3, dan konvolusi 1x1 lagi. Struktur ini memungkinkan MobileNetV3 mencapai kinerja yang baik dengan jumlah parameter dan operasi yang lebih sedikit.

Tabel 3.7 Arsitektur backbone MobilNetV3

Layer	***Output Shape***	***Parameters***
Conv2dNormActivation	[-1, 16, 112, 112]	464
InvertedResidual	[-1, 16, 112, 112]	464
InvertedResidual x 2	[-1, 24, 56, 56]	[3.440, 4.440]
InvertedResidual x 3	[-1, 40, 28, 28]	[10.328, 20.992, 20.992]
InvertedResidual x 4	[-1, 80, 14, 14]	[32.080, 34.760, 31.992, 31.992]
InvertedResidual x 2	[-1, 112, 14, 14]	[214.424, 386.120]
InvertedResidual x 3	[-1, 160, 7, 7]	[429.224, 797.360, 797.360]
Conv2dNormActivation	[-1, 960, 7, 7]	[153.660, 1.920]
Total params: 2,971,952 *Trainable params: 2,971,952* *Non-trainable params: 0* *Total mult-adds (M): 214.11*		
Input size (MB): 0.60 *Forward/backward pass size (MB): 70.44* *Params size (MB): 11.89* *Estimated Total Size (MB): 82.93*		

Setelah proses ekstraksi fitur selesai, peta fitur yang dihasilkan akan menjadi input bagi lapisan pengklasifikasi. Lapisan pengklasifikasi terdiri dari tiga blok lapisan yang masing-masing bertanggung jawab untuk mengklasifikasikan status penggunaan helm, rompi, dan sepatu. Setiap blok dibangun dengan struktur yang serupa, terdiri dari *linear layer*, *batch normalization layer*, *dropout layer*, dan *output layer*. Penggunaan *batch normalization* dan *dropout layer* bertujuan untuk mengurangi *overfitting* pada model, meningkatkan generalisasi, dan mencegah model terlalu spesifik terhadap data pelatihan.

Lapisan pengklasifikasi ini memiliki peran penting dalam mengekstrak fitur khusus tugas (*task-specific features)* dari representasi global yang dihasilkan oleh lapisan ekstraksi fitur. Fitur khusus tugas adalah fitur-fitur yang secara khusus relevan dan informatif untuk tugas klasifikasi tertentu, dalam hal ini, klasifikasi penggunaan APD. Fitur-fitur ini dapat berupa pola-pola visual yang spesifik pada helm, rompi,

atau sepatu, yang membantu model dalam membedakan antara kelas "*Memakai*" dan "*Tidak Memakai*" untuk setiap atribut APD.

3.4.2 Pelatihan Model

Pelatihan model deteksi objek dan klasifikasi *multi-output* dilakukan dengan menggunakan *hyperparameter* yang konsisten pada setiap jenis dan tugas model. *Hyperparameter* yang diatur meliputi jumlah *epoch, batch size,* dan *learning rate*. Hal ini bertujuan untuk memastikan perbandingan yang adil antara berbagai model yang digunakan, sehingga model terbaik dapat diidentifikasi secara objektif.

Khusus untuk model klasifikasi *multi-output*, strategi *early stopping* diterapkan sebagai teknik regularisasi untuk mencegah *overfitting*. Strategi ini memantau performa model pada data validasi selama proses pelatihan. Jika performa tidak menunjukkan peningkatan selama beberapa *epoch* berturut-turut, pelatihan akan dihentikan secara otomatis. Dengan demikian, model yang dihasilkan diharapkan memiliki kemampuan generalisasi yang lebih baik pada data baru yang belum pernah dilihat sebelumnya.

3.5 Evaluasi

Untuk mengukur kinerja kedua model, dilakukan evaluasi dengan metode yang berbeda. Model deteksi dievaluasi menggunakan *intersection of union* (IoU) dan *mean average precision* (mAP), sedangkan model klasifikasi dievaluasi menggunakan *F1-score*. Berikut adalah rincian daripada metrik pengujian tersebut:

1. *Intersection of Union* (IoU)

$$IoU = \frac{area(B_{gt} \cap B_P)}{area(B_{gt} \cup B_P)} \qquad (3.1)$$

Intersection over Union (IoU) adalah metrik yang mengukur tingkat kesesuaian antara dua *bounding box*. Nilai ini dihitung dengan membagi luas area tumpang tindih antara dua *bounding box* dengan luas total area yang dicakup oleh kedua *bounding box* tersebut. Semakin besar nilai IoU (mendekati 1), semakin tinggi tingkat kesesuaian antara prediksi dan *ground truth*. Sebaliknya, nilai IoU yang mendekati 0 menunjukkan

ketidaksesuaian. Dalam praktiknya, ambang batas IoU ditentukan sebelumnya. Jika nilai IoU melebihi ambang batas, objek dianggap sebagai deteksi yang benar (*true positive*), sedangkan jika kurang dari ambang batas, objek dianggap sebagai deteksi yang salah (*false positive*) [43].

2. *Mean Average Precision* (mAP)

   Mean Average Precision (mAP) adalah metrik standar untuk mengevaluasi kinerja model deteksi objek seperti Fast R-CNN, YOLO, dan Mask R-CNN. mAP mengukur akurasi model dengan menghitung rata-rata nilai *Average Precision* (AP) untuk setiap kelas objek [35]. Nilai mAP yang lebih tinggi menunjukkan kinerja model deteksi objek yang lebih baik, dengan nilai 1 mengindikasikan performa sempurna.

$$AP = \frac{1}{11} \sum_{r \in \{0, 0.1, 0.2, .., 1\}} \rho_{inter}(r) \qquad (3.2)$$

$$mAP = \frac{1}{n} \sum_{i=1}^{n} AP_i \qquad (3.3)$$

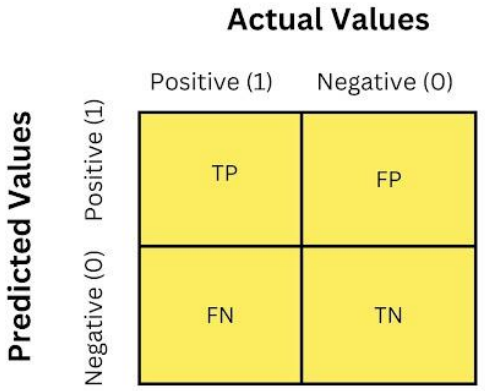
   Perhitungan AP melibatkan beberapa langkah. Pertama, *precision* dan *recall* dihitung untuk setiap prediksi model berdasarkan *Intersection over Union* (IoU) dengan *ground truth*. Penelitian ini menggunakan ambang batas IoU sebesar 0.5, sehingga metrik yang dihasilkan disebut mAP@50. Selanjutnya, kurva *Precision-Recall* (PR) dibuat untuk setiap kelas objek.

   Area di bawah kurva PR (AP) kemudian dihitung untuk setiap kelas menggunakan metode interpolasi, seperti metode *11-point interpolation*. Terakhir, mAP diperoleh dengan menghitung rata-rata nilai AP dari semua kelas objek.

3. *F1-score*

   Confusion matrix adalah tabel yang merangkum kinerja model klasifikasi dengan membandingkan label prediksi dengan label sebenarnya. Tabel ini berguna untuk mengevaluasi model klasifikasi, baik untuk masalah

klasifikasi biner maupun multi-kelas. Dari nilai-nilai dalam *confusion matrix*, berbagai metrik performa seperti akurasi, *precision*, *recall*, dan *F1-score* dapat dihitung untuk memberikan gambaran yang lebih komprehensif tentang kinerja model [44].



Gambar 3.8 Tabel confusion matrix

F1-score merupakan salah satu metrik penting yang diturunkan dari confusion matrix. Metrik ini mengukur kinerja model klasifikasi dengan mempertimbangkan keseimbangan antara *precision* (proporsi prediksi positif yang benar) dan *recall* (proporsi sampel positif yang berhasil diidentifikasi). *F1-score* dihitung sebagai rata-rata harmonik dari *precision* dan *recall*, sehingga memberikan penalti jika salah satu metrik memiliki nilai yang sangat rendah. Rentang *nilai F1-score* adalah dari 0 hingga 1, dengan 1 menunjukkan kinerja sempurna (*precision* dan *recall* maksimum) dan 0 menunjukkan kinerja terburuk.

$$Precision = \frac{TP}{TP + FP} \qquad (3.4)$$

$$Recall = \frac{TP}{TP + FN} \qquad (3.5)$$

$$F1 - score = 2 \times \frac{Precision \times Recall}{Precision + Recall} \qquad (3.6)$$

Keunggulan *F1-score* terutama terlihat pada kasus klasifikasi dengan data tidak seimbang, yaitu ketika salah satu kelas memiliki jumlah sampel yang jauh lebih banyak daripada kelas lainnya [15]. Dalam situasi seperti ini, akurasi dapat memberikan gambaran yang kurang sesuai karena model dapat mencapai akurasi tinggi hanya dengan memprediksi kelas mayoritas secara terus-menerus. Sebaliknya, *F1-score* lebih sensitif terhadap kinerja model pada kelas minoritas, karena memperhitungkan *recall* (kemampuan mendeteksi sampel positif dari kelas minoritas) yang seringkali rendah pada data tidak seimbang.

3.6 Deployment

Tahap terakhir adalah pengembangan prototipe web sederhana untuk demonstrasi model. Model yang telah dibangun akan diintegrasikan ke dalam sebuah aplikasi web menggunakan pustaka Streamlit pada Python. Prototipe web ini bertujuan untuk memberikan demonstrasi visual tentang cara kerja model dalam memprediksi penggunaan APD pada gambar pekerja konstruksi, serta untuk menguji dan mengevaluasi kinerja model secara interaktif.

BAB IV
ANALISIS DAN PEMBAHASAN

Bab ini menyajikan analisis dan pembahasan mendalam mengenai sistem yang telah dikembangkan. Analisis mencakup aspek-aspek penting seperti analisis data, pemodelan, evaluasi kinerja model, dan *deployment*.

4.1 Analisis Data

Dataset yang digunakan dalam penelitian ini berasal dari gabungan berbagai *dataset* publik yang belum terlabel sesuai kebutuhan. Setelah dilakukan pelabelan ulang dengan format MS COCO, distribusi label pada 6165 objek pekerja dapat dilihat pada Tabel 4.1. Terdapat ketidakseimbangan signifikan pada atribut helm (5142 memakai, 1023 tidak memakai), sementara distribusi atribut rompi (3362 memakai, 2803 tidak memakai) dan sepatu (2962 memakai, 3203 tidak memakai) relatif lebih seimbang.

Tabel 4.1 Distribusi label pada masing-masing atribut APD

Status Penggunaan APD	**Nama Atribut**		
	Helm	**Rompi**	**Sepatu**
Memakai	5142	3362	2962
Tidak Memakai	1023	2803	3203
Total	6165		

Setelah proses pelabelan ulang selesai, *dataset* yang telah dianotasi kemudian dibagi menjadi tiga set yaitu data latih (70%), data validasi (10%), dan data tes (20%). Pembagian ini dilakukan untuk melatih, mengevaluasi, dan menguji kinerja dua model yang akan digunakan yaitu model deteksi objek dan model klasifikasi *multi-output*. Tabel 4.2 merinci distribusi 2099 gambar dan 6165 anotasi objek pekerja dalam *dataset* yang digunakan untuk melatih dan mengevaluasi model deteksi objek. Sebagian besar data, yaitu 1469 gambar (4315 anotasi) dialokasikan untuk pelatihan, sementara 210 gambar (616 anotasi) digunakan untuk validasi, dan sisanya, 420 gambar (1234 anotasi) digunakan untuk pengujian.

Tabel 4.2 Distribusi pembagian dataset untuk model deteksi objek

Keterangan	Data Latih	Data Validasi	Data Tes	Total
Jumlah Gambar	1469	210	420	2099
Jumlah Objek Pekerja	4315	616	1234	6165

Tabel 4.3 menyajikan distribusi *dataset* yang digunakan untuk melatih dan mengevaluasi model klasifikasi *multi-output*, yang dirancang untuk mengklasifikasikan penggunaan alat pelindung diri (APD) pada pekerja konstruksi. Data latih menunjukkan ketidakseimbangan signifikan pada atribut helm (3601 memakai, 714 tidak memakai), sementara atribut rompi (2324 memakai, 1991 tidak memakai) dan sepatu (2082 memakai, 2233 tidak memakai) relatif seimbang. Pola serupa terlihat pada data validasi dan tes.

Tabel 4.3 Distribusi pembagian dataset untuk model klasifikasi multi-output

Nama Atribut	Status Penggunaan	Data Latih	Data Validasi	Data Tes
Helm	Memakai	3601	510	1031
	Tidak Memakai	714	106	203
Rompi	Memakai	2324	337	701
	Tidak Memakai	1991	279	533
Sepatu	Memakai	2082	286	594
	Tidak Memakai	2233	330	640

4.2 Analisis Pemodelan dan Evaluasi

Bagian analisis pemodelan dan evaluasi menjelaskan pengaturan *hyperparameter* tunggal yang digunakan secara konsisten pada semua model, serta penilaian mendalam terhadap kinerja model deteksi objek dan klasifikasi *multi-output*. Evaluasi ini memanfaatkan metrik relevan seperti *mean average precision* (mAP) dan *F1-score* untuk memberikan wawasan komprehensif tentang performa masing-masing model. Hasil analisis ini menjadi dasar penting dalam menentukan model terbaik yang sesuai dengan kebutuhan dan tujuan penelitian.

4.2.1 *Hyperparameter* Model

Pengaturan *hyperparameter* pada semua model deteksi objek dan klasifikasi *multi-output* diterapkan seragam. Hal ini dilakukan untuk menghindari bias yang mungkin muncul akibat perbedaan konfigurasi *hyperparameter* antar model, sehingga memungkinkan evaluasi yang adil dan objektif terhadap kinerja intrinsik masing-masing model. Tabel 4.4 merinci pengaturan *hyperparameter* yang digunakan secara konsisten pada semua model, baik untuk deteksi objek maupun klasifikasi *multi-output*.

Pelatihan model deteksi objek pekerja akan dilakukan dengan menggunakan konfigurasi *hyperparameter* yang konsisten, meliputi jumlah *epochs*, *batch size*, dan *learning rate*. Jumlah *epochs* diatur seragam pada nilai 20, yang dianggap cukup untuk *fine-tuning* model deteksi objek yang telah dilatih sebelumnya pada kasus yang lebih umum. *Batch size* diatur pada nilai 8 untuk menghemat sumber daya komputasi selama pelatihan. *Learning rate* diatur pada nilai *default* 0.01 untuk setiap model. Namun, pemilihan *optimizer* tidak diseragamkan karena setiap model memiliki karakteristik arsitektur dan dinamika pelatihan yang berbeda. Model *Faster R-CNN* dan *RetinaNet* menggunakan *optimizer Stochastic Gradient Descent* (SGD) karena cenderung lebih stabil dalam proses pelatihan, sedangkan model *YOLO* menggunakan optimizer *AdamW* yang lebih adaptif dan mampu mempercepat konvergensi model.

Tabel 4.4 Hyperparameter model deteksi objek dan klasifikasi multi-output

***Hyperparameter* Model Deteksi Objek**	
Jumlah *Epochs*	20
Batch Size	8
Learning Rate	0.01
Hyperparameter* Model Klasifikasi *Multi-output	
Jumlah *Epochs* Maksimal	50
Batch Size	32
Learning Rate	0.0001
Optimizer	Adam

Pelatihan model klasifikasi *multi-output* status penggunaan alat pelindung diri akan dilakukan dengan konfigurasi *hyperparameter* yang konsisten, meliputi jumlah *epochs* maksimal, *batch size*, *learning rate*, dan *optimizer*. Jumlah *epochs* maksimal dibatasi pada 50, namun strategi *early stopping* diterapkan untuk menghentikan pelatihan lebih awal jika *validation total loss* tidak membaik selama 10 epochs berturut-turut. *Batch size* diatur pada nilai 32 untuk mempercepat proses pelatihan, sementara *learning rate* diatur pada 0.0001. Pemilihan *Adam* sebagai *optimizer* didasarkan pada kemampuan untuk menangani masalah optimasi non-konveks yang sering terjadi pada model *deep learning*. Selain itu, *optimizer Adam* dapat secara adaptif menyesuaikan kecepatan belajar untuk setiap parameter.

4.2.2 Evaluasi Model Deteksi Objek

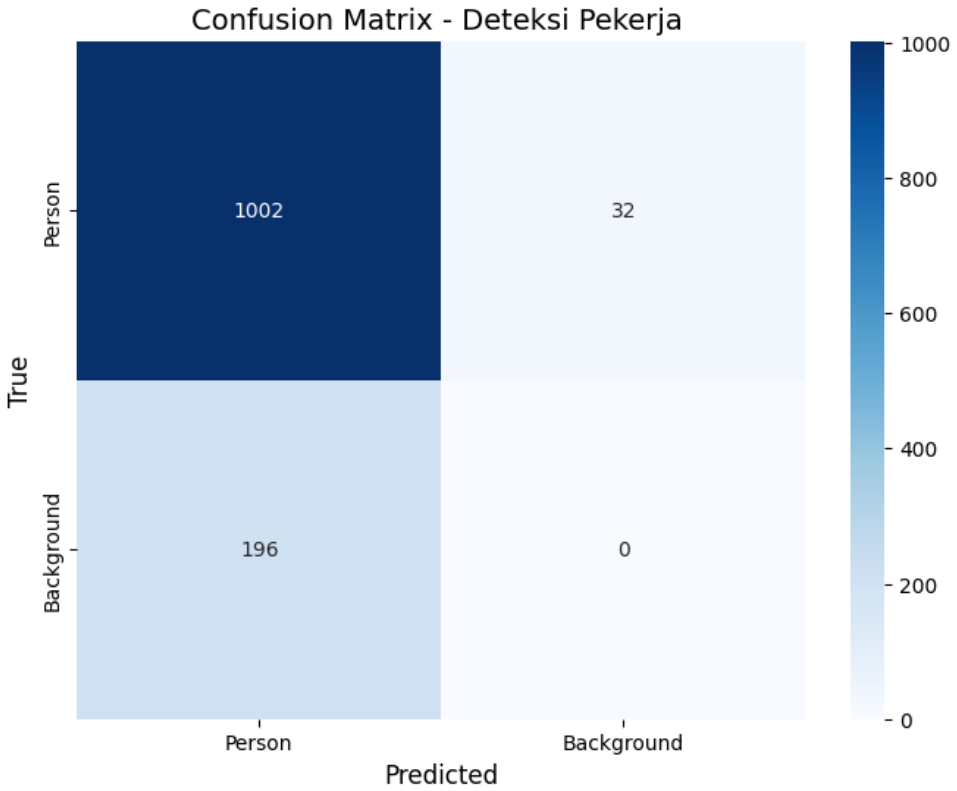
Evaluasi model deteksi objek akan dilakukan menggunakan metrik *mean Average Precision* (mAP) pada *Intersection over Union* (IoU) dengan ambang batas 50% (mAP@50). Waktu pelatihan dan ukuran model juga akan dipertimbangkan sebagai data pendukung untuk evaluasi, meskipun bukan faktor penentu utama. Tujuan dari evaluasi ini adalah untuk mengidentifikasi model dengan kinerja terbaik yang nantinya akan diimplementasikan dalam sistem yang dikembangkan pada penelitian ini.

Tabel 4.5 Perbandingan model deteksi objek

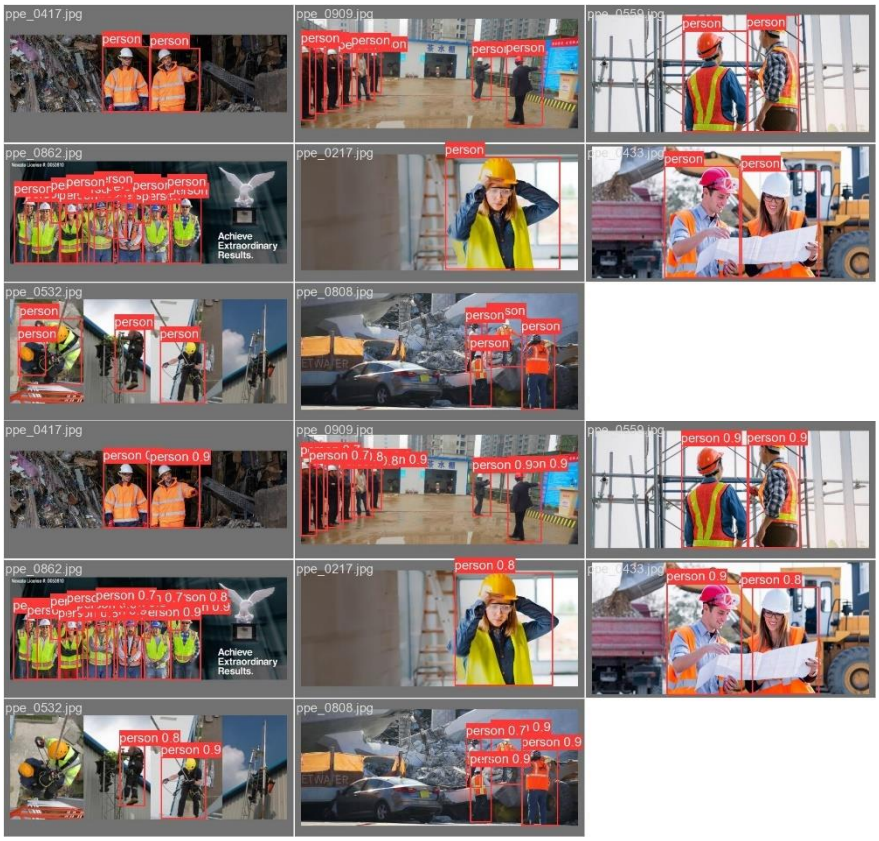
Nama Model	***Mean Average Precision* (mAP@50)**	**Waktu Pelatihan**	**Ukuran Model (MB)**
Faster R-CNN	0.9081	01:06:44	314.74
RetinaNet	0.8995	01:12:22	288.96
YOLOv5s	0.9017	00:11:45	17.64
YOLOv5m	0.8962	00:19:43	48.13
YOLOv5l	0.8955	00:30:53	101.82
YOLOv5x	0.8914	00:48:59	185.92
YOLOv8s	0.8937	00:12:09	21.46
YOLOv8m	0.9011	00:22:27	49.6
YOLOv8l	0.9006	00:32:37	83.57
YOLOv8x	0.9096	00:46:45	130.37

Tabel 4.5 menyajikan hasil pelatihan model deteksi objek. Secara keseluruhan, semua model menunjukkan performa mAP@50 yang sangat baik, berkisar antara 0.89 hingga 0.91. YOLOv8x unggul dengan mAP@50 tertinggi (0.9096), namun memiliki waktu pelatihan terlama (46 menit 45 detik) dan ukuran model yang relatif sedang (130.37 MB). Faster R-CNN juga mencatat mAP@50 tinggi (0.9081), namun waktu pelatihannya lebih dari satu jam dengan ukuran model terbesar (314.74 MB). YOLOv5s dan YOLOv8s menawarkan alternatif menarik dengan waktu pelatihan tercepat (kurang dari 20 menit) dan ukuran model terkecil (17.64 MB dan 21.46 MB), meskipun mAP@50 mereka sedikit lebih rendah.

Analisis komprehensif terhadap hasil evaluasi menunjukkan bahwa YOLOv8x merupakan kandidat model terbaik secara keseluruhan. Meskipun memerlukan sumber daya komputasi yang lebih besar, terutama dalam hal waktu pelatihan dan ukuran model, YOLOv8x menawarkan performa mAP@50 tertinggi di antara model-model yang dievaluasi, membuktikan kemampuan deteksi objek yang unggul.



Gambar 4.1 Confusion matrix deteksi pekerja YOLOv8x



Gambar 4.2 Sampel hasil prediksi model deteksi pekerja YOLOv8x

Confusion matrix pada Gambar 4.1 menunjukkan hasil deteksi pekerja menggunakan model YOLOv8x. Model berhasil mendeteksi 1002 objek pekerja dengan benar (TP). Namun, terdapat 32 kasus *false positive* (FP), di mana model salah mendeteksi pekerja padahal sebenarnya tidak ada. Selain itu, terdapat 196 kasus *false negative* (FN), yang menunjukkan bahwa model masih melewatkan sejumlah objek pekerja yang seharusnya terdeteksi.

Gambar 4.2 menyajikan contoh hasil prediksi model YOLOv8x, dengan gambar atas menunjukkan label asli (*ground truth*) dan gambar bawah menunjukkan label prediksi. Secara umum, model ini menunjukkan kemampuan yang baik dalam mendeteksi pekerja dalam berbagai kondisi diantaranya yaitu *close-up*, jarak dekat, dan jarak jauh. Namun, terdapat beberapa kasus kegagalan prediksi terutama ketika pekerja tidak terlihat sepenuhnya seperti saat jongkok atau terhalang oleh pekerja lain maupun objek di lokasi konstruksi. Meskipun demikian, kasus-kasus ini relatif jarang terjadi dan tidak signifikan mempengaruhi performa model secara keseluruhan. Model tetap menunjukkan performa yang baik dalam mendeteksi pekerja.

4.2.3 Evaluasi Model Klasifikasi *Multi-output*

Evaluasi model klasifikasi *multi-output* akan dilakukan menggunakan *F1-score* sebagai metrik utama. Dalam evaluasi ini, *F1-score* akan dihitung secara individual untuk masing-masing atribut alat pelindung diri (helm, rompi, dan sepatu), serta *F1-score* rata-rata yang menggabungkan performa pada ketiga atribut tersebut. Dengan demikian, akan diperoleh empat nilai *F1-score* yang memberikan gambaran komprehensif tentang kinerja model dalam mengklasifikasikan status penggunaan alat pelindung diri pada pekerja konstruksi.

Tabel 4.6 menyajikan hasil performa model klasifikasi *multi-output*. Model VGG16 secara konsisten menunjukkan performa terbaik, dengan rata-rata *F1-score* tertinggi sebesar 0.885. Keunggulan VGG16 juga terlihat pada masing-masing atribut APD, dengan *F1-score* sebesar 0.9508 untuk helm, 0.8854 untuk rompi, dan 0.8189 untuk sepatu. EfficientNetV2 menyusul dengan performa yang cukup bersaing, mencapai rata-rata *F1-score* 0.878. Sementara itu, AlexNet dan ResNet18 menunjukkan performa yang setara, dengan rata-rata *F1-score* masing-masing sebesar 0.8765 dan 0.8742. Dari seluruh model yang dievaluasi, MobileNetV3 menunjukkan performa terendah dalam tugas klasifikasi *multi-output* ini.

Tabel 4.7 menyajikan perbandingan *metadata* model klasifikasi *multi-output*, meliputi jumlah *epochs* pelatihan, waktu pelatihan, dan ukuran model, yang menjadi pertimbangan penting dalam pemilihan model terbaik. AlexNet menonjol dengan waktu pelatihan tercepat, jumlah *epochs* pelatihan paling sedikit, dan ukuran model terkecil. VGG16 memerlukan waktu pelatihan sekitar 30 menit dengan 17 *epochs* dan memiliki ukuran model sedang. ResNet18 membutuhkan waktu pelatihan sekitar 34 menit dengan 20 *epochs* dan juga memiliki ukuran model sedang. MobileNetV3, meskipun memiliki waktu pelatihan sekitar 36 menit dengan 21 *epochs*, memiliki ukuran model yang cukup besar. Di sisi lain, EfficientNetV2 memiliki waktu pelatihan paling lama, yaitu sekitar 1 jam dengan 40 *epochs*, dan juga memiliki ukuran model terbesar di antara model-model yang dibandingkan.

Tabel 4.6 Perbandingan performa model klasifikasi multi-output

Nama Model	F1-score			
	Helm	**Rompi**	**Sepatu**	**Rata-rata**
Alexnet	0.9362	0.8817	0.8118	0.8765
VGG16	0.9508	0.8854	0.8189	0.885
ResNet18	0.9454	0.8732	0.804	0.8742
EfficientNetV2	0.948	0.884	0.8019	0.878
MobileNetV3	0.9086	0.7084	0.5736	0.7302

Tabel 4.7 Perbandingan metadata model model klasifikasi multi-output

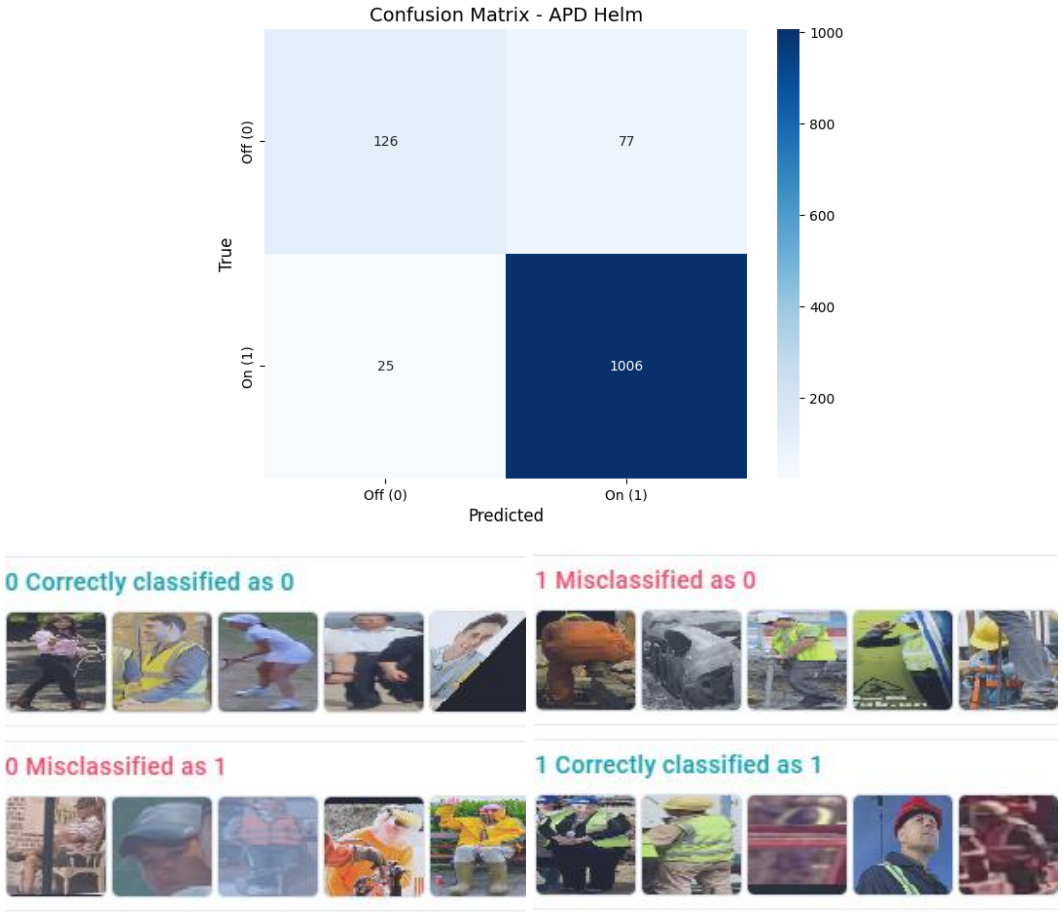
Nama Model	Jumlah Epochs	Waktu Pelatihan	Ukuran Model (MB)
Alexnet	16	00:25:52	50.28
VGG16	17	00:29:53	166.75
ResNet18	20	00:34:14	153.32
EfficientNetV2	40	01:07:30	353.83
MobileNetV3	21	00:36:09	218.62

Berdasarkan analisis komprehensif dari kedua tabel, model VGG16 dipilih sebagai model terbaik dalam penelitian ini. Model ini tidak hanya mencapai rata-rata *F1-score* tertinggi dibandingkan model lain, tetapi juga memiliki ukuran model yang relatif efisien dalam hal penggunaan sumber daya komputasi. Penggunaan rata-rata *F1-score* sebagai metrik utama memastikan bahwa model mampu mengklasifikasikan semua atribut APD dengan akurat dan seimbang, tidak hanya berfokus pada satu atribut tertentu. Oleh karena itu, kombinasi antara performa tinggi dan efisiensi ukuran model menjadikan VGG16 pilihan optimal untuk diterapkan dalam konteks penelitian ini.

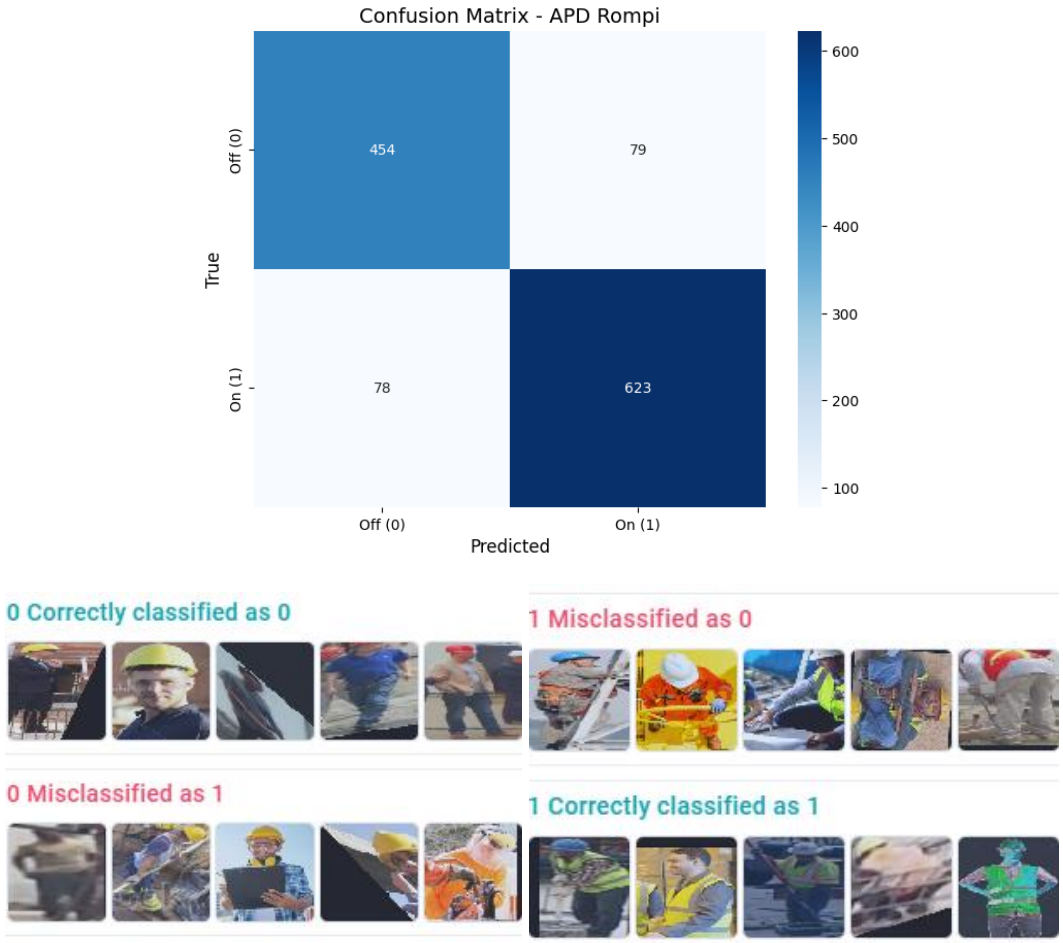
Berdasarkan Gambar 4.3, *confusion matrix* dari model VGG16 pada atribut APD helm menunjukkan bahwa dari 1234 data uji, model berhasil mengidentifikasi 1006 pekerja yang menggunakan helm dengan benar atau *true positive* (TP). Namun, model masih perlu ditingkatkan dalam mengidentifikasi kondisi tidak menggunakan helm, terlihat dari 77 kasus *false positive* (FP) di mana model salah

mengidentifikasi pekerja tidak menggunakan helm padahal sebenarnya menggunakan helm. Meskipun demikian, jumlah *true negative* (TN) yang sebesar 126 dan *false negative* (FN) yang hanya 25 menunjukkan bahwa model secara keseluruhan memiliki performa yang baik, terutama dalam mendeteksi penggunaan helm.

Sampel prediksi *confusion matrix* pada Gambar 4.3 menunjukkan adanya beberapa kesalahan dalam prediksi model, baik yang benar maupun salah. Terdapat beberapa kasus di mana model salah memprediksi pekerja tidak menggunakan helm (*false positive*) padahal sebenarnya menggunakan atribut yang mirip helm, seperti topi atau masker *full face*. Selain itu, terdapat pula kasus di mana model salah memprediksi pekerja menggunakan helm (*false negative*) padahal sebenarnya tidak, terutama ketika atribut helm tidak terlihat jelas pada gambar, misalnya saat pekerja jongkok atau terhalang oleh objek lain.



Gambar 4.3 Confusion matrix atribut APD helm model VGG16



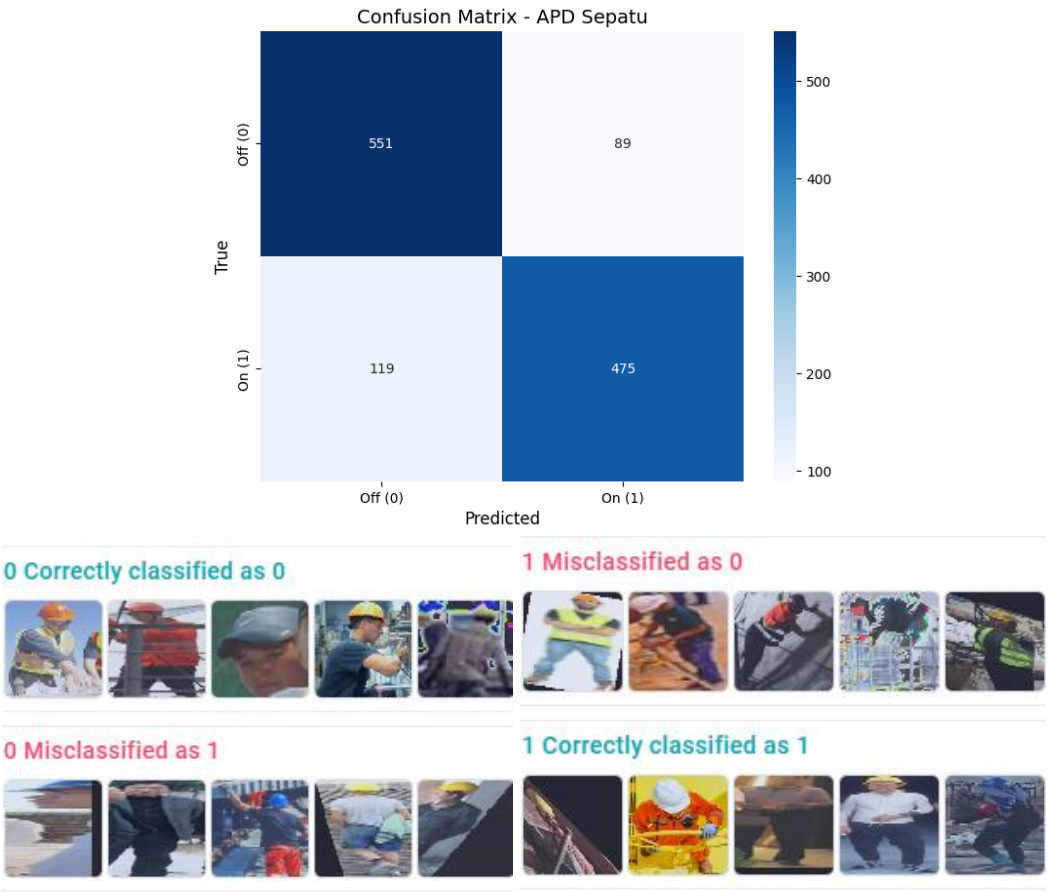
Gambar 4.4 Confusion matrix atribut APD rompi model VGG16

Confusion matrix pada Gambar 4.4 menunjukkan performa model VGG16 dalam mengklasifikasikan atribut APD rompi pada 1234 data uji. Model ini berhasil mengidentifikasi 623 pekerja yang menggunakan rompi dengan benar atau *true positive* (TP). Namun, terdapat 79 kasus *false positive* (FP), yang mengindikasikan bahwa model perlu ditingkatkan dalam mengidentifikasi kondisi tidak menggunakan rompi. Meskipun demikian, dengan 454 *true negative* (TN) dan 78 *false negative* (FN), secara keseluruhan model menunjukkan performa yang baik, terutama dalam mendeteksi penggunaan rompi.

Gambar 4.4 juga menyajikan contoh prediksi model VGG16 pada atribut APD rompi. Secara keseluruhan, model menunjukkan kemampuan yang baik dalam membedakan atribut rompi dari atribut lainnya. Namun, terdapat beberapa kasus kesalahan prediksi yang dapat dianalisis lebih lanjut. Kesalahan-kesalahan ini

sering terjadi ketika kualitas gambar rendah sehingga detail rompi tidak terlihat jelas, atau ketika bagian tubuh pekerja yang seharusnya mengenakan rompi terhalang atau terpotong oleh batas gambar. Hal ini menunjukkan bahwa model masih memiliki keterbatasan dalam mengenali atribut rompi dalam kondisi visual yang menantang, seperti gambar buram, gelap, atau terpotong. Selain itu, model juga kesulitan mengenali rompi dengan warna atau pola mirip latar belakang.

Berdasarkan Gambar 4.5, *confusion matrix* dari model VGG16 pada atribut APD sepatu menunjukkan bahwa dari 1234 data uji, model berhasil mengidentifikasi 475 pekerja yang menggunakan sepatu dengan benar atau *true positive* (TP). Namun, terdapat 89 kasus *false positive* (FP), yang mengindikasikan bahwa model perlu ditingkatkan dalam mengidentifikasi kondisi tidak menggunakan sepatu. Meskipun demikian, dengan 551 *true negative* (TN) dan 119 *false negative* (FN), secara keseluruhan model menunjukkan performa yang cukup baik, terutama dalam mendeteksi penggunaan sepatu.

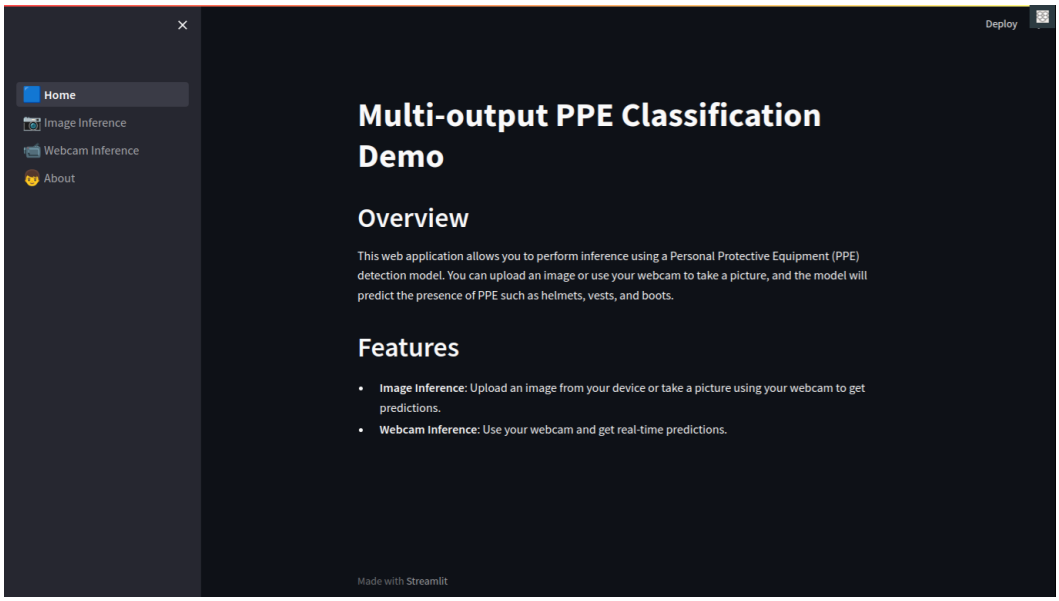


Gambar 4.5 Confusion matrix atribut APD sepatu model VGG16

Gambar 4.5 juga menyajikan contoh prediksi model VGG16 pada atribut APD sepatu. Secara umum, model menunjukkan kemampuan untuk memprediksi atribut sepatu meskipun sering kali bagian sepatu tidak terlihat jelas dalam gambar. Kesalahan prediksi yang terjadi umumnya disebabkan oleh keterbatasan visual ini, di mana bagian sepatu tertutupi atau tidak tertangkap kamera. Selain itu, cara pelabelan data yang menganggap pekerja tanpa sepatu terlihat dalam gambar sebagai "*tidak menggunakan sepatu*" juga menambah tingkat kesulitan bagi model dalam membedakan kondisi penggunaan sepatu secara akurat. Hal ini mengindikasikan bahwa peningkatan kualitas data, terutama dalam hal visibilitas atribut sepatu, dapat menjadi langkah penting untuk meningkatkan performa model dalam mengklasifikasikan penggunaan sepatu.

4.3 Analisis *Deployment*

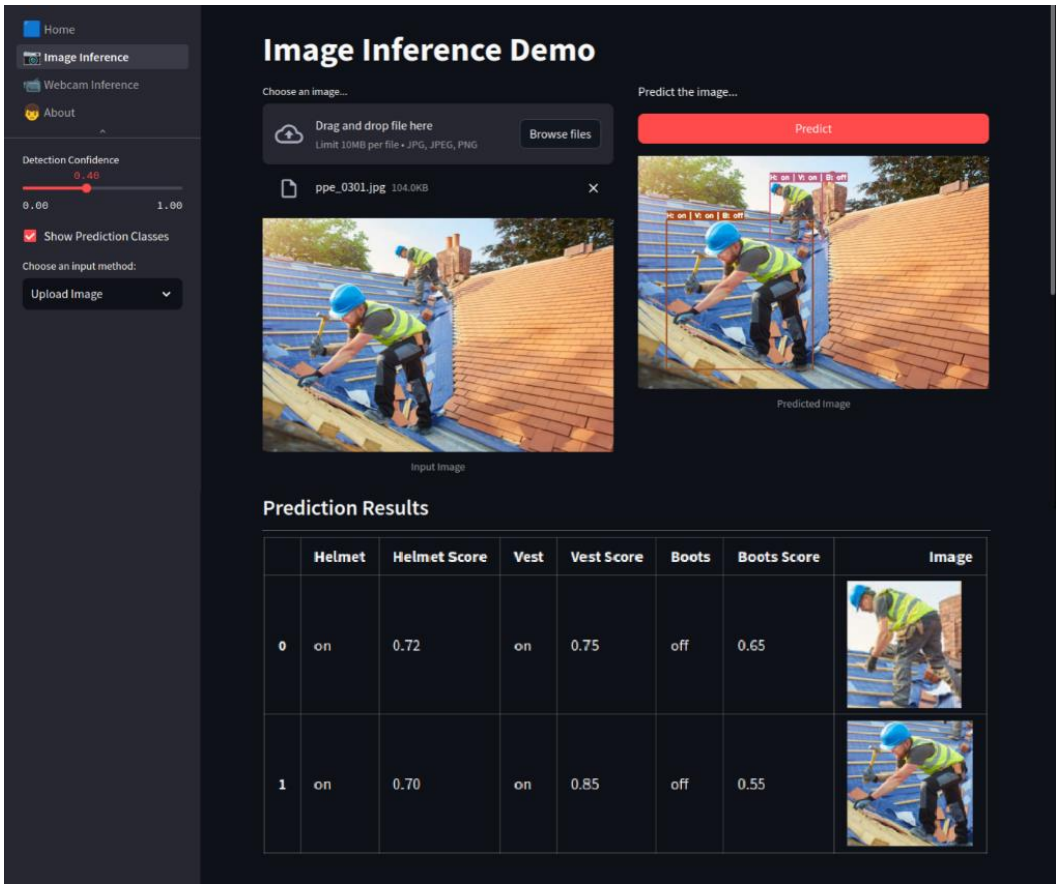
Bagian analisis *deployment* akan membahas pengujian integrasi model yang telah dilatih ke dalam prototipe web. Pengujian ini akan mencakup model deteksi objek dan klasifikasi *multi-output*, dengan menggunakan berbagai sumber data gambar, seperti unggahan pengguna, tangkapan *webcam*, dan video *real-time*. Tujuannya adalah untuk memastikan kinerja dan keandalan model dalam lingkungan produksi yang sesungguhnya.



Gambar 4.6 Halaman beranda prototipe web

4.3.1 Pengujian Unggahan Pengguna

Untuk melakukan prediksi berdasarkan unggahan gambar, pengguna terlebih dahulu perlu mengatur ambang batas tingkat kepercayaan prediksi deteksi objek pekerja. Setelah itu, pengguna dapat mengunggah gambar ke kolom yang disediakan dan mengklik tombol prediksi. Hasil prediksi akan ditampilkan dalam bentuk gambar dengan *bounding box* dan label yang sesuai, serta tabel yang merinci hasil prediksi per objek pekerja, termasuk atribut APD helm, sepatu, dan rompi. Gambar 4.7 menunjukkan contoh hasil pengujian prediksi menggunakan fitur unggah gambar ini.

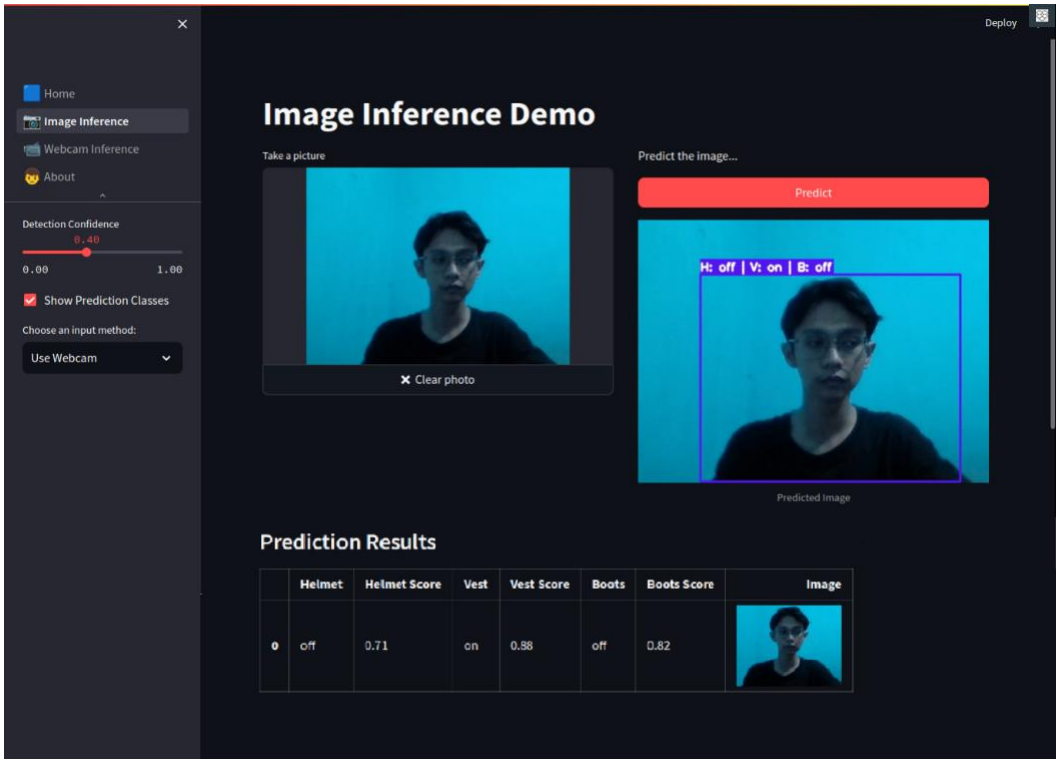


Gambar 4.7 Pengujian fitur unggahan pengguna

4.3.2 Pengujian Tangkapan *Webcam*

Untuk melakukan prediksi berdasarkan tangkapan *webcam*, pengguna terlebih dahulu mengatur ambang batas tingkat kepercayaan prediksi deteksi objek pekerja. Selanjutnya, pengguna mengklik tombol "*mulai webcam*", lalu "*tangkap gambar*" untuk mengambil gambar dari *webcam*. Setelah gambar berhasil ditangkap,

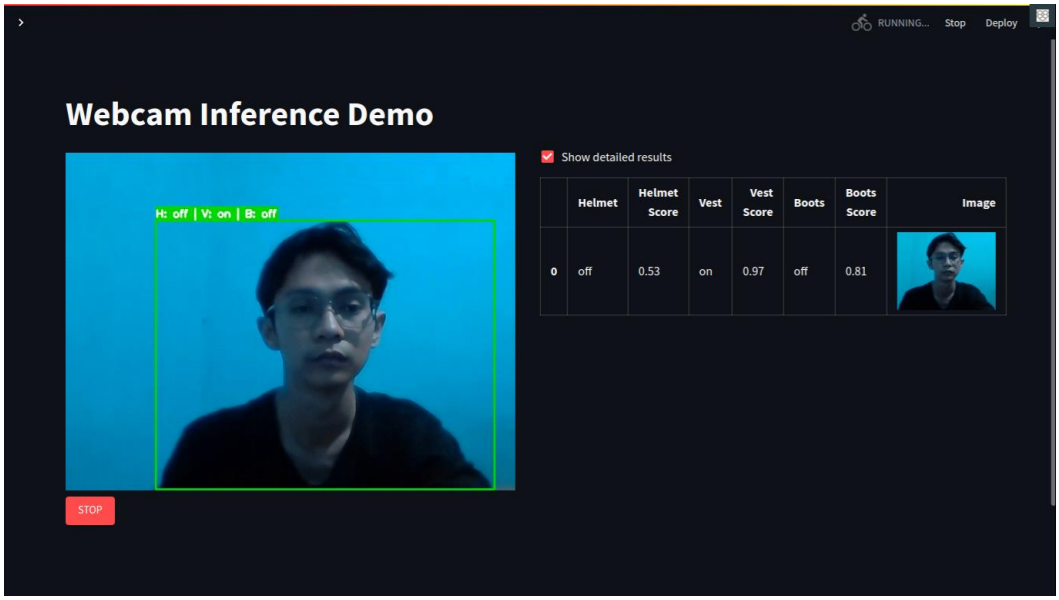
pengguna dapat mengklik tombol "*prediksi*" untuk melihat hasilnya. Hasil prediksi akan ditampilkan dalam bentuk gambar dengan *bounding box* dan label yang sesuai, serta tabel yang merinci hasil prediksi per objek pekerja, termasuk atribut APD helm, sepatu, dan rompi. Gambar 4.8 menunjukkan contoh hasil pengujian prediksi menggunakan fitur tangkapan *webcam* ini.



Gambar 4.8 Pengujian fitur tangkapan webcam

4.3.3 Pengujian Video *Real-time*

Untuk melakukan prediksi pada video secara *real-time*, pengguna perlu mengaktifkan *webcam* dengan mengklik tombol "*mulai webcam*". Sistem akan memproses video dari *webcam* tersebut secara *frame per frame*. Setiap *frame* akan diinferensi oleh model, menghasilkan prediksi yang ditampilkan langsung pada video *real-time*. Selain itu, rincian hasil prediksi per objek, termasuk atribut helm, rompi, dan sepatu, juga akan disajikan dalam bentuk tabel. Gambar 4.9 menunjukkan contoh hasil pengujian prediksi menggunakan fitur tangkapan *webcam* ini.



Gambar 4.9 Pengujian fitur video real-time

BAB V
KESIMPULAN

5.1 Kesimpulan

Berdasarkan hasil penelitian pada skripsi "*Sistem Cerdas Multi-output Model Deep Learning pada Identifikasi Alat Pelindung Diri di Lingkungan Industri*", dapat diambil kesimpulan sebagai berikut:

1. Sistem identifikasi alat pelindung diri di lingkungan industri berhasil dibangun dengan mengintegrasikan dua model *deep learning*, yaitu model deteksi objek YOLOv8x untuk mendeteksi pekerja dan model klasifikasi *multi-output* VGG16 untuk memprediksi status penggunaan atribut APD (helm, rompi, dan sepatu) pada masing-masing pekerja.
2. Model deteksi objek terbaik pada penelitian ini adalah YOLOv8x yang berhasil mendeteksi pekerja di lingkungan industri. Model ini memiliki performa mAP@50 sebesar 0.9096. Selain performanya yang tinggi, ukuran model yang relatif sedang (130.37 MB) menjadikannya cocok untuk diimplementasikan pada sistem tanpa menimbulkan beban komputasi yang berlebihan.
3. Model klasifikasi *multi-output* terbaik pada penelitian ini adalah VGG16 yang berhasil memprediksi status kepatuhan penggunaan APD yang dikenakan oleh pekerja. Model ini memiliki performa rata-rata *F1-score* sebesar 0.885. Penggunaan rata-rata *F1-score* sebagai metrik evaluasi utama memastikan bahwa model mampu memprediksi ketiga atribut APD (helm, rompi, dan sepatu) secara seimbang dan akurat.

5.2 Saran

Berdasarkan hasil penelitian pada skripsi "Sistem *Cerdas Multi-output Model Deep Learning pada Identifikasi Alat Pelindung Diri di Lingkungan Industri*", penulis memiliki saran untuk pengembangan selanjutnya sebagai berikut:

1. Eksplorasi model *machine learning* lainnya, baik untuk deteksi objek maupun klasifikasi *multi-output*, dapat dilakukan untuk menemukan model

yang lebih optimal dalam mengenali APD pada berbagai kondisi dan jenis APD.

2. Untuk mengukur efektivitas sistem *multi-output deep learning* ini secara komprehensif, disarankan untuk melakukan perbandingan dengan pendekatan lain yang ada dalam identifikasi APD. Perbandingan ini dapat memberikan wawasan tentang keunggulan dan kelemahan masing-masing pendekatan, serta potensi pengembangan lebih lanjut dari sistem yang telah dibangun.

DAFTAR PUSTAKA

[1] C. D. Yuliandi dan E. Ahman, "PENERAPAN KESELAMATAN DAN KESEHATAN KERJA (K3) DI LINGKUNGAN KERJA BALAI INSEMINASI BUATAN (BIB) LEMBANG," *J. MANAJERIAL*, vol. 18, no. 2, hlm. 98–109, Agu 2019, doi: 10.17509/manajerial.v18i2.18761.

[2] International Labour Organization, "A call for safer and healthier working environments," ILO, Geneva, 2023. doi: 10.54394/HQBQ8592.

[3] K. O. P. P. Nugraha dan A. P. Rifai, "Convolutional Neural Network for Identification of Personal Protective Equipment Usage Compliance in Manufacturing Laboratory," *J. Ilm. Tek. Ind.*, vol. 22, no. 1, hlm. 11–24, Jun 2023, doi: 10.23917/jiti.v22i1.21826.

[4] OSHA, "Worker safety series: construction." Diakses: 16 April 2024. [Daring]. Tersedia pada: https://www.osha.gov/Publications/OSHA3252/3252.html

[5] M. Mola dan H. Herlina, "Analisis Tingkat Kepatuhan Penggunaan Alat Pelindung Diri di PT Wijaya Karya Industri dan Konstruksi Pabrik Fabrikasi Baja," *J. Persada Husada Indones.*, vol. 7, no. 25, hlm. 14–22, Apr 2022, doi: 10.56014/jphi.v7i25.285.

[6] S. Indragiri dan L. Salihah, "HUBUNGAN PENGAWASAN DAN KELENGKAPAN ALAT PELINDUNG DIRI DENGAN TINGKAT KEPATUHAN PENGGUNAAN ALAT PELINDUNG DIRI," *J. Kesehat.*, vol. 10, no. 1, hlm. 1238–1245, Feb 2020, doi: 10.38165/jk.v10i1.2.

[7] N. Fenelia dan C. K. Herbawani, "FAKTOR YANG BERHUBUNGAN DENGAN KEPATUHAN PENGGUNAAN ALAT PELINDUNG DIRI PADA PEKERJA KONSTRUKSI : KAJIAN LITERATUR," *PREPOTIF J. Kesehat. Masy.*, vol. 6, no. 1, hlm. 221–230, Jan 2022, doi: 10.31004/prepotif.v6i1.2974.

[8] M. N. Nirvana, R. F. Rachmadi, dan I. K. E. Purnama, "Sistem Pendeteksi Alat Pelindung Diri (APD) Pada Pekerja Konstruksi Berbasis Convolutional Neural Network," *J. Tek. ITS*, vol. 12, no. 3, hlm. A214–A220, Des 2023, doi: 10.12962/j23373539.v12i3.121850.

[9] Z. Shi, H. Wu, Z. Jin, dan H. Song, "Detection Method of Safety Protective Equipment Based on Deep Learning," *Acad. J. Sci. Technol.*, vol. 4, no. 2, hlm. 45–49, Jan 2023, doi: 10.54097/ajst.v4i2.3897.

[10] M. Hatami, T. Tukino, F. Nurapriani, W. Widiyawati, dan W. Andriani, "DETEKSI HELMET DAN VEST KESELAMATAN SECARA REALTIME MENGGUNAKAN METODE YOLO BERBASIS WEB FLASK," *EDUSAINTEK J. Pendidik. Sains Dan Teknol.*, vol. 10, no. 1, hlm. 221–233, Jan 2023, doi: 10.47668/edusaintek.v10i1.651.

[11] A. Nurfirmansyah dan R. Dijaya, "DETEKSI KELALAIAN ALAT PELINDUNG DIRI (APD) PADA PEKERJA KONTRUKSI BANGUNAN," *inotek*, vol. 6, no. 1, hlm. 058–063, 2022, doi: 10.29407/inotek.v6i1.2452.

[12] A. Nugroho, D. A. W. K, dan F. A. Fiolana, "Klasifikasi Helm Keselamatan Mengunakan Metode Convolutional Neural Network (CNN)," *J. ZETROEM*, vol. 5, no. 2, hlm. 94–102, Okt 2023, doi: 10.36526/ztr.v5i2.2765.

[13] Masjuli, A. Taufani, dan A. A. Kasim, *Sistem Manajemen Keselamatan dan Kesehatan Kerja Berbasis SNI ISO 45001:2018*. Badan Standardisasi Nasional, 2019.

[14] I. Indrayani dan S. Sukmawati, "Gambaran Penggunaan Alat Pelindung Diri Tenaga Outsourcing Distribusi Di PT PLN (Persero) Rayon Wonomulyo Kabupaten Polewali Mandar," *J-KESMAS J. Kesehat. Masy.*, vol. 4, no. 1, hlm. 59, Jun 2019, doi: 10.35329/jkesmas.v4i1.236.

[15] J. Yao dan S. N. Tran, "Multi-output Deep-Supervised Classifier Chains for Plant Pathology," dalam *2023 International Joint Conference on Neural Networks (IJCNN)*, Gold Coast, Australia: IEEE, Jun 2023, hlm. 1–8. doi: 10.1109/IJCNN54540.2023.10191302.

[16] O. Stephen, U. J. Maduh, S. Ibrokhimov, K. L. Hui, A. Abdulhakim Al-Absi, dan M. Sain, "A Multiple-Loss Dual-Output Convolutional Neural Network for Fashion Class Classification," dalam *2019 21st International Conference on Advanced Communication Technology (ICACT)*, PyeongChang Kwangwoon_Do, Korea (South): IEEE, Feb 2019, hlm. 408–412. doi: 10.23919/ICACT.2019.8701958.

[17] D. Cao, Z. Chen, dan L. Gao, "An improved object detection algorithm based on multi-scaled and deformable convolutional neural networks," *Hum.-Centric Comput. Inf. Sci.*, vol. 10, no. 1, hlm. 14, Des 2020, doi: 10.1186/s13673-020-00219-9.

[18] Q. Feng, X. Xu, dan Z. Wang, “Deep learning-based small object detection: A survey,” *Math. Biosci. Eng.*, vol. 20, no. 4, hlm. 6551–6590, 2023, doi: 10.3934/mbe.2023282.

[19] M. Elgendy, *Deep learning for vision systems*. Shelter Island, NY: Manning Publications Co, 2020.

[20] R. Girshick, J. Donahue, T. Darrell, dan J. Malik, “Rich Feature Hierarchies for Accurate Object Detection and Semantic Segmentation,” dalam *2014 IEEE Conference on Computer Vision and Pattern Recognition*, Columbus, OH, USA: IEEE, Jun 2014, hlm. 580–587. doi: 10.1109/CVPR.2014.81.

[21] J. Redmon, S. Divvala, R. Girshick, dan A. Farhadi, “You Only Look Once: Unified, Real-Time Object Detection,” dalam *2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, Las Vegas, NV, USA: IEEE, Jun 2016, hlm. 779–788. doi: 10.1109/CVPR.2016.91.

[22] Y. Lecun, L. Bottou, Y. Bengio, dan P. Haffner, “Gradient-based learning applied to document recognition,” *Proc. IEEE*, vol. 86, no. 11, hlm. 2278–2324, Nov 1998, doi: 10.1109/5.726791.

[23] J. Plested dan T. Gedeon, “Deep transfer learning for image classification: a survey.” arXiv, 19 Mei 2022. Diakses: 7 Juli 2024. [Daring]. Tersedia pada: http://arxiv.org/abs/2205.09904

[24] A. Krizhevsky, I. Sutskever, dan G. E. Hinton, “ImageNet Classification with Deep Convolutional Neural Networks,” dalam *Advances in Neural Information Processing Systems*, F. Pereira, C. J. Burges, L. Bottou, dan K. Q. Weinberger, Ed., Curran Associates, Inc., 2012. [Daring]. Tersedia pada: https://proceedings.neurips.cc/paper_files/paper/2012/file/c399862d3b9d6b76c8436e924a68c45b-Paper.pdf

[25] K. Simonyan dan A. Zisserman, “Very Deep Convolutional Networks for Large-Scale Image Recognition.” arXiv, 10 April 2015. Diakses: 5 Juni 2024. [Daring]. Tersedia pada: http://arxiv.org/abs/1409.1556

[26] K. He, X. Zhang, S. Ren, dan J. Sun, “Deep Residual Learning for Image Recognition.” arXiv, 10 Desember 2015. Diakses: 5 Juni 2024. [Daring]. Tersedia pada: http://arxiv.org/abs/1512.03385

[27] A. G. Howard *dkk.*, “MobileNets: Efficient Convolutional Neural Networks for Mobile Vision Applications.” arXiv, 16 April 2017. Diakses: 5 Juni 2024. [Daring]. Tersedia pada: http://arxiv.org/abs/1704.04861

[28] M. Tan dan Q. V. Le, “EfficientNet: Rethinking Model Scaling for Convolutional Neural Networks.” arXiv, 11 September 2020. Diakses: 5 Juni 2024. [Daring]. Tersedia pada: http://arxiv.org/abs/1905.11946

[29] M. Spruit, M. Kais, dan V. Menger, “Automated Business Goal Extraction from E-mail Repositories to Bootstrap Business Understanding,” *Future Internet*, vol. 13, no. 10, hlm. 243, Sep 2021, doi: 10.3390/fi13100243.

[30] J. Adiwibowo, K. Gunadi, dan E. Setyati, “Deteksi Alat Pelindung Diri Menggunakan Metode YOLO dan Faster R-CNN,” *J. Infra*, vol. 8, no. 2, hlm. 106–112, 2020.

[31] R. M. Mailoa dan L. W. Santoso, “Deteksi Rompi dan Helm Keselamatan Menggunakan Metode YOLO dan CNN,” *J. Infra*, vol. 10, no. 2, hlm. 49–55, 2023.

[32] V. S. K. Delhi, R. Sankarlal, dan A. Thomas, “Detection of Personal Protective Equipment (PPE) Compliance on Construction Site Using Computer Vision Based Deep Learning Techniques,” *Front. Built Environ.*, vol. 6, hlm. 136, Sep 2020, doi: 10.3389/fbuil.2020.00136.

[33] G. Gallo, F. D. Rienzo, F. Garzelli, P. Ducange, dan C. Vallati, “A Smart System for Personal Protective Equipment Detection in Industrial Environments Based on Deep Learning at the Edge,” *IEEE Access*, vol. 10, hlm. 110862–110878, 2022, doi: 10.1109/ACCESS.2022.3215148.

[34] R. D. W. Pradana *dkk.*, “Identification System of Personal Protective Equipment Using Convolutional Neural Network (CNN) Method,” dalam *2019 International Symposium on Electronics and Smart Devices (ISESD)*, Badung-Bali, Indonesia: IEEE, Okt 2019, hlm. 1–6. doi: 10.1109/ISESD.2019.8909629.

[35] J.-Y. Lee, W.-S. Choi, dan S.-H. Choi, “Verification and performance comparison of CNN-based algorithms for two-step helmet-wearing detection,” *Expert Syst. Appl.*, vol. 225, hlm. 120096, Sep 2023, doi: 10.1016/j.eswa.2023.120096.

[36] Y. Zhou, F.-J. Chang, L.-C. Chang, I.-F. Kao, dan Y.-S. Wang, “Explore a deep learning multi-output neural network for regional multi-step-ahead air quality forecasts,” *J. Clean. Prod.*, vol. 209, hlm. 134–145, Feb 2019, doi: 10.1016/j.jclepro.2018.10.243.

[37] D. Jo, C.-H. Lee, H. Kim, H. Kim, J. B. Kim, dan D.-J. Kim, “EEG-Based Multioutput Classification of Sleep Stage and Apnea Using Deep Learning,”

dalam *2023 11th International Winter Conference on Brain-Computer Interface (BCI)*, Gangwon, Korea, Republic of: IEEE, Feb 2023, hlm. 1–4. doi: 10.1109/BCI57258.2023.10078663.

[38] Z. Wang, Y. Wu, L. Yang, A. Thirunavukarasu, C. Evison, dan Y. Zhao, "Fast Personal Protective Equipment Detection for Real Construction Sites Using Deep Learning Approaches," *Sensors*, vol. 21, no. 10, hlm. 3478, Mei 2021, doi: 10.3390/s21103478.

[39] R. Xiong dan P. Tang, "Pose guided anchoring for detecting proper use of personal protective equipment," *Autom. Constr.*, vol. 130, hlm. 103828, Okt 2021, doi: 10.1016/j.autcon.2021.103828.

[40] R. Duan, H. Deng, M. Tian, Y. Deng, dan J. Lin, "SODA: A large-scale open site object detection dataset for deep learning in construction," *Autom. Constr.*, vol. 142, hlm. 104499, Okt 2022, doi: 10.1016/j.autcon.2022.104499.

[41] T.-Y. Lin *dkk.*, "Microsoft COCO: Common Objects in Context." arXiv, 20 Februari 2015. Diakses: 10 Juni 2024. [Daring]. Tersedia pada: http://arxiv.org/abs/1405.0312

[42] P. P. E. datacustom, "safety-boots Dataset," *Roboflow Universe*. Roboflow, April 2022. [Daring]. Tersedia pada: https://universe.roboflow.com/ppe-datacustom/safety-boots-rmxcj

[43] H. Rezatofighi, N. Tsoi, J. Gwak, A. Sadeghian, I. Reid, dan S. Savarese, "Generalized Intersection over Union: A Metric and A Loss for Bounding Box Regression." arXiv, 14 April 2019. Diakses: 19 Juni 2024. [Daring]. Tersedia pada: http://arxiv.org/abs/1902.09630

[44] P. Singh, N. Singh, K. K. Singh, dan A. Singh, "Diagnosing of disease using machine learning," dalam *Machine Learning and the Internet of Medical Things in Healthcare*, Elsevier, 2021, hlm. 89–111. doi: 10.1016/B978-0-12-821229-5.00003-3.

LAMPIRAN

Lampiran 1 Kode Program Model Klasifikasi APD Multi-output

```
class VGG16BackboneV2(nn.Module):

    def __init__(self, freeze_layer: bool, pretrained: bool) ->
None:
        super(VGG16BackboneV2, self).__init__()

        if pretrained:
            model = vgg16(weights=VGG16_Weights)
        else:
            model = vgg16()

        self.backbone = model.features

        if freeze_layer:
            for param in self.backbone.parameters():
                param.requires_grad = False

        self.classifier_input_features =
model.classifier[0].in_features

    def forward(self, x: torch.Tensor) -> torch.Tensor:
        x = self.backbone(x)
        return x

class ClassifierBlockV2(nn.Module):

    def __init__(
        self,
        in_features: int,
        helmet_class: int,
        vest_class: int,
        boots_class: int,
        dropout_rate: float,
    ) -> None:
        super(ClassifierBlockV2, self).__init__()

        # helmet classifier with batch normalization
        self.helmet_classifier = nn.Sequential(
            nn.Linear(in_features, 128),
            nn.BatchNorm1d(128),
            nn.ReLU(),
            nn.Linear(128, 64),
```

```
            nn.BatchNorm1d(64),
            nn.ReLU(),
            nn.Dropout(dropout_rate),
            nn.Linear(64, helmet_class),
        )

        # vest classifier with batch normalization
        self.vest_classifier = nn.Sequential(
            nn.Linear(in_features, 128),
            nn.BatchNorm1d(128),
            nn.ReLU(),
            nn.Linear(128, 64),
            nn.BatchNorm1d(64),
            nn.ReLU(),
            nn.Dropout(dropout_rate),
            nn.Linear(64, vest_class),
        )

        # boots classifier with batch normalization
        self.boots_classifier = nn.Sequential(
            nn.Linear(in_features, 128),
            nn.BatchNorm1d(128),
            nn.ReLU(),
            nn.Linear(128, 64),
            nn.BatchNorm1d(64),
            nn.ReLU(),
            nn.Dropout(dropout_rate),
            nn.Linear(64, boots_class),
        )

    def forward(
        self, x: torch.Tensor
    ) -> Tuple[torch.Tensor, torch.Tensor, torch.Tensor]:
        helmet = self.helmet_classifier(x)
        vest = self.vest_classifier(x)
        boots = self.boots_classifier(x)

        return helmet, vest, boots
```

Kode lengkap dapat dilihat pada https://github.com/hiseulgi/ppe-identification/.

Lampiran 2 Kode Program Model Deteksi Pekerja

```
...

# DATA SETUP
# data module setup
datamodule = CocoDataModule(
    datasets_name=params_cfg.DATAMODULE.DATASETS_NAME,
    images_path=params_cfg.DATAMODULE.IMAGES_PATH,
    train_annotations_path=params_cfg.DATAMODULE.TRAIN_ANNOTATIONS
,
    val_annotations_path=params_cfg.DATAMODULE.VAL_ANNOTATIONS,
    test_annotations_path=params_cfg.DATAMODULE.TEST_ANNOTATIONS,
)

# get total number of train images
params_cfg.DATAMODULE.TOTAL_NUM_TRAIN_IMAGES =
datamodule.get_total_images(
    split="train"
)

# MODEL SETUP
# model config setup
cfg = FasterRCNN(
    datasets_name=params_cfg.DATAMODULE.DATASETS_NAME,
    total_number_images=params_cfg.DATAMODULE.TOTAL_NUM_TRAIN_IMAG
ES,
    model_config=params_cfg.MODEL_FACTORY.CFG,
    hyperparameters_config=params_cfg.MODEL_FACTORY.HYPERPARAMS,
    total_epochs=params_cfg.MODEL_FACTORY.TOTAL_EPOCHS,
    is_use_epoch=params_cfg.MODEL_FACTORY.IS_USE_EPOCH,
).get_cfg()

# TRAINER SETUP
# trainer setup
trainer = CometDefaultTrainer(cfg, experiment)

# calculate eval period based on total epochs
if params_cfg.MODEL_FACTORY.IS_USE_EPOCH:
    cfg.TEST.EVAL_PERIOD = (
        cfg.SOLVER.MAX_ITER //
params_cfg.MODEL_FACTORY.TOTAL_EPOCHS
    )

# Register Hook to compute metrics using an Evaluator Object
trainer.register_hooks(
    [
```

```
        hooks.EvalHook(
            cfg.TEST.EVAL_PERIOD,
            lambda: trainer.evaluate_metrics(cfg, trainer.model),
        )
    ]
)

# Register Hook to compute eval loss
trainer.register_hooks(
    [
        hooks.EvalHook(
            cfg.TEST.EVAL_PERIOD, lambda:
trainer.evaluate_loss(cfg, trainer.model)
        )
    ]
)

...
```

Kode lengkap dapat dilihat pada https://github.com/hiseulgi/detectron2-trainer/.

Lampiran 3 Kode Program *Deployment* Prototipe Web

```
...

model = load_model_state()
is_predicted = False
preds = []

detect_conf = st.sidebar.slider("Detection Confidence", 0.0, 1.0,
0.4, 0.05)
classify_conf = 0.5
is_show_classes = st.sidebar.checkbox("Show Prediction Classes",
value=True)
input_method = st.sidebar.selectbox(
    "Choose an input method:", ("Upload Image", "Use Webcam")
)

# Main content
st.title("Image Inference Demo")

col1, col2 = st.columns(2, gap="medium")

# Column 1: Image Input
```

```
with col1:
    img_input = None

    if input_method == "Upload Image":
        uploaded_file = st.file_uploader(
            "Choose an image...", type=["jpg", "jpeg", "png"],
key="file"
        )

        if uploaded_file is not None:
            img_input = Image.open(uploaded_file)

    elif input_method == "Use Webcam":
        uploaded_file = st.camera_input("Take a picture")

        if uploaded_file is not None:
            img_input = Image.open(uploaded_file)

    if img_input is not None and input_method == "Upload Image":
        st.image(img_input, caption="Input Image")

# Column 2: Image Inference
with col2:
    img_array = None

    if img_input is not None:
        st.write("Predict the image...")

        if st.button("Predict", type="primary",
use_container_width=True):
            start_time = time()
            try:
                # Convert image to numpy array
                img_array = np.array(img_input)

                # Predict
                preds = model.predict(img_array, detect_conf,
classify_conf)

                if len(preds) != 0:
                    # Draw annotations
                    img_result = model.draw_annotations(
                        img_array, preds, is_show_classes, True
                    )

                    st.image(
                        img_result,
```

```
                        caption="Predicted Image",
                        use_column_width=True,
                    )

                    duration = time() - start_time

                    st.toast(
                        f"Prediction completed in {duration:.2f}
seconds.",
                        icon="🎉",
                    )
                else:
                    st.warning("No person detected in the image.")

                is_predicted = True

            except Exception as e:
                st.exception(e)
                st.toast("An error occurred during prediction.",
icon="❌")
    else:
        st.write("")
        st.write("")
        st.info("Please upload an image file or take a picture
using webcam.")

...
```

Kode lengkap dapat dilihat pada https://github.com/hiseulgi/ppe-engine/.

Lampiran 4 Lembar Kontrol Bimbingan

	LEMBAR KONTROL BIMBINGAN TUGAS AKHIR/SKRIPSI	No. PM	7.5.18/L1
		Revisi	2
		Tanggal	1 Juli 2010
		Halaman	1 / 2

Nama : MUHAMMAD BAGUS ADI PRAYOGA Kelas : TI-4A NIM : 4.33.20.0.17	Judul Tugas Akhir/Skripsi : SISTEM CERDAS MULTI-OUTPUT MODEL DEEP LEARNING PADA IDENTIFIKASI ALAT PELINDUNG DIRI DI LINGKUNGAN INDUSTRI

No	Tanggal	Uraian	Tandatangan Pembimbing
1.	6 Februari 2024	Bimbingan proposal skripsi	1
2.	20 Februari 2024	Bimbingan datasets dan model deteksi objek serta klasifikasi	2
3.	13 Maret 2024	Progres artikel ilmiah dan pelatihan model	3
4.	17 April 2024	Laporan pelatihan ulang model dengan datasets baru	4
5.	8 Mei 2024	Bimbingan deployment web prototipe	5
6.	20 Mei 2024	Laporan skripsi BAB 3-4	6.
7.	13 Juni 2024	Revisi laporan skripsi BAB 3-4 dan artikel ilmiah	7
8.	25 Juni 2024	Finalisasi laporan skripsi dan artikel ilmiah	8

Semarang,
Pembimbing I

Prayitno, S.ST., M.T., Ph.D.
NIP 198504102014041002

	LEMBAR KONTROL BIMBINGAN TUGAS AKHIR/SKRIPSI	No. PM	7.5.18/L1
		Revisi	2
		Tanggal	1 Juli 2010
		Halaman	1 / 2

Nama : MUHAMMAD BAGUS ADI PRAYOGA Kelas : TI-4A NIM : 4.33.20.0.17	Judul Tugas Akhir/Skripsi : SISTEM CERDAS MULTI-OUTPUT MODEL DEEP LEARNING PADA IDENTIFIKASI ALAT PELINDUNG DIRI DI LINGKUNGAN INDUSTRI

No	Tanggal	Uraian	Tandatangan Pembimbing
1.	2 Februari 2024	Bimbingan proposal skripsi	1
2.	4 Maret 2024	Bimbingan datasets dan hasil pelatihan model deteksi objek	2
3.	18 April 2024	Laporan pelatihan ulang model dengan datasets baru	3
4.	7 Mei 2024	Bimbingan deployment web prototipe	4
5.	14 Mei 2024	Laporan skripsi BAB 1-3	5
6.	5 Juni 2024	Laporan skripsi BAB 3-4	6
7.	20 Juni 2024	Revisi laporan skripsi BAB 3-4	7
8.	26 Juni 2024	finalisasi laporan skripsi dan artikel ilmiah	8

Semarang,
Pembimbing II

Nurseno Bayu Aji, S.Kom., M.Kom.
NIP 19910730201903101O

	SURAT KETERANGAN SELESAI BIMBINGAN SKRIPSI	No. FPM	7.5.18/L2
		Revisi	2
		Tanggal	1 Juli 2010
		Halaman	1 / 2

JURUSAN TEKNIK ELEKTRO	SURAT KETERANGAN SELESAI BIMBINGAN SKRIPSI

Kepada:
Yth. Ketua Program Studi Teknologi Rekayasa Komputer
Politeknik Negeri Semarang

Yang bertanda tangan di bawah ini, Pembimbing I dan Pembimbing II menerangkan bahwa:

No.	Nama	NIM	Kelas
1	Muhammad Bagus Adi Prayoga	4.33.20.0.17	TI-4A

Dengan judul Tugas Akhir:

" Sistem Cerdas Multi-output Model Deep Learning pada Identifikasi Alat Pelindung Diri di Lingkungan Industri "

Benar-benar telah menyelesaikan pembuatan skripsi dan siap untuk melakukan ujian wawancara skripsi.

Semarang, 28 Juni 2023

Pembimbing I,

Prayitno, S.ST., M.T., Ph.D.
NIP 198504102014041002

Pembimbing II,

Nurseno Bayu Aji, S.Kom., M.Kom.
NIP 199107302019031010

	SURAT KETERANGAN SIAP UJIAN SKRIPSI	No. FPM	7.5.18/L6
		Revisi	2
		Tanggal	1 Juli 2010
		Halaman	1 / 1

SURAT KETERANGAN

SIAP UJIAN SKRIPSI

Kepada:
Yth. Ketua Program Studi Teknologi Rekayasas Komputer
Politeknik Negeri Semarang

Yang bertanda tangan di bawah ini, Pembimbing I dan Pembimbing II menerangkan bahwa:

No.	Nama	NIM	Kelas
1	Muhammad Bagus Adi Prayoga	4.33.20.0.17	TI-4A

Dengan judul Tugas Akhir:

" Sistem Cerdas Multi-output Model Deep Learning pada Identifikasi Alat Pelindung Diri di Lingkungan Industri "

Benar-benar telah menyelesaikan pembuatan skripsi dan siap untuk melakukan ujian wawancara skripsi.

Semarang, 28 Juni 2023

Pembimbing I,

Prayitno, S.ST., M.T., Ph.D.
NIP 198504102014041002

Pembimbing II,

Nurseno Bayu Aji, S.Kom., M.Kom.
NIP 199107302019031010

Lampiran 5 Surat Tugas

KEMENTERIAN PENDIDIKAN, KEBUDAYAAN,
RISET, DAN TEKNOLOGI
POLITEKNIK NEGERI SEMARANG
Jalan Prof. H. Soedarto, S.H, Tembalang, Semarang 50275, PO BOX 6199/SMS
Telephone (024) 7473417, 7499585, 7499586, Facsimile (024) 7472396
http://www.polines.ac.id, E-mail : sekretariat@polines.ac.id

Jurusan T. Elektro POLINES	SURAT TUGAS NO. 3256B /PL4.1.3/PKL/2024	

Ketua Jurusan Teknik Elektro memberi tugas kepada Tim Penguji Tugas Akhir berikut ini :

NO.	JABATAN	NAMA PENGUJI	NIP
1.	Ketua Penguji	PRAYITNO, S.ST., M.T., Ph.D.	198504102014041002
2.	Sekretaris	SUKO TYAS PERNANDA, M.Cs.	199109172022031007
3.	Penguji I	IDHAWATI HESTININGSIH, S.KOM, M.KOM.	197711192008012013
4.	Penguji II	AFANDI NUR AZIZ THOHARI, S.T., M.CS.	199004112019031014
5.	Penguji III	WIKTASARI, S.T., M.KOM.	198703272019032012

Untuk menguji mahasiswa tersebut :

NO.	NAMA	NIM	KELAS
1.	MUHAMMAD BAGUS ADI PRAYOGA	4.33.20.0.17	TI-4A

Yang didampingi Pembimbing sebagai berikut :

NO.	JABATAN	NAMA PEMBIMBING	NIP
1.	Pembimbing I	PRAYITNO, S.ST., M.T., Ph.D.	198504102014041002
2.	Pembimbing II	NURSENO BAYU AJI, S.KOM., M.KOM.	199107302019031010

Dengan Judul Tugas Akhir :
SISTEM CERDAS MULTI-OUTPUT MODEL DEEP LEARNING PADA IDENTIFIKASI ALAT PELINDUNG DIRI DI LINGKUNGAN INDUSTRI.

Yang dilaksanakan pada waktu sebagai berikut :
Hari, tanggal : Jum'at / 5 Juli 2024
Waktu : 09.00 – 10.30 WIB
Tempat : R. Lab. Multimedia

Tugas ini supaya dijalankan dengan sebaik-baiknya dan hasilnya dilaporkan kepada Jurusan.

Semarang, 1 Juli 2024
Ketua Jurusan Teknik Elektro,

YUSNAN BADRUZZAMAN, S.T.,M.ENG.
NIP 197503132006041001

Diserahkan ke Tim Penguji Tugas Akhir (lima orang) dan Pembimbing paling lambat tiga hari sebelum ujian, beserta naskah Tugas Akhir untuk Penguji.

Lampiran 6 Form Revisi Skripsi

	FORMULIR PROSEDUR	No. PM	F.PPd.4.08-L1
politeknik negeri SEMARANG	LEMBAR REVISI SKRIPSI	Revisi	3
		Tanggal	21.12.2017
		Halaman	1 / 3

No	Uraian	Tandatangan Penguji
1	Revisi lihat di laporan	
2	Gambar sampel diperbesar	

Semarang, 5 Juli 2024

Penguji I,

Idhawati Hestiningsih, S. Kom., M. Kom.

NIP. 197711192008012013

	FORMULIR PROSEDUR	No. PM	F.PPd.4.08-L1
	LEMBAR REVISI SKRIPSI	Revisi	3
		Tanggal	21.12.2017
		Halaman	2 / 3

No	Uraian	Tandatangan Penguji
1	Lihat di Laporan	

Semarang, 5 Juli 2024

Penguji II,

Afandi Nur Aziz Thohari, S.T., M.Cs.

NIP. 199004112019031014

	FORMULIR PROSEDUR	No. PM	F.PPd.4.08-L1
	LEMBAR REVISI SKRIPSI	Revisi	3
		Tanggal	21.12.2017
		Halaman	3 / 3

No	Uraian	Tandatangan Penguji
1	Tinjauan pustaka	
2	Tambah sepatu (dataset)	
3	Tambahkan hasil untuk model deteksi objek	

Semarang, 5 Juli 2024

Penguji III,

Wiktasari, S.T., M.Kom

NIP. 198703272019032012

Lampiran 7 Surat Keterangan Selesai Revisi Skripsi

	FORMULIR PROSEDUR	No. FP	F.PPd.4.08-L3
	REVISI SKRIPSI	Revisi	3
		Tanggal	21.12.2017
		Halaman	1 / 1

Yang bertanda tangan di bawah ini, Penguji I/II/III menerangkan bahwa:

No.	Nama	NIM	Kelas
1	Muhammad Bagus Adi Prayoga	4.33.20.0.17	TI-4A

Dengan judul Skripsi :

Sistem Cerdas Multi-output Model Deep Learning pada Identifikasi Alat Pelindung Diri di Lingkungan Industri

Benar-benar telah melaksanakan revisi skripsi. Surat keterangan ini dapat dipergunakan sebagaimana mestinya.

Semarang, 5 Juli 2024

Penguji I,	Penguji II,	Penguji III,
Idhawati Hestiningsih, S. Kom., M. Kom.	Afandi Nur Aziz Thohari, S.T., M.Cs.	Wiktasari, S.T., M.Kom.
NIP. 197711192008012013	NIP. 199004112019031014	NIP. 198703272019032012