RANCANG BANGUN APLIKASI PREDIKSI BEBAN PUNCAK PENGGUNAAN LISTRIK PADA PEMBANGKIT LISTRIK DENGAN MODEL *DEEP LEARNING* BERBASIS WEB: STUDI KASUS WEB "*CONNECT* UP2DJTY"

Disusun oleh:

Elza Safira Permatasari

4.33.20.0.09

PROGRAM STUDI S.Tr TEKNOLOGI REKAYASA KOMPUTER

JURUSAN TEKNIK ELEKTRO

POLITEKNIK NEGERI SEMARANG

2024

RANCANG BANGUN APLIKASI PREDIKSI BEBAN PUNCAK PENGGUNAAN LISTRIK PADA PEMBANGKIT LISTRIK DENGAN MODEL *DEEP LEARNING* BERBASIS WEB: STUDI KASUS WEB "*CONNECT* UP2DJTY"

Skripsi ini disusun untuk melengkapi sebagian persyaratan menjadi Sarjana Terapan

Disusun oleh:

Elza Safira Permatasari

4.33.20.0.09

PROGRAM STUDI S.Tr TEKNOLOGI REKAYASA KOMPUTER

JURUSAN TEKNIK ELEKTRO

POLITEKNIK NEGERI SEMARANG

2024

PERNYATAAN KEASLIAN SKRIPSI

Saya menyatakan dengan sesungguhnya bahwa skripsi dengan judul **Rancang Bangun Aplikasi Prediksi Beban Puncak Penggunaan Listrik pada Pembangkit Listrik dengan Model *Deep Learning* Berbasis Web: Studi Kasus Web "*Connect* UP2DJTY"** yang dibuat untuk melengkapi sebagian persyaratan menjadi Sarjana Terapan pada Program Studi S.Tr Teknologi Rekayasa Komputer Jurusan Teknik Elektro Politeknik Negeri Semarang, sejauh yang saya ketahui bukan merupakan tiruan atau duplikasi dari skripsi yang sudah dipublikasikan dan atau pernah dipakai untuk mendapatkan gelar Sarjana terapan di lingkungan Politeknik negeri Semarang maupun di perguruan tinggi atau instansi manapun, kecuali bagian yang sumber informasinya dicantumkan sebagaimana mestinya.

Semarang, 27 Juni 2024

Penulis

Elza Safira Permatasari

NIM 4.33.20.0.09

HALAMAN PERSETUJUAN

Skripsi dengan judul **Rancang Bangun Aplikasi Prediksi Beban Puncak Penggunaan Listrik pada Pembangkit Listrik dengan Model *Deep Learning* Berbasis Web: Studi Kasus Web "*Connect* UP2DJTY"** dibuat untuk melengkapi sebagian persyaratan menjadi Sarjana terapan pada Program Studi S.Tr Teknologi Rekayasa Komputer, Jurusan Teknik Elektro Politeknik Negeri Semarang dan disetujui untuk diajukan dalam sidang ujian skripsi.

Semarang, 27 Juni 2024

Pembimbing I,	Pembimbing II,
Prayitno, S.ST., M.T., Ph.D.	Wiktasari, S.T., M.Kom.
NIP. 198504102014041002	NIP. 198703272019032012

Mengetahui,

Ketua Program Studi S.Tr Teknologi Rekayasa Komputer

Kuwat Santoso, S.T., M.Kom.

NIP. 198407192019031008

HALAMAN PENGESAHAN

Skripsi dengan judul **Rancang Bangun Aplikasi Prediksi Beban Puncak Penggunaan Listrik pada Pembangkit Listrik dengan Model Deep Learning Berbasis Web: Studi Kasus Web "Connect UP2DJTY"** telah dipertahankan dalam ujian wawancara dan diterima sebagai syarat untuk menjadi Sarjana Terapan pada Program Studi S.Tr Teknologi Rekayasa Komputer Jurusan Teknik Elektro Politeknik Negeri Semarang pada tanggal 5 Juli 2024.

Tim Penguji

Penguji I,	Penguji II,	Penguji III,
Mardiyono, S.Kom., M.Sc.	Tri Raharjo Yudantoro, S.Kom., M. Kom.	Nurseno Bayu Aji, S.Kom., M.Kom.
NIP. 197403112000121001	NIP. 196810252000121001	NIP. 199107302019031010

Ketua,	Sekretaris,
Prayitno, S.ST., M.T., Ph.D.	Muttabik Fathul Lathief S.Kom., M.Eng.
NIP. 198504102014041002	NIP. 199209092020121007

Mengesahkan,
Ketua Jurusan Teknik Elektro

Yusnan Badruzzaman, S.T., M.Eng.
NIP. 197503132006041001

KATA PENGANTAR

Puji syukur atas segala nikmat dan karunia yang telah diberikan oleh Tuhan Yang Maha Esa, sehingga penulis dapat menyelesaikan skripsi sebagai salah satu rangkaian akademis dari Program Studi S.Tr Teknologi Rekayasa Komputer Jurusan Teknik Elektro Politeknik Negeri Semarang.

Adapun tujuan dari penulisan skripsi ini adalah untuk memenuhi persyaratan kelulusan mahasiswa yang dibuat oleh Program Studi S.Tr Teknologi Rekayasa Komputer. Serta sebagai sarana belajar bagi para pembaca yang ingin mengetahui pembuatan dan hasil dari Rancang Bangun Aplikasi Prediksi Beban Puncak Penggunaan Listrik pada Pembangkit Listrik dengan Model *Deep Learning* Berbasis Web: Studi Kasus Web "*Connect* UP2DJTY".

Penulis ucapkan terima kasih kepada seluruh pihak yang telah memberikan bantuan, dukungan, serta doanya kepada penulis untuk menyelesaikan program ini secara baik. Pihak – pihak yang terkait itu diantaranya sebagai berikut:

1. Bapak Yusnan Badruzzaman, S.T.,M.Eng, Ketua Jurusan Teknik Elektro Politeknik Negeri Semarang
2. Kuwat Santoso, S.T., M.Kom., Ketua Program Studi S.Tr Teknologi Rekayasa Komputer Politeknik Negeri Semarang.
3. Prayitno, S.ST., M.T., Ph.D., Dosen Pembimbing 1
4. Wiktasari, S.T., M.Kom., Dosen Pembimbing 2
5. Keluarga dari penulis
6. Tallentzia Dara Bagasurya Huntoro, Amaranggana Hang-Arna Prianto, dan Talitha Rajni Syahda Nabilah sahabat dari penulis.

Semarang, 4 Mei 2024
Penulis

Elza Safira Permatasari
NIM 4.33.20.0.09

ABSTRAK

Elza Safira Permatasari, "Rancang Bangun Aplikasi Prediksi Beban Puncak Penggunaan Listrik pada Pembangkit Listrik dengan Model Deep Learning Berbasis Web*: Studi Kasus* Web *"Connect UP2DJTY"", Skripsi DIV Jurusan Teknik Elektro Politeknik Negeri Semarang, di bawah bimbingan Prayitno, S.ST., M.T., Ph.D. dan Wiktasari, S.T., M.Kom., Juni 2024, 53.*

PT PLN (Persero) adalah perusahaan Badan Usaha Milik Negara (BUMN) yang bertanggung jawab atas penyediaan layanan listrik nasional di Indonesia. Dalam menjalankan tugasnya, PT (PLN) Persero Unit Pelaksana Pengatur Distribusi Jateng dan DIY menghadapi tantangan dalam memprediksi beban puncak pembangkit listrik, yang bersifat *time series* dan nonlinear. Penelitian ini bertujuan untuk mengembangkan sistem prediksi beban puncak menggunakan metode *deep learning*, yaitu *Gated Recurrent Unit* (GRU), *Recurrent Neural Network* (RNN), *Long Short-Term Memory* (LSTM), *Convolutional Neural Network* (CNN), dan *hybrid* LSTM-GRU.

Penelitian ini menggunakan data simulasi dari web RTE dan data prediksi dari data historis beban listrik perusahaan yang diolah melalui berbagai tahap seperti persiapan data, pembuatan model, pelatihan, dan evaluasi hasil *error*. Hasil penelitian menunjukkan bahwa di antara kelima metode yang digunakan, GRU dengan konfigurasi 64-unit, *batch size* 70, dan *validation split* 0,4 memiliki kinerja terbaik dengan nilai RMSE sebesar 24,87%, MSE sebesar 6,18%, dan MAE sebesar 15,05%.

Implementasi sistem prediksi ini dilakukan dalam bentuk aplikasi berbasis web yang menggunakan API dari *framework* Flask. Aplikasi ini memungkinkan PT PLN untuk mengelola dan memprediksi beban puncak secara lebih efektif dan efisien, sehingga dapat membantu dalam perencanaan dan pengelolaan sistem kelistrikan secara keseluruhan. Penelitian ini memberikan kontribusi praktis bagi PT PLN dalam mengoptimalkan distribusi sumber daya dan mengurangi risiko pelepasan beban yang berdampak negatif pada ekonomi nasional.

Kata kunci: *Deep Learning,* GRU, RNN, LSTM, CNN, *Hybrid* LSTM-GRU, Prediksi Beban Puncak.

ABSTRACT

Elza Safira Permatasari, "Design and Development of Peak Electricity Usage Prediction Application in Power Plants using Web-Based Deep Learning Model: A Case Study of 'Connect UP2DJTY' Web", Thesis of the Department of Electrical Engineering, State Polytechnic of Semarang, under the guidance of Prayitno, S.ST., M.T., Ph.D. and Wiktasari, S.T., M.Kom., June 2024, 53.

PT PLN (Persero) *is a state-owned enterprise responsible for providing national electricity services in Indonesia. In carrying out its duties,* PT PLN (Persero) Unit Pelaksana Pengatur Distribusi Jateng dan DIY *faces challenges in predicting peak loads for power plants, which are characterized by time series and nonlinear properties. This study aims to develop a peak load prediction system using deep learning methods, namely Gated Recurrent Unit (GRU), Recurrent Neural Network (RNN), Long Short-Term Memory (LSTM), Convolutional Neural Network (CNN), and hybrid LSTM-GRU.*

The study uses simulation data from the RTE web and prediction data from the company's historical electricity load data, processed through various stages such as data preparation, model creation, training, and error evaluation. The results show that among the five methods used, GRU with a configuration of 128 units, batch size of 70, and validation split of 0.4 performed the best, with RMSE of 24.87%, MSE of 6.18%, and MAE of 15.05%.

The prediction system implementation is in the form of a web-based application using an API from the Flask framework. This application enables PT PLN (Persero) *to manage and predict peak loads more effectively and efficiently, thereby assisting in the overall planning and management of the electrical system. This study provides practical contributions to* PT PLN (Persero) *in optimizing resource distribution and reducing the risk of load shedding, which negatively impacts the national economy.*

Keywords: Deep Learning, GRU, RNN, LSTM, CNN, Hybrid LSTM-GRU, Peak Load Prediction.

DAFTAR ISI

HALAMAN JUDUL ii
PERNYATAAN KEASLIAN SKRIPSI iii
HALAMAN PERSETUJUAN iv
HALAMAN PENGESAHAN v
KATA PENGANTAR vi
ABSTRAK vii
ABSTRACT viii
DAFTAR ISI ix
DAFTAR TABEL xi
DAFTAR GAMBAR xii
BAB I 1
PENDAHULUAN 1
1.1. Latar Belakang 1
1.2. Rumusan Masalah 3
1.3. Batasan Masalah 3
1.4. Tujuan 4
1.5. Manfaat 4
1.6. Sistematika Penulisan 4
BAB II 7
TINJAUAN PUSTAKA 7
2.1. Dasar Teori 7
2.2. Alat dan Teknologi yang Digunakan 20
2.3. *Waterfall* 28
BAB III 29
KEGIATAN PELAKSANAAN 29
3.1. Metode Pelaksanaan 29
3.2. Gambaran Umum Sistem 31
3.3. Analisis Kebutuhan 33
3.4. Perancangan Sistem 34
BAB IV 40
ANALISIS DAN PEMBAHASAN 40
4.1. Analisis Algoritma 40

BAB V 56
KESIMPULAN 56
5.1. Kesimpulan 56
5.2. Saran 56
DAFTAR PUSTAKA 58
LAMPIRAN 63
A. Lembar Kontrol Bimbingan 63
B. Surat Keterangan Selesai bimbingan Skripsi 65
C. Surat Keterangan Siap Ujian Skripsi 66
D. Surat Tugas 67
E. Lembar Revisi Skripsi 68
F. Lembar Pernyataan Telah Melakukan Revisi 71
G. Lembar Responden 72
H. Dokumentasi 74
I. Kode Program *Deep Learning* 75
J. Kode Program *Flask* 76
K. Kode Program Larvel *Controller* 78
L. Kode Program Larvel *View* 78

DAFTAR TABEL

Tabel 2. 1 Perbandingan Model Antar Jurnal pendahulu 20
Tabel 4. 1 Contoh Dataset Simulasi Beban Puncak 40
Tabel 4. 2 Skenario Ukuran Data 41
Tabel 4. 3 Hasil Percobaan GRU Skenario 1 42
Tabel 4. 4 Hasil Percobaan GRU Skenario 2 42
Tabel 4. 5 Hasil Percobaan GRU Skenario 3 42
Tabel 4. 6 Hasil Percobaan LSTM Skenario 1 43
Tabel 4. 7 Hasil Percobaan LSTM Skenario 2 43
Tabel 4. 8 Hasil Percobaan LSTM Skenario 3 43
Tabel 4. 9 Hasil Percobaan RNN Skenario 1 44
Tabel 4. 10 Hasil Percobaan RNN Skenario 2 44
Tabel 4. 11 Hasil Percobaan RNN Skenario 3 44
Tabel 4. 12 Hasil Percobaan CNN Skenario 1 45
Tabel 4. 13 Hasil Percobaan CNN Skenario 2 45
Tabel 4. 14 Hasil Percobaan CNN Skenario 3 45
Tabel 4. 15 Hasil Percobaan Hybrid LSTM-GRU Skenario 1 46
Tabel 4. 16 Hasil Percobaan Hybrid LSTM-GRU Skenario 2 46
Tabel 4. 17 Hasil Percobaan Hybrid LSTM-GRU Skenario 3 47
Tabel 4. 18 Hasil Terbaik dari Seluruh Model 47
Tabel 4. 19 Hasil Prediksi Pembangkit Tahun 2024 52

DAFTAR GAMBAR

Gambar 2. 1 Arsitektur RNN 24
Gambar 2. 2 Arsitektur LSTM 25
Gambar 2. 3 Arsitektur GRU 26
Gambar 2. 4 Arsitektur CNN 26
Gambar 3. 1 Metode *Waterfall* 29
Gambar 3. 2 Gambaran Umum Sistem 31
Gambar 3. 3 *Use Case Diagram* 35
Gambar 3. 4 Rincian *Use Case Diagram* 35
Gambar 3. 5 *Activity Diagram* 36
Gambar 3. 6 *Flowchart* Model Prediksi 37
Gambar 3. 7 *Mockup* Halaman Login 38
Gambar 3. 8 *Mockup* Halaman Dashboard 39
Gambar 4. 1 Grafik Hasil Terbaik Model Hybrid LSTM-GRU 48
Gambar 4. 2 Grafik Hasil Terbaik Model CNN 48
Gambar 4. 3 Grafik Hasil Terbaik Model RNN 49
Gambar 4. 4 Grafik Hasil Terbaik Model LSTM 49
Gambar 4. 5 Grafik Hasil Terbaik Model GRU 50
Gambar 4. 6 Grafik Hasil Prediksi Beban Puncak Pembangkit Listrik 51
Gambar 4. 7 Response API *Framework* Flask 52
Gambar 4. 8 Tampilan Grafik Prediksi Januari 53
Gambar 4. 9 Tampilan Grafik Prediksi Februari 53
Gambar 4. 10 Tampilan Grafik Prediksi Maret 54
Gambar 4. 11 Tampilan Grafik Prediksi April 54
Gambar 4. 12 Tampilan Grafik Prediksi Hanya 1 Pembangkit 55

BAB I

PENDAHULUAN

1.1. Latar Belakang

PT PLN (Persero), salah satu perusahaan BUMN bergerak di bidang energi listrik, bertanggung jawab menyediakan listrik di seluruh Indonesia melalui pembangkit listrik yang mengubah berbagai sumber energi menjadi energi listrik. Pada pembangkit listrik, terdapat istilah beban yang berarti daya atau energi listrik yang digunakan oleh penduduk sekitar, dengan nilai data beban yang bersifat *time series* dan tidak tetap atau nonlinear tergantung pemakaian penduduk (Huang et al., 2022). PT PLN (Persero) Unit Pelaksana Pengatur Distribusi Jawa Tengah dan Yogyakarta saat ini menghadapi kesulitan dalam memprediksi beban puncak pembangkit listrik. Salah satu usaha untuk membantu menyelesaikan permasalahan ini adalah membuat sistem yang dapat memprediksi beban puncak pembangkit listrik.

Prediksi beban energi selalu menjadi topik penting dalam sektor ketenagalistrikan dan salah satu hal yang membantu perusahaan ketenagalistrikan menjadi lebih efisien secara ekonomi. Selain itu, pembangkit listrik mempunyai kapasitas terbatas yang besarnya ditentukan oleh pola umum berdasarkan permintaan pelanggan. Peramalan penggunaan puncak listrik penting dalam situasi ini karena dapat memperoleh keuntungan dari penggunaan beberapa model atau teknik peramalan deret waktu yang populer (Sadli et al., 2020).

Keuntungan dalam penerapan prediksi ini adalah meminimalkan kebutuhan cadangan energi yang terlalu besar (Dhaked et al., 2023). Prediksi yang tepat memungkinkan perusahaan untuk mendistribusikan sumber daya mereka dan mengelola sistem dengan efektif untuk menjaga keseimbangan antara permintaan dan pasokan listrik (Attiwal & Indora, 2024). Selanjutnya, hal ini akan memudahkan penyelesaian masalah terkait dengan *load shedding* atau pelepasan beban. Operasi pelepasan beban ini dapat menimbulkan beberapa dampak negatif, seperti hilangnya beban daya dan kerugian ekonomi nasional akibat kekurangan pasokan listrik (Chen et al., 2022). Dalam prediksi ini membutuhkan bantuan

dengan metode *artificial intelligence*, banyak metode yang dapat digunakan untuk melakukan prediksi beban puncak.

Banyak penelitian yang dilakukan oleh peneliti sebelumnya untuk memprediksi data seperti pada penelitian Y. Zhu dalam (Zhu, 2020) menjelaskan mengenai prediksi harga saham menggunakan metode RNN berhasil dalam memprediksi harga saham yang cukup akurat dengan RMSE sebesar 8,27. Selanjutnya, penelitian yang dilakukan oleh A. R. F. Dewandra, A. P. Wibawa, U. Pujianto, A. B. P. Utama, dan A. Nafalski dalam (Dewandra et al., 2022), menjelaskan mengenai prediksi data menggunakan *Convolutional Neural Network* (CNN) dengan menggunakan ekstraksi fitur 1D membuktikan bahwa CNN juga dapat memprediksi dengan jumlah *neuron* yang berbeda. Penelitian yang dilakukan oleh Y. Sari, Y. F. Arifin, N. Novitasari, dan M. R. Faisal dalam (Sari et al., n.d.) menjelaskan penelitian mengenai prediksi suhu udara menggunakan metode *hybrid* GRU-LSTM. Setelah kedua model digabungkan memberikan hasil, bahwa memberikan input yang berbeda juga memberikan hasil yang berbeda. Dengan menggunakan 12 parameter input hasilnya menjadi meningkat secara signifikan. W. Li, H. Wu, N. P. E. E. Chrismawan, S. Winardi, dan R. Tambunan (Chrismawan et al., 2023) melakukan percobaan prediksi tren harga saham nikel menggunakan metode GRU. Dalam percobaannya menggunakan banyak variasi dari *sequence length*, dan ditemukan *sequence length* sejumlah 15 memberikan akurasi prediksi yang lebih baik dengan MAE sebesar 0,0181, MSE sebesar 0,0007, dan MAPE sebesar 2,94%. Dalam penelitian yang dibuat oleh A. S. B. Karno dalam (Karno, 2020) menjelaskan mengenai prediksi saham bank bri menggunakan metode LSTM dan mencari *epoch* terbaik. Dari semua percobaan *epoch*, didapatkan pada *epoch* 9 yang memiliki nilai RMSE paling terkecil yakni sebesar 227,47.

Pada beberapa penelitian yang telah disebutkan, telah mengkonfirmasi bahwa metode tersebut adalah metode yang dapat digunakan untuk prediksi data *time series*. Secara keseluruhan, pemilihan metode tergantung pada sifat data yang sedang diprediksi dan tujuan dari prediksi tersebut. Hal ini menunjukkan bahwa tidak ada satu metode yang secara konsisten unggul dalam semua kasus, dan

pemilihan metode harus didasarkan pada karakteristik khusus dari data dan tujuan prediksi.

Oleh karena itu, pada skripsi ini akan melakukan prediksi beban puncak dari beberapa metode *deep learning* yaitu *Gated Recurrent Unit* (GRU), *Recurrent Neural Network* (RNN), *Long Short-Term Memory* (LSTM), *Convolutional Neural Network* (CNN), dan *Hybrid* LSTM-GRU. Penelitian ini diharapkan untuk menemukan solusi yang paling tepat dan dapat diandalkan untuk meramalkan beban puncak pembangkit listrik dengan melakukan analisis menyeluruh terhadap kinerja dan akurasi prediksi dari setiap model. Sehingga penelitian ini akan memberikan kontribusi praktis dalam konteks perencanaan dan pengelolaan sistem kelistrikan.

1.2. Rumusan Masalah

Berdasarkan uraian di atas, penulis telah berhasil mengidentifikasi permasalahan yang muncul. Permasalahan tersebut menjadi titik sentral dalam analisis yang dilakukan, diantaranya yaitu:

a) Bagaimana melakukan prediksi beban puncak pembangkit listrik?
b) Apa metode *deep learning* yang paling efektif diantara RNN, GRU, LSTM, CNN, dan *hybrid* LSTM-GRU untuk memprediksi nilai beban puncak?
c) Bagaimana cara agar metode *deep learning* tersebut dapat memprediksi beban puncak?
d) Bagaimana mekanisme dari fitur yang diimplementasikan tersebut dalam *platform* website?

1.3. Batasan Masalah

Pada pembuatan skripsi, agar pembahasan tetap terfokus, diberikan batasan masalah sebagai berikut:

a) Fokus dengan pembuatan fitur prediksi beban puncak pembangkit listrik.
b) Data simulasi yang digunakan dalam skripsi ini adalah data beban puncak perbulan diambil dari web RTE sebagai data *testing* dan *training* model sebanyak 145 data dari Desember 2011 hingga Desember 2023.
c) Data prediksi menggunakan data yang telah diberikan oleh pihak perusahaan.

d) Waktu dari hasil prediksi adalah 4 bulan setelahnya dari data yang telah diberikan.
e) Hanya untuk menyampaikan data prediksi kondisi beban puncak dan tidak melakukan aksi apapun.
f) Fitur prediksi dalam skripsi akan dibuat dalam *platform* website.

1.4. Tujuan

Dalam pembuatan skripsi ini, ada beberapa tujuan utama yang ingin dicapai diantaranya yakni:

a) Melakukan prediksi beban puncak pembangkit listrik menggunakan data per bulan serta mengetahui cara agar metode deep learning tersebut dapat memprediksi beban puncak, dan menentukan metode deep learning yang paling efektif di antara RNN, GRU, LSTM, CNN, dan hybrid LSTM-GRU untuk memprediksi nilai beban puncak.
b) Mengetahui mekanisme dari fitur yang diimplementasikan tersebut dalam *platform* website.

1.5. Manfaat

Ada beberapa manfaat dari pengerjaan skripsi ini yang dapat berdampak pada sekitar, antara lain:

a) Membantu stakeholder untuk membuat keputusan dalam manajemen kapasitas pembangkit berdasarkan hasil beban puncak di tahun 2024.
b) Mengefisienkan kerja dari pegawai perusahaan.

1.6. Sistematika Penulisan

Sistematika penulisan dari penyusunan skripsi ini akan dijelaskan dalam setiap bab dengan penjelasan sebagai berikut:

BAB I : PENDAHULUAN

Pada bab pendahuluan memberikan gambaran umum mengenai permasalahan yang akan dibahas. Bab ini terdiri dari beberapa sub bab seperti latar belakang, rumusan masalah, batasan masalah, tujuan, dan manfaat dari skripsi yang telah dibuat, serta sistematika penulisan.

BAB II : TINJAUAN PUSTAKA

Aktivitas ini melibatkan peninjauan literatur yang telah dipublikasikan oleh akademisi atau peneliti lain. Tujuan utamanya adalah untuk mengkaji kembali hasil-hasil penelitian sebelumnya. Kegiatan ini membantu memahami perkembangan terkini dalam topik yang kita teliti.

BAB III : KEGIATAN PELAKSANAAN

Pada bab pelaksanaan kegiatan ini, dijelaskan langkah-langkah metode pelaksanaan serta tahapan perancangan fitur prediksi. Bab ini membahas mengenai teknik implementasi dan pengujian fitur yang dikembangkan. Akhirnya, hasil dari setiap tahapan dijelaskan untuk memberikan gambaran yang menyeluruh.

BAB IV : ANALISA DAN PEMBAHASAN

Pada bab analisis dan pembahasan, dijelaskan hasil analisis dari pembuatan fitur serta jawaban terhadap pertanyaan dari rumusan masalah. Bab ini menguraikan temuan yang diperoleh selama proses penelitian. Selain itu, bab ini juga mengaitkan hasil yang ditemukan dengan tujuan penelitian untuk memberikan pemahaman yang menyeluruh.

BAB V : KESIMPULAN

Dalam bab kesimpulan ini, terdapat rangkuman dari keseluruhan laporan skripsi serta penarikan kesimpulan yang dibuat berdasarkan hasil penelitian yang telah dilakukan. Bab ini menyajikan temuan utama dan dampaknya, serta menyertakan rekomendasi untuk penelitian lebih lanjut.

DAFTAR PUSTAKA

Dalam daftar pustaka, ditampilkan semua sumber yang digunakan sebagai referensi dalam laporan skripsi ini. Sumber-sumber ini berfungsi sebagai penunjang dalam pengerjaan laporan skripsi, memastikan akurasi dan kredibilitas penelitian. Daftar pustaka mencakup buku, artikel jurnal, serta sumber-sumber lain yang relevan dengan topik penelitian.

LAMPIRAN

Dalam lampiran terdapat dokumentasi dan dokumen tambahan yang mendukung isi dari laporan skripsi. Lampiran ini mencakup berbagai materi

pelengkap seperti kode program dan formulir yang digunakan dalam penelitian. Tujuannya adalah untuk memberikan informasi tambahan yang dapat membantu pembaca memahami lebih dalam mengenai penelitian yang dilakukan.

BAB II

TINJAUAN PUSTAKA

Pada bab tinjauan pustaka, diuraikan dasar-dasar teori yang mendukung pembuatan fitur, serta penelitian terdahulu yang relevan dengan skripsi ini. Bab ini juga menyertakan tabel perbandingan antar metode berdasarkan jurnal dari penelitian yang telah diulas. Selain itu, dijelaskan pula perangkat dan teknologi yang digunakan dalam pembuatan fitur tersebut.

2.1. Dasar Teori

Pada bagian ini menjelaskan mengenai buku, jurnal, atau media lainnya mengenai metode yang digunakan dalam penyusunan skripsi.

2.1.1. Penelitian Terkait

Pada bagian penelitian terkait, akan dijabarkan hasil pembacaan referensi dari beberapa jurnal terdahulu yang digunakan sebagai landasan dalam penyusunan laporan skripsi ini. Informasi ini bertujuan untuk mendukung pemahaman dan analisis lebih lanjut terhadap metode yang digunakan dalam penelitian ini. Pada bagian ini, penting untuk memastikan bahwa penelitian berlangsung dengan dasar yang kuat.

B. Huang, L. Tong, dan Y. Zuo dalam (Huang et al., 2022) menjelaskan sebuah penelitian prediksi pada nilai beban pembangkit listrik yang melibatkan metode *Long Short-Term Memory* (LSTM) dan *Recurrent Neural Network* (RNN) sebagai metode pembandingnya. Dalam penelitiannya menjelaskan bahwa nilai dari beban bersifat non linear dan *time series* sehingga 2 metode tersebut dapat mencoba untuk memprediksi nilai beban. Dalam penelitian ada beberapa hal yang harus dilewati untuk membuat model seperti, *preprocessing* data, membangun model, melatih model, menemukan akurasi dan memprediksi data input. Tetapi ketika hasil akurasi tidak sesuai yang diharapkan maka mengulang lagi untuk melatih data tersebut. Pada jurnal ini menggunakan data *private*, 90% data sebagai data latih dengan menggunakan Adam *function* dan 500 epoch. Dengan menggunakan 12 data mewakili 12 hari untuk mencoba prediksi ditemukan *Mean Absolute Percentage Error* (MAPE) RNN sebesar 4.40% dan LSTM sebesar 2.36%

menjelaskan bahwa MAPE RNN lebih besar dari LSTM sehingga LSTM lebih unggul. Akurasi yang didapatkan dalam testing perharinya sudah melebihi dari 90%. Pada akhir kesimpulan LSTM direkomendasikan untuk menjadi metode prediksi beban pembangkit listrik.

D. K. Dhaked, S. Dadhich, dan D. Birla dalam (Dhaked et al., 2023) menjelaskan mengenai prediksi *output* dari *solar photovoltaic* yang berfungsi untuk manajemen energi, keamanan, operasi, meningkatkan efisiensi, stabilitas jaringan listrik, dan efektivitas dari *solar photovoltaic*. Pada jurnal ini memiliki data untuk musim yang berbeda, musim semi, musim dingin, musim panas, musim gugur. Masing-masing data terbagi menjadi 3 bagian data latih, data validasi, dan data tes dengan pembagian data 90% data latih, 5% data validasi, dan 5% data tes menggunakan data *private*. Dalam percobaan LSTM dengan *layer* 2 (32, 64), 3 (16, 32,64), dan 4 (64, 64, 64, 64) hasil MAPE yang dihasilkan lebih kecil ada pada *layer* 4 dimana menghasilkan 3,52% pada data musim dingin, 5,96% pada data musim semi, 5.00% pada data musim gugur, dan 5,18% pada musim panas. Dari hasil penelitian dari kedua metode tersebut didapatkan perbandingan yang memiliki kesimpulan bahwa LSTM lebih memiliki hasil terbaik berdasarkan RMSPE yang telah dibandingkan dengan metode BPNN untuk 4 data musim.

M. A. Wakhid, A. B. Raharjo, dan R. Indralaksono dalam (Wakhid et al., 2022) menjelaskan mengenai prediksi beban listrik dengan untuk Rencana Operasi Harian (ROH), dimana data yang digunakan adalah data realisasi beban harian di sistem Sulawesi Selatan dari Januari 2017 hingga Juni 2021. *Output* dari penelitian tersebut adalah memprediksi beban listrik untuk keesokan harinya dengan 48 data, dalam penelitian ini menggunakan 5 skenario. Pada skenario pertama yakni *all day* data beban hari sebelumnya (Senin sampai dengan Minggu) untuk memprediksi beban pada hari tersebut. Skenario kedua, *same day (Weekday)* data beban hari yang sama pada pekan-pekan sebelumnya untuk memprediksi beban hari pada tersebut (*Weekday*). Skenario ketiga *same day (Weekend)* data beban hari Sabtu atau Minggu pekan-pekan sebelumnya untuk memprediksi beban pada hari Sabtu atau Minggu. Skenario keempat *day*-1, data beban hari sebelumnya ditambah data hari yang sama pada pekan sebelumnya untuk memprediksi beban pada hari tersebut. Skenario terakhir hari lebaran, data hari lebaran pada tahun sebelumnya untuk

memprediksi beban hari Lebaran berikutnya. Agar memiliki hasil yang lebih baik maka dilakukan eksplorasi pada 15 arsitektur LSTM yang berbeda, di dalam proses evaluasi menggunakan MAPE sebagai parameter pembanding antara arsitektur satu dengan lainnya, lalu evaluasi lanjut menggunakan standar deviasi untuk memastikan model tersebut. Setelah itu di dapatkan parameter arsitektur *sequence input layer* 1, LSTM *layer (Stacked LSTM)* 7, LSTM *layer* 50, *max epoch* 1000, *initial learn rate* 0.001, dan *activation function* sigmoid. Dari hasil penelitian tersebut menghasilkan bahwa dengan menggunakan model tersebut didapatkan RMSE dan MAPE skenario 1 cenderung lebih kecil yang menggunakan data hari sebelumnya untuk prediksi daripada skenario yang lainnya, dan menunjukkan bahwa model LSTM ini dapat menunjukkan hasil yang lebih baik dari pada metode tradisional seperti ARIMA, SARIMA, dan ARIMAX.

N. Selle, N. Yudistira, dan C. Dewi dalam (Selle et al., 2022) melakukan penelitian prediksi pada dataset penggunaan listrik dengan menerapkan metode LSTM, data penelitian yang digunakan adalah data *time series* penggunaan listrik dari Januari 2016 hingga Februari 2020 dengan total 1623 data terdiri dari data siang dan malam yang bersifat *private* dari PT. Brilyan Trimatra Utama. Tahapan perancangan algoritma yang dilewati dalam penelitian ini persiapan yang berisi normalisasi data menggunakan *MinMax* dan transformasi data, membangun model LSTM, melatih data, denormalisasi hasil prediksi yakni mengembalikan nilai yang telah dinormalisasi ke bentuk nilai aktual, lalu evaluasi dengan RMSE. Dalam penelitian ini memiliki beberapa pengujian diantaranya pengujian panjang *sequence input* mendapatkan hasil terbaik pada data malam panjang *sequence* terbaik yaitu 30 dengan rata-rata RMSE 57,90 dan pada data siang yaitu 20 dengan rata-rata RMSE 49,33. Pengujian jumlah neuron pada *hidden layer* pada data malam dan siang memiliki kondisi terbaik pada jumlah neuron 8 dengan rata-rata RMSE 49,87 pada malam hari dan 47,98 pada siang hari. Pengujian perbandingan jumlah data *training* dan *testing* dengan jumlah data 1623 didapatkan 70%-80% data *training* dengan rata-rata RMSE untuk siang sebesar 47,02 dan malam sebesar 51,05. Pengujian jumlah *layer* didapatkan pada data siang memiliki 3-*layer* dengan rata-rata RMSE 46,72 dan pada data malam memiliki 1-*layer* dengan rata-rata RMSE 51,05. Hasil pengujian antara 2 metode RNN dan LSTM, LSTM memiliki

kinerja yang lebih baik dengan evaluasi menggunakan RMSE dimana diuji beberapa *sequence* 5, 20, 30 hasil dari kedua metode pada *sequence* 5 tidak begitu signifikan walaupun dalam *sequence* 5 ini adalah nilai RMSE terendah dari RNN tetapi tetap tidak lebih rendah dari LSTM. Pada *sequence* 30 LSTM memiliki nilai RMSE terendah dan memiliki selisih RMSE yang cukup besar diantara *sequence* yang lainnya.

M. BiLgiLi, N. Arslan, A. ŞekertekiN, dan A. Yaşar dalam (BiLgiLi et al., 2022) menjelaskan penelitian mengenai peramalan atau prediksi konsumsi energi listrik menggunakan metode jaringan saraf *Long Short-Term Memory* (LSTM), *Adaptive Neuro-Fuzzy Inference System* (ANFIS) dengan pengelompokan *subtractive clustering* (SC), ANFIS dengan *fuzzy* cmeans (FCM), dan ANFIS dengan partisi grid (GP). Data pada penelitian ini didapatkan dari *Turkish Electricity Transmission Corporation* 1 Januari 2016 hingga 31 Desember 2019 tanpa adanya *missing data* sejumlah 1460 data dibagi menjadi 75% data *training* dan 25% data *testing*. Pada keempat metode tersebut dibuatkan beberapa percobaan seperti ANFIS-FCM dilakukan 5 percobaan dengan nomor MFs yang berbeda dan didapatkan hasil terbaik pada *Number of MFs* 6 memiliki MAE 18,37 GWh, MAPE 2,36%, RMSE 29,50 GWh, R sebesar 0,9201. Pada ANFIS-SC hasil terbaik didapatkan dengan *Influence radius* 0.4 dengan MAE 27,91 GWh, MAPE 3.66%, RMSE 41.17 GWh, R sebesar 0,8383. Pada ANFIS-GP hasil terbaik didapatkan dengan *Number of MFs* 2 dengan MAE 33,80 GWh, MAPE 4.47%, RMSE 80,14 GWh, R sebesar 0,6076. Pada metode LSTM dilakukan percobaan dengan *hidden layer* 50, 100, 150, 200, 250 hasil terbaik didapatkan oleh *hidden layer* 150 dengan MAE 14,78 GWh, MAPE 1,91%, RMSE 25,94 GWh, dan R sebesar 0,9480. Dalam hasil percobaan prediksi LSTM memberikan hasil paling terbaik diantara keempat metode berdasarkan nilai RMSE, Sehingga dalam penelitian ini berhasil membuktikan dalam data EEC metode LSTM dapat memberikan hasil yang lebih baik diantara metode ANFIS.

A. Talwariya, P. Singh, J. H. Jobanputra, dan M. L. Kolhe dalam (Talwariya et al., 2023) menjelaskan penelitian mengenai prediksi pembangkit listrik tenaga surya dan tenaga angin pembangkit tersebut memiliki ketergantungan pada cuaca. Lalu memprediksi mengenai konsumsi energi dengan mengkategorikan beban

fixed, non-shiftable, dan *shiftable.* Dalam penelitian ini, dua metode *Convolutional Neural Network* (CNN) dan LSTM digunakan dengan tugas yang berbeda. CNN bertanggung jawab untuk memprediksi pembangkit listrik, sementara LSTM digunakan untuk memprediksi konsumsi listrik. Pada percobaan pelatihan dan pengujian menggunakan metode CNN, terdapat nilai *error* yang dihasilkan oleh pembangkit, nilai kesalahan dari tenaga surya diperoleh MSE sebesar 6,122, RMSE sebesar 2,474, dan MAE sebesar 1,495. Nilai kesalahan pada tenaga angin diperoleh nilai MSE sebesar 78,25, RMSE sebesar 3,034, MAE sebesar 5,41. Data prediksi mencakup variabel seperti kelembapan, suhu, kecepatan angin, radiasi matahari, arah angin, curah hujan, dan lain-lain. Selain itu percobaan prediksi konsumsi energi menggunakan LSTM pada masing masing tipe, *fixed loads* diperoleh MSE sebesar 0,0007*,* RMSE sebesar 0,027*,* dan MAE sebesar 0,0175. Pada *non-shiftable loads* diperoleh MSE sebesar 0,0045, RMSE sebesar 0,067, MAE sebesar 0,049 dan yang terakhir pada *shiftable loads* memperoleh nilai MSE sebesar 0,047, RMSE sebesar 0,21, dan MAE sebesar 0,13. Sehingga dari penelitian ini memiliki kesimpulan bahwa metode CNN dan LSTM melakukan tugasnya dengan baik dengan nilai *error* yang cukup rendah dan metode tersebut dapat digunakan untuk manajemen sisi permintaan jaringan listrik dan juga dapat membantu menyeimbangkan energi jaringan dengan menyimpannya.

M. Sadli, Fajriana, W. Fuadi, Ermatita, dan I. Pahendra dalam (Sadli et al., 2020) menjelaskan mengenai penelitian prediksi beban puncak pada gardu induk di Lhoksumewe selama 6 bulan menggunakan 2 metode *Support Vector Machine* (SVM) dan LSTM. Penelitian ini menggunakan data perjam dari beban puncak listrik selama 6 bulan dari Januari 2017 hingga Juni 2017 dengan rata-rata beban pada bulan Januari sebesar 20,23 Mw, Februari sebesar 23,63 Mw, Maret sebesar 21,25 Mw, April Sebesar 26,23 Mw, Mei sebesar 26,65 Mw, Juni sebesar 22,3 Mw, dengan *grand* total yang diperoleh sebesar 22,7 Mw. Hasil dari penelitian tersebut memiliki hasil akurasi yang berbeda, hasil akurasi SVM sebesar 4,29% dan LSTM sebesar 47,6% dengan RMSE sebesar 11,91%. Dalam kesimpulannya menunjukkan bahwa LSTM dan SVM berguna untuk meramalkan beban puncak listrik. Dengan demikian, teknik pembelajaran mesin berbasis LSTM dan SVM memungkinkan analisis data untuk tujuan ini.

Dalam penelitian yang dibuat oleh A. S. B. Karno dalam (Karno, 2020) menjelaskan mengenai prediksi saham bank bri menggunakan metode LSTM dan mencari *epoch* yang memberikan hasil yang terbaik. Pada penelitian ini menggunakan data *open source* dari https://finance.yahoo.com dari 2010 hingga 2020 perharinya dengan total data sebesar 2551 data. Data *training* dimulai dari awal data hingga 2018 dengan jumlah data 2211 data, dan *testing* dimulai dari tahun 2019 hingga akhir sebesar 340 data. Dalam penelitian ini menggunakan 4 *hidden layer* setiap *layer* memiliki 50 *node*, *dropout* 0,2, dan 1 *output layer* dengan 1 *node*. Dari semua *epoch* yang telah dilakukan percobaan, didapatkan pada epoch 9 yang memiliki nilai RMSE paling terkecil yakni sebesar 227,47. Sehingga dalam pemilihan *epoch* harus dipertimbangkan karena dapat mempengaruhi hasil.

Dalam penelitian yang dibuat oleh Sabar Sautomo and Hilman Ferdinandus Pardede dalam (Sabar Sautomo & Hilman Ferdinandus Pardede, 2021) menjelaskan mengenai perkiraan pengeluaran belanja pemerintah menggunakan *hidden layer* yang berbeda. Penelitian ini menggunakan data *history* harian dari Kementerian Keuangan Republik Indonesia, dari 2018 hingga 2020 memiliki total 721 data. Memiliki data *training* sebesar 80% dan data *testing* 20%. Pada pembuatan model menggunakan 1 hingga 4 *hidden layer*, unit 150, *dropout* 0,221, *activation* relu, *optimizer* adam, *epoch* 150, *batch* 50, dan *validation split* 0,4651. Sehingga penelitian ini memiliki hasil terbaik pada 3 *hidden layer* pada *selected attribute* dengan hasil kesalahan MAPE sebesar 0,4214, MSE sebesar 0,2325, RMSE sebesar 0,4820 dan MAE sebesar 0,3292.

Dalam artikel yang dibuat oleh G. Shen, Q. Tan, H. Zhang, P. Zeng, and J. Xu dalam (Shen et al., 2018) menjelaskan mengenai prediksi *time series* keuangan menggunakan beberapa model yakni GRU, GRU-SVM, DNN, dan SVM. Pada artikel ini memiliki 3 data, HIS memiliki 6423 *sample size* dari tanggal 27 Agustus 1991 hingga 24 Agustus 2017. DAX memiliki 6580 *sample size* dari tanggal 23 Agustus 1991 hingga 23 Agustus 2017. S&P 500 memiliki 6551 *sample size* dari tanggal 23 Agustus 1991 hingga 23 Agustus 2017. Kesimpulan dari keempat model tersebut GRU dan GRU-SVM memiliki akurasi yang baik, melebihi 50% pada 3 data yakni HIS, DAX, dan S&P 500.

K. E. ArunKumar, D. V. Kalaga, Ch. Mohan Sai Kumar, M. Kawaji, dan T. M. Brenza dalam (ArunKumar et al., 2022) menjelaskan mengenai prediksi trend covid 19 menggunakan GRU, LSTM, Arima, dan Sarima. Pada artikel ini menggunakan data dari 10 negara diantaranya Amerika Serikat, Brazil, India, Rusia, Afrika Selatan, Meksiko, Peru, chili, Britania Raya dan Iran per 22 Juni 2021. Panjang waktu prediksi adalah 60 hari. Setelah melakukan percobaan model dikarenakan masing masing negara memiliki sifat yang berbeda linear dan nonlinear sehingga hasil yang diberikan oleh keempat model tersebut berbeda. Disampaikan bahwa model yang memiliki basis RNN seperti GRU dan LSTM lebih baik dalam menangani data yang nonlinear.

W. Li, H. Wu, N. Zhu, Y. Jiang, J. Tan, dan Y. Guo dalam (Li et al., 2021) menjelaskan mengenai membandingkan 3 model RNN, LSTM, dan GRU untuk prediksi oksigen terlarut di kolam perikanan. Evaluasi dalam artikel ini menggunakan MAE, MSE, R2, dan MAPE. Data dari penelitian ini menggunakan data pribadi yang dikumpulkan oleh penulis dari Mei 2018 hingga Juli 2018. Pada model RNN diterapkan *learning rate* sebesar 0,015, *hidden layers* sebesar 30, lalu *epoch* 6000. Pada model LSTM *learning rate* sebesar 0,01, *hidden layers* sebesar 30, lalu *epoch* 6000. Pada model GRU *learning rate* sebesar 0,01, *hidden layers* sebesar 25, lalu *epoch* 6000. Dari artikel ini memiliki kesimpulan bahwa kinerja RNN belum dapat mengungguli dari kinerja GRU dan LSTM. Kedua metode yang unggul ini memiliki kesamaan tetapi tetap memiliki perbedaan dalam waktu yang dihabiskan dan parameter yang dipakai jauh lebih rendah GRU dari pada LSTM. Sehingga GRU adalah model yang paling baik dalam penelitian ini.

D. R. Rizvi dan M. Khalid dalam (Rizvi & Khalid, 2024) menjelaskan mengenai prediksi harga saham dari *apple.inc* dengan mengkomparasikan 3 model untuk mendapatkan model terbaik. 3 model tersebut adalah LSTM, GRU, dan MLP. Dalam penelitian ini menggunakan dataset AAPL (*Apple.inc*) yang didapatkan dari *yahoo finance* web dari tanggal 15 Juli 2005 hingga 15 mei 2023, terdiri dari 4489 baris dan 7 kolom data. Dalam proses prapemrosesan data, langkah pertama yang dilakukan adalah mencari nilai yang hilang (*missing value*). Selanjutnya, format kolom "*Date*" diubah menjadi tipe data *date time*. Penelitian ini menggunakan satu

kolom data, yang dibagi menjadi 85% untuk data latih (training data) dan 15% untuk data uji (*testing* data). *Timestep* diatur menjadi 60, dan data dinormalisasi menggunakan *MinMaxScaler*. *Epoch* yang digunakan ada 5 percobaan 10, 20, 30, 40, dan 50. Setiap model mencapai akurasi tertinggi pada *epoch* ke-50, dengan hasil akurasi GRU mencapai 79%, LSTM mencapai 83%, dan MLP mencapai 73%. Oleh karena itu, penelitian ini menyimpulkan bahwa LSTM adalah model yang terbaik.

Y. Sari, Y. F. Arifin, N. Novitasari, dan M. R. Faisal dalam (Sari et al., n.d.) menjelaskan penelitian mengenai prediksi suhu udara menggunakan metode *hybrid* GRU-LSTM. Data yang digunakan yakni rata-rata suhu udara berasal dari BMKG dari tanggal 1 Januari 1996 hingga 31 Desember 2021. Dalam penelitian ini menggunakan 2 *layer* GRU dan 2 *dense layer* dengan 240 *neuron* serta fungsi aktivasi yang berbeda tiap *layer*-nya, begitu pula sama dengan LSTM. Setelah kedua model digabungkan memberikan hasil, bahwa memberikan input yang berbeda juga memberikan hasil yang berbeda. Dengan menggunakan 12 parameter *input* hasilnya menjadi meningkat secara signifikan.

A. R. F. Dewandra, A. P. Wibawa, U. Pujianto, A. B. P. Utama, dan A. Nafalski dalam (Dewandra et al., 2022) menjelaskan mengenai prediksi data menggunakan *Convolutional Neural Network* (CNN) dengan menggunakan ekstraksi fitur 1D serta menggunakan evaluasi *error* dengan RMSE sebagai pengukuran kinerja dari algoritma CNN. Dataset dalam penelitian ini adalah data aktivitas pengunjung dari portal jurnal *Knowledge Engineering and Data Science* (KEDS). Data yang digunakan mencakup periode dari 1 Januari 2017 hingga 31 Desember 2020. Data ini memiliki empat atribut: sesi, tampilan halaman, pengunjung, dan pengunjung baru. Penelitian ini menggunakan 3 model, dengan data *training* pada model pertama yaitu data tahun 2018, model kedua yaitu data tahun 2019, dan model ketiga yaitu data tahun 2018 hingga 2019. Sedangkan data *testing* yang digunakan pada model 1 yaitu data tahun 2019, model kedua dan ketiga menggunakan data tahun 2020. Dalam penelitian ini menggunakan ukuran *neuron* yang berbeda-beda dengan *neuron* dalam penelitian ini adalah 16, 32, 64, 128, dan 256. Hasil dari penelitian ini adalah dengan penambahan dari *neuron* menghasilkan

nilai *erorr* yang berbeda pada model pertama ditemukan RMSE terkecil pada 64 dan 256 *neuron*.

Y. Zhu dalam (Zhu, 2020) menjelaskan mengenai prediksi harga saham menggunakan metode RNN. Dalam penelitian ini menggunakan data *Apple's stock* (AAPL) dari *Yahoo Finance* dari 9 Agustus 2009 sampai 12 Agustus 2020 serta membagi data sebesar 65% untuk *training* dan data sebesar 35% untuk *testing*. Penelitian ini menggunakan dua *time steps* yang berbeda yakni 5 dan 10 setelah melakukan percobaan menggunakan model RNN dengan *time steps* yang berbeda, didapatkan hasil *error* terendah diraih oleh *time steps* 5 dengan RMSE sebesar 8,27. Hasil menunjukkan bahwa metode RNN berhasil dalam memprediksi harga saham.

M. S. Islam dan E. Hossain dalam (Islam & Hossain, 2021) menjelaskan mengenai prediksi nilai tukar mata uang asing menggunakan metode *hybrid* GRU-LSTM. Penelitian ini menggunakan data yang berasal dari web Histdata yang terdiri dari EUR/USD, GBP/USD, USD/CAD, dan USD/CHF. Data dikumpulkan dari 1 Januari 2017 hingga 31 Desember 2018 untuk prediksi setiap 10 menit, dan dari 1 Januari 2019 hingga 30 Juni 2020 untuk prediksi setiap 30 menit. Setiap data berisi total 5 atribut: Tanggal dan Waktu, Harga Pembukaan, Harga Tertinggi, Harga Terendah, dan Harga Penutupan. Data ini berisi data *time series* OHLC (*Open-High-Low-Close*) dengan interval 1 menit selama 24 jam setiap hari. Dalam pemodelannya, mereka menggunakan *layer* GRU dengan 20 *hidden neuron*, LSTM 256 *hidden neuron*, serta *layer dense* ketiga dan keempat masing-masing adalah 64 dan 1 *hidden neuron*. Hasil penelitian memiliki kesimpulan bahwa model *hybrid* memberikan hasil yang lebih akurat dibandingkan model tunggal dari LSTM atau GRU saja.

P. E. E. Chrismawan, S. Winardi, dan R. Tambunan (Chrismawan et al., 2023) melakukan percobaan prediksi tren harga saham nikel menggunakan metode GRU. Data yang digunakan dalam percobaan ini menggunakan data yang berasal dari web *Yahoo Finance* dengan kolom tanggal, *opening price*, *lowest price*, *highest price*, dan *closing price* dari PT Aneka Tambang Tbk (ANTM.JK). Dalam percobaannya menggunakan banyak variasi dari *sequence length*, dan ditemukan

sequence length sejumlah 15 memberikan akurasi prediksi yang lebih baik dengan MAE sebesar 0,0181, MSE sebesar 0,0007, dan MAPE sebesar 2,94%.

Dengan melihat penelitian-penelitian tersebut mendapati beberapa perbandingan metode beserta dataset yang dijelaskan dalam tabel 2.1 sebagai berikut.

No	Penelitian	Dataset	Metode	Hasil Artikel
1	*Short-term power generation load forecasting based on LSTM neural network*	Data *private*, 90% data latih. Menggunakan 12 data mewakili 12 hari untuk mencoba prediksi.	RNN dan LSTM.	(MAPE) RNN sebesar 4.40% dan LSTM sebesar 2.36%. LSTM direkomendasikan untuk menjadi metode prediksi beban pembangkit listrik.
2	*Power output forecasting of solar photovoltaic plant using LSTM*	Pembagian data 90% data latih, 5% data validasi, dan 5% data tes, menggunakan data *private.*	LSTM dan BPNN.	MAPE yang dihasilkan lebih kecil ada pada *layer* 4 menghasilkan 3,52 pada data musim dingin, 5,96% pada data musim semi, 5.00% pada data musim gugur, dan 5,18% pada musim panas. LSTM lebih memiliki hasil terbaik berdasarkan RMSPE yang telah dibandingkan dengan metode BPNN untuk 4 data musim.
3	Peramalan Beban pada Rencana Operasi Harian dengan Menggunakan LSTM Studi Kasus: Sub Sistem Sulawesi Selatan	Data *private*, data realisasi beban harian di sistem Sulawesi Selatan dari Januari 2017 hingga Juni 2021 per 30 menit dalam sehari.	LSTM.	Menggunakan 5 skenario, menghasilkan bahwa dengan menggunakan model tersebut didapatkan RMSE dan MAPE skenario 1 cenderung lebih kecil (2,3484%) yang menggunakan data hari sebelumnya untuk prediksi daripada skenario yang lainnya.
4	Perbandingan Prediksi Penggunaan Listrik Dengan Menggunakan Metode *Long Short-Term Memory* (LSTM) dan *Recurrent Neural Network* (RNN)	Data *private,* setiap hari 2 data siang dan malam dari Januari 2016 hingga Februari 2020, jumlah data 1623, 70%-80% data *training* dan 20%-30% data *testing.*	LSTM & RNN.	Setelah melakukan pengujian pada beberapa aspek didapatkan hasil terbaik diantaranya panjang *sequence* 20 dan 30, 8 neuron, 1-3 *layer*, memberikan kesimpulan LSTM lebih unggul dari RNN dengan evaluasi menggunakan RMSE dengan RMSE LSTM lebih rendah dari RNN.

No	Penelitian	Dataset	Metode	Hasil Artikel
5	*Application of Long Short-Term Memory (LSTM) Neural Network Based on Deeplearning for Electricity Energy Consumption Forecasting*	Data *Turkish Electricity Transmission Corporation* 1 Januari 2016 hingga 31 Desember 2019, 1460 data 75% data *training* dan 25% data *testing*.	ANFIS & LSTM.	Dari semua metode, metode LSTM adalah metode paling unggul dengan 5 percobaan dengan *hidden layer* yang berbeda 50, 100, 150, 200, 250. Didapatkan hasil LSTM yang terbaik dengan *hidden layer* 150 dengan RMSE 25.94 GWh.
6	*Machine learning based renewable energy generation and energy consumption forecasting*	Data prediksi pembangkit terdiri kelembapan, suhu, kecepatan angin, radiasi matahari, arah angin, curah hujan, dan lain-lain. Data prediksi konsumsi energi mencakup 3 *fixed load, Non-shiftable loads,* dan *Shiftable loads.*	CNN & LSTM.	Kedua metode tersebut berhasil melakukan tugasnya dengan mendapatkan hasil *error* yang cukup kecil.
7	*Electrical Peak Load Forecasting Using Long Short-Term Memory and Support Vector Machine*	Data perjam dari beban puncak listrik pada gardu induk dari Januari 2017 hingga Juni 2017	SVM & LSTM.	Kedua metode memberikan hasil yang terbaik dengan hasil akurasi SVM sebesar 4.289553602147689% dan LSTM sebesar 47.673406% dengan RMSE sebesar 11.91%.
8	Prediksi Data *Time Series* Saham Bank BRI Dengan Mesin Belajar LSTM (*Long ShortTerm Memory*)	Menggunakan data *open source* https://finance.yahoo.com, data dari tahun 2010 hingga 2020 dengan total 2551 data. Data latih sebanyak 2211 data dari awal hingga tahun 2018. Data testing dari tahun 2019 hingga akhir.	LSTM.	Dengan 4 *hidden layer* setiap *layer* memiliki 50 *node*, *dropout* 0,2, dan 1 *output layer* dengan 1 *node.* didapatkan pada *epoch* 9 yang memiliki nilai RMSE paling terkecil yakni sebesar 227,470333244533.
9	Prediksi Belanja Pemerintah Indonesia Menggunakan *Long Short-Term Memory* (LSTM)	Data dari 2018 hingga 2020 memiliki total 721 data. Data *training* sebesar 80% dan data *testing* 20%.	ARIMA & LSTM.	Menggunakan 1 hingga 4 *hidden layer*, unit 150, *dropout* 0,221, *activation* relu, *optimizer* adam, *epoch* 150, *batch* 50, dan *validation split* 0,4651. Hasil terbaik didapatlan pada 3 *hidden layer* pada *selected attribute* dengan hasil kesalahan MAPE sebesar 0,4214, MSE sebesar 0,2325, RMSE sebesar

No	Penelitian	Dataset	Metode	Hasil Artikel
				0,4820 dan MAE sebesar 0,3292.
10	*Deep Learning with Gated Recurrent Unit Networks for Financial Sequence Predictions*	Data *open source* dari *yahoo*. Memiliki 3 kategori data, HIS memiliki 6423 *sample size,* DAX memiliki 6580 *sample size,* S&P 500 memiliki 6551 *sample size.*	GRU, GRU-SVM, DNN, & SVM	Diantara keempat model, GRU dan GRU-SVM memiliki akurasi yang baik. Melebihi 50% pada 3 data yakni HIS, DAX, dan S&P 500.
11	*Comparative analysis of Gated Recurrent Units (GRU), long Short-Term memory (LSTM) cells, autoregressive Integrated moving average (ARIMA), seasonal autoregressive Integrated moving average (SARIMA) for forecasting COVID-19 trends*	Menggunakan data dari 10 negara, dimulai dari Februari 2021 hingga Juni 2021.	GRU, LSTM, Arima, & Sarima.	Panjang waktu prediksi adalah 60 hari. Kesimpulan pada dasarnya data masing-masing negara memiliki karakter masing masing (linear & nonlinear) sehingga model yang unggul akan berbeda tiap negaranya. Pada model yang berbasis RNN dapat bekerja baik jika dihadapkan dengan data yang non-linear.
12	*Prediction of dissolved oxygen in a fishery pond based on gated recurrent unit (GRU)*	Data pribadi yang dikumpulkan oleh penulis dari Mei 2018 hingga Juli 2018	GRU, RNN, & LSTM	Model RNN diterapkan *learning rate* sebesar 0,015, *hidden layers* sebesar 30. Model LSTM *learning rate* sebesar 0,01, *hidden layers* sebesar 30. Model GRU *learning rate* sebesar 0,01, *hidden layers* sebesar 25. Semua model menggunakan *epoch* 6000. Hasil pada penelitian GRU dan LSTM memiliki hasil yang hampir sama tetapi dari segi waktu dan angka parameter lebih rendah GRU.
13	*Performance Analysis of Stocks using Deep Learning Models*	Menggunakan dataset AAPL (*Apple.inc*) yang didapatkan dari *yahoo finance* website dari tanggal 15 Juli 2005 hingga 15 mei 2023, terdiri dari 4489 baris dan	GRU, LSTM, & MLP	*Epoch* yang digunakan ada 5 percobaan 10, 20, 30, 40, dan 50. Setiap model mencapai akurasi tertinggi pada *epoch* ke-50, dengan hasil akurasi GRU mencapai 79%, LSTM

No	Penelitian	Dataset	Metode	Hasil Artikel
		7 kolom data, dibagi menjadi 85% untuk data latih (*training* data) dan 15% untuk data uji (*testing* data).		mencapai 83%, dan MLP mencapai 73%. Penelitian ini menyimpulkan bahwa LSTM adalah model yang terbaik.
14	*Journal Unique Visitors Forecasting Based on Multivariate Attributes Using CNN*	Data aktivitas pengunjung dari portal jurnal *Knowledge Engineering and Data Science* (KEDS) dari 1 Januari 2017 hingga 31 Desember 2020, dengan empat atribut: sesi, tampilan halaman, pengunjung, dan pengunjung baru. Penelitian ini menggunakan tiga model: model pertama menggunakan data pelatihan tahun 2018, model kedua menggunakan data tahun 2019, dan model ketiga menggunakan data tahun 2018-2019. Data pengujian untuk model pertama adalah data tahun 2019, sedangkan model kedua dan ketiga menggunakan data tahun 2020.	CNN	Hasil dari penelitian ini adalah dengan penambahan dari *neuron* menghasilkan nilai *erorr* yang berbeda pada model pertama ditemukan RMSE terkecil pada 64 dan 256 *neuron*.
15	*Stock price prediction using the RNN model*	Data *Apple's stock* (AAPL) dari Yahoo *Finance* dari 9 Agustus 2009 sampai 12 Agustus 2020 serta membagi data sebesar 65% untuk *training* dan data sebesar 35% untuk *testing*	RNN	Menggunakan dua *time steps* yang berbeda 5 dan 10, dengan hasil RMSE terendah diraih dengan *time steps* 5 yakni sebesar 8,27.
16	*Foreign exchange currency rate prediction using a GRU-LSTM hybrid network*	Berasal dari web Histdata terdiri dari 4 pasang mata uang. Data dikumpulkan dari 1 Januari 2017 hingga 31 Desember 2018 untuk prediksi setiap 10 menit, dan dari 1 Januari 2019 hingga 30 Juni 2020 untuk	*Hybrid GRU-LSTM*	Pemodelannya, menggunakan *layer* GRU dengan 20 *hidden neuron*, LSTM 256 *hidden neuron*, serta *layer dense* ketiga dan keempat masing-masing adalah 64 dan 1 *hidden neuron*. Hasil penelitian memiliki kesimpulan bahwa model

No	Penelitian	Dataset	Metode	Hasil Artikel
		prediksi setiap 30 menit		*hybrid* memberikan hasil yang lebih akurat dibandingkan model tunggal dari LSTM atau GRU saja.
17	*Robust Stock Price Prediction using Gated Recurrent Unit* (GRU)	data yang berasal dari web *Yahoo Finance* dengan kolom tanggal, *opening price*, *lowest price*, *highest price*, dan *closing price* dari PT Aneka Tambang Tbk (ANTM.JK).	GRU	Menggunakan banyak variasi dari *sequence length*, dan ditemukan *sequence length* sejumlah 15 memberikan akurasi prediksi yang lebih baik dengan MAE sebesar 0,0181, MSE sebesar 0,0007, dan MAPE sebesar 2,94%.
18	*Deep Learning Approach Using the GRU-LSTM Hybrid Model for Air Temperature Prediction on Daily Basis*	Data yang digunakan yakni rata-rata suhu udara berasal dari BMKG dari tanggal 1 Januari 1996 hingga 31 Desember 2021	*Hybrid* LSTM-GRU	Setelah kedua model digabungkan memberikan hasil, bahwa memberikan input yang berbeda juga memberikan hasil yang berbeda. Dengan menggunakan 12 parameter input hasilnya menjadi meningkat secara signifikan.

Tabel 2. 1 Perbandingan Model Antar Jurnal pendahulu

2.2. Alat dan Teknologi yang Digunakan

Pada bagian ini membahas tentang beberapa alat yang digunakan untuk membangun fitur prediksi beban puncak pada website "CONNECT UP2DJTY" dengan rincian sebagai berikut:

2.2.1. Bahasa Pemrograman

Dalam perancangan fitur prediksi pada website "CONNECT UP2DJTY" menggunakan beberapa bahasa pemrograman diantaranya yaitu:

a) Python

Python adalah bahasa pemrograman yang dibuat oleh Guido Van Rossum pada tahun 1990. Python juga salah satu bahasa pemrograman umum, untuk setiap tahap siklus hidup perangkat lunak - analisis, desain, *prototyping*, pengkodean, pengujian, *debugging*, *tuning*, dokumentasi, dan pemeliharaan python memberikan

produktivitas yang sangat baik. Selain itu python bahasa yang sangat baik untuk merangkai komponen perangkat lunak yang ditulis dalam bahasa pemrograman lain karena program-programnya dapat bekerja dengan berbagai komponen perangkat lunak lain dengan mudah (Martelli et al., 2023). Python memiliki banyak *library* yang berfungsi untuk mendukung kinerja dari aplikasi baik *deep learning* maupun *machine learning* yang sedang dibuat membuat lebih efisien dan mudah (Riziq sirfatullah Alfarizi et al., 2022).

b) Hypertext Preprocessor (PHP)

Hypertext Preprocessor juga dikenal sebagai PHP, adalah salah satu bahasa pemrograman yang diciptakan oleh Rasmus Lerdorf pada tahun 1994. PHP bersifat *open source* digunakan secara gratis atau tidak berbayar hanya perlu mengunduh PHP untuk menggunakan didalam proyeknya. Bahkan di bisnis, pengembangan perangkat lunak telah menjadi lebih terjangkau secara keseluruhan, menawarkan fleksibilitas dan keandalan yang lebih besar. PHP menyediakan berbagai *library* untuk mengakses basis data ini dan berkomunikasi dengan web server (Surya et al., 2021).

2.2.2. *Framework*

Dalam perancangan fitur prediksi pada website "CONNECT UP2DJTY" menggunakan beberapa *framework* diantaranya yaitu:

a) Laravel

Laravel, sebuah *framework* populer yang memanfaatkan bahasa *Hypertext Preprocessor* (PHP). Laravel sebagai salah satu kerangka kerja yang memungkinkan untuk membuat aplikasi secara cepat. Dengan fokus pada pengurangan kurva belajar dan penyederhanaan proses peluncuran aplikasi baru, laravel juga menyediakan ekosistem alat yang komprehensif bagi pengembang untuk membangun dan menerapkan aplikasi dengan efisien (Stauffer, 2019). Sehingga laravel menjadi salah satu *framework* yang memiliki popularitas cukup tinggi dikalangan *developer.*

b) Flask

Flask adalah salah satu *framework* yang menggunakan bahasa pemrograman python. Dalam standar kebanyakan, flask dianggap sebagai *framework* yang ringkas cukup kecil untuk disebut "*micro-framework*" dan cukup mudah dikelola. Diciptakan untuk dapat diperluas sejak awal. Flask juga menawarkan fondasi yang kokoh dengan fitur-fitur penting, sementara fungsionalitas tambahan didelegasikan kepada ekstensi (Grinberg, 2018).

2.2.3. *Deep Learning*

Deep learning, sebagai cabang baru dalam domain *machine learning*, tengah mengalami perkembangan yang pesat belakangan ini. Berbeda dari teknik *machine learning* lainnya, *deep learning* mampu secara otomatis merepresentasikan data tanpa memerlukan aturan kode atau pengetahuan domain manusia. Terinspirasi dari struktur otak manusia, *deep learning* memungkinkan model untuk mandiri mempelajari representasi data melalui proses pembelajaran, menyerupai cara otak manusia memproses informasi. Dengan merekam langkah-langkahnya, *deep learning* mampu menemukan solusi secara otomatis dengan cepat. Tantangan utama dalam *deep learning* adalah melatih jaringan saraf menggunakan metode penurunan gradien, yang semakin kompleks dengan penambahan lapisan. Hal ini dapat mengurangi efektivitas penurunan gradien dan mempengaruhi kualitas *output*. Mesin akan menganalisis data dan membuat beberapa hasil salah satunya prediksi (Pandowo et al., 2022), (Pumsirirat & Yan, 2018), (Raup et al., 2022). Menurut KBBI prediksi adalah hasil dari kegiatan memprediksi atau meramal atau memperkirakan nilai pada masa yang akan datang dengan menggunakan data masa lalu.

2.2.3.1 Evaluasi

Dalam artikel (Chicco et al., 2021), dijelaskan beberapa persamaan dari metode untuk evaluasi. Mereka menguraikan berbagai pendekatan dan teknik yang digunakan dalam proses evaluasi tersebut. Penjelasan ini mencakup aspek-aspek kunci yang menjadi dasar dalam menilai efektivitas metode evaluasi.

$$\text{MSE} = \frac{1}{m}\sum_{i=1}^{m}(Xi - Yi)^2 \quad (1)$$

$$\text{RMSE} = \sqrt{\frac{1}{m}\sum_{i=1}^{m}(Xi - Yi)^2} \quad (2)$$

$$\text{MAE} = \frac{1}{m}\sum_{i=1}^{m}\left|\frac{Yi - Xi}{Yi}\right| \quad (3)$$

Keterangan:

MSE : *Mean Squared Error*

RMSE : *Root Mean Squared Error*

MAE : *Mean Absolute Error*

Xi : Nilai prediksi data ke-i

Yi : Nilai aktual data ke-i

$\bar{Y}i$: Mean dari nilai aktual data ke-i

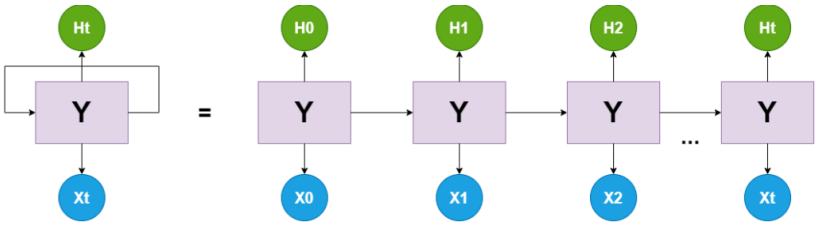
i : $1,2,3,\dots,m$

Pertama mengenai MSE untuk mengukur nilai rata-rata dari perbedaan kuadrat antara nilai yang diprediksi dan nilai aktual, diikuti oleh penggunaan *Root Mean Squared Error* (RMSE) dengan persamaan nomor 2, yang merupakan akar kuadrat dari *Mean Squared Error* (MSE) yang ditampilkan dengan persamaan nomor 1 dan mencerminkan kesalahan dalam satuan variabel target. Selain itu, akan digunakan MSE sebagai metode untuk menghitung rata-rata dari selisih absolut antara nilai yang diamati dan nilai yang diprediksi. Evaluasi berikutnya, Mean Absolute Error (MAE), yang dijelaskan pada persamaan nomor 3, dapat diterapkan ketika outlier mewakili data yang rusak. Sebenarnya, MAE tidak terlalu menghukum outlier selama proses pelatihan (Rizvi & Khalid, 2024).

a) Recurrent Neural Network (RNN)

Jaringan saraf dianggap sebagai algoritma prediktif dalam pembelajaran mesin. Jaringan saraf dengan lapisan yang terhubung secara acak disebut sebagai RNN dalam konteks jaringan saraf buatan. Ini ditampilkan dalam statistik deret waktu dengan pengaturan kronologis dengan menggunakan fase waktu sebelumnya melalui tautan umpan balik (Dhaked et al., 2023). Untuk detail lebih lanjut, memori untuk informasi sebelumnya dan kapasitasnya untuk memenuhi kebutuhan temporal. Ini dilakukan dengan memberi *feedback hidden state* dari jaringan ke

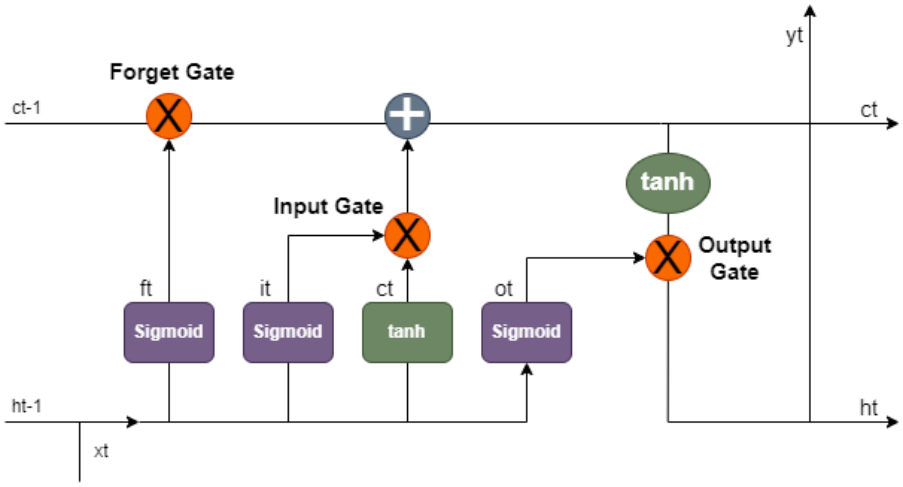
dalam dirinya sendiri pada setiap langkah waktu melalui koneksi berulang. Koneksi berulang ini memungkinkan RNN untuk menafsirkan data berurutan dengan mempertimbangkan baik keadaan masa lalu maupun input saat ini (Z. Ye et al., 2019). RNN dapat belajar menggunakan informasi masa lalu dalam situasi di mana terdapat kesenjangan kecil antara informasi yang relevan dan lokasi di mana informasi tersebut diperlukan. RNN kehilangan kemampuannya untuk belajar menghubungkan data saat kesenjangan tersebut semakin melebar (Barman & Boruah, 2018).



Gambar 2. 1 Arsitektur RNN

b) Long Short-Term Memory (LSTM)

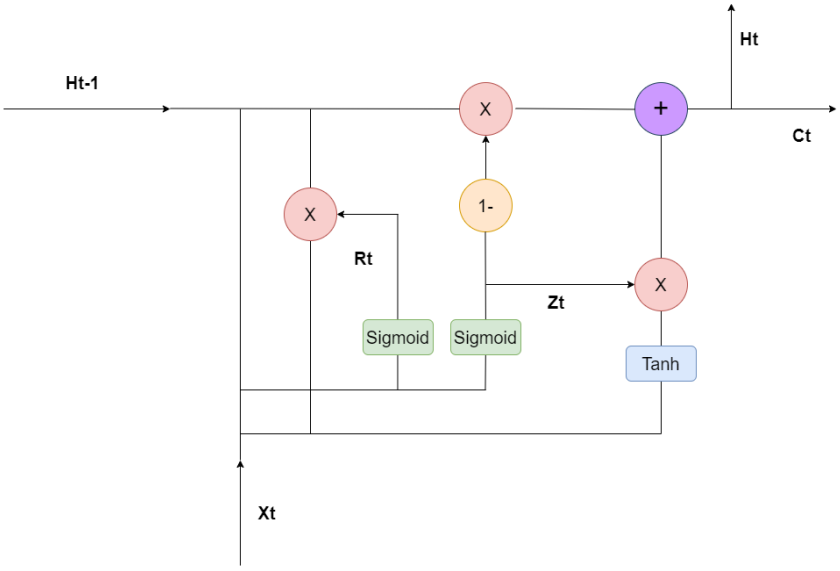
LSTM memiliki tiga gerbang, yaitu *forget gate*, *input gate*, dan *output gate* yang memiliki fungsi masing-masing dan juga LSTM memiliki satu memori tambahan yaitu *cell state* (Peng et al., 2023). *Long Short-Term Memory* (LSTM), jaringan saraf siklus nonlinier yang unggul dalam prediksi, menggunakan data deret waktu dari pembangkit listrik dengan hubungan nonlinier. Sebuah peristiwa dengan interval waktu yang sangat panjang dan keterlambatan dalam deret waktu dapat diproses dan diprediksi menggunakan jaringan saraf rekursif waktu (LSTM), yang dapat menyelesaikan masalah ketergantungan jangka panjang dari RNN umum. Jaringan saraf LSTM mengandung empat lapisan, berbeda dengan jaringan saraf RNN tunggal yang hanya memiliki satu lapisan, ia memiliki *loop* internal LSTM tambahan selain *loop* RNN luar. Penting untuk menentukan apakah data berharga ketika memasuki LSTM berdasarkan kriteria yang telah ditetapkan. Informasi yang tidak mengikuti pedoman akan dilupakan melalui gerbang lupakan, meninggalkan hanya informasi yang sesuai dengan mereka (Huang et al., 2022).



Gambar 2. 2 Arsitektur LSTM

c) Gated Recurrent Network (GRU)

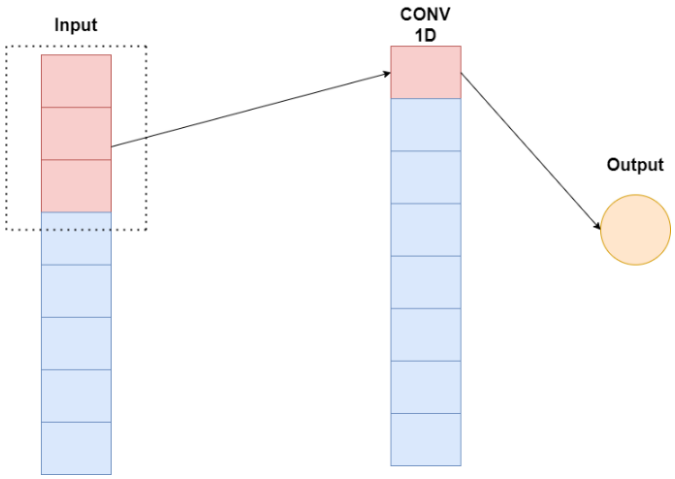
GRU terdiri dari dua gerbang, *reset gate* memilih elemen data mana yang akan diabaikan saat menangani data baru, sementara *update gate* mempertahankan keadaan saat ini dari proses ekstraksi sel memori. Oleh karena itu, GRU memiliki struktur yang lebih sederhana daripada LSTM sehingga GRU menonjol karena waktu pelatihan yang lebih cepat. Algoritma GRU bekerja mirip dengan LSTM tetapi sel GRU menggunakan satu keadaan tersembunyi yang menggabungkan fungsi *forget gate* dan *input gate* ke dalam satu gerbang pembaruan yang terpadu. Selain itu, GRU menggabungkan keadaan tersembunyi dan sel menjadi satu keadaan tunggal. Akibatnya, GRU hanya memiliki separuh jumlah gerbang dibandingkan dengan LSTM, menjadikannya varian yang lebih populer dan lebih sederhana dari sel LSTM (Rizvi & Khalid, 2024), (ArunKumar et al., 2022), (Karim et al., 2023).



Gambar 2. 3 Arsitektur GRU

d) Convolutional Neural Network (CNN)

CNN sangat disukai sebagai model pengolahan data gambar, tetapi CNN dengan fitur satu dimensi (1D) juga cocok untuk meramalkan masalah deret waktu satu dimensi. 1D CNN yang menggunakan teknik terbaik saat ini, seperti *dilated convolutions*, seringkali memiliki kinerja yang sama atau bahkan lebih baik daripada arsitektur RNN. *Input layer* menerima data satu dimensi, yang kemudian diteruskan ke *layer* konvolusi. Pada *layer* konvolusi, data dikonvolusi dengan filter 1D, selain itu ada dua parameter penting yakni *layer dropout* dan fungsi aktivasi (Dewandra et al., 2022), (Bai et al., 2018), (Malek et al., 2017),(Shenfield & Howarth, 2020). Struktur CNN dengan konvolusi satu dimensi (conv1D) ada pada gambar 2.4.



Gambar 2. 4 Arsitektur CNN

2.2.4. Teknologi

Dalam perancangan fitur prediksi pada website "CONNECT UP2DJTY" menggunakan beberapa teknologi diantaranya yaitu:

a) *Aplication Programming Interface* (API)

API, merupakan antarmuka yang dibuat oleh pengembang sistem untuk memungkinkan akses terprogram ke beberapa atau semua fungsi sistem. Dengan API, komunikasi atau pertukaran data antara sistem-sistem yang berbeda dapat difasilitasi dengan menggunakan teknologi antarmuka virtual. Penggunaan API dapat menyederhanakan proses integrasi komponen aplikasi baru ke dalam sistem yang sudah ada, sehingga membantu dalam kolaborasi antara tim (Hasanuddin et al., 2022), (Sontana et al., 2019), (Pratiwi et al., 2024).

b) *Database*

Database adalah kumpulan data yang disimpan secara sistematis di dalam komputer dan dapat diperiksa dengan program komputer untuk mendapatkan informasi darinya (Sulistyo, 2018). *Database*, menurut beberapa para ahli dalam (Yani & Saputra, 2018), Salah satu definisi *database* adalah sistem berkas terpadu yang bertujuan untuk mengurangi pengulangan atau redundansi data. Selain itu, ada yang berpendapat bahwa *database* adalah kumpulan informasi bermanfaat yang diatur secara khusus untuk memenuhi berbagai kebutuhan organisasi.

2.2.5. *Tools*

Dalam perancangan fitur prediksi pada website "CONNECT UP2DJTY" menggunakan beberapa *tools* diantaranya yaitu:

a) Visual Studio Code

Microsoft membuat sebuah platform *text editor* yang bernama Visual Studio Code bersifat *multiplatform* sehingga tidak hanya windows melainkan linux dan mac bisa memakai teks editor ini. *Text editor* ini mendukung bahasa pemrograman JavaScript, Typescript, dan Node.js secara langsung, serta bahasa pemrograman lainnya dengan bantuan *plugin* yang dapat dipasang melalui marketplace Visual

Studio Code. Contoh bahasa pemrograman ini termasuk C++, C#, Python, Go, dan Java (Permana & Romadlon, 2019).

b) XAMPP

XAMPP adalah pilihan utama sebagai server untuk belajar PHP secara independen, terutama bagi pemula dalam pemrograman. Selain gratis, XAMPP dilengkapi dengan fitur yang lengkap dan mudah digunakan oleh para *programmer* PHP yang masih dalam tingkat awal. Hal yang perlu dilakukan hanyalah menjalankan modul Apache yang disediakan di dalam XAMPP (Enterprise, 2018).

2.3. *Waterfall*

Metode Waterfall adalah salah satu model SDLC yang umum digunakan dalam pengembangan sistem informasi atau perangkat lunak. Model ini mengadopsi pendekatan yang terstruktur dan berurutan, tahapan dalam model ini dimulai dari perencanaan hingga pemeliharaan (*maintenance*) dan dilaksanakan secara bertahap. Kelebihan dari penggunaan metode Waterfall dalam pengembangan sistem informasi adalah kualitas sistem yang dihasilkan akan baik karena setiap tahap dilakukan secara berurutan. Metode Waterfall cocok untuk proyek pembuatan sistem baru serta pengembangan sistem atau perangkat lunak berskala besar (Wahid, 2020).

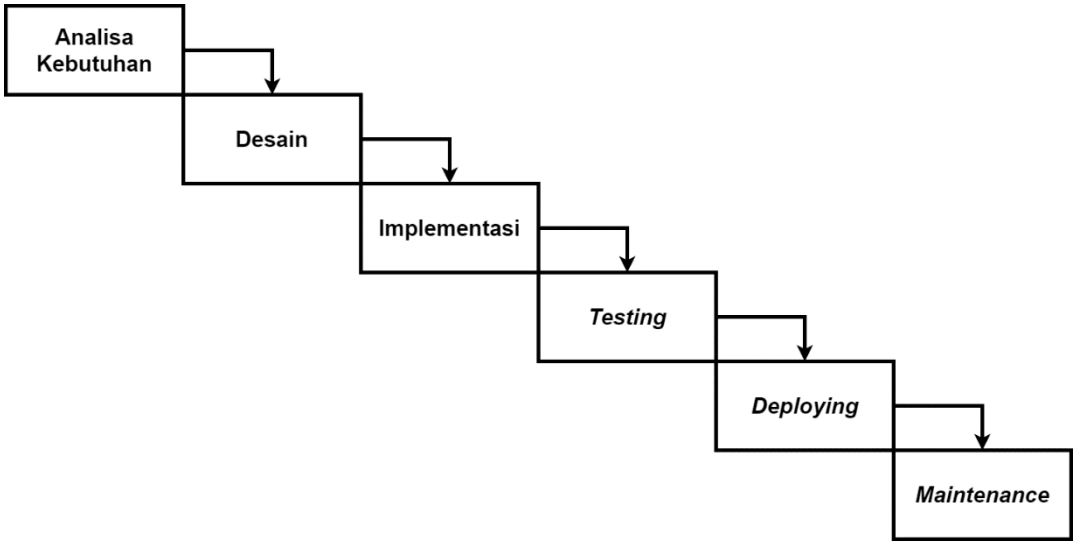
BAB III

KEGIATAN PELAKSANAAN

Dalam pembuatan laporan skripsi membutuhkan beberapa tahapan yang dibutuhkan seperti metode pelaksanaan, gambaran umum sistem, analisa kebutuhan, perancangan sistem, dan perancangan pengujian sistem yang akan dibahas sebagai berikut.

3.1. Metode Pelaksanaan

Pada pelaksanaan skripsi ini menerapkan metode *waterfall* yang memiliki prinsip dimana setiap tahapan harus diselesaikan sebelum ke tahap selanjutnya seperti yang ditmapilkan pada gambar, metode *waterfall* diantaranya sebagai berikut:



Gambar 3. 1 Metode Waterfall

a) Analisa Kebutuhan

Requirement analysis atau analisis kebutuhan bertujuan untuk mengetahui dan mengumpulkan informasi-informasi yang berkaitan dengan topik, seperti berdiskusi dengan yang bekepentingan serta studi literatur yang bisa didapat dari jurnal, buku, dan lainnya yang menunjang proses pelaksanaan.

b) Desain

Desain ini bertujuan menciptakan panduan yang jelas bagi pengembang dengan menyediakan *flowchart* dari model dan UML. Panduan ini akan membantu

pengembang memahami alur kerja sistem dan struktur data dengan lebih baik. Dengan menggunakan *flowchart* dan UML, pengembang dapat mengidentifikasi secara visual proses dan hubungan antar komponen dalam sistem.

c) Implementasi

Implementasi, atau tahap penerapan, adalah saat dimulainya proses pengkodean dari sistem yang telah direncanakan sebelumnya, seperti menggunakan perangkat lunak Visual Studio Code dan alat lainnya.

d) *Testing*

Pada tahap *testing*, semua pengkodean telah selesai dan dilakukan percobaan alur dari awal sampai akhir sistem. Tujuannya adalah untuk menemukan dan memperbaiki *bug* sebelum melanjutkan ke tahap selanjutnya dalam pengembangan.

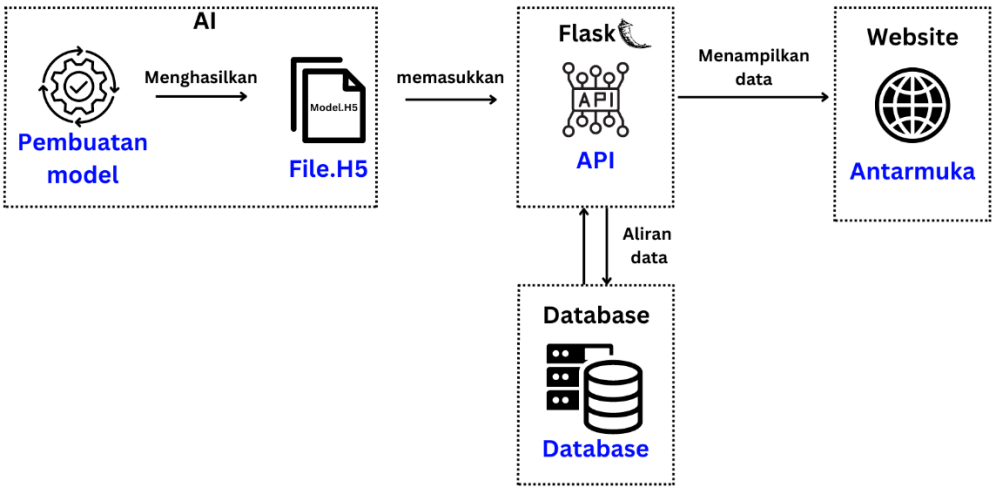
e) *Deployment*

Pada tahap ini, sistem yang telah diuji akan diimplementasikan ke lingkungan produksi. Proses ini mencakup pengaturan server, instalasi perangkat lunak, dan konfigurasi sistem agar dapat diakses dan digunakan oleh pengguna akhir. Tujuannya adalah untuk memastikan bahwa semua komponen berjalan dengan baik di lingkungan yang sebenarnya.

f) *Maintenance*

Setelah sistem di-deploy, tahap maintenance dilakukan untuk memantau dan memastikan kinerja sistem tetap optimal. Pengecekan rutin dilakukan untuk mendeteksi dan memperbaiki masalah atau bug yang muncul setelah sistem digunakan. Maintenance juga mencakup pembaruan fitur dan peningkatan performa agar pengalaman pengguna tetap baik dan sistem berjalan dengan stabil.

3.2. Gambaran Umum Sistem



Gambar 3. 2 Gambaran Umum Sistem

Dalam alat fitur prediksi ini, prosesnya terdiri dari beberapa tahapan. Pertama, pembuatan model terlebih dahulu setelah itu mengkonversi model tersebut ke dalam *file* berformatkan H5. Selanjutnya setelah *file* H5 telah dibuat maka dapat dimasukkan ke dalam kerangka kerja flask, selain itu *framework* flask mengambil data yang ada pada *database*. Selanjutnya dalam *framework* flask membuat API untuk data hasil prediksinya, agar bisa ditampilkan pada antarmuka website, lalu ketika API telah dibuat maka siap untuk ditampilkan ke dalam antarmuka dengan pemanggilan metode "GET".

3.2.1. Arsitektur Model

Dalam skripsi ini, untuk mengoptimalkan hasil dari masing-masing model, akan dilakukan beberapa percobaan dengan berbagai hyperparameter. Menggunakan model yang sederhana akan meningkatkan efisiensi waktu dan sumber daya dalam proses ini. Setiap percobaan akan menggunakan lapisan yang berbeda, Adam untuk pengoptimal, MSE untuk fungsi kerugian, dan lainnya seperti yang ditunjukkan dalam tabel-tabel berikut ini.

No	Layer	Optimizer	Unit	Hyperparameter			Loss Function
				Epoch	Batch size	Validation split	
1	1 (LSTM), 1 (Dropout), 1 (GRU), 1 (Dropout), 1 (Dense)	adam	64	300	90	0,4	MSE
2			128		90	0,4	
3			64		70	0,4	
4			64		70	0,3	
5			128		70	0,4	

Tabel 3. 1 Arsitektur Model Hybrid LSTM-GRU

No	Layer	Optimizer	Unit	Hyperparameter			Loss Function
				Epoch	Batch size	Validation split	
1	1 (LSTM), 1 (Dropout), 1 (Dense)	adam	64	300	90	0,4	MSE
2			128		90	0,4	
3			64		70	0,4	
4			64		70	0,3	
5			128		70	0,4	

Tabel 3. 2 Arsitektur Model LSTM

No	Layer	Optimizer	Unit	Hyperparameter			Loss Function
				Epoch	Batch size	Validation split	
1	1 (GRU), 1 (Dropout), 1 (Dense)	adam	64	300	90	0,4	MSE
2			128		90	0,4	
3			64		70	0,4	
4			64		70	0,3	
5			128		70	0,4	

Tabel 3. 3 Arsitektur Model GRU

No	Layer	Optimizer	Unit	Hyperparameter			Loss Function
				Epoch	Batch size	Validation split	
1	1 (SimpleRNN), 1 (Dropout), 1 (Dense)	adam	64	300	90	0,4	MSE
2			128		90	0,4	
3			64		70	0,4	
4			64		70	0,3	
5			128		70	0,4	

Tabel 3. 4 Arsitektur Model RNN

No	Layer	Optimizer	Filter	Hyperparameter			Loss Function
				Epoch	Batch size	Validation split	
1	1 (Conv1D), 1 (Dropout), 1 (Flatten), 1 (Dense)	adam	64	300	90	0,4	MSE
2			128		90	0,4	
3			64		70	0,4	
4			64		70	0,3	
5			128		70	0,4	

Tabel 3. 5 Arsitektur Model CNN

3.3. Analisis Kebutuhan

Analisis kebutuhan mencakup analisis kebutuhan fungsional dan nonfungsional, yang merupakan langkah penting dalam pengembangan sistem. Proses ini melibatkan identifikasi dan penentuan persyaratan yang harus dipenuhi oleh sistem, baik dalam hal fungsi yang harus dilakukan (fungsional) maupun kualitas atau karakteristik tertentu yang harus dimiliki (nonfungsional). Kedua jenis kebutuhan ini kemudian digunakan sebagai dasar untuk merancang dan mengembangkan solusi yang sesuai dengan tujuan dan kebutuhan pengguna.

3.3.1. Analisis Kebutuhan Fungsional

Analisis kebutuhan fungsional alat pada skripsi ini mengacu pada serangkaian fitur dan kemampuan yang diperlukan agar sistem dapat beroperasi sesuai dengan kebutuhan pengguna. Dalam konteks ini, perlu dipertimbangkan bahwa sistem harus memiliki kemampuan untuk:

a) Mengumpulkan dan menyimpan data beban puncak pembangkit listrik secara efisien dalam struktur *database* beban puncak listrik yang sesuai.
b) Menyediakan antarmuka yang memungkinkan akses data beban puncak dengan menggunakan *framework* Flask melalui API.
c) Melakukan pemrosesan data yang akurat dan efektif untuk melakukan prediksi beban puncak pembangkit listrik, menggunakan metode atau algoritma yang sesuai dengan tujuan analisis.
d) Menghasilkan angka-angka prediksi beban puncak pembangkit listrik.

Dengan demikian, analisis kebutuhan fungsional ini memastikan bahwa fitur yang dikembangkan dalam skripsi ini mampu memenuhi kebutuhan pengguna dengan memberikan solusi yang akurat, efisien, dan mudah diakses.

3.3.2. Analisis Kebutuhan Non Fungsional

Kebutuhan nonfungsional memiliki peran penting dalam memastikan tercapainya kebutuhan fungsional. Berikut adalah beberapa contoh kebutuhan nonfungsional yang harus dipertimbangkan:

a) Analisis Kebutuhan Perangkat Keras

Perangkat keras yang dibutuhkan dalam pembuatan fitur dalam skripsi ini adalah laptop atau komputer yang memiliki minimal RAM 8 GB dan penyimpanan *hardisk* 7 GB.

b) Analisis Kebutuhan Perangkat Lunak

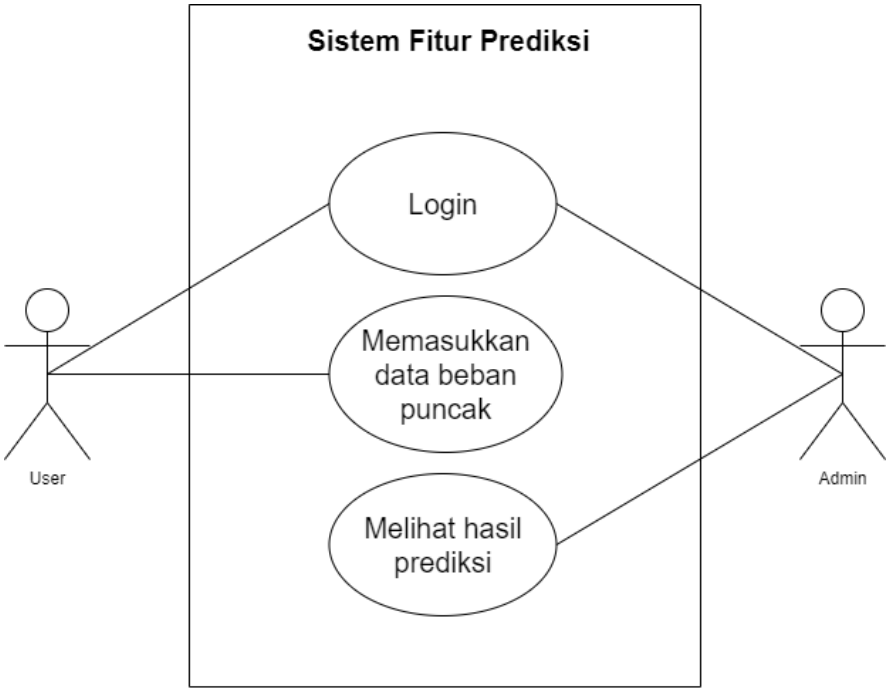
Perangkat lunak yang dibutuhkan dalam pembuatan fitur dalam skripsi ini adalah *text editor Visual Studio Code* dan XAMPP.

3.4. Perancangan Sistem

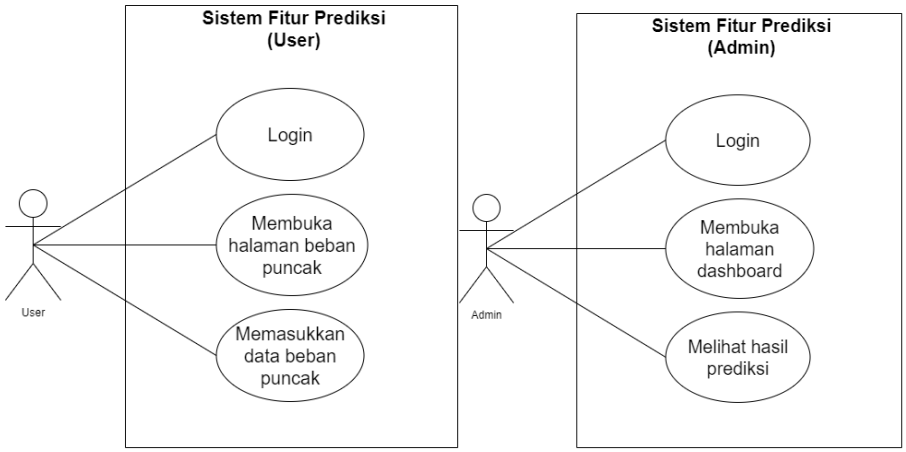
Berdasarkan pada analisis kebutuhan yang telah diperoleh, dilakukan penyusunan rancangan sistem yang tercantum di bawah ini menggunakan UML dan *flowchart*.

3.4.1. UML

Pada laporan skripsi ini UML fitur prediksi yang digunakan sebagai salah satu rancangan sistem menggunakan *use case diagram* dan *activity diagram.*

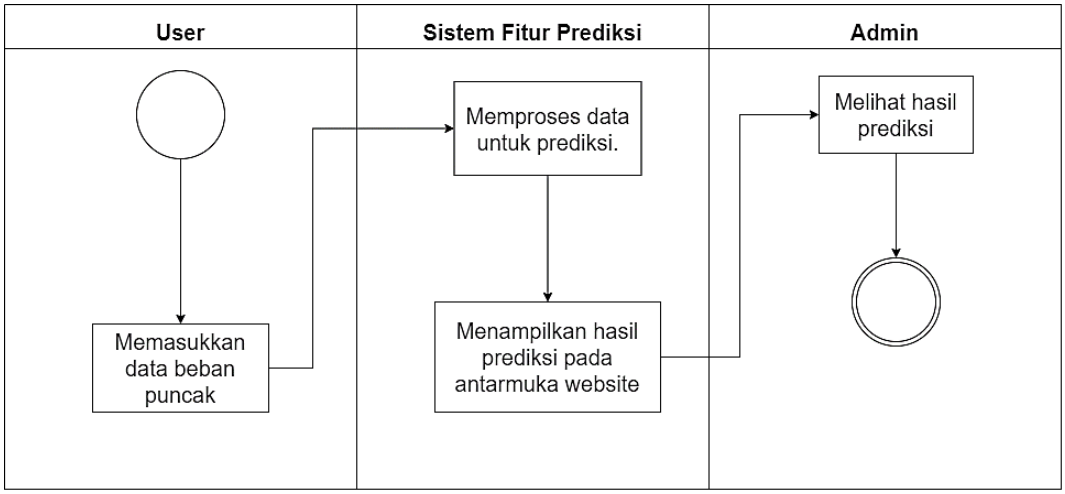


Gambar 3. 3 Use Case Diagram



Gambar 3. 4 Rincian Use Case Diagram

Pada gambar diagram 3.3 dengan rincian pada gambar diagram 3.4, terdapat langkah-langkah untuk mencapai prediksi beban puncak. Pada sisi *user*, langkah pertama adalah *login* ke website, kemudian membuka halaman beban puncak, dan terakhir memasukkan data beban puncak pembangkit listrik. Selanjutnya, pada sisi admin, untuk melihat prediksi beban puncak, langkah pertama adalah login terlebih dahulu, kemudian membuka halaman dashboard, dan melihat grafik hasil prediksi beban puncak.

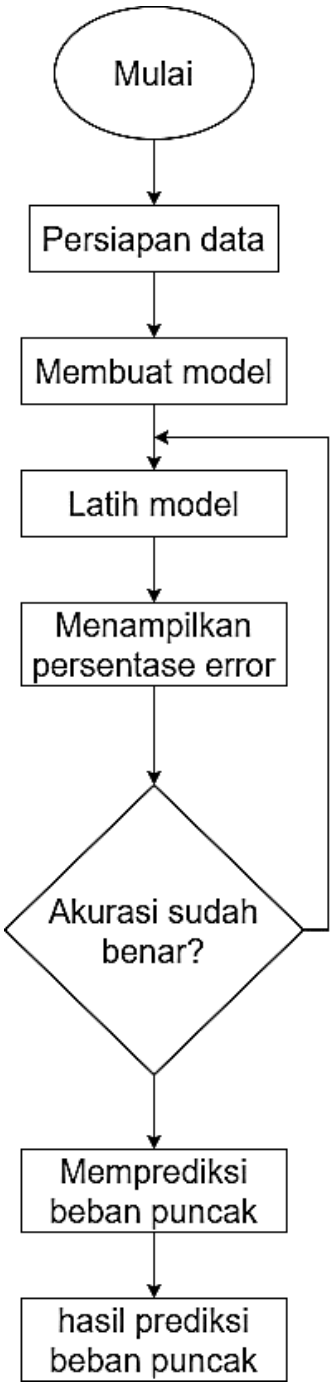


Gambar 3. 5 Activity Diagram

Pada gambar diagram 3.5 dijelaskan aktivitas dari user, sistem, dan admin. Penjelasannya sebagai berikut: setelah user memasukkan nilai beban puncak, data tersebut akan masuk ke dalam sistem yang kemudian memproses data untuk prediksi. Proses ini meliputi pengolahan data dan penampilan hasil prediksi di website. Setelah itu, admin dapat melihat hasil prediksi tersebut.

3.4.2. Flowchart

Dalam laporan skripsi ini, untuk memberikan penjelasan yang lebih jelas tentang rancangan sistem pemodelan algoritma, digunakanlah *flowchart* sebagai alat visual yang efektif. *Flowchart* ini membantu memvisualisasikan alur logika dan proses yang ada. Sehingga *flowchart* ini juga mempermudah pembaca dalam memahami struktur algoritma. Selain itu, *flowchart* membantu menjelaskan hubungan antar komponen dalam algoritma yang diusulkan. *Flowchart* dalam skripsi ini digambarkan sebagai berikut:



Gambar 3. 6 Flowchart Model Prediksi

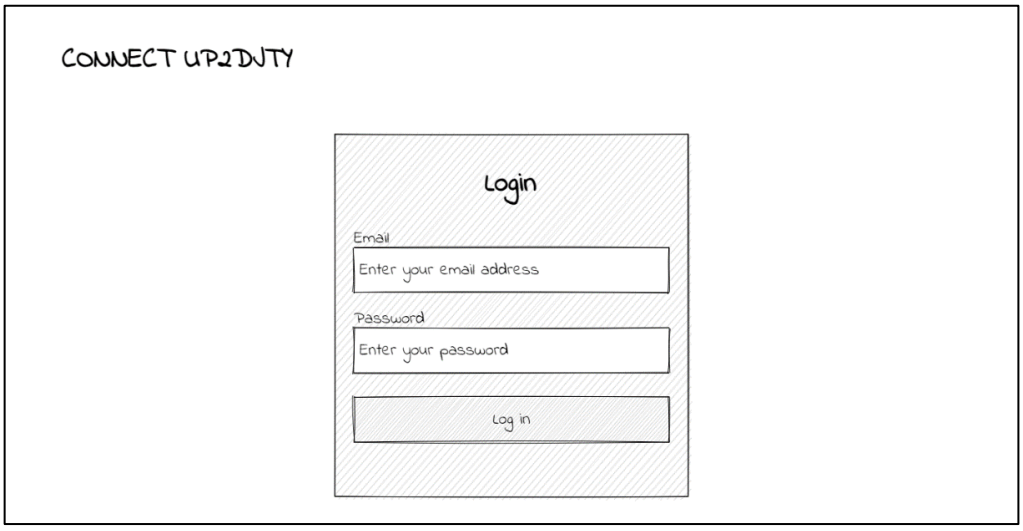
Tahap pertama adalah melakukan persiapan data dengan membaca data, memproses kolom, dan mengatur indeks. Selanjutnya, data ditransformasi dengan menetapkan panjang dan urutan jumlah fitur. Setelah itu, membuat urutan dan label dari data yang sudah dinormalisasi, kemudian mengonversi data ke format yang sesuai. Setelah itu membuat model dengan menggunakan arsitektur yang sesuai untuk masing masing model. Selanjutnya masuk ke pelatihan model jika akurasi

dirasa sudah cukup maka masuk ke bagian prediksi beban puncak setelah itu menampilkan hasil prediksi beban puncak pembangkit listrik.

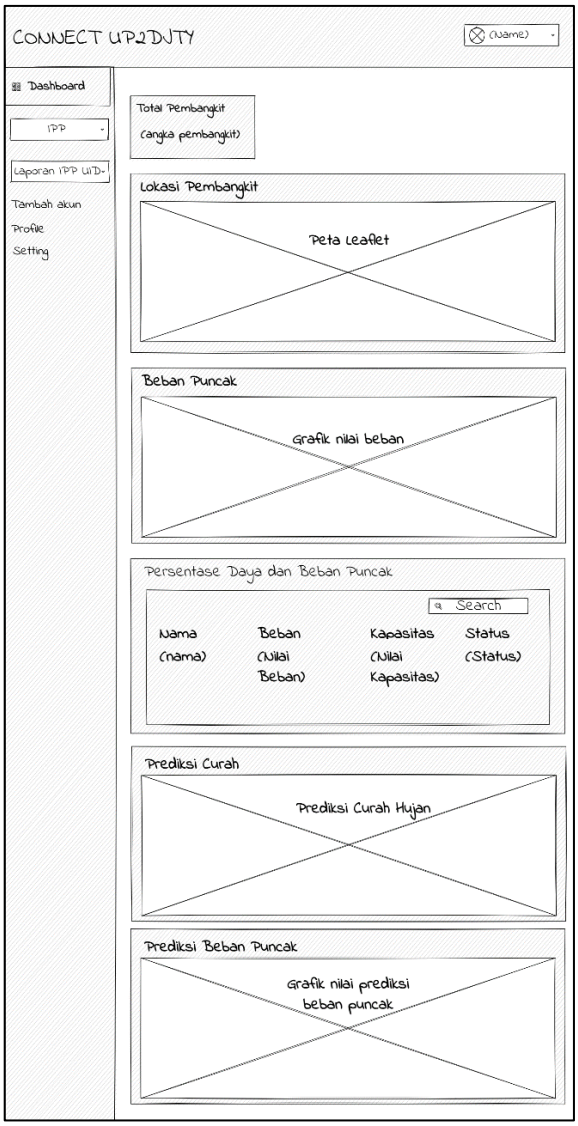
3.4.3. Rancangan Antar Muka dan Interaksi Aplikasi

Tujuan penggunaan website ini adalah untuk memprediksi beban puncak pembangkit listrik. Fitur ini menggunakan API flask untuk menampilkan data hasil prediksi beban puncak pembangkit listrik pada *interface*. *Input* yang diberikan adalah data dari pembangkit listrik ke dalam algoritma, sehingga memiliki *output* hasil prediksi selama 4 bulan. Dengan demikian, pengguna dapat melihat pergerakan dari nilai beban puncak pembangkit listrik melalui grafik. Dalam interaksinya seperti yang digambarkan dalam UML gambar 3.2 hingga gambar 3.4

Dalam laporan skripsi ini, *mockup* digunakan sebagai alat visual yang efektif untuk menjelaskan rancangan antarmuka dan interaksi sistem dengan lebih jelas. *Mockup* ini membantu mengubah konsep dari pemikiran menjadi gambar yang dapat divisualisasikan. Dengan demikian, *mockup* memudahkan pembaca untuk memahami tampilan dan struktur web. Selain itu, *mockup* juga berfungsi untuk menjelaskan komponen-komponen yang ada dalam web. Adapun *mockup* dalam skripsi ini digambarkan sebagai berikut:



Gambar 3. 7 Mockup Halaman Login



Gambar 3. 8 Mockup Halaman Dashboard

BAB IV

ANALISIS DAN PEMBAHASAN

Pada bab ini akan menjelaskan mengenai analisis dan pembahasan sistem dari hasil percobaan dengan rangakian yang telah dibuat sebelumnya. Analisa algoritma dan pengimplementasian model ke dalam web merupakan dua hal yang akan dibahas dan dianalisis pada bab ini.

4.1. Analisis Algoritma

Analisis algoritma akan menjelaskan hasil dari percobaan algoritma yang telah dilakukan. Dalam analisis ini, akan dijelaskan mulai dari data yang digunakan, arsitektur algoritma yang diterapkan, hingga nilai evaluasi yang diperoleh. Tujuan dari analisis ini adalah untuk memberikan gambaran yang jelas tentang kinerja algoritma dan bagaimana setiap komponen berkontribusi terhadap hasil akhir.

4.1.1. Data

Dalam skripsi ini, digunakan data simulasi sumber terbuka dari situs web RTE (https://www.services-rte.com/), yaitu data beban pembangkit listrik per jam. Dari semua data ini, beban puncak bulanan diambil dari salah satu unit pembangkit yang berkaitan dengan tenaga air. Data tersebut terdiri dari 145 beban puncak bulanan yang dikumpulkan dari Desember 2011 hingga Desember 2023, dengan beberapa data seperti yang ditampilkan dalam tabel 4.1.

Tanggal	Beban
1-Dec-11	144
1-Jan-12	142
1-Feb-12	135
1-Mar-12	133
1-Apr-12	129
1-May-12	132
1-Jun-12	130

Tabel 4. 1 Contoh Dataset Simulasi Beban Puncak

Untuk prediksi kedepannya menggunakan data dari 13 pembangkit listrik yang diberikan oleh perusahaan, masing-masing pembangkit memiliki 5 data dari Agustus hingga Desember 2023. Dalam proses pengujian dan pelatihan, terdapat tiga skenario ukuran data pengujian dan pelatihan yang ditampilkan pada tabel 4.2. Skenario pertama adalah pelatihan sebesar 70% dan pengujian sebesar 30%, skenario kedua adalah pelatihan sebesar 80% dan pengujian sebesar 20%, serta skenario ketiga adalah pelatihan sebesar 90% dan pengujian sebesar 10%.

Skenario	**Ukuran Data**	
	Pelatihan	**Pengujian**
1	70%	30%
2	80%	20%
3	90%	10%

Tabel 4. 2 Skenario Ukuran Data

Pada tahap *preprocessing* data, beberapa langkah dilakukan. Pertama, data dibaca dan diproses kolom tanggal serta diatur indeksnya. Selanjutnya, data dinormalisasi menggunakan *MinMax Scaler*. Setelah itu, data ditransformasi sesuai kebutuhan. Terakhir, data dikonversi ke format yang sesuai untuk pemrosesan lebih lanjut.

4.1.2. Evaluasi Model

Dalam penelitian ini, algoritma GRU digunakan dan dibandingkan dengan model LSTM, RNN, CNN, dan *hybrid* LSTM-GRU. Percobaan dilakukan untuk setiap model dengan berbagai skenario pembagian data, yaitu 70% untuk pelatihan dan 30% untuk pengujian, 80% untuk pelatihan dan 20% untuk pengujian, serta 90% untuk pelatihan dan 10% untuk pengujian. Hasil percobaan menunjukkan variasi performa yang signifikan antara model-model tersebut, yang dirangkum dalam tabel di bawah ini.

No	Unit	Hyperparameter			MAE	MSE	RMSE	Avg RMSE Kfold 10
		Epochs	Batch_size	Validation_split				
1	64	26/300	29/300	0,4	15,37%	6,32%	25,14%	0,120
2	128	19/300	18/300	0,4	15,27%	6,83%	26,13%	0,123
3	64	24/300	26/300	0,4	15,05%	6,18%	24,87%	0,120
4	64	32/300	20/300	0,3	14,50%	6,64%	25,77%	
5	128	17/300	19/300	0,4	15,53%	6,76%	26,00%	0,120

Tabel 4. 3 Hasil Percobaan GRU Skenario 1

No	Unit	Hyperparameter			MAE	MSE	RMSE	Avg RMSE Kfold 10
		Epochs	Batch_size	Validation_split				
1	64	22/300	90	0,4	19,28%	9,82%	31,34%	0,113
2	128	16/300	90	0,4	19,34%	10,26%	32,03%	0,121
3	64	39/300	70	0,4	18,81%	9,24%	30,40%	0,114
4	64	29/300	70	0,3	20,04%	9,92%	31,50%	
5	128	17/300	70	0,4	20,12%	10,13%	31,83%	0,113

Tabel 4. 4 Hasil Percobaan GRU Skenario 2

No	Unit	Hyperparameter			MAE	MSE	RMSE	Avg RMSE Kfold 10
		Epochs	Batch_size	Validation_split				
1	64	30/300	90	0,4	26,50%	13,12%	36,22%	0,126
2	128	20/300	90	0,4	27,79%	14,63%	38,24%	0,136
3	64	15/300	70	0,4	25,43%	12,73%	35,69%	0,127
4	64	14/300	70	0,3	26,82%	13,70%	37,01%	
5	128	12/300	70	0,4	27,17%	14,32%	37,84%	0,126

Tabel 4. 5 Hasil Percobaan GRU Skenario 3

Tabel 4.3 menjelaskan performa algoritma GRU pada pembagian data 70% untuk pelatihan dan 30% untuk pengujian. Hasil terbaik diperoleh pada percobaan ketiga dengan nilai MAE sebesar 15,05%, MSE sebesar 6,18%, dan RMSE sebesar 24,87%. Tabel 4.4 menjelaskan hasil algoritma GRU dengan ukuran data pelatihan sebesar 80% dan data pengujian sebesar 20%. Pada percobaan ini, hasil *error* terendah dicapai pada percobaan ketiga, dengan nilai MAE sebesar 18,81%, MSE sebesar 9,24%, dan RMSE sebesar 30,40%. Pada tabel 4.5 memberikan hasil performa algoritma GRU dengan pembagian data 90% *training* dan 10% *testing*. 5

percobaan telah dilakukan dan hasil yang paling terbaik adalah pada percobaan ketiga dengan MSE sebesar 25,43%, MSE sebesar 12,73%, dan RMSE sebesar 35,69%.

No	Unit	Hyperparameter			MAE	MSE	RMSE	Avg RMSE Kfold 10
		Epochs	Batch_size	Validation_split				
1	64	41/300	90	0,4	16,19%	7,02%	26,49%	0,123
2	128	25/300	90	0,4	16,63%	7,29%	26,99%	0,128
3	64	37/300	70	0,4	16,89%	7,09%	26,63%	0,123
4	64	41/300	70	0,3	15,02%	7,05%	26,56%	
5	128	29/300	70	0,4	16,37%	7,44%	27,29%	0,123

Tabel 4. 6 Hasil Percobaan LSTM Skenario 1

No	Unit	Hyperparameter			MAE	MSE	RMSE	Avg RMSE Kfold 10
		Epochs	Batch_size	Validation_split				
1	64	48/300	90	0,4	20,68%	10,60%	32,56%	0,117
2	128	27/300	90	0,4	20,50%	11,22%	33,50%	0,127
3	64	36/300	70	0,4	20,51%	10,69%	32,69%	0,116
4	64	21/300	70	0,3	21,22%	10,49%	32,39%	
5	128	29/300	70	0,4	20,32%	11,04%	33,23%	0,118

Tabel 4. 7 Hasil Percobaan LSTM Skenario 2

No	Unit	Hyperparameter			MAE	MSE	RMSE	Avg RMSE Kfold 10
		Epochs	Batch_size	Validation_split				
1	64	37/300	90	0,4	28,64%	14,84%	38,52%	0,130
2	128	29/300	90	0,4	29,69%	15,88%	39,85%	0,137
3	64	26/300	70	0,4	29,10%	15,34%	39,17%	0,130
4	64	24/300	70	0,3	28,85%	14,66%	38,28%	
5	128	16/300	70	0,4	29,55%	16,15%	40,18%	0,130

Tabel 4. 8 Hasil Percobaan LSTM Skenario 3

Berdasarkan hasil percobaan algoritma LSTM dengan tiga skenario yang disajikan dalam tabel 4.6 hingga tabel 4.8, didapatkan beberapa temuan penting. Pada skenario pertama, dengan pembagian data 70% untuk pelatihan dan 30% untuk pengujian, percobaan pertama memberikan hasil terbaik dengan nilai MAE sebesar 16,19%, MSE sebesar 7,02%, dan RMSE sebesar 26,49%. Pada skenario kedua, dengan pembagian data 80% untuk pelatihan dan 20% untuk pengujian, hasil

terbaik juga dicapai pada percobaan keempat dengan nilai MAE sebesar 21,22%, MSE sebesar 10,49%, dan RMSE sebesar 32,39%. Terakhir, pada skenario ketiga dengan pembagian data 90% untuk pelatihan dan 10% untuk pengujian, percobaan keempat memberikan hasil terbaik dengan nilai MAE sebesar 28,84%, MSE sebesar 14,66%%, dan RMSE sebesar 38,28%.

No	Unit	Hyperparaeter			MAE	MSE	RMSE	Avg RMSE Kfold 10
		Epochs	Batch_size	Validation_split				
1	64	11/300	90	0,4	19,83%	12,66%	35,58%	0,144
2	128	18/300	90	0,4	20,15%	12,12%	34,81%	0,172
3	64	15/300	70	0,4	24,97%	14,46%	38,02%	0,160
4	64	14/300	70	0,3	22,51%	16,27%	40,34%	
5	128	7/300	70	0,4	17,62%	10,93%	33,06%	0,144

Tabel 4. 9 Hasil Percobaan RNN Skenario 1

No	Unit	Hyperparameter			MAE	MSE	RMSE	Avg RMSE Kfold 10
		Epochs	Batch_size	Validation_split				
1	64	12/300	90	0,4	27,75%	20,05%	44,77%	0,140
2	128	8/300	90	0,4	27,07%	16,13%	40,16%	0,145
3	64	12/300	70	0,4	20,21%	10,95%	33,09%	0,140
4	64	12/300	70	0,3	19,03%	9,45%	30,74%	
5	128	8/300	70	0,4	27,48%	13,40%	36,61%	0,143

Tabel 4. 10 Hasil Percobaan RNN Skenario 2

No	Unit	Hyperparameter			MAE	MSE	RMSE	Avg RMSE Kfold 10
		Epochs	Batch_size	Validation_split				
1	64	12/300	90	0,4	30,42%	17,47%	41,79%	0,161
2	128	8/300	90	0,4	35,32%	20,98%	45,80%	0,154
3	64	12/300	70	0,4	37,61%	23,82%	48,80%	0,153
4	64	32/300	70	0,3	30,03%	16,65%	40,81%	
5	128	10/300	70	0,4	32,31%	19,46%	44,11%	0,162

Tabel 4. 11 Hasil Percobaan RNN Skenario 3

Percobaan menggunakan metode RNN dilakukan dengan tiga skenario data yang ditampilkan pada tabel 4.9 hingga tabel 4.11. Pada skenario pertama, dengan pembagian data 70% untuk pelatihan dan 30% untuk pengujian, hasil terbaik diperoleh pada percobaan kelima dengan nilai MAE sebesar 17,62%, MSE sebesar 10,93%, dan RMSE sebesar 33,06%. Pada skenario kedua, dengan pembagian data

80% untuk pelatihan dan 20% untuk pengujian, hasil terbaik dicapai pada percobaan keempat dengan nilai MAE sebesar 19,03%, MSE sebesar 9,45%, dan RMSE sebesar 30,74%. Pada skenario ketiga, dengan pembagian data 90% untuk pelatihan dan 10% untuk pengujian, hasil terbaik diperoleh pada percobaan kelima dengan nilai MAE sebesar 30,03%, MSE sebesar 16,65%, dan RMSE sebesar 40,81%.

No	Filter	Hyperparameter			MAE	MSE	RMSE	Avg RMSE Kfold 10
		Epochs	Batch_size	Validation_split				
1	64	38/300	90	0,4	15,93%	6,85%	26,17%	0,124
2	128	22/300	90	0,4	15,71%	6,75%	25,98%	0,124
3	64	43/300	70	0,4	15,75%	6,68%	25,85%	0,129
4	64	40/300	70	0,3	15,51%	7,65%	27,66%	
5	128	30/300	70	0,4	15,47%	6,60%	25,70%	0,123

Tabel 4. 12 Hasil Percobaan CNN Skenario 1

No	Filter	Hyperparameter			MAE	MSE	RMSE	Avg RMSE Kfold 10
		Epochs	Batch_size	Validation_split				
1	64	27/300	90	0,4	18,15%	8,83%	29,72%	0,116
2	128	27/300	90	0,4	19,91%	10,31%	32,11%	0,128
3	64	44/300	70	0,4	19,11%	9,61%	31,01%	0,116
4	64	23/300	70	0,3	18,90%	9,07%	30,11%	
5	128	28/300	70	0,4	19,79%	10,08%	31,75%	0,119

Tabel 4. 13 Hasil Percobaan CNN Skenario 2

No	Filter	Hyperparameter			MAE	MSE	RMSE	Avg RMSE Kfold 10
		Epochs	Batch_size	Validation_split				
1	64	32/300	90	0,4	26,87%	14,12%	37,57%	0,130
2	128	30/300	90	0,4	24,32%	12,15%	34,86%	0,128
3	64	30/300	70	0,4	25,50%	12,60%	35,50%	0,128
4	64	19/300	70	0,3	31,68%	17,94%	42,36%	
5	128	17/300	70	0,4	27,24%	14,12%	37,58%	0,130

Tabel 4. 14 Hasil Percobaan CNN Skenario 3

Dari percobaan CNN yang telah dilakukan dengan menggunakan 3 skenario, pada skenario pertama dengan pembagian data *size* yakni 70% data *train* dan 30% data *test* mendapatkan hasil terbaik pada percobaan kelima dengan RMSE 25,70%. Pada skenario kedua dengan pembagian data *size* yakni 80% data *train* dan 20% data *test* terdapat pada percobaan pertama dengan nilai RMSE sebesar 29,72%. Terakhir pada skenario ketiga dengan pembagian data *size* yakni 90% data *train* dan 10% data *test* mendapatkan hasil terbaik pada percobaan kedua dengan RMSE sebesar 34,86%. Dari percobaan CNN tersebut didapatkan hasil terbaik yakni pada skenario pertama dengan percobaan kelima yakni 25,70%.

No	Unit	Hyperparameter			MAE	MSE	RMSE	Avg RMSE Kfold 10
		Epochs	Batch_size	Validation_split				
1	64	22/300	90	0,4	15,74%	6,65%	25.79%	0,122
2	128	14/300	90	0,4	17,47%	7,08%	26,61%	0,126
3	64	21/300	70	0,4	15,31%	6,78%	26,03%	0,127
4	64	22/300	70	0,3	1423%	7,00%	26,45%	
5	128	14/300	70	0,4	16,16%	7,05%	26,55%	0,122

Tabel 4. 15 Hasil Percobaan Hybrid LSTM-GRU Skenario 1

No	Unit	Hyperparameter			MAE	MSE	RMSE	Avg RMSE Kfold 10
		Epochs	Batch_size	Validation_split				
1	64	18/300	90	0,4	20,68%	10,14%	31,85%	0,121
2	128	15/300	90	0,4	20,18%	10,48%	32,37%	0,120
3	64	21/300	70	0,4	19,29%	10,22%	31,97%	0,120
4	64	13/300	70	0,3	22,02%	9,83%	31,35%	
5	128	14/300	70	0,4	19,72%	10,87%	32,98%	0,121

Tabel 4. 16 Hasil Percobaan Hybrid LSTM-GRU Skenario 2

No	Unit	Hyperparameter			MAE	MSE	RMSE	Avg RMSE Kfold 10
		Epochs	Batch_size	Validation_split				
1	64	22/300	90	0,4	17,82%	6,87%	37,56%	0,133
2	128	14/300	90	0,4	28,70%	14,75%	38,40%	0,130
3	64	12/300	70	0,4	28,96%	14,11%	37,56%	0,131
4	64	13/300	70	0,3	27,23%	14,53%	38,12%	
5	128	15/300	70	0,4	26,85%	14,03%	37,45%	0,133

Tabel 4. 17 Hasil Percobaan Hybrid LSTM-GRU Skenario 3

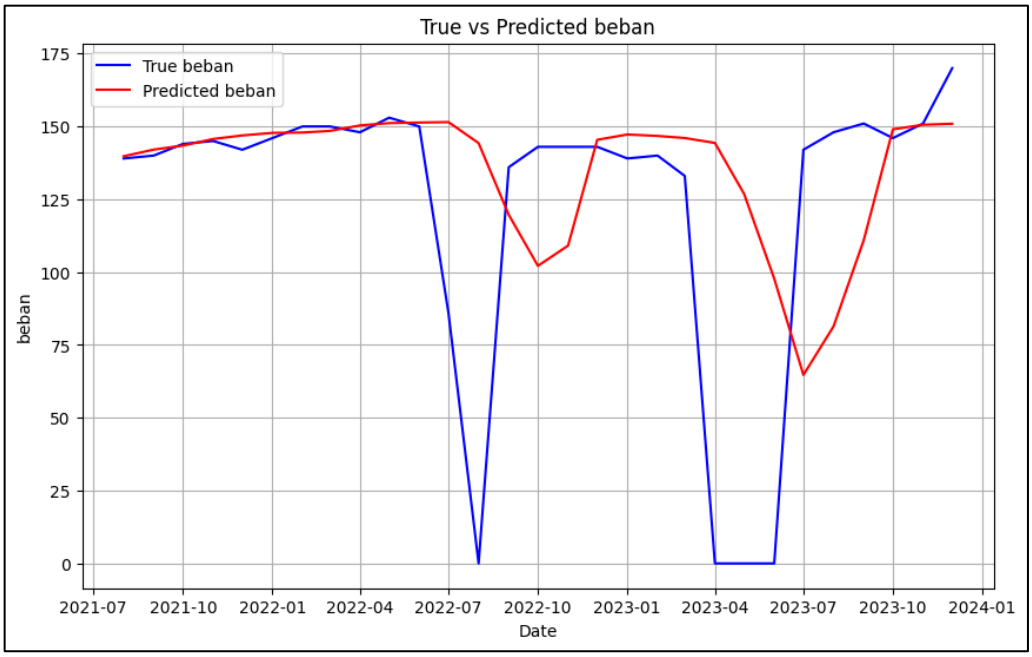
Pada percobaan selanjutnya menggunakan metode *hybrid* dari LSTM dan GRU dengan menggunakan ketiga skenario tersebut. Pada skenario pertama mendapatkan hasil terbaik pada percobaan pertama dengan hasil RMSE 25,79%. Setelah itu dengan skenario kedua mendapatkan hasil terbaik dengan RMSE 31,35% pada percobaan keempat. Skenario terakhir yakni skenario ketiga memiliki nilai RMSE terendah yakni sebesar 37,45% yang diraih oleh percobaan kelima. Dari percobaan penelitian menggunakan model *hybrid* model terbaik didapatkan oleh skenario pertama pada percobaan pertama dengan RMSE sebesar 25,79%.

No	Model	Skenario	Percobaan	MAE	MSE	RMSE
1	GRU	1	3	15,05%	6,18%	24,87%
2	LSTM	1	1	16,19%	7,02%	26,49%
3	RNN	2	4	19,03%	9,45%	30,74%
4	CNN	1	5	15,47%	6,60%	25,70%
5	*Hybrid LSTM-GRU*	2	1	15,74%	6,65%	25,79%

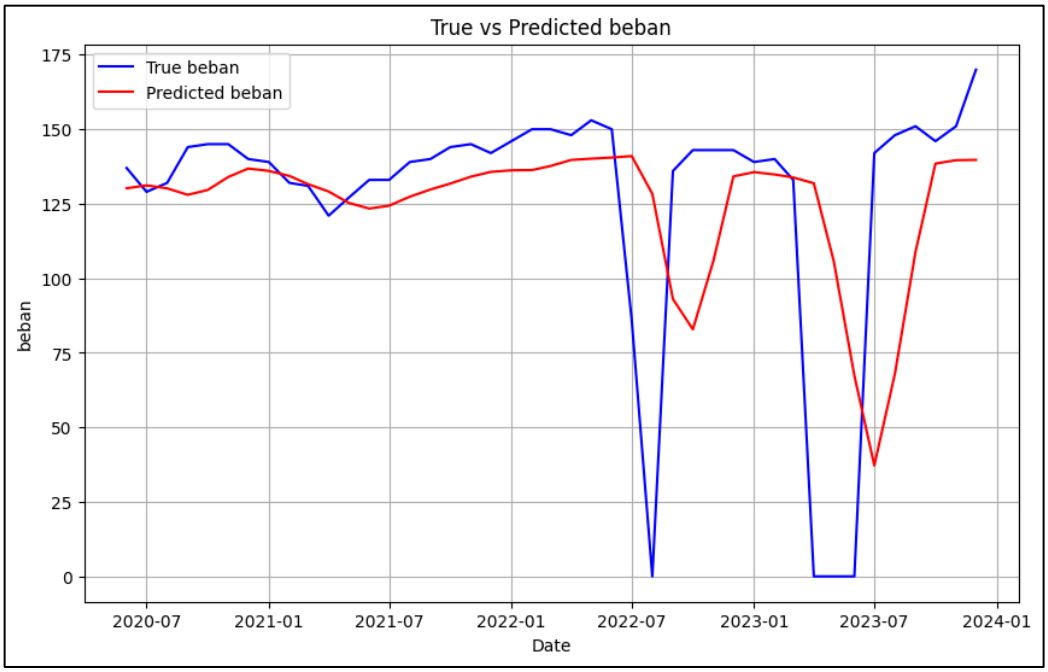
Tabel 4. 18 Hasil Terbaik dari Seluruh Model

Setelah metode GRU, LSTM, RNN, CNN, dan *hybrid* LSTM-GRU diuji, terlihat bahwa setiap algoritma memiliki performa yang berbeda-beda tergantung pada skenario pembagian data dan arsitektur yang digunakan. Pada penelitian ini metode GRU lebih unggul dengan RMSE sebesar 24,87%, MSE sebesar 6,18%, dan MAE sebesar 15,05% serta grafik perbandingan data prediksi dan *true* yang ada pada gambar 4.1. Setelah model didapatkan maka mencoba memasukkan data prediksi dari beberapa perusahaan untuk memprediksi nilai beban puncak per

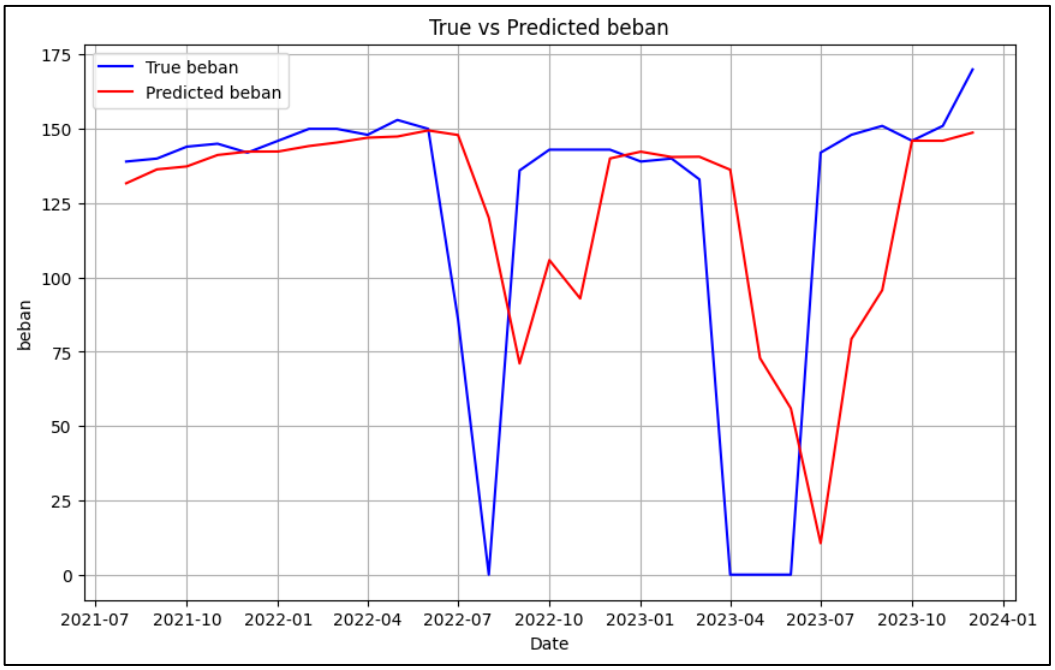
pembangkit kedepannya, hasil tersebut ditunjukkan pada gambar 4.1 dengan nilai yang ditampilkan oleh tabel 4.19 dibawah ini.



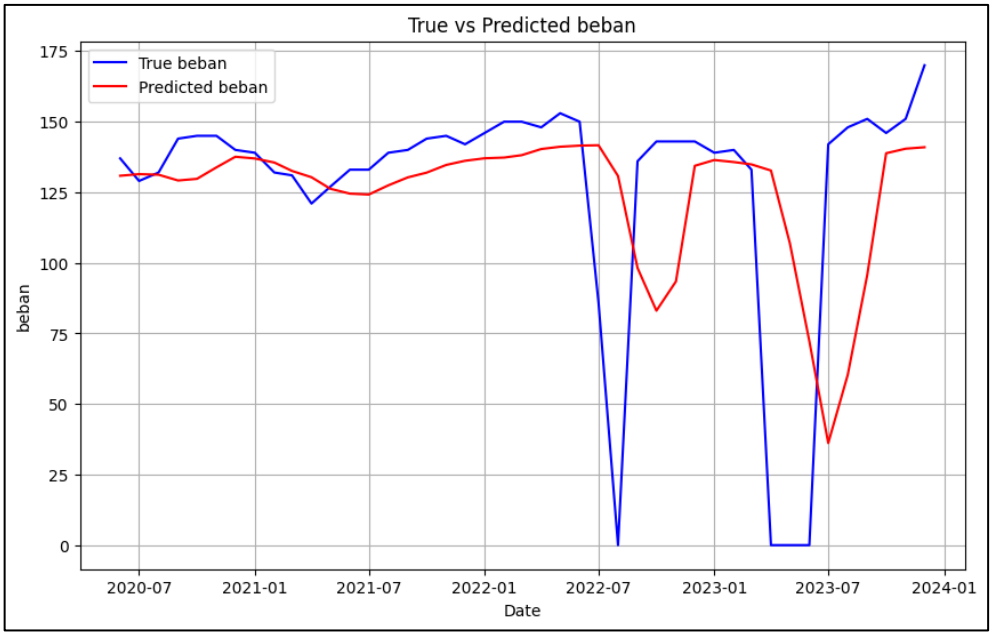
Gambar 4. 1 Grafik Hasil Terbaik Model Hybrid LSTM-GRU



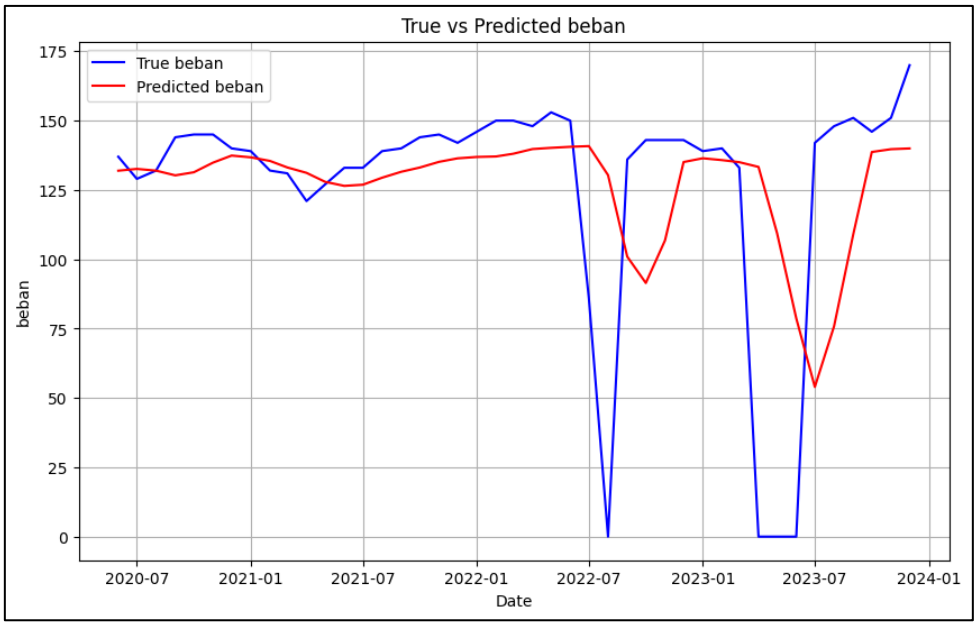
Gambar 4. 2 Grafik Hasil Terbaik Model CNN



Gambar 4. 3 Grafik Hasil Terbaik Model RNN

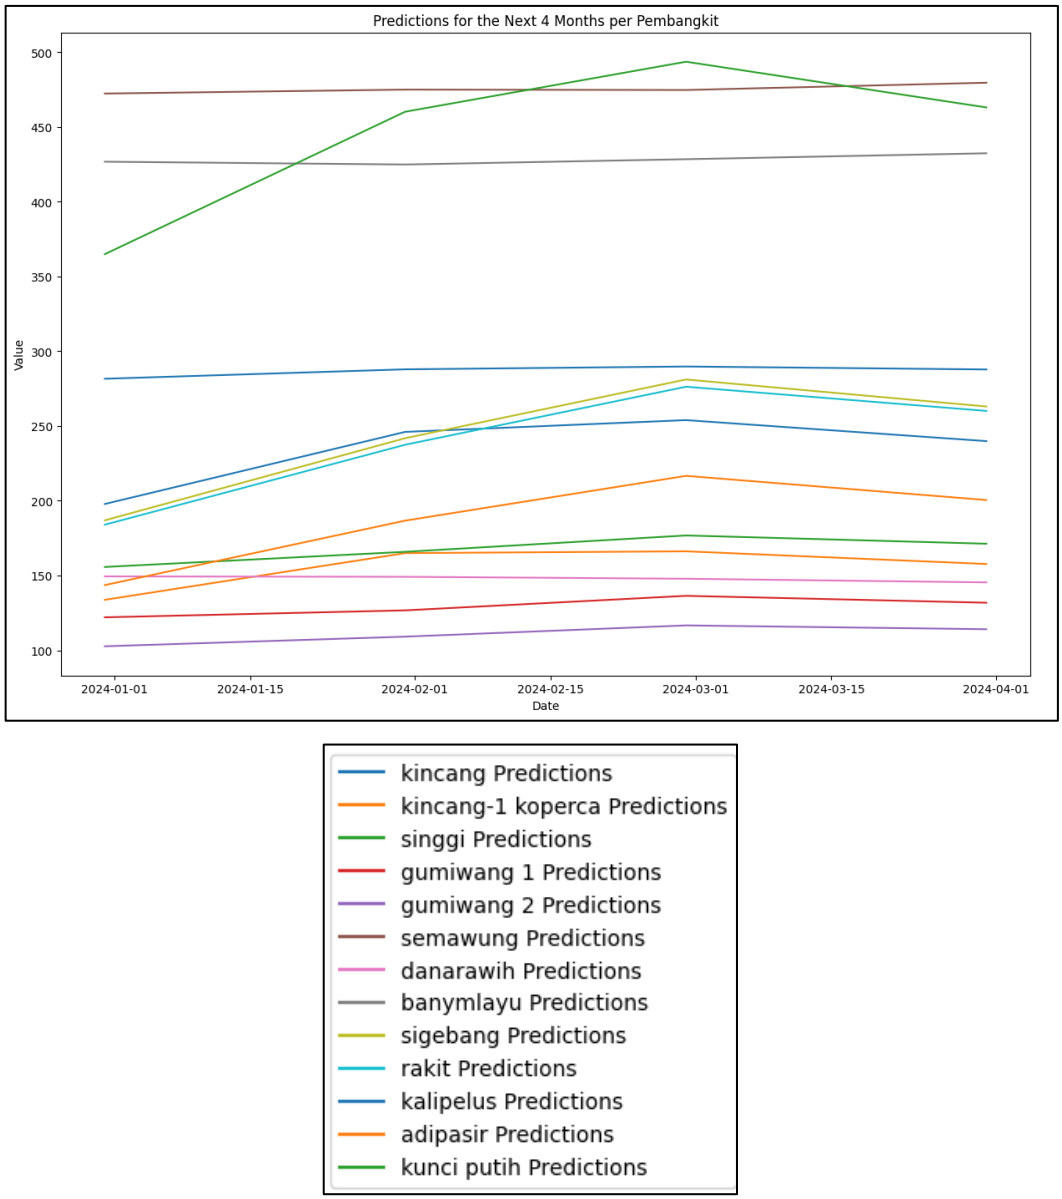


Gambar 4. 4 Grafik Hasil Terbaik Model LSTM



Gambar 4. 5 Grafik Hasil Terbaik Model GRU

Dari keseluruhan grafik yang ditampilkan pada gambar 4.1 hingga 4.5, terdapat informasi mengenai prediksi pada periode dari Juli 2022 hingga Juli 2023. Dalam periode tersebut, error terbesar terjadi. Hal ini disebabkan oleh grafik yang curam atau grafik yang memiliki nilai 0. Faktor-faktor ini mempengaruhi akurasi prediksi secara signifikan. Sehingga, tantangan dalam memprediksi data tersebut menjadi lebih besar.



Gambar 4. 6 Grafik Hasil Prediksi Beban Puncak Pembangkit Listrik

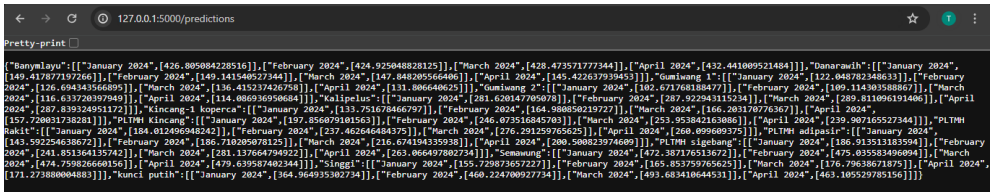
Nama Pembangkit	Januari	Februari	Maret	April
Kincang	197,85608	246,07352	253,95384	239,90717
Kincang-1 koperca	133,75168	164,98085	166,20317	157,72003
Singgi	155,72987	165,85376	176,79639	171,27388
Gumiwang 1	122,04878	126,69434	136,41524	131,80664
Gumiwang 2	102,67177	109,1143	116,63372	114,08694
Semawung	472,38718	475,03558	474,75983	479,6396
Danarawih	149,41788	149,14154	147,8482	145,42264
Banyumlayu	426,80508	424,92505	428,47357	432,441
Sigebang	186,91351	241,85136	281,13766	263,0665
Rakit	184,0125	237,46265	276,29126	260,0996
Kalipelus	281,62015	287,92294	289,8111	287,83932
Adipasir	143,59225	186,7102	216,6742	200,50082
Kunci putih	364,96494	460,2247	493,6834	463,10553

Tabel 4. 19 Hasil Prediksi Pembangkit Tahun 2024

Pada penelitian ini, dengan menggunakan data yang disediakan oleh perusahaan dan model yang telah dibuat yaitu GRU, diperoleh hasil prediksi yang ditampilkan pada tabel diatas. Hasil prediksi ini mencakup periode 4 bulan di tahun 2024 setelah data yang diberikan. Prediksi tersebut menunjukkan bahwa model GRU mampu menangkap pola dan tren dalam data historis. Hasil ini dapat digunakan oleh perusahaan untuk perencanaan strategis dan pengambilan keputusan yang lebih baik.

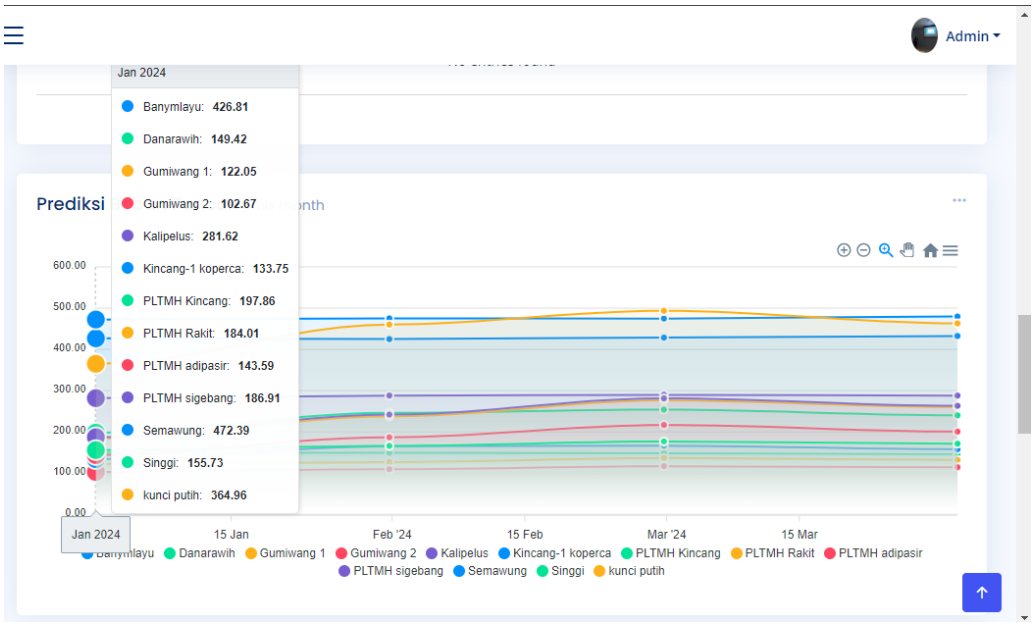
4.1.3. Pengimplementasian Model pada Website

Setelah melakukan percobaan dan mengevaluasi lima model yang terdiri dari RNN, GRU, LSTM, CNN, dan *hybrid* LSTM-GRU, penelitian telah berhasil menemukan model terbaik. Model terbaik kemudian diubah menjadi *file* H5 dan diintegrasikan ke dalam *framework* Flask. Selanjutnya, membuat API dari *framework* Flask yang akan memberikan *response* sesuai dengan yang ditampilkan pada gambar 4.7, yaitu hasil prediksi model untuk 4 bulan ke depan. Data tersebut kemudian diakses oleh *framework* Laravel melalui metode API "GET".

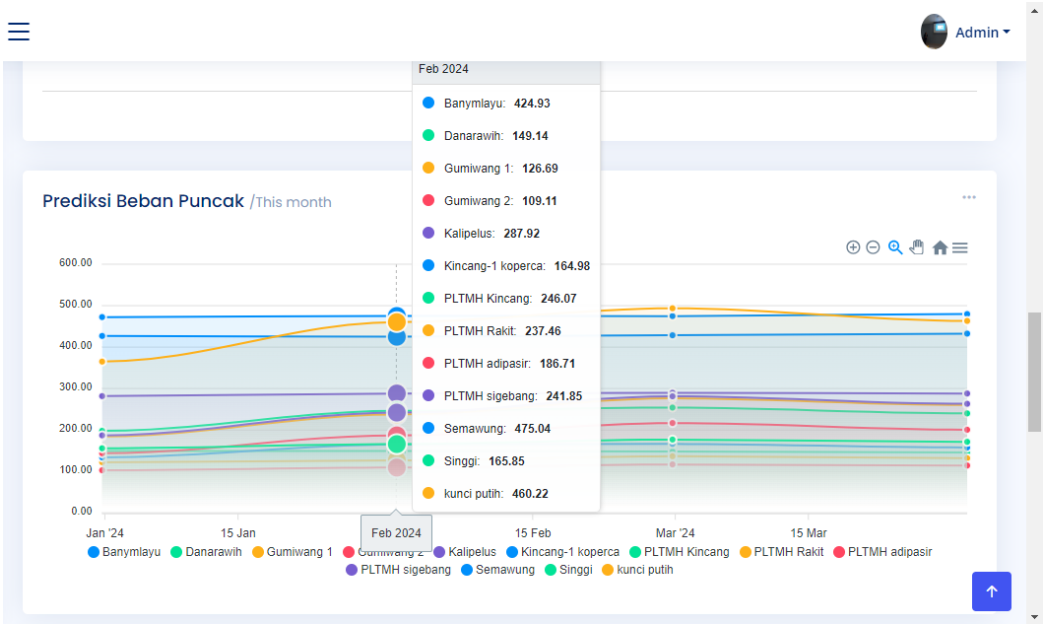


Gambar 4. 7 Response API Framework Flask

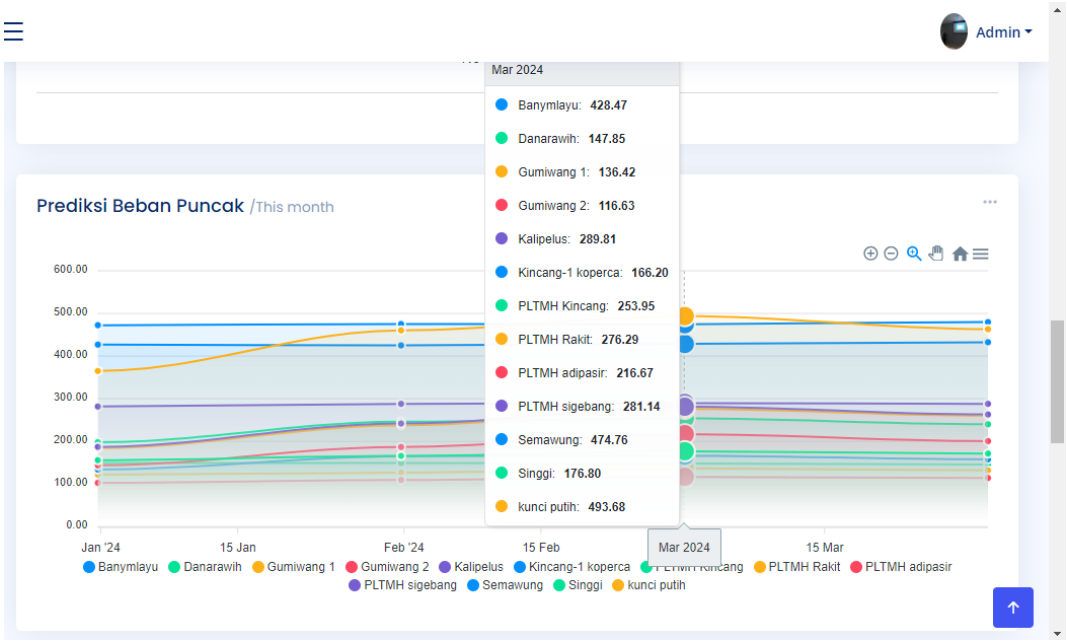
Setelah menerima respons dari API, data tersebut akan ditampilkan dalam bentuk grafik pada halaman *dashboard* web seperti yang terlihat pada gambar dibawah ini. Masing-masing gambar pada gambar 4.8 hingga gambar 4.11 menampilkan nilai-nilai hasil prediksi beban puncak secara berturut dari Januari hingga April. Dalam grafik tersebut dapat dipilah sesuai grafik yang ingin ditampilkan seperti gambar 4.12 yang menampilkan 1 grafik pembangkit.



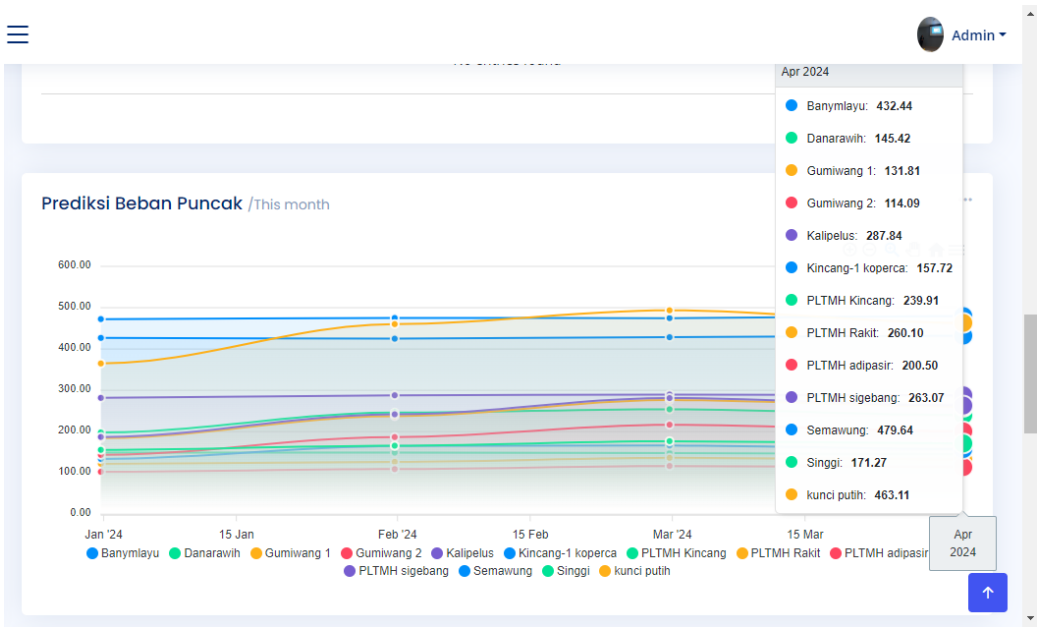
Gambar 4. 8 Tampilan Grafik Prediksi Januari



Gambar 4. 9 Tampilan Grafik Prediksi Februari



Gambar 4. 10 Tampilan Grafik Prediksi Maret



Gambar 4. 11 Tampilan Grafik Prediksi April



Gambar 4. 12 Tampilan Grafik Prediksi Hanya 1 Pembangkit

BAB V

KESIMPULAN

5.1. Kesimpulan

Setelah melakukan penelitian dari skripsi Rancang Bangun Aplikasi Prediksi Beban Puncak Penggunaan Listrik pada Pembangkit Listrik dengan Model *Deep Learning* Berbasis Web: Studi Kasus Web "*Connect* UP2DJTY" maka dari itu memiliki beberapa hasil sebagai berikut:

a) Prediksi adalah proses menggunakan algoritma untuk menganalisis data masa lalu dan menemukan pola atau tren yang bisa digunakan untuk memperkirakan nilai atau kejadian di masa depan. Proses ini melibatkan penggunaan data untuk membuat estimasi berdasarkan informasi yang sudah ada. Dengan menggunakan model yang telah terlatih maka selanjutnya digunakan kembali dengan data yang akan diprediksi.
b) Di antara kelima metode tersebut, yaitu RNN, GRU, LSTM, CNN, dan hybrid LSTM-GRU, arsitektur model GRU menggunakan 64-unit, batch size sebesar 70, dan validation split 0,4, dengan hasil error GRU menunjukkan RMSE sebesar 24,87%, MSE sebesar 6,18%, dan MAE sebesar 15,05%, sehingga dari hasil error tersebut GRU yang dibandingkan dengan model lainnya didapatkan bahwa GRU dengan skenario ketiga adalah model paling efektif; untuk mengimplementasikan fitur ke dalam website adalah dengan menggunakan API yang telah dibuat oleh framework Flask, yang secara teknis menggunakan file dengan format H5 berisikan algoritma yang telah dilatih sebelumnya, dan setelah itu program website akan mengambil data tersebut dengan metode "GET" dan menampilkannya ke dalam dashboard interface.

5.2. Saran

Berdasarkan dari hasil yang telah dibuat dalam skripsi ini, penulis memiliki beberapa saran yang bisa digunakan untuk pengembangan selanjutnya, saran sebagai berikut:

a) Penelitian ini masih menggunakan data *open source* dan belum menggunakan data perusahaan untuk *train* dan *testing*. Dalam pengembangan selanjutnya,

dapat menggunakan data perusahaan yang lebih banyak untuk masing-masing pembangkit sehingga pola-pola prediksi akan lebih akurat.

b) Dalam pengembangan selanjutnya, dapat dicoba menggunakan susunan *layer* yang berbeda dan juga menggunakan metode lainnya untuk mendapatkan hasil yang lebih baik.

DAFTAR PUSTAKA

ArunKumar, K. E., Kalaga, D. V., Mohan Sai Kumar, Ch., Kawaji, M., & Brenza, T. M. (2022). Comparative analysis of Gated Recurrent Units (GRU), long Short-Term memory (LSTM) cells, autoregressive Integrated moving average (ARIMA), seasonal autoregressive Integrated moving average (SARIMA) for forecasting COVID-19 trends. *Alexandria Engineering Journal*, *61*(10), 7585–7603. https://doi.org/10.1016/j.aej.2022.01.011

Attiwal, P., & Indora, S. (2024). A Comprehensive Review of Modern Methods for Load Prediction in the Smart Grid. *Recent Patents on Engineering*, *18*. https://doi.org/10.2174/1872212118666230423143331

Bai, S., Kolter, J., & Koltun, V. (2018). *An Empirical Evaluation of Generic Convolutional and Recurrent Networks for Sequence Modeling*.

Barman, P. P., & Boruah, A. (2018). A RNN based Approach for next word prediction in Assamese Phonetic Transcription. *Procedia Computer Science*, *143*, 117–123. https://doi.org/10.1016/j.procs.2018.10.359

BiLgiLi, M., Arslan, N., ŞekertekiN, A., & Yaşar, A. (2022). Application of long short-term memory (LSTM) neural network based on deep learning for electricity energy consumption forecasting. *Turkish Journal of Electrical Engineering and Computer Sciences*, *30*(1), 140–157. https://doi.org/10.3906/elk-2011-14

Chen, Y., Liao, S., & Xu, J. (2022). Emergency load-shedding optimization control method based on reinforcement learning assistance. *Energy Reports*, *8*, 1051–1061. https://doi.org/10.1016/j.egyr.2022.02.140

Chicco, D., Warrens, M. J., & Jurman, G. (2021). The coefficient of determination R-squared is more informative than SMAPE, MAE, MAPE, MSE and RMSE in regression analysis evaluation. *PeerJ. Computer Science*, *7*, e623. https://doi.org/10.7717/peerj-cs.623

Chrismawan, P. E. E., Winardi, S., & Tambunan, R. (2023). *Robust Stock Price Prediction using Gated Recurrent Unit (GRU)*. *5*(1). https://doi.org/10.35842/ijicom

Dewandra, A. R. F., Wibawa, A. P., Pujianto, U., Utama, A. B. P., & Nafalski, A. (2022). Journal Unique Visitors Forecasting Based on Multivariate

Attributes Using CNN. *International Journal of Artificial Intelligence Research*, *6*(2). https://doi.org/10.29099/ijair.v6i1.274

Dhaked, D. K., Dadhich, S., & Birla, D. (2023). Power Output Forecasting of Solar Photovoltaic Plant Using LSTM. *Green Energy and Intelligent Transportation*, *2*(5), 100113. https://doi.org/10.1016/j.geits.2023.100113

Enterprise, J. (2018). *HTML, PHP, dan MySQL untuk Pemula*. PT. Elex Media Komputindo.

Grinberg, M. (2018). *Flask web development: Developing web applications with Python* (2nd edition). O'Reilly.

Hasanuddin, Asgar, H., & Hartono, B. (2022). Rancang Bangun REST API Aplikasi Weshare sebagai Upaya Mempermudah Pelayanan Donasi Kemanusiaan. *Jurnal Informatika Teknologi dan Sains*, *4*(1), 8–14. https://doi.org/10.51401/jinteks.v4i1.1474

Huang, B., Tong, L., & Zuo, Y. (2022a). Short-term power generation load forecasting based on LSTM neural network. *Journal of Physics: Conference Series*, *2247*(1), 012033. https://doi.org/10.1088/1742-6596/2247/1/012033

Huang, B., Tong, L., & Zuo, Y. (2022b). Short-term power generation load forecasting based on LSTM neural network. *Journal of Physics: Conference Series*, *2247*(1), 012033. https://doi.org/10.1088/1742-6596/2247/1/012033

Islam, M. S., & Hossain, E. (2021). Foreign exchange currency rate prediction using a GRU-LSTM hybrid network. *Soft Computing Letters*, *3*, 100009. https://doi.org/10.1016/j.socl.2020.100009

Karim, Md. E., Foysal, Md., & Das, S. (2023). Stock Price Prediction Using Bi-LSTM and GRU-Based Hybrid Deep Learning Approach. In A. Khanna, D. Gupta, V. Kansal, G. Fortino, & A. E. Hassanien (Eds.), *Proceedings of Third Doctoral Symposium on Computational Intelligence* (pp. 701–711). Springer Nature Singapore.

Karno, A. S. B. (2020). Prediksi Data Time Series Saham Bank BRI Dengan Mesin Belajar LSTM (Long ShortTerm Memory). *Journal of Informatic and Information Security*, *1*(1), 1–8. https://doi.org/10.31599/jiforty.v1i1.133

Li, W., Wu, H., Zhu, N., Jiang, Y., Tan, J., & Guo, Y. (2021). Prediction of dissolved oxygen in a fishery pond based on gated recurrent unit (GRU).

Information Processing in Agriculture, *8*(1), 185–193. https://doi.org/10.1016/j.inpa.2020.02.002

Malek, S., Melgani, F., & Bazi, Y. (2017). One-dimensional convolutional neural networks for spectroscopic signal regression. *Journal of Chemometrics*, *32*. https://doi.org/10.1002/cem.2977

Martelli, A., Holden, S., McGuire, P., & Ravenscroft Martelli, A. (2023). *Python in a Nutshell: A Desktop Quick Reference* (Fourth Edition). O'Reilly Media.

Pandowo, H., Kusumaningrum, D., & Amir, V. (2022). Implementasi Deep Learning Untuk Optimasi Slump Menggunakan Convolutional Neural Network Pada PT. Handaru Wijaya Mulya. *JURNAL INFORMATIKA*, *9*(1).

Peng, F.-L., Qiao, Y.-K., & Yang, C. (2023). A LSTM-RNN based intelligent control approach for temperature and humidity environment of urban utility tunnels. *Heliyon*, *9*(2), e13182. https://doi.org/10.1016/j.heliyon.2023.e13182

Permana, A. Y., & Romadlon, P. (2019). *PERANCANGAN SISTEM INFORMASI PENJUALAN PERUMAHAN MENGUNAKAN METODE SDLC PADA PT. MANDIRI LAND PROSPEROUS BERBASIS MOBILE*. *10*.

Pratiwi, D., Pratama, D. A., & Rochman, A. (2024). Application Programming Interface (API) Development for Student Attendance System Using QR Code. *Qeios*. https://doi.org/10.32388/9OJFXV

Pumsirirat, A., & Yan, L. (2018). Credit Card Fraud Detection using Deep Learning based on Auto-Encoder and Restricted Boltzmann Machine. *International Journal of Advanced Computer Science and Applications*, *9*(1). https://doi.org/10.14569/IJACSA.2018.090103

Raup, A., Ridwan, W., Khoeriyah, Y., Supiana, S., & Zaqiah, Q. Y. (2022). Deep Learning dan Penerapannya dalam Pembelajaran. *JIIP - Jurnal Ilmiah Ilmu Pendidikan*, *5*(9), 3258–3267. https://doi.org/10.54371/jiip.v5i9.805

Riziq sirfatullah Alfarizi, M., Zidan Al-farish, M., Taufiqurrahman, M., Ardiansah, G., & Elgar, M. (2022). Penggunaan Python Sebagai Bahasa Pemrograman untuk Machine Learning dan Deep Learning. *Karimah Tauhid*, *2*(1).

Rizvi, D. R., & Khalid, M. (2024). Performance Analysis of Stocks using Deep Learning Models. *5th International Conference on Innovative Data*

Communication Technologies and Application (ICIDCA 2024), *233*, 753–762. https://doi.org/10.1016/j.procs.2024.03.264

Sabar Sautomo & Hilman Ferdinandus Pardede. (2021). Prediksi Belanja Pemerintah Indonesia Menggunakan Long Short-Term Memory (LSTM). *Jurnal RESTI (Rekayasa Sistem dan Teknologi Informasi)*, *5*(1), 99–106. https://doi.org/10.29207/resti.v5i1.2815

Sadli, M., Fajriana, Fuadi, W., Ermatita, & Pahendra, I. (2020). Electrical peak load forecasting using long short term memory and support vector machine. *IOP Conference Series: Materials Science and Engineering*, *725*(1), 012060. https://doi.org/10.1088/1757-899X/725/1/012060

Sari, Y., Arifin, Y. F., Novitasari, N., & Faisal, M. R. (n.d.). Deep Learning Approach Using the GRU-LSTM Hybrid Model for Air Temperature Prediction on Daily Basis. *International Journal of Intelligent Systems and Applications in Engineering*.

Selle, N., Yudistira, N., & Dewi, C. (2022). Perbandingan Prediksi Penggunaan Listrik dengan Menggunakan Metode Long Short Term Memory (LSTM) dan Recurrent Neural Network (RNN). *Jurnal Teknologi Informasi dan Ilmu Komputer*, *9*(1), 155–162. https://doi.org/10.25126/jtiik.2022915585

Shen, G., Tan, Q., Zhang, H., Zeng, P., & Xu, J. (2018). Deep Learning with Gated Recurrent Unit Networks for Financial Sequence Predictions. *Recent Advancement in Information and Communication Technology:*, *131*, 895–903. https://doi.org/10.1016/j.procs.2018.04.298

Shenfield, A., & Howarth, M. (2020). A Novel Deep Learning Model for the Detection and Identification of Rolling Element-Bearing Faults. *Sensors*, *20*(18), 5112. https://doi.org/10.3390/s20185112

Sontana, I., Rahmatulloh, A., & Rachman, A. N. (2019). Application Programming Interface Google Picker Sebagai Penyimpanan Data Sistem Informasi Arsip Berbasis Cloud. *Jurnal Nasional Teknologi dan Sistem Informasi*, *5*(1), 25–32. https://doi.org/10.25077/TEKNOSI.v5i1.2019.25-32

Stauffer, M. (2019). *Laravel: Up & Running: A Framework for Building Modern PHP Apps* (Second edition). O'Reilly Media.

Sulistyo, M. (2018). *DATABASE*. https://doi.org/10.31219/osf.io/pbfzm

Surya, L., Teja Yarlagadda, R., & Patel, M. (2021). *PHP For Beginners* (First edition). REDSHINE Publication. https://redshine.co.in/product/978-93-90937-52-3/

Talwariya, A., Singh, P., Jobanputra, J. H., & Kolhe, M. L. (2023). Machine learning based renewable energy generation and energy consumption forecasting. *Energy Sources, Part A: Recovery, Utilization, and Environmental Effects*, *45*(2), 3266–3278. https://doi.org/10.1080/15567036.2023.2194257

Wahid, A. A. (2020). *Analisis Metode Waterfall Untuk Pengembangan Sistem Informasi*.

Wakhid, M. A., Raharjo, A. B., & Indralaksono, R. (2022). Peramalan Beban pada Rencana Operasi Harian dengan Menggunakan LSTM Studi Kasus: Sub Sistem Sulawesi Selatan. *JUTI: Jurnal Ilmiah Teknologi Informasi*, *20*(2), 99–108. https://doi.org/10.12962/J24068535.V20I2.A1138

Yani, A., & Saputra, B. (2018). *RANCANG BANGUN SISTEM INFORMASI EVALUASI SISWA DAN KEHADIRAN GURU BERBASIS WEB (Studi Kasus di SMK Nusa Putra Kota Tangerang)*. *11*(2).

Z. Ye, A. Gilman, Q. Peng, K. Levick, P. Cosman, & L. Milstein. (2019). Comparison of Neural Network Architectures for Spectrum Sensing. *2019 IEEE Globecom Workshops (GC Wkshps)*, 1–6. https://doi.org/10.1109/GCWkshps45667.2019.9024482

Zhu, Y. (2020). Stock price prediction using the RNN model. *Journal of Physics: Conference Series*, *1650*, 032103. https://doi.org/10.1088/1742-6596/1650/3/032103

LAMPIRAN

A. Lembar Kontrol Bimbingan

	LEMBAR KONTROL BIMBINGAN TUGAS AKHIR/SKRIPSI	No. PM	7.5.18/L1
		Revisi	2
		Tanggal	1 Juli 2010
		Halaman	1 / 2

Nama : ELZA SAFIRA PERMATASARI Kelas : TI-4A NIM : 4.33.20.0.09	Judul Skripsi : RANCANG BANGUN APLIKASI PREDIKSI BEBAN PUNCAK PENGGUNAAN LISTRIK PADA PEMBANGKIT LISTRIK DENGAN MODEL *DEEP LEARNING* BERBASIS WEB: STUDI KASUS WEB "*CONNECT* UP2DJTY"

No	Tanggal	Uraian	Tandatangan Pembimbing
1	30 April 2024	Revisi Bab I, II, III	
2.	7 Mei 2024	Revisi Bab I, III	
3.	16 Mei 2024	Revisi Bab I, III	
4.	21 Mei 2024	Bab IV	
5.	[illegible]		
6.	4. Juni 2024	Bab IV, bab V	
7.	11 Juni 2024.	Revisi, Bab IV	
8.	25 Juni 2024	Revisi, Bab IV ACC	

Semarang,
Pembimbing II

Wiktasari, S.T., M.Kom.
NIP. 198703272019032012

	LEMBAR KONTROL BIMBINGAN TUGAS AKHIR/SKRIPSI	No. PM	7.5.18/L1
		Revisi	2
		Tanggal	1 Juli 2010
		Halaman	1 / 2

Nama : ELZA SAFIRA PERMATASARI Kelas : TI-4A NIM : 4.33.20.0.09	Judul Skripsi : RANCANG BANGUN APLIKASI PREDIKSI BEBAN PUNCAK PENGGUNAAN LISTRIK PADA PEMBANGKIT LISTRIK DENGAN MODEL *DEEP LEARNING* BERBASIS WEB: STUDI KASUS WEB "*CONNECT* UP2DJTY"

No	Tanggal	Uraian	Tandatangan Pembimbing
1.	27 Februari 2024	Pembahasan jurnal	1.
2.	29 April 2024	Pembahasan jurnal.	2.
3.	29 Mei 2024	Progress skripsi.	3.
4.	10 Juni 2024	Progress skripsi	4.
			5.
			6.
			7.
			8.

Semarang,
Pembimbing I

Prayitno, S.ST., M.T., Ph.D.
NIP 198504102014041002

B. Surat Keterangan Selesai bimbingan Skripsi

	SURAT KETERANGAN SELESAI BIMBINGAN TUGAS AKHIR	No. FPM	7.5.18/L2
		Revisi	2
		Tanggal	1 Juli 2010
		Halaman	1 / 2

JURUSAN TEKNIK ELEKTRO	SURAT KETERANGAN SELESAI BIMBINGAN SKRIPSI

Kepada:
Yth. Ketua Program Studi Teknologi Rekayasa Komputer
Politeknik Negeri Semarang

Yang bertanda tangan di bawah ini, Pembimbing I dan Pembimbing II menerangkan bahwa:

Nama : Elza Safira Permatasari
NIM : 4.33.20.0.09
Kelas : TI-4A

Dengan judul skripsi:

"Rancang Bangun Aplikasi Prediksi Beban Puncak Penggunaan Listrik pada Pembangkit Listrik dengan Model *Deep Learning* Berbasis Web: Studi Kasus Web "CONNECT UP2DJTY" "

Benar-benar telah menyelesaikan pembuatan tugas akhir dan siap untuk melakukan ujian wawancara tugas akhir.

Semarang, 28 Juni 2024

Pembimbing I,

Prayitno, S.ST., M.T., Ph.D.
NIP. 198504102014041002

Pembimbing II,

Wiktasari, S.T., M.Kom.
NIP. 198703272019032012

C. Surat Keterangan Siap Ujian Skripsi

	SURAT KETERANGAN SIAP UJIAN TUGAS AKHIR	No. FPM	7.5.18/L6
		Revisi	2
		Tanggal	1 Juli 2010
		Halaman	1 / 1

SURAT KETERANGAN

SIAP UJIAN SKRIPSI

Kepada:
Yth. Ketua Program Studi Teknologi Rekayasa Komputer
Politeknik Negeri Semarang

Yang bertanda tangan di bawah ini, Pembimbing I dan Pembimbing II menerangkan bahwa:

Nama : Elza Safira Permatasari

NIM : 4.33.20.0.09

Kelas : TI-4A

Dengan judul skripsi:

"Rancang Bangun Aplikasi Prediksi Beban Puncak Penggunaan Listrik pada Pembangkit Listrik dengan Model *Deep Learning* Berbasis Web: Studi Kasus Web "CONNECT UP2DJTY" "

Benar-benar telah menyelesaikan pembuatan tugas akhir dan siap untuk melakukan ujian wawancara tugas akhir.

Semarang, 28 Juni 2024

Pembimbing I,

Prayitno, S.ST., M.T., Ph.D.

NIP. 198504102014041002

Pembimbing II,

Wiktasari, S.T., M.Kom.

NIP. 198703272019032012

D. Surat Tugas

KEMENTERIAN PENDIDIKAN, KEBUDAYAAN,
RISET, DAN TEKNOLOGI
POLITEKNIK NEGERI SEMARANG
Jalan Prof. H. Soedarto, S.H, Tembalang, Semarang 50275, PO BOX 6199/SMS
Telephone (024) 7473417, 7499585, 7499586, Facsimile (024) 7472396
http://www.polines.ac.id, E-mail : sekretariat@polines.ac.id

Jurusan T. Elektro POLINES	SURAT TUGAS NO. 3256A /PL4.1.3/PKL/2024	

Ketua Jurusan Teknik Elektro memberi tugas kepada Tim Penguji Tugas Akhir berikut ini :

NO.	JABATAN	NAMA PENGUJI	NIP
1.	Ketua Penguji	PRAYITNO, S.ST., M.T., Ph.D.	198504102014041002
2.	Sekretaris	MUTTABIK FATHUL LATHIEF, S.KOM., M.ENG.	199209092020121007
3.	Penguji I	MARDIYONO, S.KOM., M.Sc.	197403112000121001
4.	Penguji II	TRI RAHARJO YUDANTORO, S.KOM, M.KOM.	196810252000121001
5.	Penguji III	NURSENO BAYU AJI, S.KOM., M.KOM.	199107302019031010

Untuk menguji mahasiswa tersebut :

NO.	NAMA	NIM	KELAS
1.	ELZA SAFIRA PERMATASARI	4.33.20.0.09	TI-4A

Yang didampingi Pembimbing sebagai berikut :

NO.	JABATAN	NAMA PEMBIMBING	NIP
1.	Pembimbing I	PRAYITNO, S.ST., M.T., Ph.D.	198504102014041002
2.	Pembimbing II	WIKTASARI, S.T., M.KOM.	198703272019032012

Dengan Judul Tugas Akhir :
" RANCANG BANGUN APLIKASI PREDIKSI BEBAN PUNCAK PENGGUNAAN LISTRIK PADA PEMBANGKIT LISTRIK DENGAN MODEL *DEEP LEARNING* BERBASIS WEB : STUDI KASUS WEB 'CONNECT UP2DJTY"".

Yang dilaksanakan pada waktu sebagai berikut :
Hari, tanggal : Jum'at / 5 Juli 2024
Waktu : 09.00 – 10.30 WIB
Tempat : R. Lab. Komputer

Tugas ini supaya dijalankan dengan sebaik-baiknya dan hasilnya dilaporkan kepada Jurusan.

Semarang, 1 Juli 2024
Ketua Jurusan Teknik Elektro,

SEMBERNAN BADRUZZAMAN, S.T.,M.ENG.
NIP. 197502132006041001

Diserahkan ke Tim Penguji Tugas Akhir (lima orang) dan Pembimbing paling lambat tiga hari sebelum ujian, beserta naskah Tugas Akhir untuk Penguji.

E. Lembar Revisi Skripsi

	FORMULIR PROSEDUR	No. FP	F.PPd.4.08-L3
	LEMBAR REVISI SKRIPSI	Revisi	3
		Tanggal	21.12.2017
		Halaman	1 / 3

No	Uraian	Tandatangan Penguji
1	Revisi Jurnal	
2	Revisi gambar laporan skripsi	

Semarang, 11 Juli 2024

Penguji I,

Mardiyono, S.Kom., M.Sc.

NIP. 197403112000121001

	FORMULIR PROSEDUR	No. FP	F.PPd.4.08-L3
	LEMBAR REVISI SKRIPSI	Revisi	3
		Tanggal	21.12.2017
		Halaman	2 / 3

No	Uraian	Tandatangan Penguji
1	Revisi laporan skripsi dan program	

Semarang, 12 Juli 2024

Penguji II,

Tri Raharjo Yudantoro, S.Kom.,M. Kom.

NIP. 196810252000121001

	FORMULIR PROSEDUR	No. FP	F.PPd.4.08-L3
	LEMBAR REVISI SKRIPSI	Revisi	3
		Tanggal	21.12.2017
		Halaman	3 / 3

No	Uraian	Tandatangan Penguji
1	Revisi laporan skripsi dan program	

Semarang, 12 Juli 2024

Penguji III,

Nurseno Bayu Aji, S.Kom., M.Kom.

NIP. 199107302019031010

F. Lembar Pernyataan Telah Melakukan Revisi

	FORMULIR PROSEDUR	No. FP	F.PPd.4.08-L3
	REVISI SKRIPSI	Revisi	3
		Tanggal	21.12.2017
		Halaman	1 / 1

Yang bertanda tangan di bawah ini, Penguji I/II/III menerangkan bahwa:

Nama : Elza Safira Permatasari

Kelas : TI-4A

NIM : 4.33.20.0.09

Dengan judul skripsi:

Rancang Bangun Aplikasi Prediksi Beban Puncak Penggunaan Listrik pada Pembangkit Listrik dengan Model *Deep Learning* Berbasis Web: Studi Kasus Web "*Connect* UP2DJTY"

Benar-benar telah melaksanakan revisi skripsi. Surat keterangan ini dapat dipergunakan sebagaimana mestinya.

Semarang, 11 Juli 2024

Penguji I,	Penguji II,	Penguji III,
Mardiyono, S.Kom., M.Sc.	Tri Raharjo Yudantoro, S.Kom., M. Kom.	Nurseno Bayu Aji, S.Kom., M.Kom.
NIP. 197403112000121001	NIP. 196810252000121001	NIP. 199107302019031010

G. Lembar Responden

ANGKET RESPONDEN SKRIPSI

RANCANG BANGUN APLIKASI PREDIKSI BEBAN PUNCAK PENGGUNAAN LISTRIK PADA PEMBANGKIT LISTRIK DENGAN MODEL *DEEP LEARNING* BERBASIS WEB: STUDI KASUS WEB "*CONNECT* UP2DJTY"

1. Identitas Responden

   Nama : Moch. Yusuf Habibie

   Unit PLN : UP2D Jateng dan DIY

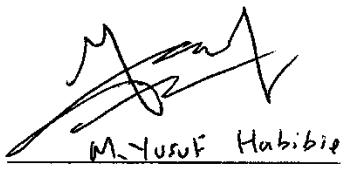
2. Petunjuk Pengisian

   Berilah tanda centang pada kolom kategori jawaban yang paling sesuai dengan kondisi yang anda alami dalam menggunakan fitur prediksi beban puncak. Pada kolom penilaian angka 1 menafsirkan tidak setuju hingga angka 5 menafsirkan sangat setuju.

No	Pertanyaan	Penilaian				
		1	2	3	4	5
1	Saya merasa puas dengan fitur prediksi beban puncak pembangkit listrik.				✓	
2	Saya merasa website ini mudah dipahami.					✓
3	Saya merasa website ini memudahkan pekerjaan saya.					✓
4	Saya merasa fitur website ini sesuai kebutuhan.					✓
5	Saya merasa website ini membantu dalam pengambilan keputusan yang berhubungan dengan nilai prediksi beban puncak.				✓	
6	Saya merasa hasil prediksi yang diberikan sudah sesuai.				✓	
7	User interface sudah baik.				✓	
8	Website ini sudah *responsive*.				✓	

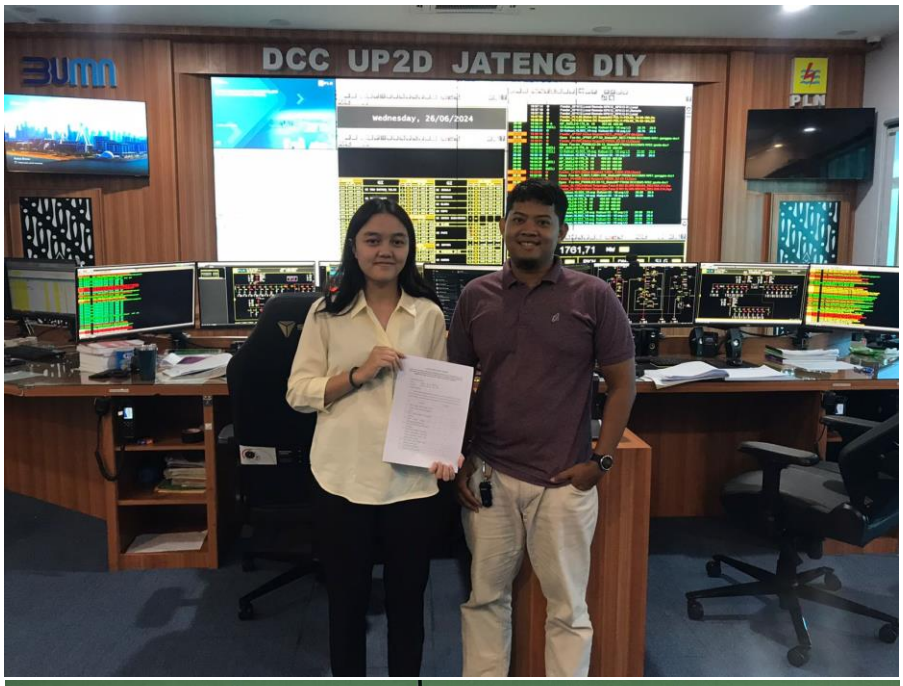
9	Website ini memiliki waktu respon yang baik saat memuat data prediksi.				✓	
10	Fitur prediksi website ini memberikan hasil prediksi sangat cepat.				✓	
11	Saya merasa proses adaptasi terhadap website tidak begitu lama.					✓
12	Performa website sudah baik.					✓
13	Proses login dan autentikasi pada website ini mudah dan aman.				✓	
14	Saya merasa layout dan desain visual website menarik.					✓
15	Website ini akan disarankan untuk digunakan perusahaan.				✓	

Semarang, 26 Jun. 2024



M. Yusuf Habibie

H. Dokumentasi





I. Kode Program *Deep Learning*

```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns
from sklearn.preprocessing import MinMaxScaler
from tensorflow.keras.models import Sequential
from tensorflow.keras.layers import GRU, Dense, Dropout
from tensorflow.keras.callbacks import EarlyStopping,
ModelCheckpoint
from sklearn.metrics import mean_absolute_error,
mean_squared_error
import pandas as pd

df = pd.read_csv(r'Your_path)
df['date'] = pd.to_datetime(df['date'], format='%d-%b-%y')
df.set_index('date', inplace=True)
df = df.asfreq('MS')

scaler = MinMaxScaler()
scaled_data = scaler.fit_transform(df)

sequence_length = 3
num_features = len(df.columns)
sequences = []
labels = []

for i in range(len(scaled_data) - sequence_length):
    seq = scaled_data[i:i+sequence_length]
    label = scaled_data[i+sequence_length, 0]
    sequences.append(seq)
    labels.append(label)

sequences = np.array(sequences)
labels = np.array(labels)

train_size = int(0.7 * len(sequences))
train_x, test_x = sequences[:train_size],
sequences[train_size:]
train_y, test_y = labels[:train_size], labels[train_size:]

model = Sequential()
model.add(GRU(units=64, input_shape=(train_x.shape[1],
train_x.shape[2]), return_sequences=False))
model.add(Dense(units=1))
model.compile(optimizer='adam', loss='mean_squared_error')

early_stopping = EarlyStopping(monitor='val_loss', patience=5,
restore_best_weights=True)
model_checkpoint = ModelCheckpoint('GRUPKL.h5',
monitor='val_loss', save_best_only=True)

history = model.fit(
    train_x, train_y,
    epochs=300,
    batch_size=70,
    validation_split=0.4,
```

```
    callbacks=[early_stopping, model_checkpoint]
)
predictions = best_model.predict(test_x)

mae = mean_absolute_error(test_y, predictions)
mse = mean_squared_error(test_y, predictions)
rmse = np.sqrt(mse)

true_beban = scaler.inverse_transform(test_y.reshape(-1, 1))[:,
0]
predicted_beban = scaler.inverse_transform(predictions)[:, 0]
test_dates = df.index[train_size+sequence_length:]

plt.figure(figsize=(10, 6))
plt.plot(test_dates, true_beban, label='True beban',
color='blue')
plt.plot(test_dates, predicted_beban, label='Predicted beban',
color='red')
plt.title('True vs Predicted beban')
plt.xlabel('Date')
plt.ylabel('beban')
plt.legend()
plt.grid(True)
plt.show()
```

J. Kode Program *Flask*

```
from flask import Flask, jsonify
import pandas as pd
import numpy as np
from sklearn.preprocessing import MinMaxScaler
import tensorflow as tf
import pymysql

app = Flask(__name__)

# Load the model
best_model = tf.keras.models.load_model('fix_GRU_7030.h5')

def get_data_from_database():
    connection = pymysql.connect(host='YOUR_HOST',
                                 user='YOUR_USER',
                                 password='YOUR_PASS',
                                 database='YOUR_DB',
                                 cursorclass=pymysql.curso
                                  rs.DictCursor)
    try:
        with connection.cursor() as cursor:

            sql = "SELECT tanggal, nama_pembangkit,
                  REPLACE(beban_puncak, ',', '.') AS
                  beban_puncak FROM laporanbebanpuncak"
            cursor.execute(sql)
            result = cursor.fetchall()
```

```
            df = pd.DataFrame(result)
            df['tanggal'] = pd.to_datetime(df['tanggal'])
            df['beban_puncak'] =
                                df['beban_puncak'].astype(
                                float)
            df.set_index('tanggal', inplace=True)
    finally:
        connection.close()
    return df

def generate_predictions(df, pembangkit_name):
    df_pembangkit = df[df['nama_pembangkit'] ==
pembangkit_name].drop(columns='nama_pembangkit')
    scaler = MinMaxScaler()
    scaled_data = scaler.fit_transform(df_pembangkit)
    sequence_length = 3
    sequences = np.array([scaled_data[i:i +
sequence_length] for i in range(len(scaled_data) -
sequence_length + 1)])
    predictions = []
    last_date = df_pembangkit.index.max()
    if len(sequences) > 0:
        current_sequence = sequences[-1]
        for i in range(4):
            current_sequence_reshaped =
current_sequence.reshape(1, sequence_length,
scaled_data.shape[1])
            next_value =
                        best_model.predict(current_sequenc
                        e_reshaped)
            predictions.append(next_value)
            current_sequence =
                                np.vstack([current_sequence
                                [1:], next_value])
        predicted_values =
                            scaler.inverse_transform(np.con
                            catenate(predictions).reshape(-
                            1, df_pembangkit.shape[1]))
        dates = [last_date + pd.DateOffset(months=i+1) for
                 i in range(4)]
        formatted_dates = [date.strftime("%B %Y") for date
                           in dates]
        return list(zip(formatted_dates,
predicted_values.tolist()))
    else:
        return []

@app.route('/predictions', methods=['GET'])
def predictions():
    new_df = get_data_from_database()
    pembangkit_names = new_df['nama_pembangkit'].unique()
    all_predictions = {}
    for pembangkit in pembangkit_names:
```

```
        pred_values = generate_predictions(new_df,
pembangkit)
        all_predictions[pembangkit] = pred_values
    return jsonify(all_predictions)

if __name__ == '__main__':
    app.run(debug=True)
```

K. Kode Program Larvel *Controller*

```
public function AdminDashboard()
  {
    $response = Http::get('http://127.0.0.1:5000/predictions');
    if ($response->successful()) {
      $predictions = $response->json();
      foreach ($predictions as $namaPembangkit => $prediksi) {
        foreach ($prediksi as $key => $value) {
          $prediksi[$key][1][0] = round($value[1][0], 2);
        }
        $predictions[$namaPembangkit] = $prediksi;
      }
    } else {
      $predictions = [];
    }

    return view('admin.admin_dashboard', compact(
      'predictions'
    ));
  }
```

L. Kode Program Larvel *View*

```
<!-- Prediksi Beban Puncak -->
          <div class="col-12">
            <div class="card">
              <div class="filter">
                <a class="icon" href="#" data-bs-
toggle="dropdown"><i class="bi bi-three-
dots"></i></a>
                <ul class="dropdown-menu dropdown-
menu-end dropdown-menu-arrow">
                  <li class="dropdown-header text-
start">
                    <h6>Filter</h6>
                  </li>
                  <li><a class="dropdown-item"
href="#">Today</a></li>
```

```
                    <li><a class="dropdown-item"
href="#">This Month</a></li>
                    <li><a class="dropdown-item"
href="#">This Year</a></li>
                  </ul>
                </div>
                <div class="card-body">
                  <h5 class="card-title">Prediksi Beban
Puncak <span>/This month</span></h5>
                  <!-- Line Chart -->
                  <div id="prediksiChart"></div>
                  <script>
                    document.addEventListener("DOMConte
ntLoaded", () => {
                      let predictions = {!!
json_encode($predictions) !!};

                      let seriesData = [];
                      let categories = [];
                      for (let namaPembangkit in
predictions) {
                        let prediksi =
predictions[namaPembangkit];
                        let data = prediksi.map(item =>
({
                          x: new Date(item[0]),
                          y: item[1][0]
                        }));
                        seriesData.push({
                          name: namaPembangkit,
                          data: data
                        });
                        categories = prediksi.map(item
=> item[0]);
                      }

                      new
ApexCharts(document.querySelector("#prediksiChart"),
{
                        series: seriesData,
                        chart: {
                          height: 350,
                          type: 'area',
                          toolbar: {
                            show: true
                          },
                        },
                        markers: {
                          size: 4
```

```
                        },
                        fill: {
                          type: "gradient",
                          gradient: {
                            shadeIntensity: 1,
                            opacityFrom: 0.3,
                            opacityTo: 0.4,
                            stops: [0, 90, 100]
                          }
                        },
                        dataLabels: {
                          enabled: false
                        },
                        stroke: {
                          curve: 'smooth',
                          width: 2
                        },
                        xaxis: {
                          type: 'datetime',
                          categories: categories
                        },
                        tooltip: {
                          x: {
                            format: 'MM/yy',
                            formatter: function(value)
{
                              return new
Date(value).toLocaleDateString('en-US', { month:
'short', year: 'numeric' });
                            }
                          }
                        }
                      }).render();
                    });
                  </script>
                  <!-- End Line Chart -->
                </div>
              </div>
            </div><!-- End Prediksi Beban Puncak -->
```

BIOGRAPHIES OF AUTHORS

	**Elza Safira Permatasari** is a final semester student of D4 Computer Science study program of Politeknik Negeri Semarang. During her lectures, she has gained a deep understanding of programming, networking, and in her final semester, she focused on web and artificial intelligence. Based on her interest in this field, she decided to take the final project on the topic of deep learning, specifically design and development of a web-based peak load prediction application for electricity usage at power plants using deep learning models: a case study of the "connect UP2DJTY" website. She can be contacted via email: elza.safira@polines.ac.id
	**Prayitno, S.ST., M.T., Ph.D.** received the B.Sc. degree in computer science from the Politeknik Elektronika Negeri Surabaya, the M.Sc. degree in electrical engineering from the Institute of Technology Bandung, and the Ph.D. degree in computer science and information engineering from the Asia University, Taiwan. He is currently an assistant professor with the department of electrical engineering Politeknik Negeri Semarang (Polines). His research interests include deep learning, data mining, and artificial intelligence for education. He can be contacted at email: prayitno@polines.ac.id
	**Wiktasari, S.T., M.Kom.** received the B.E. degree Universitas Islam Sultan Agung, the M.Sc. degree in Diponegoro University. she is currently an expert assistant with the department of electrical engineering Politeknik Negeri Semarang (Polines). Her interest is web development. she can be contacted at email: wiktasari@polines.ac.id