ANALISIS SENTIMEN PADA *BIG DATA* KASUS STUNTING DI INDONESIA (TAHUN 2019-2024)

Disusun oleh:

Choiruzzia Abdilla Audivatsani

NIM 4.33.20.0.05

PROGRAM STUDI S.TR TEKNOLOGI REKAYASA KOMPUTER

JURUSAN TEKNIK ELEKTRO

POLITEKNIK NEGERI SEMARANG

2024

ANALISIS SENTIMEN PADA *BIG DATA* KASUS STUNTING DI INDONESIA (TAHUN 2019-2024)

Skripsi ini disusun untuk melengkapi sebagian persyaratan menjadi Sarjana Terapan

Disusun oleh:

Choiruzzia Abdilla Audivatsani

NIM 4.33.20.0.05

PROGRAM STUDI S.Tr TEKNOLOGI REKAYASA KOMPUTER

JURUSAN TEKNIK ELEKTRO

POLITEKNIK NEGERI SEMARANG

2024

PERNYATAAN KEASLIAN SKRIPSI

Saya menyatakan dengan sesungguhnya bahwa skripsi dengan judul "***Analisis Sentimen pada Big Data Kasus Stunting di Indonesia (Tahun 2019-2024)***" yang dibuat untuk melengkapi sebagian persyaratan menjadi Sarjana Terapan pada Program Studi Teknologi Rekayasa Komputer Jurusan Teknik Elektro Politeknik Negeri Semarang sejauh yang saya ketahui bukan merupakan tiruan atau duplikasi dari skripsi yang sudah dipublikasikan dan atau pernah dipakai untuk mendapatkan gelar Sarjana Terapan di lingkungan Politeknik Negeri Semarang maupun di perguruan tinggi atau instansi manapun, kecuali bagian yang sumber informasinya dicantumkan sebagaimana mestinya.

Semarang, 10 Juli 2024

Pelaksana,

Choiruzzia Abdilla Audivatsani

NIM 4.33.20.0.05

HALAMAN PERSETUJUAN

Skripsi dengan judul ***"Analisis Sentimen pada Big Data Kasus Stunting di Indonesia (Tahun 2019-2024)"*** dibuat untuk melengkapi sebagian persyaratan menjadi Sarjana Terapan pada Program Studi Teknologi Rekayasa Komputer Jurusan Teknik Elektro Politeknik Negeri Semarang dan disetujui untuk diajukan dalam sidang ujian skripsi.

Semarang, 12 Juli 2024

Pembimbing I,	Pembimbing II,
Dr. Ir. Kurnianingsih, S.T., M.T.	Wiktasari, S.T., M.Kom.
NIP 197904262003122002	NIP 198703272019032012

Mengetahui,
Ketua Program Studi S.Tr Teknologi Rekayasa Komputer

Kuwat Santoso, S.Kom., M.Kom.
NIP 198407192019031008

HALAMAN PENGESAHAN

Skripsi dengan judul ***"Analisis Sentimen pada Big Data Kasus Stunting di Indonesia (Tahun 2019-2024)"*** Telah dipertahankan dalam ujian wawancara dan diterima sebagai syarat untuk menjadi Sarjana Terapan pada Program Studi Teknologi Rekayasa Komputer Jurusan Teknik Elektro Politeknik Negeri Semarang pada tanggal 1 Juli 2024.

Tim Penguji

Penguji I,	Penguji II,	Penguji III,
Idhawati Hestiningsih, S. Kom., M. Kom.	Afandi Nur Aziz Thohari, S.T., M.Cs.	Nurseno Bayu Aji, S.Kom., M.Kom.
NIP. 197711192008012013	NIP. 199004112019031014	NIP 199107302019031010

Ketua,

Dr. Ir. Kurnianingsih, S.T., M.T.
NIP 197904262003122002

Sekretaris,

Eri Eli Lavindi, M. Kom.
NIP 199601142022032014

Mengesahkan,
Ketua Jurusan Teknik Elektro

Yusnan Badruzzaman, S.T., M.Eng.
NIP. 197503132006041001

ABSTRAK

Choiruzzia Abdilla Audivatsani, "Analisis Sentimen pada Big Data Kasus Stunting di Indonesia (Tahun 2019-2024)", Skripsi DIV Jurusan Teknik Elektro Politeknik Negeri Semarang, di bawah bimbingan Dr. Ir. Kurnianingsih, S.T., M.T. dan Wiktasari, S.T, M.Kom., Juli 2024.

Stunting merupakan masalah gizi kronis yang menjadi perhatian serius di Indonesia. Analisis sentimen terhadap opini dan pernyataan publik mengenai stunting dapat memberikan wawasan berharga bagi pengambil keputusan dan pihak terkait. Penelitian ini bertujuan untuk membandingkan performa empat model *Machine Learning* (SVM, Bi-LSTM, IndoBERT, dan IndoRoBERTa) dalam mengklasifikasikan sentimen teks terkait stunting di Indonesia. Data dikumpulkan dari media sosial (Twitter dan YouTube) serta berita daring (Detik.com dan CNN Indonesia) selama periode 2019-2024. Setelah pra-pemrosesan dan pelabelan sentimen, data dibagi menjadi dua dataset: media sosial dan berita daring. Hasil penelitian menunjukkan bahwa IndoRoBERTa mencapai akurasi tertinggi sebesar 87.4% dan rata-rata F1-Score sebesar 83% pada dataset media sosial, sedangkan IndoBERT unggul pada dataset berita daring dengan akurasi 89.5% dan rata-rata F1-Score sebesar 78%. Perbedaan performa ini disebabkan oleh karakteristik data yang berbeda antara kedua sumber. Analisis sentimen mengungkapkan bahwa sentimen negatif mendominasi di media sosial, sementara sentimen netral lebih banyak ditemukan di berita daring. Penelitian ini memberikan kontribusi dalam pengembangan model klasifikasi sentimen untuk teks bahasa Indonesia, khususnya dalam konteks isu stunting.

Kata Kunci: Analisis sentimen, Stunting, *Machine Learning*, Media Sosial, Berita Daring

ABSTRACT

Choiruzzia Abdilla Audivatsani, "Sentiment Analysis on Big Data of Stunting Cases in Indonesia (2019-2024)", DIV Thesis, Department of Electrical Engineering, Politeknik Negeri Semarang, under the guidance of Dr. Ir. Kurnianingsih, S.T., M.T. and Wiktasari, S.T, M.Kom. June 2024.

Stunting is a chronic nutritional problem that is of serious concern in Indonesia. Sentiment analysis of public opinions and statements regarding stunting can provide valuable insights for decision makers and related parties. This study aims to compare the performance of four Machine Learning models (SVM, Bi-LSTM, IndoBERT, and IndoRoBERTa) in classifying text sentiment related to stunting in Indonesia. Data was collected from social media (Twitter and YouTube) and online news (Detik.com and CNN Indonesia) during the 2019-2024 period. After pre-processing and sentiment labeling, the data was divided into two datasets: social media and online news. The results showed that IndoRoBERTa achieved the highest accuracy of 87.4% and average of F1-Score of 83% on social media datasets, while IndoBERT excelled on online news datasets with 89.5% accuracy and average of F1-Score of 78%. This difference in performance is due to different data characteristics between the two sources. Sentiment analysis revealed that negative sentiments dominated on social media, while neutral sentiments were found more in online news. This research contributes to the development of sentiment classification models for Indonesian text, especially in the context of the stunting issue.

Keywords: Sentiment analysis, Stunting, Machine Learning, Social Media, Online News

KATA PENGANTAR

Puji dan syukur penulis panjatkan kehadirat Allah SWT, atas limpahan rahmat dan karunia-Nya sehingga penulis dapat menyelesaikan skripsi dengan judul "Analisis Sentimen pada *Big Data* Kasus Stunting di Indonesia (Tahun 2019-2024)" yang disusun untuk memenuhi salah satu syarat menyelesaikan pendidikan Program Studi Sarjana Terapan Teknologi Rekayasa Komputer Jurusan Teknik Elektro Politeknik Negeri Semarang.

Dalam penyusunan skripsi, penulis banyak mendapatkan bantuan dan dukungan dari berbagai pihak sehingga segala prosesnya berjalan dengan lancar. Oleh karena itu penulis ingin mengucapkan terimakasih kepada:

1. Allah SWT, atas rahmat dan karunia-Nya, serta limpahan nikmat yang diberikan.
2. Kedua orang tua dan keluarga tercinta yang selalu memberikan doa, motivasi, dan segala bentuk dukungan.
3. Ibu Dr. Eni Dwi Wardihani, S.T., M.T. selaku Direktur Politeknik Negeri Semarang.
4. Bapak Yusnan Badruzzaman, S.T., M.Eng. selaku Ketua Jurusan Teknik Elektro.
5. Bapak Kuwat Santoso, S.T., M.Kom. selaku Ketua Program Studi Sarjana Terapan Teknologi Rekayasa Komputer.
6. Ibu Dr. Ir. Kurnianingsih, S.T., M.T., dan Ibu Wiktasari, S.T., M.Kom., selaku Dosen Pembimbing yang selalu memberikan arahan dan masukan kepada penulis dalam proses penelitian dan penyusunan laporan skripsi.
7. Teman-teman Kelas TI-4A yang telah mendukung dan membantu penulis.
8. Seluruh pihak yang terlibat baik secara langsung maupun tidak langsung yang tidak bisa penulis sebutkan satu per satu dalam membantu penulis menyelesaikan laporan ini.

Penulis menyadari bahwa penyusunan skripsi ini masih banyak kekurangan. Oleh karena itu, penulis mengharapkan kritik dan saran dari semua pihak yang ingin memberikan masukan demi perkembangan positif bagi penulis. Demikian laporan

skripsi yang penulis susun, semoga dapat bermanfaat bagi semua pihak dan penulis sendiri. Akhir kata penulis ucapkan terimakasih.

Semarang, 10 Juli 2024

Choiruzzia Abdilla Audivatsani

DAFTAR ISI

PERNYATAAN KEASLIAN SKRIPSI i
HALAMAN PERSETUJUAN ii
HALAMAN PENGESAHAN iii
ABSTRAK iv
ABSTRACT v
KATA PENGANTAR vi
DAFTAR ISI viii
DAFTAR GAMBAR xi
DAFTAR TABEL xiii
DAFTAR LAMPIRAN xiv
BAB I PENDAHULUAN 1
1.1. Latar Belakang 1
1.1.1. Perumusan Masalah 3
1.1.2. Tujuan 3
1.1.3. Manfaat 3
1.2. Batasan Masalah 4
1.3. Sistematika Penulisan 4
BAB II TINJAUAN PUSTAKA 6
2.1. Dasar Teori 6
2.1.1. Stunting 6
2.1.2. *Big Data* 7
2.1.3. Analisis Sentimen 8
2.1.4. *Natural Language Processing* (NLP) 9
2.1.5. *Machine Learning* 9

2.1.6. SVM 10
2.1.7. Bidirectional Long Short-Term Memory (Bi-LSTM) 11
2.1.8. Transformer 12
2.1.9. HuggingFace 14
2.1.10. IndoBERT 15
2.1.11. IndoRoBERTa 16
2.2. Kajian Pustaka 16
BAB III KEGIATAN PELAKSANAAN 24
3.1. Metode Pelaksanaan 24
3.1.1. Business Understanding 24
3.1.2. Data Understanding 27
3.1.3. Data Preparation 28
3.1.4. Modeling 31
3.1.5. Evaluation 35
3.1.6. Deployment 37
3.2. Analisis Kebutuhan 38
3.2.1. Kebutuhan Perangkat Keras (*Hardware*) 38
3.2.2. Kebutuhan Perangkat Lunak (*Software*) 38
3.3. Perancangan Sistem 39
3.3.1. Flow Chart 39
BAB IV ANALISIS DAN PEMBAHASAN 41
4.1. Analisis Data 41
4.2. Analisis Pemodelan dan Evaluasi 45
4.2.1. Dataset Berita *Online* 46
4.2.2. Dataset Media Sosial 53
4.3. Analisis Deployment 60

BAB V KESIMPULAN 62
5.1. Kesimpulan 62
5.2. Saran 62
DAFTAR PUSTAKA 64
LAMPIRAN 70

DAFTAR GAMBAR

Gambar 2.1 Karakteristik *Big Data* [14] 7
Gambar 2.2 Arsitektur LSTM [43] 11
Gambar 2.3 Arsitektur Bi-LSTM [44] 12
Gambar 2.4 Arsitektur Transformer [34] 13
Gambar 3.1 Tahapan Crisp-DM [45] 24
Gambar 3.2 Contoh Data Terkumpul 28
Gambar 3.3 Tahapan Persiapan Data 29
Gambar 3.4 Arsitektur Model Bi-LSTM 32
Gambar 3.5 Confusion Matrix [46] 36
Gambar 3.6 Arsitektur Deployment 37
Gambar 3.7 Flowchart Sistem 39
Gambar 4.1 Data Sebelum dan Sesudah Preprocessing 42
Gambar 4.2 Frekuensi Kemunculan Kata “Stunting” 43
Gambar 4.3 Wordcloud Data 44
Gambar 4.4 Grafik *Loss* Pada Fold 4 Model IndoRoBERTa 47
Gambar 4.5 Grafik *Loss* pada Fold 4 Model IndoBERT 48
Gambar 4.6 Grafik *Loss* pada Fold 5 Model Bi-LSTM 50
Gambar 4.7 Confusion Matrix Pengujian Model IndoBERT pada Data Berita 52
Gambar 4.8 Grafik *Loss* Fold 1 Model IndoRoBERTa 54
Gambar 4.9 Grafik *Loss* pada Fold 2 Model IndoBERT 55
Gambar 4.10 Grafik *Loss* Fold 5 Model Bi-LSTM 57
Gambar 4.11 Confusion Matrix pada Pengujian Model IndoRoBERTa 59
Gambar 4.12 Fitur Analisis Sentimen Media Sosial pada Streamlit 60

Gambar 4.13 Fitur Analisis Sentimen Teks Berita pada Streamlit 61

DAFTAR TABEL

Tabel 2.1 Perbandingan Fitur 20
Tabel 3.1 Jumlah Data Setiap Sumber 27
Tabel 4.1 Sumber Data dan Tautan 41
Tabel 4.2 Jumlah Data Setelah Preprocessing 42
Tabel 4.3 Jumlah Data pada Setiap Kelas Sentimen 45
Tabel 4.4 Metrik Evaluasi Model IndoRoBERTa Dataset Berita *Online* 46
Tabel 4.5 Metrik Evaluasi Model IndoBERT pada Dataset Berita *Online* 48
Tabel 4.6 Metrik Evaluasi Model Bi-LSTM Dataset Berita *Online* 49
Tabel 4.7 Metrik Evaluasi SVM 51
Tabel 4.8 Perbandingan Metrik Evaluasi Model Dataset Berita Daring 51
Tabel 4.9 Metrik Evaluasi Model IndoRoBERTa Dataset Media Sosial 53
Tabel 4.10 Metrik Evaluasi Model IndoBERT 55
Tabel 4.11 Tabel Metrik Evaluasi Bi-LSTM 56
Tabel 4.12 Tabel Metrik Evaluasi SVM 58
Tabel 4.13 Perbandingan Metrik Evaluasi Model Media Sosial 58

DAFTAR LAMPIRAN

Lampiran 1 Lembar Kontrol Bimbingan 70
Lampiran 2 Lembar selesai bimbingan 72
Lampiran 3 Lembar Siap Ujian Skripsi 73
Lampiran 4 Surat Tugas 74
Lampiran 5 Lembar Revisi Skripsi 75
Lampiran 6 Pernyataan Telah Melakukan Revisi 78
Lampiran 7 Kode Program *Scraping* 79
Lampiran 8 Kode Program *Preprocessing* 81
Lampiran 9 Kode Program Pelatihan Model 82
Lampiran 10 Kode Program *Deployment* 84

BAB I
PENDAHULUAN

1.1. Latar Belakang

Stunting merupakan salah satu masalah kesehatan global yang menjadi perhatian serius di banyak negara, termasuk Indonesia. Stunting adalah suatu kondisi yang mempengaruhi anak-anak dan ditandai dengan gangguan pertumbuhan dan perkembangan, yang menyebabkan tinggi badan mereka jauh lebih rendah daripada anak sehat seusianya [1]. Kondisi ini dapat disebabkan oleh kekurangan gizi, infeksi berulang, akses terbatas terhadap nutrisi, akses pelayanan kesehatan seperti akses air bersih dan sanitasi yang rendah, serta kondisi ekonomi yang sulit [2].

Di Indonesia, prevalensi stunting mengalami penurunan dari 24,4% pada tahun 2021 menjadi 21,6% pada tahun 2022. Meskipun demikian, angka ini masih tergolong tinggi dan berada di atas target yang ditetapkan oleh *World Health Organization (WHO)* yaitu 20%. Upaya ini termasuk program perbaikan gizi seperti pemberian makanan tambahan pada ibu hamil dan bayi, serta kampanye edukasi tentang stunting untuk memperdalam pengetahuan ibu hamil [3]. Meskipun demikian, faktor-faktor spesifik seperti kemiskinan ekstrem, terbatasnya akses fasilitas kesehatan, serta kualitas air dan sanitasi yang buruk tetap menjadi tantangan yang perlu dipahami secara mendalam dalam menangani stunting.

Analisis sentimen merupakan sebuah metode untuk mengukur pandangan dan tanggapan terkait suatu permasalahan. Proses analisis sentimen menentukan bagaimana tanggapan masyarakat terhadap suatu permasalahan seperti stunting cenderung dengan membagi sentimen menjadi dua kelas atau lebih [4]. Analisis sentimen pada skripsi ini memungkinkan eksplorasi berbagai sudut pandang dari masyarakat, mencakup respons terhadap kebijakan pemerintah, liputan berita tentang masalah stunting, pernyataan serta opini dari berbagai pemangku kepentingan. Dengan menganalisis data dari sosial media dan berita *online*, dapat diidentifikasi sejauh mana kesadaran dan pemahaman masyarakat tentang stunting, serta faktor-faktor sosial dan budaya yang mempengaruhi implementasi kebijakan dan program kesehatan [5]. Hal ini membantu dalam merancang strategi

komunikasi yang lebih efektif dan responsif, serta dalam mengevaluasi efektivitas kebijakan yang telah diterapkan.

Pada penelitian sebelumnya tentang analisis sentimen pada kasus kesehatan secara umum dan stunting di Indonesia menghasilkan akurasi sebesar 68%-77% dengan menggunakan metode Lexicon-Based Sentiment Analysis [6]. Penelitian lain tentang analisis sentimen pada kasus stunting, menggunakan beberapa algoritma *Machine Learning* tradisional seperti Logistic Regression, Naive Bayes, Random Forest, dan SVM didapatkan algoritma SVM sebagai algoritma terbaik dengan akurasi sebesar 98% [1]. Pada penelitian lainnya, analisis sentimen juga telah diterapkan pada bidang lain yang bertujuan untuk memahami pandangan publik terhadap profesi Pegawai Negeri Sipil (PNS) melalui analisis sentimen pada data tweet dari Twitter. Penelitian tersebut nenggunakan model RoBERTa Base Sentiment Classifier Indonesia dan berhasil mencapai akurasi rata-rata 90% [39]. Namun, dengan perkembangan era *Big Data*, jumlah data yang tersedia dari berbagai sumber seperti media sosial dan portal berita *online* telah meningkat secara signifikan. Oleh karena itu, diperlukan analisis sentimen terhadap stunting dengan data yang lebih besar dan terbaru untuk memahami persepsi masyarakat secara lebih akurat dan komprehensif. Selain itu, perkembangan dalam *Natural Language Processing* (NLP) telah menghasilkan algoritma yang lebih canggih seperti SVM, Bi-LSTM, dan model berbasis Transformer seperti IndoBERT dan IndoRoBERTa, yang telah menunjukkan kinerja superior dalam analisis teks dibandingkan dengan metode tradisional.

Skripsi ini akan melakukan perbandingan algoritma-algoritma tersebut dalam melakukan analisis sentimen terhadap data teks kasus stunting di Indonesia pada periode 2019-2024 yang didapatkan dari platform media sosial dan berita *online*. Perbandingan performa antar algoritma dalam pembuatan skripsi ini bertujuan untuk mendapatkan model terbaik dalam mengklasifikasikan sentimen dalam konteks kasus stunting di Indonesia. Pemahaman mendalam terhadap sentimen masyarakat diharapkan dapat memberikan wawasan mengenai persepsi publik terhadap stunting dalam lima tahun terakhir yang dapat mendukung pengembangan strategi pencegahan dan penanggulangan stunting di Indonesia yang lebih efektif.

1.1.1. Perumusan Masalah

Berdasarkan latar belakang yang telah diberikan, rumusan masalah pada pembuatan skripsi ini adalah sebagai berikut:

1. Bagaimana *Natural Language Processing* (NLP) dapat digunakan untuk menganalisis sentimen yang terkandung dalam teks?
2. Bagaimana perbandingan performa algoritma IndoBERT, IndoRoBERTa, SVM, dan Bi-LSTM dalam melakukan analisis sentimen pada konteks kasus stunting di Indonesia?
3. Algoritma *Machine Learning* apa yang paling optimal untuk digunakan dalam analisis sentimen pada kasus stunting di Indonesia?

1.1.2. Tujuan

Tujuan dari pembuatan skripsi adalah sebagai berikut:

1. Menganalisis dan menjelaskan penerapan *Natural Language Processing* (NLP) dalam menganalisis sentimen yang terkandung dalam teks.
2. Membandingkan performa algoritma IndoBERT, IndoRoBERTa, SVM, dan Bi-LSTM dalam melakukan analisis sentimen pada konteks kasus stunting di Indonesia.
3. Menentukan algoritma *Machine Learning* yang memiliki performa paling optimal dalam menganalisis sentimen pada kasus stunting di Indonesia.

1.1.3. Manfaat

Manfaat dari pembuatan skripsi adalah sebagai berikut:

1. Secara Teoritis

   Hasil penelitian ini secara teoritis diharapkan dapat memberikan sumbangan pemikiran tentang algoritma *Machine Learning*, termasuk BERT, RoBERTa, SVM, dan Bi-LSTM, dalam menganalisis sentimen terhadap kasus stunting di Indonesia dalam lima tahun terakhir yang berfokus pada evaluasi dan perbandingan kinerja berbagai pendekatan dalam konteks yang spesifik ini.

2. Secara Praktis

   Harapan praktis dari hasil penelitian ini adalah mampu mempermudah pihak terkait dalam mengembangkan sistem analisis sentimen terhadap isu stunting dengan memanfaatkan teknologi algoritma *Machine Learning* seperti BERT,

RoBERTa, SVM, dan Bi-LSTM. Algoritma-algoritma tersebut diharapkan dapat mengklasifikasikan dan menganalisis sentimen dengan efektif terkait permasalahan stunting, berkontribusi pada perancangan kebijakan pencegahan dan penanggulangan stunting yang lebih akurat dan responsif.

3. Secara Akademis

   Hasil penelitian ini dapat dijadikan sebagai acuan untuk penelitian sejenis terhadap analisis sentimen pada kasus lain dengan menggunakan algoritma *Machine Learning* dan untuk pengayaan pengetahuan bidang deep learning.

1.2. Batasan Masalah

Dalam pembuatan skripsi ini, masalah yang akan dibahas terbatas pada beberapa faktor, antara lain:

1. Pengembangan model akan menggunakan dataset teks yang berasal dari hasil *scraping* beberapa media sosial seperti Twitter dan komentar video Youtube, serta portal berita *online* seperti CNN Indonesia dan Detik.
2. Dataset hanya terbatas pada konteks kasus stunting di Indonesia dalam lima tahun terakhir (tahun 2019-2024).
3. Sentimen yang diklasifikasikan hanya positif, negatif, dan netral.
4. Fokus utama penelitian ini adalah penggunaan algoritma IndoBERT, IndoRoBERTa, SVM, dan Bi-LSTM dalam melakukan analisis sentimen kasus stunting di Indonesia.

1.3. Sistematika Penulisan

Dalam penulisan skripsi ini menggunakan sistematika penulisan sebagai berikut:

BAB I PENDAHULUAN

Bab ini menjelaskan latar belakang yang berisi perumusan masalah, tujuan, dan manfaat pembuatan skripsi, batasan masalah penelitian dan sistematika penulisan laporan skripsi.

BAB II TINJAUAN PUSTAKA

Bab ini menjelaskan tentang dasar-dasar teori yang diperlukan untuk memecahkan masalah dan penelitian-penelitian terkait dalam pembuatan skripsi ini.

BAB III KEGIATAN PELAKSANAAN

Bab ini menjelaskan tahapan pelaksanaan penelitian menggunakan metode CRISP-DM, meliputi pemahaman bisnis, pemahaman data, pengumpulan data, persiapan data, pemodelan dengan algoritma IndoBERT, IndoRoBERTa, SVM, dan Bi-LSTM, evaluasi, serta implementasi model.

BAB IV ANALISIS DAN PEMBAHASAN

Bab ini berisi hasil dari analisis perbandingan performa algoritma berdasarkan matrik evaluasi, membahas temuan utama serta implikasinya dalam konteks kasus stunting di Indonesia.

BAB V KESIMPULAN

Bab ini berisi kesimpulan pembuatan skripsi yang didapatkan dari hasil analisis dan pembahasan.

BAB II
TINJAUAN PUSTAKA

2.1. Dasar Teori

Pada bagian ini membahas mengenai teknologi dan konsep dasar yang digunakan dalam pembuatan Analisis Sentimen pada *Big Data* Kasus Stunting di Indonesia, antara lain:

2.1.1. Stunting

Stunting merupakan suatu kondisi gagal tumbuh kembang yang terjadi pada anak-anak, ditandai dengan gangguan pertumbuhan dan perkembangan sehingga berat badan dan tinggi badan anak lebih pendek dibandingkan anak seusianya [1]. Kondisi ini dapat disebabkan oleh kekurangan gizi, infeksi berulang, akses terbatas terhadap nutrisi, akses pelayanan kesehatan seperti akses air bersih dan sanitasi yang rendah, serta kondisi ekonomi yang sulit [2]. Faktor lainnya yang dapat menyebabkan stunting pada anak adalah faktor pemahaman ibu tentang pencegahan anak stunting seperti pemberian ASI eksklusif dan makanan pendamping ASI [7].

Stunting memberikan dampak yang signifikan pada anak karena tidak hanya mengganggu pertumbuhan fisik, tetapi juga menghambat perkembangan otak. Dampak jangka panjang dari stunting termasuk penurunan kemampuan kognitif, postur tubuh yang pendek saat dewasa, kekebalan tubuh yang lebih rendah, serta risiko tinggi mengidap penyakit kronis seperti jantung dan stroke di kemudian hari [8].

Untuk mencegah stunting, upaya harus dimulai sejak 1000 hari pertama kehidupan bayi, yang merupakan periode kritis dalam perkembangan anak [9]. Beberapa langkah pencegahan yang dapat dilakukan meliputi:

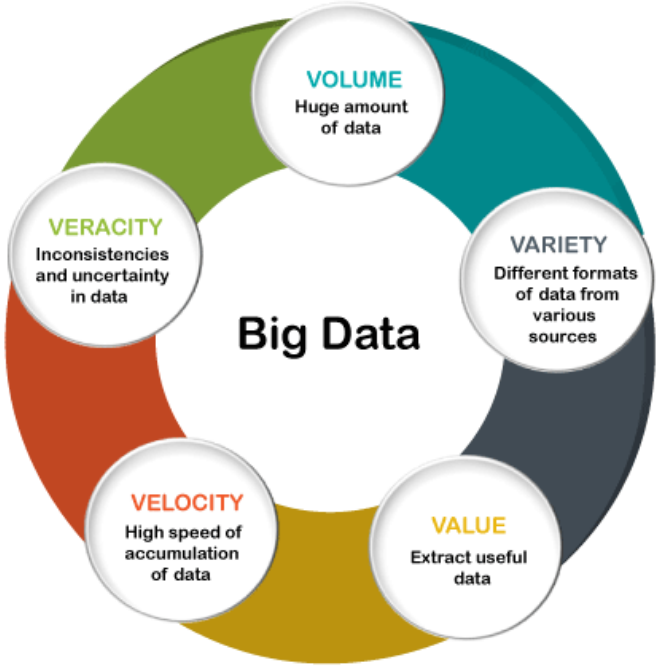
1. **Memenuhi Kebutuhan Gizi Ibu Hamil**: Pemenuhan gizi makro dan mikro yang cukup dan seimbang selama kehamilan sangat penting untuk memastikan pertumbuhan optimal janin [10].
2. **Pemberian ASI Eksklusif dan Makanan Pendamping ASI**: Menyusui secara eksklusif hingga usia 6 bulan dan pemberian makanan pendamping ASI membantu memastikan bayi mendapatkan nutrisi yang diperlukan untuk

pertumbuhan dan perkembangan yang sehat untuk mengurangi risiko stunting [11].

3. **Edukasi Calon Ibu**: Memberikan informasi dan edukasi kepada calon ibu mengenai pentingnya gizi, perawatan kesehatan, dan pencegahan stunting, sehingga calon ibu dapat mengambil langkah-langkah yang tepat untuk mencegah kondisi ini [12].
4. **Pemantauan Kesehatan dan Perkembangan Balita**: Rutin memeriksakan kesehatan dan perkembangan balita untuk memastikan balita tumbuh dan berkembang sesuai dengan tahapan usianya [13].

2.1.2. *Big Data*

Perkembangan teknologi yang semakin pesat menghasilkan lonjakan volume data yang luar biasa, baik dalam segi kecepatan, keragaman, maupun kualitas. Hal ini memberikan istilah baru yaitu *Big Data*. *Big Data* adalah sebuah kumpulan data yang sangat kompleks dan besar sehingga sulit untuk dikelola dengan menggunakan alat pengolahan data tradisional.



Gambar 2.1 Karakteristik *Big Data* [14]

Big Data tidak hanya berarti data yang memiliki volume yang sangat besar. Namun, terdapat beberapa karakteristik lain untuk dapat dikategorikan sebagai *Big Data*

seperti yang ditunjukkan pada Gambar 2.1. Berikut adalah penjelasan karakteristik *Big Data*:

1. ***Volume*:** Menunjukkan volume data yang sangat besar dan memungkinkan data terdiri hingga ratusan Terabytes.
2. ***Variety*:** Menunjukkan keragaman jenis data, baik dalam struktur, format, maupun sumber data yang dimiliki.
3. ***Veracity*:** Mengacu pada kualitas dan keandalan data yang didapatkan untuk menghasilkan wawasan yang bermanfaat.
4. ***Value*:** Menunjukkan nilai dalam *Big Data* yang dapat diperoleh melalui analisis untuk menghasilkan informasi yang berharga [15].
5. ***Velocity*:** Mengacu pada kecepatan pengumpulan data yang dihasilkan dan memungkinkan untuk segera diproses bahkan secara *real-time* [16].

Alat pengolahan data tradisional yang tidak dapat mengolah data dalam skala besar menjadi sebuah tantangan yang muncul setelah kehadiran *Big Data*. Tantangan ini mendorong kemunculan teknologi-teknologi baru yang memungkinkan untuk pengolahan dan analisis data dalam skala yang besar [17]. Beberapa platform *open-source* seperti Hadoop, Apache Spark, NoSQL Databases memungkinkan untuk menangani data dengan skalabilitas dan kecepatan analisis yang memiliki efisiensi tinggi [18]. Selain itu, *Data Mining* dan *Machine Learning* juga memiliki algoritma dan teknik untuk menggali pola dan wawasan dari data dengan skala besar dan kompleks [19].

2.1.3. Analisis Sentimen

Analisis sentimen merupakan sebuah metode untuk mengukur pandangan dan tanggapan terkait suatu permasalahan. Proses analisis sentimen menentukan bagaimana tanggapan masyarakat terhadap suatu permasalahan cenderung dengan membagi sentimen menjadi dua kelas atau lebih [4].

Dalam analisis sentimen biasanya diterapkan dua pendekatan, yaitu pendekatan berbasis leksikon dan pendekatan berbasis *Machine Learning*. Pendekatan berbasis leksikon menggunakan kamus sentimen berisi kata-kata dan/atau frasa yang memiliki nilai sentimen (positif, negatif, netral) [6]. Sedangkan pendekatan berbasis *Machine Learning* menggunakan algoritma *Machine Learning* untuk melatih model menggunakan dataset yang sudah memiliki label sentimen [20].

Analisis sentimen memiliki peran penting dalam berbagai bidang. Dalam bidang bisnis, analisis sentimen digunakan untuk memahami opini pelanggan terhadap produk atau layanan tertentu. Selain itu, dalam bidang politik analisis sentimen dapat membantu mengukur opini publik terhadap kebijakan atau kandidat tertentu.

2.1.4. *Natural Language Processing* (NLP)

Natural Language Processing (NLP) adalah cabang dari kecerdasan buatan yang berfokus pada interaksi antara komputer dan bahasa manusia. NLP mencakup berbagai teknik untuk analisis, pemahaman, dan generasi bahasa alami [21].

Teknik-teknik utama yang digunakan dalam NLP:

1. *Tokenization*: Teknik untuk memecah paragraf, frasa, kalimat, atau data teks lainnya menjadi bagian terkecil yang disebut token [22].
2. *Part-of-Speech Tagging*: Menentukan jenis kata (kata benda, kata kerja, dll.) dalam sebuah teks. Proses ini mengkategorikan kata berdasarkan definisi dan konteksnya dalam sebuah kalimat [23].
3. *Dependency Parsing*: Analisis struktur gramatikal kalimat untuk memahami hubungan antara kata-kata dalam satu kalimat.
4. *Named Entity Recognition* (NER): Identifikasi entitas penting seperti nama orang, tempat, dan organisasi dalam teks [24].

Teknik-teknik di atas memungkinkan NLP diterapkan dalam berbagai bidang untuk mengatasi tantangan dalam pemrosesan bahasa manusia. Penerapan NLP meliputi analisis sentimen, penerjemahan mesin, pengenalan suara, dan pengembangan *chatbot* serta asisten virtual. NLP banyak digunakan dalam berbagai bidang, termasuk bisnis untuk analisis opini konsumen, medis untuk ekstraksi informasi dari catatan kesehatan, dan hukum untuk analisis dokumen hukum.

2.1.5. *Machine Learning*

Machine Learning merupakan cabang dari *Artificial Intelligence* (AI). *Machine Learning* memungkinkan mesin untuk mempelajari dan memperbaiki kinerja mesin tanpa memberikan pemrograman secara eksplisit. Algoritma *Machine Learning* yang dibangun akan menganalisis dan mengidentifikasi pola yang ada dalam dataset melalui proses *training*. Model ini kemudian dapat digunakan untuk membuat prediksi atau keputusan tentang data baru yang belum pernah dilihat sebelumnya sebagai pengujian [25].

Machine Learning terdiri dari tiga tipe utama berdasarkan cara model belajar dari data yang diberikan. Berikut adalah tipe-tipe *Machine Learning*:

1. *Supervised Learning*: Algoritma dilatih dengan data yang sudah memiliki label untuk prediksi atau klasifikasi [26]. Contoh algoritma *Machine Learning Supervised Learning* yaitu Regresi Linear, Regresi Logistik, k-Nearest Neighbors, Support Vector Machines (SVMs), Random Forest, Decision Tree, dan Naive Bayes [27].
2. *Unsupervised Learning*: Algoritma dilatih dengan data tidak berlabel untuk menemukan pola atau struktur dalam data. Contoh algoritma *Machine Learning Unsupervised Learning* yaitu k-means, Apriori, DBSCAN [25].
3. *Reinforcement Learning*: Algoritma belajar melalui *trial and error* untuk mengambil tindakan yang memaksimalkan keuntungan atau *reward* [25].

Penerapan *Machine Learning* dalam kehidupan nyata sangat luas dan beragam. Dalam bidang kesehatan, *Machine Learning* digunakan untuk menganalisis gambar medis dan membantu dalam mendiagnosis penyakit seperti kanker. Contoh lainnya, penerapan *Machine Learning* pada platform media sosial digunakan untuk merekomendasikan konten yang relevan bagi pengguna dan menyaring spam. *Machine Learning* juga terdapat dalam asisten virtual seperti Siri dan Alexa yang memanfaatkan teknologi *Natural Language Processing* (NLP) untuk dapat memahami perintah suara dan melakukan tugas-tugas seperti mengatur alarm atau memutar musik.

2.1.6. SVM

Support Vector Machine (SVM) merupakan salah satu *algoritma Supervised Learning* dalam *Machine Learning*. Secara umum, SVM dapat digunakan untuk klasifikasi dan regresi dengan linear maupun non-linear [28]. Linear SVM digunakan ketika *hyperplane* linear dapat memisahkan data dengan sempurna [29]. Sedangkan non-linear SVM digunakan ketika data tidak dapat dipisahkan secara linear oleh *hyperplane* [30].

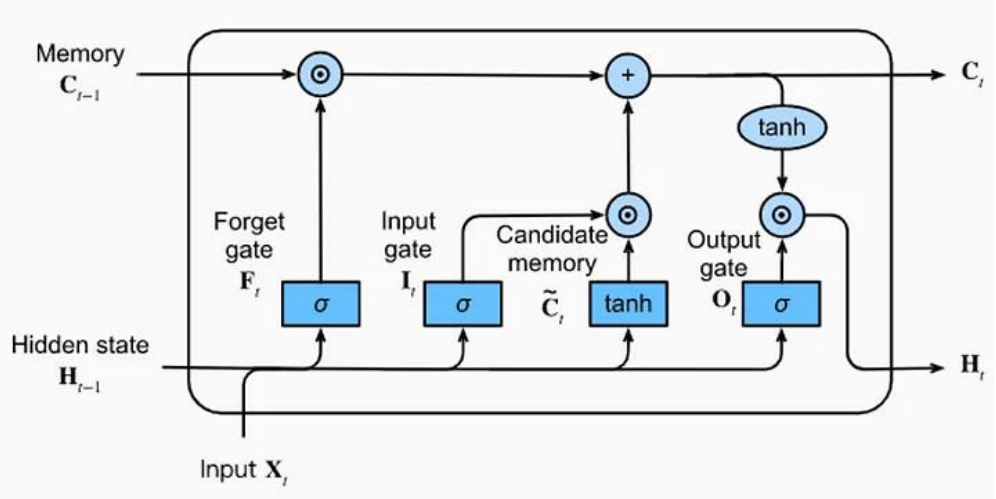
SVM bekerja dengan menemukan *hyperplane* optimal sebagai pemisah data dalam ruang fitur dan memaksimalkan margin antara kelas yang berbeda [31]. Margin dalam SVM berarti jarak antara *hyperplane* dengan data atau *pattern* terdekat dari setiap kelas. *Pattern* terdekat dengan *hyperplane* disebut dengan Support Vectors

[32]. Support Vectors ini memainkan peran penting dalam menentukan posisi *hyperplane* optimal. *Hyperplane* dengan margin yang lebih besar cenderung memiliki kemampuan generalisasi yang lebih baik pada data baru.

2.1.7. Bidirectional Long Short-Term Memory (Bi-LSTM)

Bi-LSTM (Bidirectional Long Short-Term Memory) adalah pengembangan dari LSTM yang merupakan variasi dari Recurrent Neural Network (RNN). Sama dengan LSTM, algoritma Bi-LSTM memiliki *cell state* pada arsitekturnya yang memungkinkan model untuk menyimpan informasi jangka panjang dengan lebih efektif. Bi-LSTM mampu mempelajari dan mengingat informasi jangka panjang sehingga algoritma ini cocok untuk digunakan pada dataset *time-series* maupun tugas-tugas yang melibatkan pemrosesan bahasa alami.

Perbedaan utama antara LSTM dan Bi-LSTM terletak pada cara memproses informasi. LSTM memproses urutan *input* secara satu arah (dari awal hingga akhir), sedangkan Bi-LSTM memprosesnya dari dua arah sekaligus, yaitu dari awal hingga akhir dan dari akhir hingga awal. Dengan memproses informasi dari kedua arah, Bi-LSTM dapat menangkap konteks yang lebih luas dan memahami hubungan antara kata-kata dalam kalimat dengan lebih baik.

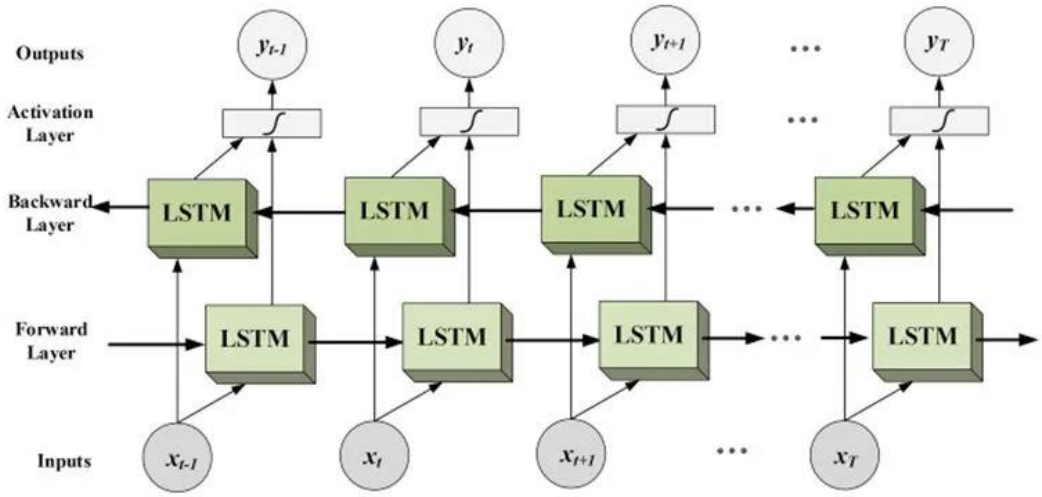


Gambar 2.2 Arsitektur LSTM [43]

Arsitektur LSTM ditunjukkan pada Gambar 2.2 dengan penjelasan sebagai berikut:

1. *Forget Gate*: Berfungsi untuk memilih informasi yang akan dihapus dari memori.

2. *Input Gate*: Berfungsi untuk memilih informasi baru yang akan disimpan ke dalam memori.
3. *Memory*: Menyimpan informasi jangka panjang di sepanjang urutan waktu.
4. *Hidden State*: Merupakan output dari iterasi sel LSTM sebelumnya. Digunakan sebagai *input* pada sel LSTM langkah berikutnya bersama dengan *input* baru.
5. *Candidate Memory*: Memilih kandidat informasi baru yang akan ditambahkan ke dalam memori.
6. *Output Gate*: Berfungsi untuk memilih informasi yang harus dikeluarkan sebagai *Hidden State* pada sel LSTM selanjutnya [33].

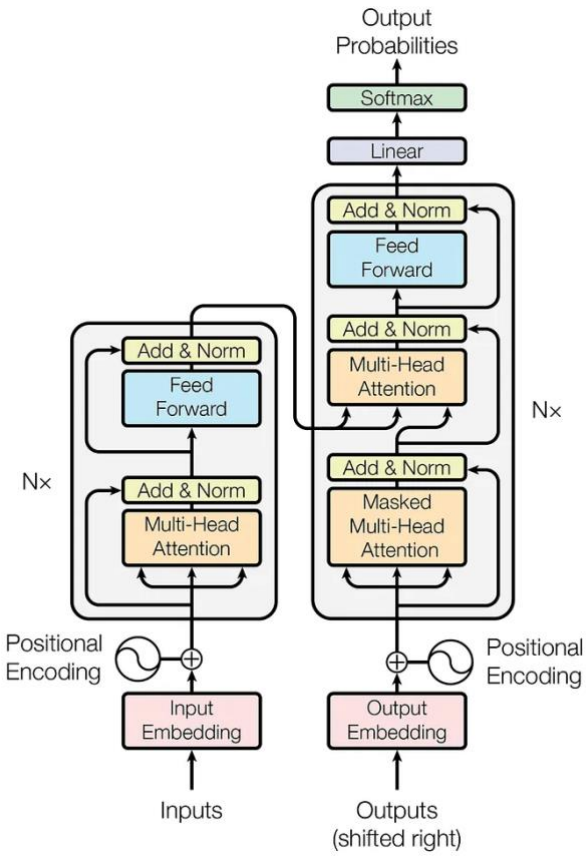


Gambar 2.3 Arsitektur Bi-LSTM [44]

Pada Gambar 2.3 menunjukkan arsitektur Bi-LSTM yang terdiri dari model LSTM. Pada Bi-LSTM, lapisan LSTM di bawah bergerak maju (*forward*) untuk mempelajari dari kata awal menuju kata terakhir, sedangkan lapisan di atasnya bergerak mundur (*backward*) untuk mempelajari dari kata terakhir menuju kata awal.

2.1.8. Transformer

Transformer adalah sebuah arsitektur jaringan saraf yang diperkenalkan oleh Vaswani et al. dalam paper yang berjudul "Attention is All You Need" pada tahun 2017. Arsitektur ini telah merevolusi bidang NLP (*Natural Language Processing*) dan berbagai aplikasi lainnya dalam pembelajaran mesin.



Gambar 2.4 Arsitektur Transformer [34]

Gambar 2.4 menunjukkan arsitektur Transformer yang terdiri dari dua bagian utama: *Encoder* dan *Decoder*. Bagian kiri adalah *encoder*, sedangkan bagian kanan adalah *decoder*. Masing-masing terdiri dari beberapa lapisan yang identik namun terpisah. Berikut adalah penjelasan *encoder* dan *decoder* pada arsitektur Transformer:

1. *Encoder*

   Encoder terdiri dari enam lapisan identik. Setiap lapisan *encoder* memiliki dua sub-lapisan:

   a. *Multi-Head Self-Attention Mechanism*: Sub-lapisan ini memungkinkan model untuk fokus pada berbagai bagian dari input secara bersamaan. Dengan menggunakan beberapa "*heads*", model dapat menggabungkan informasi dari posisi yang berbeda secara paralel.

b. *Feed-Forward Neural Network:* Setelah mekanisme *self-attention*, data diproses melalui jaringan saraf maju (*feed-forward*) yang terdiri dari dua lapisan linear dengan aktivasi non-linear di antaranya [34].

Setiap sub-lapisan di dalam encoder memiliki mekanisme *residual connection* diikuti oleh operasi normalisasi lapisan (*normalization layer*). *Residual connection* membantu mengatasi masalah *vanishing gradient* dan mempercepat pelatihan model yang dalam [35].

2. *Decoder*

Decoder terdiri dari enam lapisan yang identik. Setiap lapisan *decoder* memiliki tiga sub-lapisan:

a. *Masked Multi-Head Self-Attention Mechanism*: Sub-lapisan ini mirip dengan *multi-head self-attention* pada *encoder*, namun dengan *masking* untuk memastikan bahwa posisi masa depan tidak diperhatikan dalam prediksi saat ini.
b. *Multi-Head Attention Mechanism*: Sub-lapisan ini memungkinkan *decoder* untuk memperhatikan *output* dari *encoder*. Ini membantu dalam integrasi informasi kontekstual dari *input* sekuens.
c. *Feed-Forward Neural Network*: Sama seperti pada *encoder*, data yang diproses melalui jaringan syaraf maju di sub-lapisan ini [34].

Setiap sub-lapisan di dalam *decoder* juga memiliki mekanisme *residual connection* dan operasi normalisasi lapisan.

2.1.9. HuggingFace

Hugging Face adalah sebuah perusahaan dan komunitas yang berfokus pada pengembangan dan demokratisasi teknologi kecerdasan buatan (*Artificial Intelligence*/AI), khususnya dalam bidang *Natural Language Processing* (NLP). Hugging Face menyediakan platform dan library yang memudahkan peneliti, *developer*, dan praktisi AI untuk membangun, melatih, dan menggunakan model-model AI yang canggih. Platform ini merupakan repositori pusat yang berisi ribuan model AI yang telah dilatih sebelumnya (*pre-trained models*), dataset, dan demo aplikasi yang dapat digunakan oleh komunitas. Pengguna dapat dengan mudah mencari, mengunduh, dan menggunakan model-model ini untuk berbagai keperluan, tanpa harus melatih model dari awal.

Dalam pembuatan skripsi ini, Hugging Face digunakan untuk mengunduh *dan fine-tune* model-model IndoBERT dan IndoRoBERTa untuk tugas klasifikasi sentimen teks terkait stunting di Indonesia. Model-model ini dipilih karena telah dilatih sebelumnya pada data teks bahasa Indonesia, sehingga diharapkan dapat memberikan performa yang baik dalam memahami konteks dan nuansa bahasa Indonesia.

2.1.10. IndoBERT

BERT (*Bidirectional Encoder Representations from Transformers*) adalah model bahasa yang dikembangkan oleh Google. BERT menggunakan arsitektur Transformer, yang memungkinkan model untuk memahami konteks kata dalam sebuah kalimat dengan lebih baik dibandingkan model bahasa tradisional. BERT dilatih pada dataset teks besar dengan dua tugas utama:

1. *Masked Language Modeling* (MLM): Beberapa kata dalam kalimat ditutupi secara acak, dan model dilatih untuk memprediksi kata-kata yang ditutupi tersebut.
2. *Next Sentence Prediction* (NSP): Model diberikan dua kalimat dan dilatih untuk memprediksi apakah kalimat kedua merupakan kalimat selanjutnya yang logis dari kalimat pertama.

IndoBERT adalah varian dari model BERT yang dirancang khusus untuk Bahasa Indonesia. Dikembangkan untuk menangani kebutuhan pengolahan bahasa alami (NLP) di Indonesia, IndoBERT menggunakan arsitektur Transformer yang sama seperti BERT, tetapi dilatih pada korpus teks berbahasa Indonesia. Ini memungkinkan IndoBERT untuk memahami dan memproses teks dalam bahasa Indonesia dengan lebih akurat.

IndoBERT bekerja dengan prinsip model BERT, yaitu menggunakan *encoder* yang terdiri dari lapisan-lapisan *self-attention*. Model ini dilatih dengan dua tugas utama: *Masked Language Modeling* (MLM) dan *Next Sentence Prediction* (NSP). Dalam MLM, beberapa kata dalam kalimat diacak dan model dilatih untuk memprediksi kata-kata yang hilang. Dalam NSP, model dilatih untuk memprediksi apakah dua kalimat berurutan secara logis. Dengan pelatihan pada korpus teks bahasa Indonesia, IndoBERT dapat menangkap nuansa dan konteks bahasa Indonesia dengan lebih baik .

2.1.11. IndoRoBERTa

RoBERTa (*Robustly Optimized BERT Pretraining Approach*) adalah model NLP yang dikembangkan oleh Facebook AI yang memperbaiki dan mengoptimalkan teknik pelatihan BERT. RoBERTa menggunakan arsitektur yang sama dengan BERT tetapi dilatih dengan beberapa penyesuaian yang signifikan, termasuk penggunaan data yang lebih besar dan lebih bervariasi, serta perubahan dalam strategi pelatihan seperti menggunakan data dan *batch size* yang lebih besar, menghilangkan *Next Sentence Prediction* (NSP), dan durasi *training* yang lebih lama.

IndoRoBERTa merupakan varian dari model RoBERTa yang dikembangkan dengan menggunakan data berbahasa Indonesia yang lebih besar dan bervariasi. Model IndoRoBERTa dirancang untuk memahami bahasa Indonesia dengan lebih baik, sehingga memberikan performa yang lebih unggul dalam berbagai tugas NLP yang menggunakan bahasa Indonesia. Dalam IndoRoBERTa dilakukan beberapa penyesuaian dengan penjelasan berikut.

1. Pre*training*: IndoRoBERTa menggunakan teknik *pretraining* yang sama dengan RoBERTa, yaitu *Masked Language Modeling* (MLM), tetapi dilatih dengan dataset berbahasa Indonesia yang lebih besar.
2. Data Latihan yang Spesifik: Model ini dilatih dengan data dari berbagai sumber bahasa Indonesia, termasuk teks dari berita, media sosial, dan literatur lainnya.
3. Optimalisasi Arsitektur: Arsitektur Transformer digunakan dengan beberapa penyesuaian yang memungkinkan model untuk lebih efektif menangani struktur dan tata bahasa Indonesia.

2.2. Kajian Pustaka

1. Penelitian berjudul “Analisis Sentimen Publik pada Program Kesehatan Masyarakat menggunakan Twitter Opinion Mining” [6] menggunakan data teks dari Twitter untuk menganalisis sentimen publik terkait dengan program-program kesehatan masyarakat di Indonesia. Data yang digunakan berasal dari 6000 pesan tweet yang dikumpulkan dari media sosial Twitter. Pesan-pesan tersebut kemudian diproses menggunakan metode analisis sentimen berbasis leksikon untuk mengolah data teks dari Twitter terkait enam program kebijakan

pemerintah, yaitu imunisasi, asuransi kesehatan, stunting, gizi buruk, pelayanan kesehatan, dan jaminan kesehatan masyarakat. Hasil analisis sentimen menunjukkan bahwa model yang dikembangkan dapat membaca sentimen publik di Twitter sejak awal bulan Agustus 2018 dengan akurasi berkisar antara 68%-77%.

2. Penelitian berjudul "Optimization of Sentiment Analysis of Program Sembako (BPNT) Based on Twitter" [36] menggunakan dataset *tweet* berbahasa Indonesia yang diambil dari Twitter dengan kata kunci "BPNT" dan "Kartu Sembako". Dataset tersebut terdiri dari 1.094 *tweet* yang kemudian dilakukan proses text mining untuk mengklasifikasikan sentimen publik terhadap Program Sembako/BPNT menggunakan metode SVM, Naïve Bayes, dan k-NN. Hasil performa menunjukkan bahwa metode SVM dengan optimasi menggunakan *Particle Swarm Optimization* (PSO) menghasilkan akurasi sebesar 78,02%, presisi sebesar 78,73%, *recall* sebesar 82,16%, dan AUC sebesar 0,848.
3. Penelitian berjudul "Twitter Dataset On Public Sentiments Towards Biodiversity Policy In Indonesia" [37] dilakukan menggunakan dataset Twitter terkait biodiversitas, yang mencakup isu-isu kesehatan, keamanan pangan, dan manajemen lingkungan. Dataset ini terdiri dari 13.435 *tweet* yang telah diberi label sentimen positif, negatif, dan netral. Dalam pengembangan model analisis sentimen, digunakan dua skenario pada penelitian ini. Pada skenario pertama, penelitian ini memanfaatkan model pre-trained IndoBERT Tweet dengan dua lapisan terhubung penuh yang menggunakan sentence embeddings dari model tersebut. Dalam penelitian ini juga mencoba beberapa konfigurasi fungsi aktivasi untuk lapisan terhubung pertama. Hasilnya, konfigurasi dengan fungsi aktivasi GELU menunjukkan akurasi tertinggi sebesar 82.63% dan F1-score tertinggi sebesar 0.7959. Pada skenario kedua penelitian ini digunakan metode Term Frequency – Inverse Document Frequency (TF-IDF) untuk ekstraksi fitur dari dataset yang diberi label, yang kemudian digunakan dalam berbagai algoritma pembelajaran mesin tradisional seperti Logistic Regression, Support Vector Classifier (SVC), Light Gradient Boosting Machine (LGBM), Random Forest, Extreme Gradient Boosting (XGB), AdaBoost, dan Decision Tree. Dari

hasil evaluasi, Logistic Regression dan SVC menunjukkan akurasi tertinggi sebesar 72.115% dan 71.967% serta F1-score tertinggi sebesar 0.70619 dan 0.70230, secara berturut-turut.

4. Penelitian berjudul "Benchmarking Of Multi-Class Algorithms For Classifying Documents Related To Stunting" [1] menggunakan dataset yang terdiri dari dokumen-dokumen terkait stunting yang dikumpulkan dari berbagai sumber, seperti situs web berita, situs web pemerintah, situs web kesehatan, dan juga data dari Twitter. Dataset tersebut kemudian dibagi menjadi tiga kelas, yaitu informasi tentang stunting, diskusi masyarakat tentang stunting, dan data yang tidak terkait dengan stunting. Selanjutnya, penelitian ini menggunakan empat algoritma pembelajaran mesin yang berbeda, yaitu regresi logistik, naive Bayes, random forest, dan support vector machine (SVM), serta tiga jenis fitur teks yang berbeda, yaitu term occurrence (TO), term presence (TP), dan term frequency-inverse document frequency (TF-IDF). Hasil performa dari masing-masing algoritma dan fitur dievaluasi untuk menentukan algoritma dan fitur terbaik untuk klasifikasi multi-kelas pada domain teks. Dalam penelitian ini SVM sebagai algoritma terbaik dengan akurasi sebesar 98%.
5. Penelitian berjudul "Analisis Sentimen Terhadap Aplikasi Pluang Menggunakan Algoritma Naive Bayes dan Support Vector Machine (SVM)" [38] bertujuan untuk melakukan analisis sentimen terhadap ulasan pengguna terhadap aplikasi Pluang menggunakan algoritma Naive Bayes dan Support Vector Machine (SVM). Data yang digunakan dalam penelitian ini adalah dataset berisi ulasan pengguna yang telah dilabeli dengan sentimen positif dan negatif. Jumlah data yang digunakan adalah 2000 ulasan aplikasi. Hasil penelitian menunjukkan bahwa model SVM memberikan akurasi sebesar 99,50%, presisi sebesar 99,67%, recall sebesar 99,33%, dan skor F1 sebesar 99,50%. Sedangkan model Naive Bayes memiliki akurasi sebesar 99,25%, presisi sebesar 99,44%, recall sebesar 99,06%, dan skor F1 sebesar 99,25%. Dari hasil evaluasi, dapat disimpulkan bahwa model SVM memiliki kinerja yang lebih baik dalam memprediksi sentimen pengguna terhadap aplikasi Pluang dibandingkan dengan model Naive Bayes.

6. Penelitian berjudul “Analisis Sentimen pandangan public terhadap profesi PNS (Pegawai Negeri Sipil) dari Twitter menerapkan Indonesian Roberta Base Sentiment Classifier” [39] bertujuan untuk mendapatkan pandangan masyarakat terkait profesi Pegawai Negeri Sipil (PNS) yang tersebar di media sosial Twitter. Model RoBERTa Base Sentiment Classifier Indonesia digunakan untuk melabeli sentimen opini masyarakat di Twitter. Dataset yang digunakan adalah data tweet yang diambil dari Twitter menggunakan metode scraping dengan kata kunci "Aparatur Sipil Negara" dan "Pegawai Negeri Sipil", dengan total 395 tweet. Algoritma yang digunakan dalam penelitian ini adalah RoBERTa Base Sentiment Classifier Indonesia, yang merupakan metode Robustly Optimized BERT Pre*training* Approach. Algoritma ini digunakan untuk melakukan analisis sentimen terhadap data tweet yang telah di-label ke dalam 3 kategori: positif, negatif, dan netral. Hasil uji coba pelabelan menunjukkan bahwa prediksi yang dilakukan memiliki akurasi yang baik, dengan rata-rata keseluruhan akurasi sebesar 90% dan nilai F1 Score sebesar 91%.
7. Penelitian berjudul “Analisis Sentimen Pengguna Twitter terhadap Vaksinasi COVID-19 di Indonesia menggunakan Algoritma Random Forest dan BERT” [40] bertujuan untuk melakukan analisis sentimen pengguna Twitter terhadap vaksinasi Covid-19 di Indonesia menggunakan Algoritma Random Forest dan BERT. Dataset yang digunakan dalam penelitian ini adalah data tweet yang diambil menggunakan Package snscrape dalam bahasa pemrograman Python. Data tweet tersebut berjumlah 47,140 tweet dengan kata kunci "vaksin corona" yang diambil dalam rentang tanggal 1 September 2020 hingga 30 Juni 2021. Setelah proses pembersihan data dari tweet duplikat, tersisa 18,805 tweet untuk analisis. Algoritma yang digunakan dalam penelitian ini adalah Algoritma Random Forest dan BERT (Bidirectional Encoder Representation from Transformer). Random Forest digunakan untuk klasifikasi data tweet dalam analisis sentimen, sedangkan BERT digunakan untuk pemrosesan bahasa alami yang lebih kompleks. Hasil penelitian menunjukkan bahwa Algoritma Random Forest memiliki akurasi sebesar 81%. Sedangkan Algoritma BERT memiliki akurasi sebesar 82% dan F1 Score sebesar 79%.

8. Penelitian berjudul "Model Bidirectional LSTM untuk Pemrosesan Sekuensial Data Teks Spam" [41] bertujuan untuk menguji efektivitas model Bi-LSTM dalam memproses data teks spam. Penelitian ini menggunakan dua dataset, yaitu dataset SMS spam dan dataset email spam, dengan total 5170 data yang terdiri dari 3672 data ham (non-spam) dan 1499 data spam. Algoritma yang digunakan dalam penelitian ini adalah model Bi-LSTM (Bidirectional Long Short-Term Memory). Hasil pengujian menunjukkan bahwa model Bi-LSTM memiliki performa yang lebih baik daripada model LSTM konvensional. Model Bi-LSTM mencapai akurasi sebesar 95.75% pada dataset email spam, sedangkan model LSTM hanya mencapai akurasi 92.81%.

Berdasarkan uraian di atas, dapat diketahui perbandingan fitur pada penelitian terdahulu dengan penelitian pada skripsi ini sebagai berikut.

Tabel 2.1 Perbandingan Fitur

No	Judul	Fitur			
		Jumlah Dataset	Tujuan	Algoritma	Akurasi dan F1-Score
1.	Analisis Sentimen Publik pada Program Kesehatan Masyarakat menggunakan Twitter Opinion Mining	6000	Analisis sentimen program kesehatan masyarakat	*Lexicon-Based Algorithm*	Akurasi: 68% - 77%
2.	Optimization Of Sentiment Analysis Of Program Sembako (BPNT) Based On Twitter	1094	Analisis sentimen program sembako (BNPT)	SVM, Naïve Bayes, k-NN	Akurasi: 78.02%

3.	Twitter Dataset On Public Sentiments Towards Biodiversity Policy In Indonesia	13435	Analisis sentimen kebijakan biodiversitas di Indonesia	IndoBERT, Logistic Regression, SVM, LGBM Classifier, Random Forest, XGB, AdaBoost, Decision Tree	Akurasi: 72.11% F1-Score: 70.61%
4.	Benchmarking Of Multi-Class Algorithms For Classifying Documents Related To Stunting	900	Klasifikasi multi-kelas dokumen terkait stunting	Logistic Regression, Naïve Bayes, Random Forest, SVM.	Akurasi: 98%
5.	Analisis Sentimen Terhadap Aplikasi Pluang Menggunakan Algoritma Naive Bayes dan Support Vector Machine (SVM)	2000	Analisis sentimen ulasan aplikasi Pluang	SVM, Naïve Bayes	Akurasi: 99.5% F1-Score: 99.5%
6.	Analisis Sentimen pandangan public terhadap profesi	395	Analisis sentimen terhadap	Indo-RoBERTa	Akurasi: 90% F1-

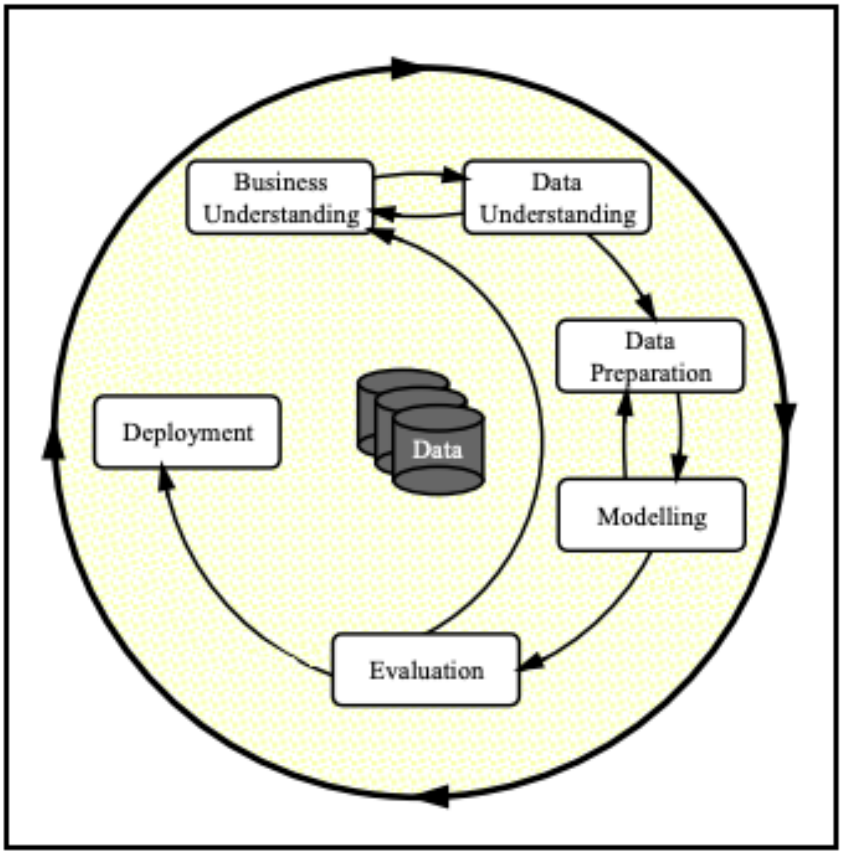
	PNS (Pegawai Negeri Sipil) dari Twitter menerapkan Indonesian Roberta Base Sentiment Classifier		profesi PNS		Score: 91%
7.	Analisis Sentimen Pengguna Twitter terhadap Vaksinasi COVID-19 di Indonesia menggunakan Algoritma Random Forest dan BERT	18805	Analisis sentimen terhadap vaksinasi COVID-19 di Indonesia	Random Forest, BERT	Akurasi: 82% F1-Score: 79%
8.	Model Bidirectional LSTM untuk Pemrosesan Sekuensial Data Teks Spam	5170	Klasifikasi data teks spam	Bi-LSTM	Akurasi: 95.75%
9.	Analisis Sentimen pada *Big Data* Kasus Stunting di Indonesia (Tahun 2019-2024)	6633	Analisis sentimen kasus stunting di Indonesia	Indo-BERT, Indo-RoBERTa, Bi-LSTM, SVM	Akurasi: 87.4% - 89.5% F1-Score: 78% - 83%

Pada Tabel 2.1 dapat dilihat bahwa dari beberapa penelitian yang dibuat oleh peneliti sebelumnya dan berkaitan dengan Skripsi ini masih ada yang belum menggunakan analisis sentimen stunting, *Big Data* untuk dataset, algoritma IndoBERT, IndoRoBERTa, Bi-LSTM, dan SVM dalam satu penelitian. Pada skripsi ini penulis memasukkan semua fitur pada satu penelitian, dengan lengkapnya fitur pada sebuah penelitian ini akan sangat membantu peneliti dalam memanfaatkan hasil penelitian tersebut.

BAB III
KEGIATAN PELAKSANAAN

3.1. Metode Pelaksanaan

Dalam pembuatan skripsi ini menggunakan metode CRISP-DM atau *Cross-Industry Standard Process for Data Mining.* Metode ini merupakan salah satu teknik standardisasi data mining yang disusun oleh lima perusahaan yaitu Integral Solutions Ltd (ISL), Teradata, Daimler AG, NCR Corporation, dan OHRA. CRISP-DM memiliki enam tahap yaitu, *business understanding, data understanding, data preparation, modeling, evaluation,* dan *deployment.*



Gambar 3.1 Tahapan Crisp-DM [45]

3.1.1. Business Understanding

Tahap ini menjelaskan latar belakang dan tujuan pembuatan skripsi, sumber dataset, kebutuhan, asumsi, batasan, dan tolak ukur keberhasilan dalam melakukan analisis sentimen pada *Big Data* kasus stunting di Indonesia.

Stunting adalah masalah kesehatan yang serius yang ditandai dengan gangguan pertumbuhan dan perkembangan pada anak-anak akibat kekurangan gizi, infeksi berulang, dan faktor lainnya [1], [2]. Meskipun prevalensi stunting di Indonesia telah menurun, angka tersebut masih tergolong tinggi dan melebihi target yang ditetapkan oleh WHO [3]. Upaya penanggulangan stunting telah dilakukan, namun tantangan seperti kemiskinan ekstrem dan akses terbatas ke fasilitas kesehatan masih menjadi penghalang [3].

Analisis sentimen dapat digunakan untuk memahami persepsi masyarakat terhadap stunting dengan menganalisis data dari media sosial dan berita *online* [4], [5]. Penelitian sebelumnya telah menggunakan metode analisis sentimen dengan algoritma dan akurasi yang bervariasi [1], [6]. Namun, dengan meningkatnya volume data dan perkembangan dalam *Natural Language Processing* (NLP), diperlukan analisis yang lebih komprehensif menggunakan algoritma yang lebih canggih seperti SVM, Bi-LSTM, IndoBERT, dan IndoRoBERTa untuk mendapatkan pemahaman yang lebih akurat tentang sentimen publik terhadap stunting dalam lima tahun terakhir.

Tujuan dari pembuatan skripsi adalah sebagai untuk menganalisis dan menjelaskan penerapan *Natural Language Processing* (NLP) dalam menganalisis sentimen yang terkandung dalam teks. Selain itu, skripsi ini akan membandingkan performa algoritma IndoBERT, IndoRoBERTa, SVM, dan Bi-LSTM untuk menentukan algoritma yang memiliki performa paling optimal dalam menganalisis sentimen pada kasus stunting di Indonesia.

Kebutuhan data dalam pembuatan skripsi ini meliputi data teks berita dan pendapat terkait kasus stunting di Indonesia. Sumber dataset dalam pembuatan skripsi ini adalah sebagai berikut:

1. Dataset media sosial Twitter diambil melalui teknik scraping dengan kata kunci “stunting”, “stunting indonesia”, “anak stunting”, “pencegahan stunting”.
2. Dataset media sosial Youtube diambil melalui teknik scraping komentar pada video dengan kata kunci “stunting indonesia”, “anak stunting”, dan “stunting kemenkes”.

3. Dataset berita *online* didapatkan melalui teknik scraping pada portal berita CNN Indonesia dan Detik.com dengan tag “stunting”.

Dataset dikumpulkan melalui teknik scraping menggunakan bahasa pemrograman Python pada Kaggle Notebook. Selanjutnya dataset dilakukan tahap pra-pemrosesan dan pelabelan untuk mempersiapkan dataset sebelum digunakan dalam pelatihan model *Machine Learning*. Hasil pengumpulan, pra-pemrosesan, serta pelabelan data dari Twitter dan YouTube digabungkan menjadi satu dataset media sosial. Sementara itu, data dari Detik.com dan CNN Indonesia digabungkan menjadi satu dataset berita *online*. Kedua dataset gabungan ini kemudian digunakan untuk melatih model *Machine Learning* dalam mengklasifikasikan sentimen menjadi tiga kategori: positif, negatif, dan netral.

Kualitas dataset yang dihasilkan dinilai cukup akurat dan dapat mewakili pernyataan serta opini mengenai keadaan stunting di Indonesia pada periode tahun 2019-2024. Hal ini dikarenakan data dikumpulkan dari sumber-sumber utama informasi publik seperti platform media sosial yang banyak digunakan (Twitter dan YouTube) serta media berita *online* nasional (Detik.com dan CNN Indonesia). Jumlah sampel data yang cukup besar juga telah dikumpulkan untuk memastikan representasi yang baik dari berbagai pandangan dan sentimen terkait stunting di Indonesia. Selain itu, proses pra-pemrosesan data yang dilakukan, termasuk pembersihan dan pelabelan sentimen secara semi-otomatis dengan verifikasi manual, turut berkontribusi pada peningkatan kualitas dan akurasi data.

Dalam pembuatan skripsi ini berfokus pada algoritma *Machine Learning* yang dibangun untuk analisis sentimen dalam mengklasifikasikan teks berita dan pendapat terkait kasus stunting di Indonesia ke dalam tiga kategori sentimen, yaitu positif, negatif, dan netral. Model atau algoritma tidak dirancang untuk melakukan analisis sentimen yang lebih spesifik, seperti mengidentifikasi emosi atau aspek tertentu dalam teks.

Analisis sentimen kasus stunting dalam pembuatan skripsi ini memiliki tolak ukur keberhasilan sebagai berikut:

1. Prediksi akurasi sentimen positif, negatif, dan netral bernilai $\geq$80%.
2. Akurasi testing bernilai >85%.
3. Model terbaik mampu mengungguli performa baseline yang telah ditentukan.

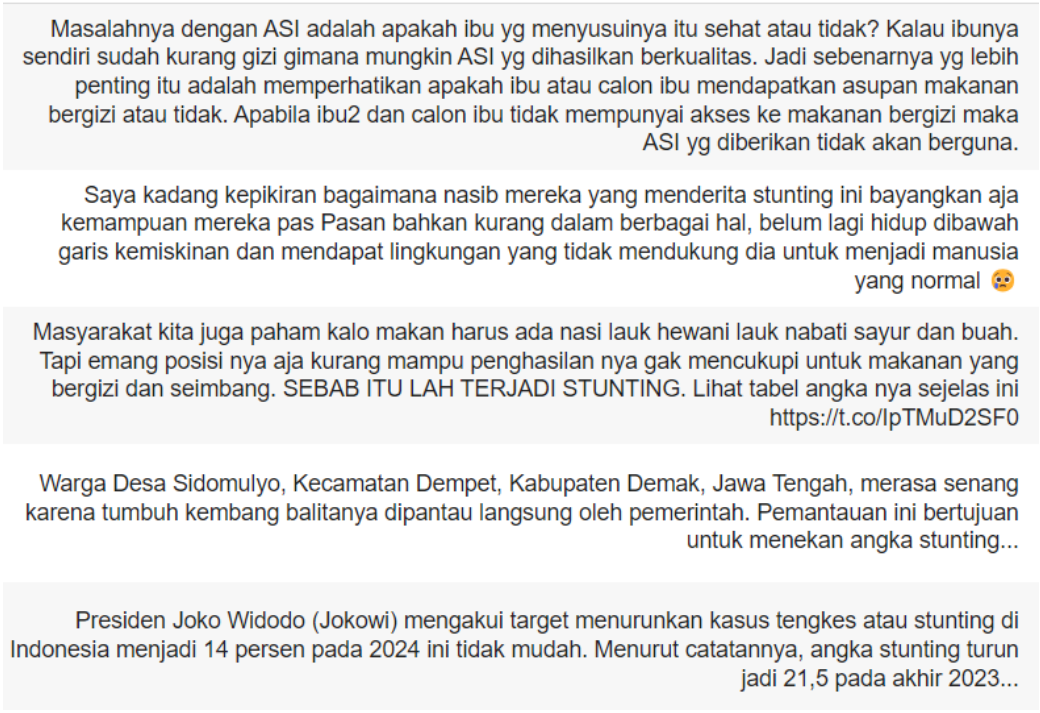
3.1.2. Data Understanding

Proses pengumpulan data teks berita dan pendapat terkait kasus stunting di Indonesia dilakukan dengan teknik scraping menggunakan bahasa pemrograman Python pada Kaggle Notebook. Teknik scraping dilakukan dengan beberapa library dalam bahasa pemrograman python seperti googleapiclient dan beautifulsoup dalam pengambilan data. Data yang dikumpulkan berasal dari dua jenis sumber, yaitu media sosial dan portal berita *online*. Dalam proses pengumpulan data dari platform media sosial, digunakan beberapa kata kunci seperti "stunting", "stunting indonesia", "pencegahan stunting", "kurang gizi", "sanitasi buruk", "gizi ibu kurang", dan "anak stunting". Sedangkan untuk data dari platform berita *online*, pengumpulan data dilakukan dengan menggunakan library BeautifulSoup yang akan mengakses halaman-halaman berita dengan kata kunci "stunting" dan mengekstrak teks berita yang muncul. Sumber media sosial meliputi platform Twitter dan YouTube, yang dipilih karena dianggap representatif terhadap opini publik terkait isu kesehatan seperti stunting. Selain itu, sumber berita *online* meliputi portal berita nasional Detik.com dan CNN Indonesia, yang dipilih karena kredibilitas dan jangkauan pembaca yang luas. Pengumpulan data dilakukan dalam rentang waktu 2019 hingga 2024, dengan fokus pada teks berita dan pendapat yang secara eksplisit membahas isu stunting di Indonesia.

Tabel 3.1 Jumlah Data Setiap Sumber

Sumber Data	**Jumlah Data**
Twitter	4071
Youtube	2639
Detik.com	3404
CNN Indonesia	711
Total	**10825**

Tabel 3.1 di atas menunjukkan jumlah data teks yang berhasil dikumpulkan dari masing-masing sumber. Selain informasi kuantitatif tersebut, berikut disajikan beberapa contoh teks yang diambil dari dataset untuk memberikan gambaran mengenai jenis data yang dianalisis:

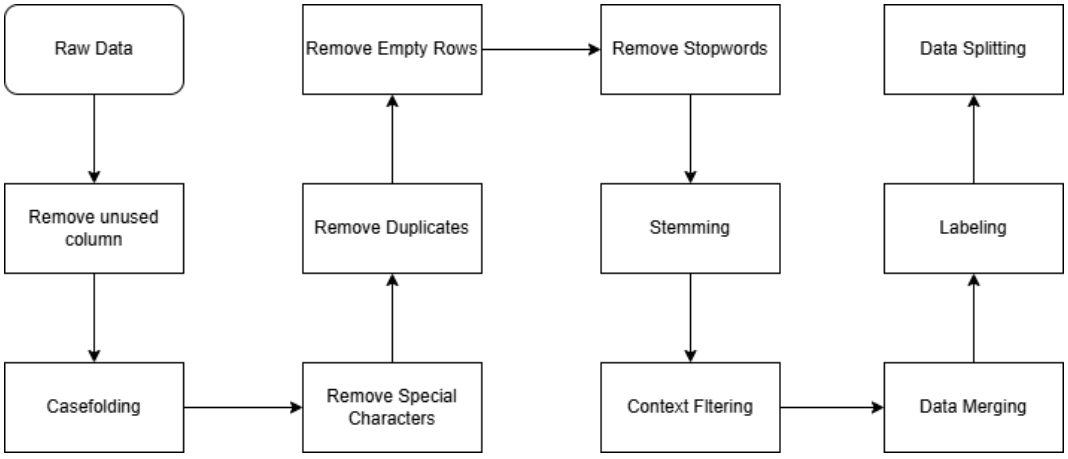


Gambar 3.2 Contoh Data Terkumpul

Gambar 3.2 menunjukkan variasi dalam gaya bahasa, panjang teks, dan sentimen yang terdapat dalam dataset. Analisis lebih lanjut terhadap data ini akan dilakukan pada tahap selanjutnya untuk mengidentifikasi pola dan tren terkait sentimen publik terhadap kasus stunting di Indonesia.

3.1.3. Data Preparation

Tahap ini berfungsi untuk mempersiapkan data sebelum digunakan untuk melatih model *Machine Learning*. Tahap persiapan data merupakan tahap yang krusial karena tahap ini dapat mempengaruhi kualitas data yang dimiliki. Kualitas data secara langsung akan memengaruhi performa model *Machine Learning* yang dikembangkan.



Gambar 3.3 Tahapan Persiapan Data

Langkah-langkah yang dikerjakan dalam tahap persiapan data ditunjukkan pada Gambar 3.3 dengan penjelasan sebagai berikut:

3.1.3.1. Preprocessing

Dalam preprocessing dilakukan menggunakan bahasa pemrograman python dengan beberapa library seperti pandas, regex, NLTK, dan Sastrawi. Tahap pertama dari preprocessing adalah menghapus kolom tidak terpakai pada data yang telah terkumpul. Sebagai contoh, pada hasil pengumpulan data twitter terdapat kolom conversation_id_str, created_at, favorite_count, full_text, id_str, image_url, in_reply_to_screen_name, lang, location, quote_count, reply_count, retweet_count, tweet_url, user_id_str, dan username. Namun, kolom yang akan digunakan untuk data twitter pada pembuatan skripsi ini hanya kolom full_text saja, sehingga kolom lainnya perlu dihapus. Proses serupa juga diterapkan untuk data dari platform lainnya.

Setelah penghapusan kolom, dilakukan *case folding* untuk mengubah seluruh teks menjadi huruf kecil. Langkah ini bertujuan untuk menyamakan penulisan dan menghindari perbedaan perlakuan terhadap kata yang sama namun memiliki kapitalisasi berbeda, seperti "Stunting" dan "stunting". Selanjutnya, pembersihan teks dilakukan dengan menghapus karakter khusus seperti tanda baca, simbol, angka, emoji, dan tautan yang tidak relevan dengan analisis sentimen. Data duplikat dan data kosong (null) juga dihapus untuk memastikan setiap data unik dan menghindari bias dalam analisis.

Tahap berikutnya adalah menghilangkan stopwords, yaitu kata-kata umum yang sering muncul tetapi tidak memiliki makna signifikan dalam analisis sentimen, seperti "dan", "yang", "di". Tahap ini dilakukan dengan menggunakan library NLTK yang menyediakan daftar stopwords untuk berbagai bahasa. Setelah itu, dilakukan *stemming*, yaitu proses mengubah kata berimbuhan menjadi kata dasar. Misalnya, kata "menurunkan" akan diubah menjadi "turun". *Stemming* bertujuan untuk mengurangi variasi kata dan meningkatkan akurasi dalam analisis sentimen. Proses *stemming* dilakukan menggunakan library Sastrawi yang menyediakan algoritma *stemming* yang lengkap untuk bahasa Indonesia.

Proses dilanjutkan dengan normalisasi data teks untuk mengubah kata-kata yang tidak baku, alay, singkatan, atau kesalahan penulisan menjadi kata baku. Dalam tahap ini digunakan file “colloquial indonesian lexicon” yang berisi pasangan kata tidak baku dan kata baku yang sesuai. Kemudian dilakukan filter data untuk memastikan bahwa hanya data yang relevan dengan kasus stunting di Indonesia yang digunakan dalam analisis. Data yang tidak berhubungan atau tidak memberikan informasi yang berguna untuk analisis sentimen akan dihapus. Proses ini dilakukan secara manual untuk memastikan akurasi dan relevansi data yang digunakan dalam penelitian. Terakhir proses penggabungan data, yaitu data dari platform Twitter dan Youtube digabung menjadi dataset media sosial. Sedangkan untuk data dari platform Detik.com dan CNN Indonesia digabung menjadi dataset berita *online*.

3.1.3.2. Pelabelan Data

Data yang telah melalui tahap preprocessing kemudian akan diberi label sentimen positif, negatif, atau netral berdasarkan ekspresi dan opini yang terkandung dalam teks. Proses pelabelan ini dilakukan secara semi-otomatis untuk meningkatkan efisiensi dan akurasi. Tahap awal pelabelan menggunakan model Pre-trained BERT untuk Text Classification analisis sentimen yang telah dilatih sebelumnya dengan data berbahasa Indonesia. Penggunaan model ini membantu memberikan label awal yang lebih akurat dan mempercepat proses pelabelan secara keseluruhan. Namun, untuk memastikan keakuratan pelabelan, setiap label yang dihasilkan oleh model akan diverifikasi dan diperbaiki secara manual. Verifikasi manual ini penting untuk mengoreksi kesalahan potensial yang mungkin terjadi pada pelabelan otomatis dan

memastikan setiap data memiliki label sentimen yang tepat sesuai dengan konteks dan nuansa bahasa Indonesia.

3.1.3.3. Pembagian Data

Pada tahap akhir persiapan data, kedua dataset (media sosial dan berita *online*) dibagi menjadi dua bagian: data latih (80%) dan data uji (20%). Pembagian ini dilakukan secara acak dan proporsional untuk memastikan representasi yang seimbang antara kedua jenis data. Data latih digunakan untuk melatih model *Machine Learning*, yaitu memberikan model informasi yang cukup untuk mempelajari pola dan hubungan dalam data. Sementara itu, data uji digunakan untuk mengevaluasi performa model pada data yang belum pernah dilihat sebelumnya, sehingga memberikan gambaran yang lebih akurat tentang kemampuan generalisasi model. Proses pembagian data ini dilakukan menggunakan bahasa pemrograman Python dengan library scikit-learn, yang menyediakan fungsi train_test_split untuk membagi data secara acak dan konsisten.

3.1.4. Modeling

Tahap ini berfokus pada pengembangan model *Machine Learning* untuk mengklasifikasi sentimen pada data teks kasus stunting. Penjelasan dalam tahap ini meliputi arsitektur model yang dikembangan dan pelatihan model.

3.1.4.1. Arsitektur Model

Pada pembuatan skripsi ini dikembangkan empat algoritma *Machine Learning* yang akan dibandingkan untuk mendapatkan model dengan performa paling optimal untuk melakukan analisis sentimen pada kasus stunting. Algoritma-algoritma tersebut adalah SVM, Bi-LSTM, serta model turunan transformer yaitu IndoBert, dan IndoRoBERTa.

1. SVM

Dalam pembuatan skripsi ini, model SVM dikembangkan dengan menggunakan TF-IDF (Term Frequency-Inverse Document Frequency) untuk mengubah teks menjadi representasi numerik yang dapat diproses oleh algoritma. TF-IDF tidak hanya memperhitungkan frekuensi kemunculan kata dalam dokumen, tetapi juga mempertimbangkan pentingnya kata tersebut dalam keseluruhan korpus. Sehingga, TF-IDF akan memberikan bobot yang lebih tinggi pada kata-kata yang jarang muncul namun memiliki makna penting dalam konteks tertentu. Untuk

meningkatkan efisiensi dan menghindari kebocoran data, TF-IDF dan model SVM dengan kernel linear digabungkan dalam sebuah pipeline. Model SVM dengan kernel linear dipilih karena dianggap cukup efektif untuk klasifikasi teks dengan dimensi fitur yang relatif tinggi seperti yang dihasilkan oleh TF-IDF.

2. Bi-LSTM

Model Bi-LSTM yang dikembangkan dalam pembuatan skripsi ini memiliki arsitektur yang ditunjukkan pada Gambar 3.2 berikut.

```
Model: "sequential"
_________________________________________________________________
 Layer (type)                Output Shape              Param #
=================================================================
 embedding (Embedding)       (None, 512, 128)          1280000

 bidirectional (Bidirection  (None, 512, 256)          263168
 al)

 dropout (Dropout)           (None, 512, 256)          0

 bidirectional_1 (Bidirecti  (None, 256)               394240
 onal)

 dropout_1 (Dropout)         (None, 256)               0

 batch_normalization (Batch  (None, 256)               1024
 Normalization)

 dense (Dense)               (None, 64)                16448

 dropout_2 (Dropout)         (None, 64)                0

 dense_1 (Dense)             (None, 3)                 195

=================================================================
Total params: 1955075 (7.46 MB)
Trainable params: 1954563 (7.46 MB)
Non-trainable params: 512 (2.00 KB)
_________________________________________________________________
```

Gambar 3.4 Arsitektur Model Bi-LSTM

Pada Gambar 3.4 menunjukkan layer yang digunakan pada model Bi-LSTM ini terdiri dari lapisan Embedding, dua lapisan Bi-LSTM, tiga lapisan dropout, lapisan Batch Normalization, dan dua lapisan Dense untuk menghasilkan keluaran klasifikasi. Lapisan embedding digunakan untuk memetakan setiap kata dalam teks menjadi vektor numerik dengan dimensi 128. Ukuran input dari lapisan ini (input_dim) ditentukan oleh ukuran kosakata (vocab_size) yaitu 10000, dan panjang input (input_length) dibatasi oleh nilai maxlen yaitu 512.

Selanjutnya, dua lapisan Bidirectional LSTM dengan masing-masing 128 unit LSTM digunakan untuk menangkap informasi kontekstual dari kedua arah (maju dan mundur) dalam teks. Lapisan dropout ditambahkan setelah setiap lapisan Bi-LSTM dengan dropout rate sebesar 0.6 untuk mencegah overfitting. Setelah lapisan Bi-LSTM kedua, terdapat lapisan Batch Normalization untuk menormalisasi aktivasi dan mempercepat pelatihan. Selanjutnya, terdapat lapisan Dense yang terdiri dari 64 unit yang bertujuan untuk menyederhanakan informasi yang didapatkan dari lapisan sebelumnya. Lapisan ini juga menggunakan fungsi aktivasi ReLU dan diikuti oleh lapisan Dropout dengan dropout rate 0.6 untuk mencegah model overfitting.

Lapisan dense terakhir menggunakan fungsi aktivasi softmax untuk menghasilkan probabilitas kelas sentimen (positif, negatif, dan netral). Dalam pengembangan model Bi-LSTM ini juga terdapat Tokenisasi teks menggunakan tokenizer dari TensorFlow, yang secara otomatis menangani pemisahan kata dan pemetaan kata ke indeks.

3. Transformer (IndoBERT dan IndoRoBERTa)

IndoBERT dan IndoRoBERTa adalah model bahasa berbasis Transformer yang telah disesuaikan dan dilatih secara khusus untuk bahasa Indonesia. Arsitektur dasar dari kedua model ini sama, yaitu menggunakan transformer encoder yang terdiri dari beberapa lapisan self-attention dan feed-forward. Perbedaan utama antara model-model ini terletak pada data yang digunakan untuk pra-pelatihan. IndoBERT dilatih pada korpus teks berbahasa Indonesia yang relatif lebih kecil dan umum, sementara IndoRoBERTa dilatih pada korpus yang jauh lebih besar dengan pendekatan *masked language modeling* yang lebih dinamis. Hal ini memungkinkan IndoRoBERTa untuk mempelajari representasi kata yang lebih kontekstual dan akurat.

Dalam penelitian ini, digunakan dua model berbasis Transformer, yaitu IndoBERT dan IndoRoBERTa. Kedua model tersebut merupakan turunan dari model BERT dan RoBERTa yang telah dilatih sebelumnya menggunakan data teks Bahasa Indonesia. Model-model tersebut akan digunakan untuk menganalisis sentimen pada kasus stunting di Indonesia. Model IndoBERT dan IndoRoBERTa yang

digunakan diakses melalui platform Hugging Face, yang menyediakan berbagai model terlatih untuk berbagai tugas pemrosesan bahasa alami.

3.1.4.2. Pelatihan Model

Pelatihan model dalam pembuatan skripsi ini dilakukan dengan menerapkan strategi yang sama untuk semua model yang digunakan, baik Bi-LSTM maupun model-model turunan Transformer (IndoBERT dan IndoRoBERTa). Jumlah epoch yang diterapkan adalah 10, yang berarti terdapat 10 iterasi model dalam proses *training*. Pemilihan jumlah epoch ini didasarkan pada percobaan awal dan bertujuan untuk mencapai kondisi model yang telah mempelajari pola data dengan baik tanpa menyebabkan overfitting.

Ukuran batch size yang digunakan adalah 8. Batch size menentukan jumlah sampel data yang diproses oleh model dalam setiap iterasi pelatihan. Pemilihan batch size 8 ini mempertimbangkan keterbatasan sumber daya komputasi dan bertujuan untuk menyeimbangkan antara kecepatan pelatihan dan stabilitas model.

Selain itu, semua model menggunakan optimizer Adam untuk memperbarui parameter model selama pelatihan. Optimizer Adam dapat menyesuaikan learning rate secara otomatis untuk setiap parameter model. Penggunaan Adam bertujuan untuk mempercepat proses pelatihan model dan mencapai hasil yang optimal.

Strategi yang diterapkan dalam pelatihan model SVM berbeda dengan model-model sebelumnya. Pelatihan model SVM dilakukan dengan menggunakan pipeline yang terdiri dari TF-IDF Vectorizer dan LinearSVC. TF-IDF Vectorizer berfungsi untuk mengubah teks menjadi representasi numerik berdasarkan bobot kata, sedangkan LinearSVC adalah algoritma SVM yang digunakan untuk klasifikasi. Model SVM dilatih dengan menggunakan parameter default dari LinearSVC.

Setiap model dilatih dengan menggunakan data latih (80% dari dataset) yang telah melalui proses pembagian data sebelumnya. Kemudian akan diterapkan k-fold cross-validation dengan 5 fold untuk memastikan bahwa model tidak overfitting dan memiliki kemampuan generalisasi yang baik. Pada setiap fold, data dibagi menjadi 5 bagian, salah satu bagian digunakan sebagai data validasi dan sisanya sebagai data latih. Proses pelatihan dan evaluasi model dilakukan sebanyak 5 kali, dengan setiap bagian data bergantian menjadi data validasi. Hasil evaluasi dari

semua fold kemudian dirata-ratakan untuk mendapatkan estimasi performa model yang lebih akurat.

3.1.5. Evaluation

Tahap evaluasi merupakan tahapan untuk mengukur performa model yang telah dilatih dalam melakukan klasifikasi sentimen teks pada kasus stunting di Indonesia. Dalam pembuatan skripsi ini dilakukan pengukuran performa model dengan menggunakan metrik-metrik berikut:

1. Akurasi

   Akurasi adalah rasio prediksi benar dari keseluruhan prediksi. Akurasi dihitung dengan membagi total prediksi benar dengan jumlah total prediksi dalam dataset evaluasi.

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN} \tag{3.1}$$

   Pada persamaan (3.1) TP mewakili jumlah prediksi positif yang benar, TN adalah jumlah prediksi negatif yang benar, FP adalah jumlah prediksi positif yang salah, dan FN adalah jumlah prediksi negatif yang salah.

2. Precision

   Precision adalah proporsi sampel yang diambil dan dihitung sebagai rasio antara sampel yang diklasifikasikan dengan benar dan semua sampel yang ditugaskan ke kelas tersebut [42]. Precision membagi hasil prediksi positif yang benar dengan jumlah prediksi positif yang benar dan prediksi positif yang salah.

$$Precision = \frac{TP}{TP + FP} \tag{3.2}$$

   Pada persamaan (3.2) TP mewakili jumlah prediksi positif yang benar, sedangkan FP adalah jumlah prediksi positif yang salah.

3. Recall

   Recall adalah tingkat prediksi positif yang diklasifikasikan dengan benar. Recall dihitung dengan membagi antara prediksi positif yang diklasifikasikan dengan benar dengan keseluruhan data yang sebenarnya positif..

$$Recall = \frac{TP}{TP + FN} \tag{3.3}$$

Pada persamaan (3.3) TP mewakili jumlah prediksi positif yang benar, sedangkan FN adalah jumlah prediksi negatif yang salah.

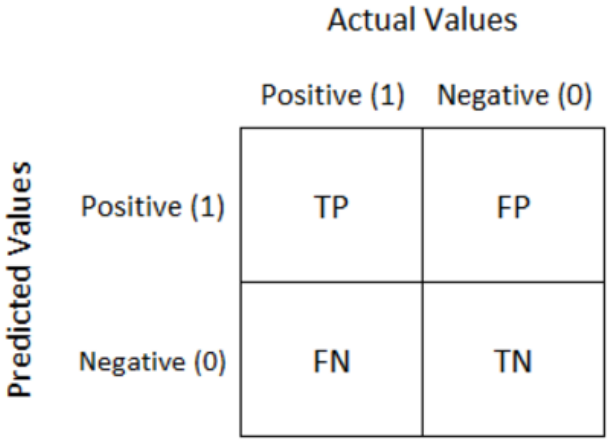
4. F1-Score

   F1-Score merupakan rata-rata harmonik antara presisi dan recall.F1-Score menggabungkan nilai Precision dan Recall menjadi skor tunggal yang menggambarkan keseimbangan antara keduanya. F1-Score berguna untuk mendapatkan gambaran yang komprehensif tentang performa sistem dalam mengklasifikasikan sentimen positif, negatif, atau netral. Persamaan F1-Score ditunjukkan pada persamaan (3.4) berikut.

$$F1 = 2 \times \frac{Precision \times Recall}{Precision + Recall} \tag{3.4}$$

5. Confusion Matrix

   Confusion matrix adalah tabel yang memungkinkan untuk melihat hasil klasifikasi terperinci dari sebuah algoritma pada data uji. Confusion matrix akan menampilkan jumlah data yang diklasifikasikan pada kelas yang benar (true positive dan true negative) dan salah (false positive dan false negative). Metrik ini dapat digunakan untuk memperoleh nilai precision, recall, dan accuracy karena memberikan nilai TP, TN, FP, dan FN secara detail seperti yang ditunjukkan Gambar 3.5 berikut.



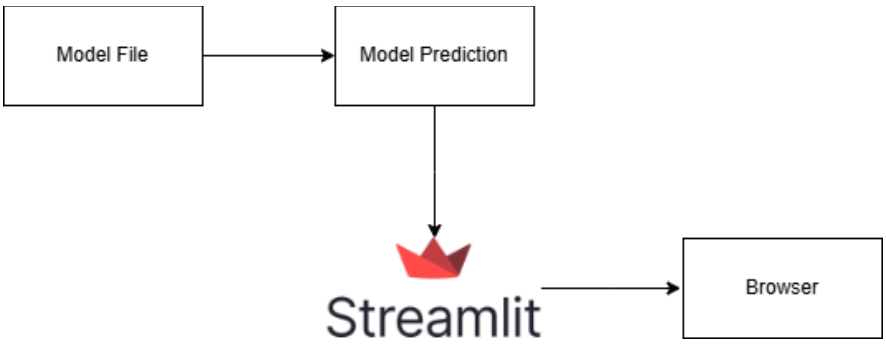
Gambar 3.5 Confusion Matrix [46]

Dengan menganalisis *confusion matrix* dapat dipahami jenis-jenis kesalahan yang dilakukan oleh masing-masing model. Hal ini dapat memberikan wawasan tentang kekuatan dan kelemahan masing-masing model dalam mengidentifikasi sentimen tertentu.

Metrik-metrik ini dipilih karena dapat memberikan gambaran yang cukup jelas mengenai performa model dalam melakukan klasifikasi sentimen positif, negatif, dan netral. Akurasi memberikan gambaran umum mengenai tingkat kebenaran prediksi. Presisi dan recall memberikan informasi yang lebih spesifik mengenai kemampuan model dalam mengidentifikasi kelas positif. F1-score memberikan ukuran yang lebih seimbang antara presisi dan recall. Sedangkan confusion matrix akan memberikan informasi tentang jumlah data yang diklasifikasikan dengan benar (true positive dan true negative) dan salah (false positive dan false negative) secara spesifik.

3.1.6. Deployment

Tahap deployment merupakan tahap akhir dalam pembuatan skripsi ini. Pada tahap ini dilakukan deployment terhadap model yang telah dikembangkan. Dalam pembuatan skripsi ini model terbaik yang telah dikembangkan akan diterapkan dalam aplikasi website simpel dengan menggunakan Streamlit. Gambar 3.6 berikut menunjukkan arsitektur backend yang akan dikembangkan.



Gambar 3.6 Arsitektur Deployment

Aplikasi ini menyediakan dua fitur yang dapat diakses untuk melakukan klasifikasi sentimen terhadap teks terkait stunting di Indonesia sebagai input. Setiap model terbaik yang telah dilatih pada setiap dataset memiliki satu fitur tersendiri, sehingga model dapat dipilih sesuai dengan kebutuhan. Setiap fitur dapat menerima masukan berupa teks dan mengembalikan hasil klasifikasi yang berisi label sentimen (positif, negatif, atau netral). *Request* dan *response* akan dilakukan dalam aplikasi *browser*.

Alur kerja sistem dimulai ketika mengirimkan permintaan *request* pada salah satu fitur dengan menyertakan teks yang akan diklasifikasi. Streamlit menerima permintaan dan mengekstrak teks input, kemudian melakukan pra-pemrosesan teks. Selanjutnya, berdasarkan fitur yang digunakan, sistem akan memilih model yang sesuai untuk melakukan klasifikasi sentimen. Model yang dipilih akan menerima teks yang telah diproses dan menghasilkan prediksi sentimen. Streamlit kemudian membentuk respons yang berisi label sentimen lalu mengirimkan respons tersebut.

3.2. Analisis Kebutuhan

Kebutuhan sistem dalam pembuatan skripsi adalah sebagai berikut:

3.2.1. Kebutuhan Perangkat Keras (*Hardware*)

Berikut perangkat keras yang digunakan dalam pembuatan skripsi ini:

a. Laptop dengan spesifikasi:
    i. Sistem Operasi Windows 10
    ii. Processor InterCore i3
    iii. RAM 4 GB

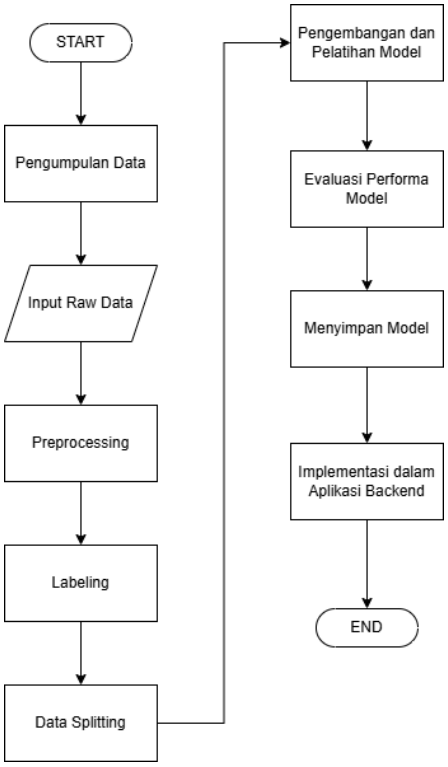
3.2.2. Kebutuhan Perangkat Lunak (*Software*)

Berikut perangkat lunak yang digunakan dalam pembuatan skripsi ini:

a. Chrome Browser
b. Kaggle Notebook
c. Python
d. PyTorch
e. Pandas
f. HuggingFace
g. Scikit-learn
h. Keras
i. TensorFlow
j. Flask

3.3. Perancangan Sistem

3.3.1. Flow Chart



Gambar 3.7 Flowchart Sistem

Gambar 3.7 menggambarkan alur pengerjaan pada skripsi ini. Tahap awal dimulai dengan pengumpulan data dari berbagai sumber, diikuti oleh preprocessing data. preprocessing data mencakup proses *case folding*, menghapus karakter khusus, angka, emoji, tautan, menghapus data duplikat dan data null, menghilangkan stopwords, dan proses *stemming*. Tahap ini bertujuan untuk mempersiapkan data sebelum masuk ke tahap selanjutnya hingga tahap pelatihan model.

Data yang sudah dilakukan preprocessing kemudian dilakukan pelabelan sesuai dengan sentimen yang tergambarkan dalam data teks tersebut. Proses ini dilakukan secara semi-otomatis menggunakan model Pre-trained BERT untuk Text Classification analisis sentimen, yang kemudian diverifikasi dan diperbaiki secara manual untuk memastikan akurasi. Data yang sudah diberi label kemudian digabungkan untuk data twitter dan youtube sebagai dataset media sosial serta data berita Detik.com dan CNN Indonesia sebagai dataset berita *online*. Kedua dataset selanjutnya dibagi menjadi data latih dan data uji dengan rasio 80% untuk data latih dan 20% untuk data uji.

Tahap selanjutnya adalah pengembangan model SVM, Bi-LSTM, dan model transformer seperti IndoBERT dan IndoRoBERTa. Model-model yang sudah dibangun kemudian dilatih menggunakan data latih dengan menerapkan teknik k-fold cross validation untuk memastikan bahwa model tidak overfitting dan memiliki kemampuan generalisasi yang baik.Setelah pelatihan, performa model dievaluasi menggunakan metrik seperti akurasi, F1-score, precision, recall, dan confusion matrix pada data uji. Setelah melakukan evaluasi performa, model terbaik yang sudah dibangun disimpan dalam file.

Tahap akhir dalam pembuatan skripsi ini adalah mengimplementasikan model yang sudah dibangun ke dalam aplikasi backend menggunakan framework flask. Aplikasi ini akan memiliki API Endpoint untuk setiap model terbaik yang menerima masukan berupa teks dan memberikan keluaran berupa label sentimen dan nilai confidence.

BAB IV
ANALISIS DAN PEMBAHASAN

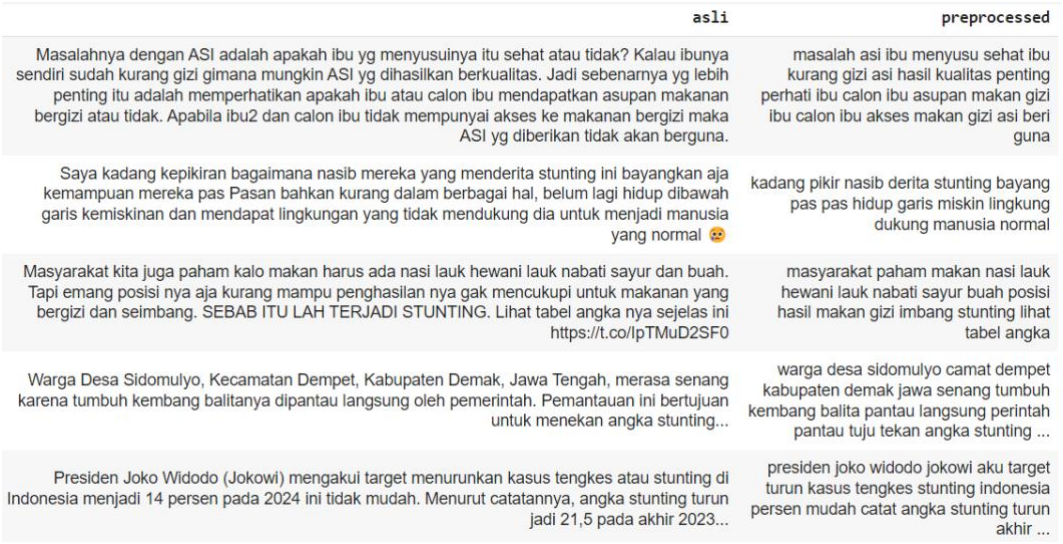
4.1. Analisis Data

Dataset yang digunakan terdiri dari teks berita dan opini terkait kasus stunting di Indonesia. Teks-teks ini dikumpulkan dari berbagai sumber untuk mendapatkan representasi yang beragam dari berbagai pandangan dan sentimen terhadap isu stunting. Sumber data berasal dari dua media sosial, Twitter dan Youtube, serta dua portal berita daring, Detik.com dan CNN Indonesia. Data yang dikumpulkan dibatasi hanya pada tahun 2019 hingga 2024. Hasil dari proses scraping di setiap platform kemudian disimpan dalam file berformat csv. Tabel 4.1 berikut menunjukkan tautan sumber data yang digunakan.

Tabel 4.1 Sumber Data dan Tautan

Sumber Data	**Tautan**
Twitter	https://x.com/
Youtube	https://www.youtube.com/
Detik.com	https://www.detik.com/
CNN Indonesia	https://www.cnnindonesia.com/

Data-data yang telah dikumpulkan pada proses sebelumnya, kemudian dilakukan preprocessing untuk mempersiapkan data sebelum digunakan untuk melatih model. Tahap preprocessing diawali dengan menghapus kolom yang tidak digunakan. Selanjutnya adalah proses *case folding*, menghapus data null dan data duplikat, menghapus karakter khusus seperti tanda baca, angka, emotikon, tautan, dan karakter lain. Proses dilanjutkan dengan menghapus stopwords, melakukan *stemming*, dan normalisasi data. Kemudian, dilanjutkan dengan memfilter data untuk menghilangkan data yang tidak relevan dengan kasus stunting di Indonesia.



	asli	preprocessed
	Masalahnya dengan ASI adalah apakah ibu yg menyusuinya itu sehat atau tidak? Kalau ibunya sendiri sudah kurang gizi gimana mungkin ASI yg dihasilkan berkualitas. Jadi sebenarnya yg lebih penting itu adalah memperhatikan apakah ibu atau calon ibu mendapatkan asupan makanan bergizi atau tidak. Apabila ibu2 dan calon ibu tidak mempunyai akses ke makanan bergizi maka ASI yg diberikan tidak akan berguna.	masalah asi ibu menyusu sehat ibu kurang gizi asi hasil kualitas penting perhati ibu calon ibu asupan makan gizi ibu calon ibu akses makan gizi asi beri guna
	Saya kadang kepikiran bagaimana nasib mereka yang menderita stunting ini bayangkan aja kemampuan mereka pas Pasan bahkan kurang dalam berbagai hal, belum lagi hidup dibawah garis kemiskinan dan mendapat lingkungan yang tidak mendukung dia untuk menjadi manusia yang normal 😳	kadang pikir nasib derita stunting bayang pas pas hidup garis miskin lingkung dukung manusia normal
	Masyarakat kita juga paham kalo makan harus ada nasi lauk hewani lauk nabati sayur dan buah. Tapi emang posisi nya aja kurang mampu penghasilan nya gak mencukupi untuk makanan yang bergizi dan seimbang. SEBAB ITU LAH TERJADI STUNTING. Lihat tabel angka nya sejelas ini https://t.co/IpTMuD2SF0	masyarakat paham makan nasi lauk hewani lauk nabati sayur buah posisi hasil makan gizi imbang stunting lihat tabel angka
	Warga Desa Sidomulyo, Kecamatan Dempet, Kabupaten Demak, Jawa Tengah, merasa senang karena tumbuh kembang balitanya dipantau langsung oleh pemerintah. Pemantauan ini bertujuan untuk menekan angka stunting...	warga desa sidomulyo camat dempet kabupaten demak jawa senang tumbuh kembang balita pantau langsung perintah pantau tuju tekan angka stunting ...
	Presiden Joko Widodo (Jokowi) mengakui target menurunkan kasus tengkes atau stunting di Indonesia menjadi 14 persen pada 2024 ini tidak mudah. Menurut catatannya, angka stunting turun jadi 21,5 pada akhir 2023...	presiden joko widodo jokowi aku target turun kasus tengkes stunting indonesia persen mudah catat angka stunting turun akhir ...

Gambar 4.1 Data Sebelum dan Sesudah Preprocessing

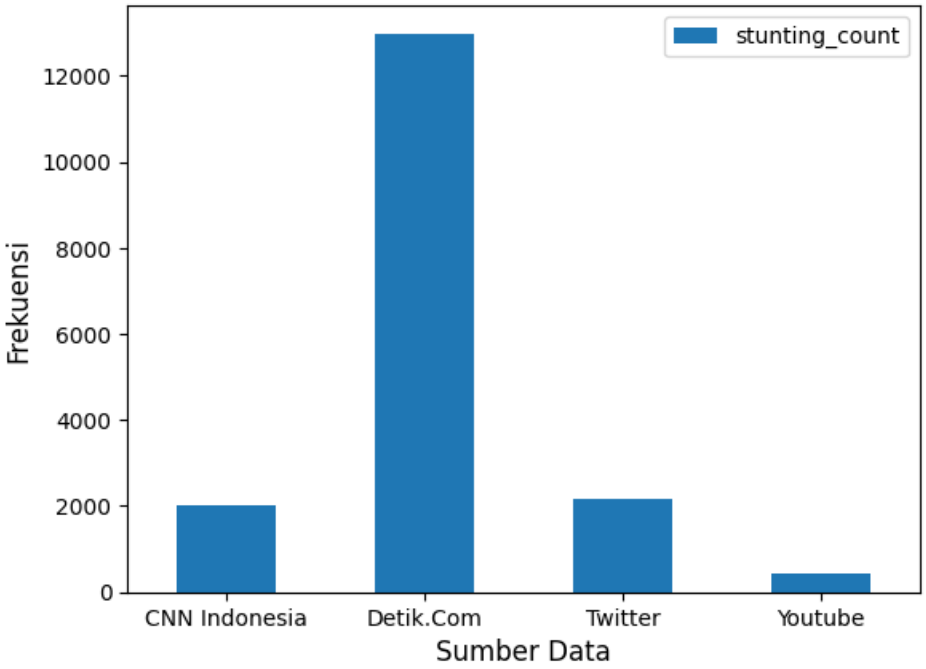
Gambar 4.1 menunjukkan beberapa contoh data sebelum dan sesudah dilakukan preprocessing. Perbedaan antara data asli dan data setelah preprocessing cukup signifikan. Pada data asli menunjukkan bahwa data memiliki banyak noise, seperti tanda baca, huruf kapital, kata tidak baku, singkatan, tautan, bahkan emotikon. Setelah data dilakukan preprocessing, data menjadi lebih terstruktur dan bersih sehingga lebih mudah untuk dilakukan analisis. Dengan menghilangkan noise dan menyamakan format teks, model *Machine Learning* dapat lebih fokus pada kata-kata yang memiliki makna penting dalam menentukan sentimen.

Tabel 4.2 Jumlah Data Setelah Preprocessing

Sumber	**Jumlah Data**
Twitter	2014
Youtube	1125
Detik.com	2930
CNN Indonesia	564
Total	**6633**

Tabel 4.2 menunjukkan jumlah data yang telah melalui tahap preprocessing. Terdapat penurunan jumlah data jika dibandingkan dengan data asli terutama pada data Twitter dan Youtube. Hal ini disebabkan oleh beberapa faktor seperti data

duplikat dan data kurang relevan. Adanya data duplikat yang cukup banyak merupakan akibat dari penggunaan kata kunci serupa pada proses pengambilan data Twitter seperti “stunting”, “anak stunting”, “pencegahan stunting”, dan “stunting indonesia” sehingga data dapat terambil lebih dari satu kali. Selain itu, tidak semua data yang terkumpul relevan dengan kasus stunting di Indonesia. Beberapa *tweet* atau komentar YouTube hanya menyebutkan kata "stunting" secara sepintas tanpa membahas isu tersebut secara mendalam, atau bahkan menjadikan kata stunting sebagai umpatan. Data komentar youtube juga banyak yang lebih cenderung mengomentari video daripada membahas konten video yang membahas kasus stunting. Data-data yang tidak relevan ini perlu dihapus untuk menjaga fokus analisis pada sentimen publik terhadap stunting di Indonesia.



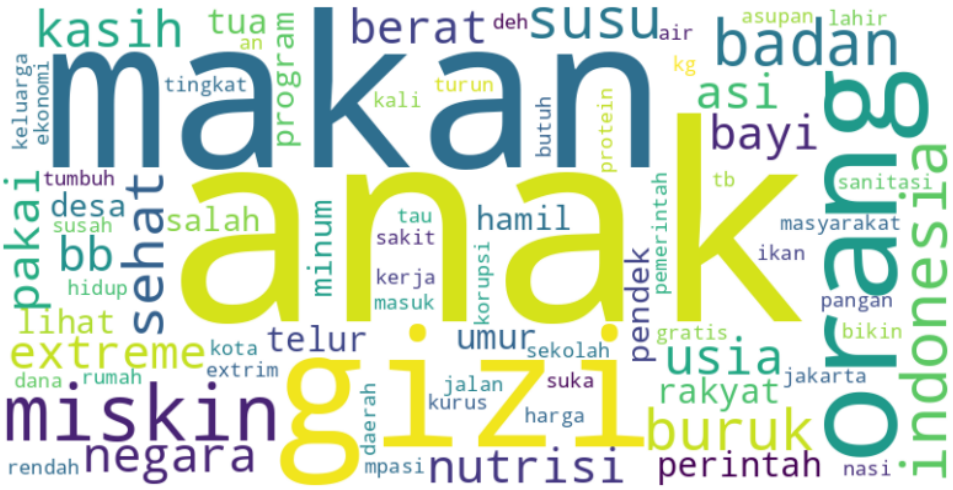
Gambar 4.2 Frekuensi Kemunculan Kata “Stunting”

Gambar 4.2 menunjukkan grafik frekuensi kemunculan kata “stunting” pada setiap sumber data. Pada grafik tersebut data dari Detik.com memiliki frekuensi kemunculan kata “stunting” paling banyak. Hal ini mengindikasikan perhatian yang besar terhadap isu-isu kesehatan masyarakat, termasuk stunting, terlihat dari banyaknya artikel pada Detik.com yang membahas tentang stunting. Selain itu, frekuensi kemunculan kata “stunting” yang cukup banyak pada data Detik.com dapat dikarenakan karakteristik penulisan berita yang cenderung lebih padat

informasi. Satu artikel berita dapat menyebutkan kata "stunting" beberapa kali untuk menekankan pentingnya isu ini atau menjelaskan berbagai aspek terkait stunting.

Frekuensi kemunculan kata “stunting” pada data Twitter dan CNN Indonesia cukup seimbang. Frekuensi pada data CNN Indonesia yang jauh lebih sedikit daripada data Detik.com dapat disebabkan oleh jumlah data CNN Indonesia yang lebih sedikit. Meskipun data CNN Indonesia lebih sedikit daripada data Twitter, data ini memiliki frekuensi kemunculan kata “stunting” yang seimbang dengan data Twitter karena karakteristik penulisan berita yang memungkinkan penyebutan kata “stunting” lebih dari satu kali dalam satu artikel. Grafik frekuensi yang ditunjukkan untuk data Twitter menggambarkan pengguna twitter cukup banyak membahas stunting.

Pada data Youtube, frekuensi kemunculan kata “stunting” paling sedikit. Meskipun demikian, hal tersebut tidak langsung berarti stunting tidak banyak dibahas pada platform Youtube. Namun, hal ini dapat disebabkan karena dalam komentar Youtube cenderung menggunakan variasi bahasa yang lebih luas dalam membahas stunting, termasuk pertanyaan yang berkaitan dengan stunting, atau pembahasan mengenai penyebab stunting tanpa menyebutkan kata "stunting" secara eksplisit.



Gambar 4.3 Wordcloud Data

Gambar 4.3 menunjukkan *wordcloud* kata yang paling sering muncul dalam seluruh data selain kata “stunting”. Pada *wordcloud* tersebut menggambarkan beberapa topik dalam data yang terkait dengan stunting seperti fokus permasalahan dan faktor penyebab stunting. Kata-kata yang paling menonjol seperti "anak", "makan", "gizi",

"nutrisi", "asi", "bayi", dan "susu" menunjukkan bahwa data yang dikumpulkan berfokus pada masalah gizi dan kesehatan anak. Selain itu, kata-kata seperti "miskin", "ekonomi", "rendah", "desa", "sanitasi", dan "air" menunjukkan bahwa faktor-faktor dalam kejadian stunting adalah kemiskinan dan kondisi sosial ekonomi dan akses terhadap sanitasi serta air bersih yang buruk.

Data yang telah dilakukan preprocessing selanjutnya diberi label sentimen positif, negatif, atau netral. Proses ini dilakukan secara semi-otomatis dengan bantuan *pretrained model* Indonesia BERT *sentiment analysis,* kemudian dilakukan verifikasi dan perbaikan label secara manual.

Tabel 4.3 Jumlah Data pada Setiap Kelas Sentimen

Dataset	**Kelas Sentimen**		
	Positif	**Negatif**	**Netral**
Berita *Online*	438	411	2645
Media Sosial	551	1539	1049
Jumlah	989	1950	3694

Tabel 4.3 menunjukkan jumlah data pada masing-masing kelas. Dari tabel tersebut diketahui bahwa sentimen pada platform media sosial paling banyak adalah sentimen negatif. Hal ini sesuai dengan ekspektasi bahwa media sosial lebih sering menjadi wadah untuk mengungkapkan opini dan emosi pribadi. Sedangkan untuk sentimen pada platform berita *online* paling banyak adalah label sentimen netral yang dapat menggambarkan bahwa berita *online* umumnya menyajikan informasi secara lebih objektif dan berimbang.

Pada dataset berita *online*, sentimen netral mendominasi dengan persentase 75.7% dari total data, diikuti oleh sentimen positif (12.5%) dan negatif (11.7%). Sedangkan pada dataset media sosial, sentimen negatif mendominasi dengan persentase 49%, diikuti oleh sentimen positif (17.5%) dan netral (33.4%).

4.2. Analisis Pemodelan dan Evaluasi

Pada bagian ini akan membahas secara rinci proses pelatihan dan evaluasi model-model klasifikasi sentimen yang digunakan dalam pembuatan skripsi ini. Model

yang dibangun yaitu SVM, Bi-LSTM, IndoBERT, dan IndoRoBERTa. Analisis akan difokuskan pada performa masing-masing model pada dataset berita *online* dan media sosial, serta pemilihan model terbaik untuk setiap dataset.

4.2.1. Dataset Berita *Online*

Pelatihan model IndoBERT, IndoRoBERTa, Bi-LSTM, dan SVM menggunakan sebanyak 80% dataset berita *online*. Pada pelatihan menggunakan dataset ini, diterapkan K-fold Cross Validation pada semua model yang dikembangkan. Jumlah fold yang digunakan adalah lima fold. K-fold Cross Validation diterapkan dengan tujuan untuk menghindari overfitting dan mengoptimalkan performa model.

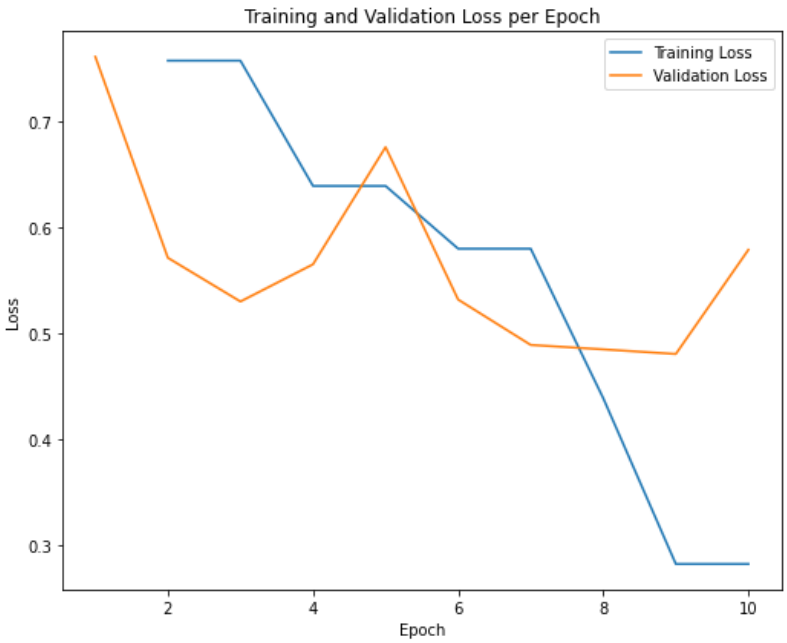
Pada model IndoRoBERTa pada pembuatan skripsi ini dikembangan dengan menggunakan model IndoRoBERTa yang sudah pernah dikembangkan sebelumnya dan tersedia pada platform HuggingFace. Model ini kemudian dilakukan hyperparameter fine-tuning untuk melakukan analisis sentimen dalam kasus stunting. Hyperparameter yang digunakan adalah 10 epoch pelatihan, optimizer adam, dan 8 batch size.

Tabel 4.4 Metrik Evaluasi Model IndoRoBERTa Dataset Berita *Online*

Fold	Accuracy	F1-Score	Precision	Recall
1	0.8425760286	0.6981306722	0.7801792705	0.6507466954
2	0.8819320215	0.8062918688	0.8266537483	0.792261439
3	0.8586762075	0.7711516445	0.7792752321	0.7635198135
4	0.9105545617	0.8241961147	0.8347634588	0.816179988
5	0.8139534884	0.5136592876	0.4786134068	0.5544004769
Mean	**0.8615384615**	**0.7226859176**	**0.7398970233**	**0.7154216826**

Pada Tabel 4.4 menunjukkan hasil evaluasi model IndoRoBERTa pada dataset berita *online* menggunakan 5-fold cross-validation. Secara keseluruhan, model menunjukkan performa yang cukup baik dengan rata-rata akurasi 86%, F1-Score 72%, presisi 73%, dan recall 71%. Namun, terdapat sedikit variasi performa pada setiap fold, terutama pada metrik recall yang menunjukkan kemampuan model dalam mengidentifikasi semua data positif. Fold terbaik pada model ini adalah fold

keempat. Hal ini ditentukan dari nilai akurasi dan F1-Score yang paling tinggi dibandingkan dengan metrik pada fold lainnya. Secara umum model IndoBERT dapat dikatakan cukup baik dalam mengklasifikasikan sentimen pada dataset berita *online* karena nilai akurasi yang tinggi dan nilai F1-score yang baik.



Gambar 4.4 Grafik *Loss* Pada Fold 4 Model IndoRoBERTa

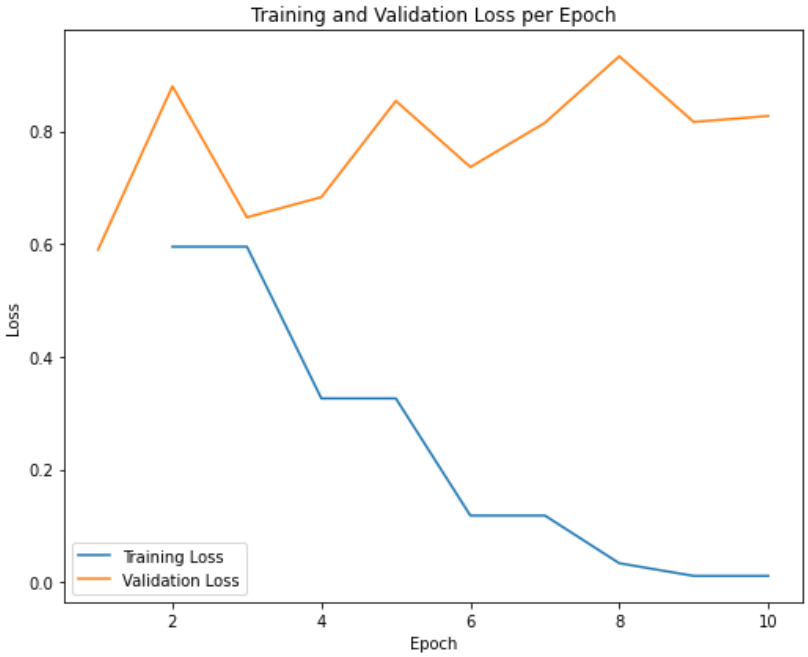
Grafik pada Gambar 4.4 merupakan *loss* yang didapatkan pada model dengan fold terbaik yaitu fold empat. Grafik tersebut menunjukkan penurunan nilai *training loss* secara umum selama proses pelatihan model seiring bertambahnya epoch. Namun, untuk *loss* pada data validasi cukup fluktuatif terutama pada epoch ke lima dan sepuluh. Hal ini menunjukkan potensi overfitting, yaitu model terlalu menyesuaikan diri dengan data latih sehingga tidak dapat menggeneralisasi dengan baik pada data yang belum pernah dilihat sebelumnya.

Model IndoBERT ini menggunakan model IndoBERT yang tersedia pada platform HuggingFace dan dilakukan hyperparameter fine-tuning. Hyperparameter yang diterapkan sama seperti model IndoRoBERTa, antara lain 10 epoch, optimizer adam, dan 8 batch size.

Tabel 4.5 Metrik Evaluasi Model IndoBERT pada Dataset Berita *Online*

Fold	Accuracy	F1-Score	Precision	Recall
1	0.8783542039	0.7740330821	0.8472238773	0.7260721692
2	0.8676207513	0.7631772103	0.8325769736	0.7278568971
3	0.7549194991	0.6588407506	0.6771628921	0.7549194991
4	0.8944543828	0.8112543814	0.7857482185	0.8431116739
5	0.8765652952	0.7474476254	0.8188894707	0.7027796408
Mean	**0.8543828265**	**0.75095061**	**0.7923202864**	**0.750947976**

Tabel 4.5 menampilkan hasil evaluasi model IndoBERT pada dataset berita daring menggunakan 5-fold cross-validation. Fold terbaik pada model ini terdapat pada fold keempat, ketika nilai akurasi dan nilai F1-Score lebih tinggi dari nilai pada fold lainnya. Secara keseluruhan, model menunjukkan performa yang baik dengan rata-rata akurasi 85%, F1-Score 75%, presisi 79%, dan recall 75%. Secara umum model IndoBERT dinilai cukup baik dalam mengklasifikasikan sentimen pada dataset berita *online* karena memiliki nilai akurasi dan F1-score yang cukup baik.



Gambar 4.5 Grafik *Loss* pada Fold 4 Model IndoBERT

Grafik yang ditunjukkan Gambar 4.5 merupakan grafik nilai *loss* dalam pelatihan model IndoBERT pada fold terbaik. Pada grafik tersebut nilai *training loss* cenderung mengalami penurunan signifikan seiring bertambahnya epoch. Ini menunjukkan bahwa model dapat mempelajari data dengan baik. Sedangkan nilai *loss* pada data validasi cenderung fluktuatif naik. Ini dapat berpotensi overfitting pada model.

Pengembangan model Bi-LSTM pada skripsi ini menggunakan beberapa lapisan seperti lapisan embedding, dua lapisan Bi-LSTM, dua lapisan Dropout, lapisan BatchNormalization, dan dua lapisan Dense. Pelatihan pada model Bi-LSTM yang dikembangkan dengan hyperparameter yang sama seperti hyperparameter yang diterapkan pada model berbasis transformer sebelumnya. Pelatihan model menggunakan teknik K-fold Cross Validation dengan 5 fold, 10 epoch, optimizer adam, dan 8 batch size. Hasil pelatihan model Bi-LSTM ditunjukkan dengan metrik evaluasi pada Tabel 4.4 berikut.

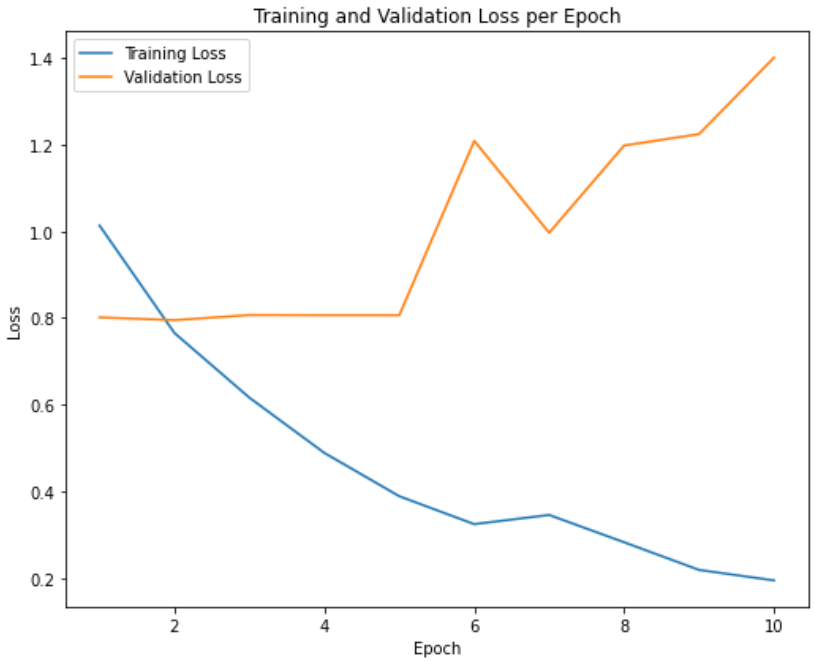
Tabel 4.6 Metrik Evaluasi Model Bi-LSTM Dataset Berita *Online*

Fold	**Accuracy**	**F1-Score**	**Precision**	**Recall**
1	0.7459749553	0.6374417138	0.5564786339	0.7459749553
2	0.7316636852	0.618286048	0.5353317482	0.7316636852
3	0.6851520572	0.6781335529	0.6718639887	0.6851520572
4	0.7334525939	0.7098337516	0.6899271273	0.7334525939
5	0.7245080501	0.7116520964	0.7020816835	0.7245080501
Mean	**0.7241502683**	**0.6710694326**	**0.6134003745**	**0.7241502683**

Hasil pelatihan model Bi-LSTM pada dataset latih berita *online* ditunjukkan pada tabel 4. Dari tabel tersebut dapat diketahui bahwa metrik yang didapatkan pada model Bi-LSTM tidak sebaik dua model Transformer sebelumnya. Rata-rata nilai akurasi sebesar 72%, F1-Score sebesar 67%, presisi sebesar 61%, dan Recall sebesar 72% menunjukkan bahwa model ini tidak mengklasifikasikan sentimen lebih baik dari model Transformer sebelumnya. Secara umum model Bi-LSTM

kurang baik dalam melakukan analisis sentimen karena nilai akurasi dan F1-score yang cukup rendah.

Fold terbaik yang didapatkan pada pelatihan model Bi-LSTM ini adalah fold kelima. Meskipun nilai akurasi pada fold keempat lebih tinggi dari fold keempat, namun nilai F1-score pada fold kelima lebih tinggi dari nilai F1-score pada fold keempat. Oleh karena itu, fold kelima dipilih sebagai fold dengan model terbaik.



Gambar 4.6 Grafik *Loss* pada Fold 5 Model Bi-LSTM

Gambar 4.6 menunjukkan grafik nilai *loss* pada pelatihan dan validasi model Bi-LSTM untuk fold model terbaik yaitu fold lima. Berdasarkan grafik *loss* tersebut dapat diketahui bahwa model belajar dari data pelatihan dan berhasil meminimalkan kesalahan pada data pelatihan. Namun, ada peningkatan pada validation *loss* setelah epoch ke-5, yang mungkin menunjukkan bahwa model mulai mengalami overfitting.

Model SVM dengan kernel linear yang dikembangkan pada pembuatan skripsi ini dengan TF-IDF untuk mengubah data menjadi representasi numerik. Model yang dikembangkan menggabungkan TF-IDF dan model SVM dengan kernel linear dalam sebuah pipeline.

Tabel 4.7 Metrik Evaluasi SVM

Fold	Accuracy	F1-Score	Precision	Recall
1	0.83571429	0.7782094193	0.77084656	0.78571429
2	0.80714286	0.7754584	0.7812	0.80714286
3	0.75	0.69498229	0.703125	0.75
4	0.79285714	0.73504018	0.73040353	0.79285714
5	0.81294964	0.76251259	0.76207605	0.76294964
Mean	**0.799732786**	**0.74971394**	**0.74953022**	**0.77973278**

Hasil pelatihan pada model SVM menghasilkan metrik-metrik evaluasi seperti yang ditunjukkan pada Tabel 4.7. Dari tabel tersebut dapat diketahui fold pertama menghasilkan metrik evaluasi paling tinggi dibandingkan dengan fold yang lain. Secara umum, rata-rata metrik evaluasi yang didapatkan pada pelatihan model SVM menunjukkan nilai yang cukup tinggi. Nilai presisi yang tinggi menunjukkan bahwa model cenderung lebih akurat dalam memprediksi sentimen positif, sementara nilai recall yang tinggi menunjukkan bahwa model mampu mengidentifikasi sebagian besar data positif.

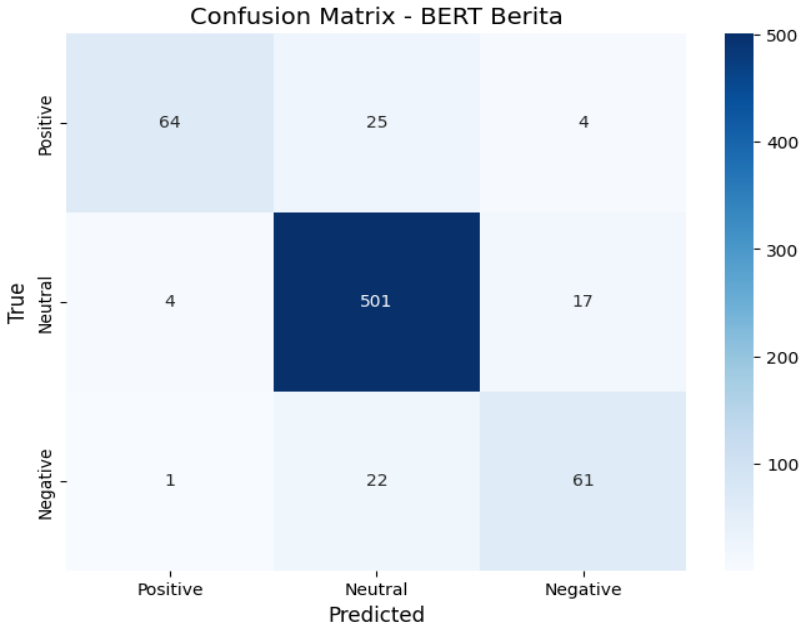
Berdasarkan penjelasan hasil pelatihan model, dapat dilakukan perbandingan model dengan dataset media sosial sebagai data latih seperti yang ditunjukkan pada Tabel 4.8.

Tabel 4.8 Perbandingan Metrik Evaluasi Model Dataset Berita Daring

Model	Evaluation Metrics			
	Mean Accuracy	Mean F1-Score	Mean Precision	Mean Recall
IndoRoBERTa	0.862	0.723	0.739	0.715
IndoBERT	0.854	0.751	0.792	0.751
Bi-LSTM	0.724	0.671	0.613	0.724
SVM	0.799	0.749	0.749	0.779

Hasil evaluasi yang didapatkan, model IndoBERT dapat dianggap sebagai model terbaik untuk dataset berita *online*. Meskipun IndoRoBERTa memiliki nilai akurasi yang cukup tinggi, IndoBERT secara keseluruhan memiliki akurasi dan F1-score yang lebih tinggi. Ini menunjukkan performa yang lebih baik dalam mengklasifikasikan sentimen secara umum. Selain itu, IndoBERT juga memiliki nilai precision dan recall yang cukup tinggi, menunjukkan bahwa model ini mampu mengidentifikasi sebagian besar data positif dengan baik.

Model terbaik yaitu model IndoBERT yang sudah dikembangkan, selanjutnya dilakukan pengujian dengan menggunakan data uji yang telah disiapkan sebelumnya. Data uji didapatkan dari hasil pembagian dataset sebesar 20%. Model IndoBERT yang merupakan model terbaik untuk dataset berita daring diuji dengan data uji yang bertujuan untuk mengetahui performa model ketika menemukan data yang belum pernah dilihat sebelumnya. Berikut adalah *confusion matrix* hasil pengujian model IndoBERT pada data berita *online.*



Gambar 4.7 Confusion Matrix Pengujian Model IndoBERT pada Data Berita

Pada gambar 4.7 ditunjukkan hasil prediksi model IndoBERT menggunakan data latih berita daring. Untuk data berlabel positif, model dapat memprediksi nilai benar sebanyak 64 data dari 93 data. Sedangkan prediksi nilai salah *false positive* sebanyak 5 data dan nilai *false negative* sebanyak 29 data. Untuk sentimen netral,

model memprediksi nilai benar sebanyak 501 dengan nilai *false negative* sebanyak 21 data dan *false positive* sebanyak 47 data. Sedangkan untuk data dengan sentimen negatif terdapat 61 data diprediksi dengan benar dengan *false positive* sebanyak 21 data dan *false negative* sebanyak 23 data. Secara keseluruhan, model IndoBERT menunjukkan performa yang baik, terutama dalam mengidentifikasi sentimen netral. Akurasi keseluruhan model dapat dihitung dengan (TP + TN) / Total data = (64 + 501 + 61) / 626 = 89.5%. Sedangkan untuk rata-rata nilai F1-Score sebesar 83%. Hal ini berarti model cukup baik dalam mengidentifikasi sentimen positif dan negatif, namun masih terdapat beberapa kesalahan klasifikasi. Model cenderung lebih sering salah memprediksi sentimen positif sebagai netral, dan sentimen negatif sebagai netral.

4.2.2. Dataset Media Sosial

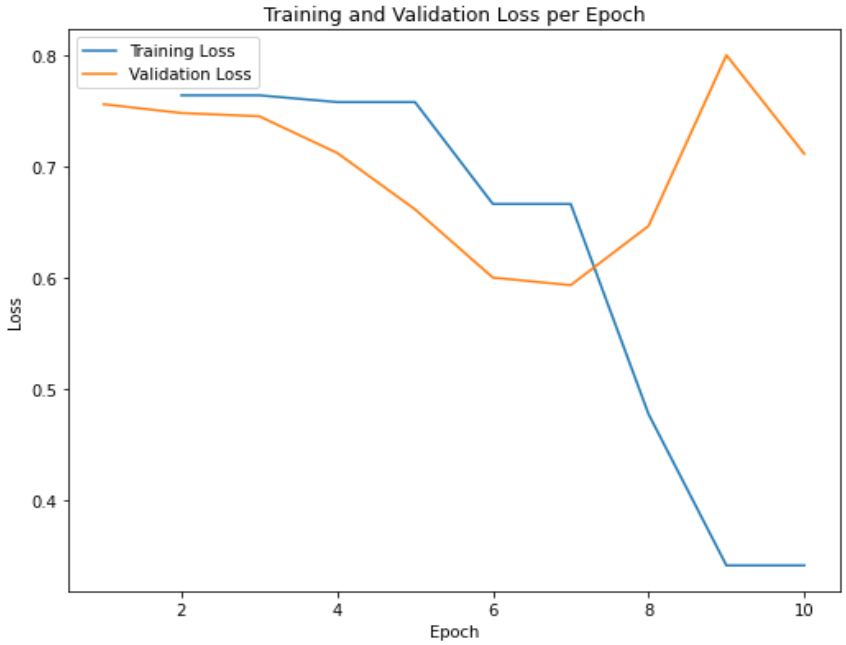
Pelatihan model pada dataset media sosial sama dengan yang digunakan untuk dataset berita *online*. Model dilatih menggunakan data latih sebanyak 80% dari seluruh jumlah data pada dataset. K-fold cross validation dengan K sebanyak 5 juga diterapkan dalam pelatihan untuk mengoptimalkan performa model dan menghindari overfitting.

Model IndoRoBERTa yang dikembangkan untuk dataset media sosial pada pengembangan skripsi ini sama dengan model yang dikembangkan pada model untuk dataset berita *online*. *Hyperparameter fine-tuning* yang diterapkan juga sama yaitu 10 epoch, *optimizer* adam, dan 8 batch size. Perbedaannya hanya pada dataset pelatihan yang digunakan.

Tabel 4.9 Metrik Evaluasi Model IndoRoBERTa Dataset Media Sosial

Fold	Accuracy	F1-Score	Precision	Recall
1	0.8707753479	0.8482861109	0.8700355489	0.8338268862
2	0.8784860558	0.8475398529	0.850901505	0.8452730834
3	0.8565737052	0.8285522684	0.8384986702	0.8215055159
4	0.8545816733	0.8333893622	0.8333775578	0.8336158434
5	0.8625498008	0.8353094198	0.8331721462	0.8376391048
Mean	**0.8645933166**	**0.8386154029**	**0.8451970856**	**0.8343720867**

Berdasarkan tabel hasil evaluasi pada model IndoRoBERTa, dapat disimpulkan bahwa fold pertama merupakan fold terbaik. Hal ini didasarkan pada beberapa metrik evaluasi akurasi dan F1-Score yang paling tinggi diantara fold lainnya. Secara umum, model ini dapat melakukan analisis sentimen pada data latih media sosial dengan baik. Hal ini dapat diketahui dari nilai rata-rata tiap metrik memiliki nilai yang cukup tinggi.



Gambar 4.8 Grafik *Loss* Fold 1 Model IndoRoBERTa

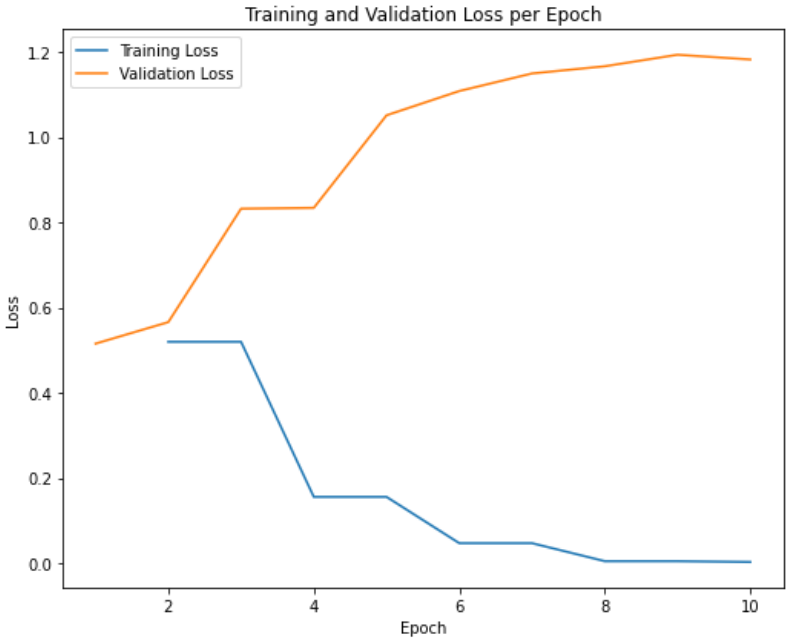
Grafik yang ditunjukkan pada Gambar 4.9 menggambarkan nilai *training loss* yang semakin menurun seiring dengan bertambahnya epoch. Pada sekitar epoch ke-7, *loss* pelatihan tiba-tiba menurun drastis hingga mendekati nol. Ini menandakan bahwa model sangat baik dalam mempelajari data pelatihan. Di sisi lain, kurva *loss* validasi (validation *loss*) menunjukkan tren yang kurang stabil. Meskipun pada awalnya *loss* validasi menurun seiring dengan menurunnya *loss* pelatihan, mulai dari epoch ke-6, *loss* validasi mengalami peningkatan yang signifikan hingga mencapai puncaknya pada epoch ke-8 sebelum akhirnya menurun lagi pada epoch ke-9 dan ke-10.

Model IndoBERT yang dikembangkan dalam pembuatan skripsi ini sama dengan model IndoBERT yang dikembangkan untuk dataset berita *online*. Namun, untuk model ini dilatih dengan menggunakan dataset media sosial yang sudah dikumpulkan.

Tabel 4.10 Metrik Evaluasi Model IndoBERT

Fold	Accuracy	F1-Score	Precision	Recall
1	0.8469184891	0.819354266	0.8334912019	0.8102347465
2	0.8605577689	0.821127182	0.8352676793	0.8103904884
3	0.8386454183	0.810101598	0.8281480307	0.7986289206
4	0.8187250996	0.77797589	0.7939921085	0.7672915429
5	0.8585657371	0.813421054	0.8342349024	0.8004698807
Mean	**0.8446825026**	**0.80839599**	**0.8250267846**	**0.7974031158**

Tabel 4.10 menampilkan hasil evaluasi model Bi-LSTM pada dataset media sosial. Berdasarkan metrik akurasi dan F1-score dapat disimpulkan bahwa fold dua merupakan fold terbaik. Fold dua memiliki akurasi cukup tinggi (86%) dengan F1-score tertinggi (82%) dibandingkan dengan fold lainnya. Secara keseluruhan, model IndoBERT yang dikembangkan menunjukkan performa yang cukup seimbang dan konsisten berdasarkan rata-rata pada empat metrik evaluasi, sehingga dapat dianggap sebagai model yang cukup baik.



Gambar 4.9 Grafik *Loss* pada Fold 2 Model IndoBERT

Gambar 4.10 menunjukkan grafik nilai *loss* untuk data *training* dan validasi. Nilai *loss* pelatihan memberikan tren menurun secara perlahan hingga mencapai nilai mendekati nol pada epoch terakhir. Ini menunjukkan model terus belajar namun dengan tingkat perbaikan yang semakin kecil. Sedangkan nilai *loss* untuk data validasi memiliki tren yang cenderung naik. Ini dapat mengindikasikan bahwa model *overfitting* yaitu model terlalu fokus pada data pelatihan dan tidak dapat beradaptasi dengan baik pada data baru (data validasi).

Model Bi-LSTM yang dikembangkan menggunakan arsitektur yang sama seperti model Bi-LSTM untuk dataset berita *online*. Pelatihan pada model Bi-LSTM yang dikembangkan dengan hyperparameter yang sama seperti hyperparameter yang diterapkan pada model berbasis transformer sebelumnya. Hasil pelatihan model Bi-LSTM dengan dataset media sosial sebagai data latih ditunjukkan dengan metrik evaluasi pada Tabel 4.4 berikut.

Tabel 4.11 Tabel Metrik Evaluasi Bi-LSTM

Fold	**Accuracy**	**F1-Score**	**Precision**	**Recall**
1	0.73161033797	0.73944405	0.755221723	0.731610337
2	0.74302788844	0.745894636	0.750451767	0.731610337
3	0.69322709163	0.697523142	0.711415808	0.693227091
4	0.69721115537	0.709413603	0.729961807	0.697211155
5	0.74302788844	0.74753624	0.766119526	0.743027888
Mean	**0.7216208724**	**0.727962334**	**0.742634126**	**0.719337361**

Tabel 4.11 menunjukkan bahwa fold dua dan fold lima memiliki akurasi terbaik dan sama. Namun, untuk menentukan fold dengan performa terbaik juga perlu dilihat pada nilai F1-Score. Oleh karena itu, fold kelima dipilih sebagai fold dengan metrik evaluasi terbaik. Secara keseluruhan, model Bi-LSTM menunjukkan performa yang baik dalam mengklasifikasikan sentimen teks. Model ini memiliki

rata-rata akurasi dan F1-score yang cukup baik, menunjukkan kemampuan yang baik dalam memprediksi sentimen secara umum.



Gambar 4.10 Grafik *Loss* Fold 5 Model Bi-LSTM

Gambar 4.10 merupakan grafik yang menunjukkan perubahan nilai *loss* pada *training* dan validation terhadap epoch yang dihasilkan pada fold terbaik model Bi-LSTM yaitu fold kelima. Pada grafik tersebut nilai *training loss* pada model Bi-LSTM secara umum cenderung menurun seiring bertambahnya epoch meskipun pada epoch delapan dan sepuluh terjadi kenaikan *loss* kembali. Nilai *loss* terendah dicapai sekitar epoch ke-9, menunjukkan bahwa model mencapai performa terbaik pada titik tersebut. Sedangkan untuk nilai validation *loss* cenderung fluktuatif pada setiap pertambahan epoch. Dari hasil tersebut menunjukkan bahwa model semakin baik dalam mempelajari pola-pola dalam data pelatihan dan mengurangi kesalahan prediksi.

Model SVM dengan kernel linear dan representasi teks menggunakan TF-IDF dilatih pada dataset media sosial. Model yang dikembangkan menggabungkan TF-IDF dan model SVM dengan kernel linear dalam sebuah pipeline.

Tabel 4.12 Tabel Metrik Evaluasi SVM

Fold	Accuracy	F1-Score	Precision	Recall
1	0.79324056	0.78580843	0.78862602	0.79324056
2	0.82270916	0.81399194	0.81509002	0.82270916
3	0.78486056	0.77659432	0.77832104	0.78486056
4	0.75896414	0.74877467	0.75297135	0.75896414
5	0.80478088	0.80157005	0.80103442	0.80478088
Mean	**0.79291106**	**0.785347882**	**0.78720857**	**0.79291106**

Hasil pelatihan pada model SVM menghasilkan metrik-metrik evaluasi pada data latih seperti yang ditunjukkan pada Tabel 4.12. Dari tabel tersebut dapat diketahui fold kedua menghasilkan evaluasi metrik paling tinggi dibandingkan dengan fold yang lain. Hal ini berarti fold kedua menghasilkan model terbaik untuk model SVM. Rata-rata metrik evaluasi yang didapatkan pada pelatihan model SVM menunjukkan nilai yang cukup stabil. Nilai presisi yang tinggi menunjukkan bahwa model cenderung lebih akurat dalam memprediksi sentimen positif, sementara nilai recall yang tinggi menunjukkan bahwa model mampu mengidentifikasi sebagian besar data positif.

Berdasarkan penjelasan hasil pelatihan model, dapat dilakukan perbandingan model dengan dataset media sosial sebagai data latih seperti yang ditunjukkan pada Tabel 4 13.

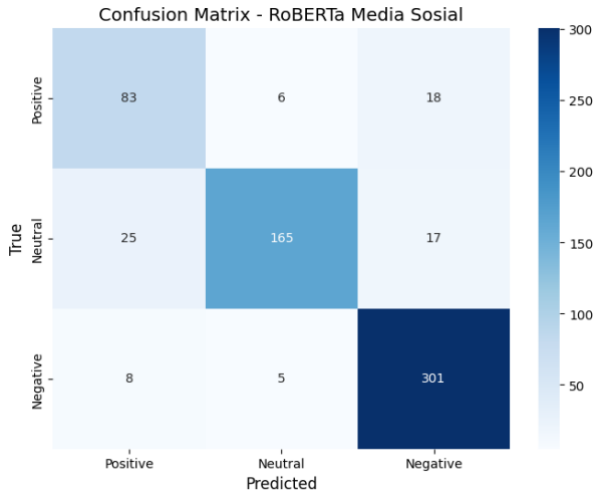
Tabel 4.13 Perbandingan Metrik Evaluasi Model Media Sosial

Model	Metric Evaluation			
	Mean Accuracy	Mean F1-Score	Mean Precision	Mean Recall
IndoRoBERTa	0.823	0.795	0.814	0.799
IndoBERT	0.744	0.677	0.638	0.744

Model	Metric Evaluation			
	Mean Accuracy	**Mean F1-Score**	**Mean Precision**	**Mean Recall**
Bi-LSTM	0.721	0.728	0.743	0.719
SVM	0.793	0.786	0.788	0.793

Hasil evaluasi pelatihan model yang didapatkan, model IndoRoBERTa dapat dianggap sebagai model terbaik untuk dataset media sosial. Meskipun SVM juga memiliki nilai yang tinggi untuk sentimen positif, IndoRoBERTa secara keseluruhan memiliki akurasi dan F1-score yang lebih tinggi, menunjukkan performa yang lebih baik dalam mengklasifikasikan sentimen secara umum. Selain itu, IndoRoBERTa juga memiliki recall yang tinggi, menunjukkan bahwa model ini mampu mengidentifikasi sebagian besar data positif dengan baik.

Model terbaik yang telah didapatkan selanjutnya digunakan untuk pengujian pada data yang telah disimpan sebagai data uji. Data uji ini didapatkan dari hasil pembagian 20% dari dataset secara keseluruhan. Hasil dari pengujian ini dapat digunakan sebagai evaluasi model pada data baru yang belum dilihat. Pengujian pada model IndoRoBERTa untuk data uji pada dataset media sosial menghasilkan *confusion matrix* berikut.

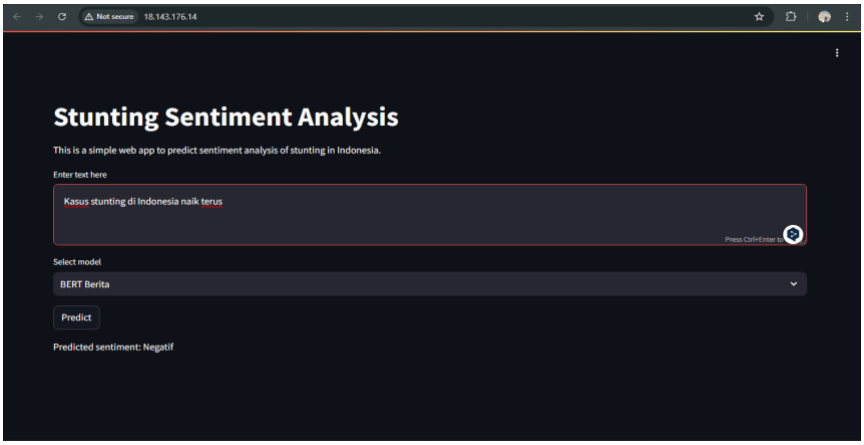


Gambar 4.11 Confusion Matrix pada Pengujian Model IndoRoBERTa

Pada gambar 4.11 ditunjukkan hasil prediksi model IndoRoBERTa menggunakan data latih media sosial. Untuk data berlabel positif, model dapat memprediksi nilai benar sebanyak 83 data dari 107 data berlabel positif. Sedangkan prediksi nilai salah *false positive* sebanyak 32 data dan nilai *false negative* sebanyak 24 data. Untuk sentimen netral, model memprediksi nilai benar sebanyak 165 dengan nilai *false negative* sebanyak 42 data dan *false positive* sebanyak 11 data. Sedangkan untuk data dengan sentimen negatif terdapat 301 data diprediksi dengan benar dengan *false positive* sebanyak 35 data dan *false negative* sebanyak 13 data. Secara keseluruhan, model IndoRoBERTa menunjukkan performa yang baik, terutama dalam mengidentifikasi sentimen netral. Akurasi keseluruhan model dapat dihitung dengan (TP + TN) / Total data = (83 + 165 + 301) / 626 = 87.4%. Sedangkan untuk rata-rata F1-Score sebesar 78%. Secara keseluruhan, model IndoRoBERTa pada dataset media sosial menunjukkan performa yang baik dalam mengidentifikasi sentimen positif, negatif, dan netral. Namun, model masih terdapat beberapa kesalahan dalam melakukan klasifikasi sentimen.

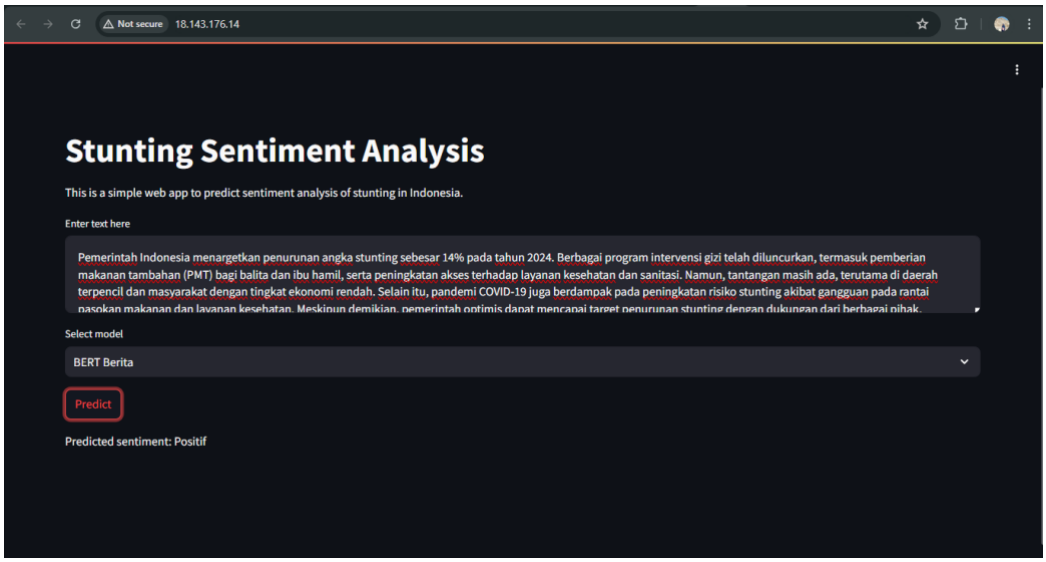
4.3. Analisis Deployment

Model terbaik dari hasil pelatihan pada kedua dataset, yaitu dataset berita daring dan media sosial, kemudian diterapkan pada website sederhana. Website ini menggunakan *framework* Streamlit yang tersedia pada bahasa pemrograman Python. Pada website ini terdapat dua fitur, yaitu fitur untuk memprediksi kelas sentimen teks media sosial dan fitur untuk prediksi kelas sentimen pada teks berita daring.



Gambar 4.12 Fitur Analisis Sentimen Media Sosial pada Streamlit

Gambar 4.12 menunjukkan hasil implementasi model terbaik untuk dataset media sosial yaitu model IndoRoBERTa ke dalam website sederhana. Pada tampilan website mengandung beberapa elemen seperti judul website, form untuk input teks yang akan dianalisis, *drop down* untuk memilih model sesuai dengan kategori input teks, tombol untuk prediksi, dan text yang akan mengeluarkan label sentimen dari teks yang dimasukkan. Dalam website tersebut, model telah diimplementasikan dan dapat melakukan klasifikasi sentimen dengan baik.



Gambar 4.13 Fitur Analisis Sentimen Teks Berita pada Streamlit

Gambar 4.13 menunjukkan fitur analisis sentimen untuk teks berita sebagai implementasi dari model IndoBERT. Pada fitur ini memiliki elemen yang sama seperti fitur untuk teks media sosial. Untuk melakukan analisis sentimen pada teks berita, pengguna perlu memilih model IndoBERT pada *drop down* yang tersedia. Hasil implementasi pada website ini menunjukkan bahwa model dapat diimplementasikan dan mampu memprediksi teks berita dengan baik.

BAB V
KESIMPULAN

5.1. Kesimpulan

Berdasarkan hasil penelitian pada skripsi "*Analisis Sentimen pada Big Data Kasus Stunting di Indonesia (Tahun 2019-2024)*", dapat disimpulkan sebagai berikut:

1. Analisis sentimen pada penelitian ini didapatkan bahwa isu stunting mendapatkan perhatian yang cukup besar dari publik, baik di media sosial maupun berita daring. Sentimen negatif mendominasi pada media sosial, menunjukkan adanya kritik dan ketidakpuasan terhadap penanganan stunting. Sedangkan sentimen netral mendominasi pada berita daring, menunjukkan bahwa berita cenderung menyajikan informasi secara lebih objektif.
2. Penelitian analisis sentimen pada *Big Data* kasus stunting di Indonesia berhasil mengimplementasikan dan membandingkan empat model *Machine Learning* (SVM, Bi-LSTM, IndoBERT, IndoRoBERTa) untuk analisis sentimen terkait kasus stunting di Indonesia selama periode 2019-2024 menggunakan data dari media sosial (Twitter dan YouTube) serta berita daring (Detik.com dan CNN Indonesia).
3. Model IndoBERT berhasil memprediksi klasifikasi sentimen dengan performa baik pada data berita daring dengan akurasi sebesar 89% dan rata-rata F1-Score sebesar 83% pada data uji. Model IndoRoBERTa berhasil memprediksi klasifikasi sentimen dengan performa baik untuk data media sosial dengan akurasi sebesar 87% den rata-rata F1-Score sebesar 78% pada data uji.

5.2. Saran

Berdasarkan hasil penelitian pada skripsi "*Analisis Sentimen pada Big Data Kasus Stunting di Indonesia (Tahun 2019-2024)*", penulis memiliki saran untuk pengembangan selanjutnya sebagai berikut:

1. Eksplorasi dan pengembangan model lainnya seperti model ensemble untuk meningkatkan performa yang lebih baik dengan waktu komputasi yang

lebih cepat serta mampu menangani berbagai jenis data teks dengan karakteristik yang berbeda-beda.

2. Penggunaan dataset yang lebih besar dengan jumlah pada setiap kelas sentiment yang lebih seimbang untuk meningkatkan performa model klasifikasi sentimen, terutama pada kelas yang memiliki jumlah data lebih sedikit, sehingga model dapat mempelajari pola-pola yang lebih representatif dan menghasilkan prediksi yang lebih akurat.

DAFTAR PUSTAKA

[1] R. Kusumaningrum, T. A. Indihatmoko, S. R. Juwita, A. F. Hanifah, K. Khadijah, and B. Surarso, "Benchmarking of Multi-Class Algorithms for Classifying Documents Related to Stunting," *Appl. Sci.*, vol. 10, no. 23, Art. no. 23, Dec. 2020, doi: 10.3390/app10238621.

[2] S. Sukmawati, H. Hendrayati, C. Chaerunnimah, and N. Nurhumaira, "Status Gizi Ibu Saat Hamil, Berat Badan Lahir Bayi Dengan Stunting Pada Balita Usia 06-36 Bulan Di Puskesmas Bontoa," *Media Gizi Pangan*, vol. 25, no. 1, p. 18, Jun. 2018, doi: 10.32382/mgp.v25i1.55.

[3] M. E. Setiyawati, L. P. Ardhiyanti, E. N. Hamid, N. A. T. Muliarta, and Y. J. Raihanah, "Studi Literatur: Keadaan Dan Penanganan Stunting Di Indonesia," *IKRA-ITH Hum. J. Sos. Dan Hum.*, vol. 8, no. 2, Art. no. 2, Jul. 2024, doi: 10.37817/ikraith-humaniora.v8i2.3113.

[4] R. Aryanti, T. Misriati, and A. Sagiyanto, "Analisis Sentimen Aplikasi Primaku Menggunakan Algoritma Random Forest dan SMOTE untuk Mengatasi Ketidakseimbangan Data," vol. 5, no. 1, Art. no. 1, 2023.

[5] M. Y. Abuhashesh *et al.*, "The Role of Social Media in Raising Public Health Awareness during the Pandemic COVID-19: An International Comparative Study," *Informatics*, vol. 8, no. 4, p. 80, Nov. 2021, doi: 10.3390/informatics8040080.

[6] A. S. Aribowo, "Analisis Sentimen Publik pada Program Kesehatan Masyarakat menggunakan Twitter Opinion Mining," 2018.

[7] C. N. Walters, H. Rakotomanana, J. J. Komakech, and B. J. Stoecker, "Maternal determinants of optimal breastfeeding and complementary feeding and their association with child undernutrition in Malawi (2015–2016)," *BMC Public Health*, vol. 19, no. 1, p. 1503, Dec. 2019, doi: 10.1186/s12889-019-7877-8.

[8] N. Rusliani, W. R. Hidayani, and H. Sulistyoningsih, "Literature Review: Faktor-Faktor yang Berhubungan dengan Kejadian Stunting pada Balita," *Bul. Ilmu Kebidanan Dan Keperawatan*, vol. 1, no. 01, pp. 32–40, Aug. 2022, doi: 10.56741/bikk.v1i01.39.

[9] G. Muthia, E. Edison, and E. Yantri, “Evaluasi Pelaksanaan Program Pencegahan Stunting Ditinjau dari Intervensi Gizi Spesifik Gerakan 1000 HPK Di Puskesmas Pegang Baru Kabupaten Pasaman,” *J. Kesehat. Andalas*, vol. 8, no. 4, Jan. 2020, doi: 10.25077/jka.v8i4.1125.

[10] S. Hendrawati, W. Mardiah, and R. A. Febri, “PEMENUHAN VITAMIN D PADA IBU HAMIL UNTUK MENCEGAH STUNTING: SEBUAH NARRATIVE REVIEW,” *J. Ilmu Keperawatan Dan Kebidanan*, vol. 15, no. 1, pp. 50–67, Feb. 2024, doi: 10.26751/jikk.v15i1.2178.

[11] M. Marni, D. Soares, T. Wahyudi, M. Irfan, and S. Nurul, “Analysis Stunting Prevention and Intervention: A Literatur Review,” *Proc. Int. Conf. Nurs. Health Sci.*, vol. 3, no. 1, pp. 27–36, May 2022, doi: 10.37287/picnhs.v3i1.1110.

[12] A. Nuradhiani, “Upaya Pencegahan Stunting Sejak Dini melalui Pemberian Edukasi pada Ibu Hamil,” *J. Gizi Kerja Dan Produkt.*, vol. 3, no. 1, Art. no. 1, May 2022, doi: 10.52742/jgkp.v3i1.15452.

[13] Kiftyah and K. I. P. Sari, “PEMERIKSAAN KESEHATAN DAN PENYULUHAN PENCEGAHAN STUNTING DENGAN POLA ASUH DAN POLA MAKAN YANG BENAR,” *J. Community Serv. Consort.*, vol. 3, no. 2, Nov. 2023, doi: 10.37715/consortium.v3i2.4263.

[14] R. H. Hariri, E. M. Fredericks, and K. M. Bowers, “Uncertainty in *Big Data* analytics: survey, opportunities, and challenges,” *J. Big Data*, vol. 6, no. 1, p. 44, Dec. 2019, doi: 10.1186/s40537-019-0206-3.

[15] Research Student, Department of Computer Science, Savitribai Phule Pune University (SPPU), Pune, Maharashtra, India., V. Keskar*, Dr. J. Y. Yadav, Assistant Professor, Department of Computer Science, Savitribai Phule Pune University, Pune, Maharashtra, India., Dr. A. H. Kumar, and Research Guide, Department of Computer Science, Savitribai Phule Pune University, Pune, Maharashtra, India., “5V’s of *Big Data* Attributes and their Relevance and Importance across Domains,” *Int. J. Innov. Technol. Explor. Eng.*, vol. 9, no. 11, pp. 154–163, Sep. 2020, doi: 10.35940/ijitee.K7709.0991120.

[16] S. Dash, S. K. Shakyawar, M. Sharma, and S. Kaushik, “*Big Data* in healthcare: management, analysis and future prospects,” *J. Big Data*, vol. 6,

no. 1, p. 54, Dec. 2019, doi: 10.1186/s40537-019-0217-0.

[17] N. Ahmed, A. L. C. Barczak, T. Susnjak, and M. A. Rashid, "A comprehensive performance analysis of Apache Hadoop and Apache Spark for large scale data sets using HiBench," *J. Big Data*, vol. 7, no. 1, p. 110, Dec. 2020, doi: 10.1186/s40537-020-00388-5.

[18] M.A.Raza, H. U. R. Kayani, M. T. Aslam, A. Suleman, Aimen, and M. Gul, "REVIEW: *BIG DATA* V'S MODELS, CHALLENGES, HADOOP ECOSYSTEM, ISSUES, USES, BENEFITS AND APPLICATIONS," *Pak. J. Sci. Res.*, vol. 3, no. 1, pp. 47–60, Jun. 2023, doi: 10.57041/pjosr.v3i1.967.

[19] J. Zhu and J. Wang, "Based on Data Mining Algorithm of Data Mining Research," in *Advances in Transdisciplinary Engineering*, C.-H. Chen, A. Scapellato, A. Barbiero, and D. G. Korzun, Eds., IOS Press, 2023. doi: 10.3233/ATDE231061.

[20] E. Budianita, E. P. Cynthia, A. Pranata, and D. Abimanyu, "Pendekatan berbasis *Machine Learning* dan Leksikal Pada Analisis Sentimen," 2022.

[21] E. Sholihatin *et al.*, "Pemanfaatan Teknologi Chat GPT dalam Pembelajaran Bahasa Indonesia di Era Digital pada Mahasiswa Universitas Pembangunan Nasional Veteran Jawa Timur," 2023.

[22] S. Tabinda Kokab, S. Asghar, and S. Naz, "Transformer-based deep learning models for the sentiment analysis of social media data," *Array*, vol. 14, p. 100157, Jul. 2022, doi: 10.1016/j.array.2022.100157.

[23] A. Chiche and B. Yitagesu, "Part of speech tagging: a systematic review of deep learning and *Machine Learning* approaches," *J. Big Data*, vol. 9, no. 1, p. 10, Jan. 2022, doi: 10.1186/s40537-022-00561-y.

[24] J. Yu, B. Bohnet, and M. Poesio, "Named Entity Recognition as Dependency Parsing." arXiv, 2020. doi: 10.48550/ARXIV.2005.07150.

[25] A. Roihan, P. A. Sunarya, and A. S. Rafika, "Pemanfaatan *Machine Learning* dalam Berbagai Bidang: Review paper," *IJCIT Indones. J. Comput. Inf. Technol.*, vol. 5, no. 1, May 2020, doi: 10.31294/ijcit.v5i1.7951.

[26] H. Abijono, P. Santoso, and N. L. Anggreini, "ALGORITMA SUPERVISED LEARNING DAN UNSUPERVISED LEARNING DALAM PENGOLAHAN DATA," *J. Teknol. Terap. G-Tech*, vol. 4, no. 2, pp. 315–

318, Apr. 2021, doi: 10.33379/gtech.v4i2.635.

[27] F. Fahira, Z. A. Dwiyanti, and R. Habibi, "Pendekatan Supervised Learning untuk Diagnosa Kehamilan," *J. Tekno Insentif*, vol. 17, no. 2, pp. 99–111, Oct. 2023, doi: 10.36787/jti.v17i2.1102.

[28] K. I. Gunawan and J. Santoso, "Multilabel Text Classification Menggunakan SVM dan Doc2Vec Classification Pada Dokumen Berita Bahasa Indonesia," *J. Inf. Syst. Hosp. Technol.*, vol. 3, no. 01, pp. 29–38, Apr. 2021, doi: 10.37823/insight.v3i01.126.

[29] S. Rabbani, D. Safitri, N. Rahmadhani, A. A. F. Sani, and M. K. Anam, "Perbandingan Evaluasi Kernel SVM untuk Klasifikasi Sentimen dalam Analisis Kenaikan Harga BBM: Comparative Evaluation of SVM Kernels for Sentiment Classification in Fuel Price Increase Analysis," *MALCOM Indones. J. Mach. Learn. Comput. Sci.*, vol. 3, no. 2, pp. 153–160, Oct. 2023, doi: 10.57152/malcom.v3i2.897.

[30] O. D. Amelia, A. M. Soleh, and S. Rahardiantoro, "Pemodelan Support Vector Machine Data Tidak Seimbang Keberhasilan Studi Mahasiswa Magister IPB," *Xplore J. Stat.*, vol. 2, no. 1, pp. 33–40, Jun. 2018, doi: 10.29244/xplore.v2i1.76.

[31] S. S. Maulina Putri, M. Arhami, and H. Hendrawaty, "Penerapan Metode SVM pada Klasifikasi Kualitas Air," *J. Artif. Intell. Softw. Eng. J-AISE*, vol. 3, no. 2, p. 93, Nov. 2023, doi: 10.30811/jaise.v3i2.4630.

[32] H. N. Irmanda and Ria Astriratma, "Klasifikasi Jenis Pantun Dengan Metode Support Vector Machines (SVM)," *J. RESTI Rekayasa Sist. Dan Teknol. Inf.*, vol. 4, no. 5, pp. 915–922, Oct. 2020, doi: 10.29207/resti.v4i5.2313.

[33] G. Van Houdt, C. Mosquera, and G. Nápoles, "A review on the long short-term memory model," *Artif. Intell. Rev.*, vol. 53, no. 8, pp. 5929–5955, Dec. 2020, doi: 10.1007/s10462-020-09838-1.

[34] A. Vaswani *et al.*, "Attention Is All You Need," no. arXiv:1706.03762. arXiv, Aug. 01, 2023. Accessed: Jan. 30, 2024. [*Online*]. Available: http://arxiv.org/abs/1706.03762

[35] K. He, X. Zhang, S. Ren, and J. Sun, "Deep Residual Learning for Image Recognition." arXiv, Dec. 10, 2015. Accessed: Jul. 01, 2024. [*Online*].

Available: http://arxiv.org/abs/1512.03385

[36] M. Noor, W. Gata, R. Risnandar, F. Fakhrudin, and A. Novitarani, "Optimization of Sentiment Analysis of Program Sembako(BPNT) Based on Twitter," *J. Appl. Eng. Technol. Sci. JAETS*, vol. 4, no. 1, Art. no. 1, Oct. 2022, doi: 10.37385/jaets.v4i1.1006.

[37] M. T. Uliniansyah *et al.*, "Twitter dataset on public sentiments towards biodiversity policy in Indonesia," *Data Brief*, vol. 52, p. 109890, Feb. 2024, doi: 10.1016/j.dib.2023.109890.

[38] B. A. Maulana, M. J. Fahmi, A. M. Imran, and N. Hidayati, "Analisis Sentimen Terhadap Aplikasi Pluang Menggunakan Algoritma Naive Bayes dan Support Vector Machine (SVM): Sentiment Analysis of Pluang Applications With Naive Bayes and Support Vector Machine (SVM) Algorithm," *MALCOM Indones. J. Mach. Learn. Comput. Sci.*, vol. 4, no. 2, pp. 375–384, Feb. 2024, doi: 10.57152/malcom.v4i2.1206.

[39] A. Jaya, "Analisis Sentimen pandangan public terhadap profesi PNS (Pegawai Negeri Sipil) dari Twiter menerapkan Indonesian Roberta Base Sentiment Classifier," vol. 4, no. 1, 2023.

[40] A. Elhan, M. K. D. Hardhienata, Y. Herdiyeni, S. H. Wijaya, and J. Adisantoso, "Analisis Sentimen Pengguna Twitter terhadap Vaksinasi COVID-19 di Indonesia menggunakan Algoritme Random Forest dan BERT," *J. Ilmu Komput. Dan Agri-Inform.*, vol. 9, no. 2, pp. 199–211, Nov. 2022, doi: 10.29244/jika.9.2.199-211.

[41] Universitas Methodist Indonesia *et al.*, "MODEL BIDIRECTIONAL LSTM UNTUK PEMROSESAN SEKUENSIAL DATA TEKS SPAM," *METHOMIKA J. Manaj. Inform. Dan Komputerisasi Akunt.*, vol. 7, no. 2, pp. 265–271, Oct. 2023, doi: 10.46880/jmika.Vol7No2.pp265-271.

[42] S. A. Hicks *et al.*, "On evaluation metrics for medical applications of artificial intelligence," *Sci. Rep.*, vol. 12, no. 1, p. 5979, Apr. 2022, doi: 10.1038/s41598-022-09954-8.

[43] H. Namdari, A. Haghighi, and S. M. Ashrafi, "Short-term urban water demand forecasting; application of 1D convolutional neural network (1D

CNN) in comparison with different deep learning schemes," *Stoch. Environ. Res. Risk Assess.*, Sep. 2023, doi: 10.1007/s00477-023-02565-3.

[44] Mr. A. Soni, Mr. R. Pachouri, and Mr. A. Jain, "A Cloud Security Attack Detection Using Proposed BGRU and Bi-LSTM Models," *Int. J. Res. Appl. Sci. Eng. Technol.*, no. 9, pp. 815–823, Sep. 2022, doi: 10.22214/ijraset.2022.46739.

[45] R. Wirth and J. Hipp, "CRISP-DM: Towards a Standard Process Model for Data Mining".

[46] D. Atmajaya, A. Febrianti, and H. Darwis, "Metode SVM dan Naive Bayes untuk Analisis Sentimen ChatGPT di Twitter," *Indones. J. Comput. Sci.*, vol. 12, no. 4, Aug. 2023, doi: 10.33022/ijcs.v12i4.3341.

LAMPIRAN

Lampiran 1 Lembar Kontrol Bimbingan

	LEMBAR KONTROL BIMBINGAN TUGAS AKHIR/SKRIPSI	No. PM	7.5.18/L1
		Revisi	2
		Tanggal	1 Juli 2010
		Halaman	1 / 2

Nama : CHOIRUZZIA ABDILLA AUDIVATSANI Kelas : TI-4A NIM : 4.33.20.0.05	Judul Tugas Akhir/Skripsi : ANALISIS SENTIMEN PADA BIG DATA KASUS STUNTING DI INDONESIA (TAHUN 2019-2024)

No	Tanggal	Uraian	Tandatangan Pembimbing
1.	26 Januari 2024	Bimbingan topik skripsi	
2.	~~Bimbingan~~		
2.	05 Februari 2024	Bimbingan proposal skripsi dan teknis pengerjaan skripsi	
3.	15 April 2024	Bimbingan progres pengerjaan dataset & pembuatan model	
4.	17 Mei 2024	Laporan hasil preprocessing dataset	
5.	27 Mei 2024	Laporan hasil training ulang model	
6.	13 Juni 2024	Bimbingan laporan skripsi bab 1 dan 2	
7.	24 Juni 2024	Bimbingan bab 3 dan 4 laporan skripsi	
8.	8 Juli 2024	Bimbingan laporan skripsi bab 4	

Semarang,
Pembimbing I

Dr. Ir. Kurnianingsih, S.T., M.T.
NIP 197904262003122002

	LEMBAR KONTROL BIMBINGAN TUGAS AKHIR/SKRIPSI	No. PM	7.5.18/L1
		Revisi	2
		Tanggal	1 Juli 2010
		Halaman	1 / 2

Nama : CHOIRUZZIA ABDILLA AUDIVATSANI Kelas : TI-4A NIM : 4.33.20.0.05	Judul Tugas Akhir/Skripsi : ANALISIS SENTIMEN PADA BIG DATA KASUS STUNTING DI INDONESIA (TAHUN 2019-2024)

No	Tanggal	Uraian	Tandatangan Pembimbing
1.	Jum'at, 26-1-2024	Bimbingan topik skripsi	
2.	3 Februari 2024	Bimbingan laporan skripsi	
3.	20 Februari 2024	Bimbingan strategi pengumpulan data & labeling	
4.	21 Mei 2024	Bimbingan dataset & preprocessing	
5.	26 Juni 2024	Bimbingan bab 1 & 2 laporan skripsi	
6.	2 Juli 2024	Bimbingan bab 3 laporan skripsi	
7.	10 Juli 2024	Bimbingan bab 4 laporan skripsi	
8.	11 Juli 2024	Finalisasi draft laporan skripsi dan PPT	

Semarang,
Pembimbing II

Wiktasari, S.T, M.Kom.
NIP 198703272019032012

Lampiran 2 Lembar selesai bimbingan

	SURAT KETERANGAN SELESAI BIMBINGAN SKRIPSI	No. FPM	7.5.18/L2
		Revisi	2
		Tanggal	1 Juli 2010
		Halaman	1 / 2

JURUSAN TEKNIK ELEKTRO	SURAT KETERANGAN SELESAI BIMBINGAN SKRIPSI

Kepada:
Yth. Ketua Program Studi Teknologi Rekayasa Komputer
Politeknik Negeri Semarang

Yang bertanda tangan di bawah ini, Pembimbing I dan Pembimbing II menerangkan bahwa:

No.	Nama	NIM	Kelas
1	Choiruzzia Abdilla Audivatsani	4.33.20.0.05	TI-4A

Dengan judul Tugas Akhir:

" Analisis Sentimen pada Big Data Kasus Stunting di Indonesia (Tahun 2019-2024)"

Benar-benar telah menyelesaikan pembuatan skripsi dan siap untuk melakukan ujian wawancara skripsi.

Semarang, 10 Juli 2023

Pembimbing I,

Dr. Ir. Kurnianingsih, S.T., M.T.
NIP 197904262003122002

Pembimbing II,

Wiktasari S.T., M.Kom
NIP 198703272019022012

Lampiran 3 Lembar Siap Ujian Skripsi

	SURAT KETERANGAN SIAP UJIAN SKRIPSI	No. FPM	7.5.18/L6
		Revisi	2
		Tanggal	1 Juli 2010
		Halaman	1 / 1

SURAT KETERANGAN

SIAP UJIAN SKRIPSI

Kepada:
Yth. Ketua Program Studi Teknologi Rekayasas Komputer
Politeknik Negeri Semarang

Yang bertanda tangan di bawah ini, Pembimbing I dan Pembimbing II menerangkan bahwa:

No.	Nama	NIM	Kelas
1	Choiruzzia Abdilla Audivatsani	4.33.20.0.05	TI-4A

Dengan judul Tugas Akhir:

" Analisis Sentimen pada Big Data Kasus Stunting di Indonesia (Tahun 2019-2024) "

Benar-benar telah menyelesaikan pembuatan skripsi dan siap untuk melakukan ujian wawancara skripsi.

Semarang, 10 Juli 2023

Pembimbing I,

Dr. Ir. Kurnianingsih, S.T., M.T.
NIP 197904262003122002

Pembimbing II,

Wiktasari S.T., M.Kom
NIP 198703272019022012

Lampiran 4 Surat Tugas

KEMENTERIAN PENDIDIKAN, KEBUDAYAAN,
RISET, DAN TEKNOLOGI
POLITEKNIK NEGERI SEMARANG
Jalan Prof. H. Soedarto, S.H, Tembalang, Semarang 50275, PO BOX 6199/SMS
Telephone (024) 7473417, 7499585, 7499586, Facsimile (024) 7472396
http://www.polines.ac.id, E-mail : sekretariat@polines.ac.id

Jurusan T. Elektro POLINES	SURAT TUGAS NO. 3256/PL4.1.3/PK/2024	

Ketua Jurusan Teknik Elektro memberi tugas kepada Tim Penguji Skripsi berikut ini :

NO.	JABATAN	NAMA PENGUJI	NIP
1.	Ketua Penguji	Dr. IR. KURNIANINGSIH, S.T., M.T.	197904262003122002
2.	Sekretaris	ERI ELI LAVINDI, M.KOM.	199601142022032014
3.	Penguji I	IDHAWATI HESTININGSIH, S.KOM, M.KOM.	197711192008012013
4.	Penguji II	AFANDI NUR AZIZ THOHARI, S.T., M.CS.	199004112019031014
5.	Penguji III	NURSENO BAYU AJI, S.KOM., M.KOM.	199107302019031010

Untuk menguji mahasiswa tersebut :

NO.	NAMA	NIM	KELAS
1.	CHOIRUZZIA ABDILLA AUDIVATSANI	4.33.20.0.05	TI-4A

Yang didampingi Pembimbing sebagai berikut :

NO.	JABATAN	NAMA PEMBIMBING	NIP
1.	Pembimbing I	Dr. IR. KURNIANINGSIH, S.T., M.T.	197904262003122002
2.	Pembimbing II	WIKTASARI, S.T., M.KOM.	198703272019032012

Dengan Judul Skripsi :
"ANALISIS SENTIMEN PADA BIG DATA KASUS STUNTING DI INDONESIA (TAHUN 2019-2024)".

Yang dilaksanakan pada waktu sebagai berikut :
Hari, tanggal : Jum'at / 12 Juli 2024
Waktu : 09.00 – 10.30 WIB
Tempat : R. Lab. Komputer

Tugas ini supaya dijalankan dengan sebaik-baiknya dan hasilnya dilaporkan kepada Jurusan.

Semarang, 11 Juli 2024
Ketua Jurusan Teknik Elektro,

YUSNAN BADRUZZAMAN, S.T.,M.ENG.
NIP. 197503132006041001

Diserahkan ke Tim Penguji Tugas Akhir (lima orang) dan Pembimbing paling lambat tiga hari sebelum ujian, beserta naskah Tugas Akhir untuk Penguji.

Lampiran 5 Lembar Revisi Skripsi

	FORMULIR PROSEDUR	No. PM	F.PPd.4.08-L1
	LEMBAR REVISI SKRIPSI	Revisi	3
		Tanggal	21.12.2017
		Halaman	1 / 3

No	Uraian	Tandatangan Penguji
1	Revisi saran nomor 2	
2	Filter data tahun di youtube	

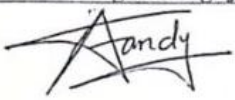
Semarang, 12 Juli 2024

Penguji I,

Idhawati Hestiningsih, S. Kom., M. Kom.

NIP. 197711192008012013

	FORMULIR PROSEDUR	No. PM	F.PPd.4.08-L1
	LEMBAR REVISI SKRIPSI	Revisi	3
		Tanggal	21.12.2017
		Halaman	2 / 3

No	Uraian	Tandatangan Penguji
1	Lihat di Laporan	

Semarang, 12 Juli 2024

Penguji II,



Afandi Nur Aziz Thohari, S.T., M.Cs.

NIP. 199004112019031014

	FORMULIR PROSEDUR	No. PM	F.PPd.4.08-L1
	LEMBAR REVISI SKRIPSI	Revisi	3
		Tanggal	21.12.2017
		Halaman	3 / 3

No	Uraian	Tandatangan Penguji
1	Tambah gambar CRISP-DM dan Confusion Matrix	
2	Tambah penjelasan kata kunci di youtube	
3	Training model dengan epoch 100	
4	Penanganan kelas tidak seimbang	

Semarang, 12 Juli 2024

Penguji III,

Nurseno Bayu Aji, S.Kom., M.Kom.

NIP. 199107302019031010

Lampiran 6 Pernyataan Telah Melakukan Revisi

	FORMULIR PROSEDUR	No. FP	F.PPd.4.08-L3
	REVISI SKRIPSI	Revisi	3
		Tanggal	21.12.2017
		Halaman	1 / 1

Yang bertanda tangan di bawah ini, Penguji I/II/III menerangkan bahwa:

No.	Nama	NIM	Kelas
1	Choiruzzia Abdilla Audivatsani	4.33.20.0.05	TI-4A

Dengan judul Skripsi :

Analisis Sentimen pada Big Data Kasus Stunting di Indonesia (Tahun 2019-2024)

Benar-benar telah melaksanakan revisi skripsi. Surat keterangan ini dapat dipergunakan sebagaimana mestinya.

Semarang, 12 Juli 2024

Penguji I,	Penguji II,	Penguji III,
Idhawati Hestiningsih, S. Kom., M. Kom.	Afandi Nur Aziz Thohari, S.T., M.Cs.	Nurseno Bayu Aji, S.Kom., M.Kom.
NIP. 197711192008012013	NIP. 199004112019031014	NIP. 199107302019031010

Lampiran 7 Kode Program *Scraping*

```
from requests import get
from urllib.parse import urlsplit
from bs4 import BeautifulSoup

class DetikNewsApi:

    def __init__(self):
        """ Search URL"""
        self.search_url                                                 =
'https://www.detik.com/search/searchall?'

    def build_search_url(self, query: str, page_number: int):
        """ Building search url with query input, we can jump to
specific page number"""
        qs = f'query={query}'
        qs2                                                             =
'&siteid=2&sortby=time&fromdatex=01/01/2019&todatex=25/04/2024&r
esult_type=relevansi&page='
        return self.search_url + qs + qs2 + str(page_number)

    def build_detail_url(self, url: str):
        """ Build detail URL will turn off pagination in detail
page """
        a = urlsplit(url)
        qs = 'single=1'
        detail_url = a.scheme + '://' + a.netloc + a.path + '?'
+ qs
        return detail_url

    def result_count(self, search_response):
        """ Search result count, need search response page """
        soup = BeautifulSoup(search_response.text, 'html.parser')
        tag = soup.find('span', 'fl text').text
        count = [int(s) for s in tag.split() if s.isdigit()]
        return count[0]

    def detail(self, url: str) -> str:
        detail_url = self.build_detail_url(url)
        req = get(detail_url)
        soup = BeautifulSoup(req.text, 'html.parser')
        tag = soup.find('div', class_="detail__body-text")
        body = ''
        if tag.find_all('p'):
            for i in tag.find_all('p'):
                body += i.text
        else:
            body += tag.text

        return body

    def get_comments(self, url: str) -> list:
        detail_url = self.build_detail_url(url)
        req = get(detail_url)
        soup = BeautifulSoup(req.text, 'html.parser')
        comment_tags     =     soup.select('.komentar-iframe-min-
media__desc')
        comments = []
```

```
        for comment_tag in comment_tags:
            comments.append(comment_tag.text.strip())
        return comments

    def parse(self, search_response, detail):
        soup = BeautifulSoup(search_response.text, 'html.parser')
        tag = soup.find_all('article')
        data = []

        for i in tag:
            judul = i.find('h2').text
            link = i.find('a').get('href')
            gambar = i.find('img').get('src')
            body = ''
            if detail:
                body = self.detail(link)

            comments = []
            if detail:
                comments = self.get_comments(link)

            waktu = i.find('span', class_="date").text
            data.append({'judul': judul,
                    'link': link,
                    'gambar': gambar,
                    'body': body,
                    'waktu': waktu,
                    'comments': comments
                    })
        return data

    def search(self, query, page_number=1, detail=False):
        url = self.build_search_url(query, page_number)
        search_response = get(url)
        parse_result = self.parse(search_response, detail)
        return parse_result

detik = DetikNewsApi()

isi = []

for i in range(10):
    # method search(query, page_number, detail)
    page_num = i+1
    print(f"Scrape page ke-{page_num}")
    res_detik = detik.search('stunting', page_num, True)
    print(res_detik)
    print()
    isi.extend(res_detik)

...
```

Kode program *scraping* yang lebih lengkap dapat dilihat pada url berikut:

https://github.com/choiruzzia/Skripsi

Lampiran 8 Kode Program *Preprocessing*

```
import pandas as pd
import re
from Sastrawi.Stemmer.StemmerFactory import StemmerFactory
import os
import shutil
from multiprocessing import Pool, cpu_count
import pandas as pd
import nltk
from nltk.corpus import stopwords
from nltk.tokenize import word_tokenize
nltk.download('stopwords')
nltk.download('punkt')

nom_text = pd.read_csv(dest_path + "colloquial-indonesian-
lexicon.csv")

def remove_special_characters(text):
    url_pattern = r'https?://\S+|www\.\S+'
    special_char_pattern = r'[^\w\s]|\d'
    pattern = r'(ADVERTISEMENT|SCROLL TO CONTINUE WITH
CONTENT|\r|\n|\s{2,})'

    text_without_urls = re.sub(url_pattern, ' ', text)
    text_without_advertisement = re.sub(pattern, ' ',
text_without_urls, flags=re.IGNORECASE)
    cleaned_text = re.sub(r'@\w+', ' ',
text_without_advertisement)
    cleaned_text2 = re.sub(r'[^\x00-\x7F]', ' ', cleaned_text)
    cleaned_text3 = re.sub(special_char_pattern, ' ',
cleaned_text2)
    cleaned_text4 = re.sub(r'\s+', ' ', cleaned_text3)
    # cleaned_text2 = cleaned_text.replace('  ', ' ')

    return cleaned_text4

def remove_stopwords(text):
    stopwords_indo = set(stopwords.words('indonesian'))
    word_tokens = word_tokenize(text)
    filtered_text = [word for word in word_tokens if word.lower()
not in stopwords_indo]
    return " ".join(filtered_text)

factory = StemmerFactory()
stemmer = factory.create_stemmer()

def stemming(teks):
  stemmed = stemmer.stem(teks)
  return stemmed

def parallel_stem_texts(texts, batch_size=100):
    total_texts = len(texts)
    with Pool(cpu_count()) as pool:
        result = []
        for i in range(0, total_texts, batch_size):
            batch = texts[i:i + batch_size]
            print(f"Starting stemming for texts {i + 1} to {i +
len(batch)} out of {total_texts}")
```

```
            stemmed_batch = pool.map(stemming, batch)
            result.extend(stemmed_batch)
            print(f"Processed   {i   +   len(batch)}   out   of
{total_texts} texts")
    return result

detik = pd.read_csv(dest_path + "detikcom_all.csv")
isi = detik["body"].str.lower()
isi1 = pd.Series(isi1)
isi2 = isi1.apply(remove_special_characters)
isi3 = isi2.drop_duplicates(keep="first")
clean = isi3[isi3!=" "]
clean2 = clean.apply(remove_stopwords)
clean3 = parallel_stem_texts(clean2.to_list())

...
```

Kode program *preprocessing* yang lebih lengkap dapat dilihat pada url berikut:

https://colab.research.google.com/drive/1e1RKOiMu93aFFqT7dqKXoOftLHugh5CV?authuser=1#scrollTo=1OCgT1DpvGea

Lampiran 9 Kode Program Pelatihan Model

```
import pandas as pd
import numpy as np
from datasets import Dataset
from         transformers         import         BertTokenizer,
BertForSequenceClassification, set_seed
from    sklearn.metrics    import    accuracy_score,    f1_score,
precision_score, recall_score, classification_report
import wandb
from transformers import Trainer, TrainingArguments, set_seed
from sklearn.model_selection import KFold
import tensorflow as tf

df = pd.read_csv("/kaggle/working/train_berita_resampled2.csv")
test = pd.read_csv("/kaggle/working/test_berita.csv")
label_dict = {'positive': 0, 'neutral': 1, 'negative': 2,}
df['label'] = df['label'].map(label_dict).tolist()
df["label"].value_counts(), test["label"].value_counts()
label_dict = {'positive': 0, 'neutral': 1, 'negative': 2,}
test['label'] = test['label'].map(label_dict).tolist()
X_train = Dataset.from_pandas(df)
X_test = Dataset.from_pandas(test)

max_length = 512
tokenizer   =   BertTokenizer.from_pretrained("ayameRushia/bert-
base-indonesian-1.5G-sentiment-analysis-smsa",
max_length=max_length)
def tokenize_function(examples):
    # process the input sequence
    tokenized_input = tokenizer(examples["text"],
                                truncation=True,
                                padding='max_length',
```

```
                                    max_length=max_length)
    # process the labels
    tokenized_input['label'] = examples['label']
    return tokenized_input

tokenized_train_data      =      X_train.map(tokenize_function,
batched=True)
tokenized_test_data = X_test.map(tokenize_function, batched=True)

def compute_metrics(p):
    pred, labels = p
    pred = np.argmax(pred, axis=1)

    report = classification_report(labels, pred, digits=4)
    acc = accuracy_score(y_true=labels, y_pred=pred)
    rec     =     recall_score(y_true=labels,     y_pred=pred,
average="macro")
    prec    =    precision_score(y_true=labels,    y_pred=pred,
average="macro")
    f1 = f1_score(y_true=labels, y_pred=pred, average="macro")

    print("Classification Report:\n{}".format(report))
    return {"accuracy": acc, "precision": prec, "recall": rec,
"f1": f1}

wandb.init(mode="disabled")

kfold = KFold(n_splits=5, shuffle=True, random_state=42)
best_accuracy = 0.0

np.random.seed(42)
tf.random.set_seed(42)
set_seed(42)

for         fold,         (train_idx,         val_idx)         in
enumerate(kfold.split(tokenized_train_data)):
    if fold != 4:
        continue
    print(f"Training fold {fold}...")
    train_dataset = tokenized_train_data.select(train_idx)
    val_dataset = tokenized_train_data.select(val_idx)

    model = BertForSequenceClassification.from_pretrained(
        "ayameRushia/bert-base-indonesian-1.5G-sentiment-
analysis-smsa",
        num_labels=3
    )

    output_dir = f"./22best_berita_bert_model_fold_{fold+1}"
    training_args = TrainingArguments(
        output_dir=output_dir,
        eval_strategy="epoch",
        save_strategy="epoch",
        num_train_epochs=10,  # Sesuaikan jumlah epoch
        per_device_train_batch_size=8,  # Sesuaikan batch size
        per_device_eval_batch_size=8,
        load_best_model_at_end=True,
        metric_for_best_model="accuracy",
    )
```

```
    trainer = Trainer(
        model=model,
        args=training_args,
        tokenizer=tokenizer,
        train_dataset=train_dataset,
        eval_dataset=val_dataset,
        compute_metrics=compute_metrics,
    )

    trainer.train()

    # Evaluasi pada validation set
    metrics = trainer.evaluate()
    accuracy = metrics["eval_accuracy"]
    print(accuracy)
    if accuracy > best_accuracy:
        best_accuracy = accuracy
#         trainer.save_model(output_dir)  # Simpan model terbaik

...
```

Kode program pelatihan model yang lebih lengkap dapat dilihat pada url berikut: https://github.com/choiruzzia/Skripsi

Lampiran 10 Kode Program *Deployment*

```
import rootutils

ROOT = rootutils.autosetup()

import numpy as np
import streamlit as st

from src.engine.model_engine import load_model_state

LABEL_DICT = {
    "Positif": 0,
    "Netral": 1,
    "Negatif": 2,
}

st.set_page_config(
    page_title="Stunting Sentiment Analysis",
    layout="wide",
)


def main():
    bert_berita, roberta_medsos = load_model_state()

    st.title("Stunting Sentiment Analysis")
    st.write(
        "This is a simple web app to predict sentiment analysis
of stunting in Indonesia."
```

```
    )

    text = st.text_area("Enter text here")
    model_type = st.selectbox("Select model", ["BERT Berita",
"RoBERTa Medsos"])

    if st.button("Predict"):
        if model_type == "BERT Berita":
            model = bert_berita
        elif model_type == "RoBERTa Medsos":
            model = roberta_medsos

        inputs = model.tokenize(text)
        _, preds = model.predict(inputs)

        sentiment = np.argmax(preds)
        sentiment                                                    =
list(LABEL_DICT.keys())[list(LABEL_DICT.values()).index(sentimen
t)]

        st.write(f"Predicted sentiment: {sentiment}")


if __name__ == "__main__":
    main()

...
```

Kode program *deployment* yang lebih lengkap dapat dilihat pada url berikut:

https://github.com/choiruzzia/deploy-stunting